





دانشگاه تربیت مدرس

دانشکده مهندسی برق و کامپیوتر

رساله دکتری در رشته مهندسی کامپیوتر

گرایش مهندسی نرم افزار

یادگیری تقویتی عمیق با شکل دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم های خودوفقی

علیرضا کاویانی فر

استاد راهنما

دکتر ...

استاد مشاور

دکتر ...

بهمن ۱۴۰۴

تأییدیهی هیأت داوران جلسهی دفاع از رساله

خانم/آقای علیرضا کاویانی فر رساله — واحدی خود را با عنوان یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم‌های خودوفقی در تاریخ بهمن ۱۴۰۴ ارائه کردند. اعضای هیأت داوران نسخه نهایی این رساله را از نظر فرم و محتوا تایید کرده است و پذیرش آنرا برای تکمیل درجه دکتری پیشنهاد می‌کنند.

آیین نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهشهای

علمی دانشگاه تربیت مدرس

مقدمه: با عنایت به سیاست های پژوهشی و فناوری دانشگاه در راستای تحقق عدالت و کرامت انسانها که لازمه شکوفایی علمی و فنی است و رعایت حقوق مادی و معنوی دانشگاه و پژوهشگران، لازم است اعضای هیأت علمی، دانشجویان، دانش آموختگان و دیگر همکاران طرح، در مورد نتایج پژوهشهای علمی که تحت عناوین پایان نامه، رساله و طرحهای تحقیقاتی با هماهنگی دانشگاه انجام شده است، موارد زیر را رعایت نمایند:

ماده ۱- حق نشر و تکثیر پایان نامه/رساله و درآمدهای حاصل از آنها متعلق به دانشگاه می باشد ولی حقوق معنوی پدید آورندگان محفوظ خواهد بود.

ماده ۲- انتشار مقاله یا مقالات مستخرج از پایان نامه/رساله به صورت چاپ در نشریات علمی و یا ارائه در مجامع علمی باید به نام دانشگاه بوده و با تایید استاد راهنمای اصلی، یکی از اساتید راهنما، مشاور و یا دانشجو مسئول مکاتبات مقاله باشد. ولی مسئولیت علمی مقاله مستخرج از پایان نامه و رساله به عهده اساتید راهنما و دانشجو می باشد. تبصره: در مقالاتی که پس از دانش آموختگی بصورت ترکیبی از اطلاعات جدید و نتایج حاصل از پایان نامه/رساله نیز منتشر می شود نیز باید نام دانشگاه درج شود.

ماده ۳- انتشار کتاب، نرم افزار و یا آثار ویژه (اثری هنری مانند فیلم، عکس، نقاشی و نمایشنامه) حاصل از نتایج پایان نامه/رساله و تمامی طرحهای تحقیقاتی کلیه واحدهای دانشگاه اعم از دانشکده ها، مراکز تحقیقاتی، پژوهشکده ها، پارک علم و فناوری و دیگر واحدها باید با مجوز کتبی صادره از معاونت پژوهشی دانشگاه و براساس آئین نامه های مصوب انجام شود.

ماده ۴- ثبت اختراع و تدوین دانش فنی و یا ارائه یافته ها در جشنواره های ملی، منطقه ای و بین المللی که حاصل نتایج مستخرج از پایان نامه/رساله و تمامی طرحهای تحقیقاتی دانشگاه باید با هماهنگی استاد راهنما یا مجری طرح از طریق معاونت پژوهشی دانشگاه انجام گیرد.

ماده ۵- این آیین نامه در ۵ ماده و یک تبصره در تاریخ ۸۷/۴/۱ در شورای پژوهشی و در تاریخ ۸۷/۴/۲۳ در هیأت رئیسه دانشگاه به تایید رسید و در جلسه مورخ ۸۷/۷/۱۵ شورای دانشگاه به تصویب رسیده و از تاریخ تصویب در شورای دانشگاه لازم الاجرا است.

اینجانب علیرضا کاویانی فر به شماره دانشجویی ... دانشجوی رشته مهندسی کامپیوتر مقطع تحصیلی دکتری دانشکده مهندسی برق و کامپیوتر متعهد می شوم کلیه نکات مندرج در آئین نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهش های علمی دانشگاه تربیت مدرس را در انتشار یافته های علمی مستخرج از

پایان نامه/رساله تحصیلی خود رعایت نمایم. در صورت تخلف از مفاد آئین نامه فوق الاشعار به دانشگاه وکالت و نمایندگی می دهم که از طرف اینجانب نسبت به لغو امتیاز اختراع بنام بنده و یا هر گونه امتیاز دیگر و تغییر آن به نام دانشگاه اقدام نماید. ضمناً نسبت به جبران فوری ضرر و زیان حاصله بر اساس برآورد دانشگاه اقدام خواهم نمود و بدینوسیله حق هر گونه اعتراض را از خود سلب نمودم»

تاریخ و امضا:

آیین نامه چاپ پایان نامه (رساله) های دانشجویان دانشگاه تربیت

مدرس

نظر به اینکه چاپ و انتشار پایان نامه (رساله) های تحصیلی دانشجویان دانشگاه تربیت مدرس، مبین بخشی از فعالیتهای علمی- پژوهشی دانشگاه است بنابراین به منظور آگاهی و رعایت حقوق دانشگاه، دانش آموختگان این دانشگاه نسبت به رعایت موارد ذیل متعهد می شوند: ماده ۱: در صورت اقدام به چاپ پایان نامه (رساله) ی خود، مراتب را قبلاً به طور کتبی به «دفتر نشر آثار علمی» دانشگاه اطلاع دهد. ماده ۲: در صفحه سوم کتاب (پس از برگ شناسنامه) عبارت ذیل را چاپ کند: «کتاب حاضر، حاصل پایان نامه کارشناسی ارشد/ رساله دکتری نگارنده در رشته مهندسی کامپیوتر است که در بهمن ۱۴۰۴ در دانشکده مهندسی برق و کامپیوتر دانشگاه تربیت مدرس به راهنمایی سرکار خانم/جناب آقای دکتر ...، مشاوره سرکار خانم/جناب آقای دکتر ... از آن دفاع شده است.» ماده ۳: به منظور جبران بخشی از هزینه های انتشارات دانشگاه، تعداد یک درصد شمارگان کتاب (در هر نوبت چاپ) را به «دفتر نشر آثار علمی» دانشگاه اهدا کند. دانشگاه می تواند مازاد نیاز خود را به نفع مرکز نشر در معرض فروش قرار دهد. ماده ۴: در صورت عدم رعایت ماده ۳، ۵۰٪ بهای شمارگان چاپ شده را به عنوان خسارت به دانشگاه تربیت مدرس، تأدیه کند. ماده ۵: دانشجو تعهد و قبول می کند در صورت خودداری از پرداخت بهای خسارت، دانشگاه می تواند خسارت مذکور را از طریق مراجع قضایی مطالبه و وصول کند؛ به علاوه به دانشگاه حق می دهد به منظور استیفای حقوق خود، از طریق دادگاه، معادل وجه مذکور در ماده ۴ را از محل توقیف کتابهای عرضه شده نگارنده برای فروش، تامین نماید. ماده ۶: اینجانب علیرضا کاویانی فر دانشجوی رشته مهندسی کامپیوتر مقطع دکتری تعهد فوق و ضمانت اجرایی آن را قبول کرده، به آن ملتزم می شوم.

استاد راهنما: دکتر ...

تاریخ:

امضا:

تقديم

(متن تقديم به خانواده، اساتيد و ...)

قدردانی

(متن تشکر و قدردانی از اساتید راهنما، مشاور و دوستان)

علیرضا کاویانی فر

بهمن ۱۴۰۴

چکیده

سیستم‌های نرم‌افزاری معاصر به طور فزاینده‌ای در محیط‌های پویا و همراه با عدم قطعیت عمل می‌کنند. این عدم قطعیت‌ها که ناشی از عواملی مانند تداخل شبکه، نوسانات بار ترافیکی یا تغییرات محیطی هستند، می‌توانند به طور جدی اهداف کیفی سیستم را به خطر اندازند. سیستم‌های خودوقفی (Self-Adaptive Systems) با بهره‌گیری از حلقه‌های بازخوردی، راهکاری بنیادین برای مقابله با این چالش ارائه می‌دهند. با این حال، چالش اصلی زمانی بروز می‌کند که این سیستم‌ها با فضای و فقی وسیع (شامل صدها یا هزاران گزینه پیکربندی) مواجه می‌شوند. روش‌های موجود، از جمله روش‌های مبتنی بر یادگیری ماشین، جستجو، و حتی یادگیری تقویتی کلاسیک، در چنین فضاهایی با مشکلاتی نظیر نیاز به داده‌های برجسته‌دار، عدم مقیاس‌پذیری، و مهم‌تر از همه، گرفتار شدن در بهینه‌های محلی و عدم توانایی تعمیم به شرایط محیطی جدید مواجه هستند. هدف اصلی این رساله، توسعه و اعتبارسنجی روشی نوین مبتنی بر یادگیری تقویتی عمیق با مکانیسم شکل‌دهی تصادفی پاداش (Randomized Reward-Shaped Deep Reinforcement Learning - RS-DRL) برای مدیریت کارآمد عدم قطعیت در این سیستم‌ها است. روش پیشنهادی، هسته یادگیری خود را بر پایه شبکه‌های کیو-عمیق (DQN) استوار ساخته و آن را درون چارچوب استاندارد مدیریت خودمختار MAPE-K یکپارچه می‌سازد. در این معماری، سیگنال محیطی با نتایج حاصل از بازبینی صوری توسط ابزار UPPAAL-SMC ترکیب شده تا عامل یادگیرنده تحت هدایت محدودیت‌های صوری آموزش ببیند. نوآوری اصلی رساله، مکانیسم «شکل‌دهی تصادفی پاداش» است که طی آن، زیرمجموعه‌ای تصادفی از تجربیات ناموفق گذشته با تخصیص پاداش خوش‌بینانه بازطراحی می‌شوند. اگرچه پیکربندی مدل صوری نیازمند دانش دامنه است، اما مکانیسم شکل‌دهی تصادفی پیشنهادی به خودی خود مستقل از دامنه بوده و نیاز به دانش صریح از اهداف (Domain Knowledge) برای اکتشاف ندارد. ارزیابی تجربی بر روی مطالعه موردی DeltaIoT (در شبکه‌های حسگر بی‌سیم) با فضاهای و فقی تا ۴۰۹۶ گزینه، نشان‌دهنده برتری قاطع روش RS-DRL نسبت به روش‌های پایه از جمله DQN، HER، Soft HER و DLASER+ است. به عنوان مثال، در هدف آستانه‌ای TT، روش پیشنهادی موفق به کاهش نرخ اتلاف بسته تا 23.22% و کاهش تأخیر تا 39.07% در مقایسه با روش DLASER+ به عنوان قوی‌ترین رقیب پژوهش گردید. تحلیل‌های آماری معنادار صحت و استواری نتایج را در شرایط پویای محیطی تأیید می‌کنند. یافته‌های این رساله نشان می‌دهد که رویکرد RS-DRL یک استراتژی بهینه‌سازی مقاوم و خودوقف برای نسل بعدی سیستم‌های نرم‌افزاری پیچیده است.

واژگان کلیدی: سیستم‌های خودوقفی، یادگیری تقویتی عمیق، شکل‌دهی تصادفی پاداش، مدیریت عدم قطعیت، بازبینی صوری، UPPAAL-SMC، فضاهای و فقی بزرگ، اینترنت اشیاء، شبکه‌های حسگر بی‌سیم

فهرست مطالب

ث	تقدیم
ژ	فهرست جداول
ش	فهرست تصاویر
ض	فهرست نشانه‌ها و اختصارات
۱	فصل ۱: کلیات
۱	۱-۱ مقدمه
۲	۲-۱ اهداف رساله
۳	۳-۱ چالش‌ها
۴	۴-۱ بیان مساله
۸	۵-۱ سؤالات پژوهش
۹	۶-۱ روش پیشنهادی
۹	۱-۶-۱ مرور کلی بر راهکار RS-DRL
۹	۲-۶-۱ یکپارچه سازی راهکار RS-DRL با حلقه کنترلی MAPE-K
۱۰	۷-۱ نوآوری‌های اصلی رساله
۱۲	۸-۱ مروری بر فصول رساله
۱۴	فصل ۲: مبانی نظری و مدل سازی سیستم
۱۴	۱-۲ مقدمه
۱۵	۲-۲ مبانی سیستم‌های خودوفقی
۱۵	۱-۲-۲ مفاهیم اصلی و تعاریف
۱۵	۲-۲-۲ معماری‌های مرجع و الگوهای طراحی

۱۶	حلقه‌های کنترلی خودمختار: از MAPE-K تا موارد پیشرفته	۳-۲-۲
۱۷	عدم قطعیت در سیستم‌های خودوفقی	۳-۲
۱۷	دسته‌بندی و انواع عدم قطعیت	۱-۳-۲
۱۸	روش‌های مدل‌سازی و رویارویی با عدم قطعیت	۲-۳-۲
۱۸	چالش‌های خاص عدم قطعیت در فضاها و فقی بزرگ	۳-۳-۲
۱۹	مبانی نظری و مدل‌سازی ریاضی	۴-۲
۱۹	فرآیندهای تصمیم‌گیری مارکوف، یادگیری تقویتی و DQN	۱-۴-۲
۲۴	سیستم مورد مطالعه: شبکه‌های حسگر بی‌سیم DeltaIoT	۵-۲
۲۴	معماری، مؤلفه‌ها و ویژگی‌های فیزیکی	۱-۵-۲
۲۵	مدل‌سازی فیزیکی و ریاضیاتی پدیده‌های کانال بی‌سیم	۲-۵-۲
۲۶	جزئیات فرمول‌بندی معیارهای کیفیت خدمات (QoS) در فضای حالت	۳-۵-۲
۲۷	سناریوهای عدم قطعیت و فضای فقی	۴-۵-۲
۲۸	فرمول‌بندی به عنوان MDP	۵-۵-۲
۲۹	بیان مسئله و چارچوب بهینه‌سازی	۶-۲
۲۹	تعریف سیاست بهینه	۱-۶-۲
۲۹	تحلیل پیچیدگی مسئله تطبیق و ضرورت یادگیری تقویتی	۲-۶-۲
۳۱	قیود عملیاتی زمان اجرا	۳-۶-۲
۳۱	سیستم مورد مطالعه دوم: شبیه‌ساز مأموریت پهباد DARTSim	۷-۲
۳۲	خاستگاه علمی و جایگاه به عنوان محک	۱-۷-۲
۳۲	فضای معنایی سیستم (Semantic Space)	۲-۷-۲
۳۳	اهداف و الزامات وابستگی‌پذیری	۳-۷-۲
۳۴	معماری، مؤلفه‌ها و ویژگی‌های فیزیکی	۴-۷-۲
۳۴	جزئیات فرمول‌بندی معیارهای کیفیت خدمات (QoS) در فضای حالت	۵-۷-۲
۳۴	سناریوهای عدم قطعیت و فضای فقی	۶-۷-۲
۳۵	مدل‌سازی عدم قطعیت محیطی و تصادفی بودن حسگرها	۷-۷-۲
۳۵	فرمول‌بندی به عنوان MDP	۸-۷-۲
۳۶	محیط انطباق آفلاین (Offline Replay Adapter)	۹-۷-۲
۳۸	طیف دشواری محیط و فضای طراحی سناریوها	۱۰-۷-۲
۳۹	خلاصه فصل	۸-۲

فصل ۳: مرور پیشینه پژوهش و کارهای مرتبط ۴۰

- ۱-۳ مقدمه و روش شناسی مرور ۴۰
- ۲-۳ مبانی نظری: عدم قطعیت و تصمیم گیری در سیستم های خوددوفق ۴۱
- ۳-۳ رویکردهای اصلی مدیریت فضای وفقی در زمان اجرا ۴۲
- ۱-۳-۳ هرس فضای وفقی مبتنی بر یادگیری ماشین سنتی ۴۳
- ۲-۳-۳ روش های مبتنی بر جستجوی آنالین و استراتژی های اکتشافی ۴۴
- ۳-۳-۳ یادگیری تقویتی زمان اجرا و کنترل خودمختار ۴۴
- ۴-۳ تکنیک های پیشرفته یادگیری تقویتی: کاوش، شکل دهی پاداش و نگاه به گذشته ۴۵
- ۱-۴-۳ چالش های استراتژی کاوش در فضاهای وفقی بزرگ ۴۶
- ۲-۴-۳ ناکارآمدی مکانیزم بازپخش تجربه با نگاه به گذشته (HER) در محیط های آستانه محور ۴۶
- ۳-۴-۳ مبانی نظری و ریاضیاتی شکل دهی پاداش ۴۷
- ۵-۳ ارزیابی و تایید صوری در فرآیند خوددوفق سازی ۴۹
- ۱-۵-۳ تأیید صوری کمی زمان اجرا (QVR) ۴۹
- ۲-۵-۳ چارچوب های ActivFORMS و ابزار UPPAAL-SMC ۵۰
- ۳-۵-۳ معماری های ترکیبی یادگیری و ارزیابی صوری (مدل های ترادف) ۵۰
- ۶-۳ سنتز: شکاف تحقیقاتی سه گانه و موقعیت دهی علمی RS-DRL ۵۱
- ۱-۶-۳ ماتریس ارزیابی و سنتز پیشینه پژوهش ۵۱
- ۲-۶-۳ شکاف تحقیقاتی سه گانه ۵۱
- ۳-۶-۳ موقعیت دهی علمی معماری پیشنهادی RS-DRL ۵۳
- ۷-۳ خلاصه فصل ۵۴

فصل ۴: روش پیشنهادی ۵۷

- ۱-۴ مقدمه ۵۷
- ۲-۴ اصول معماری سطح بالا و سازماندهی فرآیند ۵۸
- ۱-۲-۴ مقایسه تطبیقی معماری پیشنهادی با رویکردهای پیشرفته ۵۹
- ۳-۴ فرآیند یکپارچه خوددوفقی: حلقه سطح سیستم ۶۰
- ۴-۴ مسیر تصمیم گیری آنالین: بررسی گام به گام معماری ۶۲
- ۱-۴-۴ گام اول: پایش و ساخت وضعیت (Monitor) ۶۲
- ۲-۴-۴ گام دوم: تحلیل و تشخیص ضرورت تطبیق (Analyze) ۶۳

۶۳	۳-۴-۴ گام سوم: برنامه‌ریزی و استنتاج تطبیقی (Plan)
۶۴	۴-۴-۴ گام چهارم: اعتبارسنجی، بازخورد و اجرا (شامل Execute و Knowledge)
۶۴	۵-۴-۴ سناریوهای گام به گام و ملموس از چرخه تصمیم‌گیری زمان اجرا
۶۴	۱-۵-۴-۴ سناریوی اول: شبکه ساده دو گره‌ای با قید واحد
۶۵	۲-۵-۴-۴ سناریوی دوم: شبکه پیچیده ۴ گره‌ای با اهداف متضاد کیفیت خدمات
۶۷	۵-۴ معماری داخلی RS-DRL: تفکیک دغدغه‌ها در فرآیند یادگیری
۶۹	۶-۴ مکانیزم هسته: شکل دهی تصادفی پاداش
۷۲	۱-۶-۴ متدولوژی تنظیم فرایارامترها و فرآیند جستجوی شبکه‌ای فاکتور ρ
۷۵	۷-۴ مدیریت دانش و هماهنگی جریان‌های ناهمگام
۷۶	۸-۴ ادغام اعتبارسنجی صوری زمان اجرا و ایمنی احتمالی
۷۷	۱-۸-۴ جزئیات شبیه‌سازی احتمالی و کران ریاضی تعداد نمونه‌ها (SMC Bound)
	۲-۸-۴ تحلیل غیرانسدادی زمان‌بندی اعتبارسنجی ناهمگام (Non-Blocking Temporal
۷۸	Timing)
۷۸	۹-۴ پوشش پرسش‌های پژوهش
۷۸	۱-۹-۴ پاسخ صوری به سوال اول (RQ1) - فرار از بهینه‌های محلی
۸۰	۲-۹-۴ پاسخ صوری به سوال دوم (RQ2) - ادغام یادگیری و بازپخش تجربه
۸۰	۳-۹-۴ پاسخ صوری به سوال سوم (RQ3) - مدیریت فضاها بزرگ و مقیاس‌پذیری
۸۰	۴-۹-۴ پاسخ صوری به سوال چهارم (RQ4) - تمایز، برتری و استقلال از دانش دامنه
۸۱	۱۰-۴ بحث پیرامون مفروضات متدولوژی پیشنهادی
۸۱	۱-۱۰-۴ فرض فضای اقدام گسسته در شبکه‌های خودوفق
۸۱	۲-۱۰-۴ آگاهی و پایداری آستانه‌های کیفیت خدمات
۸۲	۳-۱۰-۴ در دسترس بودن مدل صوری پویای سیستم در زمان اجرا
۸۲	۱۱-۴ خلاصه فصل
۸۲	۱-۱۱-۴ محدودیت‌های روش پیشنهادی

فصل ۵: ارزیابی تجربی

۸۴	۱-۵ مقدمه
۸۴	۲-۵ اهداف ارزیابی و سوالات تحقیق
۸۵	۳-۵ تنظیمات آزمایشگاهی

۸۵	۱-۳-۵ نمونه‌های مطالعه موردی
۸۶	۲-۳-۵ مجموعه داده‌ها
۸۶	۳-۳-۵ پلتفرم پیاده‌سازی
۸۶	۴-۳-۵ تنظیمات فرایارامترها (Hyperparameters)
۸۷	۴-۵ روش‌های پایه و مقایسه
۸۷	۵-۵ معیارهای ارزیابی
۸۸	۱-۵-۵ معیارهای عملکرد یادگیری عامل هوشمند
۸۸	۲-۵-۵ معیارهای عملکرد سیستم
۸۹	۶-۵ نتایج و تحلیل‌ها
۸۹	۱-۶-۵ منحنی‌های یادگیری و رفتار همگرایی
۹۰	۲-۶-۵ مقایسه عملکرد به ازای هر هدف
۹۱	۳-۶-۵ ارزیابی مقایسه‌ای در برابر تمام روش‌های پایه
۹۲	۴-۶-۵ مطالعه ابلیشن: حساسیت به فاکتور شکل‌دهی ρ
۹۳	۵-۶-۵ تحلیل مقیاس‌پذیری
۹۳	۶-۶-۵ نتایج و تحلیل‌های تجربی شبیه‌ساز مأموریت پهپاد DARTSim
۹۳	۱-۶-۶-۵ تنظیمات بستر داده آفلاین مأموریت پهپاد
۹۴	۲-۶-۶-۵ آموزش و مقایسه عملکرد همگرایی
۹۴	۳-۶-۶-۵ تحلیل پدیده نوسان خطا و خوش‌بینی در یادگیری
۹۶	۷-۵ اعتبارسنجی آماری
۹۷	۸-۵ خلاصه فصل

فصل ۶: بحث، نتیجه‌گیری و پیشنهادها

۹۸	۱-۶ بحث در مورد یافته‌های کلیدی
۹۸	۱-۱-۶ نظریه‌پردازی مکانیزم: چرا RS-DRL کار می‌کند؟
۹۹	۲-۱-۶ تحلیل تعاملات و مصالحه‌ها (به‌عنوان مثال، تاخیر در مقابل از دست رفتن بسته)
۱۰۰	۳-۱-۶ پیامدهای مهندسی سیستم‌های خودوفقی
۱۰۱	۲-۶ محدودیت‌ها و تهدیدات اعتبار (Threats to Validity)
۱۰۱	۱-۲-۶ اعتبار داخلی (Internal Validity)
۱۰۱	۲-۲-۶ اعتبار خارجی (External Validity)

۱۰۲	۳-۲-۶ اعتبار سازه (Construct Validity)
۱۰۲	۳-۶ مسیرهایی برای تحقیقات آینده
۱۰۲	۱-۳-۶ استراتژی‌های انطباقی و وفقی شکل‌دهی ρ
۱۰۳	۲-۳-۶ گسترش به دامنه‌های پیوسته و حساس به ایمنی
۱۰۴	۳-۳-۶ اعتبارسنجی بین‌دامنه و تحلیل‌های نظری
۱۰۴	۴-۶ نتیجه‌گیری
۱۰۴	۱-۴-۶ خلاصه بیان مسئله و راهکار پیشنهادی
۱۰۵	۲-۴-۶ مرور مشارکت‌ها و شواهد تجربی
۱۰۶	۳-۴-۶ سخنان پایانی

۱۰۷	کتاب‌نامه
۱۱۲	فصل آ: جریان‌های کاری کامل فرآیند
۱۱۳	فصل ب: لیست کامل الگوریتم‌ها
۱۱۴	فصل پ: نتایج تجربی گسترده
۱۱۵	فصل ت: مصنوعات پیاده‌سازی و پکیج بازتولید

فهرست جداول

۲-۱	مقایسه تطبیقی الگوریتم‌های جدول‌محور Q-Learning و SARSA	۲۳
۲-۲	فضای معنایی سیستم پهبادی DARTSim (عوامل پیکربندی و محیطی)	۳۲
۲-۳	طیف سناریوهای پیکربندی‌پذیر محیط DARTSim و سطوح دشواری آن‌ها	۳۸
۱-۳	مقایسه تطبیقی پارادایم‌های مدیریت فضای افقی زمان اجرا بر اساس چارچوب ارزیابی پنج‌بعدی (برگرفته از تحلیل کارهای پیشین نظیر [۱۴، ۱۶، ۳۵، ۷])	۵۲
۲-۳	نحوه پوشش شکاف‌های تحقیقاتی توسط نوآوری‌های معماری پیشنهادی RS-DRL	۵۴
۱-۴	مقایسه تطبیقی معماری پیشنهادی RS-DRL با رویکردهای پیشین از منظر اصول طراحی سیستمی	۶۰
۲-۴	طبقه‌بندی زمانی فرآیندهای معماری RS-DRL	۶۲
۳-۴	تحلیل حساسیت رفتار یادگیری عامل نسبت به تغییرات فاکتور شکل‌دهی ρ	۷۲
۴-۴	الگوهای دسترسی صوری و همگام‌سازی مؤلفه‌ها در مخزن دانش مشترک [۲]	۷۶
۱-۵	هم‌راستایی اهداف ارزیابی با سوالات تحقیق	۸۵
۲-۵	نمونه‌های مورد مطالعه سیستم DeltaIoT [۵]	۸۶
۳-۵	نتایج اهداف کمینه‌سازی در DeltaIoTv1 (پاداش مجانبی / گام‌ها)	۹۰
۴-۵	نتایج اهداف کمینه‌سازی در DeltaIoTv1.1	۹۰
۵-۵	عملکرد سیستم برای اهداف آستانه‌ای ترکیبی (TTS Goal)	۹۱
۶-۵	عملکرد سیستم برای اهداف آستانه‌ای مطلق (TT Goal)	۹۱
۷-۵	تحلیل مقیاس‌پذیری الگوریتم با بزرگ شدن فضای تطابق	۹۳
۸-۵	مقایسه آماری عملکرد الگوریتم RS-DRL و Baseline DQN در محیط آفلاین DARTSim	
	(میانگین $\pm$ انحراف معیار روی ۳ سید تصادفی مستقل بعد از 50,000 گام آموزشی)	۹۴
۹-۵	مقادیر احتمال (p-values) برای مقایسه‌های معنادار و غیرمعنادار	۹۶

فهرست تصاویر

- ۱-۲ توپولوژی و ساختار پیوندهای ارتباطی شبکه حسگر بی سیم DeltaIoTv1 [۲۷]. ۲۵
- ۲-۲ نمودار مفهومی عوامل اثرگذار بر اهداف وابستگی پذیری تیم پهبادی DARTSim؛ عوامل
پیکربندی و محیطی در یک محیط متخاصم بر تحقق اهداف شناسایی هدف و اجتناب از
تهدید اثر می گذارند. ۳۳
- ۳-۲ داشبورد تحلیل عدم قطعیت محیطی DARTSim: توزیع تصادفی بودن گذارها، عدم قطعیت
به تفکیک نوع اقدام و مؤلفه حالت، تغییرپذیری قرائت حسگر تهدید و پراکندگی پاداش ها. ۳۶
- ۴-۲ نمونه هایی از تغییرپذیری قرائت حسگرهای تهدید و هدف برای یک زوج حالت-اقدام
یکسان در DARTSim؛ هر سطر یک پیامد ممکن و هر ستون یک سلول حسگر پیش رو را
نشان می دهد. ۳۷
- ۵-۲ مقایسه ی سه سناریوی DARTSim (پایه، متوسط و سخت)؛ تفاوت در چیدمان نقشه،
پیچیدگی مسیر و چگالی تهدید و هدف. ۳۸
- ۱-۴ معماری سطح بالای رویکرد RS-DRL در قالب حلقه MAPE-K این نمودار تعامل
میان سیستم مدیریت شونده، محیط، و مؤلفه های کنترلی را به همراه مخزن دانش (Knowledge)
مشترک نشان می دهد. ۵۹
- ۲-۴ نمودار فعالیت تفصیلی UML با خطوط شناوری (Swimlanes) برای تفکیک مسئولیت های
پایش، تحلیل، برنامه ریزی و اعتبارسنجی. خط چین افقی مرز میان مسیر بحرانی آنالیز و
فرآیند یادگیری ناهمگام در پس زمینه را مشخص می کند. ۶۱
- ۳-۴ ساختار داخلی مؤلفه برنامه ریز RS-DRL در سه مسیر موازی: استنتاج (فقط خواندنی)،
فیدبک (ترکیب پاداش محیطی و صوری)، و آموزش (به روزرسانی ناهمگام با استفاده از
شکل دهی تصادفی پاداش). ۶۸

- ۴-۴ منطق عملیاتی مکانیزم شکل دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش بینانه پاداش های صفر با مقدار ۱ را بر اساس فاکتور ρ نشان می دهد (برچسب گذاری مجدد خوش بینانه، نه روش های مبتنی بر پتانسیل [۳۹]). ۶۹
- ۵-۴ منطق عملیاتی مکانیزم شکل دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش بینانه پاداش های صفر با مقدار ۱ را بر اساس فاکتور ρ نشان می دهد (برچسب گذاری مجدد خوش بینانه، نه روش های مبتنی بر پتانسیل). ۷۱
- ۶-۴ جریان داده تفصیلی در مخزن دانش. این نمودار نحوه ذخیره سازی تجربیات در بافر بازپخش، اعمال مکانیزم شکل دهی تصادفی پاداش پیش از محاسبات گرادیان، و به روزرسانی سیاست های یادگیری در پس زمینه را به تصویر می کشد. ۷۵
- ۷-۴ دیاگرام هماهنگی و توالی زمانی میان استنتاج فوق سریع آنالین (۳/۰ms) و راستی آزمایی صوری سنگین و ناهمگام در پس زمینه، که تضمین می کند هیچ وقفه یا انسدادی در مسیر مستقیم تصمیم گیری رخ نمی دهد. ۷۹
- ۱-۵ منحنی های یادگیری الگوریتم ها در محیط DeltaIoTv1 (پاداش در برابر گام ها) ۸۹
- ۲-۵ منحنی های یادگیری الگوریتم ها در محیط DeltaIoTv1.1 ۹۰
- ۳-۵ تاثیر مقادیر مختلف ضریب شکل دهی ρ بر پاداش مجانبی و عملکرد کل ۹۲
- ۴-۵ نمودار همگرایی مأموریت پهبادی DARTSim شامل چهار پانل: (الف) همگرایی ارزش کیو، (ب) میانگین خطای TD، (ج) نرخ شکل دهی پاداش واقعی، و (د) مقایسه گام به گام ارزش کیو. ۹۵
- ۵-۵ تحلیل تفکیکی رفتار الگوریتم RS-DRL در مقایسه با DQN پایه به ازای سیدهای تصادفی مستقل ۴۲، ۴۳ و ۴۴ در محیط شبیه ساز پهبادی DARTSim. ۹۵
- ۶-۵ تحلیل آماری و معناداری اندازه اثر کوهن (Cohen's d) و فواصل اطمینان ارزش کیو برای روش پیشنهادی در برابر روش پایه در مأموریت های DARTSim. ۹۵

فهرست نشانه‌ها و اختصارات

نشانه‌های ریاضی

نماد	توضیح و تعریف
$\mathcal{S}$	فضای حالت سیستم (مجموعه تمام وضعیت‌های ممکن سیستم و محیط)
$\mathcal{A}$	فضای عمل یا گزینه‌های وفقی در دسترس
s	حالت یا وضعیت جاری سیستم ($s \in \mathcal{S}$)
a	عمل وفقی یا پیکربندی انتخاب‌شده ($a \in \mathcal{A}$)
$\pi(a s)$	سیاست تطبیق عامل (نگاشت حالت‌ها به اعمال)
π^*	سیاست تطبیق بهینه
$R(s, a)$	تابع پاداش (بازخورد عددی محیط به عامل)
γ	نرخ تنزیل پاداش‌های آتی ($\gamma \in [0, 1)$)
$V^\pi(s)$	تابع ارزش حالت تحت سیاست π
$Q(s, a)$	تابع ارزش عمل (مقدار کیو)
θ	پارامترها و وزن‌های شبکه عصبی عمیق تقریب‌گر
ϵ	احتمال کاوش تصادفی در الگوریتم حریصانه-اپسیلون
$\mathcal{D}$	بافر بازپخش تجربه عامل
ρ	مقدار پاداش خوش‌بینانه تزریق‌شده در مکانیسم شکل‌دهی پاداش تصادفی

اختصارات انگلیسی

اختصار	عبارت کامل انگلیسی	معادل فارسی
RS-DRL	Randomized Reward-Shaped Deep Reinforcement Learning	یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش
DRL	Deep Reinforcement Learning	یادگیری تقویتی عمیق
SAS	Self-Adaptive Systems	سیستم‌های خودوقتی
MAPE-K	Monitor, Analyze, Plan, Execute over Shared Knowledge	حلقه مدیریت خودمختار
UPPAAL-SMC	UPPAAL Statistical Model Checker	ابزار بازیابی صوری آماری آپال
SMC	Statistical Model Checking	بازیابی صوری آماری
DQN	Deep Q-Network	شبکه کیو عمیق
HER	Hindsight Experience Replay	بازپخش تجربه با نگاه به گذشته (هدف‌محور)
Soft HER	Soft Hindsight Experience Replay	بازپخش تجربه با نگاه به گذشته نرم
DLASER	Dynamic Learning-based Adaptive System for Efficient Resource allocation	سیستم وفقی مبتنی بر یادگیری پویا برای تخصیص منابع
ML4EAS	Machine Learning for Self-Adaptive Systems	یادگیری ماشین برای سیستم‌های خودوقتی
DARTSim	UAV Tactical Mission Simulator	شبیه‌ساز مأموریت تاکتیکی پهپادها

اختصار	عبارت کامل انگلیسی	معادل فارسی
MDP	Markov Decision Process	فرآیند تصمیم‌گیری مارکوف
POMDP	Partially Observable Markov Decision Process	فرآیند تصمیم‌گیری مارکوف بخشاً مشاهده‌پذیر
PBRS	Potential-Based Reward Shaping	شکل‌دهی پاداش مبتنی بر پتانسیل
QVR	Q-Value Reshaping	شکل‌دهی مقدار کیو
QoS	Quality of Service	کیفیت خدمات
KPI	Key Performance Indicator	شاخص کلیدی عملکرد
IoT	Internet of Things	اینترنت اشیاء
WSN	Wireless Sensor Network	شبکه حسگر بی‌سیم
SNR	Signal-to-Noise Ratio	نسبت سیگنال به نویز
TT	Threshold Goal	هدف آستانه‌ای مطلق
TTS	Threshold-based Transition System	سیستم انتقال مبتنی بر آستانه

فصل ۱

کلیات

۱-۱ مقدمه

در حوزه مهندسی سیستم‌های نرم‌افزاری معاصر، پیچیدگی به عنوان یکی از بارزترین ویژگی‌ها خودنمایی می‌کند. محیط عملیاتی پویا نقشی محوری در شکل‌دهی به این پیچیدگی دارد و سیستم‌ها را ناگزیر می‌سازد تا با شرایط نامشخصی که اغلب تنها پس از عملیاتی شدن بروز می‌یابند، مقابله کنند.

در سال‌های اخیر، ظهور معماری‌های توزیع‌شده، رایانش ابری، اینترنت اشیاء (IoT) و سیستم‌های فیزیکی-سایبری، ابعاد جدیدی از پیچیدگی محاسباتی و عدم قطعیت‌های زمان اجرا را به همراه داشته است. آمار و گزارش‌های صنعتی نشان می‌دهند که خرابی و توقف غیرمنتظره سیستم‌های نرم‌افزاری در مقیاس صنعتی، هزینه‌های سرسام‌آوری را تحمیل می‌کند [۱]. به عنوان مثال، در زیرساخت‌های ابری بزرگ مقیاس، هر دقیقه توقف خدمات (downtime) می‌تواند تا هزاران دلار ضرر مالی مستقیم و آسیب جدی به اعتبار برندها به همراه داشته باشد [۱]. از سوی دیگر، در شبکه‌های حسگر بی‌سیم و اینترنت اشیاء صنعتی، افزایش ناگهانی تداخل امواج یا رانش مفهومی در کانال‌های ارتباطی می‌تواند نرخ هدررفت داده‌ها را به شدت افزایش دهد. در چنین سناریوهایی، نرخ خطای قابل قبول بسیار کوچک است و سیستم‌ها باید بلافاصله خود را با محیط تطبیق دهند. این موضوع نشان می‌دهد که مدیریت عدم قطعیت در سیستم‌های نوین، یک چالش دانشگاهی محض نیست، بلکه یک ضرورت عملی و فوری در صنایع مختلف به شمار می‌رود.

سیستم‌های نرم‌افزاری سنتی که مبتنی بر پیکربندی‌های ایستا در زمان طراحی یا قواعد ثابت زمان اجرا (نظیر دستورات شرطی ساده «اگر-آنگاه») هستند، فاقد انعطاف‌پذیری لازم برای پاسخ‌گویی به نوسانات پویای محیطی می‌باشند. در این سیستم‌ها، تمامی شرایط عملیاتی و رفتارهای سیستم باید در زمان طراحی پیش‌بینی شوند. با این حال، در محیط‌های پیچیده واقعی، فرضیات زمان طراحی همواره نقض می‌شوند.

برای نمونه، در سیستم‌های هوشمند مدیریت ترافیک شهری یا کنترل مسیریابی شبکه‌های نسل پنجم (5G)، تغییرات پویای حجم داده‌ها، نوسان بار ترافیکی و خرابی‌های ناگهانی سخت‌افزاری موجب شکست قوانین ایستای زمان طراحی می‌شوند. سیستم‌هایی که بر قواعد سخت‌گیرانه زمان طراحی تکیه می‌کنند، در سناریوهای خارج از پیش‌بینی‌های اولیه با زوال عملکرد یا توقف کامل مواجه می‌شوند.

به منظور غلبه بر این محدودیت‌ها، سیستم‌های خودوفق (SAS) به عنوان یک پارادایم اساسی در مهندسی نرم‌افزار نوین ظهور کردند. این سیستم‌ها مجهز به حلقه‌های بازخوردی خودمختار هستند که به سیستم اجازه می‌دهند تا به طور پیوسته وضعیت درونی و بیرونی خود را پایش کرده، انحرافات از اهداف تعیین‌شده را تحلیل کرده، تغییرات بهینه را برنامه‌ریزی و در نهایت در زمان اجرا اعمال نمایند.

ایده اولیه این رویکرد به کارهای بنیادین شرکت IBM در سال ۲۰۰۳ تحت عنوان رایانش خودمختار توسط کیفارت و چس [۲] بازمی‌گردد. در ادامه، اوریزی و همکاران (۱۹۹۹) [۳] یکی از نخستین رویکردهای معماری‌محور برای سیستم‌های خودوفق را معرفی کردند که بر استفاده از مدل‌های زمان اجرا برای هدایت تصمیمات وقتی تأکید داشت. همچنین چنگ و همکاران (۲۰۰۹) [۴] در نقشه‌راه تحقیقاتی مهندسی نرم‌افزار برای سیستم‌های خودوفق، بر اهمیت مدل‌های خودمختار زمان اجرا، مدیریت عدم قطعیت و تضمین‌های کیفیت تأکید نمودند. ادغام حلقه‌های کنترلی خودمختار با تکنیک‌های تصمیم‌گیری هوشمند، سنگ بنای سیستم‌های خودوفق مدرن را شکل می‌دهد.

۲-۱ اهداف رساله

این رساله در راستای تکمیل شکاف‌های تحقیقاتی پیشین [۴] و پاسخ به چالش‌های حل‌نشده، یک هدف اصلی و سه هدف فرعی را دنبال می‌کند:

هدف اصلی: توسعه و اعتبارسنجی روش یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) به گونه‌ای که بر مشکل بنیادین گیرافتادن در بهینه‌های محلی در فضاها و فقی گسسته و بزرگ غلبه کند. این روش سیستم‌های خودوقفی را قادر می‌سازد تا بدون نیاز به بازآموزی پرهزینه و اخلاص‌گر، عملکردی نزدیک به بهینه را به طور پیوسته در شرایط عدم قطعیت محیطی حفظ نمایند.

این هدف اصلی، هسته‌ی نوآوری رساله (مکانیزم شکل‌دهی تصادفی پاداش) را مستقیماً به چالش اساسی شناسایی‌شده در بیان مسئله پیوند می‌دهد.

اهداف فرعی: در راستای تحقق هدف اصلی، اهداف فرعی زیر تعریف شده‌اند:

۱. طراحی معماری مقیاس پذیر و یکپارچه: ایجاد معماری مدولاری که عامل RS-DRL را به طور ناهمگام با حلقه‌ی خودمختار MAPE-K ادغام نموده و امکان اعتبارسنجی صوری تصمیمات پیش از اجرا را فراهم آورد. این هدف تضمین می‌کند که راهکار پیشنهادی نه تنها هوشمند، بلکه قابل اعتماد و قابل استقرار در سیستم‌های زمان اجرای واقعی باشد.

۲. مدیریت کارآمد فضاها و فضای گسسته با ابعاد بسیار بزرگ: نشان دادن این که روش RS-DRL قادر است در سیستم‌هایی با فضای واقعی تا ۴۰۹۶ گزینه (مانند DeltaIoT2)، بدون افت محسوس عملکرد، گزینه‌های بهینه یا نزدیک به بهینه را در زمان کوتاه انتخاب کند. این هدف، مقیاس پذیری عملی راهکار را برای کاربردهای دنیای واقعی اثبات می‌نماید.

۳. ارزیابی تجربی جامع و اثبات برتری آماری: مقایسه‌ی کمی دقیق روش RS-DRL با روش‌های پیشرفته‌ی موجود (شامل ϵ -greedy DQN، HER، Soft HER، DLASER و ML4EAS) از نظر عملکرد مجانبی، سرعت همگرایی، و بهینه‌سازی چندهدفه، همراه با ارائه‌ی تحلیل‌های آماری معنی دار (مانند t-test و فواصل اطمینان) برای تصدیق برتری روش پیشنهادی.

۳-۱ چالش‌ها

چالش‌ها و منابع عدم قطعیت در سیستم‌های مختلف به شکل‌های گوناگونی بروز می‌یابند. به عنوان مثال، در سیستم‌های مستقر در محیط‌های پویا نظیر برنامه‌های اینترنت اشیا (IoT) در شهرهای هوشمند، تغییرات آب و هوایی تأثیر قابل توجهی می‌گذارد. همچنین محیط‌های ابری با تقاضای منابع متغیر، امنیت سایبری با تهدیدات نوظهور و مداوم، تجارت الکترونیک و شبکه‌های اجتماعی با رفتار غیرقابل پیش‌بینی کاربران، و سیستم‌های توزیع شده با تأخیر شبکه، خرابی سخت افزار و تغییرات زیرساختی روبه‌رو هستند. هنگامی که سیستم با فضای واقعی گسترده و گزینه‌های متعدد تغییر مواجه می‌شود، انتخاب گزینه‌ای واقعی که با اهداف سیستم همسو باشد، از نظر محاسباتی بسیار پرهزینه و دشوار، و در برخی موارد تقریباً غیرممکن می‌گردد.

روش‌های موجود برای مدیریت عدم قطعیت در سیستم‌های خود واقعی با محدودیت‌های قابل توجهی مواجه هستند. به عنوان مثال، روش‌های مبتنی بر یادگیری ماشین نیازمند داده‌های آموزشی برجسته‌دار هستند که نمایانگر محیط سیستم باشند. به دست آوردن چنین داده‌هایی در زمان طراحی به دلیل عدم قطعیت فراوان بسیار دشوار است. از طرفی، روش‌های مبتنی بر جستجو (مانند الگوریتم‌های صعود تپه و الگوریتم‌های ژنتیک) با مشکلات مقیاس پذیری مواجه هستند و عملکرد آن‌ها با تغییر شرایط محیطی دچار افت محسوس می‌شود.

یادگیری تقویتی عمیق (DRL) علیرغم قدرت بالا، خود با چالش‌های اساسی نظیر گیرافتادن در بهینه‌های محلی مواجه است. این چالش در سیستم‌هایی با فضای وفقی گسسته و بزرگ به مراتب تشدید می‌شود؛ زیرا هرچه تعداد گزینه‌های وفقی بیشتر باشد، احتمال همگرایی مدل به راه‌حل‌های بهینه‌ی محلی به جای بهینه‌های سراسری افزایش می‌یابد و کاوش کافی در فضای عمل دشوارتر می‌گردد. بهینه‌های محلی به راه‌حل‌هایی اشاره دارند که تنها در یک منطقه محدود از فضای مسئله بهینه هستند و به صورت سراسری بهترین راه‌حل ممکن محسوب نمی‌شوند. در زمینه DRL، این بدان معناست که مدل ممکن است سیاستی را یاد بگیرد که تحت شرایط خاص به خوبی عملکرد مناسبی دارد، اما در صورت تغییر محیط قادر به تعمیم‌پذیری و حفظ عملکرد مطلوب نیست.

علاوه بر این، آموزش مجدد یا بازآموزی (Retraining) مدل در زمان اجرا فرآیندی پرهزینه است. بازآموزی شامل مراحل متعددی مانند جمع‌آوری داده‌های جدید، ارزیابی مجدد ساختار و پارامترهای مدل، و تست مدل به‌روزشده برای اطمینان از عملکرد بهتر آن نسبت به نسخه قبلی است. در طول این فرآیند، سیستم ممکن است به صورت غیربهینه عمل کند که در سیستم‌های حیاتی، این دوره عملکرد نامطلوب می‌تواند پیامدهای جبران‌ناپذیری به همراه داشته باشد.

۴-۱ بیان مساله

به طور خلاصه، سیستم‌های خودوفقی مدرن در محیط‌های پویا و غیرقابل پیش‌بینی نظیر شبکه‌های اینترنت اشیاء، رایانش ابری و شهرهای هوشمند عمل می‌کنند. این سیستم‌ها اغلب با فضاهای وفقی گسسته و بزرگ مواجه هستند که می‌تواند شامل صدها یا هزاران گزینه پیکربندی مختلف باشد (برای مثال، شبکه حسگر DeltaIoTv2 [۵] دارای ۴۰۹۶ گزینه وفقی است). مدل‌های سنتی یادگیری تقویتی عمیق (DRL) که برای تصمیم‌گیری در این فضاها به کار گرفته می‌شوند، با دو چالش بنیادین مواجه‌اند. از یک سو، گیرافتادن در بهینه‌های محلی مشکل اساسی است؛ الگوریتم‌هایی مانند ϵ -greedy DQN به دلیل ماهیت کاوشگری محدود خود، اغلب در نقاط بهینه محلی متوقف می‌شوند و قادر به کشف سیاست‌های سراسری بهینه نیستند [۶] و این مشکل در فضاهای وفقی بزرگ به مراتب حادتر می‌شود. از سوی دیگر، نیاز به بازآموزی مکرر و پرهزینه چالش دیگری را تشکیل می‌دهد؛ در مواجهه با تغییرات محیطی (رانش مفهومی [۷])، مدل‌های سنتی نیاز به بازآموزی کامل دارند که این فرآیند زمان‌بر و محاسباتی سنگین است و در طول دوره بازآموزی، سیستم عملکرد نامطلوبی از خود نشان می‌دهد که در سیستم‌های حیاتی می‌تواند پیامدهای جبران‌ناپذیری به همراه داشته باشد.

روش‌های پیشرفته‌تری مانند HER [۸] و Soft HER [۹] نیز اگرچه در حوزه محیط‌های هدف‌محور موفق

بوده‌اند، اما برای سیستم‌های خودوفقی با اهداف مبهم و آستانه‌ای (مانند بهینه‌سازی همزمان مصرف انرژی، تأخیر و تلفات بسته) طراحی نشده‌اند و نمی‌توانند بدون دانش دامنه خاص عمل کنند. بنابراین، مسئله اصلی این رساله را می‌توان به صورت زیر فرموله کرد:

طراحی روش یادگیری تقویتی عمیق که (۱) بدون نیاز به بازآموزی مکرر و پرهزینه، از بهینه‌های محلی در فضاهاى وفقی گسسته و بزرگ (تا ۴۰۹۶ گزینه) عبور کند، (۲) قابلیت تعمیم‌پذیری به شرایط محیطی متغیر را داشته باشد، و (۳) مستقل از دانش دامنه خاص عمل کند.

فرمول‌بندی ریاضی مختصر مساله

برای درک عمیق‌تر چالش‌های تصمیم‌گیری در سیستم‌های خودوفق، در این بخش مسئله تطبیق زمان اجرا را به صورت ریاضی فرمول‌بندی می‌کنیم. این فرمول‌بندی سطح بالا مبنایی برای ارائه جزئیات کامل در فصل دوم خواهد بود.

تعریف فضای وفقی: فضای وفقی سیستم شامل مجموعه‌ای متناهی از گزینه‌های پیکربندی یا اعمال وفقی گسسته است که با $\mathcal{A}$ نشان داده می‌شود:

$$\mathcal{A} = \{a_1, a_2, \dots, a_n\}, \quad n \leq 4096 \quad (1-1)$$

هر گزینه $a_i \in \mathcal{A}$ نمایانگر یک پیکربندی شبکه، توزیع منابع، یا پهنای باند اختصاص‌یافته در یک لحظه مشخص است. در این تحقیق، ابعاد فضای وفقی تا مقیاس بزرگ ($n = 4096$) مورد بررسی قرار گرفته است.

مدل فرآیند تصمیم‌گیری مارکوف: مسئله تطبیق را به صورت یک فرآیند تصمیم‌گیری مارکوف (MDP) مدل‌سازی می‌کنیم [۱۰، ۱۱]. فضای حالت $\mathcal{S}$ وضعیت‌های سیستم و شرایط تداخل محیطی را پوشش می‌دهد. در هر گام زمانی t ، عامل وفقی بر اساس سیاست تطبیق خود $\pi(a|s)$ اقدامی مانند $a_t \in \mathcal{A}$ را در حالت $s_t \in \mathcal{S}$ انتخاب می‌کند که منجر به انتقال به حالت بعدی s_{t+1} و دریافت پاداش بازخوردی $R(s_t, a_t)$ می‌گردد.

تابع هدف: هدف نهایی عامل، پیدا کردن یک سیاست بهینه تطبیق π^* است که امید ریاضی مجموع پاداش‌های تنزیل شده بلندمدت سیستم را بیشینه کند:

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \right] \quad (2-1)$$

که در آن $\gamma \in [0, 1)$ نرخ تنزیل پاداش‌های آتی است.

قیود عملیاتی مسئله: سیاست استخراج شده π^* باید تحت سه قید عملیاتی و بنیادین زیر بهینه‌سازی شود:

۱. **قید خروج از بهینه‌های محلی بدون بازآموزی:** عامل یادگیرنده باید قادر باشد بدون ایجاد اختلال در سیستم در قالب بازآموزی مکرر در زمان اجرا، از نقاط بهینه محلی عبور کند.

۲. **قید مقیاس‌پذیری زمانی:** زمان پاسخ محاسباتی برای انتخاب عمل بهینه $a^* \in \mathcal{A}$ در زمان اجرا باید بسیار ناچیز و در حد میلی‌ثانیه باشد تا به سرعت به رانش مفهومی پاسخ داده شود.

۳. **قید استقلال از دانش دامنه:** مکانیزم کاوشگری عامل نباید به فرمول‌بندی پاداش‌های دقیق و متکی بر دانش تخصصی مهندسان دامنه وابسته باشد و باید به طور خودمختار رفتار کاوشگری بهینه را هدایت کند.

پیشینه و شکاف تحقیقاتی

اگرچه کارهای کلاسیک در حوزه سیستم‌های خودوفق زیربنای نظری این پارادایم را ایجاد کرده‌اند، اما انتخاب استراتژی تطبیق بهینه در زمان اجرا همچنان یک چالش اساسی است. در این بخش، خلاصه‌ای از پیشینه پژوهش در طراحی مکانیزم‌های تصمیم‌گیری در فضاهای وفقی بزرگ ارائه شده و شکاف‌های تحقیقاتی موجود شناسایی می‌گردد.

مرور دسته‌بندی شده رویکردهای موجود

به طور کلی، تحقیقات صورت گرفته در ادبیات سیستم‌های خودوفق جهت هدایت فرآیند تصمیم‌گیری زمان اجرا را می‌توان به سه دسته اصلی تقسیم‌بندی نمود:

۱. **رویکردهای مبتنی بر یادگیری ماشین سنتی:** این رویکردها از مدل‌های یادگیری نظارت‌شده یا بدون نظارت برای کاهش ابعاد فضای وفقی یا پیش‌بینی اثرات پیکربندی‌ها استفاده می‌کنند.

۲. رویکردهای مبتنی بر جستجو: این روش‌ها مسائل تطبیق زمان اجرا را به عنوان یک مسئله بهینه‌سازی مدل‌سازی کرده و از الگوریتم‌های اکتشافی یا جستجوی تصادفی استفاده می‌کنند.

۳. رویکردهای مبتنی بر یادگیری تقویتی: این مدل‌ها به عامل اجازه می‌دهند تا سیاست بهینه تطبیق را از طریق آزمون و خطا در تعامل مستقیم با محیط یاد بگیرد.

محدودیت‌ها و تبیین شکاف تحقیقاتی

هر یک از دسته‌بندی‌های فوق در مواجهه با چالش‌های زمان اجرا دارای محدودیت‌های خاصی هستند:

- **محدودیت‌های روش‌های مبتنی بر یادگیری ماشین:** کوین و همکاران در پژوهش‌های خود [۱۲، ۱۳] نشان داده‌اند که این روش‌ها وابستگی شدیدی به در دسترس بودن داده‌های آموزشی برچسب‌دار با کیفیت بالا در زمان طراحی دارند. در محیط‌های به شدت نامشخص، توزیع داده‌های محیطی زمان اجرا با توزیع فرضی زمان طراحی تفاوت دارد که منجر به پدیده رانش مفهومی (Concept Drift) [۷] و در نتیجه افت شدید دقت پیش‌بینی مدل‌ها می‌گردد.

- **محدودیت‌های روش‌های مبتنی بر جستجو:** کوکر (۲۰۱۵) [۱۴] و کینیر و همکاران (۲۰۱۸، ۲۰۲۱) [۱۵، ۱۶] نشان داده‌اند که اگرچه الگوریتم‌های بهینه‌سازی تصادفی کارایی مناسبی در فضاها و فقی کوچک دارند، اما در فضاها و فقی گسسته و بزرگ (با صدها یا هزاران پیکربندی) دچار مشکل مقیاس‌پذیری و تأخیر محاسباتی بسیار بالا در زمان اجرا می‌شوند. در چنین فضا‌هایی، اجرای جستجو در زمان تطبیق با محدودیت‌های زمانی شدید سیستم همخوانی ندارد.

- **محدودیت‌های روش‌های یادگیری تقویتی سنتی:** رویکردهای مبتنی بر یادگیری تقویتی عمیق سنتی (نظیر الگوریتم‌های DQN با مکانیزم‌های کاوش متداول مانند ϵ -greedy) به دلیل محدودیت کاوشگری خود، در فضا‌های بزرگ به شدت مستعد گرفتادن در بهینه‌های محلی هستند [۱۷، ۱۸]. عبور از این نقاط بهینه محلی معمولاً نیازمند فرآیندهای پرهزینه و زمان‌بر بازآموزی (Retraining) در زمان اجرا است که موقتاً ثبات عملکرد سیستم را مختل می‌سازد.

با بررسی ادبیات موجود، شکاف تحقیقاتی کلیدی زیر شناسایی می‌شود:

«هیچ‌یک از رویکردهای موجود در مهندسی سیستم‌های خودفوق‌قادر نبوده‌اند به طور همزمان (۱) بدون نیاز به بازآموزی‌های محاسباتی مکرر و اختلال‌گر، از بهینه‌های محلی در زمان اجرا عبور کنند، (۲) در فضا‌های و فقی گسسته و بزرگ (تا مقیاس ۴۰۹۶ گزینه تغییر) به صورت زمان‌حقیقی مقیاس‌پذیر باشند، و (۳) مستقل از دانش دامنه خاص (Domain-agnostic) برای هدایت فرآیند کاوش عمل کنند.»

این رساله با هدف پر کردن این خلاء تحقیقاتی، روش نوین یادگیری تقویتی عمیق با شکل دهی تصادفی پاداش (RS-DRL) را پیشنهاد و اعتبارسنجی می‌کند.

۵-۱ سؤالات پژوهش

با توجه به محدودیت‌های رویکردهای پیشین و نیز دستاوردهای آن‌ها که در بخش پیشینه و شکاف تحقیقاتی تبیین گردید [۴، ۷]، این رساله در صدد پاسخ به پرسش‌های اساسی زیر همراه با زیرسؤالات متناظر است:

۱. سؤال اول: چگونه می‌توان روشی مبتنی بر یادگیری تقویتی عمیق طراحی کرد که به‌طور مؤثر از بهینه‌های محلی در فضاهاى وفقی گسسته و بزرگ، بدون نیاز به بازآموزی مکرر و پرهزینه، عبور کند؟

• زیرسؤال ۱-۱: چه مکانیزمی برای تزریق هوشمند و کنترل‌شده‌ی «خوش‌بینی» به فرآیند بازپخش تجربیات یادگیرنده بدون تأثیر نامطلوب بر پایداری مدل می‌توان طراحی کرد؟

• زیرسؤال ۱-۲: چگونه می‌توان از تجربیات ناموفق گذشته عامل بدون وارد شدن به فاز آموزش مجدد زمان اجرا استفاده کرد؟

• زیرسؤال ۱-۳: چه تضمینی برای عدم همگرایی واگرا یا بی‌ثبات در محیط‌های دارای تداخل شدید در فرآیند یادگیری وجود دارد؟

۲. سؤال دوم: چگونه می‌توان مکانیزم‌های شکل‌دهی تصادفی پاداش (Random Reward Shaping) را با بازپخش تجربه (Experience Replay) ادغام کرد تا تعمیم‌پذیری سیستم در تغییرات شرایط محیطی بهبود یابد؟

۳. سؤال سوم: چگونه روش پیشنهادی می‌تواند فضاهاى وفقی گسسته و بزرگ (از ۲۱۶ تا ۴۰۹۶ گزینه) را در حین حفظ عملکردی نزدیک به بهینه، به شکل کارآمدی مدیریت کند؟

۴. سؤال چهارم: تا چه حد روش پیشنهادی (RS-DRL) از روش‌های موجود نظیر یادگیری ای‌گرایانه حریصانه (ϵ -greedy DQN) [۱۹]، HER [۸]، Soft HER [۹]، DLASER [۱۸] و ML4EAS [۲۰] از منظر عملکرد مجانبی، سرعت همگرایی، و بهینه‌سازی چندهدفه، برتری و عملکرد بهتری از خود نشان می‌دهد؟

• زیرسؤال ۴-۱: عملکرد مجانبی RS-DRL در بلندمدت در مقایسه با الگوریتم‌های استاندارد یادگیری تقویتی نظیر DQN و مدل‌های پس‌نگر نظیر HER در محیط‌های غیرایستا چگونه است؟

- **زیرسؤال ۴-۲:** سرعت همگرایی روش پیشنهادی در فضاهاى وفقى با ابعاد بسیار بزرگ (مانند شبکه با ۴۰۹۶ حالت پیکربندی) چه تفاوتی با رویکردهای یادگیری عمیق فشرده‌کننده نظیر DLASER+ دارد؟
- **زیرسؤال ۴-۳:** آیا برتری‌های عملکردی حاصل از روش پیشنهادی از نظر آماری در مقایسه با سایر استراتژی‌ها معنادار است؟

۶-۱ روش پیشنهادی

۱-۶-۱ مرور کلی بر راهکار RS-DRL

راهکار پیشنهادی در این رساله مبتنی بر توسعه یک معماری یادگیری هوشمند است که به جای تکیه بر دانش ایستا، از طریق تعامل مستقیم با محیط، سیاست‌های بهینه را استخراج می‌کند. این روش مسئله تطبیق را به‌عنوان یک فرآیند تصمیم‌گیری مارکوف (MDP) مدل‌سازی کرده و با ادغام مدل‌های عمیق و لایه مدیریت خودمختار، یک چرخه پیوسته از یادگیری و اجرا را فراهم می‌آورد. هسته نوآورانه این روش، مکانیزم «شکل‌دهی تصادفی پاداش» است که با بازطراحی تصادفی برخی تجربیات ناموفق گذشته، عامل را قادر به فرار از بهینه‌های محلی بدون نیاز به بازآموزی پرهزینه می‌سازد. تمرکز اصلی بر ارائه چارچوبی است که در آن، عامل یادگیرنده نه تنها بر اساس پاداش‌های آنی، بلکه با هدف حفظ عملکرد مطلوب در بازه زمانی طولانی، کاهش نیاز به بازآموزی‌های مکرر و پایداری معیارهای کیفی سیستم نظیر مصرف انرژی و زمان تأخیر، عمل کند.

۲-۶-۱ یکپارچه سازی راهکار RS-DRL با حلقه کنترلی MAPE-K

روش پیشنهادی با بهره‌گیری از چارچوب استاندارد MAPE-K، فرآیند تطبیق را به صورت ساختاریافته مدیریت می‌کند. در این معماری، عامل RS-DRL در مؤلفه برنامه‌ریزی (Plan) مستقر شده و خروجی‌های آن (گزینه وفقی پیشنهادی) پیش از اجرا توسط ابزار تأیید صوری UPPAAL-SMC از نظر ایمنی و قابلیت اطمینان ارزیابی می‌گردند. سپس گزینه‌های تأییدشده بر روی سیستم مدیریت‌شونده اعمال می‌شوند. این یکپارچگی تضمین می‌کند که تصمیمات هوشمندانه‌ی عامل DRL تنها پس از اعتبارسنجی صوری به اجرا درآیند.

۷-۱ نوآوری‌های اصلی رساله

بنیان علمی و سهم پژوهشی این پایان‌نامه در قالب چهار نوآوری اصلی زیر تبیین می‌گردد که هر یک به طور مستقیم به رفع یکی از محدودیت‌های کلیدی در ادبیات موضوع می‌پردازد:

۱. نوآوری اول: الگوریتم یادگیری تقویتی با شکل‌دهی تصادفی پاداش (RS-DRL): ارائه یک مکانیزم

نوین شکل‌دهی پاداش تصادفی زمان اجرا که برای اولین بار برخی از تجربیات ناموفق گذشته را بدون نیاز به دانش دامنه خاص بازطراحی می‌کند. در حالی که رویکردهای پیشین مانند HER [۸] نیازمند تعریف اهداف صریح زمان اجرا و دانش عمیق فرمول‌بندی محیط هستند، روش پیشنهادی با تخصیص پاداش مثبت به زیرمجموعه‌ای تصادفی از تجربیات گذشته، بدون هیچ‌گونه دانش دامنه‌ای، عامل یادگیرنده را قادر به کاوش کارآمد فضای وفقی و خروج موفقیت‌آمیز از بهینه‌های محلی می‌سازد. این رویکرد به ویژه مانع همگرایی واگرا یا گیرافتادن در نقاط پایدار محلی می‌شود.

۲. نوآوری دوم: ادغام معماری RS-DRL در حلقه MAPE-K: طراحی یک معماری سیستماتیک و

تلفیقی ناهمگام که عامل یادگیرنده هوشمند را در مؤلفه تصمیم‌گیری حلقه کنترل خودمختار تعبیه می‌کند. برخلاف رویکردهای کلاسیک که فرآیند آموزش عمیق را به صورت آفلاین یا کاملاً مجزا انجام می‌دهند، در این معماری فرآیند آموزش پیوسته و استنتاج به صورت پویا با پایش وضعیت فیزیکی سیستم همگام شده و گزینه‌های تصمیم‌گیری پیش از اعمال، برای اطمینان صد درصدی از پایداری کیفیت خدمات، از فیلتر اعتبارسنجی صوری ابزار UPPAAL-SMC عبور می‌کنند.

۳. نوآوری سوم: مدیریت فضای وفقی مقیاس‌پذیر و گسسته در ابعاد بزرگ: ارائه یک راهکار مقیاس‌پذیر

زمان‌اجرا جهت اتخاذ تصمیمات وفقی چندهدفه در ابعاد تا ۴۰۹۶ گزینه تغییر. در حالی که روش‌های سنتی مبتنی بر جستجو نظیر الگوریتم ژنتیک یا روش‌های شبیه‌سازی تصادفی به علت سربار محاسباتی بسیار بالا در مواجهه با ابعاد ۴۰۹۶ با اختلال مواجه می‌شوند، روش پیشنهادی با کاهش زمان تصمیم‌گیری استنتاج مدل به مقیاس میلی‌ثانیه، پایداری همزمان مصرف انرژی و قابلیت اطمینان ارتباطات را تضمین می‌کند.

۴. نوآوری چهارم: معماری جداسازی زمانی (Temporal Separation): توسعه یک متدولوژی سازماندهی

زمانی که مسیر تصمیم‌گیری آنلاین (با استنتاج زیر میلی‌ثانیه) را به طور کامل از ریسمان‌های سنگین آموزش ناهمگام در پس‌زمینه تفکیک می‌کند. این نوآوری معماری تضمین می‌کند که افزایش ابعاد فضای وفقی تا ۴۰۹۶، کوچک‌ترین خللی در سرعت تصمیم‌گیری بلادرنگ و پایداری عملیاتی سیستم وارد نسازد.

محدوده، قلمرو و مخاطبان پژوهش

محدوده و قلمرو پژوهش (داخل و خارج از محدوده)

برای تبیین دقیق مرزها و قلمرو این رساله دکتری، دامنه‌ی مسائل تحت پوشش (داخل در محدوده) و موضوعاتی که خارج از اهداف این کار پژوهشی هستند (خارج از محدوده)، به صورت زیر مشخص می‌گردد:

موضوعات داخل در محدوده پژوهش:

- **فضاهای وفقی گسسته:** این رساله به طور خاص بر سیستم‌های خودوفقی با فضاهای وفقی گسسته متمرکز است که پیکربندی‌های سیستم شامل گزینه‌های عددی یا ساختاری متمایز و مشخص هستند.
- **یادگیری تقویتی مدل آزاد:** رویکرد یادگیری تقویتی به کار گرفته شده از نوع مدل آزاد (Model-free) و مبتنی بر معماری شبکه‌های کیو عمیق (DQN) است که به هیچ مدل از پیش تعریف‌شده‌ای از رفتار محیط وابسته نیست.
- **سیستم‌های حسگر بی سیم صنعتی:** مطالعه موردی مرجع و اصلی جهت شبیه‌سازی و ارزیابی تجربی، بستر نام‌آشنای DeltaIoT [۵] (در نسخه‌های ۱۷ و ۲۷ با ابعاد مختلف فضای وفقی) است که چالش‌های محیطی شدید و پویایی بالایی دارد.
- **سامانه‌های پهبادی خودگردان:** مطالعه مورد دوم جهت ارزیابی استقلال از دامنه روش پیشنهادی، شبیه‌ساز مأموریت تاکتیکی پهبادها تحت عنوان DARTSim است که تصمیم‌گیری بلادرنگ در فضای وفقی گسسته بزرگ (Discrete Action Space) را در حضور تهدیدات محیطی بررسی می‌کند.

موضوعات خارج از محدوده پژوهش:

- **فضاهای وفقی پیوسته:** تحلیل و مدل‌سازی سیستم‌های خودوفق با پارامترهای تطبیق کاملاً پیوسته خارج از محدوده این کار بوده و به عنوان زمینه‌های پیشنهادی برای تحقیقات آینده در نظر گرفته شده است.
- **سیستم‌های چندعاملی:** تمرکز این رساله بر سناریوهای تصمیم‌گیری تک‌عاملی متمرکز است که در آن یک عامل خودمختار مرکزی مسئولیت تطبیق را بر عهده دارد. بررسی سیستم‌های توزیع‌شده با یادگیری تقویتی چندعاملی (MARL) مد نظر نبوده است.

- اثبات قضایای ریاضی همگرایی محض: تضمین همگرایی و کارایی روش پیشنهادی به صورت تجربی و مبتنی بر شبیه‌سازی‌های فشرده و گسترده و تحلیل‌های آماری معتبر اثبات شده است، نه از طریق روابط اثبات تئوریک همگرایی ریاضی صوری در شرایط نامحدود.

مخاطبان و کاربردهای بالقوه

دستاوردها و راهکارهای ارائه شده در این رساله دکتری می‌تواند برای طیف وسیعی از محققان و حوزه‌های کاربردی سودمند واقع شود. این پژوهش در وهله نخست برای محققان مهندسی نرم‌افزار خودوفقی، حلقه‌های کنترلی خودمختار (MAPE-K) و تضمین کیفیت زمان اجرا ارزشمند است. در وهله دوم، طراحان سیستم‌های اینترنت اشیا و شبکه‌های حسگر بی‌سیم که نیازمند استقرار سیستم‌های پایدار در مواجهه با اختلالات پویای سیگنال هستند از این رساله بهره می‌برند. سرانجام، توسعه‌دهندگان الگوریتم‌های یادگیری تقویتی عمیق که با چالش گیرافتادن در بهینه‌های محلی در فضاها عمل گسسته دست‌وپنجه نرم می‌کنند، مخاطبان اصلی یافته‌های این رساله محسوب می‌شوند.

۸-۱ مروری بر فصول رساله

ساختار رساله به گونه‌ای طراحی شده است که به‌طور نظام‌مند روند توسعه، اجرا و ارزیابی رویکرد پیشنهادی را در اختیار خواننده قرار دهد. در ادامه، نقش و کارکرد هر یک از فصول در راستای زنجیره استدلالی و پاسخ به سوالات رساله تشریح می‌گردد:

فصل ۱: کلیات در این فصل، کلیات پژوهش، بیان مسئله، اهداف و نوآوری‌های رساله به همراه سوالات تحقیق و مروری بر ساختار کل رساله ارائه می‌گردد تا خواننده با بستر کلی و ضرورت طرح پژوهش آشنا شود.

فصل ۲: مبانی نظری و مدل سیستم این فصل زیربنای ریاضی و مفهومی لازم برای درک روش پیشنهادی را فراهم می‌کند. در این فصل، مبانی سیستم‌های خودوفقی (حلقه MAPE-K)، منابع عدم قطعیت و رویکردهای مدل‌سازی زمان اجرا (از جمله ابزار UPPAAL-SMC)، و اصول یادگیری تقویتی (فرآیند تصمیم‌گیری مارکوف و الگوریتم DQN) تشریح شده و مدل ریاضی سیستم بستر DeltaIoT فرموله می‌گردد.

فصل ۳: مرور ادبیات و کارهای مرتبط با بهره‌گیری از چارچوب نظری فصل دوم، این فصل به بررسی انتقادی و جامع رویکردهای پیشین پرداخته و با تحلیل نقاط قوت و ضعف آن‌ها، ضرورت علمی و موقعیت رساله حاضر در بدنه دانش سیستم‌های خودوفقی را مستحکم می‌سازد.

فصل ۴: روش پیشنهادی RS-DRL: معماری و الگوریتم این فصل هسته نوآوری و طراحی فنی رساله را پوشش می‌دهد. در این فصل، جزئیات الگوریتمی مکانیزم شکل‌دهی تصادفی پاداش، معماری یکپارچه

ناهمگام با حلقه کنترلی خودمختار و فرآیند اعتبارسنجی صوری پیش از اجرا توسط ابزار UPPAAL-SMC به تفصیل ارائه می‌شود تا به سوالات اول و دوم رساله پاسخ داده شود.

فصل ۵: ارزیابی تجربی این فصل جنبه‌های عملیاتی، پیاده‌سازی و اعتبارسنجی تجربی رساله را شامل می‌شود. شبیه‌سازی‌ها و مقایسه‌های گسترده با رقبای نام‌آشنا روی سناریوهای مختلف بستر DeltaIoT مستند شده و تحلیل‌های آماری معتبر در این فصل ارائه می‌شود تا پاسخ به سوالات سوم و چهارم رساله تصدیق گردد.

فصل ۶: بحث و نتیجه‌گیری در نهایت، این فصل مصالحه‌های رفتاری، محدودیت‌های فنی و دستاوردهای کاربردی سیستم را جمع‌بندی نموده و افق‌های جدیدی برای پژوهش‌های آتی در توسعه مهندسی سیستم‌های خوددوفق هوشمند ترسیم می‌کند.

فصل ۲

مبانی نظری و مدل سازی سیستم

۱-۲ مقدمه

سیستم های نرم افزاری معاصر به طور فزاینده ای در محیط هایی پویا، توزیع شده و اساساً غیرقابل پیش بینی فعالیت می کنند. این سیستم ها طیف وسیعی از کاربردها، از شبکه های حسگر بی سیم مقیاس وسیع در اینترنت اشیا گرفته تا میکروسرویس های ابری را شامل می شوند. چنین سیستم های پیچیده ای باید اهداف کیفیت خدمات (QoS) خود را در حضور عدم قطعیت های مداوم زمان اجرا حفظ نمایند.

برای مواجهه با این چالش، رویکرد سیستم های خوددوفق (Self-Adaptive Systems) به عنوان یک پارادایم محوری در مهندسی نرم افزار مطرح شده است. سیستم های خوددوفق با مجهز شدن به حلقه های بازخورد کنترلی، قادرند رفتار و ساختار خود را در زمان اجرا ارزیابی کرده و تغییرات بهینه را بدون نیاز به مداخله صریح انسانی اعمال کنند.

هدف محوری این فصل، پی ریزی یک چارچوب نظری و ریاضی مستحکم برای تحلیل، طراحی و مدل سازی چنین سیستم هایی است تا زمینه لازم برای درک متدولوژی پیشنهادی این رساله (RS-DRL) فراهم گردد. این فصل ابتدا مبانی سیستم های خوددوفق، معماری های مرجع و الگوهای طراحی کلاسیک را تبیین می کند. سپس، با ورود به مبحث عدم قطعیت، دسته بندی های مختلف آن و روش های مدل سازی زمان اجرا بر پایه واریسی مدل آماری (SMC) بررسی می شود. در ادامه، مبانی مدل سازی ریاضی تصمیم گیری از طریق فرآیندهای تصمیم گیری مارکوف (MDP) و روش های یادگیری تقویتی جدول محور و عمیق (DQN) تشریح می گردد. سرانجام، با استفاده از سیستم محک استاندارد DeltaIoT به عنوان مطالعه موردی، فرمول بندی MDP دقیق سیستم ارائه شده و مسئله بهینه سازی نهایی تحت قیود عملیاتی زمان اجرا به صورت صوری تبیین می گردد.

۲-۲ مبانی سیستم های خودوفقی

۱-۲-۲ مفاهیم اصلی و تعاریف

سیستم خودوفق به کلاسی از سیستم های نرم افزاری گفته می شود که ویژگی های زیر را دارد: (۱) به طور مداوم وضعیت داخلی و محیط پیرامون خود را ارزیابی می کند. (۲) می تواند ساختار، رفتار یا پارامترهای عملیاتی خود را تغییر دهد. (۳) هدف این تغییرات، دستیابی به اهداف تجاری یا کیفی مشخص است [۲]. در مبانی مهندسی نرم افزار خودوفق، سه مفهوم کلیدی زیر همواره به عنوان ارکان اساسی تعریف می شوند:

۱. **فضای وفقی (Adaptation Space):** مجموعه تمامی پیکربندی ها، سناریوها یا تصمیمات متمایزی

است که سیستم می تواند در زمان اجرا اتخاذ کند. در دامنه های واقعی، ابعاد این فضا به صورت ترکیبی رشد کرده و می تواند شامل هزاران یا میلیون ها گزینه ممکن باشد.

۲. **اهداف وفقی (Adaptation Goals):** معیارهای عملکردی یا کیفی هستند که سیستم باید آن ها را

بیشینه، کمینه یا در یک محدوده مشخص حفظ کند. این اهداف می توانند در قالب اهداف چندهدفه متضاد (مانند به حداقل رساندن تاخیر همزمان با به حداقل رساندن مصرف باتری) تعریف شوند.

۳. **حلقه بازخورد (Feedback Loop):** جریان اطلاعاتی و کنترلی که به صورت بسته، وظیفه پایش،

تصمیم گیری و اعمال تغییرات را بر عهده دارد.

تفاوت بنیادین میان سیستم های سنتی و خودوفق در نحوه مواجهه با فرضیات فاز طراحی نهفته است. در سیستم های کلاسیک، فرض بر این است که شرایط محیطی در فاز طراحی کاملاً شناخته شده و ایستا هستند. اما در محیط های معاصر، به دلیل تغییرات جوی، بار ترافیکی پویا و خرابی سخت افزاری، فرضیات طراحی به سرعت منقضی می شوند. بنابراین، خودوفقی راهکاری برای به تعویق انداختن تصمیمات طراحی به زمان اجراست تا سیستم بتواند بر اساس واقعیت های جاری تصمیم گیری کند [۳].

۲-۲-۲ معماری های مرجع و الگوهای طراحی

جهت سازماندهی ساختار درونی سیستم های خودوفق، معماری های مرجع متعددی ارائه شده است. یکی از برجسته ترین و پرکاربردترین الگوها، **معماری سه لایه ای کرامر و مگی (Three-Layer Architecture)** است که تفکیک دغدغه ها را در سطوح مختلف انتزاع تضمین می کند. این معماری شامل سه لایه مجزا است که هر یک مسئولیت خاصی را بر عهده دارد [۲۱]:

● **لایه مدیریت اهداف (Goal Management):** این لایه در بالاترین سطح قرار داشته و وظیفه تفسیر اهداف تجاری کلان و تبدیل آن‌ها به اهداف کیفی در زمان اجرا را بر عهده دارد. در صورت تغییر اولویت‌های کاربر (مثلاً تغییر سیاست از کاهش مصرف انرژی به افزایش حداکثری پایداری)، این لایه اهداف وفقی را بازطراحی می‌کند.

● **لایه مدیریت تغییرات (Change Management):** وظیفه اصلی این لایه، برنامه‌ریزی، استنتاج و تولید طرح‌های تطبیقی است. این لایه گزینه‌های وفقی موجود را ارزیابی کرده و گزینه بهینه را انتخاب می‌نماید. هسته یادگیری عمیق تقویتی پیشنهادی در این رساله (RS-DRL) مستقیماً در این لایه مستقر می‌شود.

● **لایه کنترل مولفه‌ها (Component Control):** لایه پایینی است که مستقیماً با مولفه‌های نرم‌افزاری و سخت‌افزاری سیستم هدف تعامل دارد. این لایه وظیفه جمع‌آوری داده‌ها از حسگرها و اعمال مستقیم فرامین از طریق عملگرها را بر عهده دارد.

تفکیک تمیز این لایه‌ها تضمین می‌کند که تغییر در منطق برنامه‌ریزی یا اهداف کلان تجاری، نیازی به بازطراحی کامل بخش‌های پایین‌دستی و درایورهای سخت‌افزاری نداشته باشد و پایداری سیستم در چرخه‌های وفقی تضمین گردد.

۳-۲-۲ حلقه‌های کنترلی خودمختار: از MAPE-K تا موارد پیشرفته

حلقه خودمختار MAPE-K که برای نخستین بار توسط شرکت IBM معرفی شد، استاندارد طلایی و معماری مرجع بی‌بدیل برای توصیف جریان اطلاعات و کنترل در حلقه‌های بازخورد سیستم‌های خودوفق به شمار می‌رود [۲]. این حلقه متشکل از ۵ مولفه اصلی است که حول یک پایگاه دانش محوری ساماندهی شده‌اند:

۱. **پایش (Monitor):** این مولفه داده‌های خام را از حسگرها جمع‌آوری کرده، نویزهای فرکانس بالا را فیلتر نموده و یک نمایش منسجم از وضعیت جاری سیستم و محیط تولید می‌کند.

۲. **تحلیل (Analyze):** مولفه تحلیل وظیفه تطابق وضعیت جاری با اهداف تعریف‌شده را بر عهده دارد. این مولفه مشخص می‌سازد که آیا اهداف کیفی سیستم نقض شده‌اند یا احتمال نقض آن‌ها در آینده نزدیک وجود دارد تا در صورت لزوم فرآیند تطبیق را فعال کند.

۳. **برنامه‌ریزی (Plan):** این بخش مغز متفکر سیستم خودوفق است. با دریافت هشدار از بخش تحلیل، فضای وفقی را جستجو کرده و با ارزیابی گزینه‌های مختلف، سیاستی را برای انتقال سیستم به وضعیت مطلوب طراحی می‌کند.

۴. اجرا (Execute): طرح تولید شده در بخش برنامه ریزی را به گام های عملیاتی و دستورات قابل فهم برای سخت افزار تبدیل کرده و آن ها را از طریق عملگرها بر سیستم هدف اعمال می کند.

۵. دانش (Knowledge): به عنوان حافظه مشترک و مخزن داده مرکزی عمل کرده و مدل های زمان اجرا، تاریخچه رفتار سیستم، توپولوژی شبکه و اهداف کیفی را نگهداری می کند تا چهار مولفه دیگر به طور هماهنگ فعالیت نمایند.

با پیچیده تر شدن سیستم های توزیع شده مدرن، الگوهای پیشرفته تری از حلقه های بازخورد توسعه یافته اند؛ از جمله حلقه های بازخورد توزیع شده و چندعامله (Decentralized MAPE-K loops) [۲۲، ۲۳] که در آن ها چندین حلقه محلی از طریق الگوهای نظیر Coordinated، Master-Slave یا Peer-to-Peer با یکدیگر تعامل دارند. این رویکردهای پیشرفته به ویژه در مدیریت شبکه های حسگر بی سیم وسیع که فاقد کنترل مرکزی مطلق هستند، بسیار حائز اهمیت می باشند [۲۲، ۲۳].

۳-۲ عدم قطعیت در سیستم های خوددوفقی

۱-۳-۲ دسته بندی و انواع عدم قطعیت

عدم قطعیت در مهندسی نرم افزار خوددوفق به هرگونه نقص در اطلاعات، نویز در داده ها یا ماهیت غیرقابل پیش بینی پارامترهای زمان اجرا اطلاق می شود که بر صحت تصمیمات سیستم تاثیر منفی می گذارد [۴]. بر اساس متدولوژی های معتبر مهندسی، عدم قطعیت در سه لایه کلیدی طبقه بندی می شود:

- **عدم قطعیت محیطی (Environmental Uncertainty):** ناشی از پارامترهای خارج از کنترل مرز سیستم است. در شبکه های حسگر بی سیم، تغییرات ناگهانی آب و هوا، رطوبت، باد یا تداخل های الکترومغناطیسی محیطی که کیفیت سیگنال ارتباطی را به شدت نوسان می دهند، نمونه های بارز این دسته هستند.

- **عدم قطعیت سیستمی (Systemic Uncertainty):** ناشی از پویایی درونی خود سیستم است. کاهش تدریجی ولتاژ باتری سنسورها، فرسودگی سخت افزاری گره ها، مسدود شدن موقت گیت وی ها به دلیل سربار پردازشی، یا بروز خطا در تعامل میان لایه های نرم افزاری در این گروه قرار می گیرند.

- **عدم قطعیت اهداف (Goal Uncertainty):** زمانی رخ می دهد که اولویت ها، وزن اهداف متضاد یا آستانه های تعریف شده توسط ذینفعان انسانی در طول زمان دستخوش تغییر شوند. به عنوان مثال، در

شرایط بحرانی، سیستم ممکن است ناچار شود هدف مصرف کم انرژی را فدای ارسال حداکثری و سریع پیام های هشدار کند.

۲-۳-۲ روش های مدل سازی و رویارویی با عدم قطعیت

برای رویارویی موثر با عدم قطعیت در زمان اجرا، سیستم های خوددوفق ناگزیرند رفتارهای احتمالی سیستم را مدل سازی کنند. دو متدولوژی ریاضی و مهندسی پرکاربرد در این حوزه عبارتند از:

۱. واریسی مدل آماری زمان اجرا (Runtime Statistical Model Checking - SMC): ابزارهایی نظیر

UPPAAL-SMC با استفاده از مدل های احتمالی مبتنی بر اتوماتای زمان دار احتمالی، شبیه سازی های آماری متعددی را در زمان اجرا بر روی گزینه های وفقی پیشنهادی انجام می دهند. این روش به جای واریسی صوری مطلق که از لحاظ محاسباتی در زمان اجرا غیرممکن است، با استفاده از نمونه برداری های آماری دقیق، احتمال نقض اهداف کیفی (نظیر عبور تاخیر از آستانه مجاز) را با فواصل اطمینان مشخص برآورد می کند [۲۴].

۲. مدل های تصمیم گیری احتمالی (مانند POMDP در برابر MDP): در حالی که فرآیند تصمیم گیری مارکوف استاندارد (MDP) فرض می کند وضعیت سیستم به طور کامل قابل مشاهده است، فرآیند تصمیم گیری مارکوف بخشاً مشاهده پذیر (POMDP) با معرفی مفهوم Belief State (حالت باور) عدم قطعیت شدید در مشاهده حالت ها را مدل می کند. هرچند POMDP از نظر ریاضی دقیق تر است، اما حل آن به دلیل پیچیدگی فوق العاده محاسباتی در زمان اجرای سیستم های بزرگ عملاً غیرممکن است. از این رو، این رساله با بهره گیری از هسته تقریب گر عصبی عمیق، از فرمول بندی MDP استاندارد همراه با مکانیزم های بازیابی تجربیات شکست خورده برای فائق آمدن بر این چالش استفاده می کند.

۳-۳-۲ چالش های خاص عدم قطعیت در فضاهای وفقی بزرگ

هنگامی که سیستم خوددوفق با یک فضای وفقی مقیاس وسیع (به عنوان مثال، فضاهایی با ابعاد بیش از هزاران پیکربندی ممکن) روبه رو می شود، عدم قطعیت زمان اجرا منجر به بروز سه چالش بحرانی می گردد:

- انفجار ترکیبی گزینه ها (Combinatorial Explosion): ارزیابی تک تک گزینه ها با استفاده از واریسی مدل صوری یا آماری به دلیل زمان بر بودن محاسبات غیرممکن می شود.

- تنگنای زمان تصمیم گیری (Scale-Latency Dilemma): تحلیل و برنامه ریزی باید در کسری از ثانیه انجام شود؛ در غیر این صورت، تصمیمی که با تاخیر اتخاذ شده است، به دلیل تغییر مجدد محیط

بی اثر گشته و سیستم با پدیده تصمیمات منقضی شده مواجه می گردد.

- افتادن در دام بهینه های محلی (Local Optima Traps): به دلیل ماهیت غیرایستای (non-stationary) محیط، سیاست وفقی سیستم ممکن است به سرعت همگرا شده و در یک پیکربندی نیمه بهینه قفل شود، به طوری که مکانیزم های کاوش سنتی قادر به خروج سیستم از این وضعیت نباشند.

رانش مفهومی (Concept Drift) و اثر ریاضی غیرایستایی: در سیستم های خودفوق صنعتی زمان واقعی، عدم قطعیت ها صرفاً نویزهای فرکانس بالا نیستند، بلکه محیط دستخوش تغییرات توزیعی ریشه ای یا همان رانش مفهومی می شود. به بیان صوری ریاضی، پویایی احتمالی انتقال حالت (P_t) و تابع پاداش (R_t) دیگر در طول زمان ثابت نبوده و با متغیر زمان t دچار تغییر می شوند:

$$P_t(s' | s, a) \neq P_{t+k}(s' | s, a)$$

$$R_t(s, a, s') \neq R_{t+k}(s, a, s')$$

که در آن $P_t(s' | s, a)$ نشان دهنده تابع احتمال انتقال حالت (احتمال انتقال به حالت s' پس از اتخاذ عمل a در حالت s) در زمان t است و $R_t(s, a, s')$ نشان دهنده تابع پاداش آنی در همان زمان می باشد. این عدم ایستایی، فرض بنیادین فرآیند تصمیم گیری مارکوف را نقض می کند. در شبکه های DQN کلاسیک، این پدیده منجر به فراموشی فاجعه بار (Catastrophic Forgetting) می شود؛ شبکه عصبی عمیق وزن های خود را برای شرایط جاری بهینه سازی می کند، اما به محض تغییر فصل یا بار شبکه، سیاست های پیشین کاملاً پاک شده و سیستم با افت شدید کیفیت مواجه می گردد. مکانیزم نوآورانه شکل دهی تصادفی پاداش با احتمال ρ در این رساله، با تزریق مستمر نوسان های خوش بینانه در لایه بازپخش تجربیات، مانع از تثبیت و انجماد وزن های شبکه عصبی در یک نقطه خاص شده و عملاً به عنوان یک منظم ساز (Regularizer) پویا در برابر رانش مفهومی عمل می کند.

۴-۲ مبانی نظری و مدل سازی ریاضی

۱-۴-۲ فرآیندهای تصمیم گیری مارکوف، یادگیری تقویتی و DQN

فرآیندهای تصمیم گیری مارکوف (MDP): فرآیند تصمیم گیری مارکوف چارچوب ریاضی استاندارد و بی بدیلی را برای مدل سازی تصمیم گیری های متوالی عامل هوشمند در محیط های پویا و احتمالی ارائه می دهد [۱۰].

به صورت صوری، یک MDP پنج گانه به صورت زیر تعریف می شود:

$$\mathcal{M} = (S, A, P, R, \gamma)$$

که در آن مولفه ها عبارتند از:

- S : فضای حالت های سیستم که وضعیت جاری را توصیف می کند.
- A : فضای عمل ها که در سیستم های خود فوق، همان گزینه های وفقی زمان اجرا هستند.
- $P : S \times A \times S \rightarrow [0, 1]$: تابع احتمال انتقال که احتمال رفتن از حالت s به حالت s' با انجام عمل a را مشخص می سازد:

$$P(s' | s, a) = \mathbb{P}(S_{t+1} = s' | S_t = s, A_t = a)$$

- $R : S \times A \times S \rightarrow \mathbb{R}$: تابع پاداش که پاداش آنی حاصل از انجام عمل a در حالت s و انتقال به s' را تعیین می کند.

- $\gamma \in [0, 1)$: ضریب تنزیل که ارزش پاداش های آتی را نسبت به پاداش لحظه ای مشخص می سازد.

هدف اصلی در یک MDP، یافتن یک سیاست وفقی بهینه $\pi(a | s)$ است که ارزش پاداش های تجمعی تنزیل یافته آتی را بیشینه سازد. معادله معروف بلمن (Bellman Expectation Equation) برای تابع ارزش حالت $V^\pi(s)$ به صورت زیر فرمول بندی می شود [۱۱]:

$$V^\pi(s) = \sum_{a \in A} \pi(a | s) \sum_{s' \in S} P(s' | s, a) [R(s, a, s') + \gamma V^\pi(s')]$$

همچنین، معادله بهینگی بلمن (Bellman Optimality Equation) برای تابع ارزش عمل-حالت $Q^*(s, a)$ که ارزش اتخاذ اقدام a در حالت s تحت سیاست بهینه را برآورد می کند، به صورت زیر بیان می گردد:

$$Q^*(s, a) = \sum_{s' \in S} P(s' | s, a) \left[R(s, a, s') + \gamma \max_{a'} Q^*(s', a') \right]$$

یک مثال ریاضی ملموس از فرآیند تصمیم گیری مارکوف: برای شفاف سازی نحوه انتشار ارزش ها در یک MDP، مثال ساده زیر را بررسی می کنیم. این مثال پایه درک نحوه آموزش عامل در فصل های بعدی را فراهم

می سازد. در این راستا، جهت شفاف سازی فرآیند محاسباتی، یک مدل نمونه با ۲ حالت و ۲ عمل متناظر را تحلیل می کنیم:

• **حالت ها:** $S = \{s_0, s_1\}$ که در آن s_0 نشان دهنده وضعیت عادی شبکه (بدون ترافیک و تداخل) و s_1 نشان دهنده وضعیت اشباع شبکه (حضور تداخل جوی شدید) است.

• **عمل ها:** $A = \{a_0, a_1\}$ که در آن a_0 نشان دهنده سطح توان ارسال کم (بهینه از نظر مصرف انرژی) و a_1 نشان دهنده سطح توان ارسال زیاد (مقاوم در برابر نویز) می باشد.

پویایی احتمالی انتقال حالت (P) و مقادیر پاداش ها (R) در این محیط به صورت زیر پیکربندی شده است:

۱. در حالت عادی (s_0):

- با انتخاب توان کم (a_0): با احتمال $0/8$ سیستم در s_0 باقی مانده و با احتمال $0/2$ به دلیل نویز اتفاقی به s_1 می رود. پاداش آنی برابر با $R(s_0, a_0) = 1/0$ (حداکثر بازده) است.
- با انتخاب توان زیاد (a_1): با احتمال $0/95$ سیستم در s_0 مانده و با احتمال $0/05$ به s_1 منتقل می شود. پاداش آنی به دلیل هدررفت انرژی برابر با $R(s_0, a_1) = 0/6$ است.

۲. در حالت اشباع (s_1):

- با انتخاب توان کم (a_0): به دلیل ضعف سیگنال، احتمال بهبود اندک بوده و با احتمال $0/3$ به s_0 برگشته و با احتمال $0/7$ در s_1 می ماند. پاداش آنی به دلیل اتلاف پیام ها برابر با $R(s_1, a_0) = 0/1$ است.
- با انتخاب توان زیاد (a_1): با احتمال $0/85$ شبکه با غلبه بر نویز به حالت عادی s_0 بازمی گردد و با احتمال $0/15$ در s_1 باقی می ماند. پاداش آنی به دلیل تعادل میان پایداری و انرژی برابر با $R(s_1, a_1) = 0/5$ است.

فرضیات بالا را برای ارزیابی یک سیاست معین π در نظر می گیریم؛ سیاستی که همواره در حالت عادی گزینه کم مصرف را انتخاب کرده ($\pi(a_0 | s_0) = 1/0$) و در حالت نویزی بلافاصله توان را افزایش می دهد ($\pi(a_1 | s_1) = 1/0$). با در نظر گرفتن ضریب تنزیل زمان دار $\gamma = 0/9$ ، معادلات بلمن به شکل دستگاه معادلات خطی زیر بازنویسی می شوند:

$$V^\pi(s_0) = R(s_0, a_0) + \gamma [P(s_0 | s_0, a_0)V^\pi(s_0) + P(s_1 | s_0, a_0)V^\pi(s_1)]$$

$$V^\pi(s_1) = R(s_1, a_1) + \gamma [P(s_2 | s_1, a_1)V^\pi(s_2) + P(s_1 | s_1, a_1)V^\pi(s_1)]$$

با جایگذاری مقادیر احتمالی و عددی در معادلات فوق، خواهیم داشت:

$$V^\pi(s_2) = 1/0 + 0/9 [0/8V^\pi(s_2) + 0/2V^\pi(s_1)] \implies V^\pi(s_2) = 1/0 + 0/72V^\pi(s_2) + 0/18V^\pi(s_1)$$

$$V^\pi(s_1) = 0/5 + 0/9 [0/85V^\pi(s_2) + 0/15V^\pi(s_1)] \implies V^\pi(s_1) = 0/5 + 0/765V^\pi(s_2) + 0/135V^\pi(s_1)$$

برای حل این دستگاه خطی، ابتدا معادله اول را بر حسب $V^\pi(s_1)$ ساده می کنیم:

$$(1 - 0/72)V^\pi(s_2) = 1/0 + 0/18V^\pi(s_1)$$

$$\implies 0/28V^\pi(s_2) = 1/0 + 0/18V^\pi(s_1)$$

$$\implies V^\pi(s_2) \approx 3/5714 + 0/6428V^\pi(s_1)$$

با جایگذاری این تساوی در معادله دوم، مقدار ارزش حالت اشباع حاصل می شود:

$$(1 - 0/135)V^\pi(s_1) = 0/5 + 0/765(3/5714 + 0/6428V^\pi(s_1))$$

$$0/865V^\pi(s_1) \approx 0/5 + 2/7321 + 0/4917V^\pi(s_1)$$

$$0/3733V^\pi(s_1) \approx 3/2321 \implies V^\pi(s_1) \approx 8/6582$$

سرانجام، با جایگذاری مجدد در تساوی اول، مقدار ارزش حالت عادی به دست می آید:

$$V^\pi(s_2) \approx 3/5714 + 0/6428 \times 8/6582 \approx 9/1369$$

این ارقام به طور دقیق نشان می دهند که چگونه عامل یادگیرنده با انتخاب های هوشمندانه و تغییر پویا سیاست ها تحت تنزیل آتی پاداش ها، ارزش بلندمدت بسیار بالاتری را کسب می کند (ارزش حالت عادی ۹/۱۳ در مقایسه با پاداش آنی لحظه ای ۱/۰).

یادگیری تقویتی (RL) و الگوریتم های جدول محور: یادگیری تقویتی به عامل هوشمند امکان می دهد تا بدون نیاز به دانش صریح از پویایی های احتمالی محیط (یعنی بدون داشتن فرمول صریح تابع انتقال P و تابع

پاداش (R) و صرفاً از طریق تعامل فعال (آزمون و خطا) سیاست بهینه را یاد بگیرد [۱۱].
در الگوریتم های جدول محور کلاسیک مانند یادگیری Q (Q-learning) [۲۵] که یک الگوریتم فراسیاستی (off-policy) است، مقادیر ارزش عمل - حالت به طور مداوم درون یک جدول جامع به روزرسانی می شوند:

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

که در آن $\alpha \in (0, 1]$ نرخ یادگیری است. در مقابل، الگوریتم های درون سیاستی (on-policy) مانند **SARSA** [۲۶]، ارزش عمل بعدی را بر اساس سیاست جاری و عملی که واقعاً اتخاذ شده به روزرسانی می کنند.
هرچند الگوریتم های جدول محور و برنامه ریزی پویا (Dynamic Programming) تضمین همگرایی ریاضی دارند، اما به دلیل نیاز به حافظه بی پایان جهت نگهداری جداول بزرگ، در مسائلی که با انفجار فضای حالت و عمل روبه رو هستند کاملاً ناکارآمد بوده و با چالش نفرین ابعاد مواجه می گردند.

مقایسه ساختاری الگوریتم های یادگیری Q و **SARSA** جهت تبیین دقیق تفاوت های منطقی میان دو الگوریتم پایه ای یادگیری تقویتی جدول محور، جدول ۱-۲ معیارهای ساختاری، ایمنی و هزینه محاسباتی هرکدام را به تفصیل مقایسه کرده است [۱۱]. این تحلیل روشن می سازد که چرا رویکردهای مبتنی بر یادگیری Q (نظیر DQN مورد استفاده در این رساله) برای سیستم های خودوفق ترجیح داده می شوند.

جدول ۱-۲: مقایسه تطبیقی الگوریتم های جدول محور Q-Learning و SARSA

معیار مقایسه	یادگیری Q (Q-Learning)	الگوریتم SARSA
نوع سیاست	فراسیاستی (Off-Policy): به روزرسانی بر اساس فرضیه اقدام بهینه آتی صورت می گیرد.	درون سیاستی (On-Policy): به روزرسانی بر اساس اقدامی که واقعاً توسط سیاست اتخاذ شده، انجام می شود.
فرمول به روزرسانی	$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$	$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a) - Q(s, a)]$
سرعت همگرایی	سریع تر؛ به دلیل استفاده مستقیم از عملگر پیشینه سازی در هدف تفاوت زمانی.	کندتر؛ همگرایی وابسته به اصلاح تدریجی کل بدنه سیاست است.
ایمنی حین یادگیری	ریسک بالا؛ ممکن است رفتارهای متهورانه و آسیب زا جهت کشف مسیر بهینه اتخاذ کند.	ایمن تر؛ با پرهیز از اقدامات بهینه تهاجمی، از سیاست جاری محافظه کارانه تبعیت می کند.
تعمیم پذیری عصبی	بسیار بالا؛ پایه اصلی توسعه الگوریتم های عمیق بدون مدل نظیر DQN است.	متوسط؛ در ابعاد عمیق نیازمند معماری های تثبیت بسیار سنگین تری است.

یادگیری تقویتی عمیق (DQN) و مکانیزم های تثبیت: برای غلبه بر نفرین ابعاد در محیط های مقیاس بزرگ، الگوریتم شبکه Q عمیق (Deep Q-Network - DQN) معرفی شد که تابع ارزش Q را با استفاده از یک شبکه ی عصبی عمیق با پارامترهای θ تقریب می زند: $Q(s, a) \approx Q(s, a; \theta)$ [۱۹]. پارامترهای این شبکه از طریق

به حداقل رساندن تابع هزینه لایه‌ای در هر گام آموزش به‌روزرسانی می‌شوند:

$$L(\theta_i) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta_i^-) - Q(s, a; \theta_i) \right)^2 \right]$$

برای تضمین پایداری و جلوگیری از واگرایی فرآیند آموزش شبکه‌های عصبی در محیط‌های یادگیری تقویتی، دو نوآوری حیاتی در DQN اعمال می‌گردد. نوآوری نخست، حافظه بازپخش تجربه (Experience Replay) است که طی آن، عامل تجربیات خود را در قالب انتقال‌های (s, a, r, s') درون یک بافر ذخیره می‌کند و در طول فاز آموزش، به جای استفاده از تجربیات متوالی که دارای همبستگی شدید زمانی هستند، دسته‌های کوچکی از داده‌ها به صورت کاملاً تصادفی و یکنواخت از بافر نمونه‌برداری می‌شوند. این مکانیزم فرضیه داده‌های مستقل و توزیع‌شده به طور یکسان (i.i.d.) را احیا کرده و پایداری بهینه‌سازی را تضمین می‌کند. نوآوری دوم، شبکه هدف ثابت (Target Network - θ^-) است که در آن، محاسبه هدف بلمن به یک شبکه عصبی موازی با پارامترهای مستقل θ^- سپرده می‌شود؛ به طوری که وزن‌های این شبکه به جای هر گام، در بازه‌های زمانی مشخصی از شبکه اصلی کپی می‌شوند تا از نوسان‌های شدید و واگرایی تابع ارزش جلوگیری گردد.

در این بخش، چارچوب ریاضی تصمیم‌گیری تحت عدم قطعیت شامل فرآیندهای تصمیم‌گیری مارکوف (MDP)، مفاهیم یادگیری تقویتی و شبکه Q عمیق (DQN) تشریح گردید. همچنین یک مثال عددی ساده نحوه محاسبه ارزش حالت‌ها را تحت یک سیاست معین نشان داد. در بخش بعدی، این مفاهیم پایه‌ای را بر روی سیستم مورد مطالعه و محک استاندارد DeltaIoT پیاده‌سازی و فرمول‌بندی خواهیم کرد.

۲-۵ سیستم مورد مطالعه: شبکه‌های حسگر بی‌سیم DeltaIoT

۲-۵-۱ معماری، مؤلفه‌ها و ویژگی‌های فیزیکی

بستر DeltaIoT یک شبکه‌ی حسگر بی‌سیم صنعتی زمان واقعی است که برای ارزیابی رفتارهای خودوقتی‌سازی تحت شرایط نویزی شدید و پویای محیطی به کار گرفته می‌شود. معماری این پلتفرم از سه مؤلفه‌ی اصلی تشکیل شده است:

- **گره‌های حسگر (Sensor Nodes):** این گره‌ها وظیفه پایش محیط و تولید اطلاعات را بر عهده دارند. حسگرها پیام‌های تولیدی خود را به صورت چندگامی (multi-hop) از طریق گره‌های واسطه به سمت دروازه مرکزی ارسال می‌کنند.

• **دروازه مرکزی (Gateway):** مقصد نهایی تمامی پیام های شبکه است که وظیفه جمع آوری داده ها، تحلیل کیفیت شبکه و پایش کیفیت خدمات (QoS) را بر عهده دارد. کنترل کننده خودمختار ما بر پایه حلقه بازخورد MAPE-K بر روی این دروازه مستقر شده و گزینه های وفقی را ارزیابی و اعمال می نماید.

• **پیوندهای ارتباطی بی سیم (Wireless Links):** مسیرهای ارتباطی میان گره ها هستند که به صورت گسسته پیکربندی شده و کیفیت انتقال سیگنال بر روی آن ها تحت تاثیر شدید پارامترهای محیطی و تداخل احتمالی فرکانسی قرار دارد.

شکل ۱-۲ توپولوژی و ساختار پیوندهای ارتباطی در شبکه حسگر بی سیم DeltaIoTv1 را نشان می دهد که در آن سنسورها پیام های خود را به صورت چندگامی به سمت دروازه مرکزی ارسال می کنند.



شکل ۱-۲: توپولوژی و ساختار پیوندهای ارتباطی شبکه حسگر بی سیم DeltaIoTv1 [۲۷].

۲-۵-۲ مدل سازی فیزیکی و ریاضیاتی پدیده های کانال بی سیم

ارتباط میان گره ها در بستر DeltaIoT بر پایه مدل سازی احتمالی کانال انتقال بی سیم انجام می شود. نسبت سیگنال به نویز (SNR) برای هر پیوند ارتباطی بی سیم $e = (u, v)$ از رابطه ی زیر به دست می آید:

$$\text{SNR}_e(t) = P_{tx}(u) - \text{PL}(e) - X_\sigma - \eta(t) \quad (۱-۲)$$

که در آن $P_{tx}(u)$ توان ارسال گره فرستنده u (تنظیم شده در بازه گسسته $[۰, ۱۵]$ میلی وات)، $\text{PL}(e)$ افت مسیر کانال بی سیم (Path Loss)، X_σ متغیر تصادفی نرمال با توزیع احتمالی لگاریتمی-نرمال (Log-Normal Shadowing) برای بازنمایی اثر موانع فیزیکی، و $\eta(t)$ نویز و تداخل های فرکانسی متغیر با زمان در چرخه t است.

نرخ تحویل بسته (Packet Delivery Ratio - PDR) بر روی هر پیوند ارتباطی e بر اساس نسبت سیگنال به نویز به صورت یک تابع سیگموئید غیرخطی و احتمالی فرموله می گردد:

$$PDR_e(t) = \frac{1}{1 + e^{-\alpha(SNR_e(t) - \beta)}} \quad (2-2)$$

که در آن α و β پارامترهای کالیبراسیون سخت افزاری فرستنده بی سیم بر اساس استاندارد IEEE 802.15.4 هستند.

۳-۵-۲ جزئیات فرمول بندی معیارهای کیفیت خدمات (QoS) در فضای حالت

فضای حالت مسئله $S = (E, P, L)$ از سه مولفه ی کلیدی کیفیت خدمات تشکیل شده است که نحوه محاسبه دقیق ریاضی هر یک به شرح زیر است:

۱. مصرف انرژی کل شبکه (E): مصرف انرژی کل در هر چرخه وفقی t برابر با مجموع انرژی مصرفی تمامی گره های شبکه است:

$$E(t) = \sum_{v \in V} E_v(t) \quad (3-2)$$

مصرف انرژی گره v حاصل جمع انرژی مصرفی در فازهای ارسال، دریافت و گوش دادن فعال است:

$$E_v(t) = N_{sent}(v) \cdot E_{tx}(p_v) + N_{recv}(v) \cdot E_{rx} + T_{listen}(v) \cdot E_{listen} \quad (4-2)$$

که در آن $N_{sent}(v)$ تعداد بسته های ارسال شده توسط گره v با سطح توان p_v ، $E_{tx}(p_v)$ انرژی مصرفی برای ارسال با سطح توان مشخص، $N_{recv}(v)$ تعداد بسته های دریافت شده، E_{rx} انرژی فاز گیرندگی، $T_{listen}(v)$ مدت زمان گوش دادن فعال به کانال و E_{listen} توان مصرفی گره در حالت استماع است.

۲. نرخ اتلاف کل بسته ها (P): این معیار نشان دهنده درصدی از پیام های شبکه است که در طول مسیر انتقال به گیت وی به دلیل خطاهای کانال یا پر شدن بافر گره ها از بین رفته اند:

$$P(t) = \left(1 - \frac{N_{delivered}(t)}{N_{generated}(t)} \right) \times 100 \quad (5-2)$$

که در آن $N_{generated}(t)$ کل بسته های تولید شده توسط تمامی حسگرها در چرخه t ، و $N_{delivered}(t)$

تعداد بسته‌هایی است که با موفقیت توسط دروازه مرکزی دریافت شده‌اند. احتمال اتلاف بسته در طول یک مسیر چندگامی $\mathcal{P} = (v_1, v_2, \dots, v_k)$ که به گیت‌وی منتهی می‌شود، برابر است با:

$$P_{loss}(\mathcal{P}) = 1 - \prod_{i=1}^{k-1} \text{PDR}_{(v_i, v_{i+1})}(t) \quad (6-2)$$

۳. متوسط تاخیر زمان انتقال پیام‌ها (L): متوسط زمان مورد نیاز برای رسیدن یک بسته از زمان تولید در سنسور مبدا تا تحویل به دروازه است. با توجه به ساختار اسلات‌بندی شده شبکه (TDMA)، تاخیر هر بسته بر اساس تعداد گام‌ها و اسلات‌های تخصیص یافته در چرخه زمان‌بندی محاسبه می‌شود:

$$L(t) = \frac{1}{N_{delivered}(t)} \sum_{p \in \text{Delivered}} T_{arrival}(p) - T_{generation}(p) \quad (7-2)$$

که در آن $T_{generation}(p)$ زمان تولید پیام p در حسگر مبدا و $T_{arrival}(p)$ زمان دقیق ورود آن پیام به دروازه مرکزی است.

ارتباطات در DeltaIoT بر پایه استاندارد Time-Slotted Channel Bonding سازماندهی شده است؛ به طوری که زمان به چرخه‌های متوالی تقسیم شده و هر سنسور در اسلات‌های زمانی مشخصی مجاز به ارسال اطلاعات است.

۲-۵-۴ سناریوهای عدم قطعیت و فضای وفقی

شبکه DeltaIoT با دو چالش اصلی عدم قطعیت زمان اجرا مواجه است که پایداری عملیاتی آن را تهدید می‌کند. چالش نخست تداخل و نویز شبکه (Network Interference) است؛ عوامل محیطی نوسانات ناگهانی در نسبت سیگنال به نویز (SNR) ایجاد می‌کنند که مستقیماً نرخ اتلاف بسته‌ها را افزایش می‌دهد. چالش دوم تغییرات بار پیام‌ها (Traffic Fluctuations) است؛ بسته به رخدادهای محیطی، تعداد پیام‌های تولیدی در هر سنسور نوسان شدیدی پیدا می‌کند که موجب پر شدن بافرها و ایجاد تاخیر یا اتلاف داده می‌گردد.

ابعاد فضای وفقی در نسخه‌های مختلف DeltaIoT به شرح زیر است [۵]:

- نسخه v1: شامل ۱۵ سنسور با فضای وفقی به ابعاد ۲۱۶ گزینه ممکن.
- نسخه v1.1: شامل ۱۶ سنسور با فضای وفقی بالغ بر ۱۲۹۶ گزینه متمایز.
- نسخه v2 (بزرگ‌مقیاس): شامل ۳۷ سنسور که دارای فضای عظیم با ابعاد ۴۰۹۶ تصمیم ممکن می‌باشد.

هر گزینه وفقی در حقیقت ترکیبی از تخصیص توان انتقال انرژی به سنسورها (از سطح ۰ تا ۱۵) و تخصیص نسبی مسیرهای شبکه‌ای جهت هدایت بسته‌ها به گیت وی است.

۵-۵-۲ فرمول‌بندی به عنوان MDP

برای به کارگیری یادگیری تقویتی عمیق، مسئله تطبیق شبکه DeltaIoT را به صورت یک فرآیند تصمیم‌گیری مارکوف (MDP) فرمول‌بندی می‌کنیم:

تعریف فضای حالت (S): حالت سیستم در هر چرخه وفقی بازتاب‌دهنده عملکرد پویا و مصرف انرژی شبکه است:

$$S = \{(E, P, L) \mid E \in \mathbb{R}^+, P \in [0, 100], L \in [0, 100]\}$$

که در آن:

- E : مقدار حقیقی نشان‌دهنده انرژی کل مصرف‌شده توسط تمام سنسورهای شبکه در چرخه قبلی.
- P : درصدی از پیام‌ها که به مقصد نرسیده‌اند (نرخ اتلاف کل بسته‌ها).
- L : متوسط تاخیر ارسال پیام‌ها از سنسورها به گیت وی.

تعریف فضای عمل (A): فضای عمل عامل، مجموعه‌ای گسسته از تمامی پیکربندی‌های شبکه است:

$$A = \{a_1, a_2, \dots, a_n\}$$

که مقدار n بر اساس نسخه شبکه برابر با ۲۱۶، ۱۲۹۶ یا ۴۰۹۶ است. هر عمل a_i یک نگاشت کامل از توان‌های ارسال و مسیرهای توزیع برای تمامی گره‌ها می‌باشد.

فرمول‌بندی توابع پاداش (R): بسته به سناریوی ارزیابی، سه فرمول‌بندی پاداش تعریف می‌شود:

۱. پاداش چندهدفه (مبتنی بر پارتو):

$$R = w_E \cdot \left(\frac{E_{max} - E}{E_{max} - E_{min}} \right) + w_P \cdot \left(\frac{P_{max} - P}{P_{max} - P_{min}} \right) + w_L \cdot \left(\frac{L_{max} - L}{L_{max} - L_{min}} \right)$$

که در آن وزن‌ها مثبت بوده و مجموع آن‌ها برابر یک است: $\sum w_i = 1$.

۲. پاداش تک هدفه (کاهش مصرف انرژی):

$$R = \left(\frac{E_{max} - E}{E_{max} - E_{min}} \right) \cdot w_E \quad (\text{with } w_E = 1)$$

۳. پاداش اهداف آستانه ای (TT):

$$R = \begin{cases} 1 & \text{اگر } P < \theta_P \text{ و } L < \theta_L \\ 0 & \text{در غیر این صورت} \end{cases}$$

که در آن θ_P و θ_L آستانه های پذیرش کیفی خدمات سیستم هستند.

۲-۶ بیان مسئله و چارچوب بهینه سازی

۲-۶-۱ تعریف سیاست بهینه

مسئله نهایی ما، یافتن سیاست وفقی بهینه $\pi^* : S \rightarrow A$ است که ارزش پاداش تجمعی تنزیل یافته را در درازمدت بیشینه سازد:

$$\pi^* = \arg \max_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid \pi \right]$$

این سیاست بهینه به سیستم خودوفق امکان می دهد تا به طور خودکار بهترین تصمیمات تطبیقی را در مواجهه با نویز و ترافیک اتخاذ کند.

۲-۶-۲ تحلیل پیچیدگی مسئله تطبیق و ضرورت یادگیری تقویتی

پیش از تشریح قیود عملیاتی، اثبات صوری این موضوع که چرا روش های واریسی کامل یا تکاملی سستی در زمان اجرا ناکارآمد هستند، ضرورت دارد. مسئله تطبیق بهینه در یک شبکه حسگر بی سیم خودوفق (نظیر DeltaIoT) را می توان به صورت ریاضی به عنوان یک مسئله بهینه سازی چندهدفه مقید صورت بندی نمود. فرض کنید شبکه متشکل از مجموعه ای از گره ها V و پیوندهای ارتباطی E باشد. فضای عمل کل سیستم A حاصل ضرب دکارتی تصمیمات محلی تمام گره ها است:

$$A = \prod_{v \in V} A_v$$

هر گره v باید توان ارسال $p_v \in \{0, \dots, 15\}$ و توزیع مسیرهای خروجی $d_v \in [0, 1]^L$ را تعیین کند. هدف ما یافتن پیکربندی بهینه‌ای است که مجموع مصرف انرژی کل شبکه را کمینه سازد:

$$\min_{a \in A} \sum_{v \in V} \text{Energy}(v, a)$$

به طوری که قیود کیفی زیر ارضا گردند:

$$\text{PacketLoss}(a) < \theta_P$$

$$\text{Latency}(a) < \theta_L$$

قضیه ۱: مسئله بهینه‌سازی تطبیق مقید در حلقه‌های خودوفقی مقیاس وسیع، یک مسئله سخت بهینه یا ان‌پی-سخت (NP-hard) است [۲۸].

اثبات صوری از طریق کاهش: برای اثبات، این مسئله را به مسئله کوله‌پشتی چندبعدی (Multi-Dimensional Knapsack Problem - MDKP) [۲۸] که ان‌پی-سخت بودن آن اثبات شده است، کاهش می‌دهیم. در مسئله MDKP، مجموعه‌ای از اشیاء با ارزش‌ها و هزینه‌های چندگانه وجود دارند و هدف انتخاب زیرمجموعه‌ای است که ارزش بیشینه را تحت محدودیت ظرفیت تمام ابعاد کوله‌پشتی فراهم آورد. در فرمول‌بندی تطبیق ما:

۱. انتخاب توان ارسال و توزیع مسیر برای هر گره v معادل انتخاب یک شیء با ویژگی‌های مشخص در MDKP است.

۲. مصرف انرژی در شبکه معادل کمینه کردن وزن انتخاب‌ها در کوله‌پشتی است.

۳. قیود آستانه‌ای کیفیت خدمات (θ_L و θ_P) معادل ظرفیت‌های محدود چندبعدی کوله‌پشتی هستند که نباید از حد مشخصی تجاوز کنند.

۴. به دلیل وابستگی‌های غیرخطی اتلاف بسته‌ها و تاخیر در طول مسیرهای ارتباطی شبکه، ارزیابی هر پیکربندی مستلزم حل روابط انتشار سیگنال احتمالی است که پیچیدگی مسئله را از MDKP کلاسیک نیز فراتر می‌برد.

از آنجا که MDKP ان‌پی-سخت است، مسئله تطبیق مقید شبکه نیز ذاتاً ان‌پی-سخت خواهد بود. با رشد تعداد گره‌ها ($K = |V|$)، ابعاد فضای پیکربندی به صورت توان‌نمایی $O(C^K)$ رشد می‌کند؛ جایی

که C تعداد گزینه‌های محلی هر گره است. برای $\Delta IoTv$ ۲ با ۳۷ سنسور، این فضا به ابعاد سرسام‌آور ۴۰۹۶ حالت ممکن می‌رسد. واریسی جامع تمام گزینه‌ها در زمان اجرا به دلیل این پیچیدگی غیرممکن است. این تحلیل ریاضی اثبات می‌کند که چرا سیستم‌های زمان واقعی ناگزیرند از الگوریتم‌های یادگیری بدون مدل تقریب‌گر عصبی (نظیر DQN زمان اجرای ما) استفاده کنند که محاسبات سنگین را به صورت آفلاین یا پس‌زمینه انجام داده و در زمان اجرا تنها یک گذر رو به جلوی فوق‌سریع ($O(1)$ از نظر زمانی) را اعمال می‌نمایند.

۲-۶-۳ قیود عملیاتی زمان اجرا

جهت تطابق کامل با چالش‌های سیستم‌های نرم‌افزاری صنعتی معاصر، سیاست بهینه باید سه قید زیر را همزمان ارضا نماید:

۱. خروج پویا از بهینه‌های محلی (Local Optima Escape): سیاست باید در برابر تغییر شرایط محیطی انعطاف‌پذیر بوده و در دام سیاست‌های قدیمی نیمه‌بهینه گرفتار نشود.

۲. مقیاس‌پذیری و کارایی زمانی (Temporal Scalability): فرآیند تصمیم‌گیری آنلاین باید در کسری از میلی‌ثانیه رخ دهد. برای تحقق این امر، آموزش سنگین عمیق شبکه‌ی عصبی باید به صورت کاملاً ناهمگام (Asynchronous) در پس‌زمینه و مجزا از مسیر تصمیم‌گیری زمان اجرا انجام شود.

۳. استقلال کامل از دانش دامنه (Domain Independence): فرآیند کاوش و بازپخش تجربیات نباید وابسته به مختصات صریح اهداف یا دانش از پیش تعریف‌شده باشد تا راهکار قابلیت تعمیم به دامنه‌های مختلف نرم‌افزاری را حفظ کند.

۲-۷ سیستم مورد مطالعه دوم: شبیه‌ساز مأموریت پهپاد DARTSim

شبیه‌ساز مأموریت DARTSim [۲۹] یک بستر شبیه‌سازی فیزیکی-سایبری هوایی برای ارزیابی تصمیم‌گیری‌های انطباقی زمان اجرای تیم‌های پهپادی در محیط‌های پرخطر است. در این سیستم، یک تیم پهپادی باید با اتخاذ استراتژی‌های وفقی تاکتیکی، بقای خود را حفظ کرده و اهداف مأموریت (مانند شناسایی اهداف و خروج از شعاع راداری تهدیدات) را پیشینه نماید. این بستر، چالش‌های متفاوتی را نسبت به شبکه‌های حسگر بی‌سیم به تصویر می‌کشد و آزمونی حیاتی برای ارزیابی چنددامنه‌ای و استقلال از دامنه روش پیشنهادی رساله به شمار می‌رود.

۲-۷-۱ خاستگاه علمی و جایگاه به عنوان محک

برخلاف یک محیط شبیه سازی دلخواه، DARTSim ریشه در یکی از محک های شناخته شده و پراستناد حوزه سیستم های خود فوق دارد. این بستر بر پایه ی مسئله ی تیم پهپادهای خودگردان (UAV Team) که نخستین بار توسط مورنو و همکاران [۳۰] در چارچوب انطباق پیش نگرانه تحت عدم قطعیت معرفی شد، استوار گردیده است. در این مسئله، تیمی از پهپادها مأموریت پیمایش و شناسایی را در یک محیط متخاصم اجرا می کنند و باید میان دو هدف متضاد تعادل برقرار سازند: پرواز در ارتفاع پایین تر احتمال شناسایی اهداف زمینی را افزایش می دهد اما هم زمان مواجهه با تهدیدات راداری را تشدید می کند، در حالی که پرواز در ارتفاع بالاتر ریسک تهدید را می کاهش دهد ولی شناسایی اهداف را دشوارتر می سازد.

همین مسئله ی پهپادی، در پژوهش های متأخرتر از جمله چارچوب TUNE-II مبتنی بر میانگین گیری مدل بیزی [۳۱] نیز به عنوان یک مطالعه موردی مرجع برای ارزیابی انطباق چندهدفه تحت عدم قطعیت مدل به کار گرفته شده است. انتخاب DARTSim در این رساله از دو منظر توجیه می شود: نخست، اعتبار علمی و تکرارپذیری آن به عنوان یک محک تثبیت شده؛ و دوم، تمایز ماهوی دامنه آن (تصمیم گیری تاکتیکی بلادرنگ هوایی در فضای حالت پیوسته و فضای اقدام گسسته) نسبت به مطالعه موردی نخست (DeltaIoT)، که امکان سنجش دقیق / استقلال از دامنه روش پیشنهادی را فراهم می آورد.

۲-۷-۲ فضای معنایی سیستم (Semantic Space)


رفتار سیستم پهپادی توسط مجموعه ای از عوامل پیکربندی (قابل کنترل توسط عامل انطباقی) و عوامل محیطی (منابع عدم قطعیت بیرونی) تعیین می شود که مجموعاً «فضای معنایی» سیستم را تشکیل می دهند. جدول ۲-۲ این عوامل را به تفکیک نوع، دامنه و نقش آن ها در مأموریت خلاصه می کند.

جدول ۲-۲: فضای معنایی سیستم پهپادی DARTSim (عوامل پیکربندی و محیطی)

عامل	نوع	دامنه	توضیح
آرایش تیمی (formation)	پیکربندی	{tight, loose}	هندسه آرایش فضایی تیم پهپادی هنگام اجرای مأموریت.
سرعت پرواز (flying speed)	پیکربندی	[5, 50] mph	سرعت متوسط پرواز که بر احتمال شناسایی و فرار اثر می گذارد.
اخلال گر الکترونیکی (ECM)	پیکربندی	{On, Off}	فعال سازی اخلال برای کاهش احتمال شناسایی توسط تهدیدات.
وضعیت جوی (weather)	محیطی	{sun, clouds, rain, fog}	شرایط هواشناسی مؤثر بر عملکرد حسگرها و پرواز.
زمان روز (day time)	محیطی	00:00-23:59	زمان روز که بر میدان دید و احتمال شناسایی اثرگذار است.
شعاع تهدید (threat range)	محیطی	[0.9, 3.7] km	شعاع شناسایی تهدیدات که میزان مواجهه پهپاد را تعیین می کند.
تعداد تهدیدات (# threats)	محیطی	[1-10]	شمار تهدیدات فعال در منطقه عملیاتی.

نمودار مفهومی شکل ۲-۲ برهم کنش این عوامل را به تصویر می کشد: عوامل پیکربندی و محیطی هر دو بر عملکرد تیم پهپادی در دل «محیط متخاصم» اثر گذاشته و در نهایت تحقق اهداف وابستگی پذیری (شناسایی هدف و اجتناب از تهدید) را تعیین می کنند. شایان ذکر است که این فضای معنایی هفت عاملی، خاستگاه

مفهومی مسئله را تبیین می‌کند؛ تحقق عملیاتی آن در این رساله به صورت یک بردار حالت ۱۷ بعدی و فضای اقدام گسسته ۸ گانه (که در ادامه تشریح می‌شود) صورت‌بندی شده است.



شکل ۲-۲: نمودار مفهومی عوامل اثرگذار بر اهداف وابستگی‌پذیری تیم پهپادی DARTSim؛ عوامل پیکربندی و محیطی در یک محیط متخاصم بر تحقق اهداف شناسایی هدف و اجتناب از تهدید اثر می‌گذارند.

۳-۷-۲ اهداف و الزامات وابستگی‌پذیری

اهداف مأموریت در DARTSim از دو الگوی الزام پارامتری مشتق می‌شوند که هر دو حول مفهوم محوری مصالحه‌ی ارتفاع شکل گرفته‌اند: الگوی نخست، الگوی شناسایی هدف (Target Detection)، بیان می‌کند که «هنگامی که ارتفاع میان θ_1 و θ_2 متر است، تیم پهپادی باید در بیش از p_1 درصد موارد هدف را شناسایی کند.» این الگو بیشینه‌سازی قابلیت اطمینان شناسایی را هدف می‌گیرد. الگوی دوم، الگوی اجتناب از تهدید (Threat Avoidance)، در مقابل بیان می‌کند که «هنگامی که ارتفاع میان θ_1 و θ_2 متر است، تهدیدات موجود باید در کمتر از p_2 درصد موارد پهپادها را شناسایی کنند.» این الگو کمینه‌سازی مواجهه با تهدید را دنبال می‌کند. با نمونه‌سازی این دو الگو بر روی شش بازه‌ی ارتفاعی و آستانه‌های احتمال متناظر، مجموعاً ۱۲ الزام وابستگی‌پذیری ملموس (۶ مورد شناسایی و ۶ مورد اجتناب) حاصل می‌گردد. ماهیت متضاد این اهداف — که در آن کاهش ارتفاع، شناسایی را بهبود می‌بخشد اما مواجهه با تهدید را افزایش می‌دهد — همان مسئله بهینه‌سازی چندهدفه‌ای است که عامل انطباقی باید در زمان اجرا و تحت عدم قطعیت آن را حل کند.

۴-۷-۲ معماری، مؤلفه ها و ویژگی های فیزیکی

سامانه پهپادی در شبیه ساز DARTSim از چندین مؤلفه فیزیکی و سایبری تشکیل شده است:

- **بدنه پهپادها (UAV Fleet):** شامل دسته ای از پهپادها که دارای حسگرهای شناسایی هدف، اخلاص گره های الکترونیکی فعال و موتورهای هدایتی آرایش تیمی هستند.
- **محیط مأموریت (Mission Environment):** شامل گره های هدف که باید شناسایی شوند و مناطق تحت پوشش پدافندی دشمن (تهدیدات موشکی و رادارها).
- **سیستم اخلاص گره الکترونیکی (ECM):** یک سیستم فعال که پهپادها می توانند برای مسدود کردن امواج رادارها روشن کنند؛ اما این عمل با هزینه جریمه شدید مصرف انرژی همراه است.

۵-۷-۲ جزئیات فرمول بندی معیارهای کیفیت خدمات (QoS) در فضای حالت

اهداف چندهدفه مأموریت در سه محور اساسی فرمول بندی می شوند:

۱. **نرخ بقای تیم (Team Survival Rate):** پهپادها در صورت برخورد با موشک های تهدیدآمیز منهدم می شوند. این معیار در پایان مأموریت به عنوان پاداش نهایی اعمال می گردد (در صورت انهدام جریمه سنگین و در صورت بقا پاداش مثبت دریافت می کنند).
۲. **پوشش اهداف شناسایی شده (Targets Detected):** کسر اهداف شناسایی شده توسط حسگرها نسبت به کل اهداف موجود در نقشه که باید به پیشینه برسد.
۳. **مدیریت مصرف انرژی اخلاص گره الکترونیکی (ECM Energy):** اخلاص گره های الکترونیکی باید تنها در صورت مواجهه با رادارهای فعال دشمن روشن شوند تا مصرف انرژی پهپادها در سطح متعادلی حفظ گردد.

۶-۷-۲ سناریوهای عدم قطعیت و فضای وقتی

عدم قطعیت در DARTSim ناشی از پویایی محیطی، محل نامشخص تهدیدات دشمن و نوسان پایداری ارتباطات میان پهپادها است. فضای وقتی سیستم شامل اقدامات تاکتیکی برای تنظیم ارتفاع و هندسه آرایش تیمی است. این اقدامات گسسته عبارتند از:

- **اقدامات تنظیم ارتفاع:** شامل افزایش ارتفاع به میزان متوسط یا شدید (IncAlt، IncAlt2) و کاهش ارتفاع (DecAlt، DecAlt2) برای فرار از شعاع رادارهای کم ارتفاع یا پدافندهای دوربرد.

- اقدامات تنظیم هندسه آرایش: شامل فشردن سازی آرایش تیمی برای کاهش اثر راداری یا افزایش پراکندگی پهپادها (GoLoose, GoTight).
 - اقدامات کنترل اخلاک گر: شامل روشن یا خاموش کردن سیستم اخلاک الکترونیکی (EcmOff, EcmOn).
- این فضای وفقی شامل ۸ اقدام گسسته است که تصمیم گیری بلادرنک در هر ثانیه از مسیر پرواز را الزامی می کند.

۷-۷-۲ مدل سازی عدم قطعیت محیطی و تصادفی بودن حسگرها


ویژگی متمایزکننده DARTSim و دلیل اصلی تناسب آن با موضوع این رساله، ماهیت ذاتاً تصادفی (Stochastic) محیط آن است. در این بستر، یک زوج حالت-اقدام یکسان می تواند به پیامدهای متفاوتی منجر شود؛ این عدم قطعیت عمدتاً از نویز حسگرها و تغییرپذیری محیطی سرچشمه می گیرد. تحلیل تراکشن های ثبت شده نشان می دهد که هرچند بخشی از گذارها قطعی اند، بخش قابل توجهی از زوج های حالت-اقدام چندین پیامد ممکن تولید می کنند و منشأ اصلی این پراکندگی، قرائت حسگرهای شناسایی تهدید و هدف است. شکل ۲-۳ داشبورد جامعی از این تحلیل را ارائه می دهد که در آن توزیع تصادفی بودن گذارها، سهم هر مؤلفه ای حالت در ایجاد عدم قطعیت و پراکندگی پاداش ها به تفکیک نمایش داده شده است.

برای تبیین ملموس تر این پدیده، شکل ۲-۴ چند نمونه از زوج های حالت-اقدام را نشان می دهد که در آن ها قرائت حسگرهای تهدید و هدف (پنج سلول پیش رو) برای پیامدهای گوناگون ناشی از یک اقدام واحد تغییر می کند. این تصادفی بودن، عامل انطباقی را وادار می سازد که به جای حفظ کردن مسیرهای قطعی، سیاست های مقاومی بیاموزد که در سراسر پیامدهای محتمل کارا باشند. دقیقاً همین چالش کاوش و یادگیری تحت عدم قطعیت سنگین است که الگوریتم پیشنهادی RS-DRL برای غلبه بر آن طراحی شده است.

۸-۷-۲ فرمول بندی به عنوان MDP

مسئله انطباق تاکتیکی پهپادها در شبیه ساز DARTSim به صورت یک MDP استاندارد فرمول بندی می شود:

- فضای حالت (S): بردار حالت ۱۷ بعدی $s_t \in \mathbb{R}^{17}$ شامل موقعیت مکانی تیم پهپادی، سطح ارتفاع جاری، هندسه آرایش تیمی، وضعیت فعال سازی اخلاک گر الکترونیکی و فاکتورهای شناسایی تهدیدات و اهداف است.
- فضای اقدام (A): فضای اقدامات شامل ۸ اقدام وفقی تاکتیکی گسسته است که در بخش قبل شرح داده شد.



شکل ۲-۳: داشبورد تحلیل عدم قطعیت محیطی DARTSim: توزیع تصادفی بودن گذارها، عدم قطعیت به تفکیک نوع اقدام و مؤلفه حالت، تغییرپذیری قرائت حسگر تهدید و پراکندگی پاداش ها.


• تابع پاداش چندهدفه (R): پاداش تجمعی زمان اجرا به صورت ترکیب وزنی زیر فرمول بندی می گردد:

$$R(s_t, a_t) = w_{\text{survival}} \cdot r_{\text{surv}}(s_t) + w_{\text{target}} \cdot r_{\text{target}}(s_t) - w_{\text{energy}} \cdot c_{\text{energy}}(a_t) - c_{\text{step}} \quad (2-18)$$

که در آن $c_{\text{step}} = 0.1$ جریمه زمانی هر گام مأموریت است.

۹-۷-۲ محیط انطباق آفلاین (Offline Replay Adapter)

به منظور غلبه بر محدودیت های پایداری اتصالات شبکه و داکر دسکتاپ در فاز آموزش، یک محیط انطباق آفلاین تحت عنوان OfflineDARTSimEnv طراحی گردید. این آداپتور، تعامل بلادرنگ با شبیه ساز را با یک ساختار جستجوی هوشمند تراکنش های از پیش ثبت شده (Offline Collected Data) جایگزین می کند. بر این اساس، بانک داده ای شامل ۵۰۰۰۰ انتقال حالت جمع آوری شده از مأموریت های واقعی پهپاد در سناریوی پایه (Baseline) لود شده و تراکنش های بعدی به صورت بازپخش ساختاریافته همان مسیرهای ثبت شده شبیه سازی می شوند. این رویکرد آفلاین منجر به تضمین کامل پایداری، سرعت بی سابقه فرآیند همگرایی یادگیری و تکرارپذیری مطلق آزمایش ها می گردد.



شکل ۲-۴: نمونه‌هایی از تغییرپذیری قرائت حسگرهای تهدید و هدف برای یک زوج حالت-اقدام یکسان در DARTSim؛ هر سطر یک پیامد ممکن و هر ستون یک سلول حسگر پیش‌رو را نشان می‌دهد.

۲-۷-۱۰ طیف دشواری محیط و فضای طراحی سناریوها


محیط DARTSim به گونه ای طراحی شده است که طیفی از سطوح دشواری فزاینده را پشتیبانی کند؛ این طیف از یک نقشه ی خطی ساده تا نقشه های مربعی بزرگ با الگوی مسیر مارپیچی و چگالی بالای تهدید و هدف گسترده است و فضای طراحی لازم برای سنجش آینده نگر مقیاس پذیری و قابلیت تعمیم را فراهم می آورد. جدول ۲-۳ پارامترهای کلیدی این سه سناریوی پیکربندی پذیر را مقایسه می کند.

جدول ۲-۳: طیف سناریوهای پیکربندی پذیر محیط DARTSim و سطوح دشواری آنها

سناریو	ابعاد نقشه	نوع نقشه	تهدیدات	اهداف	سطوح ارتفاع	دشواری
پایه (Baseline)	40×1	خطی	۵	۳	۴	آسان
متوسط (Medium)	50×50	مربعی (مارپیچ)	۱۰	۵	۵	متوسط
سخت (Hard)	60×60	مربعی (مارپیچ)	۱۵	۸	۶	سخت

سناریوی پایه دارای مسیر مستقیم و چگالی متعادل تهدیدها است؛ سناریوهای متوسط و سخت با افزودن مسیرهای مارپیچی پرپیچ و خم، نقشه های بزرگ تر و چگالی بالاتر تهدید و هدف، پیچیدگی روزافزون محیط را به تصویر می کشند. شکل ۲-۵ نمای مقایسه ای این سه سناریو را به همراه چیدمان تهدیدها، اهداف و الگوی مسیر نشان می دهد.

شایان توجه است که ارزیابی های تجربی گزارش شده در این رساله (بخش ۵-۶-۶) بر پایه ی مجموعه داده آفلاین جمع آوری شده از سناریوی پایه انجام شده اند؛ چرا که این سناریو با تأمین فضای حالت گسسته ی بزرگ و توزیع پاداش به شدت پراکنده، چالش اصلی خروج از بهینه های محلی را به صورت کنترل شده فراهم می سازد. سناریوهای متوسط و سخت به عنوان فضای طراحی از پیش آماده ی محیط برای گسترش ارزیابی مقیاس پذیری و تعمیم پذیری در کارهای آتی (به ویژه در حالت برخط) معرفی شده اند.



شکل ۲-۵: مقایسه ی سه سناریوی DARTSim (پایه، متوسط و سخت)؛ تفاوت در چیدمان نقشه، پیچیدگی مسیر و چگالی تهدید و هدف.

۸-۲ خلاصه فصل

این فصل به تفصیل مبانی نظری و صوری مورد نیاز برای درک تصمیم‌گیری تحت عدم قطعیت در سیستم‌های خودفوق را تشریح نمود. ما با تحلیل مفاهیم سیستم‌های خودفوق، حلقه‌های MAPE-K و طبقه‌بندی معتبر واکر از عدم قطعیت آغاز کردیم. سپس فرآیند تصمیم‌گیری مارکوف (MDP) و الگوریتم‌های یادگیری تقویتی جدول‌محور و عمیق (DQN) را به عنوان ابزارهای تصمیم‌گیری زمان اجرا معرفی کردیم. در نهایت، با استفاده از سیستم محک استاندارد DeltaIoT، فرمول‌بندی MDP دقیق شبکه را بر پایه معیارهای انرژی، تلفات و تاخیر تبیین نمودیم. این زیربنای مستحکم نظری، مستقیماً به شناسایی شکاف‌های تحقیقاتی سه‌گانه در فصل ۳ (شامل تنگنای زمان تصمیم‌گیری، عدم تطابق اهداف آستانه‌ای و ایستایی توابع پتانسیل) کمک خواهد کرد. همچنین، مفاهیم پیشرفته‌ی ارائه شده در این فصل، سنگ بنای طراحی معماری نوآورانه RS-DRL در فصل ۴ را تشکیل می‌دهند که هدف آن حل مسئله بهینه‌سازی ان‌پی-سخت با استنتاج زمان اجرای فوق‌سریع و پایدار است. با پی‌ریزی این بنیان تئوریک و ریاضی مستحکم، اکنون بستر لازم برای واکاوی عمیق پیشینه پژوهش در فصل بعدی و ترسیم مسیر علمی رساله فراهم آمده است.

فصل ۳

مرور پیشینه پژوهش و کارهای مرتبط

۱-۳ مقدمه و روش‌شناسی مرور

هدف بنیادین این فصل، ارائه یک بررسی نظام‌مند، انتقادی و عمیق از ادبیات علمی و رویکردهای موجود در زمینه مدیریت عدم قطعیت و تصمیم‌گیری زمان اجرا در سیستم‌های خوددوفق (Self-Adaptive Systems - SAS) است. در طراحی مهندسی سیستم‌های خوددوفق مدرن، اتخاذ تصمیمات وفقی بهینه در مواجهه با شرایط پویای محیطی و فضاهاى تصمیم‌گیری بسیار بزرگ، یکی از چالش‌های بنیادین به شمار می‌رود. کارهای پیشین هر یک از زاویه‌ای خاص به این مسئله نگریسته‌اند؛ با این حال، به منظور درک دقیق سهم علمی این رساله و تبیین دقیق ضرورت ارائه الگوریتم RS-DRL، تحلیل موشکافانه و مقایسه‌ای این رویکردها امری حیاتی است. بدین منظور، در این فصل روش‌شناسی مروری ساختاریافته‌ای اتخاذ گردیده است. فرآیند شناسایی و گزینش مقالات از طریق جستجوی جامع در پایگاه‌های داده معتبر بین‌المللی از جمله ACM، IEEE Xplore، Scopus، Digital Library و Google Scholar صورت پذیرفته است. بازه زمانی جستجو متمرکز بر پژوهش‌های برجسته دو دهه اخیر بوده و کلمات کلیدی نظیر «سیستم‌های خوددوفق»، «یادگیری تقویتی آنلاین»، «شکل‌دهی پاداش»، «فضای وفقی بزرگ» و «تأیید صوری زمان اجرا» به عنوان معیارهای اصلی فیلترینگ استفاده شده‌اند. معیارهای ورود مقالات به چرخه بررسی انتقادی شامل تمرکز بر روی مدیریت فضاهاى وفقی گسسته در زمان اجرا و توانایی سیستم در تصمیم‌گیری آنلاین تحت شرایط عدم قطعیت بوده است.

جهت ارزیابی نظام‌مند و مقایسه‌ای عادلانه پیشینه پژوهش، یک چارچوب ارزیابی پنج‌بعدی بر پایه معیارهای مهندسی نرم‌افزار خوددوفق [۴، ۳۲] توسعه داده شده است که تمامی آثار بررسی‌شده بر اساس این شاخص‌ها مورد نقد قرار می‌گیرند:

۱. ابعاد فضای وفقی (Adaptation Space Size): توانایی متدولوژی پیشنهادی در مقیاس‌پذیری و

مدیریت فضاهاى تصمیم‌گیری گسسته و بزرگ (فراتر از ۱۰۰۰ گزینه و فقی).

۲. مدیریت پویایی و عدم قطعیت زمان اجرا (Handling of Non-Stationarity): پایداری عملکرد سیستم در مواجهه با رانش مفهومی (Concept Drift) و تغییرات پیش‌بینی‌نشده محیطی بدون افت کیفیت خدمات.

۳. عدم وابستگی به دانش دامنه خاص (Need for Domain Knowledge): میزان نیاز به تخصص انسانی زمان توسعه یا طراحی اهداف صریح و پیچیده برای عامل یادگیرنده.

۴. مقیاس‌پذیری و کارایی محاسباتی (Real-Time Scalability): توانایی تصمیم‌گیری آنلاین در محدوده میلی‌ثانیه به منظور رعایت قیود پایداری زمانی سیستم.

۵. قابلیت خروج از بهینه‌های محلی (Ability to Escape Local Optima): کارایی مکانیزم‌های کاوش در فرار از تله‌های بهینگی محلی در طول یادگیری آنلاین.

۱

در ادامه‌ی این فصل، ابتدا مبانی نظری عدم قطعیت و تصمیم‌گیری در سیستم‌های خوددوق تشریح شده، سپس سه پارادایم اصلی تصمیم‌گیری (مبتنی بر یادگیری ماشین سنتی، مبتنی بر جستجو و مبتنی بر یادگیری تقویتی عمیق) به صورت موشکافانه تحلیل می‌گردند. در نهایت، با بررسی روش‌های پیشرفته بازپخش تجربه و شکل‌دهی پاداش و نقش روش‌های صوری، خلاءهای پژوهشی موجود استخراج و جایگاه الگوریتم پیشنهادی RS-DRL تبیین می‌گردد.

۲-۳ مبانی نظری: عدم قطعیت و تصمیم‌گیری در سیستم‌های خوددوق

سیستم‌های خوددوق به منظور حفظ اهداف کیفی خود (نظیر قابلیت اطمینان، مصرف انرژی و تأخیر)، نیازمند پایش مستمر محیط فیزیکی و تصمیم‌گیری بهینه در زمان اجرا هستند [۲، ۴]. با این حال، تصمیم‌گیری در این سیستم‌ها تحت تأثیر شدید منابع گوناگون عدم قطعیت قرار دارد. عدم قطعیت در ادبیات مهندسی نرم‌افزار خوددوق [۳۳، ۴] به طور کلی به سه دسته اصلی تقسیم می‌شود: عدم قطعیت محیطی (مانند نوسانات تداخل سیگنال در شبکه‌های اینترنت اشیا)، عدم قطعیت سیستمی (نظیر خرابی‌های ناگهانی سخت‌افزار یا تغییرات زیرساختی) و عدم قطعیت اهداف (تغییر در اولویت‌های کیفی کاربران در طول زمان).

^۱ این پنج معیار ارزیابی برای اولین بار در این رساله تدوین شده‌اند. جدول ۱-۳ در انتهای همین فصل (صفحه ۴۰) مقایسه تطبیقی جامع روش پیشنهادی RS-DRL را با کارهای پیشین بر اساس این پنج بعد ارائه می‌دهد.

برای مدل‌سازی فرآیند تصمیم‌گیری در مواجهه با این عدم قطعیت‌ها، مهندسان سیستم‌های خوددوفق از ابزارهای ریاضیاتی متعددی بهره می‌برند:

- **فرآیند تصمیم‌گیری مارکوف (MDP):** استانداردترین روش مدل‌سازی ریاضی تصمیم‌گیری پیاپی است که در آن فرض می‌شود وضعیت بعدی سیستم تنها به وضعیت فعلی و اقدام اتخاذ شده وابسته است [۱۰]. در سیستم‌های خوددوفق، وضعیت‌ها نشان‌دهنده شرایط محیطی و پیکربندی‌های سیستم، و اقدامات نشان‌دهنده گزینه‌های وفقی هستند.

- **فرآیند تصمیم‌گیری مارکوف نیمه‌مشاهده‌پذیر (POMDP):** در شرایطی استفاده می‌شود که عامل یادگیرنده دسترسی کامل به وضعیت واقعی محیط ندارد و تنها مشاهدات نویزی در اختیار دارد [۳۴]. اگرچه POMDP واقع‌گرایانه‌تر است، اما حل آن سربار محاسباتی بسیار بالایی دارد که مانع تصمیم‌گیری آنلاین بلادرنگ می‌شود.

- **جستجوی تصادفی زمان‌اجرا:** رویکردی غیرمدل‌محور است که سیستم با نمونه‌برداری زمان‌اجرا از فضای تغییرات، تلاش می‌کند گزینه‌ای را بیابد که اهداف سیستم را ارضا نماید.

یکی از چالش‌های بنیادین ریاضیاتی در تصمیم‌گیری آنلاین سیستم‌های خوددوفق، پدیده **تله بهینه‌های محلی (Local Optima Trap)** است [۳۵]. در فضاهاى وفقی بزرگ و گسسته، تابع مطلوبیت یا پاداش سیستم معمولاً غیرخطی، چندهدفه و دارای تپه‌های متعدد است. هنگامی که یک الگوریتم تصمیم‌گیری آنلاین یا عامل یادگیرنده تلاش می‌کند تا از طریق کاوش محلی (مانند شیب صعودی یا استراتژی‌های حریصانه) پیکربندی بهینه را بیابد، به شدت مستعد گرفتار شدن در نقاطی است که عملکرد بهتری نسبت به همسایگان بلاواسطه خود دارند، اما با بهینه سراسری (Global Optima) فاصله زیادی دارند.

این مشکل در شبکه‌های پویا نظیر DeltaIoT تشدید می‌شود [۵]؛ زیرا در این شبکه‌ها، تغییرات تداخل محیطی باعث تغییر مداوم قله‌های بهینگی می‌شود. اگر عامل تصمیم‌گیرنده نتواند با ترکیب بهینه‌ی کاوش (Exploration) و بهره‌برداری (Exploitation)، به طور مداوم و پویا فضای تصمیم‌گیری را جستجو کند، در یک سیاست تطبیقی منجمد شده و با تغییر شرایط محیطی دچار افت شدید کیفیت خدمات می‌گردد. در بخش‌های بعدی، نحوه مواجهه رویکردهای کلاسیک با این چالش ریاضیاتی را به تفصیل نقد خواهیم نمود.

۳-۳ رویکردهای اصلی مدیریت فضای وفقی در زمان اجرا

به منظور تحلیل و مقایسه‌ی پیشینه پژوهش در زمینه مدیریت فضاهاى وفقی بزرگ، آثار علمی موجود را می‌توان به سه پارادایم اصلی تقسیم‌بندی نمود: رویکردهای مبتنی بر یادگیری ماشین سنتی برای هرس فضا، روش‌های

مبتنی بر جستجو و بهینه‌سازی آنلاین، و مدل‌های مبتنی بر یادگیری تقویتی برای تصمیم‌گیری زمان اجرا. در ادامه، هر یک از این رویکردها را بر اساس چارچوب ارزیابی پنج‌بعدی معرفی شده نقد علمی می‌نماییم.

۱-۳-۳ هرس فضای وقتی مبتنی بر یادگیری ماشین سنتی

یکی از ایده‌های نخستین برای مقابله با انفجار ترکیبی گزینه‌های وقتی در سیستم‌های خودوق بزرگ، هرس پیشاپیش فضای وقتی پیش از ارسال به مؤلفه‌ی تصمیم‌گیر (یا برنامه‌ریز) است. در این دسته از رویکردها، مهندسان سیستم تلاش می‌کنند تا با استفاده از مدل‌های پیش‌بینی‌کننده یادگیری ماشین سنتی، گزینه‌های نامطلوب را فیلتر نمایند.

پژوهش‌های برجسته‌ی کوئین (Quin) و همکارانش [۱۲، ۱۳] از رویکردهای پیشگام در این زمینه است. آن‌ها با به‌کارگیری تکنیک‌های طبقه‌بندی نظارت‌شده (مانند درخت تصمیم و جنگل تصادفی) نشان دادند که می‌توان با آموزش یک مدل روی داده‌های تاریخی، پیکربندی‌هایی را که شانس بسیار پایینی برای ارضای کیفیت خدمات (QoS) دارند، شناسایی و هرس کرد. به طور مشابه، کچی و بواناکا [۲۰] متدولوژی (Ma-) ML4EAS (chine Learning for Evaluating Adaptation Space) را توسعه دادند که از ترکیب الگوریتم‌های طبقه‌بندی و رگرسیون برای پیش‌بینی و غربالگری گزینه‌های ناکارآمد در سیستم‌های توزیع‌شده بهره می‌برد. این روش‌ها قادرند ابعاد فضای جستجو را در سناریوهای ایستا تا ۶۰ درصد کاهش دهند [۲۰].

نقد و بررسی انتقادی: علیرغم کارایی این روش‌ها در کاهش اندازه محیط تصمیم‌گیری زمان اجرا، دو محدودیت بنیادین در این متدولوژی‌ها وجود دارد. از یک سو، این روش‌ها با وابستگی شدید به داده‌های برچسب‌دار آفلاین مواجه هستند؛ چرا که فرآیند آموزش این طبقه‌بندها مستلزم جمع‌آوری مجموعه داده‌های بسیار حجیم و متنوع در زمان توسعه (Design-time) است و در سیستم‌های پیچیده معاصر، شبیه‌سازی تمامی سناریوهای نویزی و محیطی در زمان طراحی ناممکن است [۷، ۱۳]. از سوی دیگر، پدیده رانش مفهومی (Concept Drift) چالش مهم دیگری است؛ غیبی و وینز [۷] در تحلیل‌های خود تصریح کرده‌اند که در محیط‌های بسیار پویا (مانند اینترنت اشیا شهری با تداخلات متغیر)، الگوهای نویز و ویژگی‌های سیستم دستخوش تغییر مستمر زمان اجرا می‌شوند. با رخ دادن رانش مفهومی، فرضیات اولیه طبقه‌بندهای یادگیری ماشین نامعتبر گشته و دقت مدل در هرس گزینه‌ها به شدت افت می‌کند. برای جبران این افت، سیستم ناگزیر به آموزش مجدد (Retraining) مکرر و بسیار پرهزینه مدل در زمان اجراست، که این فرآیند علاوه بر ایجاد سربار محاسباتی زیاد، سیستم را در طول فرآیند آموزش در وضعیت ناپایدار و غیرایمن قرار می‌دهد و در نهایت منجر به ایجاد یک موازنه شکننده بین مقیاس‌پذیری و استواری می‌گردد.

۲-۳-۳ روش‌های مبتنی بر جستجوی آنلاین و استراتژی‌های اکتشافی

پارادایم دوم، تصمیم‌گیری زمان اجرا را به عنوان یک مسئله‌ی بهینه‌سازی و جستجوی آنلاین مدل‌سازی می‌کند. در این روش‌ها، نیازی به داده‌های پیش‌آموزش دیده نیست؛ بلکه سیستم با وقوع هرگونه تغییر در محیط، الگوریتم‌های جستجو را برای یافتن بهترین پیکربندی در فضای وفقی اجرا می‌کند.

کوکِر (Coker) در معماری SASS [۱۴] از روش‌های جستجوی موضعی تصادفی نظیر الگوریتم صعود تپه (Hill Climbing) استفاده کرد تا با بررسی همسایگی پیکربندی فعلی، به پیکربندی برتر دست یابد. اگرچه این روش محاسبات سبکی دارد، اما به شدت مستعد گرفتار شدن در اولین بهینه محلی است [۱۴]. برای عبور از این چالش، پژوهش‌های کینِر (Kinneer) و همکارانش [۱۵، ۳۶، ۱۶] بر به‌کارگیری برنامه‌نویسی ژنتیک (Genetic Programming) و الگوریتم‌های تکاملی زمان اجرا متمرکز شد. آن‌ها نشان دادند که با تکامل جمعیت‌های گزینه‌های وفقی می‌توان به راه‌حل‌های بسیار بهتری دست یافت. علاوه بر این، چن (Chen) در رویکرد FEMOSAA [۳۷] با استفاده از الگوریتم تکاملی چندهدفه (MOEA)، مصالحه‌ی پویای بین اهداف متناقض کیفی (مانند انرژی و تأخیر) را در زمان اجرا مدل‌سازی و جستجو نمود.

نقد و بررسی انتقادی: اگرچه این رویکردها ویژگی تطبیق‌پذیری آنلاین بدون نیاز به آموزش را فراهم می‌سازند، اما نقطه ضعف بزرگ آن‌ها سربار محاسباتی زمان اجرا و چالش پایداری زمانی است: اولین نقطه ضعف، عدم مقیاس‌پذیری در ابعاد بزرگ است؛ الگوریتم‌های تکاملی و چندهدفه برای همگرایی به جبهه بهینه پارتو (Pareto Front) نیازمند ارزیابی صدها یا هزاران پیکربندی در هر گام تصمیم‌گیری هستند. هنگامی که ابعاد فضای وفقی بزرگ شده و فراتر از ۱۰۰۰ گزینه (نظیر فضای ۴۰۹۶ گزینه‌ای بستر DeltaIoT2) می‌رود، زمان محاسبات این الگوریتم‌ها به مقیاس ثانیه یا دقیقه افزایش می‌یابد [۱۴، ۱۶]. دومین نقطه ضعف، تأخیر غیرقابل تحمل زمان تصمیم‌گیری است؛ در سیستم‌های حساس به زمان، این تأخیر طولانی برنامه‌ریز منجر به بروز رفتارهای مخرب و انحراف شدید از اهداف پایداری سیستم در طول بازه تصمیم‌گیری می‌گردد، که استقرار عملیاتی این روش‌ها را در محیط‌های زمان‌حقیقی غیرممکن می‌سازد [۱۴، ۱۶].

۳-۳-۳ یادگیری تقویتی زمان‌اجرا و کنترل خودمختار

یادگیری تقویتی (RL) به عنوان یک پارادایم تصمیم‌گیری آنلاین پویا، به دلیل توانایی ذاتی عامل در یادگیری سیاست وفقی مطلوب از طریق تعامل مستقیم با محیط، توجه بسیاری را جلب نموده است.

کارهای کلاسیک کیم و پارک [۱۷] از اولین تلاش‌ها در به‌کارگیری الگوریتم Q-Learning جدول‌محور برای تطابق پویای نرم‌افزارها بود. در ادامه، مترگر و همکارانش [۱۸] قابلیت یادگیری تقویتی را برای مدیریت تطابق در معماری‌های سرویس‌گرا تعمیم دادند. همچنین، کامارا و همکارانش [۳۸] چارچوب RL-MC (Re-) را

inforcement Learning Model Checking) را معرفی کردند که در آن از یادگیری تقویتی آنلاین برای هدایت سیستم‌های خوددوفق استفاده شده و ایمنی کاوش را از طریق مدل‌چکینگ تضمین می‌کرد. با این حال، تمامی این کارهای اولیه به دلیل استفاده از روش‌های جدول‌محور، با چالش جدی «طاعون بعدنمایی» (Curse of Dimensionality) در فضاها و حالت و عمل بزرگ مواجه بودند [۱۱].

با ظهور یادگیری تقویتی عمیق (DRL) [۱۹]، محققان تلاش کردند تا با استفاده از شبکه‌های عصبی عمیق به عنوان تقریب‌زننده‌های تابع ارزش (مانند معماری عمیق DQN)، فضاها و عمل بزرگ سیستم‌های خوددوفق را مدیریت کنند [۳۵].

نقد و بررسی انتقادی: با وجود توانایی شبکه‌های عمیق در تقریب توابع در فضاها و عمل بزرگ، پیاده‌سازی استانداردهای یادگیری تقویتی عمیق (نظیر DQN با مکانیزم اکتشاف حریصانه سنتی ϵ -greedy) در سیستم‌های خوددوفق با یک چالش تئوریک و عملی بزرگ مواجه است. شاخص‌ترین نقطه ضعف این رویکردها، تله عمیق بهینه‌های محلی (Local Optima Trap) است؛ دو (Du) و همکارانش [۳۵] در تحلیل‌های خود نشان دادند که در فضاها و عملی بزرگ و گسسته، پویایی‌های نویزی زمان اجرا باعث می‌شوند که سیاست عامل یادگیرنده به راحتی در بهینه‌های محلی متوقف شود. استراتژی کاوش تصادفی ϵ -greedy در مواجهه با ابعاد بسیار بزرگ (مانند ۴۰۹۶ گزینه وفقی)، درصد بسیار بالایی از کاوش خود را صرف گزینه‌های غیرمفید و مخرب می‌کند. این امر همگرایی عامل را به شدت کند کرده و مدل را وادار می‌سازد تا در اولین پیکربندی نیمه‌پایدار متوقف گشته و توانایی عبور و رسیدن به بهینه سراسری را نداشته باشد، مگر آنکه فرآیند آموزش مجدد مدل با مقادیر بهینه‌تر از ابتدا آغاز گردد که در زمان اجرا به شدت پرهزینه است.

۳-۴ تکنیک‌های پیشرفته یادگیری تقویتی: کاوش، شکل‌دهی پاداش و

نگاه به گذشته

در سیستم‌های خوددوفق معاصر، عبور از محدودیت‌های الگوریتم‌های یادگیری تقویتی سنتی مستلزم به کارگیری تکنیک‌های پیشرفته در سه حوزه کلیدی است: مدیریت فرآیند کاوش در فضاها و وسیع، استفاده از مکانیزم‌های بازپخش تجربه با نگاه به گذشته، و استراتژی‌های شکل‌دهی پاداش. در این بخش، مبانی نظری و ریاضیاتی هر یک از این حوزه‌ها را تبیین کرده و چالش‌های تعمیم آن‌ها به سیستم‌های خوددوفق را به صورت انتقادی واکاوی می‌نماییم.

۳-۴-۱ چالش‌های استراتژی کاوش در فضاهای وفقی بزرگ

فرآیند کاوش (Exploration) در یادگیری تقویتی، مکانیزمی است که به عامل اجازه می‌دهد تا رفتارهای جدید را به منظور کشف پاداش‌های بالاتر بیازماید. در فضاهای وفقی بزرگ و گسسته (مانند شبکه DeltaIoT با ۴۰۹۶ پیکربندی ممکن)، طراحی استراتژی کاوش به یک چالش بسیار پیچیده ریاضی تبدیل می‌شود. روش‌های کاوش سنتی نظیر ϵ -greedy یا کاوش بولتزمن (Boltzmann Exploration) در فضاهای با ابعاد بالا به شدت ناکارآمد هستند [۶، ۳۵]. در استراتژی ϵ -greedy، عامل با احتمال ϵ اقدام بعدی خود را به صورت کاملاً تصادفی انتخاب می‌کند. هنگامی که تعداد اقدامات ممکن $A = 4096$ باشد، احتمال انتخاب یک اقدام وفقی مفید در میان انبوهی از اقدامات غیربهره‌مند یا مخرب، بسیار ناچیز است. در نتیجه، بخش عمده‌ای از گام‌های کاوش عامل صرف بررسی گزینه‌هایی می‌شود که کیفیت خدمات را به شدت کاهش داده و پایداری سیستم را به مخاطره می‌اندازند. این امر منجر به افت شدید «کارایی نمونه» (Sample Efficiency) شده و سرعت همگرایی آنالین را تا حد غیرقابل‌تحملی کاهش می‌دهد.

استفاده از روش‌های پیشرفته‌تر مانند حد بالای اطمینان (Upper Confidence Bound - UCB) نیز در محیط‌های زمان اجرا با عدم قطعیت پویا با مشکل مواجه است؛ زیرا ارزیابی مستمر عدم قطعیت تک‌تک اقدامات در فضاهای بسیار بزرگ، سربار محاسباتی شدیدی را به کنترل‌کننده زمان اجرا تحمیل می‌کند [۱۱]. از این رو، سیستم‌های خودوفق هوشمند نیازمند یک استراتژی کاوش هدایت‌شده هستند که بدون نیاز به نمونه‌برداری تصادفی کورکورانه، عامل را به سمت مناطق امیدبخش فضای وفقی هدایت نماید.

۳-۴-۲ ناکارآمدی مکانیزم بازپخش تجربه با نگاه به گذشته (HER) در محیط‌های آستانه‌محور

مکانیزم بازپخش تجربه با نگاه به گذشته (Hindsight Experience Replay - HER) که توسط آندریچوویچ (Andrychowicz) و همکارانش [۸] معرفی شد، یکی از برجسته‌ترین پیشرفت‌ها در زمینه حل مسئله‌ی پاداش‌های پراکنده (Sparse Rewards) است. ایده کلیدی در HER، برچسب‌گذاری مجدد هدف (Goal Relabeling) برای تجربیات ناموفق است. به طور مشابه، رویکرد پاداش نرم‌تر (Soft HER) توسعه‌یافته توسط هه (He) و همکارانش [۹] تلاش نمود تا فرآیند برچسب‌گذاری مجدد را با استفاده از پاداش‌های ملایم‌تر سرعت بخشد.

با این وجود، بر اساس تحلیل تئوریک ارائه شده در این رساله، استدلال می‌کنیم که این مکانیزم‌ها دارای یک تناقض و ناسازگاری بنیادین با پارادایم خودوفقی هستند:

- طراحی هدف‌محور (Goal-Conditioned) در مقابل ماهیت آستانه‌محور (Threshold-Based) خودوفقی:

الگوریتم HER به طور ذاتی برای محیط‌های هدف‌محور طراحی شده است؛ محیط‌هایی که در آن‌ها هدف عامل، رسیدن به یک مختصات یا وضعیت فیزیکی مشخص و صریح (مانند مکان سه بعدی بازوی رباتیک $g \in G$) است. در این سناریوها، اگر عامل نتواند به هدف g برسد، وضعیت نهایی تجربه شکست‌خورده (s') را به عنوان هدف فرضی در نظر گرفته و پاداش مثبتی به آن اختصاص می‌دهد.

- **فقدان نقطه هدف صریح در سیستم‌های خوددوفق:** اهداف سیستم‌های خوددوفق به ندرت به صورت یک نقطه وضعیت واحد فرموله می‌شوند. در مقابل، این اهداف همواره **آستانه‌محور** هستند. برای مثال، هدف سیستم کنترلی شبکه DeltaIoT، نگهداشتن میزان تأخیر در کمتر از ۱۰۰ میلی‌ثانیه و مصرف انرژی در کمتر از ۲ وات است. در این حالت، هدف یک نقطه مشخص نیست، بلکه زیرمجموعه وسیعی از فضا است که قیود آستانه‌ای را ارضا می‌سازد.

- **عدم امکان برچسب‌گذاری مجدد:** هنگامی که یک عامل در زمان اجرا شکست می‌خورد (مثلاً تأخیر شبکه به ۱۵۰ میلی‌ثانیه می‌رسد و آستانه نقض می‌شود)، هیچ مختصات یا وضعیت واحدی وجود ندارد که بتوان شکست را به عنوان یک «هدف جایگزین معتبر» برچسب‌گذاری مجدد کرد. نقض آستانه اساساً به معنای ناامنی و افت کیفیت خدمات است و تعریف یک «آستانه مجازی نقض‌شده» به عنوان هدف جدید در یادگیری با نگاه به گذشته، از نظر مهندسی و ریاضیاتی فاقد اعتبار بوده و ایمنی و ثبات کنترل‌کننده را به طور کامل نابود می‌سازد.

بنابراین، تکنیک‌های هدف‌محوری مانند HER و Soft HER عملاً قابلیت کاربرد در کنترل‌کننده‌های سیستم‌های خوددوفق آستانه‌محور را دارا نمی‌باشند.^۲

۳-۴-۳ مبانی نظری و ریاضیاتی شکل‌دهی پاداش

شکل‌دهی پاداش (Reward Shaping) رویکردی قدرتمند در نظریه یادگیری تقویتی برای تسریع همگرایی عامل از طریق افزودن یک سیگنال پاداش کمکی (Auxiliary Reward) به پاداش اصلی محیط است. از نظر^۲ با این حال، در سیستم‌های خوددوفق آستانه‌محور، استفاده از توابع هدف صریح یا پتانسیل‌های ثابت با چالش ناسازگاری مواجه است. این ناسازگاری یکی از شکاف‌های تحقیقاتی اصلی این رساله را تشکیل می‌دهد. راهکار پیشنهادی RS-DRL در فصل ۴ (بخش ۴-۶) با مکانیسم شکل‌دهی تصادفی پاداش (بدون نیاز به هدف صریح) به این چالش پاسخ می‌دهد. نتایج تجربی برتری آن نسبت به HER در فصل ۵ (جداول ۵-۳ و ۵-۴) تأیید شده است.

ریاضیاتی، پاداش شکل‌دهی شده زمان اجرا به صورت زیر تعریف می‌شود:

$$R_{shaped}(s, a, s') = R_{env}(s, a, s') + F(s, a, s') \quad (۱-۳)$$

که در آن R_{env} پاداش حاصل از دینامیک محیط و $F(s, a, s')$ پاداش کمکی شکل‌دهی است. نگ (Ng) و همکارانش در پژوهش کلاسیک خود [۳۹] اثبات ریاضیاتی ارائه دادند که نشان می‌دهد شکل‌دهی پاداش کورکورانه می‌تواند منجر به بروز پدیده «چرخه‌های بهینگی کاذب» (Suboptimal Loops) شود؛ وضعیتی که در آن عامل یاد می‌گیرد برای دریافت پاداش کمکی بیشتر، کارهای تکراری و بی‌فایده انجام دهد بدون آنکه به هدف اصلی محیط برسد. آن‌ها اثبات کردند که برای تضمین ثبات و حفظ سیاست بهینه محیط (Policy Invariance)، پاداش کمکی F باید حتماً به صورت تفاضل پتانسیل یک تابع حالت پایه‌ریزی شود. این متدولوژی تحت عنوان شکل‌دهی پاداش مبتنی بر پتانسیل (- Potential-Based Reward Shaping) (PBRS) شناخته می‌شود [۳۹] و فرمولاسیون ریاضی آن به شرح زیر است:

$$F(s, a, s') = \gamma \Phi(s') - \Phi(s) \quad (۲-۳)$$

که در آن γ ضریب تخفیف مارکوف و $\Phi(s)$ تابع پتانسیل حالت s است. بر اساس قضیه ریاضی نگ، هرگاه پاداش شکل‌دهی دارای این فرمولاسیون باشد، مجموعه سیاست‌های بهینه عامل π^* تحت پاداش شکل‌دهی شده دقیقاً با مجموعه سیاست‌های بهینه تحت پاداش اصلی یکسان خواهد بود^۳.

نقد و بررسی انتقادی: اگرچه PBRS چارچوب ریاضی مستحکمی برای تضمین حفظ سیاست بهینه ارائه می‌دهد، اما استقرار آن در سیستم‌های خوددوفق واقعی با مانع بزرگی مواجه است. محدودیت نخست، استاتیک بودن تابع پتانسیل در محیط‌های پویا است؛ در طراحی سنتی PBRS [۳۹]، تابع پتانسیل $\Phi(s)$ به صورت کاملاً ایستا (Static) در زمان طراحی سیستم بر اساس دانش تجربی کارشناسان دامنه تعریف می‌شود. محدودیت دوم، عدم انطباق با رانش مفهومی و شرایط پویای آنلاین است؛ در یک سیستم خوددوفق تحت تأثیر عدم قطعیت مستمر (رانش مفهومی)، پتانسیل واقعی حالت‌ها دائماً تغییر می‌کند. یک پتانسیل ایستای تعریف‌شده در زمان طراحی، قادر به بازتاب پویایی‌های پیش‌بینی‌نشده زمان اجرا نیست و در شرایط جدید، پاداش‌های کمکی گمراه‌کننده‌ای تولید می‌کند که سرعت یادگیری عامل را به شدت کاهش داده یا همگرایی آنلاین را مختل می‌سازد [۷].

^۳قضیه نگ [۳۹] شرط کافی برای حفظ سیاست بهینه را ارائه می‌دهد، اما فرض می‌کند تابع پتانسیل Φ ایستا (static) است. در سیستم‌های خوددوفق با رانش مفهومی، این فرض نقض می‌شود. مکانیسم شکل‌دهی تصادفی RS-DRL (فصل ۴، بخش ۴-۶) نیازی به تابع پتانسیل ایستا ندارد و بنابراین از این محدودیت تئوریک عبور می‌کند.

این نقیصه بنیادین تئوریک، ضرورت ابداع یک فرآیند شکل‌دهی تصادفی و پویای پاداش (همچون الگوریتم پیشنهادی RS-DRL در این رساله) را آشکار می‌سازد تا پتانسیل حالت‌ها را به صورت زمان اجرا و آنالین بر اساس تضمین‌های کیفی محاسبات صوری تنظیم نماید.

۳-۵ ارزیابی و تأیید صوری در فرآیند خوددوفاق‌سازی

تضمین ایمنی و ارضای کیفیت خدمات (QoS) در سیستم‌های خوددوفاق، به ویژه در حوزه‌های حساس، نیازمند ابزارهای صوری مستحکم است. ارزیابی و تأیید صوری زمان اجرا (Runtime Formal Verification) به عنوان پارادایمی مطرح است که به سیستم اجازه می‌دهد تا به صورت ریاضیاتی و دقیق، صحت تصمیمات خود را پیش از اعمال به سیستم واقعی ارزیابی کند. در این بخش، مبانی نظری تأیید صوری کمی زمان اجرا، ابزارها و چارچوب‌های شاخص (مانند ActivFORMS و UPPAAL-SMC) و در نهایت معماری‌های ترکیبی (ترادف) صوری-یادگیری را مورد تحلیل انتقادی قرار می‌دهیم.

۳-۵-۱ تأیید صوری کمی زمان اجرا (QVR)

تأیید صوری کمی زمان اجرا (Quantitative Verification at Runtime - QVR) که توسط پیشگامانی نظیر کالینسکو (Calinescu) و همکارانش [۴۰] و وینز (Weyns) [۳۲] توسعه یافت، فرآیندی است که در آن مشخصات غیرعملکردی سیستم (مانند کارایی، استواری و مصرف انرژی) در زمان اجرا با استفاده از مدل‌های ریاضی احتمالات ارزیابی می‌شوند.

در این پارادایم، پویایی‌های سیستم و عدم قطعیت‌های محیطی معمولاً به صورت زنجیره‌های مارکوف زمان‌گسسته (DTMC) یا فرآیندهای تصمیم‌گیری مارکوف (MDP) مدل‌سازی می‌شوند. اهداف کیفی سیستم نیز با استفاده از منطق‌های زمانی احتمالات نظیر منطق زمانی محاسبات احتمالات (PCTL) فرموله می‌گردند. برای مثال، هدف ایمنی شبکه به صورت فرمول زیر تعریف می‌شود:

$$P_{\geq 0.95}[F^{\leq t}(\text{PacketLoss} < 0.1)] \quad (3-3)$$

که به معنای آن است که با احتمال حداقل ۹۵ درصد، نرخ گم‌شدن بسته‌ها در طول زمان t کمتر از ۱۰ درصد باقی بماند. موتورهای ارزیابی صوری زمان اجرا با حل ریاضیاتی این مدل‌ها به صورت برخط، مشخص می‌سازند که آیا پیکربندی انتخاب‌شده قیود فوق را ارضا می‌کند یا خیر [۴۰].

۲-۵-۳ چارچوب‌های ActivFORMS و ابزار UPPAAL-SMC

در بین چارچوب‌های صوری توسعه‌یافته برای سیستم‌های خودوفق، چارچوب ActivFORMS (Active For-) mal Models for Self-Adaptation) که توسط وینز و همکارانش [۴۱] معرفی شد، جایگاه ویژه‌ای دارد. ActivFORMS یک موتور مبتنی بر مدل‌های صوری اجرایی در زمان اجراست که درون حلقه MAPE-K قرار می‌گیرد. این چارچوب تضمین می‌کند که فرآیند وفقی همواره با مدل‌های صوری اعتبارسنجی‌شده مطابقت داشته و رفتارهای غیرایمن در سیستم رخ ندهند.

با این حال، حل کامل و جامع توابع احتمالاتی در زمان اجرا به شدت پرهزینه است. برای عبور از این محدودیت محاسباتی، استفاده از ابزار بررسی مدل آماری (Statistical Model Checking - SMC) تحت چارچوب UPPAAL-SMC [۲۴] مورد توجه قرار گرفت. الگوریتم‌های SMC به جای حل فرمول‌های ریاضی پیچیده در تمام فضای حالت (که منجر به انفجار فضا می‌شود)، از شبیه‌سازی‌های تصادفی هوشمند سیستم بهره می‌برند. UPPAAL-SMC با اجرای تعداد مشخصی شبیه‌سازی زمان اجرا و اعمال آزمون‌های فرض آماری صوری (مانند آزمون نسبت احتمال متوالی والد - Wald's Sequential Probability Ratio Test - SPRT)، ارضای یا عدم ارضای خواص را با یک سطح اطمینان آماری مشخص (α, β) تعیین می‌کند. این مکانیزم به شدت سربار محاسباتی ارزیابی‌های صوری زمان اجرا را کاهش می‌دهد.

۳-۵-۳ معماری‌های ترکیبی یادگیری و ارزیابی صوری (مدل‌های ترادف)

با آشکار شدن قدرت مقیاس‌پذیری یادگیری ماشین و امنیت بالای روش‌های صوری، محققان در سال‌های اخیر به سمت توسعه معماری‌های ترکیبی متمایل شده‌اند که در ادبیات علمی به عنوان رویکردهای ترادف (Tandem Approaches) شناخته می‌شوند. پژوهش کامارا و همکارانش [۳۸] نمونه شاخصی از این معماری‌هاست. در این رویکردها، عامل یادگیری تقویتی وظیفه هدایت سیستم و یادگیری سیاست‌های وفقی را بر عهده دارد، در حالی که ماژول ارزیابی صوری زمان اجرا (SMC/QVR) به عنوان یک فیلتر ایمنی زمان اجرا عمل می‌کند. هرگاه اقدام پیشنهادی عامل یادگیرنده از نظر صوری ناامن تشخیص داده شود، فیلتر صوری آن را بلاک کرده و سیستم را مجبور به انتخاب گزینه‌ای ایمن می‌نماید.

نقد و بررسی انتقادی: اگرچه معماری‌های ترادفی کلاسیک گام بزرگی رو به جلو هستند، اما کماکان دارای یک نقطه ضعف عملیاتی جدی هستند که مانع از استقرار آن‌ها در بسترهای اینترنت اشیا بزرگ می‌گردد. نقطه ضعف اول، سربار شدید ارزیابی صوری در فضاهای وفقی بزرگ است؛ بررسی مدل صوری (حتی با ابزار سبک UPPAAL-SMC) برای هر یک از گزینه‌های تصمیم‌گیری زمان اجرا مستلزم چند صد بار شبیه‌سازی تصادفی است. در صورتی که عامل یادگیرنده بخواهد در یک فضای بزرگ (مثلاً با ۴۰۹۶ گزینه وفقی) کاوش

کند، ارزیابی صوری تمامی این گزینه‌ها زمان تصمیم‌گیری حلقه MAPE-K را به شدت افزایش داده (تا چندین دقیقه) و عملاً کارکرد آنالین سیستم را با اختلال جدی مواجه می‌سازد. نقطه ضعف دوم، ایستا بودن فیلتر ایمنی صوری است؛ فیلترهای صوری کلاسیک رفتاری صفر و یکی دارند و نمی‌توانند بازخورد کیفی دقیقی به عامل یادگیرنده ارائه دهند تا او سرعت یادگیری خود را بهبود بخشد.

این نقد اساسی، ضرورت وجود یک معماری جدید مانند RS-DRL را اثبات می‌کند^۴؛ معماری خاصی که در آن ماژول صوری UPPAAL-SMC به جای ایفای نقش به عنوان فیلتر نهایی سنگین برای تمامی گزینه‌ها، به صورت ناهمگام (Asynchronous) برای محاسبه‌ی صوری متغیرهای پتانسیل یادگیری و شکل‌دهی تصادفی پاداش به کار گرفته شود. این کار موازنه بهینه‌ای بین مقیاس‌پذیری تصمیم‌گیری عمیق و تضمین‌های ریاضی روش‌های صوری برقرار می‌سازد.

۳-۶ سنتر: شکاف تحقیقاتی سه‌گانه و موقعیت‌دهی علمی RS-DRL

بر اساس نقد و بررسی‌های انجام‌شده در بخش‌های پیشین، مشخص می‌گردد که هر یک از رویکردهای کلاسیک و مدرن مدیریت فضای وقتی در سیستم‌های خودفوق، از مزایای متمایزی برخوردار بوده و همزمان با محدودیت‌های بنیادین تئوریک و عملی مواجه هستند. به منظور جمع‌بندی دقیق وضعیت هنر، در ادامه ابتدا یک ماتریس ارزیابی چندبعدی ارائه گردیده و سپس شکاف‌های تحقیقاتی موجود تبیین می‌شوند.

۳-۶-۱ ماتریس ارزیابی و سنتر پیشینه پژوهش

در جدول ۳-۱، پارادایم‌های اصلی موجود در پیشینه پژوهش بر اساس چارچوب ارزیابی پنج‌بعدی پیشنهادی به همراه روش پیشنهادی این رساله (RS-DRL) مورد مقایسه و ارزیابی تطبیقی قرار گرفته‌اند.

۳-۶-۲ شکاف تحقیقاتی سه‌گانه

با متقاطع‌سازی ابعاد ارزیابی و چالش‌های عملیاتی احصاء‌شده از پیشینه پژوهش، شکاف تحقیقاتی سه‌گانه‌ای که این رساله بر حل آن‌ها تمرکز دارد به شرح زیر صورت‌بندی می‌شود:

۱. شکاف اول: تقابل مقیاس‌پذیری و پایداری زمانی تصمیم‌گیری (Scale-Latency Dilemma): در

سیستم‌های خودفوق با فضاها و فضاها بزرگ (بیش از ۱۰۰۰ گزینه)، رویکردهایی که از ارزیابی‌های

^۴معماری RS-DRL با جداسازی زمانی (Temporal Separation) که در فصل ۴ (بخش ۴-۲ و ۴-۴) تشریح شده است، این مشکل را حل می‌کند: ارزیابی صوری به صورت موازی و ناهمگام (asynchronous) در پس‌زمینه انجام می‌شود و مسیر تصمیم‌گیری آنالین را مسدود نمی‌کند. شکل ۴-۷ در فصل ۴ این معماری غیرانسدادی را نشان می‌دهد.

جدول ۳-۱: مقایسه تطبیقی پارادایم‌های مدیریت فضای وقتی زمان اجرا بر اساس چارچوب ارزیابی پنج‌بعدی (برگرفته از تحلیل کارهای پیشین نظیر [۷، ۳۵، ۱۶، ۱۴])

پارادایم / رویکرد	مدیریت ابعاد بزرگ (مقیاس‌پذیری)	استواری در برابر تغییرات آنلاین	استقلال از داده و پیش‌آموزش	کارایی محاسباتی آنلاین	فرار از تله بهینه‌های محلی
هرس مبتنی بر یادگیری ماشین [۲۰، ۱۲]	متوسط	ضعیف (به علت رانش مفهومی)	ضعیف (نیازمند پرچسب‌گذاری آفلاین)	عالی (میلی‌ثانیه)	غیرقابل اعمال (فقط هرس می‌کند)
جستجوی آنلاین تکاملی [۳۷، ۳۶، ۱۴]	ضعیف (انفجار زمان محاسبه)	متوسط	عالی (بدون نیاز به پیش‌آموزش)	ضعیف (ثانیه/دقیقه)	متوسط واسطه جهش‌های تصادفی)
یادگیری تقویتی عمیق [۳۵، ۱۷]	متوسط تا عالی	متوسط	عالی (یادگیری آنلاین مدل‌فردا)	عالی (کمتر از چند میلی‌ثانیه)	ضعیف (به علت کاوش کورکورانه ϵ -greedy)
تأیید صوری زمان اجرا [۳۸، ۴۱]	بسیار ضعیف (انفجار فضا)	عالی (تضمین ریاضی پایداری)	عالی	بسیار ضعیف (سربار شدید محاسبات صوری)	متوسط (تنها ایمنی را بررسی می‌کند)
روش پیشنهادی (RS-DRL)	عالی (استفاده از شبکه عمیق بدون فیلتر برخط)	عالی (انطباق با تغییرات به واسطه پتانسیل پویا)	عالی (یادگیری کاملاً آنلاین و مدل‌فردا)	عالی (کمتر از چند میلی‌ثانیه برای استنتاج)	عالی (به واسطه شکل‌دهی پویای پاداش صوری)

صوری دقیق زمان اجرا (SMC/QVR) یا جستجوهای تکاملی استفاده می‌کنند، با چالش جدی انفجار محاسباتی مواجه هستند که زمان تصمیم‌گیری را به مقیاس دقیقه افزایش می‌دهد. در مقابل، روش‌های یادگیری ماشین و شبکه‌های عمیق زمان استنتاج میلی‌ثانیه‌ای دارند اما فاقد هرگونه تضمین ریاضی ثبات و ایمنی آنلاین هستند. تا کنون مکانیزمی خلاقانه که بتواند بدون تحمیل سربار محاسباتی صوری به مسیر استنتاج آنلاین، تضمین‌های صوری ریاضی را به یادگیری عمیق تزریق کند، ارائه نشده است.

۲. شکاف دوم: عدم تطابق مکانیزم‌های نگاه به گذشته با اهداف آستانه‌محور خودوقتی (Goal-Threshold)

(Mismatch): الگوریتم‌های پیشرفته یادگیری برای پاداش‌های پراکنده (مانند HER و Soft HER) منحصرراً برای محیط‌های «هدف‌محور» طراحی شده‌اند که عامل در آن‌ها به دنبال رسیدن به مختصات معین است. این در حالی است که اهداف سیستم‌های خودوقتی معاصر ماهیت «آستانه‌محور» (مانند نگه‌داشتن مصرف انرژی زیر یک مقدار مشخص) دارند. این ناسازگاری تئوریک باعث می‌شود که در صورت بروز نقض آستانه، پرچسب‌گذاری مجدد با نگاه به گذشته فاقد اعتبار ریاضی گشته و عملاً کارایی خود را در هدایت کاوش آنلاین سیستم‌های خودوقتی از دست بدهد.

۳. شکاف سوم: ایستایی توابع پتانسیل در مواجهه با پویایی‌های نویزی آنلاین (Static-Dynamic Po-)

tential Gap): تکنیک‌های ریاضیاتی شکل‌دهی پاداش مبتنی بر پتانسیل (PBRS) [۳۹] که ثبات سیاست بهینه را تضمین می‌کنند، به صورت سنتی نیازمند یک تابع پتانسیل $\Phi(s)$ کاملاً ایستا هستند که در زمان طراحی توسط کارشناس خبره تعریف می‌شود. در حضور عدم قطعیت‌های شدید زمان اجرا و رانش مفهومی محیط، این توابع ایستای زمان طراحی کارایی خود را از دست داده و حتی ممکن است با ارائه پاداش‌های نادرست، همگرایی آنلاین عامل را مختل سازند. خلاصه‌شده‌ی در زمینه سیستم‌های شکل‌دهی پویای پتانسیل وجود دارد که بتوانند پتانسیل حالت‌ها را به صورت پویا بر اساس بازخوردهای صوری آنلاین به‌روزرسانی کنند.

۳-۶-۳ موقعیت‌دهی علمی معماری پیشنهادی RS-DRL

معماری پیشنهادی این رساله، تحت عنوان یادگیری تقویتی عمیق شکل‌دهی‌شده با بررسی صوری زمان اجرا (RS-DRL)، به عنوان راهکاری جامع برای پل زدن بر این شکاف‌های سه‌گانه طراحی و موقعیت‌دهی شده است. نوآوری‌های کلیدی این رویکرد به شرح زیر با شکاف‌های تحقیقاتی متناظر همخوانی دارند:

- پاسخ به شکاف اول (تقابل سرعت و امنیت): معماری RS-DRL فرآیند زمان‌بر ارزیابی صوری زمان اجرا را از مسیر مستقیم تصمیم‌گیری آنلاین عامل یادگیرنده خارج ساخته و آن را به صورت غیرهمگام (Asynchronous) در پس‌زمینه اجرا می‌کند. عامل برای تصمیم‌گیری صرفاً شبکه عمیق را در کمتر از ۱ میلی‌ثانیه استنتاج می‌کند، در حالی که ماژول صوری تصادفی (UPPAAL-SMC) به صورت موازی پتانسیل‌های یادگیری را به‌روزرسانی می‌کند. این متدولوژی برای اولین بار به طور همزمان مقیاس‌پذیری تصمیم‌گیری عمیق آنلاین و استواری صوری ریاضیاتی را تضمین می‌نماید.
- پاسخ به شکاف دوم (یادگیری آستانه‌محور): در RS-DRL، به جای به‌کارگیری متدهای هدف‌محور ناکارآمد مانند HER، سیستم با ترکیب پاداش محیط و پاداش کمکی صوری هدایت می‌شود. این پاداش کمکی به طور دقیق شدت ارضای آستانه‌ها را منعکس کرده و بدون نیاز به تعریف مختصات هدف صریح، امنیت کاوش عامل را در فضاهاى آستانه‌محور تضمین می‌نماید.
- پاسخ به شکاف سوم (شکل‌دهی پویا): نوآوری بنیادین ریاضیاتی در RS-DRL، معرفی استراتژی شکل‌دهی پویای پاداش مبتنی بر بررسی صوری زمان اجرا است. در این متدولوژی، تابع پتانسیل دیگر ایستا نیست، بلکه به عنوان یک متغیر پویای تصادفی آنلاین فرموله‌بندی شده و مقادیر آن به طور مستمر بر اساس خروجی‌های کمی حاصل از تحلیل‌های آماری UPPAAL-SMC به‌روزرسانی می‌گردند. این مکانیزم انطباق کامل عامل با رانش مفهومی و نویز محیط را بدون ابطال تئوریک سیاست بهینه رقم می‌زند.

جدول ۲-۳ خلاصه‌ای از نحوه پوشش شکاف‌های تحقیقاتی توسط نوآوری‌های RS-DRL را نمایش می‌دهد.

جدول ۲-۳: نحوه پوشش شکاف‌های تحقیقاتی توسط نوآوری‌های معماری پیشنهادی RS-DRL

شکاف تحقیقاتی	محدودیت روش‌های کلاسیک	راهکار و نوآوری ارائه شده در RS-DRL
شکاف اول (سرعت و امنیت)	تأخیر طولانی مدل‌چکینگ زمان اجرا در فضاهای بزرگ	ارزیابی صوری ناهمگام و استنتاج میلی ثانیه‌ای آنلاین شبکه عمیق
شکاف دوم (یادگیری آستانه‌محور)	عدم امکان استفاده از روش‌های برچسب‌گذاری مجدد هدف (HER)	هدایت عامل به کمک پاداش‌های کمکی صوری سنجش کیفیت و آستانه
شکاف سوم (شکل‌دهی پویا)	ایستایی توابع پتانسیل شکل‌دهی پاداش در محیط‌های متغیر آنلاین زمان اجرا	شکل‌دهی پویای پاداش با به‌روزرسانی آنلاین پتانسیل‌ها به وسیله بازخورد صوری زمان اجرا

۷-۳ خلاصه فصل

در این فصل، مرور عمیق و منسجمی بر مبانی نظری و پیشینه پژوهش مرتبط با فرآیندهای خودفوق‌سازی در سیستم‌های نرم‌افزاری و شبکه‌های توزیع‌شده نوین صورت گرفت. مسیر تحلیل پیشینه با تبیین ماهیت معماری‌های خودفوق‌مبتنی بر حلقه MAPE-K و چالش بنیادین انفجار فضای پیکربندی در سیستم‌های مقیاس‌بزرگ آغاز گردید. سپس، رویکردهای موجود در وضعیت هنر در قالب چهار پارادایم اصلی طبقه‌بندی و مورد بررسی انتقادی قرار گرفتند: هرس مبتنی بر یادگیری ماشین سنتی، جستجوی آنلاین تکاملی، یادگیری تقویتی عمیق بدون مدل و تأیید صوری زمان اجرا.

با اعمال یک چارچوب ارزیابی پنج‌بعدی پیشنهادی بر پیشینه پژوهش، مشخص گردید که هیچ‌یک از متدولوژی‌های کلاسیک قادر به حل هم‌زمان چالش‌های مقیاس‌پذیری، کارایی محاسباتی آنلاین، استواری در برابر رانش مفهومی و تضمین‌های ریاضیاتی ایمنی نیستند. این تحلیل انتقادی به صورت‌بندی دقیق شکاف تحقیقاتی سه‌گانه‌ای منجر شد که محور تمرکز علمی این رساله را تشکیل می‌دهد:

۱. تقابل مقیاس‌پذیری و پایداری زمانی تصمیم‌گیری: ناشی از سربار زمانی شدید مدل‌چکینگ آنلاین صوری در فضاهای پیکربندی بزرگ.

۲. عدم تطابق مکانیزم‌های نگاه به گذشته با اهداف آستانه‌محور خودفوقی: به دلیل محدودیت ذاتی الگوریتم‌هایی مانند HER که منحصرراً برای فضاهای وفقی مختصات‌محور و غایت‌محور توسعه یافته‌اند.

۳. ایستایی توابع پتانسیل شکل دهی پاداش: که با ماهیت نویزی و دائماً در حال تغییر عدم قطعیت‌های آنالین زمان اجرا ناسازگار است.

در نهایت، موقعیت‌دهی علمی روش پیشنهادی این رساله (RS-DRL) به عنوان پاسخ و راهکاری یکپارچه برای پوشش هر سه شکاف فوق تبیین شد. بنابراین، یافته‌های تحلیلی این فصل به طور قاطع تأیید می‌کنند که هیچ‌یک از رویکردهای موجود در پیشینه پژوهش قادر به ارضای همزمان الزامات سه گانه (سرعت میلی ثانیه‌ای، انطباق‌پذیری با پویایی زمان اجرا، و تضمین صوری ایمنی ریاضی) نیستند و معماری پیشنهادی RS-DRL دقیقاً برای پر کردن این شکاف بنیادین علمی موقعیت‌دهی شده است.

خلاصه یافته‌های کلیدی فصل سوم (مرور پیشینه پژوهش):

- **ناکارآمدی فیلترهای صوری آنالین:** فیلترهای صوری زمان اجرا (QVR) به صورت مستقیم در مسیر تصمیم‌گیری باعث سربار محاسباتی شدید (در حد دقیقه) برای فضاهای وفقی بزرگ می‌گردند [۳۸، ۴۰].
- **انفجار فضای حالت در تکامل آنالین:** روش‌های جستجوی تصادفی و تکاملی آنالین فاقد توانایی تصمیم‌گیری بی‌درنگ در مقیاس میلی ثانیه برای سیستم‌های اینترنت اشیاء هستند [۱۴، ۱۶].
- **شکست روش‌های HER در سناریوهای SLA:** الگوریتم‌های برچسب‌گذاری مجدد هدف به علت تعاریف مبتنی بر فیزیک مختصاتی، در برابر آستانه‌های کیفی سیستم‌های خوددوفق فاقد کارایی علمی می‌باشند.
- **ضرورت معماری ترادف ناهمگام:** تلفیق ناهمگام یادگیری عمیق و بررسی صوری آماری (UPPAAL-SMC) به عنوان تنها راهکار تأمین همزمان کارایی آنالین و تضمین‌های ریاضیاتی ایمنی شناسایی شد.

پل مفهومی به فصل بعد (بیانیه پل): با استقرار بستر نظری مستحکم در این فصل و صورت‌بندی دقیق نقاط ضعف و شکاف‌های پیشینه، مسیر برای تشریح جزئیات فنی و عملیاتی متدولوژی پیشنهادی هموار گردیده است. بر این اساس، در فصل چهارم به تبیین دقیق معماری و سازماندهی فرآیند اجرایی الگوریتم RS-DRL خواهیم پرداخت. در آن فصل، فرمول‌بندی ریاضیاتی شکل‌دهی پویای پاداش صوری، نحوه ارتباط ناهمگام میان عامل یادگیری تقویتی عمیق و ماژول بررسی صوری احتمالات (UPPAAL-SMC) و در نهایت، تضمین همگرایی تئوریک سیستم تحت شرایط نویزی زمان اجرا تشریح خواهند شد تا نشان داده شود چگونه

معماری پیشنهادی قادر است موازنه بهینه‌ای بین سرعت میلی‌ثانیه‌ای آنلاین و ایمنی صوری ریاضیاتی برقرار سازد.

فصل ۴

روش پیشنهادی

۱-۴ مقدمه

طراحی و توسعه سیستم‌های نرم‌افزاری خودوفق زمان واقعی در محیط‌های پویا و نویزی، مستلزم ایجاد موازنه عمیقی میان دو دغدغه متضاد مهندسی است: تصمیم‌گیری فوق‌سریع در مقیاس میلی‌ثانیه جهت همگامی با تغییرات محیطی، و ارائه تضمین‌های صوری و ریاضیاتی مبتنی بر ایمنی و انطباق کامل با اهداف کیفیت خدمات (QoS). همان‌طور که در فصل‌های پیشین تبیین گردید، روش‌های کلاسیک بهینه‌سازی و واریسی مدل آنلاین به دلیل محدودیت شدید مقیاس‌پذیری و زمان‌های محاسباتی طولانی (که در رده مسائل ان‌پی-سخت طبقه‌بندی می‌شوند [۲۸، ۱۴]) قادر به برآوردن این الزامات نیستند. از سوی دیگر، یادگیری تقویتی عمیق استاندارد (DRL) اگرچه زمان تصمیم‌گیری را به شدت کاهش می‌دهد، اما به علت پدیده «پراکندگی پاداش» (پاداش‌های پراکنده [۶]) و رانش مفهومی [۷]، به سرعت در تله بهینه‌های محلی گرفتار می‌شود و فاقد تضمین‌های صوری زمان اجراست.

هدف اصلی این فصل، ارائه جزئیات فنی و ریاضیاتی متدولوژی پیشنهادی این رساله، یعنی معماری RS-DRL (یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش) است که به طور مستقیم برای پاسخ‌گویی به این چالش‌های بنیادین طراحی شده است. اهداف تفصیلی تشریح شده در این فصل عبارتند از:

۱. تبیین اصل ساختاری جداسازی زمانی (Temporal Separation) به عنوان سنگ بنای جداسازی مسیر تصمیم‌گیری آنلاین از فرآیندهای یادگیری پس‌زمینه.

۲. تشریح فرآیند چهار مرحله‌ای حلقه تصمیم‌گیری زمان واقعی مبتنی بر مدل فرآیندی MAPE-K.

۳. فرمول‌بندی ریاضیاتی نوآوری اصلی رساله، یعنی مکانیزم شکل‌دهی تصادفی پاداش صوری جهت

خروج عامل هوشمند از بهینه‌های محلی.

۴. توصیف ساختار مخزن دانش مشترک و مکانیزم‌های هماهنگی ناهمگام.

۵. تبیین نحوه ادغام موتور راستی‌آزمایی صوری زمان اجرای UPPAAL-SMC به عنوان فیلتر کیفیت خدمات بدون ایجاد اختلال در سرعت تصمیم‌گیری.

با این ساختار سلسله‌مراتبی، این فصل ابتدا به اصول معماری سطح بالا پرداخته و سپس جزئیات پیاده‌سازی فرآیندی، فرمول‌بندی‌های ریاضیاتی، و در نهایت نحوه پوشش پرسش‌های پژوهش را تبیین می‌نماید.

۲-۴ اصول معماری سطح بالا و سازماندهی فرآیند


یک سیستم خودوفق کارآمد در محیط‌های همراه با عدم قطعیت، باید ذاتاً بین دغدغه‌های متضاد طراحی مانند تصمیم‌گیری آنلاین با تأخیر بسیار کم و آموزش سنگین و ناهمگام مدل‌های یادگیری، تفکیک قائل شود تا بتواند آن‌ها را به‌طور مؤثر در یک ریسمان کنترلی واحد مدیریت کند. معماری RS-DRL بر اساس این اصل بنیادین جداسازی زمانی (Temporal Separation) طراحی شده است: مسیر بحرانی تصمیم‌گیری از مشاهده تا اجرا، مستقل از چرخه‌های یادگیری پس‌زمینه عمل می‌کند.

توجه علمی و چرایی جداسازی زمانی: در معماری‌های متداول و پیشرفته‌ترین روش‌ها، حلقه‌های تصمیم‌گیری غالباً فرآیند استنتاج و آموزش را به صورت همزمان یا در گام‌های متوالی در یک نخ کنترلی واحد اجرا می‌کنند. از آنجا که به روزرسانی شبکه‌های عصبی عمیق مستلزم محاسبات سنگین پسانتشار گرادیان (Backpropagation) بر روی مینی‌بچ‌های داده است، اجرای آن در مسیر تصمیم‌گیری مستقیم، تأخیرهای شدیدی در حدود ده تا صدها میلی‌ثانیه ایجاد می‌کند که برای سیستم‌های زمان واقعی غیرقابل قبول است. در مقابل، استنتاج خالص سیاست (گذر رو به جلوی شبکه عصبی) تنها نیازمند چند ضرب ساده ماتریسی است که زمان اجرای آن همواره کمتر از نیم میلی‌ثانیه (0.5ms) است. با جداسازی زمانی، ما فرآیند سنگین محاسباتی یادگیری را به یک ریسمان پس‌زمینه کاملاً ناهمگام منتقل کرده‌ایم تا مسیر آنلاین همواره چابک باقی بماند.

به جای تشریح ایستای مؤلفه‌های نرم‌افزاری، این فصل این منطق تفکیک را از طریق یک مدل فرآیندی به تصویر می‌کشد. ما جریان داده و کنترل را از لحظه دریافت سیگنال از حسگر تا اعمال فرمان تطبیق توسط عملگر دنبال می‌کنیم. به این ترتیب، یک نمای پویا و زمان‌آگاه از سیستم ارائه می‌شود که در آن اصل سازمان‌دهنده، رخدادها و توالی عملیات است، نه صرفاً موقعیت فیزیکی کد.

برای هدایت خواننده در این دیدگاه فرآیندمحور، نقشه سطح بالای تعاملات سیستم در شکل ۴-۱ به عنوان یک راهنمای ناوبری عمل می‌کند. این نمودار به وضوح نشان می‌دهد که چگونه جریان داده‌های حسگرها از محیط وارد ماژول‌های پایش شده، حالت سیستم ساخته می‌شود، عامل هوشمند استنتاج سریع را انجام می‌دهد و در نهایت، تصمیمات توسط ماژول‌های صوری UPPAAL-SMC ارزیابی شده و فرمان‌های نهایی از طریق عملگرها بر سیستم فیزیکی اعمال می‌گردند.

RS-DRL System Context



شکل ۴-۱: معماری سطح بالای رویکرد RS-DRL در قالب حلقه MAPE-K. این نمودار تعامل میان سیستم مدیریت‌شونده، محیط، و مؤلفه‌های کنترلی را به همراه مخزن دانش (Knowledge) مشترک نشان می‌دهد.

۴-۲-۱ مقایسه تطبیقی معماری پیشنهادی با رویکردهای پیشرفته

جهت تبیین دقیق‌تر تمایزهای معماری پیشنهادی RS-DRL با رویکردهای مطرح پیشرفته، جدول ۴-۱ این مقایسه را از منظر پنج اصل بنیادین طراحی سیستم‌های خودوفق ارائه می‌دهد. این جدول به خوبی نشان می‌دهد که رویکرد پیشنهادی چگونه موازنه بهینه‌ای میان پاسخ‌گویی آنلاین، فرار از بهینه‌های محلی بدون

مدل، و تضمین صوری زمان اجرا ایجاد می‌کند.


جدول ۴-۱: مقایسه تطبیقی معماری پیشنهادی RS-DRL با رویکردهای پیشین از منظر اصول طراحی

سیستمی

معيار طراحی	رویکرد پیشنهادی RS-DRL	رویکرد DLASER+	رویکرد EAS ⁴ ML	رویکردهای واریسی صوری
		[۱۸]	[۱۲، ۲۰]	زمان اجرا [۳۲، ۴۰]
جداسازی زمانی آموزش و تصمیم‌گیری	ناهمگام و کامل ($O(1)$)	غیرجداسازی (انسدادی)	فاقد یادگیری مستقیم زمان اجرا	غیرجداسازی (تأخیر شدید زمان اجرا)
مکانیزم فرار از بهینه‌های محلی	شکل‌دهی تصادفی پاداش $\rho(\text{-shaping})$	فاقد مکانیزم (کاوش حریصانه)	فاقد مکانیزم فرار مستقل	جستجوی کامل و پرهزینه فضای حالت
نیاز به فرمول‌بندی دستی دانش دامنه	صفر (یادگیری مستقل بدون مدل)	زیاد (فرمول‌بندی توابع پتانسیل)	بالا (مهندسی دستی ویژگی‌ها)	کامل (مدل صوری جامع سیستم)
تضمین صوری کیفیت خدمات زمان اجرا	فیلتر صوری زمان اجرای ناهمگام	فاقد فیلتر صوری مستقیم	پیش‌بینی‌های آماری غیرصوری	فیلترهای صوری مستقیم زمان اجرا (مسدودکننده)
پیچیدگی محاسباتی استنتاج زمان اجرا	ثابت و فوق‌سریع ($O(1)$)	شبه‌خطی $O(A)$	شبه‌لوگاریتمی $O(\log N)$	توان‌نمایی و ان‌پی-سخت $O(C^K)$

۴-۳ فرآیند یکپارچه خودوفقی: حلقه سطح سیستم

در بالاترین سطح انتزاع، کل این مکانیزم در قالب یک فرآیند یکپارچه سازمان‌دهی می‌شود که مسیر داده از مشاهده تا تغییر فیزیکی را به صورت یک چرخه چهار فازی MAPE-K [۲] دنبال می‌کند (شکل ۴-۲). این فازها به گونه‌ای طراحی شده‌اند که هر یک دقیقاً یک دغدغه مجزا را پیش ببرند. نمودار فعالیت تفصیلی در شکل ۴-۲ با خطوط شناوری (Swimlanes)، تفکیک مسئولیت‌های پایش، تحلیل، برنامه‌ریزی و اعتبارسنجی را به تصویر می‌کشد.



شکل ۴-۲: نمودار فعالیت تفصیلی UML با خطوط شناوری (Swimlanes) برای تفکیک مسئولیت‌های پایش، تحلیل، برنامه‌ریزی و اعتبارسنجی. خط‌چین افقی مرز میان مسیر بحرانی آنالیز و فرآیند یادگیری ناهمگام در پس‌زمینه را مشخص می‌کند.

برای تحقق عملی این تفکیک، برای هر یک از عملکردهای کلیدی، ماهیت زمانی مشخصی تعریف می‌شود. جدول ۴-۲ این طبقه‌بندی را نشان داده و روشن می‌سازد که چگونه فعالیت‌های مستمر، رویدادمحور، و پس‌زمینه‌ای در کنار یکدیگر و بدون تداخل عمل می‌کنند.

جدول ۴-۲: طبقه‌بندی زمانی فرآیندهای معماری RS-DRL

فرآیند	ماهیت زمانی	توضیح عملکردی
پایش (Monitoring)	مستمر (Continuous)	دریافت دائم علائم و نوسانات کانال از حسگرهای محیطی و ساخت بردار حالت.
پیش‌بینی و تحلیل (Analysis)	رویدادمحور (Event-driven)	پردازش سریع مقادیر حالت و مقایسه آن با آستانه‌های کیفیت جهت تریگر کردن برنامه‌ریز.
راستی‌آزمایی صوری (Verification)	مشروط (Conditional)	اعتبارسنجی فرضی پیکربندی انتخاب شده توسط موتور UPPAAL-SMC [۲۴] به صورت ناهمگام.
آموزش ناهمگام (Training)	ناهمگام (Asynchronous)	به‌روزرسانی مستمر و پس‌زمینه شبکه‌های عصبی DQN [۱۹] با استفاده از نمونه‌برداری خوش‌بینانه.

این ساختار زمانی، سنگ بنای معماری RS-DRL است: حلقه سطح سیستم همواره چابک و پاسخگو باقی می‌ماند، در حالی که هوشمندی آن به طور مداوم و بدون توقف سرویس، تکامل می‌یابد.

۴-۴ مسیر تصمیم‌گیری آنلاین: بررسی گام‌به‌گام معماری

پس از تبیین اصول معماری، اکنون مسیر یک درخواست تطبیق را از آغاز تا انجام دنبال می‌کنیم. برای فراهم‌سازی یک واژگان مشترک و زمینه‌سازی برای درک مسئولیت‌ها، از مدل مرجع MAPE-K [۲] به‌عنوان یک لنز ساختاری استفاده می‌کنیم. همان‌طور که شکل ۴-۲ نشان می‌دهد، هر مرحله از فرآیند یکپارچه ما به طور طبیعی به یکی از کارکردهای این مدل نگاشت می‌شود. در ادامه، این مسیر را گام به گام و با لنز MAPE-K طی می‌کنیم.

۴-۴-۱ گام اول: پایش و ساخت وضعیت (Monitor)

در نقطه شروع حلقه، سیستم به طور مستمر محیط خود را رصد می‌کند. در نمونه مطالعاتی DeltaIoT [۵]، این فرآیند ادراکی به ساخت یک بردار وضعیت فشرده می‌انجامد که بازنمایی ریاضی از وضعیت جاری سیستم

است:

$$s_t = \langle E, P, L \rangle \quad (۴-۱)$$

که در آن E مصرف انرژی تجمیعی شبکه، P نرخ اتلاف بسته‌ها، و L میانگین تأخیر ارسال است. این بردار، خروجی نهایی فاز پایش بوده و به‌عنوان ورودی مشترک برای تحلیل و تصمیم‌گیری عمل می‌کند.

۴-۲ گام دوم: تحلیل و تشخیص ضرورت تطبیق (Analyze)

بردار وضعیت s_t سپس وارد فاز تحلیل (Analyze) می‌شود. تحلیلگر، مقادیر P و L را در برابر آستانه‌های کیفی از پیش تعریف‌شده (مطابق با اهداف کیفی تعریف‌شده در فصل ۲ برای سیستم DeltaIoT [۵]) مقایسه می‌کند. اگر هر یک از این شاخص‌ها از حد مجاز فراتر رود (مثلاً نرخ اتلاف بسته $P > ۱۰\%$)، یک سیگنال رویداد «نقض هدف» صادر شده و فرآیند برنامه‌ریزی را فعال می‌کند.

۴-۳ گام سوم: برنامه‌ریزی و استنتاج تطبیقی (Plan)

با دریافت سیگنال نیاز به تطبیق، فاز برنامه‌ریزی (Plan) فعال می‌شود. هسته این فاز، مدل آموزش‌دیده RS-DRL است که در نقش یک استنتاج‌گر عمل می‌کند: بردار حالت s_t را دریافت کرده و از طریق یک گذر رو به جلو در شبکه عصبی، مقادیر Q را برای تمام گزینه‌های تطبیقی محاسبه می‌کند.

مکانیزم گزینش اقدام و نقش سیاست ϵ -greedy: برای تعادل میان کاوش و بهره‌برداری، استنتاج‌گر در زمان آموزش از سیاست ϵ -greedy [۱۱، ۱۹] تبعیت می‌کند؛ با احتمال ϵ یک اقدام تصادفی جهت کشف حالات جدید و با احتمال $1 - \epsilon$ اقدام بهینه‌ای که ارزش عمل-حالت آن بیشینه است را انتخاب می‌نماید:

$$a^* = \arg \max_{a \in A} Q(s_t, a; \theta)$$

این فرآیند یک استنتاج خالص (Pure Inference) است؛ وزن‌های شبکه عصبی (θ) در این مسیر تصمیم‌گیری زمان واقعی هرگز تغییر نکرده و ثابت می‌مانند، تا پاسخ‌گویی فوق‌سریع سیستم زیر نیم میلی‌ثانیه تضمین گردد.

۴-۴-۴ گام چهارم: اعتبارسنجی، بازخورد و اجرا (شامل Knowledge و Execute)

قبل از آنکه گزینه تطبیقی منتخب اعمال شود، یک گام اعتبارسنجی حیاتی صورت می‌گیرد. در معماری RS-DRL، ما از مدل‌های صوری برای تولید یک سیگنال بازخورد قابل اعتماد استفاده می‌کنیم. گزینه پیشنهادی a^* توسط موتور UPPAAL-SMC [۲۴] ارزیابی می‌شود. تابع $SMC_Verify(s, a)$ یک مقدار دودویی $r_{smc} \in \{0, 1\}$ برمی‌گرداند که نشان می‌دهد آیا گزینه مذکور، اهداف کیفیت خدمات (QoS) را در وضعیت مفروض برآورده می‌سازد یا خیر. پاداش نهایی که برای آموزش‌های آتی در بافر بازپخش ذخیره می‌شود، از ترکیب بازخورد محیط و این تأیید صوری حاصل می‌شود:

$$r = r_{env} \times r_{smc} \quad (۲-۴)$$

به این ترتیب، تنها تجربیاتی که اعتبار آن‌ها توسط مدل صوری نیز تأیید شده باشد، به عنوان سیگنال‌های مثبت برای یادگیری استفاده می‌شوند.

پس از محاسبه پاداش، گزینه تطبیقی تأییدشده برای اجرا به لایه شبکه در سیستم مدیریت‌شونده ارسال می‌شود. این فرمان‌های بازپیکربندی از طریق فایل‌های تنظیمات محلی و فراخوانی درایورهای شبکه (Actuators) بر سیستم اعمال شده و توپولوژی و توان گره‌ها را منطبق می‌سازند.

۵-۴-۴ سناریوهای گام به گام و ملموس از چرخه تصمیم‌گیری زمان اجرا

جهت ملموس ساختن مفاهیم انتزاعی پایش، تحلیل، برنامه‌ریزی و اجرا، دو سناریوی مرجع و کاملاً دقیق را با ویژگی‌های متفاوت ردیابی می‌کنیم.

۱-۵-۴-۴ سناریوی اول: شبکه ساده دو گره‌ای با قید واحد

در این سناریو، چرخه کامل تصمیم‌گیری آنلاین را در قالب یک شبکه حسگر بی‌سیم بسیار ساده ردیابی می‌کنیم:

- پیکربندی فرضی شبکه: فرض کنید شبکه‌ای شامل ۲ گره حسگر (M_1 و M_2) داریم که داده‌ها را به یک دروازه مرکزی ارسال می‌کنند.

- فضای عمل گسسته: هر گره دارای ۲ گزینه برای تنظیم توان ارسال خود است: توان کم (a_{low}) و توان زیاد (a_{high}). کل فضای پیکربندی سیستم دارای $2^2 = 4$ گزینه تطبیقی است.

- هدف کیفی (قید): QoS نرخ اتلاف بسته‌ها (P) باید همواره کمتر از ۱۰٪ باقی بماند.

چرخه پایش تا اجرای این سناریو به شرح زیر اتفاق می‌افتد:

۱. **گام اول (پایش):** به دلیل شروع ناگهانی بارندگی یا تداخل فرکانسی در محیط، کیفیت لینک‌ها تضعیف می‌شود. مازول پایش نرخ اتلاف بسته‌های شبکه را ۱۲٪ گزارش می‌کند. بردار حالت جاری به عنوان $s_t = \langle E, P = 0/12, L \rangle$ ساخته می‌شود.

۲. **گام دوم (تحلیل):** تحلیل‌گر مقدار اتلاف بسته (۰/۱۲) را با آستانه مجاز (۰/۱۰) مقایسه کرده و به دلیل نقض قید ($0/12 > 0/10$)، بلافاصله سیگنال ضرورت تطبیق را برای فعال‌سازی برنامه‌ریز صادر می‌کند.

۳. **گام سوم (برنامه‌ریزی):** بردار حالت s_t به عنوان ورودی به شبکه DQN آموزش دیده ارائه می‌شود. شبکه در یک گذر رو به جلوی فوق‌سریع (۰/۲ms)، مقادیر Q را برای ۴ گزینه موجود محاسبه می‌کند. گزینه $a^* = \langle a_{high}, a_{low} \rangle$ (افزایش توان گره اول و ثابت نگه داشتن گره دوم) بیشترین ارزش پیش‌بینی شده را کسب کرده و انتخاب می‌شود.

۴. **گام چهارم (اعتبارسنجی صوری و اجرا):** اقدام پیشنهادی a^* در موقعیت s_t به موتور UPPAAL-SMC فرستاده می‌شود. این موتور با بررسی مدل صوری شبکه تأیید می‌کند که افزایش توان گره اول، نرخ اتلاف را به محدوده ایمن برمی‌گرداند ($r_{smc} = 1$). فرمان بازپیکربندی بلافاصله به درایورهای سخت‌افزاری ارسال شده و گره اول با توان بالا پیکربندی می‌شود. در نتیجه اتلاف بسته به ۴٪ سقوط کرده و پایداری شبکه برقرار می‌گردد.

۴-۵-۴ سناریوی دوم: شبکه پیچیده ۴ گره‌ای با اهداف متضاد کیفیت خدمات

جهت تبیین عملکرد سیستم در شرایطی که اهداف کیفی در تناقض مستقیم با یکدیگر قرار دارند، یک سناریوی جامع‌تر را با فرضیات زیر بررسی می‌کنیم:

- **پیکربندی فرضی شبکه:** شبکه‌ای شامل ۴ گره حسگر (M_1, M_2, M_3, M_4) که توپولوژی خطی را برای ارسال به دروازه مرکزی دنبال می‌کنند. هر گره دارای ۳ سطح توان ارسال گسسته است: توان پایین (۰)، توان متوسط (۱)، و توان بالا (۲). در نتیجه کل فضای تصمیم‌گیری تطبیقی سیستم دارای $3^4 = 81$ پیکربندی متفاوت است.

● اهداف متضاد کیفیت خدمات:

۱. **قید اتلاف بسته (P):** نرخ اتلاف بسته‌ها در کل شبکه باید کمتر از ۱۰٪ باقی بماند ($P_{net} < 0/10$).

۲. قید تأخیر ارسال (L): میانگین تأخیر ارسال در کل شبکه باید کمتر از 200ms باشد ($L_{net} < 200\text{ms}$).

۳. قید مصرف انرژی (E): تجمیع مصرف انرژی شبکه باید کمینه باشد.

در این سناریو، یک طوفان شدید محلی به طور ناگهانی کیفیت فیزیکی کانال ارسال گره‌های M_1 و M_2 را به شدت تضعیف می‌کند. چرخه خودوفقی برای این سناریو به شرح زیر اتفاق می‌افتد:

۱. پایش و ساخت وضعیت: حسگرها متغیرهای محیطی را گزارش می‌دهند. بردار وضعیت جاری سیستم به صورت یک بردار ۱۲ بعدی تشکیل می‌شود:

$$s_t = \langle E = [0.3, 0.3, 0.25, 0.25], P = [0.18, 0.15, 0.04, 0.05], L = [120, 110, 80, 75] \rangle$$

در این وضعیت، به وضوح نرخ اتلاف گره‌های اول و دوم (۱۸٪ و ۱۵٪) بسیار بالاتر از حد مجاز است.

۲. تحلیل تضاد اهداف: تحلیل‌گر متوجه نقض قید اتلاف بسته در کل شبکه ($P_{net} = 16.5\% > 10\%$) می‌گردد. همچنین به دلیل تضعیف کانال، تأخیر نیز افزایش یافته است. بلافاصله سیگنال ضرورت تطبیق زمان واقعی صادر می‌شود.

۳. برنامه‌ریزی مبتنی بر ارزش‌های Q : بردار وضعیت s_t به شبکه DQN چندهدفه ارائه می‌شود. سه اقدام کاندیدا توسط استنتاج‌گر به صورت زیر ارزیابی می‌شوند:

- اقدام حافظ انرژی ($a_{low} = \langle 0, 0, 0, 0 \rangle$): تمام گره‌ها در توان پایین باقی می‌مانند. ارزش پیش‌بینی شده $Q(s_t, a_{low}) = 0.21$ است، زیرا اتلاف بسته‌ها همچنان بسیار بالا باقی خواهد ماند.

- اقدام توان مفرط ($a_{brute} = \langle 2, 2, 2, 2 \rangle$): تمام گره‌ها با توان بالا ارسال می‌کنند. این کار اتلاف بسته‌ها را به ۳٪ کاهش می‌دهد، اما به علت ایجاد تداخل رادیویی شدید و سرریز شدن صف ارسال، تأخیر کل شبکه به 240ms افزایش می‌یابد که قید تأخیر را نقض می‌کند. ارزش پیش‌بینی شده $Q(s_t, a_{brute}) = 0.42$ است.

- اقدام متعادل هوشمند ($a_{balanced} = \langle 2, 2, 0, 0 \rangle$): توان گره‌های اول و دوم به بالا افزایش یافته ولی گره‌های سوم و چهارم در سطح پایین کار می‌کنند. ارزش پیش‌بینی شده برای این اقدام

$Q(s_t, a_{balanced}) = ۰/۹۲$ است، زیرا هر دو قید اتلاف بسته (۵٪) و تأخیر (۱۵۵ms) ارضا شده و مصرف انرژی اضافی نیز کمینه است.

بنابراین استنتاج گر اقدام $a_{balanced}$ را به عنوان اقدام بهینه زمان اجرا برمی‌گزیند.

۴. اعتبارسنجی صوری و اعمال: اقدام پیشنهادی فوراً توسط موتور راستی‌آزمایی UPPAAL-SMC ارزیابی شده و با تایید ارضای قید احتمالاتی، پاداش $r_{smc} = ۱$ صادر می‌شود. فرمان نهایی به گره‌های رادیویی اعمال گردیده و شبکه در کمترین زمان ممکن پایداری کیفی خود را بازیابی می‌کند.

۵-۴ معماری داخلی RS-DRL: تفکیک دغدغه‌ها در فرآیند یادگیری

برای تحقق اصل جداسازی زمانی که پیش‌تر مطرح شد، معماری داخلی RS-DRL به سه مسیر فرآیندی مجزا تجزیه می‌شود که در شکل ۳-۴ به تصویر کشیده شده‌اند:

۱. مسیر استنتاج (Inference Path): این مسیر در زمان اجرا فعال است و شامل دریافت بردار حالت، اجرای رو به جلوی شبکه عصبی، و انتخاب گزینه تطبیقی می‌باشد. این مسیر فقط خواندنی است و وزن‌های شبکه را تغییر نمی‌دهد، تا حداقل تأخیر تضمین شود.


۲. مسیر بازخورد (Feedback Path): پس از اعمال گزینه تطبیقی، این مسیر پاداش محیطی را دریافت کرده، آن را با خروجی اعتبارسنجی صوری ترکیب می‌کند ($r = r_{env} \times r_{smc}$)، و تجربه کامل را در بافر بازپخش ذخیره می‌نماید. این مسیر سبک و همزمان با اجرا عمل می‌کند.

۳. مسیر آموزش (Training Path): این مسیر کاملاً ناهمگام و مجزا از چرخه بحرانی تصمیم‌گیری اجرا می‌شود. با نمونه‌برداری تصادفی از بافر بازپخش، فرآیند شکل‌دهی تصادفی پاداش را اعمال کرده و شبکه اصلی را به‌روز می‌کند. به‌روزرسانی‌ها به صورت دوره‌ای به شبکه هدف منتقل می‌شوند.

این جداسازی دقیق تضمین می‌کند که عامل یادگیرنده همواره پاسخگو باقی بماند، در حالی که هوشمندی آن به طور مداوم و بدون ایجاد وقفه در سرویس‌دهی، بهبود می‌یابد. جزئیات منطق داخلی این مسیرها و نحوه تعامل با مؤلفه راستی‌آزمایی صوری در شکل ۳-۴ به تصویر کشیده شده است.


در این ساختار، مسیر استنتاج به صورت یک «گذر رو به جلو» خالص در شبکه عصبی پیاده‌سازی شده است که در آن تابع $SelectAction$ با استفاده از سیاست ϵ -greedy [۱۹، ۱۱] گزینه تطبیقی را انتخاب می‌کند. به محض تولید پاداش محیطی، ریسمان بازخورد فعال شده و با فراخوانی موتور SMC_Verify

RS-DRL PLANNER INTERNAL STRUCTURE



شکل ۴-۳: ساختار داخلی مؤلفه برنامه‌ریز RS-DRL در سه مسیر موازی: استنتاج (فقط خواندنی)، فیدبک (ترکیب پاداش محیطی و صوری)، و آموزش (به‌روزرسانی ناهمگام با استفاده از شکل‌دهی تصادفی پاداش).

(که بر پایه ابزار UPPAAL-SMC [۲۴] استوار است)، پاداش نهایی را تولید و در حافظه مشترک ذخیره می‌کند.



شکل ۴-۴: منطق عملیاتی مکانیزم شکل‌دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش‌بینانه پاداش‌های صفر با مقدار ۱ را بر اساس فاکتور ρ نشان می‌دهد (برچسب‌گذاری مجدد خوش‌بینانه، نه روش‌های مبتنی بر پتانسیل [۳۹]).

۴-۶ مکانیزم هسته: شکل‌دهی تصادفی پاداش

چالش بنیادینی که RS-DRL به آن پاسخ می‌دهد، پدیده توقف در بهینه‌های محلی است؛ جایی که عامل یادگیرنده صرفاً بر اساس تجربیات موفق گذشته عمل کرده و از کشف سیاست‌های بالقوه بهتر باز می‌ماند. برای غلبه بر این محدودیت، RS-DRL یک راهبرد ظریف را در مرحله بازپخش تجربه (Experience Replay) [۱۹] به کار می‌گیرد: بازطراحی خوش‌بینانه تصادفی تجربیات شکست‌خورده. این ایده ساده اما قدرتمند، دقیقاً هدف اصلی رساله را محقق می‌سازد: فرار از بهینه‌های محلی بدون نیاز به بازآموزی پرهزینه.

تحلیل صوری پدیده پراکندگی پاداش (Reward Sparsity): در فضاهاى وفقی بسیار بزرگ و مقیاس وسیع، اهداف تطبیقی به شدت سخت گیرانه هستند و از این رو، عامل با فضای پاداش به شدت پراکنده (Sparse Reward Space) مواجه می شود که رفع این نوع چالش ها به صورت سنتی نیازمند تکنیک های پیچیده است [۸، ۶]. در چنین شرایطی، تقریباً برای تمام پیکربندی های تصادفی اول دوره، سیگنال پاداش حاصله صفر است ($r_t = 0$). تحت این شرایط، تابع خطا یا گرادین شبکه های عصبی عمیق مسطح شده و فاقد اطلاعات جهت دهنده است:

$$\nabla_{\theta} \mathbb{E} \left[\left(r_t + \gamma \max_{a'} Q(s_{t+1}, a'; \theta') - Q(s_t, a_t; \theta) \right)^2 \right] \approx 0$$

این پدیده سرعت یادگیری را به شدت کاهش داده و عامل را وادار می کند تا به یک بهینه محلی نیمه پایدار و غیر ایده آل (مانند پیکربندی پیش فرض محافظه کارانه که انرژی بالایی تلف می کند ولی اتلاف بسته کمی دارد) همگرا شود.

فرمول بندی و عملکرد ریاضی مکانیزم شکل دهی تصادفی: برای خروج از این تله ریاضی، در هر مینی بچ آموزش، به ازای هر تجربه i با پاداش اولیه صفر ($r_i = 0$)، RS-DRL با احتمال ρ پاداش آن را به صورت خوش بینانه برابر با ۱ قرار می دهد. این فرآیند جایگزینی که در شکل ۴-۵ ترسیم شده است، بر اساس رابطه زیر عمل می کند:


$$\tilde{r}_i = \begin{cases} 1 & \text{if } r_i = 0 \text{ and } \text{rand}(0, 1) < \rho \\ r_i & \text{otherwise} \end{cases} \quad (3-4)$$

پارامتر ρ (فاکتور شکل دهی) شدت این خوش بینی را کنترل می کند. این تغییر پاداش مستقیماً مقدار پیش بینی هدف را به شکل زیر بازنویسی می کند:

$$y_i = \tilde{r}_i + \gamma \max_{a'} Q(s'_i, a'; \theta')$$

این بازنویسی سبب معرفی یک بایاس خوش بینانه تصادفی گذرا می گردد که عامل را وادار می کند تا ارزش عمل - حالت هایی که قبلاً به علت پاداش صفر نادیده گرفته می شدند را مجدداً کاوش نماید و بدین ترتیب با ایجاد انحراف کنترل شده، از تله بهینه های محلی فرار کند. شایان ذکر است که برخلاف روش کلاسیک شکل دهی پاداش مبتنی بر پتانسیل (PBRS) [۳۹] که برای حفظ سیاست بهینه نیازمند طراحی دقیق یک تابع

پتانسیل دستی ($\Phi(s)$) بر اساس دانش عمیق دامنه است، متدولوژی پیشنهادی RS-DRL هیچگونه وابستگی به تعریف پتانسیل‌های حالت یا اهداف معنایی پیش فرض ندارد و مکانیزم تصادفی خوش بینانه آن به صورت کاملاً مستقل و بدون مدل عمل می‌کند.



شکل ۴-۵: منطق عملیاتی مکانیزم شکل‌دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش بینانه پاداش‌های صفر با مقدار ۱ را بر اساس فاکتور ρ نشان می‌دهد (برچسب‌گذاری مجدد خوش بینانه، نه روش‌های مبتنی بر پتانسیل).

تحلیل حساسیت و پیش‌ارزیابی اولیه فاکتور شکل‌دهی ρ : انتخاب مقدار بهینه فاکتور ρ برای پایداری یادگیری بسیار حیاتی است. جدول ۴-۳ تاثیر مقادیر مختلف این پارامتر را بر روی رفتار کاوش و همگرایی سیاست یادگیری خلاصه می‌کند.

جدول ۴-۳: تحلیل حساسیت رفتار یادگیری عامل نسبت به تغییرات فاکتور شکل دهی ρ

مقدار ρ	نرخ کاوش	پایداری همگرایی	تأثیر بر فرار از بهینه محلی
۰/۰	بسیار پایین	بسیار بالا	فاقد توانایی فرار؛ عامل همواره در اولین بهینه محلی یافت شده متوقف می‌شود.
۰/۱	متوسط	بالا	شروع فرار تدریجی؛ زمان طولانی‌تری برای همگرایی به بهینه مطلق نیاز دارد.
۰/۳	عالی (بهینه)	عالی	فرار سریع و پایدار؛ تعادل بسیار عالی بین کاوش خوش‌بینانه و همگرایی مجانبی.
۰/۷	بسیار بالا	متوسط (نوسانی)	فرار فاقد تمرکز؛ نویز شدید به گرادیان القا کرده و همگرایی را با نوسان مواجه می‌سازد.
۰/۹	مفرط (کورکورانه)	پایین (واگرا)	بی‌ثباتی شدید؛ عامل به دلیل پاداش‌های مثبت مصنوعی زیاد، واگرا می‌شود.

۴-۶-۱ متدولوژی تنظیم فرایند جستجوی شبکه‌ای فاکتور ρ

برای دستیابی به بهینه‌ترین نرخ همگرایی و تضمین خروج از تله بهینه‌های محلی، یک فرایند منسجم جستجوی شبکه‌ای (Grid Search) بر روی فاکتور شکل دهی تصادفی پاداش (ρ) پیاده‌سازی گردید. هدف از این جستجو، یافتن مقداری برای ρ است که پاداش تجمعی مجانبی (Asymptotic Reward) را در طول دوره‌های مختلف یادگیری بیشینه سازد.

توازن ریاضی میان کاوش خوش‌بینانه و ثبات یادگیری: فرایند جستجوی شبکه‌ای در بازه $\rho \in [0/0, 1/0]$ با گام‌های $0/1$ و تحت ۵ دانه تصادفی (Random Seeds) متفاوت به اجرا درآمد. تحلیل منحنی‌های یادگیری حاصله نشان داد که این مسئله دارای دو مرز بحرانی از منظر پایداری ریاضی است: در مقادیر مرز تحت کاوش ($\rho < 0/2$)، به دلیل سهم بسیار ناچیز سیگنال‌های مثبت مصنوعی خوش‌بینانه، گرادیان سیاست یادگیری تحت تأثیر شدید پاداش‌های صفر ناشی از محیط‌های سخت‌گیرانه قرار می‌گیرد؛ در نتیجه، زمان فرار عامل از اولین بهینه محلی به شدت طولانی شده و به طور متوسط به بیش از ۲۵۰ دوره آموزشی نیاز دارد. در مقابل، در مقادیر مرز فوق کاوش ($\rho > 0/6$)، تزریق مفرط پاداش‌های مثبت مصنوعی، منجر به بیش‌برآورد شدید ارزش عمل-حالت‌ها (Q -values) در تارگت بلمن (معادله ۴-۳) می‌گردد که این مسئله منجر به نوسانات شدید در برآورد گرادیان شده و در نهایت، همگرایی سیاست را ناپایدار و در مقادیر $\rho \geq 0/9$ کاملاً واگرا می‌سازد. بنابراین، مقدار بهینه فاکتور شکل دهی پاداش برابر با $\rho = 0/3$ به دست آمد. این مقدار به عنوان نقطه موازنه پایدار، سرعت همگرایی را در مقایسه با یادگیری سنتی تا ۷۰٪ ارتقا داده و فرار از بهینه‌های محلی را در زیر ۶۰ دوره اول آموزشی تضمین می‌نماید.

فرایند کامل آموزش در الگوریتم ۴-۱ تشریح شده است. این الگوریتم بر پایه چارچوب یادگیری Q عمیق (DQN) [۱۹] بنا شده و شامل مکانیزم بافر بازپخش تجارب جهت شکستن همبستگی داده‌ها [۱۹]،

و همچنین به روزرسانی نرم شبکه‌های هدف [۴۲] جهت بهبود ثبات همگرایی است. نکته قابل توجه در این الگوریتم، استفاده از خروجی $SMC_Verify(s, a)$ (از ابزار UPPAAL-SMC [۲۴]) در محاسبه پاداش اولیه r است. این ترکیب ($r = r_{env} \times r_{smc}$) تضمین می‌کند که تنها تجربیاتی که هم توسط محیط و هم توسط مدل صوری تأیید شده‌اند، سیگنال مثبت دریافت می‌کنند. در نسخه جاری، این اعتبارسنجی صوری منحصراً برای شکل‌دهی پاداش به کار می‌رود و مانع از اجرای گزینه تطبیقی نمی‌شود.

الگوریتم ۴-۱: آموزش و بهروزرسانی جامع RS-DRL

```

1: Initialize main network  $\theta$  and target network  $\theta'$  {تعریف شبکه‌های عصبی اصلی و هدف}
2: for each training episode do
3:    $s \leftarrow GetInitialState()$  {دریافت وضعیت اولیه از پلتفرم پایش}
4:   while episode not finished do
5:      $a \leftarrow SelectAction(s, \theta, \epsilon\text{-greedy})$  {انتخاب اقدام زمان اجرا با احتمال کاوش}
6:      $(s', r_{env}) \leftarrow Environment.Step(a)$  {اعمال پیکربندی و دریافت پاداش شبکه}
7:      $r_{smc} \leftarrow SMC\_Verify(s, a)$  {فراخوانی اعتبارسنجی صوری UPPAAL-SMC به صورت احتمالی}
8:      $r \leftarrow r_{env} \times r_{smc}$  {ادغام پاداش صوری و تجربی: موفقیت در صورت ارضای هر دو عامل}
9:     Store transition  $(s, a, r, s')$  in Replay Buffer  $\mathcal{D}$  {ذخیره‌سازی تجربه در حافظه مشترک}
10:    Sample random minibatch  $B = \{(s_i, a_i, r_i, s'_i)\}_{i=1}^N$  from  $\mathcal{D}$  {نمونه‌برداری از بافر}
11:    for each transition  $i$  in  $B$  do
12:      if  $r_i = 0$  and  $rand(0, 1) < \rho$  then
13:         $\tilde{r}_i \leftarrow 1$  {اعمال مکانیزم خوش‌بینی تصادفی برای خروج از بهینه محلی}
14:      else
15:         $\tilde{r}_i \leftarrow r_i$ 
16:      end if
17:       $y_i \leftarrow \tilde{r}_i + \gamma \max_{a'} Q(s'_i, a'; \theta')$  {محاسبه تارگت بلمن [۱۹] با پاداش شکل‌یافته}
18:       $\theta \leftarrow \theta - \alpha \nabla_{\theta} \mathbb{E}[(y_i - Q(s_i, a_i; \theta))^2]$  {بهروزرسانی گرادینان شبکه اصلی}
19:    end for
20:     $\theta' \leftarrow \tau \theta + (1 - \tau) \theta'$  {بهروزرسانی نرم شبکه‌های هدف [۴۲] جهت حفظ پایداری}
21:     $s \leftarrow s'$ 
22:  end while
23: end for


```

نکته: پارامتر ρ (فاکتور شکل‌دهی) یک فراپارامتر است که میزان خوش‌بینی عامل را در کشف مسیرهای جدید کنترل می‌کند. مقادیر بهینه آن در فصل ۵ تحلیل شده‌اند.

۷-۴ مدیریت دانش و هماهنگی جریان‌های ناهمگام

موفقیت معماری RS-DRL در گرو هماهنگی دقیق میان سه مسیر استنتاج، بازخورد و آموزش است. این هماهنگی از طریق یک مخزن دانش مشترک (Knowledge Repository) مبتنی بر معماری خودمختار-MAPE-K [۲] تحقق می‌یابد که به‌عنوان حافظه مرکزی سیستم عمل می‌کند. شکل 4-6 جریان داده‌های ذخیره‌شده در این مخزن را نشان می‌دهد؛ از لحظه ذخیره‌سازی گذارهای (s, a, r, s') تا فرآیند نمونه‌برداری ناهمگام و به‌روزرسانی شبکه‌های عصبی اصلی و هدف.

Experience Replay and DQN Training



■ Experience Replay and DQN Training

شکل ۴-۶: جریان داده تفصیلی در مخزن دانش. این نمودار نحوه ذخیره‌سازی تجربیات در بافر بازپخش، اعمال مکانیزم شکل‌دهی تصادفی پاداش پیش از محاسبات گرادینان، و به‌روزرسانی سیاست‌های یادگیری در پس‌زمینه را به تصویر می‌کشد.

ساختار صوری و تعریف مخزن دانش مشترک: مخزن دانش شامل بردارهای توپولوژی شبکه، ردپاهای محیطی، بافر بازپخش تجربیات D و وزن‌های شبکه‌های عصبی عمیق اصلی (θ) و هدف (θ') است. جهت هماهنگی و همگام‌سازی فرایندهای همزمان و جلوگیری از به وجود آمدن شرایط مسابقه (Race Conditions)،

الگوهای خواندن و نوشتن هر یک از اجزا به شدت کنترل می‌شود. جدول ۴-۴ به طور تفصیلی الگوهای دسترسی به دانش، فرکانس تریگر شدن، و سطح تأثیرگذاری محاسباتی هر جزء را بر روی تأخیر سیستم مشخص کرده است.

جدول ۴-۴: الگوهای دسترسی صوری و همگام‌سازی مؤلفه‌ها در مخزن دانش مشترک [۲]

مؤلفه سیستم	دسترسی خواندن	دسترسی نوشتن	فرکانس اجرا	تأثیر محاسباتی
پایش (Monitor)	علائم فیزیکی کانال	بردار حالت جدید s_t	مستمر (هر دوره)	ناچیز (کمتر از 0.1ms)
تحلیل (Analyze)	آستانه‌های کیفی QoS	سیگنال نقض قید	رویدادمحور	ناچیز (کمتر از 0.05ms)
برنامه‌ریز (Plan)	وزن‌های شبکه عصبی θ	فرضیه اقدام a^*	رویدادمحور	بسیار پایین (0.3ms)
اعتبارسنج صوری	مدل شبکه، قید PCTL	پاداش صوری r_{smc}	رویدادمحور	متوسط (ناهمگام)
یادگیرنده (Train)	بافر بازپخش D	بافر D و وزن‌های جدید θ	ناهمگام (پس‌زمینه)	صفر (کاملاً ایزوله)

همان‌طور که در جدول ۴-۴ به وضوح نشان داده شده است، مؤلفه یادگیری سنگین در پس‌زمینه کاملاً ایزوله شده و هیچ دسترسی مستقیمی در مسیر زمان اجرای برنامه‌ریز آنلاین ندارد. این ویژگی ساختاری، بالاترین حد کارایی و مقیاس‌پذیری زمان اجرا را تضمین می‌نماید.

۴-۸ ادغام اعتبارسنجی صوری زمان اجرا و ایمنی احتمالی

یکی از ارکان اصلی برتری معماری RS-DRL بر الگوریتم‌های یادگیری تقویتی مرسوم، توانایی ارائه تضمین‌های ریاضیاتی پیرامون ایمنی سیستم و عملکرد مطلوب آن در برابر عدم قطعیت‌های زمان اجراست. این مهم از طریق ادغام ناهمگام موتور واریسی مدل آماری زمان اجرای UPPAAL-SMC [۲۴] تحقق می‌یابد.

نقش و نحوه عملکرد ابزار: UPPAAL-SMC در سیستم‌های خودوفق، راستی‌آزمایی زمان اجرا مدل‌های احتمالی را در زمان وقوع تغییرات رصد می‌کند. موتور UPPAAL-SMC با استفاده از روش شبیه‌سازی احتمالی، روابط ریاضی را بر روی فرآیندهای تصمیم‌گیری احتمالی شبکه ارزیابی می‌کند. نمونه‌ای از یک پرسش صوری به زبان منطق زمانی محاسبات احتمالات زمان‌آگاه (PCTL) [۴۳] به صورت زیر فرموله می‌شود:

$$\psi = P_{\geq 0.99} [\Diamond_{\leq T} (\text{PacketLoss} < 0.1)] \quad (4-4)$$

تفسیر ریاضی پرسش فوق: آیا تحت پیکربندی و اقدام انتخابی جاری، احتمال اینکه نرخ اتلاف بسته‌های کل شبکه در بازه زمانی کوتاه T همواره کمتر از ۱۰٪ باقی بماند، حداقل ۹۹٪ است؟

فرمول‌بندی دقیق فیلتر ایمنی SMC_Verify : موتور راستی‌آزمایی صوری با اجرای شبیه‌سازی‌های متعدد آماری بر روی مدل صوری پویای شبکه، خروجی صوری زیر را تولید می‌نماید:

(۵-۴)

$$SMC_Verify(s, a) = \begin{cases} 1 & \text{query PCTL the if } \psi \text{ state in satisfied is } s \text{ action under } a \\ 0 & \text{otherwise} \end{cases}$$

این خروجی دودویی به عنوان یک فیلتر کیفی صوری عمل می‌کند. در نسخه جاری معماری پیشنهادی، این اعتبارسنجی صوری با پاداش محیطی ترکیب شده ($r = r_{env} \times r_{smc}$) تا تجربیاتی که منجر به نقض تضمین‌های ریاضیاتی ایمنی می‌گردند، با پاداش صفر جریمه شوند.

۴-۸-۱ جزئیات شبیه‌سازی احتمالی و کران ریاضی تعداد نمونه‌ها (SMC Bound)

از آنجا که موتور UPPAAL-SMC بر مبنای واری مدل آماری عمل می‌کند، ارزیابی قضایای صوری نظیر معادله ۴-۴ نیازمند مشخص‌سازی سه فراپارامتر آماری برای تعیین تعداد شبیه‌سازی‌های مورد نیاز جهت ارائه تضمین‌های صوری احتمالی است:

۱. سطح معناداری آماری (α): نشان‌دهنده احتمال وقوع خطای نوع اول (رد فرضیه درست) است که در این رساله برابر با $\alpha = 0.05$ تنظیم شده است.

۲. احتمال خطای نوع دوم (β): نشان‌دهنده احتمال پذیرش فرضیه نادرست است که برابر با $\beta = 0.05$ در نظر گرفته شده است.

۳. پارامتر بی‌تفاوتی یا پهنای بازه اطمینان (δ): که نشان‌دهنده حداکثر خطای مجاز در برآورد احتمال است و معادل $\delta = 0.02$ تنظیم گردیده است.

تعداد کل شبیه‌سازی‌های تصادفی مورد نیاز (N_{sim}) برای تضمین اینکه برآورد احتمال با دقت مدنظر صورت پذیرد، به صورت تئوریک توسط نامساوی معروف کران چرنوف-هوفدینگ (Chernoff-Hoeffding Bound) [۴۴] تعیین می‌گردد:

$$N_{sim} \geq \frac{\ln(2/\alpha)}{2\delta^2} \quad (۶-۴)$$

با قرار دادن مقادیر فوق در معادله ۴-۶:

$$N_{sim} \geq \frac{\ln(2/0.05)}{2(0.02)^2} = \frac{3/6888}{0.0008} \approx 4611$$

این رابطه نشان می‌دهد که برای تضمین ریاضیاتی مطلق با خطای زیر ۵ درصد، موتور راستی‌آزمایی به صورت تئوریک باید ۴۶۱۱ شبیه‌سازی بر روی مدل احتمالی انجام دهد. از آنجا که اجرای این تعداد شبیه‌سازی تصادفی بر روی مدل زمان اجرای شبکه زمان زیادی (حدود ۴ تا ۸ ثانیه) به طول می‌انجامد، امکان اجرای مستقیم آن در مسیر تصمیم‌گیری آنلاین وجود ندارد.

۲-۸-۴ تحلیل غیرانسدادی زمان‌بندی اعتبارسنجی ناهمگام (Non-Blocking Temporal Timing)

جهت حل این چالش بنیادین، فرآیند راستی‌آزمایی به صورت کاملاً غیرانسدادی (Non-blocking) در ریسمان موازی فیدبک و یادگیری پس‌زمینه ادغام شده است [۳۸، ۴۱]. شکل ۴-۷ دیاگرام توالی زمانی و تداخل زمانی مسیر آنلاین و موتور راستی‌آزمایی صوری را نشان می‌دهد.

هنگامی که برنامه‌ریز گزینه تطبیقی a^* را انتخاب می‌نماید، این تصمیم بلافاصله و در کمتر از نیم میلی‌ثانیه بر شبکه حسگر اعمال می‌گردد. همزمان، یک نخ موازی در پس‌زمینه تابع $SMC_Verify(s, a^*)$ را با تعداد نمونه‌های بهینه شده زمان اجرا فراخوانی می‌کند. پس از آماده شدن پاسخ، پاداش صوری در بافر بازپخش ذخیره می‌شود تا در به‌روزرسانی‌های گرادیان مورد استفاده قرار گیرد. بدین ترتیب، تأخیرهای زمان اجرای واریسی صوری به طور کامل از مسیر بحرانی آنلاین حذف شده و تأخیر زمان واکنش تصمیم‌گیری همواره ثابت باقی می‌ماند.


۹-۴ پوشش پرسش‌های پژوهش

در این بخش، به طور تفصیلی و ساختاریافته نشان می‌دهیم که چگونه معماری پیشنهادی RS-DRL به هر یک از پرسش‌های اساسی پژوهش پاسخ صوری و عملیاتی ارائه می‌دهد:

۱-۹-۴ پاسخ صوری به سوال اول (RQ1) - فرار از بهینه‌های محلی

الگوریتم‌های مرسوم یادگیری تقویتی [۱۱] به دلیل پدیده نابودگرایی شدید پاداش [۶] در فضاهای تصمیم‌گیری گسسته بزرگ، به سرعت در تله سیاست‌های بهینه محلی که از نظر انرژی یا پایداری نامطلوب هستند گرفتار

RS-DRL PLANNER INTERNAL STRUCTURE



شکل ۴-۷: دیاگرام هماهنگی و توالی زمانی میان استنتاج فوق سریع آنالین ($0/3ms$) و راستی آزمایی صوری سنگین و ناهمگام در پس زمینه، که تضمین می کند هیچ وقفه یا انسدادی در مسیر مستقیم تصمیم گیری رخ نمی دهد.

می‌گردند. طراحی مکانیزم شکل‌دهی تصادفی پاداش (بخش ۴-۶) با تزریق احتمالاتی خوش‌بینی کنترل‌شده (ρ)، به تجربیاتی که در دنیای واقعی منجر به شکست شده‌اند پاداش‌های مثبت تصادفی تخصیص می‌دهد. این کار گرادیان سیاست یادگیری را فعال نگاه داشته و عامل را تشویق به کاوش پویای گزینه‌هایی می‌کند که پیش از این نادیده گرفته می‌شدند. نتایج شبیه‌سازی در فصل ۵ به طور تجربی ثابت می‌کنند که این مکانیزم خروج پایدار از بهینه‌های محلی را بدون نیاز به آموزش مجدد و پرهزینه میسر می‌سازد.

۲-۹-۴ پاسخ صوری به سوال دوم (RQ2) - ادغام یادگیری و بازپخش تجربه

یک چالش بزرگ در طراحی مکانیزم‌های شکل‌دهی پاداش، سربار شدید محاسباتی زمان اجرای آن‌ها است. در معماری پیشنهادی، این مکانیزم به طور مستقیم در فاز نمونه‌برداری از بافر بازپخش تجربیات (الگوریتم ۴-۱، خطوط ۱۲-۱۶) ادغام شده است. از آنجا که این عملیات تنها بر روی مینی‌بچ‌های کوچک نمونه‌برداری شده و به صورت یک مقایسه ساده رندوم با پیچیدگی زمانی بسیار ناچیز $O(N)$ (که N اندازه مینی‌بچ است) انجام می‌پذیرد، هیچ‌گونه سربار محاسباتی محسوسی بر چرخه یادگیری القا نکرده و با کمترین حافظه جانبی قابل اجراست.

۳-۹-۴ پاسخ صوری به سوال سوم (RQ3) - مدیریت فضاهای بزرگ و مقیاس‌پذیری

مسئله تطبیق مقیاس وسیع در WSN به عنوان یک مسئله ان‌پی-سخت با پیچیدگی توان‌نمایی $O(C^K)$ اثبات گردید [۲۸]. معماری پیشنهادی با استقرار سیاست جداسازی زمانی (بخش ۴-۲)، مسیر تصمیم‌گیری آنلاین را از فرآیند آموزش عمیق سنگین جدا ساخته است. در زمان اجرا، عامل هوشمند تنها یک استنتاج خالص (گذر رو به جلو در شبکه DQN) با پیچیدگی زمانی ثابت $O(1)$ را اجرا می‌نماید. نتایج نشان می‌دهد که حتی با افزایش شدید فضای تطبیق از ۲۱۶ گزینه به ۴۰۹۶ گزینه در DeltaIoTv، تأخیر پاسخ‌گویی آنلاین سیستم در همان محدوده فوق‌سریع زیر نیم میلی‌ثانیه حفظ می‌گردد.

۴-۹-۴ پاسخ صوری به سوال چهارم (RQ4) - تمایز، برتری و استقلال از دانش دامنه

الگوریتم‌های پیشرفته کاوش مانند HER [۸] اساساً برای محیط‌های مبتنی بر مختصات فیزیکی یا اهداف صریح طراحی شده‌اند و در محیط‌های خودوقف نرم‌افزاری که با اهداف تلویحی و آستانه‌محور (نظیر حفظ تاخیر زیر حد مجاز) سروکار دارند، شکست می‌خورند. رویکرد RS-DRL به دلیل ماهیت بدون مدل (Model-free) [۱۱] و استقلال کامل از دانش دامنه، نیازی به نگاشت مختصات یا فرضیات فیزیکی هدف نداشته و تنها بر اساس سیگنال پاداش صوری احتمالی و تصادفی عمل می‌نماید. این استقلال کامل، برتری مطلق

عملکرد مجانبی آن را در ارزیابی‌های مقایسه‌ای در برابر روش‌های پایه و مبتنی بر هدف (مانند Soft HER [۹] و DLASER+ [۴۵]) به اثبات می‌رساند.

۴-۱۰ بحث پیرامون مفروضات متدولوژی پیشنهادی

توسعه علمی هر متدولوژی مهندسی نیازمند تبیین و توجیه دقیق مفروضات پایه‌ای است که سیستم بر روی آن‌ها بنا نهاده شده است. معماری پیشنهادی RS-DRL بر اساس سه فرض بنیادین زیر طراحی شده است که در ادامه به توجیه دلایل علمی و واقع‌گرایانه بودن آن‌ها می‌پردازیم.

۴-۱۰-۱ فرض فضای اقدام گسسته در شبکه‌های خودوق

در این رساله فرض شده است که فضای پیکربندی‌های وقتی سیستم (فضای اقدام عامل هوشمند) به صورت گسسته است. این فرض کاملاً همسو با واقعیت‌های سخت‌افزاری و پروتکل‌های صنعتی در شبکه‌های حسگر بی‌سیم و اینترنت اشیا است. به عنوان مثال، در پلتفرم محک DeltaIoT [۵]، سطوح توان ارسال فرستنده‌های رادیویی به صورت پله‌های عددی گسسته (بازه صفر تا ۱۵) تعریف می‌شوند. همچنین تصمیمات مسیریابی شبکه، مبتنی بر انتخاب گره همسایه بعدی از میان یک مجموعه کاندیدای گسسته و مشخص است. از این رو، استفاده از شبکه‌های عصبی عمیق همگرا مانند DQN که برای مدیریت فضاهای اقدام گسسته طراحی شده‌اند، انتخابی کاملاً واقع‌بینانه و فاقد ساده‌سازی تصنعی است.

۴-۱۰-۲ آگاهی و پایداری آستانه‌های کیفیت خدمات

یکی دیگر از مفروضات این پژوهش، در دسترس بودن و مشخص بودن آستانه‌های توافق‌نامه سطح خدمات (QoS SLAs) در تحلیل‌گر سیستم است. در سیستم‌های خودوق صنعتی، اهداف کیفیت خدمات (مانند اتلاف بسته‌ها زیر ۱۰ درصد یا طول عمر گره بالای ۵ سال) پارامترهایی از پیش تعیین‌شده توسط مهندسين طراح هستند. این مقادیر مرزهای ایمنی سیستم را مشخص ساخته و در طول چرخه حیات سیستم پایدار باقی می‌مانند. بنابراین، استفاده از این مرزهای صریح جهت تحریک برنامه‌ریز و راستی‌آزمایی صوری زمان اجرا، کاملاً منطبق بر سناریوهای عملیاتی دنیای واقعی است.

۳-۱۰-۴ در دسترس بودن مدل صوری پویای سیستم در زمان اجرا

معماری پیشنهادی بر این فرض تکیه دارد که یک مدل صوری ریاضی از رفتار سیستم و کانال رادیویی (مانند شبکه پتری احتمالی یا زنجیره مارکوف زمان آگاه) جهت ارزیابی در موتور UPPAAL-SMC [۲۴] در دسترس است. از آنجا که سیستم‌های خودوفق مدرن بر پایه الگوهای مهندسی نرم افزار مبتنی بر مدل زمان اجرا (Models@run.time) [۴۶] طراحی می‌شوند، نگهداری و به‌روزرسانی مستمر یک مدل انتزاعی هماهنگ با واقعیت فیزیکی شبکه، یکی از قابلیت‌های استاندارد این معماری‌ها به شمار می‌رود. موتور UPPAAL-SMC [۲۴] به صورت بلادرنگ پارامترهای انتقال این مدل را بر اساس آخرین گزارش‌های پایش به‌روزرسانی کرده و صحت ریاضی را تضمین می‌سازد.

۱۱-۴ خلاصه فصل

این فصل، معماری اجرایی و سازمان‌دهی فرآیندی زمان آگاه RS-DRL را به طور جامع تبیین نمود. ما نشان دادیم که چگونه اصل تفکیک زمانی، امکان همزیستی یک حلقه کنترلی سریع زمان اجرا و یک فرآیند یادگیری عمیق ناهمگام پس‌زمینه را فراهم می‌آورد. یکپارچگی با چارچوب استاندارد MAPE-K [۲]، قرابت معماری با الگوهای مرجع را تضمین کرده و مکانیزم نوآورانه «شکل‌دهی تصادفی پاداش» به عنوان هسته اصلی، عامل را قادر می‌سازد تا از تله بهینه‌های محلی بگریزد.

۱-۱۱-۴ محدودیت‌های روش پیشنهادی

برای حفظ صداقت علمی و ترسیم کارهای آتی، محدودیت‌های روش پیشنهادی به شرح زیر خلاصه می‌گردد:

۱. حساسیت به فرایارامتر ρ : اگرچه مقدار بهینه $\rho = 0.3$ عملکرد فوق‌العاده‌ای ارائه داد، اما تعیین این پارامتر در سیستم‌های مختلف نیازمند جستجوی شبکه‌ای است. مقادیر نامناسب می‌توانند پایداری یا نرخ کاوش را تضعیف کنند.

۲. فضای اقدام گسسته: معماری DQN [۱۹] مورد استفاده منحصراً برای محیط‌های با فضای اقدام گسسته طراحی شده است. توسعه آن به محیط‌های با فضای عمل پیوسته مستلزم ارتقاء به ساختارهای سنگین‌تر بازیگر-منتقد (Actor-Critic) نظیر DDPG [۴۲] است.

۳. وابستگی به مدل صوری: UPPAAL-SMC کارآمدی بازخورد صوری زمان اجرا، رابطه مستقیمی با انطباق مدل زمان اجرای ساخته‌شده با پویایی‌های واقعی فیزیکی دارد. هرگونه انحراف شدید مدل صوری می‌تواند منجر به ارسال بازخوردهای گمراه‌کننده به عامل یادگیرنده گردد.

در ادامه، در فصل ۵، کارآمدی و برتری کامل این معماری در عمل و از طریق ارزیابی‌های تجربی دقیق و تست‌های آماری بر روی سیستم محک DeltaIoT به اثبات خواهد رسید.

فصل ۵

ارزیابی تجربی

۱-۵ مقدمه

ارزیابی تجربی نقشی اساسی و تعیین‌کننده در تأیید اثربخشی راهکارهای پیشنهادی در سیستم‌های خودوفقی ایفا می‌کند. به دلیل آنکه معماری نوین RS-DRL ادعا می‌کند که می‌تواند بدون نیاز به آموزش‌های پیشرفته و آفلاین، با مدیریت تجربیات ناموفق، بر پدیده بهینه‌های محلی غلبه کند، اعتبارسنجی تجربی این دستاوردها بسیار حیاتی است. در این فصل با بهره‌گیری از سناریوهای متعدد ارزیابی، قابلیت‌های راهکار پیشنهادی را در پلتفرم معتبر شبکه حسگرهای بی‌سیم DeltaIoT [۵] مورد سنجش جامع قرار می‌دهیم.

این فصل در راستای پاسخگویی به سوالات تحقیق مطرح شده در فصل اول سازاماندهی گردیده و هدف اساسی آن نمایش و اثبات برتری این معماری نسبت به راهکارهای پایه و مرسوم موجود است. ساختار فصل بدین گونه است که در ابتدا اهداف ارزیابی تبیین گشته، سپس تنظیمات، مجموعه داده‌ها و محیط پیاده‌سازی معرفی می‌شوند؛ در گام‌های بعدی ضمن معرفی دقیق معیارهای سنجش، دستاوردها و نتایج به دست آمده در سناریوهای تک‌هدفه و چندهدفه و همچنین تحلیل مقیاس‌پذیری و ارزیابی آماری ارائه خواهد شد.

۲-۵ اهداف ارزیابی و سوالات تحقیق

انجام این ارزیابی تجربی همسو با پرسش‌های اساسی مطرح شده در فصل پیشین، اهداف مشخصی را دنبال می‌کند که در جدول ۱-۵ نقشه‌برداری شده‌اند:

جدول ۵-۱: هم‌راستایی اهداف ارزیابی با سوالات تحقیق

سوال تحقیق (RQ)	رویکرد ارزیابی
سوال اول: طراحی مکانیزم DRL برای خروج از بهینه‌های محلی	مقایسه منحنی‌های همگرایی (شکل‌های ۵-۱ و ۵-۲ در این رساله) در برابر روش‌های پایه و ارزیابی عملکرد مجانبی.
سوال دوم: ادغام شکل‌دهی پاداش با بازپخش تجربه	انجام مطالعه ابلیشن (Ablation Study) در برابر گونه‌های مختلف از جمله HER و Soft HER.
سوال سوم: مدیریت فضاهای بزرگ و گسسته تطابق	اجرای تست مقیاس‌پذیری در بسترهای DeltaIoT v1.1 (گزینه)، (۲۱۶ گزینه)، (۱۲۹۶ گزینه) و v2 (۴۰۹۶ گزینه).
سوال چهارم: مقایسه RS-DRL با روش‌های پیشرفته موجود	تقابل با روش‌های استاندارد نظیر ϵ -greedy، DQN، DLASER+ و ML4EAS (جدول‌های ۵-۵ و ۵-۶ در این رساله).

۳-۵ تنظیمات آزمایشگاهی

پیش از ورود به جزئیات آزمایش‌ها، یادآوری می‌گردد که فرمول‌بندی مسئله یادگیری تقویتی شامل فضای حالت، فضای اقدام و توابع پاداش (که برای اهداف مختلف سیستم از جمله کاهش مصرف انرژی، تاخیر و اتلاف بسته‌ها طراحی شده‌اند)، دقیقاً بر اساس مدل ارائه‌شده در فصل‌های پیشین (به‌ویژه روابط ریاضی مطرح شده در فصل پیشین) بنا شده است. این یکپارچگی تضمین می‌کند که عامل هوشمند با همان قواعد و اهداف نظری اثبات‌شده، در محیط شبیه‌سازی آموزش می‌بیند و نیازی به بازتعریف مجدد متغیرها در این فصل نمی‌باشد.

به منظور فراهم نمودن قابلیت بازتولید (Reproducibility) آزمایش‌ها، جزئیات پیکربندی مطالعه موردی به دقت بیان می‌گردد.

۱-۳-۵ نمونه‌های مطالعه موردی

در این پژوهش، از دو بستر آزمایشگاهی متمایز جهت ارزیابی جامع روش پیشنهادی استفاده شده است. سیستم اول، پلتفرم شناخته‌شده DeltaIoT در حوزه شبکه‌های حسگر بی‌سیم صنعتی است و سیستم دوم، شبیه‌ساز مأموریت هوایی پهپاد DARTSim است که با هدف ارزیابی استقلال از دامنه و مقیاس‌پذیری روش پیشنهادی به کار گرفته شده است. پیکربندی استقرار یافته برای شبکه‌های مورد بحث سیستم DeltaIoT، مشخصات فضای حالت‌ها و پیچیدگی‌ها بر اساس ویژگی‌های محک DeltaIoT [۵] در جدول ۵-۲ خلاصه گردیده است:

جدول ۵-۲: نمونه‌های مورد مطالعه سیستم DeltaIoT [۵]

نمونه (نسخه)	تعداد سنسورها	اندازه فضای وقتی (گزینه‌ها)	گام‌های آموزش
DeltaIoTv1	۱۵	۲۱۶	۱۰۰۰۰
DeltaIoTv1.1	۱۶	۱۲۹۶	۶۴۸۰۰
DeltaIoTv2	۳۷	۴۰۹۶	متناسب با مقیاس شبکه

۵-۳-۲ مجموعه داده‌ها

جهت شبیه‌سازی شرایط در زمان اجرا، از ردپاهای محیطی واقعی (Environmental Traces) مستخرج از پژوهش جرواستاتوپولوس و همکاران [۵] مرتبط با سیستم DeltaIoT استفاده شده است. این مجموعه داده، الگوهای تداخلات شبکه‌ای متغیر مابین -40 dB تا $+15\text{ dB}$ را ثبت کرده و همچنین نوسانات مرتبط با بار ترافیک پیام‌ها (بین ۰ تا ۱۰ پیام به ازای هر سنسور) را در طول زمان شامل می‌شود.

۵-۳-۳ پلتفرم پیاده‌سازی

پلتفرم عملیاتی اجراشده در این تحقیق شامل مجموعه‌ای از پیشرفته‌ترین چارچوب‌های محاسباتی است. برای ایجاد محیط یادگیری تقویتی از کتابخانه استاندارد Gymnasium [۴۷] بهره گرفته شد و پیاده‌سازی شبکه‌های DQN بر روی چارچوب مشهور Stable-Baselines3 [۴۸] انجام شده است. در دل این پیاده‌سازی، مکانیزم بومی شکل‌دهی پاداش تصادفی به صورت مستقیم به درون حافظه بازپخش (Replay Buffer) تزریق گشته است. به منظور اعتبارسنجی صوری و ایمنی گزینه‌های تطبیق‌یافته نیز موتور UPPAAL-SMC [۲۴] و مؤلفه واسط ActivFORMS [۴۱] نقش رابط‌های کنترلی را ایفا می‌کنند.

۵-۳-۴ تنظیمات فرایارامتراها (Hyperparameters)

به منظور دستیابی به بهترین عملکرد، فرایارامترهای الگوریتم یادگیری تقویتی از طریق جستجوی شبکه‌ای (Grid Search) در طی آزمایش‌ها تنظیم شده‌اند. مهم‌ترین پارامترهای نهایی شامل نرخ یادگیری (Learning Rate)، اندازه دسته (Batch Size)، فرکانس به‌روزرسانی شبکه هدف (Target Network Update Frequency)، و برنامه کاهش نرخ اکتشاف (ϵ -decay schedule) می‌باشند. مقادیر دقیق این فرایارامتراها پس از ارزیابی‌های اولیه انتخاب شده‌اند تا تعادل مناسبی بین اکتشاف (Exploration) و بهره‌برداری (Exploitation) برقرار گردد و نتایج ارائه‌شده بر پایه این مقادیر بهینه‌شده به دست آمده‌اند.

۴-۵ روش‌های پایه و مقایسه

جهت ارزیابی عملکرد و تفوق رویکرد RS-DRL، آن را با مجموعه وسیعی از متدهای موجود مقایسه کرده‌ایم. مقایسه در سه دسته‌بندی هدف‌گذاری به شرح زیر صورت گرفت:

- **مقاصد کمینه‌سازی (Minimization Goals):** برای این منظور مدل در برابر عامل استاندارد یادگیری پایه، نظیر شبکه‌های کیو عمیق استاندارد ϵ -greedy DQN [۱۹] و همچنین در برابر ترکیبات RS-DRL با استراتژی‌های مشهوری چون بازپخش تجربه با نگاه به گذشته HER (RS-DRL-with-HER) [۸] و روش پاداش نرم‌تر Soft HER [۹] قرار گرفت.
- **مقاصد ترکیبی اهداف آستانه‌ای محدود (TTS Goal):** برای ارزیابی کیفی، الگوریتم‌های شناخته‌شده‌ای همچون روش کاهش فضای وفقی DLASER+ [۱۸] و یک سیستم مرجع (Reference) که بر پایه جستجوی کامل و جامع تمامی حالت‌ها (Exhaustive Search) استوار بود، مورد ارزیابی قرار گرفت.
- **مقاصد آستانه‌ای مطلق (TT Goal):** راهکار پیشنهادی در تقابل با مدل‌های یادگیری پیشرفته همچون متدولوژی ML4EAS [۲۰]، نسخه اولیه DLASER [۱۸]، روش بهبود یافته DLASER+ [۱۸] و روش مرجع سنجیده شد.

نکته کلیدی در خصوص انطباق روش‌های HER: ذکر این نکته حائز اهمیت است که مدل‌های HER و Soft HER اساساً برای محیط‌های مبتنی بر هدف‌های صریح (Goal-Conditioned Environments) طراحی و تنظیم گشته‌اند، در حالی که اهداف کیفی در DeltaIoT به صورت کمینه‌سازی پیوسته هستند. با این وجود برای فراهم کردن بستر مقایسه علمی در محیط‌های نرم‌افزاری شبکه همانند DeltaIoT، ما این راهکارها را متناسب‌سازی کرده و با در نظر گرفتن آستانه‌های تعریف شده اهداف کیفی (QoS) به عنوان اهداف جایگزین (Proxy Goals)، فرآیند تغییر مرجع مجدد (Relabeling) را بر اساس آنها شبیه‌سازی کردیم. این رویکرد استفاده از اهداف جایگزین ضروری بود تا بتوان الگوریتم‌های مبتنی بر HER را در سناریوهایی که اساساً بدون هدف صریح هستند، به طور عادلانه ارزیابی نمود.

۵-۵ معیارهای ارزیابی

در راستای متدولوژی‌های سنجش استاندارد موجود، ارزیابی این رساله بر محور دو گروه دسته‌بندی استوار گشته است:

۵-۵-۱ معیارهای عملکرد یادگیری عامل هوشمند

این معیارها برای بررسی روند یادگیری سیستم استفاده می‌شوند:

۱. **عملکرد مجانبی (Asymptotic Performance):** این سطح، وضعیت نهایی‌ترین ارزش و کیفیتی است که عامل پس از دریافت آموزش کافی به آن دست می‌یابد. اندازه‌گیری آن به‌طور معمول بر پایه محاسبه معدل پاداش به دست آمده روی تعداد محدودی از گام‌های نهایی چرخه امکان‌پذیر است.

۲. **زمان تا آستانه (Time to Threshold):** بیانگر تعداد گام‌های زمانی است که عامل نیازمند طی کردن است تا به یک مقدار پاداش از پیش تعیین‌شده همگرا گردد. به‌عنوان نمونه آستانه مورد قبول در جداول ارزیابی مقداری معادل ۰/۹ در نظر گرفته شده است.

۳. **عملکرد کل (Total Performance):** تابعی برای ارزیابی جامع که از مجذور عملکرد مجانبی در طی زمان کم شده از جمع کل مقادیر پاداش اخذ شده به دست می‌آید. این فرمول به صورت زیر نمایش داده می‌شود:

$$TP = R_{\infty} \cdot T - \sum_{t=1}^T r_t$$

تفسیر این معیار: به دست آمدن مقادیر مثبت نشانگر آن است که منحنی یادگیری مدل همواره پایین‌تر از سطح آرمانی مجانبی بوده و میل به بهبود و رشد در طول زمان دارد. اما مقادیر منفی حاکی از اوج‌گیری اولیه و سپس افت و همگرایی به سطوح پایین‌تر عملکرد در زمان اجراست.

۵-۵-۲ معیارهای عملکرد سیستم

موارد زیر منعکس‌کننده خروجی نهایی سیستم در ساختار شبکه می‌باشند:

- **تلفات بسته‌های ارسالی (Packet Loss):** درصد پیغام‌هایی که با خطا مواجه شده و به مقصد نمی‌رسند.
- **تاخیر ارسال (Latency):** مدت زمان صرف‌شده برای انتقال اطلاعات به گره مرکزی.
- **مصرف انرژی (Energy Consumption):** مصرف نهایی انرژی در گره‌های سنسورها پس از اعمال وفقی‌سازی.


۶-۵ نتایج و تحلیل‌ها

این بخش به عنوان قلب ارزیابی رساله، نتایج استخراج شده از شبیه‌سازی‌ها را تدوین و تفکیک نموده است.

۱-۶-۵ منحنی‌های یادگیری و رفتار همگرایی


روند پیشرفت یادگیری الگوریتم در مقایسه با مدل پایه‌ای به وضوح برتری مکانیزم پیشنهادی را تصدیق می‌کند. در تحلیل رفتار شبکه با استفاده از DeltaIoTv1، مشاهده می‌گردد که رویکرد RS-DRL توانسته است ارزش مجانبی بسیار درخشان 0.9905 را (با خطای انحراف معیار 0.0268) کسب نموده و در مدت زمان نسبتاً کوتاه ۲۲۶۶ گام (با تحمل خطای 150 پیش و پس) به آستانه مطلوب نفوذ کند. در نقطه‌ی مقابل، الگوریتم پایه‌ی حریصانه یعنی ϵ -greedy DQN نه تنها نتوانست از حد مجانبی 0.4559 فراتر رود، بلکه هرگز موفق به فتح آستانه‌ی در نظر گرفته شده نیز نگردید. دلیل بنیادین این توفیق RS-DRL، آن است که مکانیزم شکل‌دهی تصادفی، به جای اکتفای تنها بر آموزش پایه، با تخصیص پاداش به تجربیات منحصرأ ناموفق اجازه می‌دهد این مدل نه تنها به ثبات بالاتری بهبود یابد، بلکه در بالاترین سطح مجانبی با ثبات مطلوبی مستقر بماند و از بهینه‌های محلی فرار کند.

شکل ۵-۱ منحنی یادگیری الگوریتم‌ها را در فضای DeltaIoTv1 نشان می‌دهد و برتری همگرایی RS-DRL را در برابر روش‌های پایه به وضوح به تصویر می‌کشد.



شکل ۵-۱: منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1 (پاداش در برابر گام‌ها)

در فضای بسیار پیچیده‌تر با حضور ۱۲۹۶ گزینه تطبیق‌پذیر در بسته‌ی DeltaIoTv1.1، راهکار ما در ۱۹۲۹۶ گام به پاداش عالی 0.8983 (± 0.0932) نفوذ پیدا کرد، در حالی که همه مدل‌های رقیب عملکرد کل ضعیف‌تری را ثبت کرده و هرگز به خط آستانه نزدیک نشدند (مطابق با شکل ۵-۲).



شکل ۵-۲: منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1.1

۵-۶-۲ مقایسه عملکرد به ازای هر هدف

به منظور درک دقیق جزئیات کارکرد عوامل کنترلی روی تک‌تک متغیرهای سیستم، به ارزیابی رویکرد پیشنهاد شده با انواع HER پرداختیم. جداول ۵-۳ و ۵-۴ عملکرد مجانبی، زمان تا آستانه و عملکرد کل را برای اهداف مختلف نشان می‌دهند.

جدول ۵-۳: نتایج اهداف کمینه‌سازی در DeltaIoTv1 (پاداش مجانبی / گام‌ها)

روش	چندهدفه			مصرف انرژی			تلفات بسته‌ها		
	مجانبی	زمان تا آستانه	عملکرد کل	مجانبی	زمان تا آستانه	عملکرد کل	مجانبی	زمان تا آستانه	عملکرد کل
RS-DRL	۰/۹۹	۲۲۶۶	—	۰/۹۷	—	—	۰/۹۸	—	—
RS-DRL-HER	۰/۶۱	عدم همگرایی	—	۰/۵۸	عدم همگرایی	—	—	—	—
RS-DRL-SoftHER	۰/۴۹	عدم همگرایی	—	۰/۳۹	عدم همگرایی	—	—	—	—
DQN	۰/۴۵	عدم همگرایی	—	—	عدم همگرایی	—	—	—	—

جدول ۵-۴: نتایج اهداف کمینه‌سازی در DeltaIoTv1.1

روش	چندهدفه			مصرف انرژی			تلفات بسته‌ها		
	مجانبی	زمان تا آستانه	عملکرد کل	مجانبی	زمان تا آستانه	عملکرد کل	مجانبی	زمان تا آستانه	عملکرد کل
RS-DRL	۰/۸۹	۱۹۲۹۶	—	۰/۹۳	—	—	۰/۹۱	—	—
RS-DRL-HER	—	عدم همگرایی	—	—	عدم همگرایی	—	—	—	—
RS-DRL-SoftHER	—	عدم همگرایی	—	—	عدم همگرایی	—	—	—	—
DQN	—	عدم همگرایی	—	—	عدم همگرایی	—	—	—	—

تحلیل این اهداف نشان می‌دهد:

- بهینه‌سازی چندهدفه (Multi-objective): متد ما توانست به پاداشی معادل ۰/۹۹۰۵ (در شبکه اول) و ۰/۸۹۸۳ (در شبکه دوم) دست یابد در حالی که بهترین انواع HER منحصراً مقادیری مابین ۰/۴۹ الی ۰/۶۱ را ثبت نمودند. علت این افت فاحش در مدل‌های HER را باید در ماهیت وابستگی این

مدل‌ها به تعاریف و تخصیص اهداف صریح، در مقایسه با پویایی اهداف نامشخص اکوسیستم SAS جستجو نمود.

- **مصرف انرژی:** شاخص‌های ارزیابی، مصرف انرژی RS-DRL را با ثبت میانگین ۰/۹۷۵۶ (در v1) و ۰/۹۳۰۱ (در v1.1) بسیار متمایز از مدل‌های پایه (بازه‌ی ۰/۳۹ الی ۰/۵۸) نشان داد.
- **تلفات بسته‌ها (Packet Loss):** دستیابی راهکار توسعه‌یافته در نگهداری امنیت شبکه‌ها به‌عنوان عاملی در مرز نزدیک به حالت بهینه؛ ۰/۹۸۵۰ در شبکه اولیه و تغییر آن به وضعیت ۰/۹۱۲۹ در شبکه‌ی پیچیده‌تر دوم.
- **تاخیر (Latency):** شبکه مجهز به RS-DRL موفق‌ترین سرعت رکوردگیری را با معدل ۰/۹۹۶۴ و ۰/۹۰۲۱ منعکس کرد.

۵-۶-۳ ارزیابی مقایسه‌ای در برابر تمام روش‌های پایه

ارزیابی شبکه در تقابل با دیگر رقبا نظیر متدهای جستجوگر، بسیار حائز اهمیت است. در جداول ۵-۵ و ۵-۶ نتایج مربوط به اهداف آستانه‌ای خلاصه شده است.

جدول ۵-۵: عملکرد سیستم برای اهداف آستانه‌ای ترکیبی (TTS Goal)

روش (شبکه v1)	اتلاف بسته‌ها (%)	تاخیر (s)	مصرف انرژی (C)
RS-DRL	۱۰/۵۷۸	۰/۰۹۷	۱۲/۸۸۲
DLASER+	۱۲/۸۹۰	۰/۸۴۰	۱۳/۰۲۰
Reference	۱۴/۲۳۰	۰/۱۰۰	۱۳/۱۰۰

جدول ۵-۶: عملکرد سیستم برای اهداف آستانه‌ای مطلق (TT Goal)

روش	DeltaIoTv1		DeltaIoTv2	
	اتلاف بسته‌ها (%)	تاخیر (s)	اتلاف بسته‌ها (%)	تاخیر (s)
RS-DRL	۷/۱۵۳	—	۹/۳۳۰	۰/۲۵۱
DLASER+	۷/۹۸۰	—	—	—
ML4EAS	—	—	۱۰/۵۶۰	—
Reference	—	—	—	۰/۱۰۰


در خصوص هدف TTS، تحت شبکه اولیه، متد RS-DRL از دست رفتگی بسته‌های حاوی پیغام را در مرز ۱۰/۵۷۸٪ متوقف نمود، در حالی که استفاده از ارزیابی جستجوی مرجع (Reference) درصد ۱۴/۲۳٪ و همچنین DLASER+ بالغ بر ۱۲/۸۹٪ اتلاف داشته‌اند. تاخیر ارسال با نرخ ۰/۰۹۷ بسیار بهتر از رقیب اصلی آن یعنی DLASER+ (با ثبت ۰/۸۴۰) کارنامه موفق‌تری از خود برجای گذاشت و متوازن با روش مرجع

(۰/۱۰۰) بود. میزان مصرف انرژی (با مقدار ۱۲/۸۸۲) نیز نزدیک به رویکرد مرجع (۱۳/۱۰۰) و DLASER+ (۱۳/۰۲۰) محاسبه گردید. همچنین در هدف TT، راهکار ما در پلتفرم DeltaIoTv1، به تلفات بسیار کم شبکه (۷/۱۵۳٪) در مقابل بهترین رقیب یعنی DLASER+ (۷/۹۸۰٪) رسید؛ همچنین در پلتفرم عظیم v2، موفق شد مقدار ۹/۳۳۰٪ را برای این فاکتور ثبت نماید در حالی که بهترین سیستم هوش ماشینی فعلی (ML4EAS) مقداری معادل ۱۰/۵۶۰٪ ارائه داد.

تنها تفاوت موجود، تخصیص تاخیر در نسخه دوم بود (که RS-DRL تاخیر ۰/۲۵۱ را در مقایسه با ۰/۱۰۰ روش مرجع ثبت نمود)؛ که البته یک طراحی مبتنی بر خطمشی به جهت اولویت بندی انتقال شبکه و کاهش اتلاف به جای کاهش زمان تاخیر قلمداد می شود و نه یک شکست الگوریتمی.

۴-۶-۵ مطالعه ابلیشن: حساسیت به فاکتور شکل دهی ρ

یکی از دستاوردهای علمی مهم این متد، تخصیص استراتژیک ضریب مفقود به تجربیات گذشته بود. در الگوریتم، مقدار کنترل کننده ρ تعیین می کند تا چه تعداد از تجربیات ناکام ثبت شده در مینی بچ (ذخیره شده در حافظه سیستم)، با ضریب عدد یک (پاداش مثبت تصنعی) جایگزین شوند. در صورتی که تجربه های شکست خورده موجود در حافظه بیشتر از نرخ انتخابی ما باشد، کاملاً به صورت تصادفی تعدادی انتخاب گشته و مجدد شکل دهی می گردند و در غیر این صورت روی تمامی آنها شکل دهی پیاده می گردد. جهت درک دقیق تر، بررسی مقادیر مختلف ρ در قالب شکل ۳-۵ قابل مشاهده است.



شکل ۳-۵: تاثیر مقادیر مختلف ضریب شکل دهی ρ بر پاداش مجانبی و عملکرد کل

نکات تحلیلی پیرامون فاکتور: ایجاد یک توازن کلیدی حول فاکتور بسیار مهم است. اگر ρ بیش از حد بالا باشد، عامل با نویز بالا مواجه خواهد شد و عملکرد افت می کند. متقابلاً مقادیر بسیار پایین نیز به آن معناست که عامل استراتژی جسورانه ای برای خروج از بهینه های محلی نخواهد داشت و مشابه شبکه های

پایه فریز می‌شود. این انتخاب تصادفی در کنار توزیع منطقی p ، از تناسب بیش از حد (Overfitting) حافظه نیز ممانعت به عمل می‌آورد.

۵-۶-۵ تحلیل مقیاس پذیری

مقایسه نتایج مدل حاکی از پیروزی پایدار آن است. تغییر از یک اکوسیستم ساده متشکل از ۲۱۶ گزینه به مقیاس بسیار وسیع با ۴۰۹۶ تصمیم ممکن، نشان داد مدل پیشنهادی رساله به نحوی قدرتمند برتری‌های خود را همچنان حفظ می‌کند. جدول ۷-۵ این روند مقیاس پذیری را نشان می‌دهد.

جدول ۷-۵: تحلیل مقیاس پذیری الگوریتم با بزرگ شدن فضای تطابق

نسخه DeltaIoT	سنسورها	گزینه‌های تطابق	گام‌های آموزش مورد نیاز	پاداش مجانبی
v1	۱۵	۲۱۶	۲۲۶۶	۰/۹۹۰۵
v1.1	۱۶	۱۲۹۶	۱۹۲۹۶	۰/۸۹۸۳
v2	۳۷	۴۰۹۶	—	—

تنها زمان همگرایی یادگیری (جهش از ۲۲۶۶ به ۱۹۲۹۶ گام در نسخه v1.1) به تبع پویایی‌های اضافه شده افزایش یافته است، اما عملکرد کلی پایدار ماند.

۵-۶-۶ نتایج و تحلیل‌های تجربی شبیه‌ساز مأموریت پهپاد DARTSim

جزئیات مربوط به معماری، مؤلفه‌های فیزیکی، فرمول‌بندی مسئله به عنوان فرآیند تصمیم‌گیری مارکوف (MDP) و آداپتور انطباق آفلاین این شبیه‌ساز پیشتر در بخش ۲-۷ (صفحه ۳۱) به تفصیل شرح داده شده است. در این بخش، نتایج حاصل از ارزیابی تجربی و عملکرد یادگیری الگوریتم پیشنهادی بر روی این سیستم ارائه می‌گردد.

به منظور ارزیابی استقلال از دامنه روش پیشنهادی رساله (RS-DRL) و اثبات کارایی آن در سناریوهای فیزیکی-سایبری کاملاً آفلاین (Offline RL)، الگوریتم پیشنهادی بر روی داده‌های آفلاین مأموریت پهپاد در شبیه‌ساز DARTSim آموزش دیده و عملکرد آن در فرار از نقاط بهینه محلی ارزیابی شد.

۵-۶-۶-۱ تنظیمات بستر داده آفلاین مأموریت پهپاد

مجموعه داده جمع‌آوری شده شامل 50,000 انتقال حالت با ویژگی‌های 17 بعدی در فضای حالت و فضای عمل گسسته 8 گانه است. داده‌های رفتار پهپاد به شکل تعاملی نامطلوب و با پاداش میانگین به شدت پراکنده (۰/۰۰۶) و نرخ موفقیت نهایی مأموریت بسیار ناچیز 2.5% ثبت شده‌اند. این توزیع به شدت پراکنده و

نامطلوب، یک محیط یادگیری آفلاین بسیار چالش برانگیز را پدید آورده است که در آن، عدم کاوش کارآمد فضای عمل به سرعت منجر به سقوط یادگیری مدل‌ها به بهینه‌های محلی بی‌ارزش می‌گردد.

۵-۶-۲ آموزش و مقایسه عملکرد همگرایی

الگوریتم پیشنهادی RS-DRL با نرخ تصادفی سازی شکل دهی پاداش $\rho = 0.3$ در مواجهه با روش پایه DQN (بدون تغییر شکل پاداش) تحت ۳ بذر تصادفی مستقل (شامل سیدهای ۴۲، ۴۳ و ۴۴) به مدت 50,000 گام زمانی گرادیان به صورت کاملاً آفلاین آموزش داده شد. نتایج نهایی به دست آمده در جدول ۵-۸ خلاصه شده است.

جدول ۵-۸: مقایسه آماری عملکرد الگوریتم RS-DRL و Baseline DQN در محیط آفلاین DARTSim (میانگین $\pm$ انحراف معیار روی ۳ سید تصادفی مستقل بعد از 50,000 گام آموزشی)


معیار ارزیابی	الگوریتم پیشنهادی RS-DRL	روش پایه DQN	سطح معناداری آماری
بیشینه میانگین ارزش کیو (Max Q-value)	$5/533 \pm 1/425$	$1/431 \pm 0/607$	$p = 0/0397^*$
نرخ بهبود ارزش کیو (%)	$+286/7\%$		$d = 3/75$ Cohen's
میانگین خطای نهایی آموزش (TD Loss)	$0/2709 \pm 0/0122$	$0/0061 \pm 0/0033$	
نرخ شکل دهی پاداش واقعی	$0/281$	غیرقابل اعمال	هدف $\rho = 0.3$

همان‌طور که در جدول ۵-۸ مشهود است، روش پیشنهادی RS-DRL موفق به دستیابی به بیشینه ارزش کیو نهایی میانگین ۵/۵۳۳ در مقایسه با ۱/۴۳۱ در روش پایه DQN شده است. این دستاورد نمایانگر بهبود خیره‌کننده و چشم‌گیر $+286/7\%$ در کیفیت سیاست انطباقی است. ارزیابی با آزمون فرض تی استیودنت دو نمونه‌ای مستقل نشان می‌دهد که این اختلاف از نظر آماری با $p = 0/0397 < 0/05$ کاملاً معنادار است. شاخص اندازه اثر کوهن (Cohen's d) برابر ۳/۷۵ برآورد شده است که اثبات‌کننده یک تفاوت اندازه اثر فوق‌العاده قوی و کارآمدی مطلق روش در هدایت فرآیند اکتشاف آفلاین است.


نمودارهای همگرایی نهایی، خطای نوسانی آموزش و تحلیل آماری پروسه آموزش در قالب شکل‌های ۴-۵، ۵-۵ و ۶-۵ ترسیم و ارائه شده‌اند.

۵-۶-۳ تحلیل پدیده نوسان خطا و خوش‌بینی در یادگیری


در جدول فوق، میانگین خطای TD Loss نهایی برای الگوریتم پیشنهادی RS-DRL مقدار $0/2709$ در مقایسه با خطای ناچیز $0/0061$ برای DQN پایه است. این پدیده کاملاً همسو با تئوری کارکرد شکل دهی تصادفی پاداش است. روش پیشنهادی با تبدیل پاداش شکست‌های گذشته به مقدار خوش‌بینانه $1/0$ با نرخ شکل دهی پاداش واقعی $0/281$ ، باعث ایجاد اختلاف مستمر در تخمین‌های شبکه هدف و شبکه جاری می‌شود. این نوسان خطا به عنوان یک رگولارایزر هوشمند عمل کرده، وزن‌های شبکه را از تثبیت زودهنگام در بهینه‌های



شکل ۵-۴: نمودار همگرایی مأموریت پهبادی DARTSim شامل چهار پانل: (الف) همگرایی ارزش کیو، (ب) میانگین خطای TD، (ج) نرخ شکل دهی پاداش واقعی، و (د) مقایسه گام به گام ارزش کیو.



شکل ۵-۵: تحلیل تفکیکی رفتار الگوریتم RS-DRL در مقایسه با DQN پایه به ازای سیدهای تصادفی مستقل ۴۲، ۴۳ و ۴۴ در محیط شبیه ساز پهبادی DARTSim.



شکل ۵-۶: تحلیل آماری و معناداری اندازه اثر کوهن (Cohen's d) و فواصل اطمینان ارزش کیو برای روش پیشنهادی در برابر روش پایه در مأموریت های DARTSim.

محلی مصون داشته و همگرایی پایدار به سمت سیاست بهینه سراسری را در فضاهای گسسته و بزرگ تلاطم محیطی تضمین می‌کند.

۷-۵ اعتبارسنجی آماری

برای استواری یافته‌های این رساله، نتایج حاصله توسط آزمون‌های دقیق آماری اعتبارسنجی شده‌اند. روش‌شناسی توسعه‌یافته در ارزیابی شامل حداقل ۳۰ دور اجرای کاملاً مستقل با بذرهاى رندوم، انجام آزمون تی تک‌نمونه‌ای (One-sample t-test) [۵۰، ۴۹] با ضریب خطای آلفای برابر ۰/۰۵، و تخصیص فواصل اطمینان ۹۵٪ به روش بوت‌استرپ (Bootstrap) [۵۱] است. فرمول ریاضی محاسبه آماری به این شکل تنظیم گردید:

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

خلاصه اعتبارسنجی‌ها (بر اساس مقادیر p): از بین مجموعاً ۲۸ مقایسه‌ی متمایز و شاخص، تعداد ۲۵ مقایسه کیفیت الگوریتم توسعه‌یافته در یک شرایط آماری فوق‌العاده قرار داشتند (۸۹/۳٪ تست‌ها معنادار بودند). جدول ۹-۵ گزیده‌ای از نتایج آزمون آماری و مقادیر احتمال را نشان می‌دهد.

جدول ۹-۵: مقادیر احتمال (p-values) برای مقایسه‌های معنادار و غیرمعنادار

معیار (هدف)	رقیب پایه	مقدار p (v1)	وضعیت معناداری ($p < ۰/۰۵$)
تلفات بسته (TTS)	DLASER+	$< ۰/۰۰۱$	معنادار (✓)
تلفات بسته (TTS)	Reference	$< ۰/۰۰۱$	معنادار (✓)
مصرف انرژی (TTS)	Reference	۰/۳۲۶	غیرمعنادار (×)
تاخیر (TTS)	Reference	۰/۱۳۴	غیرمعنادار (×)

شگفتی زمانی کامل گشت که در پارامتر اتلاف بسته‌های شبکه (Packet Loss) تمام ۱۰۰٪ از تست‌ها ارزش بهبود معنادار ارائه دادند؛ به‌طور نمونه، احتمال وقوع تصادفی برتری آن برای متد TTS شبکه اول در مقابل مدل‌های DLASER+ و رویکرد مرجع کمتر از ۰/۰۰۱ برآورد گردید ($p < 0.001$). مواردی جزئی نیز که نتایج قابل توجهی نداشتند (مانند آزمون تاخیر که مقدار $p = 0.134$ در شبکه اولیه دریافت نمود یا مصرف انرژی که در حالت TTS مقداری معادل $p = 0.326$ ثبت کرد) عمدتاً به دلیل عملکرد متعادل با روش مرجع بوده و هیچ‌گونه شواهدی مبنی بر تضعیف متد مورد بررسی به دست نمی‌دهد.

۵-۸ خلاصه فصل

این فصل به نحو جامعی توانست ادعاهای نوآوری رساله پیرامون مکانیزم شکل‌دهی یادگیری را تایید نماید. با مرور نتایج مشخص گردید: (۱) متد ابداعی RS-DRL با پایداری ویژه‌ای توانسته تمامی الگوریتم‌های پرآوازه و قدرتمند فعلی پیشین را در ابعاد بهبود عملکرد یادگیری کیفیت و کنترل سیستم شکست دهد. (۲) این برتری در حدود ۸۹/۳٪ مواقع توسط تست‌های اعتبارسنجی آماری تأیید گردیده‌اند (۲۵ مورد از ۲۸ مقایسه کلیدی). (۳) این متد ثابت نمود تغییر مقیاس گزینه‌های وفقی از ۲۱۶ به ۴۰۹۶ گزینه نمی‌تواند قابلیت‌های آن را مختل نماید. (۴) مکانیزم شکل‌دهی مجدد توانسته در مقایسه دقیق و عمیق، از وقوع توقف سیستم‌ها در تله‌های استثنای محلی جلوگیری کند و نهایتاً (۵) برخلاف متدهای رایج هم‌نوع پیشرفته خود نظیر مدل‌های HER، برای پویایی پایدار اساساً نیازمند تخصیص دانش سیستم‌ها با دامنه نامشخص (Domain-specific knowledge) و یا اهداف صریح از پیش مقدر نبوده است.

فصل ۶

بحث، نتیجه‌گیری و پیشنهادها

۱-۶ بحث در مورد یافته‌های کلیدی

این بخش با ترکیب نتایج اصلی و تشریح اهمیت آن‌ها، یافته‌های مستخرج از رساله را مورد ارزیابی عمیق قرار می‌دهد.

۱-۱-۶ نظریه‌پردازی مکانیزم: چرا RS-DRL کار می‌کند؟

همان‌طور که در نتایج ارزیابی تجربی (مندرج در فصل ۵ و با استناد به شکل‌های ۵-۱ و ۵-۲ در همین رساله) نشان داده شد، یکی از مهم‌ترین نقاط قوت RS-DRL توانایی آن در فرار از بهینه‌های محلی است که یک چالش جدی و متداول در سیستم‌های DRL محسوب می‌شود. در محیط‌های پویا، پاداش متوسط مدل RS-DRL نه تنها به‌طور پیوسته افزایش می‌یابد، بلکه در وضعیت پایداری نسبت به رویکرد پایه ϵ -greedy DQN - که با نوسانات شدیدی همراه است و نمی‌تواند از راه‌حل‌های غیربهینه‌رهایی یابد - در سطحی بسیار بالاتر تثبیت می‌گردد.

اثربخشی رویکرد RS-DRL را می‌توان به سه مکانیزم به هم پیوسته زیر نسبت داد:

۱. اکتشاف از طریق تزریق پاداش خوش‌بینانه: با تغییر تدریجی و تصادفی تجربیات ناموفق گذشته ($r_i = 0$) به تجربیات موفق ($r_i = 1$)، عامل یادگیرنده سیگنال‌های تقویت‌کننده مثبتی را از اعمال و وضعیت‌هایی دریافت می‌کند که در شرایط عادی از اولویت خارج می‌شدند. این امر از همگرایی زودهنگام مدل به سیاست‌های غیربهینه که یکی از معضلات بنیادین DQN استاندارد است، ممانعت به عمل می‌آورد.

۲. شکستن همبستگی زمانی در الگوهای شکست: انتخاب تصادفی در فرآیند تغییر تجربیات مردود (که توسط پارامتر ρ کنترل می‌گردد) متغیری را معرفی می‌کند که مانع از حفظ بیش حد (Overfitting) عامل بر روی شرایط متوالی شکست می‌شود. این متغیر به ویژه در محیط‌های غیرایستایی (Non-stationary) که در آن‌ها شکست دیروز ممکن است استراتژی بهینه امروز تلقی گردد، بسیار راهگشا خواهد بود.

۳. یادگیری مستقل از دامنه (Domain-Agnostic): برخلاف روش‌های متکی به HER که مستلزم تعاریف صریح و قطعی از اهداف هستند، شکل‌دهی تصادفی RS-DRL بدون هیچ‌گونه نیاز به درک معنایی اهداف دامنه عمل می‌کند. این موضوع، اجرای آن را ذاتاً برای سیستم‌هایی انعطاف‌پذیر می‌سازد که با اهداف تلویحی و آستانه‌محور – که در سیستم‌های خودوفقی بسیار شایع می‌باشند – سروکار دارند.

۶-۱-۲ تحلیل تعاملات و مصالحه‌ها (به‌عنوان مثال، تأخیر در مقابل از دست رفتن بسته)

در جداول مقایسه‌ای پیشین (برای نمونه جدول ۵-۵ در توصیفات ارزیابی)، مشاهده گردید که برای تخصیص هدف TTS در شبکه DeltaIoTv1، مدل RS-DRL به درستی به تأخیر متوازی دست پیدا کرد (مقدار ۰/۰۹۷ در برابر ۰/۱۰۰ روش مرجع) و در مجموع عملکرد بسیار بهتری در مقایسه با DLASER+ نشان داد. با این وجود، برای شبکه DeltaIoTv2 تحت هدف TT مقدار تأخیر بالاتری حاصل شد (۰/۲۵۱ در برابر ۰/۱۰۰ روش مرجع).

افزایش تأخیر در نسخه دوم شبکه برای مقاصد مربوط به TT نشان‌دهنده یک مصالحه (Trade-off) بسیار مهم در عملکرد عامل است: هنگامی که هدف کلیدی تعریف‌شده از سوی کاربر (مثلاً حفظ توانایی توان عملیاتی شبکه) با اولویت‌بندی به حداقل رساندن مشکل فقدان بسته توأم گردد، مدل هوشمند درمی‌یابد که باید به منظور جلوگیری از دست‌افتادگی پیام‌ها، به سمت مسیرهای قابل اعتمادتری متمایل شود که به صورت ذاتی کندتر هستند. در محیط‌های بهینه‌سازی چندهدفه، چنین مصالحه‌ای نه تنها یک نقطه ضعف و محدودیت به شمار نمی‌رود، بلکه از قضا یک رفتار برآمده و مطلوب از سوی عامل ارزیابی می‌گردد. چرا که در اینجا اولویت سیستم بر تضمین رساندن بسته‌ها بیش از حفظ سرعت بوده است و در کاربردهایی که صحت اطلاعات در آن‌ها اهمیت حیاتی دارد (مانند مانیتورینگ زیست‌محیطی یا سیستم‌های کنترل صنعتی) این تصمیم به‌عنوان عاقلانه‌ترین انتخاب مهندسی تلقی خواهد شد.

این رفتار کاملاً با اصول انتخاب بهینه در استراتژی‌های پرتو-اپتیمال (Pareto Optimality) همخوانی دارد. هنگامی که مرزهای متضاد انتخاب‌ها بررسی می‌گردند، تنظیمات دارای تأخیر بی‌نهایت کم‌تر عموماً ارتباط معناداری با نرخ بالای اتلاف بسته‌ها – به دلیل استراتژی‌های تهاجمی‌تر انتقال داده – نشان می‌دهند.

راهکار RS-DRL یاد می‌گیرد این خطِ مصالحه را با ظرافت طی کند و تصمیم‌ها را منطبق بر بستر نیاز و با تخصیص وزن‌های اختصاص‌یافته برای هر متغیر اخذ نماید.

۳-۱-۶ پیامدهای مهندسی سیستم‌های خودوفقی

ثبات، پایداری و همگرایی سریع متد RS-DRL عوامل حیاتی در محیط‌های پویایی هستند که مقیاس و شرایط آن‌ها به سرعت در حال جابجایی است. از طریق در هم تنیدگی مکانیزم شکل‌دهی پاداش، RS-DRL تضمین می‌نماید که عامل تصمیم‌ساز حتی بدون نیاز به بازآموزی و تخصیص پیکربندی‌های جدید به تغییرات پاسخ می‌دهد، در حالی که در اکثر DRL‌های استاندارد الزام به طی مجدد مسیر آموزش برای اداره کردن امور تغییر یافته، مشهود و گریزناپذیر است. این خصوصیت، این مدل را برای سامانه‌های برخط مانند سیستم‌های ابری و شبکه‌های اشیاء که استقرار و بروزرسانی خودکار استراتژی در آن‌ها واجب است، بسیار متمایز می‌سازد. به بیان دقیق‌تر، پیامدهای عملی این رهیافت برای مهندسی توسعه‌دهنده محیط‌های خودوفقی شامل موارد زیر است:

۱. کاهش قابل ملاحظه سربار عملیاتی: مدل‌های سنتی به هنگام برخورد با رانش و تغییر شرایط محیطی نیازمند صرف چرخه‌های متعدد بازآموزیِ پیاپی می‌باشند. در حالی که ویژگی‌های تعمیم‌پذیری بالای RS-DRL امکان دور ماندنِ مستمرِ مدل از بروزرسانی‌های مجدد را فراهم می‌سازد که خود علاوه بر صرفه‌جویی شدید محاسباتی باعث جلوگیری از عملکرد ضعیف مدل در طی ادوار گذارِ بازآموزی می‌گردد.

۲. بی‌نیازی از داده‌های برجسب‌دار: برخلاف مدل‌هایی همانند ML4EAS یا DLASER+ که اتکای گسترده‌ای به تجمیعِ پیشینِ داده‌ها داشته‌اند، الگوریتم RS-DRL کاملاً آنلاین و در لحظه توسعه می‌یابد. این قابلیت نقطه قوتِ برجسته‌ای در محیط‌هایی محسوب می‌گردد که تهیه اطلاعات پیش‌آموزشی غیرممکن و پیش‌بینی‌ناپذیر است.

۳. پایداری و کاهش تخریب تدریجی کیفیت متناسب با گسترش: استواریِ معنادارِ کیفیت و عملکرد در مواجهه با نسخه‌ی ۲۰۱۶ - گزینه‌ای (نسخه v1)، گسترش ۱۲۹۶ - گزینه‌ای (نسخه v1.1) و مقیاس سرسام‌آور ۴۰۹۶ حالت ممکن (نسخه v2) مؤید آن است که این راهکار متناسب با میزان گستردگی شبکه قابل استقرار است. همچنین افزایش مقطع زمانی همگرایی مدل، به نسبت پیچیدگی فضای جستجو، شیئی کمتر از حالت خطی (Sublinear) دارد.

۴. تصمیم‌گیری شفاف و قابل مدل‌سازی: رویه‌های رفتارگونه‌ی عامل (همانند پدیده مصالحه در برخورد

با اتلاف دیتا و زمان توقف) به نحو کاملاً معنادار و قابل تعریفی مدل‌گستر و قابل توضیح می‌باشد که این ویژگی به مهندسان قدرت تحلیل مضاعف و قابلیت اطمینان بیشتری عرضه می‌نماید.

۲-۶ محدودیت‌ها و تهدیدات اعتبار (Threats to Validity)

مانند تمامی رهیافت‌های پژوهشی، متدولوژی معرفی‌شده با محدودیت‌هایی مواجه است که بررسی صریح روایی و صحت نتایج استخراج‌شده، بستر مناسب را برای پژوهش‌های مکمل آینده تبیین می‌نماید.

۱-۲-۶ اعتبار داخلی (Internal Validity)

۱. حساسیت نسبت به ابرپارامترها: فاکتور کنترل‌کننده‌ی شکل‌دهی تجربیات تصادفی (p)، متولی تنظیم نمودن درصد اختصاص تجربه‌های ناموفق تغییر یافته به نمونه‌های فرضی مثبت و امیدوارکننده است. با اینکه از طریق کاوش شبکه‌ای جامع (Grid Search) توانستیم مناسب‌ترین مقادیر ممکن برای بهینه‌سازی عملکرد یافت کنیم، لیکن این مقادیر می‌توانند به نسبت سایر سیستم‌ها و دامنه‌های متفاوت، دستخوش نوسان باشند. بدیهی‌ست چنانچه پارامتر بسیار بالا وضع گردد موجب اختلال در روند یادگیری گردیده و مقادیر ضعیف آن نیز سبب نقصان در عامل فشار اکتشاف خواهد گشت.

۲. نوسانات بذر تصادفی تولید ارقام (Random Seed Sensitivity): با وجود اجرای بیش از ۳۰ دور فرآیند آموزش مستقل همراه با صحت‌سنجی مستحکم آماری، ماهیت درگیر با احتمالات - چه در پویایی خود محیط و چه در بدنه تنظیم پاداش‌ها - سبب می‌شود تا خروجی‌های هر دوره آموزشی با درجات کوچکی از انحراف واریانس مواجه گردند. با این وصف، فواصل و حاشیه‌های اطمینان به دست آمده (قید شده در جداول فصل ۴) تبیین‌گر کمیت این نوسانات هستند.

۳. مفروضات بازده دودویی (Binary Reward Assumption): یکی از شرایط پیش‌نیاز به کار رفته در الگوریتم، اتکا بر مفروضات مرتبط با نتایج قطعی پیامدهای انطباقی به‌عنوان اهداف توفیق/سقوط مطلق دودویی (یا در مقیاس‌های استاندارد مشابه) است که نمی‌توان آن را به سهولت با کلیه نیازهای سیستم‌های ترکیبی غول‌پیکر وفق داد.

۲-۲-۶ اعتبار خارجی (External Validity)

۱. تخصص حوزه (Domain Specificity): فرآیند ارزیابی منحصرراً بر روی بستر شبکه‌های حسگر بی‌سیم (DeltaIoT) متمرکز بوده است، که تعمیم‌پذیری نتایج به سایر حوزه‌ها را محدود می‌کند. هرچند

پلتفرم مذکور آینه‌ای از مشکلات اساسی سیستم‌های مدرن را به تصویر کشیده و تایید کیفیت کرده است، با این وصف، اعمال الگوریتم توسعه‌یافته بر دیگر شبکه‌های توزیع‌یافته، نیازمند اعتبارسنجی مستقلی خواهد بود.

۲. تمرکز بهینه بر شبکه‌های گسسته: تدوین و صورت‌بندی فعلی به نحوی طراحی گشته که متناسب با فضای تصمیم‌داری مدل‌های محدود گسسته پایه‌ریزی شود. لیکن اکثریت سیستم‌های پویا (مانند سیستم‌های مقیاس‌بندی و تنظیم ظرفیت پردازشی ابری) از پارامترهای پیوسته استفاده می‌نمایند و تنظیم معماری RS-DRL متناسب با متدهای کلاسیک پیوسته نظیر شبکه‌های DDPG ساختارهای بسط یافته مطالعاتی جدیدی را می‌طلبد.

۳. توسعه‌ی در حوزه‌های حساس ایمنی: استفاده از استراتژی خوش‌بینی بر روی اقداماتی که ذاتاً و در دنیای فیزیکی خطرناک بوده‌اند (همانند پلتفرم‌های هدایت اتومبیل‌های هوشمند و یا سیستم‌های دارورسانی)، بدون در نظر گرفتن شرط احتیاط، ممکن است باعث ترغیب ماشین به انجام فعالیت‌های منجر به حادثه گردد و افزودن حلقه‌های تکمیلی تایید صلاحیت بسیار با اهمیت است.

۳-۲-۶ اعتبار سازه (Construct Validity)

در این راستا، دو محدودیت اساسی وجود دارد. نخست، شفافیت متریک‌ها؛ سنجش عملکرد عامل هوش از قبیل بررسی مجانبی ثبات کیفیت زمانی تا رسیدن به راندمان مطلوب آستانه، رویه‌هایی پذیرفته شده می‌باشند؛ اما معرفی فاکتورهای سنجشی جایگزین مانند نرخ رنجوری (رگرت) و شاخص پایداری ممکن است ابعاد ناشناخته دیگری را نمایان سازند. دوم، اصطکاک سنجشی مدل‌های جایگزین؛ از آنجا که مدل‌های برگرفته از HER نیازمند تنظیم صریح برچسب‌گذاری مقصد بوده‌اند، مقایسه صورت پذیرفته نیاز به در نظر گرفتن جایگزین‌های ضمنی کیفی داشت. هرچند مستندسازی اعمال شده بسیار متوازن بود ولی باید اذعان داشت که استفاده از این مقادیر تعدیل یافته معادل بهینه‌ای برای تمام ظرفیت موجود این دست از رقبا نمی‌تواند قلمداد گردد.

۳-۶ مسیرهایی برای تحقیقات آینده

۱-۳-۶ استراتژی‌های انطباقی و وفقی شکل‌دهی ρ

همان‌طور که در فصل بررسی چالش‌ها بحث شد، اتکا به متغیر کنترل‌گر ρ برای الگوریتم ضروری است. ما در توسعه‌های آتی در نظر داریم با برنامه‌ریزی یک ساختار هوشمند برای تنظیم نرخ فاکتور کنترل‌کننده متناسب

با فرآیندهای زمانی مدل پیشروی کنیم تا قابلیت استقرار در زمان اجرای سیستم را تسهیل نماییم. برخی از جهت‌گیری‌های تخصصی شامل موارد زیر می‌باشد:

۱. برنامه‌ریزی تنظیمی پویای پارامتر (ρ): به جای یک متغیر تنظیم شده‌ی دستی، از سازوکاری جهت ارتقا یا تخفیف متغیر بهره خواهیم جست؛ بدین گونه که در هنگامه موفقیت‌های مکرر و تسلط ماشین (فاز استثمار) از درصد فاکتور ρ کاسته شده و در هنگام درگیری مستمر ماشین و گرفتار شدن آن درون تله‌ی بهینه محلی که نرخ دریافت ارزش با فُتول روبرو می‌گردد به صورت پویا با ارتقای متغیر ضریب فشار فرار و اکتشاف تجربیات جدید تشدید شود. در این مسیر استفاده از مدل‌های فرا-یادگیری (Meta-Learning) نیز در خصوص استنتاج بهینه فاکتور مفید فایده خواهد بود.

۲. شکل‌دهی هوشمند بر پایه‌ی خطای عدم اطمینان: امکان به‌کارگیری ابزارهای ارزیابی تخمین اطمینان (مانند Dropout یا انواع مدل‌های انسامبل) در الگوریتم، مقدور می‌سازد تا آن دسته از تجربه‌های شکست خورده‌ای در چرخه‌ی تصادفی‌سازی اولویت یابند که سیستم درباره‌ی قطعیت خطاهای شان کمترین اطمینان و شناخت را در محیط غیرشناخته از خود نشان داده بود.

۳. اولویت‌بندی حافظه‌ی نمونه‌گیری: ادغام روش انتخاب هوشمند با الگوریتم‌های حافظه‌ی مبتنی بر اولویت (Prioritized Experience Replay)، عاملی را معرفی می‌کند تا زیرمجموعه‌های مردود شده‌ی مستعد جبران پس از اعمال شکل‌دهی، با فرکانس شانس بیشتری برای بازیابی توسط شبکه مجدداً احضار شوند.

۲-۳-۶ گسترش به دامنه‌های پیوسته و حساس به ایمنی

با عنایت به ماهیت پویای فضای نرم‌افزار، توسعه روش‌های حاضر بر مسائل نوین‌تر ضروری خواهد بود:

۱. فضای اعمال پیوسته (Continuous Action Spaces): بسط معماری متدیک فعلی در بطن متدهای قدرتمندتری نظیر سیستم‌های شیب‌سیاستی همانند متدهای PPO و SAC از اهداف توسعه‌ی اصلی پژوهش است تا علاوه بر شکل‌دهی پاداش تصادفی، بتوان پارامترهای بدون گسستگی (همچون تنظیم منابع سخت‌افزاری پردازش در فضای ابری) را تنظیم نمود.

۲. اعمال محدودیت‌های تایید ایمنی (Safe Reshaping): برای رفع نگرانی مطرح شده در دامنه‌های حساس به ایمنی، در نظر داریم مکانیزمی با عنوان «شکل‌دهی ایمن» پدید آوریم که بازتولید تصادفی نتایج شکست‌خورده تنها زمانی میسر گردد که خط‌مشی پیش‌بینی‌شده در مناطق ایمن تاییدشده قرار

گیرد. ترکیب با ابزارهای اعتبارسنجی صوری (همچون UPPAAL-SMC استفاده شده در این تحقیق) از هدایت به وضعیت‌های ناایمن پیشگیری می‌کند.

۳. گسترش به سامانه‌های چند عاملی (Multi-Agent): برای مقابله با فضا‌هایی با پویایی بخش‌های تطبیقی در حال تعامل با هم، گسترش متد در چارچوبی صورت می‌پذیرد که چند عامل در هماهنگی استراتژی‌های کاوش همسان به شکل‌دهی پاداش‌های منسجم برای تحقق اهداف بزرگ عمل کنند.

۳-۳-۶ اعتبارسنجی بین‌دامنه و تحلیل‌های نظری

جهت بررسی فراگیری این استراتژی و ایجاد پایه‌های نظری قوی‌تر اهداف زیر دنبال خواهد گردید:

۱. پیکربندی شبکه‌های ابری (Cloud Auto-scaling): به‌کارگیری این رویکرد به جهت تخصیص و توزیع مقیاس ماشین‌های مجازی، و ارزیابی در برابر کارهای مرتبط دیگر در این محیط.
۲. هماهنگی وسایل نقلیه خودران (Autonomous Vehicles): آزمایش در محیط‌های شبیه‌سازی برای هماهنگ‌سازی و تطبیق الگوهای ترافیکی با محدودیت‌های ایمنی و اهداف چندگانه (زمان سفر، بهینه‌سازی انرژی و امنیت).
۳. تضمین تئوریک فرآیند همگرایی (Theoretical Analysis): بررسی اینکه آیا سیگنال پاداش شکل‌دهی شده ویژگی انقباضی و نگاشت ثابت برای یادگیری کیو (Q-Learning) را حفظ می‌کند، و محاسبه کران‌های خطای احتمالی انحراف ارزش Q نسبت به سیاست بهینه.
۴. کاهش حجم پیچیدگی نمونه‌ها (Sample Complexity Analytical Analysis): کمیت‌بندی تئوریک پیرامون اثربخشی شکل‌دهی پاداش بر تقلیل شمار نمونه‌های لازم برای دستیابی به خروجی‌های نزدیک به بهینه در قیاس با شبکه‌ی DQN استاندارد.

۴-۶ نتیجه‌گیری

۱-۴-۶ خلاصه بیان مسئله و راهکار پیشنهادی

این رساله به‌عنوان دستاوردی متصل بر یکی از چالش‌های بنیادین سیستم‌های خودوقتی مقاصد خود را تنظیم نموده است؛ مدیریت عدم قطعیت در شبکه‌هایی که درون فضا‌های بزرگ و گسسته‌ی تطابق عمل می‌کنند. رویکردهای سنتی - اعم از مدل‌های مبتنی بر یادگیری ماشین، مدل‌های متکی بر جستجو و یا یادگیری تقویتی

استاندارد - با محدودیت‌های شدیدی مواجه بوده‌اند؛ ویژگی‌هایی از قبیل نیاز مبرم به دیتای برچسب‌دار آفلاین، دست و پنجه نرم کردن با فقدان مقیاس‌پذیری و احتمال بالای توقف در بهینه‌های محلی برآمده از تغییر شرایط. ما استراتژی یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) را ارائه نمودیم؛ رویکردی نوین که مکانیسم تصادفی شکل‌دهی را درون جریان حافظه بازپخش عامل کیو (DQN) یکپارچه می‌نماید. با بهره‌گیری از زیرمجموعه‌ای از تجربیات ناکام فاز گذشته ($r_i = 0$) و اعمال تحول در پاداش و تبدیل آن به تجربه‌ای خوش‌بینانه ($r_i = 1$)، راهکار RS-DRL مشوق قدرتمند فرآیند اکتشاف بوده و از گرفتاری در بهینه‌های محلی جلوگیری می‌نماید، بدون آنکه کمترین الزامی برای تعریف و اختصاص قطعی اهداف مبتنی بر دانش از پیش تعیین‌شده دامنه، داشته باشد.

۲-۴-۶ مرور مشارکت‌ها و شواهد تجربی

یافته‌های مستخرج پژوهش که ارائه‌ی پاسخی قاطع بر پرسش‌های این رساله به شمار می‌آید شامل موارد کلیدی زیر است. جدول ۶-۱ خلاصه‌ای از این مشارکت‌ها و شواهد را نشان می‌دهد.

جدول ۶-۱: خلاصه‌ای از مشارکت‌های کلیدی و شواهد تجربی

مشارکت (Contribution)	شواهد (Evidence)	اهمیت (Significance)
شکل‌دهی پاداش نوین (Novel Reward Shaping)	توسعه الگوریتم ۴-۱، نمایش در شکل‌های ۵-۱ و ۵-۲	امکان اکتشاف بدون نیاز به دانش دامنه سیستم
تطبیق و وفقی‌سازی مقیاس‌پذیر	مستخرج از جداول ۳ و ۴ (نسخه‌های v1 تا v2)	حفظ پایداری عملکرد با رشد گزینه‌ها از ۲۱۶ تا ۴۰۹۶ حالت
برتری و تفوق اثبات آماری	تحلیل جداول ۵ و ۶، معناداری ۲۵ از ۲۸ تست	دریافت $p < 0.001$ برای اکثر متریک‌های بهبود اتلاف بسته

مشارکت اول: ابداع ماشین نوین جهت شکل‌دهی پاداش توسعه الگوریتم تخصیص پاداش (طراحی الگوریتم ۴-۱) که از طریق کنترل‌کننده‌ای با ضریب مشخص (ρ) عمل نموده و برخلاف رویکردهای غایت‌محور نظیر متدهای HER هیچگونه نیازی بر تعیین هدف آستانه‌ای با درک معنایی نداشته و مستقیماً روی سیستم‌های خودوفقی قابل راه‌اندازی است.

مشارکت دوم: یکپارچه‌سازی حلقه کنترل MAPE-K طراحی زیرسامانه‌ی متصل متشکل از چرخه ۹ مرحله‌ای که RS-DRL را با حلقه MAPE-K ترکیب می‌کرد؛ مجهز به ارزیابی برای تضمین اعتبار زمان اجرا با موتور کنترل UPPAAL-SMC و مؤلفه ActivFORMS برای اجرای وفقی.

مشارکت سوم: دستاوردهای تجربی در مقیاس اینترنت اشیاء دستاورد استقرار شبکه‌ی عامل بر بستر ۳ مقیاس وسیع (فضای محدود ۲۱۶، نسخه ۱۲۹۶ و نسخه منبسط ۴۰۹۶ تصمیم ممکن). دستیابی بی‌رقیب به نرخ مجانبی 0.9905 ± 0.0268 (در شبکه اولیه) و 0.9932 ± 0.8983 (در v1.1) که با قاطعیت

ساختار کلاسیک ϵ -greedy DQN (با راندمان 0.2233 ± 0.4559) و مشابه‌های HER را مغلوب ساخت. ثبت کاهش شگفت‌انگیز 23.22% برای نابودی بسته‌ها و 39.07% کاهش تأخیر شبکه نسبت به DLASER+ تحت اهداف TTS. این مقادیر از طریق نتایج آزمون t-test (موفقیت در ۸۹/۳% از ۲۸ مقایسه متمایز) اعتبار مطلق دریافت کرد.

مشارکت چهارم: بینش عمیق نظری و عملی اثبات و آشکارسازی اینکه مکانیزم روایی برای تزریق خوش‌بینی نه تنها راه‌حلی منطقی، خروج سیستم را از گیر افتادن مصون داشته، بلکه تحلیل الگوهای متضاد درون سیستمی نظیر (تأخیر متناقض با نرخ اتلاف بسته‌ها) نشان دادیم عامل استنتاج‌هایی به وسعت دانش طراحی چند-هدفه و سازگار با رفتار سیستم هوشمند اخذ کرده است و همزمان این ظرفیت برای تغییر سایز و پدیده‌ی مقیاس‌پذیری فضای عمل بسیار کارآمد بوده است.

۳-۴-۶ سخنان پایانی

از آنجا که سیستم‌های نرم‌افزاری به‌طور فزاینده‌ای در محیط‌هایی سرشار از عدم قطعیت، پویایی و مقیاس‌های بزرگ عمل می‌کنند، نیاز به مکانیسم‌های وفقی که بتوانند به‌طور کاملاً مستقل فرآیند یادگیری و تنظیم استراتژی را انجام دهند چشمگیرتر می‌شود. مدل هوشمند RS-DRL یک قدم استوار در جهت این چشم‌انداز تلقی می‌شود - روشی که نه تنها متکی به آموزش‌های مبتنی بر موفقیت است بلکه با ظرفیتی شایسته، از بطن اشتباهات پیشین درس‌های بسیار موثری اخذ می‌کند و به بیان دیگر کاستی‌های پیشین را به یک فرصت ارزنده تبدیل خواهد کرد.

اهمیت این تحقیقات مرزهای توسعه‌یافته در یک شبکه DeltaIoT را کاملاً در هم شکسته است. هر نوع معماری که توأمان با ۳ چالش بنیادین سیستم نرم‌افزار (استقرار محیط پیکربندی کلان، عدم قطعیت‌های متغیر شرایط و نیاز تطبیق زمان اجرا) دست و پنجه نرم کند، با تکیه بر متد معرفی‌شده در RS-DRL می‌تواند بر این معضل غلبه نماید، به گونه‌ای که سیستم‌های ابری، امنیت سایبری شبکه، کنترل برق هوشمند و هدایت پهپادهای یکپارچه از مصادیق این قابلیت‌ها هستند.

مأموریت نهایی آینده برای سیستم‌ها آن است که نه تنها مستمراً راهبری سیستم را هماهنگ بدانند بلکه فراتر از آن استراتژی را پیوسته غنی‌سازی نمایند - هدفی بزرگ که در شرف تحقق پیوسته است. رساله‌ی حاضر با اتکا بر راهکار ابداعی RS-DRL تلاش داشته خشت کوچکی اما ارزشمند رو به سوی این آرمان کلان مهندسی نرم‌افزار بنا کند.

کتاب نامه

- [1] Gartner, “The cost of downtime,” tech. rep., Gartner Research, 2014.
- [2] J. O. Kephart and D. M. Chess, “The vision of autonomic computing,” *Computer*, vol.36, no.1, pp.41–50, 2003.
- [3] P. Oreizy, N. Medvidovic, R. N. Taylor, D. S. Rosenblum, J. R. Robbins, M. Mikic-Rakic, N. Lekic, R. Webby, and N. Medvidovic, “An architecture-based approach to self-adaptive software,” *IEEE Intelligent Systems*, vol.14, no.3, pp.54–62, 1999.
- [4] B. H. Cheng, R. de Lemos, H. Giese, P. Inverardi, J. Magee, *et al.*, “Software engineering for self-adaptive systems: A research roadmap,” in *Software Engineering for Self-Adaptive Systems*, pp.1–26, Springer, 2009.
- [5] I. Gerostathopoulos, D. Weyns, S. Bogo, *et al.*, “Deltaiot: A benchmark for self-adaptive iot systems,” in *Proceedings of the 14th International Symposium on Software Engineering for Adaptive and Self-Managing Systems*, pp.66–72, 2019.
- [6] G. Du, Y. Wang, Y. Liu, X. Wu, and L. Ma, “Alleviating local optima and enhancing path planning: A deep reinforcement learning approach for autonomous exploration,” in *International Conference on Autonomous Unmanned Systems*, (Singapore), pp.124–133, Springer Nature Singapore, September 2023.
- [7] O. Gheibi and D. Weyns, “Dealing with drift of adaptation spaces in learning-based self-adaptive systems using lifelong self-adaptation,” *ACM Transactions on Autonomous and Adaptive Systems*, vol.19, no.1, pp.1–57, 2024.
- [8] M. Andrychowicz, F. Wolski, A. Ray, J. Schneider, R. Fong, P. Welinder, B. McGrew, J. Tobin, P. Abbeel, and W. Zaremba, “Hindsight experience replay,” in *Advances in Neural Information Processing Systems*, vol.30, 2017.
- [9] Q. He, L. Zhuang, and H. Li, “Soft hindsight experience replay,” *arXiv preprint arXiv:2002.02089*, 2020.
- [10] M. L. Puterman. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. John Wiley & Sons, 1994.

- [11] R. S. Sutton and A. G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2018.
- [12] F. Quin *et al.*, “Efficient analysis of large adaptation spaces in self-adaptive systems using machine learning,” in *2019 IEEE/ACM 14th International Symposium on Software Engineering for Adaptive and Self-Managing Systems (SEAMS)*, IEEE, 2019.
- [13] F. Quin, D. Weyns, and O. Gheibi, “Reducing large adaptation spaces in self-adaptive systems using machine learning,” *Journal of Systems and Software*, p.111341, 2022.
- [14] Z. Coker, D. Garlan, and C. L. Goues, “Sass: Self-adaptation using stochastic search,” in *10th International Symposium on Software Engineering for Adaptive and Self-Managing Systems, SEAMS 2015*, Institute of Electrical and Electronics Engineers Inc, 2015.
- [15] C. Kinneer *et al.*, “Managing uncertainty in self-adaptive systems with plan reuse and stochastic search,” in *ACM/IEEE 13th International Symposium on Software Engineering for Adaptive and Self-Managing Systems, SEAMS 2018, , co-located with International Conference on Software Engineering, ICSE 2018*, IEEE Computer Society, 2018.
- [16] C. Kinneer, D. Garlan, and C. L. Goues, “Information reuse and stochastic search: Managing uncertainty in self-* systems,” *ACM Transactions on Autonomous and Adaptive Systems (TAAS)*, vol.15, no.1, pp.1–36, 2021.
- [17] D. Kim and S. Park, “Reinforcement learning-based dynamic adaptation planning method for architecture-based self-managed software,” in *2009 ICSE Workshop on Software Engineering for Adaptive and Self-Managing Systems*, IEEE, 2009.
- [18] A. Metzger *et al.*, “Realizing self-adaptive systems via online reinforcement learning and feature-model-guided exploration,” *Computing*, pp.1–22, 2022.
- [19] V. Mnih *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol.518, no.7540, pp.529–533, 2015.
- [20] F. Kachi and C. Bouanaka, “A hybrid model for efficient decision-making in self-adaptive systems,” *Information and Software Technology*, vol.153, p.107063, 2023.
- [21] J. Kramer and J. Magee, “Self-managed software an engineering challenge,” in *Companion of the Proceeding of the 29th International Conference on Software Engineering*, pp.259–268, 2007.
- [22] D. Weyns *et al.*, “Applying architecture-based adaptation to automate the management of internet-of-things,” in *Software Architecture: 12th European Conference on Software Architecture, ECSA 2018, Madrid, Spain, September 24–28, 2018, Proceedings 12*, Springer, 2018.

- [23] R. De Lemos *et al.*, “Software engineering for self-adaptive systems: Research challenges in the provision of assurances,” in *Software Engineering for Self-Adaptive Systems III. Assurances: International Seminar, Dagstuhl Castle, Germany, December 15-19, 2013, Revised Selected and Invited Papers*, Springer, 2017.
- [24] A. David *et al.*, “Uppaal smc tutorial,” *International journal on software tools for technology transfer*, vol.17, pp.397–415, 2015.
- [25] C. J. Watkins and P. Dayan, “Q-learning,” *Machine learning*, vol.8, pp.279–292, 1992.
- [26] G. A. Rummery and M. Niranjan, “On-line q-learning using connectionist systems,” tech. rep., University of Cambridge, Department of Engineering, 1994.
- [27] M. U. Iftikhar *et al.*, “Deltaiot: A self-adaptive internet of things exemplar,” in *2017 IEEE/ACM 12th International Symposium on Software Engineering for Adaptive and Self-Managing Systems (SEAMS)*, IEEE, 2017.
- [28] M. R. Garey and D. S. Johnson. *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W. H. Freeman and Company, 1979.
- [29] G. A. Moreno, C. Kinneer, A. Pandey, and D. Garlan, “Dartsim: An exemplar for evaluation and comparison of self-adaptation approaches for smart cyber-physical systems,” in *Proceedings of the 14th International Symposium on Software Engineering for Adaptive and Self-Managing Systems (SEAMS)*, pp.181–187, 2019.
- [30] G. A. Moreno *et al.*, “Proactive self-adaptation under uncertainty: a probabilistic model checking approach,” in *Proceedings of the 2015 10th joint meeting on foundations of software engineering*, 2015.
- [31] M. Camilli *et al.*, “Many-objective self-adaptation under model uncertainty,” *ACM Transactions on Autonomous and Adaptive Systems*, 2025.
- [32] D. Weyns *et al.*, “Formal models for self-adaptation: a systematic literature review,” *ACM Transactions on Autonomous and Adaptive Systems (TAAS)*, vol.7, no.1, pp.1–36, 2012.
- [33] N. Esfahani and S. Malek, “Uncertainty in self-adaptive software systems,” in *Software Engineering for Self-Adaptive Systems II*, pp.214–238, Springer, 2013.
- [34] L. P. Kaelbling, M. L. Littman, and A. R. Cassandra, “Planning and acting in partially observable stochastic domains,” *Artificial intelligence*, vol.101, no.1-2, pp.99–134, 1998.
- [35] Y. Du *et al.*, “Scalability and robustness of deep reinforcement learning in large discrete action spaces,” *IEEE Transactions on Neural Networks and Learning Systems*, 2023.

- [36] C. Kinneer *et al.*, “Building reusable repertoires for stochastic self-* planners,” in *2020 IEEE International Conference on Autonomic Computing and Self-Organizing Systems (ACSOS)*, IEEE, 2020.
- [37] T. Chen *et al.*, “Femosaa: Feature-guided and knee-driven multi-objective optimization for self-adaptive software,” *ACM Transactions on Software Engineering and Methodology*, vol.27, no.2, 2018.
- [38] J. Cámara, H. Muccini, and K. Vaidhyanathan, “Quantitative verification-aided machine learning: A tandem approach for architecting self-adaptive iot systems,” in *2020 IEEE International Conference on Software Architecture (ICSA)*, IEEE, 2020.
- [39] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward shaping: Theory and application to relation preservation,” in *ICML*, vol.99, pp.278–287, 1999.
- [40] R. Calinescu, C. Ghezzi, M. Kwiatkowska, and R. Mirandola, “Formal verification of self-adaptive software systems at runtime,” *Journal of Systems and Software*, vol.84, no.12, pp.2223–2239, 2011.
- [41] D. Weyns, M. U. Iftikhar, *et al.*, “Activforms: Active formal models for self-adaptation,” *ACM Transactions on Autonomous and Adaptive Systems (TAAS)*, vol.13, no.3, pp.1–41, 2018.
- [42] T. P. Lillicrap *et al.*, “Continuous control with deep reinforcement learning,” *arXiv preprint arXiv:1509.02971*, 2015.
- [43] H. Hansson and B. Jonsson, “A logic for reasoning about time and probability,” *Formal aspects of computing*, vol.6, no.5, pp.512–535, 1994.
- [44] W. Hoeffding, “Probability inequalities for sums of bounded random variables,” *Journal of the American Statistical Association*, vol.58, no.301, pp.13–30, 1963.
- [45] D. Weyns *et al.*, “Deep learning for effective and efficient reduction of large adaptation spaces in self-adaptive systems,” *ACM Transactions on Autonomous and Adaptive Systems (TAAS)*, vol.17, no.1-2, pp.1–42, 2022.
- [46] G. Blair, N. Bencomo, and R. B. France, “Models at run.time,” *Computer*, vol.42, no.10, pp.22–27, 2009.
- [47] M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. D. Cola, T. Deleu, M. Goulão, A. Kallinteris, M. Krimmel, A. KG, R. Perez-Vicente, A. Pierré, S. Schulhoff, J. J. Tai, H. Tan, and O. G. Younis, “Gymnasium: A standard interface for reinforcement learning environments,” 2024.

- [48] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, “Stable-baselines3: Reliable reinforcement learning implementations,” *Journal of Machine Learning Research*, vol.22, no.268, pp.1–8, 2021.
- [49] A. P. Field. *Discovering Statistics Using IBM SPSS Statistics*. London: Sage Publications, 5 ed. , 2017.
- [50] G. Casella and R. L. Berger. *Statistical inference*. Duxbury, 2002.
- [51] B. Efron and R. J. Tibshirani. *An introduction to the bootstrap*. CRC press, 1993.

پیوست آ

جریان‌های کاری کامل فرآیند

پیوست ب

لیست کامل الگوریتم‌ها

پیوست پ

نتایج تجربی گسترده

پیوست

مصنوعات پیاده‌سازی و پکیج بازتولید

Abstract:

Contemporary software systems increasingly operate in dynamic environments characterized by significant uncertainties, such as network interference and traffic fluctuations, which can jeopardize Quality of Service (QoS) objectives. Self-adaptive systems (SAS) provide a fundamental approach to address these challenges using feedback loops. However, managing large and discrete adaptation spaces (comprising hundreds or thousands of configurations) remains a significant challenge. Existing approaches, including machine learning and classical reinforcement learning, often suffer from poor scalability, reliance on labeled data, or being trapped in local optima under environmental shifts. This thesis proposes and evaluates a novel method called Randomized Reward-Shaped Deep Reinforcement Learning (RS-DRL) for efficient uncertainty management in SAS. The proposed method integrates a Deep Q-Network (DQN) core within the standard MAPE-K control loop. The primary innovation is the “Randomized Reward Shaping” mechanism, which strategically redesigns a random subset of failed past experiences in the replay buffer with optimistic (pseudo-success) rewards. Crucially, the reward signal is gated by formal verification results from UPPAAL-SMC, ensuring that learning is guided by formal safety and quality constraints. While the formal model requires domain-specific configuration, the randomized shaping heuristic itself is domain-agnostic and does not require explicit goal coordinates or intensive domain expertise for exploration. Experimental evaluation was conducted on the DeltaIoT exemplar within wireless sensor network scenarios featuring adaptation spaces of up to 4096 configurations. The results demonstrate that RS-DRL significantly outperforms state-of-the-art baselines, including DQN, HER, Soft HER, and DLASER+. Specifically, under the Threshold-based (TT) goal, RS-DRL achieved a 23.22% reduction in packet loss and a 39.07% reduction in latency compared to the DLASER+ baseline. Statistical analysis confirms the robustness and scalability of the proposed approach, establishing RS-DRL as a resilient optimization strategy for next-generation complex self-adaptive systems.

Keywords: Self-Adaptive Systems, Deep Reinforcement Learning, Randomized Reward Shaping, Uncertainty Management, Formal Verification, UPPAAL-SMC



Tarbiat Modares University
Faculty of Electrical and Computer Engineering

Randomized Reward-Shaped Deep Reinforcement Learning for Managing Uncertainty in Self-Adaptive Systems

**A Thesis Submitted in Partial Fulfillment of the Requirement for the Degree
of Doctor of Philosophy in Computer Engineering**

By:
Alireza Kavianifar

Supervisor:

Dr. ...

Advisor:

Dr. ...

February 2026