



دانشگاه تربیت مدرس

دانشکده مهندسی برق و کامپیوتر

رساله دکتری در رشته مهندسی کامپیوتر

گرایش نرم افزار

یادگیری تقویتی عمیق با شکل دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم های خودوفقی

علیرضا کاویانی فر

استاد راهنما

دکتر ...

استاد مشاور

دکتر ...

بهمن ۱۴۰۴



تأییدیهی هیأت داوران جلسهی دفاع از رساله

خانم / آقای علیرضا کاویانی فر رساله — واحدی خود را با عنوان یادگیری تقویتی عمیق با شکل دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم های خودوفقی در تاریخ بهمن ۱۴۰۴ ارائه کردند. اعضای هیات داوران نسخه نهایی این رساله را از نظر فرم و محتوا تایید کرده است و پذیرش آنرا برای تکمیل درجه دکتری پیشنهاد می کنند.

آیین نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهشهای علمی دانشگاه تربیت مدرس

مقدمه: با عنایت به سیاست‌های پژوهشی و فناوری دانشگاه در راستای تحقق عدالت و کرامت انسانها که لازمه شکوفایی علمی و فنی است و رعایت حقوق مادی و معنوی دانشگاه و پژوهشگران، لازم است اعضای هیأت علمی، دانشجویان، دانش‌آموختگان و دیگر همکاران طرح، در مورد نتایج پژوهشهای علمی که تحت عناوین پایان‌نامه، رساله و طرحهای تحقیقاتی با هماهنگی دانشگاه انجام شده است، موارد زیر را رعایت نمایند:

ماده ۱- حق نشر و تکثیر پایان‌نامه/ رساله و درآمدهای حاصل از آنها متعلق به دانشگاه می باشد ولی حقوق معنوی پدید آورندگان محفوظ خواهد بود.

ماده ۲- انتشار مقاله یا مقالات مستخرج از پایان‌نامه/ رساله به صورت چاپ در نشریات علمی و یا ارائه در مجامع علمی باید به نام دانشگاه بوده و با تایید استاد راهنمای اصلی، یکی از اساتید راهنما، مشاور و یا دانشجو مسئول مکاتبات مقاله باشد. ولی مسئولیت علمی مقاله مستخرج از پایان‌نامه و رساله به عهده اساتید راهنما و دانشجو می باشد. تبصره: در مقالاتی که پس از دانش‌آموختگی بصورت ترکیبی از اطلاعات جدید و نتایج حاصل از پایان‌نامه/ رساله نیز منتشر می شود نیز باید نام دانشگاه درج شود.

ماده ۳- انتشار کتاب، نرم افزار و یا آثار ویژه (اثری هنری مانند فیلم، عکس، نقاشی و نمایشنامه) حاصل از نتایج پایان‌نامه/ رساله و تمامی طرحهای تحقیقاتی کلیه واحدهای دانشگاه اعم از دانشکده ها، مراکز تحقیقاتی، پژوهشکده ها، پارک علم و فناوری و دیگر واحدها باید با مجوز کتبی صادره از معاونت پژوهشی دانشگاه و براساس آئین نامه های مصوب انجام شود.

ماده ۴- ثبت اختراع و تدوین دانش فنی و یا ارائه یافته ها در جشنواره های ملی، منطقه ای و بین المللی که حاصل نتایج مستخرج از پایان‌نامه/ رساله و تمامی طرحهای تحقیقاتی دانشگاه باید با هماهنگی استاد راهنما یا مجری طرح از طریق معاونت پژوهشی دانشگاه انجام گیرد.

ماده ۵- این آیین نامه در ۵ ماده و یک تبصره در تاریخ ۸۷/۴/۱ در شورای پژوهشی و در تاریخ ۸۷/۴/۲۳ در هیأت رئیسه دانشگاه به تایید رسید و در جلسه مورخ ۸۷/۷/۱۵ شورای دانشگاه به تصویب رسیده و از تاریخ تصویب در شورای دانشگاه لازم الاجرا است.

اینجانب علیرضا کاویانی فر به شماره دانشجویی ... دانشجوی رشته مهندسی کامپیوتر مقطع تحصیلی دکتری دانشکده مهندسی برق و کامپیوتر متعهد می شوم کلیه نکات مندرج در آئین نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهش های علمی دانشگاه تربیت مدرس را در انتشار یافته های علمی مستخرج از

پ

پایان نامه / رساله تحصیلی خود رعایت نمایم. در صورت تخلف از مفاد آئین نامه فوق الاشعار به دانشگاه وکالت و نمایندگی می دهم که از طرف اینجانب نسبت به لغو امتیاز اختراع بنام بنده و یا هر گونه امتیاز دیگر و تغییر آن به نام دانشگاه اقدام نماید. ضمناً نسبت به جبران فوری ضرر و زیان حاصله بر اساس برآورد دانشگاه اقدام خواهم نمود و بدینوسیله حق هر گونه اعتراض را از خود سلب نمودم»

تاریخ و امضا:

آیین نامه چاپ پایان نامه (رساله) های دانشجویان دانشگاه تربیت

مدرس

نظر به اینکه چاپ و انتشار پایان نامه (رساله) های تحصیلی دانشجویان دانشگاه تربیت مدرس، مبین بخشی از فعالیتهای علمی - پژوهشی دانشگاه است بنابراین به منظور آگاهی و رعایت حقوق دانشگاه، دانش آموختگان این دانشگاه نسبت به رعایت موارد ذیل متعهد می شوند: ماده ۱: در صورت اقدام به چاپ پایان نامه (رساله) ی خود، مراتب را قبلاً به طور کتبی به «دفتر نشر آثار علمی» دانشگاه اطلاع دهد. ماده ۲: در صفحه سوم کتاب (پس از برگ شناسنامه) عبارت ذیل را چاپ کند: «کتاب حاضر، حاصل پایان نامه کارشناسی ارشد/ رساله دکتری نگارنده در رشته مهندسی کامپیوتر است که در بهمن ۱۴۰۴ در دانشکده مهندسی برق و کامپیوتر دانشگاه تربیت مدرس به راهنمایی سرکار خانم/جناب آقای دکتر ...، مشاوره سرکار خانم/جناب آقای دکتر ... از آن دفاع شده است.» ماده ۳: به منظور جبران بخشی از هزینه های انتشارات دانشگاه، تعداد یک درصد شمارگان کتاب (در هر نوبت چاپ) را به «دفتر نشر آثار علمی» دانشگاه اهدا کند. دانشگاه می تواند مازاد نیاز خود را به نفع مرکز نشر در معرض فروش قرار دهد. ماده ۴: در صورت عدم رعایت ماده ۳، ۵۰٪ بهای شمارگان چاپ شده را به عنوان خسارت به دانشگاه تربیت مدرس، تأدیه کند. ماده ۵: دانشجو تعهد و قبول می کند در صورت خودداری از پرداخت بهای خسارت، دانشگاه می تواند خسارت مذکور را از طریق مراجع قضایی مطالبه و وصول کند؛ به علاوه به دانشگاه حق می دهد به منظور استیفای حقوق خود، از طریق دادگاه، معادل وجه مذکور در ماده ۴ را از محل توقیف کتابهای عرضه شده نگارنده برای فروش، تأمین نماید. ماده ۶: اینجانب علیرضا کاویانی فر دانشجوی رشته مهندسی کامپیوتر مقطع دکتری تعهد فوق و ضمانت اجرایی آن را قبول کرده، به آن ملتزم می شوم.

استاد راهنما: دکتر ...

تاریخ:

امضا:

تقديم

(متن تقديم به خانواده، اساتيد و ...)

قدردانی

(متن تشکر و قدردانی از اساتید راهنما، مشاور و دوستان)

علیرضا کاویانی فر

بهمن ۱۴۰۴

چکیده

(خلاصه‌ای از چالش، راهکار و نتایج کلیدی در ۳۰۰ تا ۵۰۰ کلمه)

واژگان کلیدی: سیستم‌های خودوفقی، یادگیری تقویتی عمیق، شکل‌دهی پاداش، عدم قطعیت

فهرست مطالب

فهرست جداول

فهرست تصاویر

فهرست علائم و اختصارات

(لیست نمادهای ریاضی مانند ρ ، γ و اختصارات مانند DRL، SAS)

فصل ۱

مقدمه

۱-۱ مقدمه

در حوزه مهندسی سیستم‌های نرم‌افزاری معاصر، پیچیدگی به عنوان یکی از بارزترین ویژگی‌ها خودنمایی می‌کند. محیط عملیاتی پویا نقش محوری در شکل‌دهی به این پیچیدگی ایفا کرده و سیستم‌ها را مجبور می‌سازد تا با شرایط نامشخصی که معمولاً تنها پس از عملیاتی شدن بروز می‌کنند، دست و پنجه نرم کنند. علاوه بر این، چالش‌ها و منابع عدم قطعیت در سیستم‌های مختلف به شکل‌های گوناگونی نمود پیدا می‌کنند. به عنوان مثال، در سیستم‌های مستقر در محیط‌های پویا نظیر برنامه‌های اینترنت اشیا (IoT) در شهرهای هوشمند، تغییرات آب و هوایی تأثیر قابل توجهی می‌گذارد. همچنین محیط‌های ابری با تقاضای منابع متغیر، امنیت سایبری با تهدیدات نوظهور و مداوم، تجارت الکترونیک و شبکه‌های اجتماعی با رفتار غیرقابل پیش‌بینی کاربران، و سیستم‌های توزیع‌شده با تأخیر شبکه، خرابی سخت‌افزار و تغییرات زیرساختی روبه‌رو هستند.

سیستم‌های سنتی ایستا یا مبتنی بر قواعد، انعطاف‌پذیری لازم برای پاسخ به چنین تغییراتی در زمان اجرا را ندارند. در مقابل، سیستم‌های خودوقتی (SAS) مجهز به حلقه‌های بازخوردی هستند که به آن‌ها اجازه می‌دهد تا محیط و وضعیت خود سیستم را پایش کنند، انحرافات از رفتار مورد انتظار را تحلیل نمایند و به طور خودمختار استراتژی‌ها و تغییرات وقتی را برنامه‌ریزی و اجرا کنند.

هنگامی که سیستم با یک فضای وقتی و گزینه‌های تغییر بسیار گسترده مواجه می‌شود، وظیفه انتخاب یک گزینه وقتی که با اهداف سیستم همسو باشد، از نظر محاسباتی بسیار پرهزینه و دشوار، و در برخی موارد تقریباً غیرممکن می‌گردد. تمرکز این رساله بر سیستم‌هایی است که دارای فضای وقتی گسترده و بزرگ هستند و نیاز فوری به راهکارهای کارآمد جهت انتخاب گزینه‌های بهینه در زمان اجرا دارند.

۱-۲-۱ بیان مسئله و سوالات تحقیق

۱-۲-۱ مسئله تحقیق

روش‌های موجود برای مدیریت عدم قطعیت در سیستم‌های خودوفقی با محدودیت‌های قابل توجهی روبه‌رو هستند. به عنوان مثال، روش‌های مبتنی بر یادگیری ماشین نیازمند داده‌های آموزشی برجسته‌دار هستند که نمایانگر محیط سیستم باشند؛ به دست آوردن چنین داده‌هایی در زمان طراحی به دلیل عدم قطعیت فراوان بسیار دشوار است. از طرفی، روش‌های مبتنی بر جستجو (مانند الگوریتم‌های صعود تپه و الگوریتم‌های ژنتیک) با مشکلات مقیاس‌پذیری مواجه هستند و عملکرد آن‌ها با تغییر شرایط محیطی دچار افت محسوس می‌شود. یادگیری تقویتی عمیق (DRL) اگرچه ابزاری قدرتمند است، اما خود با چالش‌های اساسی مانند گیر افتادن در بهینه‌های محلی مواجه می‌باشد. بهینه‌های محلی به راه‌حل‌هایی اشاره دارند که تنها در یک منطقه محدود از فضای مسئله بهینه هستند و به صورت سراسری بهترین راه‌حل ممکن محسوب نمی‌شوند. در زمینه DRL، این بدان معناست که مدل ممکن است سیاستی را یاد بگیرد که تحت شرایط خاص به خوبی عملکرد مناسبی دارد، اما در صورت تغییر محیط قادر به تعمیم‌پذیری و حفظ عملکرد مطلوب نیست.

علاوه بر این، آموزش مجدد یا بازآموزی (Retraining) مدل در زمان اجرا فرآیندی پرهزینه است. بازآموزی شامل مراحل متعددی مانند جمع‌آوری داده‌های جدید، ارزیابی مجدد ساختار و پارامترهای مدل، و تست مدل به‌روزشده برای اطمینان از عملکرد بهتر آن نسبت به نسخه قبلی است. در طول این فرآیند، سیستم ممکن است به صورت غیربهینه عمل کند که در سیستم‌های حیاتی، این دوره عملکرد نامطلوب می‌تواند پیامدهای جبران‌ناپذیری به همراه داشته باشد.

بیان اصلی و خلاصه‌شده مسئله: ماهیت پویا و غیرقابل پیش‌بینی محیط‌هایی که سیستم‌های نرم‌افزاری در آن‌ها عمل می‌کنند، چالش‌های قابل توجهی را برای مدل‌های سنتی یادگیری تقویتی عمیق به وجود می‌آورد. این مدل‌ها به طور مکرر با مشکل بهینه‌های محلی دست و پنجه نرم کرده و نمی‌توانند در زمان مواجهه با شرایط متغیر به خوبی عملکرد خود را تعمیم دهند که این امر منجر به عملکرد نامطلوب سیستم و نیاز به بازآموزی‌های مکرر و زمان‌بر خواهد شد.

۱-۲-۲ سوالات تحقیق

با توجه به چالش‌ها و خلاءهای تحقیقاتی مطرح شده و بر اساس دستاوردهای مقاله پیشین [۹]، این رساله به دنبال پاسخگویی به سوالات اصلی زیر است:

۱. سوال اول: چگونه می‌توان یک روش مبتنی بر یادگیری تقویتی عمیق طراحی کرد که به طور موثری از

- بهبهینه‌های محلی در محیط‌های پویا، بدون نیاز به بازآموزی مکرر، فرار کند؟
۲. سوال دوم: چگونه می‌توان مکانیزم‌های شکل‌دهی پاداش (Reward Shaping) را با بازپخش تجربه (Experience Replay) ادغام کرد تا تعمیم‌پذیری سیستم در تغییرات شرایط محیطی بهبود یابد؟
۳. سوال سوم: چگونه روش پیشنهادی می‌تواند فضاهای افقی گسسته و بزرگ (از ۲۱۶ تا ۴۰۹۶ گزینه) را در حین حفظ عملکرد نزدیک به بهینه، به شکل کارآمدی مدیریت کند؟
۴. سوال چهارم: تا چه حد روش پیشنهادی (RS-DRL) از روش‌های موجود نظیر یادگیری ای‌گرایانه حریصانه (ϵ -greedy DQN)، DLASER و ML4EAS از منظر عملکرد مجانبی، سرعت همگرایی، و بهینه‌سازی چندهدفه، برتری و عملکرد بهتری از خود نشان می‌دهد؟

۳-۱ اهداف رساله

این رساله اهداف کلان و خرد زیر را در راستای توسعه تحقیقات پیشین [۱] دنبال می‌کند:

۱. طراحی و توسعه: طراحی یک معماری نوآورانه یادگیری تقویتی عمیق با شکل‌دهی پاداش تصادفی (RS-DRL) که به شکل یکپارچه‌ای با حلقه خودمختار MAPE-K در سیستم‌های خودوفقی ادغام شده باشد.
۲. نوآوری الگوریتمی: توسعه یک مکانیزم نوین شکل‌دهی پاداش که تجربیات ناموفق را در طول فرآیند بازپخش حافظه به صورت تصادفی بازطراحی می‌نماید تا اکتشاف (Exploration) را ترویج کرده و از همگرایی مدل در بهینه‌های محلی جلوگیری کند.
۳. مدل‌سازی صوری: مدل‌سازی صوری مسئله کنترل و وفقی‌سازی تحت عدم قطعیت که شامل فضای حالت (نظیر سطح انرژی، از دست رفتن بسته‌های شبکه، زمان تأخیر)، فضای عمل (گزینه‌های افقی گسسته) و توابع پاداش جهت بهینه‌سازی‌های تک‌هدفه و چندهدفه است.
۴. ارزیابی تجربی: ارزیابی راهکار توسعه‌یافته RS-DRL در تقابل با روش‌های پیشرفته‌ی فعلی (مانند Soft HER، HER، ϵ -greedy DQN، DLASER و ML4EAS) بر روی مطالعات موردی سیستم DeltaIoT با اندازه‌های مختلف از فضاهای تطبیق (از جمله ۲۱۶، ۱۲۹۶ و ۴۰۹۶ گزینه ممکن).
۵. تحلیل‌های آماری: ارائه ارزیابی‌های آماری دقیق (تست مستقل t-test، مقادیر p-value و فاصله‌های اطمینان) برای تصدیق برتری روش پیشنهادی.

۱-۴ نوآوری‌های رساله

۱-۴-۱ نوآوری اول: ارائه الگوریتم یادگیری تقویتی عمیق با شکل دهی تصادفی پاداش

(RS-DRL)

برخلاف بازپخش تجربه سنتی در یادگیری تقویتی، الگوریتم پیشنهاد شده در این رساله (RS-DRL) برخی از تجربیات ناموفق گذشته را بازطراحی کرده و با اعطای پاداش مثبت به آن‌ها (همانند پاداش‌های موفقیت)، فرآیند یادگیری انسانی از اشتباهات گذشته خود را شبیه‌سازی می‌کند. مکانیزم انتخاب تصادفی تجربیات ناموفق که به وسیله فاکتور شکل‌دهی ρ کنترل می‌شود، تجربیات مردود سیستم را با تخصیص پاداش خوش‌بینانه (به عنوان مثال تخصیص $1 \leftarrow r_i$) شبیه‌سازی موفقیت می‌نماید. این ترفند برای محیط‌های متنوع نیازی به تعاریف تخصصی و دانش دامنه خاص ندارد و موجب می‌شود تا: ۱) تعمیم‌پذیری را در طول محیط‌های متنوع تشویق نماید و ۲) فرآیند یادگیری را از طریق تبدیل اشتباهات گذشته به درس‌های با ارزش در تجربه‌های بعدی، به شدت تسریع کند. در مقایسه با روش‌هایی نظیر بازپخش تجربه با نگاه به گذشته (HER) و Soft HER که ملزم به داشتن دانش دامنه‌ای و داشتن هدف صریح برای برچسب‌زنی مجدد اهداف (Goal Relabeling) هستند، رویکرد ما در RS-DRL از استراتژی پاداش تصادفی و خوش‌بینانه و کاملاً مستقل از دانش حوزه‌ای بهره می‌برد.

۱-۴-۲ نوآوری دوم: یکپارچه‌سازی RS-DRL با معماری خودوفقی MAPE-K

نوآوری استراتژیک دیگر، ارائه چارچوب معماری تلفیقی شامل سیستم مدیریتی و سیستم مدیریت‌شونده است. معماری پیشنهادشده که با حلقه کنترل و بازخورد MAPE-K ادغام شده است، شامل چرخه ارزیابی و انتخاب ۹ مرحله‌ای در تعامل بین مؤلفه‌های مختلف آن در زمان اجرا خواهد بود. این اجزای کلیدی شامل مازول استخراج‌کننده ویژگی از داده‌های سنسورها، انتخابگر فضای گزینه (ε-greedy DQN)، تاییدکننده گزینه وفقی از طریق اعتبارسنجی مدل با موتور UPPAAL-SMC، محاسبه‌گر پاداش، حافظه بازپخش با در نظر گرفتن مکانیزم بدیع شکل‌دهی پاداش و مؤلفه آموزش مدل می‌باشد.

۱-۴-۳ نوآوری سوم: مدیریت موثر عدم قطعیت در فضاهای وفقی بزرگ و گسسته

به عنوان یک نوآوری اساسی در سطح ارزیابی و دستاوردهای سیستم، این راهکار نشان داده که پتانسیل چشم‌گیری در مدیریت و راهبری سیستم‌های با مقیاس‌پذیری فضاهای حالت و فضای عمل بالا، مانند شبکه‌های گسترده اینترنت اشیاء داراست. کاربرست رویکرد RS-DRL در پلتفرم DeltaIoT از طریق کاهش

چشم‌گیر هدررفت داده‌ها تا محدوده ۲۳.۲۲٪ نسبت به رقبای سرسختی مانند DLASER+ و بهبود ۰۷.۳۹ درصدی زمان تأخیر انتقال در شبکه، قابل توجه است. استفاده از فضای گسسته و فقی مقیاس‌پذیر در محیط‌های آزمایشگاهی شامل نسخه‌ی DeltaIoTv1 با ۲۱۶ گزینه، نسخه‌ی DeltaIoTv1.1 شامل ۱۲۹۶ گزینه و نسخه‌ی DeltaIoTv2 شامل ۴۰۹۶ حالت ممکن، کارایی و میزان پاداش مجانبی بهبود یافته و پایداری را نسبت به روش‌های پیشین نشان می‌دهد.

۱-۵ مروری بر فصول رساله

ساختار رساله به گونه‌ای طراحی شده است که به طور نظام‌مند روند توسعه، اجرا و ارزیابی رویکرد پیشنهادی را در اختیار خواننده قرار دهد. در ادامه، مرور خلاصه‌ای از هر یک از فصول آورده شده است:

فصل ۲: مبانی و پیشینه تحقیق

مفاهیم بنیادی مربوط به سیستم‌های خودوفقی، چالش‌های عدم قطعیت و مبانی مدل‌سازی آن در زمان اجرا، اصول سیستم‌های یادگیری تقویتی (MDP، یادگیری Q و DRL (به ویژه الگوریتم‌های DQN) به تفصیل شرح داده می‌شود. سپس کارهای مرتبط پیشین در مدیریت فضاها بزرگ تطبیق، از روش‌های مبتنی بر یادگیری ماشین نظیر ML4EAS گرفته تا الگوریتم‌های اکتشافی جستجو و سایر روش‌های نوین مورد بررسی و ارزیابی قرار می‌گیرند.

فصل ۳: مدل سیستم و فرمول‌بندی مسئله

در این فصل، سیستم شبکه‌ی سنسورهای اینترنت اشیاء (DeltaIoT) به عنوان مطالعه‌ی موردی انگیزشی معرفی می‌شود. فضای حالت صوری شبکه شامل مفاهیمی پیرامون مصرف انرژی، از دست‌رفتگی بسته‌های داده و زمان تأخیر ($S = \{\text{Energy, Packet Loss, Latency}\}$) فرمول‌بندی شده و در ادامه، گزینه‌های فضای اعمال گسسته نیز مشخص و تدوین می‌گردد. در نهایت، توابع پاداش مربوط به سناریوهای بهینه‌سازی چندهدفه و تک‌هدفه به صورت ریاضی ارائه می‌شوند.

فصل ۴: روش پیشنهادی RS-DRL: معماری و الگوریتم

مرکز ثقل این رساله در این فصل واقع شده است که در آن، معماری پیشنهادی یکپارچه با کنترل‌کننده‌ی MAPE-K تبیین می‌گردد. الگوریتم پایه (RS-DRL)، به انضمام جزئیات دقیق مکانیزم شکل‌دهی پاداش‌های تصادفی با جزئیات الگوریتمی تشریح گردیده و پیاده‌سازی‌های مرتبط با اعتبارسنجی استراتژی‌های اجرایی پیش از پیاده‌سازی نهایی تغییرات توسط نرم‌افزار UPPAAL-SMC، برای تضمین پایداری سیستم، بحث و بررسی می‌شوند.

فصل ۵: ارزیابی تجربی

نحوه تخصیص محیط شبیه‌سازی، سناریوهای متعدد پیکربندی شبکه، و پروتکل‌های مقایسه‌ی جامع مدل RS-DRL با استراتژی‌های به‌روز رقیب نظیر ϵ -Greedy DQN، HER، Soft HER، DLASER، و ML4EAS در این فصل ارائه می‌گردد. ارائه‌ی شفاف معیارهای کلیدی دستاوردها شامل بررسی میزان ظرفیت عملکرد مجانبی سیستم، ارزیابی زمان مورد نیاز تقریبی برای رسیدن به آستانه قابل اتکا، و در نهایت کل مقادیر پاداش دریافتی در هر دوره‌ی آزمایش همراه با تأییدیه‌های تحلیل آماری و علمی مستند می‌باشند.

فصل ۶: بحث، کارهای آینده و نتیجه‌گیری

استلزامات نظری مرتبط با علت تفوقِ راهکار پیشنهادی بازبینی گردیده و کارایی مکانیزم از زوایای پراتیک صنعتی بحث می‌شود. در ادامه‌ی این فصل، به بررسی مصالحه‌ها، محدودیت‌ها و چالش‌های باقی‌مانده‌ی این معماری پرداخته شده و در نهایت، مسیرها و چارچوب‌هایی الهام‌بخش جهت بسط رویکرد فعلی در سیستم‌های پیوسته‌ی سایبرفیزیکی آینده پیشنهاد می‌گردد. فصل با نتیجه‌گیری کلی پیرامون مزیت‌های کاربردی راهکار نوین برای سیستم‌های عملیاتی بسته خواهد شد.

فصل ۲

مبانی و پیشینه تحقیق

۱-۲ مقدمه

هدف این فصل، ایجاد و بسط یک چارچوب و زیربنای نظری مستحکم است تا خواننده را از مفاهیم سطح بالا به سمت درک دقیق شکاف تحقیقاتی که این رساله آن را پر می‌کند، هدایت نماید. سیستم‌های نرم‌افزاری مدرن همواره با عدم قطعیت‌های مداوم مواجه هستند و باید در زمان اجرا به طور پیوسته ساختار و رفتار خود را با شرایط در حال تغییر وفق دهند. این فصل در ابتدا اصول اولیه سیستم‌های خوددوفقی و مؤلفه‌های آن را تشریح می‌کند، سپس به نقش یادگیری تقویتی و محدودیت‌های روش‌های سنتی در مقابله با فضا‌های بزرگ تصمیم‌گیری می‌پردازد و در نهایت با مروری ساختاریافته بر ادبیات تحقیق، علت نیاز به راهکار نوین RS-DRL را اثبات می‌نماید.

۲-۲ مبانی سیستم‌های خوددوفقی

۱-۲-۲ مفاهیم اصلی و الگوهای معماری

سیستم‌های خوددوفقی (Self-Adaptive Systems) یک رویکرد برجسته و مؤثر برای مقابله با عدم قطعیت به شمار می‌روند. ایده کلیدی در این سیستم‌ها، تجهیز آن‌ها به یک یا چند حلقه بازخوردی کنترلی است که به صورت مداوم مؤلفه‌های داخلی سیستم و محیط خارجی آن را پایش کرده و در صورت نیاز سیستم را با تغییرات منطبق می‌نمایند [؟].

مهمترین و شناخته‌شده‌ترین الگوی معماری برای پیاده‌سازی این سیستم‌ها، حلقه خودمختار MAPE-K است. همان‌طور که در فصل‌های بعدی با جزئیات بیشتر بررسی خواهد شد، این حلقه در کنار سیستم هدف

و منطق کسب‌وکار، جریان کنترلی زیر را اعمال می‌کند:

- **پایش (Monitor):** سنسورها وضعیت محیط فیزیکی، زیرساخت و خود سیستم را به صورت زمان حقیقی استخراج می‌کنند.
- **تحلیل (Analyze):** داده‌های پایش شده را پردازش کرده و مشخص می‌کند که آیا انحرافی از اهداف کیفی و کمی سیستم رخ داده است و نیاز به اعمال تغییر وجود دارد یا خیر.
- **برنامه‌ریزی (Plan):** در صورت نیاز تطبیق، راهکارها و استراتژی‌های موجود (گزینه‌های وفقی) مقایسه شده و گزینه بهینه برای شرایط فعلی برگزیده می‌شود.
- **اجرا (Execute):** استراتژی برنامه‌ریزی شده در قالب یک سری از دستورات اجرایی از طریق عملگرها (Actuators) بر روی سیستم اعمال می‌گردد.
- **دانش (Knowledge):** به عنوان حافظه مرکزی عمل کرده و اطلاعات، مدل‌ها و داده‌های بین چهار مرحله قبلی را هماهنگ و نگهداری می‌کند. راهکار پیشنهادی ما (RS-DRL) مستقیماً به عنوان هسته اصلی بخش برنامه‌ریزی در این الگو فعالیت می‌کند.

۲-۲-۲ چالش‌های عدم قطعیت در زمان اجرا

عدم قطعیت در سیستم‌های خودوفقی، به هرگونه انحراف از دانش قطعی اطلاق می‌شود که می‌تواند باعث کاهش اطمینان نسبت به تصمیمات زمان اجرا گردد [۴].

به عنوان نمونه‌های عینی، می‌توان به موارد گوناگونی در دامنه‌های مختلف اشاره کرد: در برنامه‌های مبتنی بر اینترنت اشیاء (IoT) که در محیط‌های شهری پراکنده هستند، تغییرات مداوم و غیرقابل پیش‌بینی آب و هوا منجر به افت کیفیت سیگنال و اختلال در ارسال اطلاعات سنسورها می‌شود. در محیط‌های ابری، نوسان شدید در تقاضای منابع از سوی کاربران، و در حوزه‌های امنیتی، ظهور بی‌وقفه و تصادفی حملات سایبری از مصادیق برجسته عدم قطعیت هستند.

اهمیت و چالش برانگیز بودن عدم قطعیت از آنجا نشأت می‌گیرد که مفروضات، پیکربندی‌ها و تصمیمات در نظر گرفته شده در فاز طراحی معماری نرم‌افزار را بی‌اعتبار می‌سازد. در نتیجه، سیستم باید قادر باشد با یادگیری آنلاین و پویا در زمان اجرا، اهداف اصلی خود را محقق نماید؛ وگرنه با نقض کیفیت خدمات خدمات سنگین احتمالی را تجربه خواهد نمود.

۲-۳ مدل سازی عدم قطعیت

۲-۳-۱ منابع عدم قطعیت

منابع عدم قطعیت به طور کلی در سه دسته وسیع طبقه بندی می شوند: نخست، نامشخص بودن موجودیت های محیطی نظیر پارازیت در حسگرها، نویزها و تغییرات جوی که از کنترل ساختار درونی سیستم خارج هستند. دوم، ماهیت غیرقابل اتکای منابع خود سیستم مثل نقص در قطعات زیربنایی، کاهش سریع سطح باتری یا مشکلات نرم افزاری تعاملات میان سرویس ها؛ و در نهایت عدم قطعیت در اهداف متغیر و ترجیحات نامشخص ذینفعان در محیط های تجاری.

۲-۳-۲ رویکردهای مدل سازی عدم قطعیت

جهت درک و محاسبه رفتار سیستم در هنگام بروز مقادیر ناشناخته، استفاده از مدل سازی های زمان اجرا (Runtime Models) ضروری به نظر می رسد. در شرایطی که فضای جستجو بسیار بزرگ و ریسک تصمیم گیری به دلیل شرایط مبهم بالاست، رویکرد پیشنهادی از مکانیزم های مدل سازی ریاضی صوری بهره گیری و پشتیبانی می کند.

در این راستا ابزارهایی مانند موتور UPPAAL-SMC و چارچوب ActivFORMS به کار گرفته می شوند. این زیرساخت ها با استفاده از اتوماتای زمان دار (Timed Automata) مدلی رفتاری از سیستم هدف و محیط آن را توسعه داده و از طریق روش های کنترل مدل آماری (Statistical Model Checking) می توانند به سرعت گزینه های وفقی پیشنهاد شده توسط سیستم هوشمند را پیش از اجرا در سیستم فیزیکی ارزیابی، تایید یا رد کنند. این قابلیت نقشی کلیدی در امنیت راهکار پیشنهادی (در بخش تاییدگر گزینه وفقی) این رساله ایفا می کند.

۲-۴ یادگیری تقویتی برای وفقی سازی

۲-۴-۱ اصول یادگیری تقویتی (MDP، یادگیری Q)

یادگیری تقویتی از طریق تعامل مستمر یک عامل (Agent) با محیط اطرافش بر پایه آزمون و خطا بنا شده است و این محیط به لحاظ ریاضی از طریق فرآیند تصمیم گیری مارکوف (MDP) فرموله می شود. فرآیند MDP خود شامل فضای حالت (State)، فضای عمل (Action) و توابع پاداش (Reward) است. در فرآیند تصمیم گیری مارکوف، برای هر حالت خاص، عامل عمل مشخصی را اتخاذ می کند و مطابق

با معادله مشهور بلمن (Bellman Equation) محیط ارزش عمل اتخاذ شده را در قالب یک پاداش ارزیابی می‌نماید و به وضعیت بعدی منتقل می‌شود. این مفهوم در سیستم‌های خودوفقی مانند محیط DeltaIoT به این صورت اعمال می‌گردد که وضعیت سیستم با معیارهایی نظیر انرژی ذخیره شده سیستم و تاخیر اندازه‌گیری شده فضای حالت را تشکیل می‌دهند و اقدام عامل، همان گزینه وفقی مورد انتخاب خواهد بود و محاسبه پاداش نیز طبق معادله بهینه‌سازی سیستم حاصل می‌گردد. نقش الگوریتم مشهور یادگیری Q ایجاد جدولی جامع برای تخصیص و پیدا کردن ارزش‌هاست تا مدل به سیاست بهینه همگرا شود.

۲-۴-۲ یادگیری تقویتی عمیق (DQN) برای فضاهای بزرگ

اما زمانی که با سیستم‌های واقعی که دارای فضای عمل گسسته ولی بسیار پهناور (برای مثال ۴۰۹۶ گزینه وفقی در شبکه‌های اینترنت اشیا) مواجه هستیم، استفاده از متد کلاسیک یادگیری Q با چالش نفرین ابعاد (Curse of Dimensionality) روبه‌رو می‌شود؛ زیرا ذخیره و بروزرسانی جدولی با میلیون‌ها حالت و عمل از لحاظ محاسباتی ناکارآمد و در بسیاری موارد غیرممکن است.

شبکه‌های Q عمیق (DQN) راهکاری هوشمندانه برای این محدودیت ارائه می‌دهند؛ آن‌ها به جای جداول، تابع ارزش کیفیت Q را با استفاده از شبکه‌های عصبی عمیق تقریب می‌زنند. برای غلبه بر بی‌ثباتی آموزش شبکه‌های عصبی در RL، مدل DQN از دو نوآوری برجسته بهره می‌برد: نخست استفاده از مکانیسم حافظه بازپخش تجربه (Experience Replay) که نمونه‌های آموزشی تصادفی‌سازی شده و باعث شکستن همبستگی زمانی متوالی می‌گردد؛ و دوم تعبیه هدف ثابت به واسطه شبکه هدف ثابت (Target Network) که بهبود تثبیت توابع هزینه را در هنگام محاسبه پیش‌بینی‌ها به دنبال دارد.

۲-۴-۳ مفهوم یادگیری مداوم در حلقه‌های وفقی

اصلی‌ترین کاربرد این رساله، ادغام مفهوم آموزش پیوسته و مداوم توسط عامل DQN در چارچوب معماری خودوفقی و به طور خاص درون حلقه MAPE-K (همانطور که در فصل ۴ و شکل ۴ از مقاله [۹] به تفصیل نشان داده خواهد شد) است. پس از جاگذاری در مؤلفه برنامه‌ریزی (Planner)، عامل یادگیرنده وضعیتی را به عنوان ورودی فضای حالت از مازول پایش دریافت نموده، استراتژی اقدام را برنامه‌ریزی کرده و بر اساس میزان موفقیت انتخابش از سوی مؤلفه تحلیل پاداش می‌گیرد. این ساختار تعاملی، سیستم خودوفقی را از پیکربندی ایستا به ساختار یادگیری پویا تبدیل می‌سازد.

۵-۲ کارهای مرتبط: مدیریت فضاها و فقی بزرگ

دستیابی به کارایی مناسب در مدیریت محیط‌های مبهم بسیار کلیدی است. برای تبیین عمیق این مباحث، در ادامه به مقایسه انتقادی دسته‌بندی‌های موجود می‌پردازیم.

۱-۵-۲ روش‌های مبتنی بر یادگیری ماشین (ML-based Methods)

اولین دسته‌بندی کارهای مرتبط در به کارگیری یادگیری ماشین نظارت‌شده و پیش‌بینی‌کننده با هدف هرس و کاهش فضای جستجو متمرکز است. رویکرد محققانی چون کین (Quin) و همکارانش [۱۰، ۱۱] و مدل یادگیری برای ارزیابی کیفی ماشین (ML4EAS) توسعه یافته توسط کاجی و بواناکا [۱۲] نشان می‌دهند که الگوریتم‌های طبقه‌بندی و رگرسیون قادرند تعداد زیادی از گزینه‌های غیربهبه را تا پیش از ارسال به مؤلفه تحلیل‌گر، غربال کنند.

نقد رویکرد: اگرچه این روش‌ها در کاهش اندازه محیط عمل خود کارا هستند، اما وجود وابستگی بنیادین به مجموعه داده‌های با برچسب آموزش دیده، نقص متدولوژی است. تهیه مجموعه داده در زمان توسعه که همسان با متغیرهای غیرمترقبه واقعیت باشد غیرعملی است. متعاقباً با بروز رانش مفهومی (Concept Drift) ناشی از تغییر مداوم شرایط محیطی، این مدل‌های پیش‌آموزش دیده، عملکرد تعمیم یافته و کارآمد خود را در برخورد با رویه‌های ناشناخته از دست می‌دهند.

۲-۵-۲ روش‌های مبتنی بر جستجو (Search-based Methods)

متدولوژی کلاسیک دیگر برای پیمایش سریع فضاها و وسیع جستجو استفاده از راهبردهای اکتشافی است. برای مثال استفاده کوکر (Coker) از الگوریتم صعود تپه (Hill Climbing) [۱۳] و برنامه‌ریزی‌های مبتنی بر الگوریتم ژنتیک (Genetic Programming) که به قلمرو مقالات کینر (Kinneer) و همکاران اختصاص دارد [۱۴، ۱۵، ۱۶]. همچنین شبیه‌سازی جستجو با استفاده از رویکرد تکامل چند هدفه نظیر MOEA توسط چن (Chen) [۱۷]، از کاربردهای متداول است.

نقد رویکرد: هرچند ویژگی انطباق خودکار بدون آموزش در این رویکرد به چشم می‌خورد، اما چالش مقیاس‌پذیری، مانع استقرار کامل آن‌ها در پروژه‌های بلادرنگ است. اجرای مجدد جمعیت تکاملی همچون ژنتیک برای یافتن سناریوی مطلوب در پی هر گونه تطابق زمانی، مستلزم محاسبات بی‌نهایت پرهزینه و ایجاد تاخیر زیاد است؛ موضوعی که در شبکه‌های حساس تاخیرپذیر غیرقابل تحمل است.

۳-۵-۲ روش‌های مبتنی بر یادگیری تقویتی (RL-based Methods)

پیشرفت‌های حاصل شده در اتوماسیون برخط سیستم‌ها با کارهای کیم و پارک [۹]، متزگر [۹] و مدل RLMC توسط کامارا [۹] به دلیل تعامل بی‌وقفه پویایی‌های آنلاین شناخته شده است که عمدتاً براساس کلاسیک الگوریتم Q-Learning توسعه یافتند.

نقد رویکرد: الگوریتم کلاسیک در ابعاد بزرگ، همانند شبکه‌ای با میلیاردها ماتریس برای مدل‌سازی از پای در می‌آید و ناتوان از رسیدگی است. حتی تلاش‌هایی که با مدل پایه ارزیابی ما یعنی معماری حریصانه کلاسیک DQN با استراتژی ϵ -greedy صورت پذیرفته است، کماکان با مشکل شدید محدودیت روبه‌رو است؛ زیرا مدل پایه عامل هوشمندی را پرورش می‌دهد که اغلب در نقاط و قله‌های بهینه‌های محلی (Local Optima) متوقف شده، مانع قابلیت یافتن قله‌های اصلی (Global Optima) در دینامیک شرایط محیط می‌گردد.

۴-۵-۲ شکل‌دهی پاداش و بازپخش تجربه با نگاه به گذشته (Reward Shaping & HER)

(HER)

بازپخش تجربه‌های ناموفق از موضوعات بسیار داغ در حوزه هوش مصنوعی بوده که مکانیزم مشهور یادگیری با نگاه به گذشته (HER) [۹] و مدل متأخر با رویکرد پاداش نرم‌تر (Soft HER) [۹] با استفاده از استراتژی برچسب‌گذاری مجدد هدف برای تجربیات ناموفق توانسته یادگیری محیط‌ها را سریع‌تر نمایند.

نقد رویکرد انطباق با این حوزه: برتری این مدل‌های عمیق کاملاً محدود به طراحی‌های وابسته به هدف و صریح (Goal-Conditioned Environments) می‌باشد. به عبارت دیگر عامل باید یک مکان یا وضعیت شفاف (مانند موقعیت سه‌بعدی ابزار مکانیکی) را تصرف کند؛ در حالی که کنترل‌کننده‌های سیستم‌های خودوفقی اساساً و غالباً اهدافی به عنوان متغیر قطعی را دنبال نمی‌کنند، بلکه نگه‌داشتن انرژی یا تاخیر شبکه در حداقل‌ها یک سیاست آستانه‌محور است که با استراتژی تغییر برچسب و ارزیابی در بازتولید HER با سازگاری اساسی تناقض دارد.

۲-۶ سنتز و شناسایی شکاف تحقیقاتی

با استناد به مطالب شرح داده شده و مروری جامع در کاستی مقالات پیشین، درمی‌یابیم که هیچ‌یک از دسته‌بندی‌های فعلی قادر به برطرف ساختن کل چالش‌ها به صورت جامع نبوده‌اند: راهکارهای یادگیری ماشین به پدیده‌های پیش‌بینی‌نشده محیط به دلیل فقدان آموزش آفلاین به شدت حساس و شکننده‌اند؛ مسیرهای اکتشاف جستجو با تاخیر غیرقابل پذیرش روبرو می‌باشند. حتی اگر از رویکردهای DRL پایه بهره بگیریم،

مستعد توقیف در استثنائات محلی بوده و قابلیت فراگیری جامع در مقابل نوسانات متغیر محیطی را متجلی نمی‌کنند. علاوه بر این ابزارهای پیشرفته مانند تخصیص مقاصد بازپخش گذشته امکان استفاده‌ی کارآمد مبتنی بر اهداف نامشخص سیستم خودوفقی را دارا نیستند.

بر این اساس یک شکاف علمی و عملی مشخص برای ابداع چارچوبی مبرهن مطرح است که دارای ویژگی‌های زیر باشد: (۱) تسلط اثربخش در فضاها و وسیع و گسترده و فقی بدون استفاده از جداول سنتی مقیاس ناپذیر، (۲) فراگیری هوشمندانه برخط بدون اجبار استفاده از داده‌های آموزش دیده‌ی گذشته، (۳) مقابله سرسختانه با بهینه‌های محلی بدون از دست دادن همگرایی و افت در محیط تغییر یافته (نیاز به شکل‌دهی استراتژی آموزش)، و (۴) قابلیت پیوستگی با نیازهای غیرخطی یک سیستم خودوفقی بدون تغییر پارادایم تحمیلی به مسائلی متمرکز به تعیین هدف.

پیشنهاد بنیادی ما در این رساله مبتنی بر ایجاد یک مکانیزم جدید تلفیقی تحت عنوان یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) است تا خلأ یاد شده کاملاً پر گشته و گامی کاربردی جهت ارتقای استقلال عوامل کنترلی نرم‌افزارهای پیچیده میسر گردد.

۲-۷ خلاصه فصل

این فصل در آغاز، با ترسیم بنیان‌های نظری مفاهیم یک سیستم پایدار و مکانیزم MAPE-K و تشریح ماهیت مدل‌سازی عدم قطعیت با ساختار زمان‌اجرا بنا گردید. به تبع آن ضمن تشریح کارکردهای یادگیری تقویتی متدهای عمیق پیوستگی استراتژی پیشنهادی، محدوده‌های فعلی در مقابله با چالش مقیاس‌پذیری نمایان شد. در خاتمه، بر پایه ارزیابی تحلیلی در سابقه کارهای تحقیقاتی پیشین مشخص گردید، فقدان یک مکانیزم هوشمند برای شکل‌دهی تصادفی برخط کاملاً مشهود است که در فصل آتی با مدل سیستم و فرمول‌سازی مسئله پیش‌نیازهای ساخت آن تنظیم می‌گردد.

فصل ۳

مدل سیستم و فرمول بندی مسئله

۱-۳ مقدمه

برای توسعه یک راهکار مبتنی بر یادگیری تقویتی به منظور مدیریت عدم قطعیت در سیستم های خودوفقی، ابتدا باید یک مدل صوری از مسئله وفقی سازی (تطابق) بنا نهیم. این فصل، مدل سیستم و فرمول بندی ریاضیاتی که بستر رویکرد پیشنهادی ما (RS-DRL) را تشکیل می دهد، ارائه می نماید. ما با معرفی DeltaIoT - یک نمونه بارز از شبکه های حسگر بی سیم که چالش های کلیدی فضا های وفقی بزرگ و عدم قطعیت های محیطی را به صورت آشکار به نمایش می گذارد - بحث را آغاز می کنیم.

سپس مسئله وفقی سازی را به عنوان یک فرآیند تصمیم گیری مارکوف (MDP) فرمول بندی کرده و فضای حالت، فضای عمل و تابع پاداش را برای سناریو های بهینه سازی تک هدفه و چند هدفه تعریف می کنیم. نهایتاً، مسئله یادگیری یک سیاست وفقی بهینه را که می بایست در شرایط متغیر زمان اجرا و به طور مداوم عمل کند، به صورت صوری بیان می نماییم.

۲-۳ مطالعه موردی انگیزشی: سیستم DeltaIoT

۱-۲-۳ مرور کلی سیستم و منابع عدم قطعیت

سیستم DeltaIoT یک شبکه حسگر بی سیم (WSN) با تعاملات پیچیده است که به صورت گسترده به عنوان یک محک استاندارد (Benchmark) برای ارزیابی سیستم های خودوفقی به کار می رود [۹]. این شبکه بسته به نسخه مورد استفاده، مابین ۱۵ تا ۳۷ گره (سنسور) دارد. دو منبع اصلی عدم قطعیت در این سیستم در زمان اجرا بروز می یابند:

۱. نویز و تداخل شبکه (Network Interference/Noise): تغییرات محیطی و مداخلات پیرامونی که موجب نوسانات پیش‌بینی‌نشده در کیفیت ارتباطات از -40dB تا +15dB می‌گردد.

۲. تغییرپذیری بار پیام‌ها (Message Load Variability): نوسان در تعداد پیام‌های تولید شده توسط هر سنسور (بین ۰ تا ۱۰ پیام) با الگوهای انتقال متفاوت در طول زمان.

همانطور که در مطالعات پیشین (و روند نشان داده شده در شکل ۲ مقاله مرجع) نمایان است، این عدم قطعیت‌ها باعث شکل‌گیری افت شدید عملکرد سیستم در طی چرخه‌های وفقی گشته و اهمیت حیاتی مکانیسم‌های تطابق پویا را برجسته می‌کنند.

۲-۲-۳ فضای وفقی و بازنمایی پیکربندی

فضای وفقی (Adaptation Space) دربرگیرنده مجموعه تمامی گزینه‌ها و پیکربندی‌های ممکن است که سیستم می‌تواند در زمان اجرا اتخاذ نماید. در DeltaIoT، سه نسخه متفاوت با مشخصاتی به شرح زیر طراحی گردیده است [۹]:

- DeltaIoTv1: شامل ۱۵ سنسور و دارای ۲۱۶ گزینه وفقی متمایز.
- DeltaIoTv1.1: شامل ۱۶ سنسور و دربرگیرنده ۱۲۹۶ گزینه وفقی است.
- DeltaIoTv2: نسخه وسیع‌تر این شبکه متشکل از ۳۷ سنسور که دارای فضای عظیم متشکل از ۴۰۹۶ تصمیم ممکن می‌باشد.

هریک از این گزینه‌های وفقی در حقیقت ترکیبی از پارامترهای مختلف هستند؛ نظیر سطوح توان انتقال انرژی (Transmission Power) برای سنسورهای مشخص و توزیع نسبی مسیرهای شبکه‌ای (Link Distribution). انتخاب یک ترکیب از این پارامترها، یک پیکربندی کاملاً جدید و واحد را شکل می‌دهد.

۳-۳ مدل صوری برای تصمیم‌گیری خودوفقی تحت عدم قطعیت

برای امکان‌پذیر کردن یادگیری تقویتی، نیاز به فرمول‌بندی مسأله تطابق شبکه در قالب یک فرآیند تصمیم‌گیری مارکوف (MDP) داریم که نمایانگر چهارگانه (S, A, R, P) است [۹].

۱-۳-۳ تعریف فضای حالت

فضای حالت مدل، وضعیت فعلی و پویای سیستم را با اندازه‌گیری سه معیار حیاتی عملکرد بازتاب می‌دهد. به بیان رسمی:

$$S = \{(E, P, L) \mid E \in \mathbb{R}, P \in [0, 100], L \in [0, 100]\}$$

که در آن:

- انرژی مصرفی (E): مقدار حقیقی نمایانگر انرژی کل مصرفی توسط تمام سنسورهای شبکه در چرخه پیشین است.
- تلفات بسته‌های شبکه (P): درصدی از پیام‌های تولید شده که در طول مسیر به مقصد (دروازه اصلی) از دست رفته‌اند (بین ۰ تا ۱۰۰ درصد).
- تاخیر ارسال (L): معیاری معادل زمان مورد نیاز جهت رسیدن اطلاعات از سنسورها به گیت‌وی (حداکثر بازه ۱۰۰).

این سه متغیر مقداری به این دلیل انتخاب شده‌اند که تصویر کاملی از نیازمندی‌های کیفی (QoS) شبکه را در یک سیستم توزیع شده با منابع محدود ارائه کرده و ارزیابی صحیحی برای عامل تصمیم‌گیرنده (Agent) فراهم می‌کنند.

۲-۳-۳ فضای عمل: گزینه‌های وفقی گسسته

فضای عمل شامل تمامی استراتژی‌ها و پیکربندی‌های ممکن به صورت مجموعه‌ای از گزینه‌های گسسته تعریف می‌شود:

$$A = \{a_1, a_2, \dots, a_n\}$$

همان‌طور که پیش‌تر اشاره شد، مقدار n بسته به ابعاد شبکه DeltaIoT برابر با ۲۱۶، ۱۲۹۶ یا ۴۰۹۶ در نظر گرفته می‌شود. هر عمل a_i نمایانگر یک پیکربندی مشخص از پارامترهای $\{p_{i1}, p_{i2}, \dots, p_{im}\}$ است که در آن هر پارامتر p_{ij} می‌تواند از مجموعه مقادیر محدود $\{v_{ij1}, v_{ij2}, \dots, v_{ijk}\}$ تبعیت کند. این پارامترها در واقع توان ارسال سنسورها، توزیع لینک‌ها و مسیر یابی هر سنسور را تغییر می‌دهند.

۳-۳-۳ فرمول‌بندی تابع پاداش

محاسبه صحیح تابع پاداش برای هدایت سیستم به سمت مقاصد از پیش تعیین شده، عاملی کلیدی محسوب می‌شود. بر اساس ماهیت سیستم و اهداف، ممکن است با بهینه‌سازی‌های تک‌هدفه، چندهدفه و یا اهداف آستانه‌ای مواجه شویم.

۱-۳-۳-۳ فرمول‌بندی پاداش چندهدفه

برای متوازن‌سازی رفتار سیستم حین برخورد با اهداف متعارض در طول چرخه خودوفقی، یک تابع پاداش بهینه‌سازی چندهدفه ارائه می‌گردد:

$$R = w_E \cdot \left(\frac{E_{max} - E}{E_{max} - E_{min}} \right) + w_P \cdot \left(\frac{P_{max} - P}{P_{max} - P_{min}} \right) + w_L \cdot \left(\frac{L_{max} - L}{L_{max} - L_{min}} \right)$$

در این نگاشت، ضرایب وزن‌دهی ($w_E + w_P + w_L = 1$) میزان اهمیت هر هدف را نشان می‌دهند و هر ترم موجود با استفاده از کران‌های بالا و پایین هر معیار محدودیت‌ها را بین بازه $[0, 1]$ نرمال‌سازی می‌کند.

۲-۳-۳-۳ فرمول‌بندی پاداش تک‌هدفه

زمانی که اولویت طراحی تنها برای غلبه بر یک مشکل واحد تعریف گردیده (مانند بهینه‌سازی صرفاً مصرف انرژی)، تابع فوق بدین شکل ساده‌سازی می‌گردد:

$$R = \left(\frac{E_{max} - E}{E_{max} - E_{min}} \right) \cdot w_E$$

در این معادله بقیه وزن‌ها معادل صفر در نظر گرفته شده‌اند که سبب هدایت بدون واسطه سیستم برای ارتقای سریع ویژگی هدف‌گذاری شده می‌شود.

۳-۳-۳-۳ پارامترهای پاداش برای اهداف آستانه‌ای (TTS و TT)

برای مسائلی که نیازمند کنترل مطلق اهدافی در سطح استثنای کیفی قابل قبول (Thresholds) هستند (که در جدول ۲ مقاله با نام‌های TTS و TT نام برده شده‌اند)، تخصیص مقادیر پاداش مشروطی به صورت دودویی (Binary) اعمال می‌گردد:

$$R = \begin{cases} 1 & \text{اگر } P < \theta_P \text{ و } L < \theta_L \\ 0 & \text{در غیر این صورت} \end{cases}$$

که در آن مقادیر مرزی θ_P و θ_L به عنوان آستانه‌های از پیش تعیین شده معرفی شده‌اند. جدول ۱؟ خلاصه مقادیر TTS و TT (تنظیمات اهداف آستانه‌ای و ترکیبی) را پیرامون معماری این نسخه‌ها نمایش می‌دهد:

جدول ۱-۳: اهداف کیفی و آستانه‌ای (TTS و TT) سیستم DeltaIoT [۹]

نسخه DeltaIoT	تنظیمات هدف	تلفات بسته (Packet Loss)	تاخیر (Latency)	انرژی (Energy)
DeltaIoTv1	TTS	کمتر از ۱۰٪ (< ۱۰٪)	کمتر از ۵٪ (< ۵٪)	کمینه‌سازی
DeltaIoTv1	TT	کمتر از ۱۰٪ (< ۱۰٪)	-	کمینه‌سازی
DeltaIoTv2	TTS	کمتر از ۱۰٪ (< ۱۰٪)	کمتر از ۵٪ (< ۵٪)	کمینه‌سازی

۴-۳ بیان مسئله: یادگیری سیاست وفقی بهینه با عملیات مداوم در زمان

اجرا

با در نظر داشتن فرمول بندی MDP در نظر گرفته شده، مسئله نهایی ما یادگیری روال سیاست وفقی بهینه $\pi^* : S \rightarrow A$ است. انتظار سیستم از این سیاست به حداکثر رسانی ارزش پاداش‌های تجمعی تنزیل یافته (Cumulative Discounted Reward) است:

$$\pi^* = \arg \max_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid \pi \right]$$

در معادله فوق، مقدار $\gamma \in [0, 1)$ ضریب تنزیل را معرفی می‌نماید. عملکرد موثر این سیاست بهینه باید همواره به طور مداوم و لاینقطع در زمان اجرا عمل کند و مکرراً با چالش‌های زیر روبرو گردد:

۱. عدم قطعیت محیطی: بار متغیر پیام‌ها و همچنین تداخل‌های ناپایدار و اختلال متناوب خطوط.
۲. فضای عمل گسترده گسترده: مدیریت فضای مقیاس‌پذیری که بسته به نسخه شبکه می‌تواند تا سقف ۴۰۹۶ تصمیم ممکن وسیع باشد.
۳. پویایی غیرایستا (Non-stationary dynamics): نیاز به تطبیق مداوم و عدم کاهش سرعت واکنش به علت تغییرات شرایط از یک چرخه وفقی به چرخه بعدی (تخریب و کاهش عملکرد نشان داده شده در شکل ۲ مقاله مرجع).

۳-۵ خلاصه فصل

فرآیند صورت بندی و مدل سازی در این فصل، زمینه ساز توسعه راهکار عملی این رساله گشته است. ما در این بخش ابتدا مطالعه موردی سیستم DeltaIoT را شرح داده و ابعاد گوناگون فضای وقتی گسسته آن را تشریح نمودیم. در ادامه این مسأله با تمرکز به مدل تصمیم گیری مارکوف ساختاریافته شامل فضای وضعیت شبکه، اعمال تصمیم سازی و توابع پاداش های چندگانه برای بهینه سازی فرموله گردید.

تکمیل این چارچوب رسمی، قابلیت و ظرفیت یادگیری استراتژی های وقتی و منطبق با متد یادگیری تقویتی را فراهم می آورد. این پایه گذاری با اهمیت به ویژه به واسطه توصیف اهداف مشخص، در فصل آتی (به عنوان طراحی متد ابتکاری RS-DRL) زمینه ساز توسعه راهکار خروج از بهینه های محلی با بهره گیری از شکل دهی تصادفی پاداش برای مدیریت عدم قطعیت خواهد بود.

فصل ۴

روش پیشنهادی RS-DRL: معماری و الگوریتم

۴-۱ مقدمه

در فصل پیشین نشان دادیم که مدل‌های مرسوم یادگیری تقویتی، توانایی لازم برای پاسخ‌گویی به فضاهاى بسیار بزرگ و گسسته تطابق را در زمان اجرای سیستم‌های خودوقتی ندارند و رویکردهای موجود اغلب در قله‌های محلی (Local Optima) متوقف می‌شوند. همچنین آموزش مجدد مدل در زمان اجرا فرآیندی پرهزینه است و اتلاف وقت قابل توجهی برای یافتن گزینه‌های بهینه می‌طلبد. برای غلبه بر این محدودیت‌ها، سیستم نیازمند رویکردی است که بتواند با کمترین میزان نیاز به داده‌های از پیش تعیین‌شده و برچسب‌دار، تجربیات پیشین خود را ارزیابی و استراتژی‌های جدیدی را در زمان اجرا به کار گیرد.

این فصل رویکرد پیشنهادی رساله یعنی مدیریت عدم قطعیت مبتنی بر مدل ترکیبی «یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش» یا به اختصار RS-DRL را معرفی می‌نماید. ما در این فصل به صورت جامع، معماری مبتنی بر حلقه کنترل MAPE-K که با الگوریتم‌های هوش مصنوعی تقویت شده است را توجیه خواهیم کرد و نشان می‌دهیم چگونه یک عامل با مدیریت بهینه و شکل‌دهی مجدد تجربیات ناموفق خود، می‌تواند سرعت همگرایی را افزایش داده و راه‌حل‌های بهینه‌سراسری را حتی در فضاهاى بزرگ تطبیقی کشف نماید. در ادامه، ابتدا مروری کلی بر ایده و روش پیشنهادی ارائه خواهد شد. سپس معماری یکپارچه سیستم و فرآیند ۹ مرحله‌ای در چرخه MAPE-K شرح داده می‌شود. در نهایت، تمرکز اصلی بر روی جزئیات الگوریتم RS-DRL و مکانیزم بدیع تصادفی‌سازی پاداش‌ها خواهد بود و مقایسه‌ای جامع بین این روش و بازپخش تجربه با نگاه به گذشته (HER) انجام می‌گیرد.

۲-۴ مرور کلی بر روش پیشنهادی

روش RS-DRL یک متدولوژی نوین است که بر پایه ارتقای الگوریتم سنتی شبکه‌های دیپ‌کیو (DQN) طراحی شده تا فرآیند بازآموزی سیستم را، بدون نیاز به دانش قبلی یا تکیه بر آموزش‌های آفلاین دشوار، بهبود بخشد. ایده اصلی این روش، تعبیه یک مکانیزم شکل‌دهی پاداش بدیع (Reward Shaping) در طول فاز حافظه بازپخش تجربه (Experience Replay) می‌باشد.

نوآوری کلیدی نهفته در روش پیشنهادی آن است که به جای استفاده‌های یکنواخت و مرسوم از تمامی تجربیات گذشته، سیستم، زیرمجموعه‌ای از تجربیات شکست‌خورده (که در آنها مقدار پاداش $r_i = 0$ بوده است) را استخراج کرده و به صورت تصادفی آنها را به عنوان تجربیات موفق (با تخصیص پاداش خوش‌بینانه $r_i = 1$) بازطراحی و شکل‌دهی مجدد می‌نماید. این ترفند استراتژیک، عامل یادگیرنده را تشویق می‌کند تا به جای گیر افتادن در سیاست‌های محلی ضعیف گذشته، با جسارت بیشتر کاوش (Exploration) بیشتری انجام دهد و در نهایت با افزایش قدرت تعمیم‌پذیری، استراتژی‌های جدیدتری را در مواجهه با شرایط عدم قطعیت پیدا کند.

۳-۴ معماری سیستم: یکپارچه‌سازی RS-DRL با حلقه MAPE-K

۱-۳-۴ سیستم مدیریت‌شده و سیستم مدیریت‌کننده

همان‌طور که در فصل‌های پیشین به تفصیل بیان شد، جداسازی منطق کسب‌وکار از منطق انطباق یکی از اصول پایه‌ای در سیستم‌های خودوقتی به شمار می‌رود. بر این اساس، معماری پیشنهادی ما از دو بخش مجزا تشکیل گردیده است:

۱. سیستم مدیریت‌شونده (Managed System): این بخش همان سیستم نرم‌افزاری پایه‌ای است که نیازمند فرآیند وفقی‌سازی (تطبیق) می‌باشد. در روند این رساله، پلتفرم DeltaIoT به عنوان یک شبکه حسگر بی‌سیم، تحت عنوان سیستم مدیریت‌شونده در نظر گرفته شده است که داده‌های محیطی زمان اجرا را تولید می‌نماید.

۲. سیستم مدیریت‌کننده (Managing System): این بخش شامل مکانیزم حلقه کنترل و بازخورد MAPE-K است که به صورت عمیقی با عامل یادگیری تقویتی RS-DRL ادغام یافته تا مدیریت پویای تصمیمات اتخاذ شده و حل مسئله بهینه‌سازی را بر عهده گیرد.

۲-۳-۴ تعامل دقیق حلقه وفقی ۹ مرحله ای

ادغام یک مدل یادگیری تقویتی مانند RS-DRL درون یک سیستم حیاتی، نیازمند یک جریان یکپارچه و امن از دریافت داده، ارزیابی وضعیت، به روزرسانی مدل، تأیید صوری و نهایتاً اجرای گزینه ها است. این فرآیند از طریق ۹ مرحله تعاملی بین مؤلفه های مختلف در حلقه مدیریت مشخص می گردد:

۱. جمع آوری داده ها توسط مؤلفه پایش (Monitor): در گام نخست، این مؤلفه داده های زمان اجرای

سیستم نظیر خوانش های سنسوری و لاگ های سیستم را به شکل مداوم جمع آوری می نماید.

۲. ارسال داده ها جهت آموزش مدل: اطلاعات جمع آوری شده شامل وضعیت رخ داده، پیامدهای استراتژی های

پیشین و توابع پاداش محاسبه شده، برای بازآموزی عامل هوشمند، مستقیماً به ماژول RS-DRL تزریق می گردد.

۳. ذخیره سازی مدل آموزش دیده در پایگاه دانش (Knowledge): پس از اتمام فاز بازآموزی و اجرای

مکانیزم بازپخش تجربه با ویژگی های شکل دهی تصادفی پاداش ها، مقادیر وزن ها و سیاست های به روز شبکه عصبی بر روی مخزن دانش مرکزی سیستم استقرار می یابد.

۴. انتقال همزمان داده ها به تحلیل گر (Analyzer): مؤلفه پایش در موازات عملیات یادگیری، داده های

شرایط کنونی را جهت بررسی انطباق ها به سمت مؤلفه تحلیل گر نیز هدایت می کند.

۵. آشکارسازی نقض اهداف کیفی: تحلیل گر، انطباق وضعیت جاری سیستم با ضمانت ها و اهداف از

پیش تعیین شده را ارزیابی می کند. در صورت مشاهده نقض اهداف کیفی (نظیر افت طولانی منابع یا اختلال)، بلافاصله هشدار را برای مؤلفه برنامه ریز (Planner) ارسال می دارد.

۶. استخراج مدل توسط انتخاب گر گزینه وفقی: با دریافت هشدار از سوی تحلیل گر، ماژول پیش بینی

کننده گزینه وفقی (Adaptation Option Predictor) که در قلب مؤلفه برنامه ریز قرار دارد، آخرین نسخه آموزش دیده و به روز از مدل RS-DRL را از بخش دانش برای استفاده استخراج می کند.

۷. پیش بینی و انتخاب گزینه ی بهینه: با فراهم شدن مدل عملیاتی، انتخاب گر وضعیت جدید شبکه را به

شبکه عصبی وارد نموده و استراتژی و گزینه تطبیقی پیش بینی شده در توابع کیفیت را انتخاب می کند.

۸. دریافت دستورالعمل های گزینش از پایگاه دانش: مؤلفه مجری (Executor) برنامه تایید شده را از

برنامه ریز اخذ کرده و برای اطلاع از مختصات عملیاتی، تنظیمات سطح پایین و جزئیات دقیق اجرای آن، مجدداً به مخزن دانش اطلاعات رجوع می نماید.

۹. اجرای قطعی فرامین وفقی: در گام پایانی، مؤلفه مجری، فرمان تطبیقی اخذ شده (مانند تغییر توان ارسال و تخصیص مسیرهای جدید برای گره‌ها در DeltaIoT) را بر روی ساختار سیستم مدیریت شده جاری می‌سازد.

۴-۴ الگوریتم RS-DRL و مکانیزم تصادفی سازی

این بخش، هسته الگوریتمی که سبب برتری کامل سیستم در حفظ کیفیت در فضاها متغیر و بزرگ شده را تبیین می‌نماید.

۴-۴-۱ الگوریتم اصلی: DQN برای مدیریت حلقه‌های وفقی جریان

برای شبکه‌های عظیم و گسسته‌ای که دارای پویایی بالا می‌باشند، ساختار الگوریتمی شبکه‌های Q عمیق (DQN) ویژگی‌های مطلوبی را فراهم می‌سازد. انتخاب این چارچوب یادگیری تقویتی بر اساس چهار برهان مستحکم صورت گرفته است: (۱) کارایی بنیادین: تسلط و پردازش سریع فضاها عمل گسسته به شیوه‌ای کارآمد بدون از دست دادن زمان. (۲) آموزندگی بهره‌ور: دارا بودن حافظه بازپخش که سبب کارایی در نمونه‌برداری از تجربیات رویدادهای تاریخی (Sample Efficiency) می‌گردد. (۳) ایستادگی و ثبات: بهره‌گیری از شبکه‌های تثبیت شده هدف (Target Networks) که ثبات اهداف و کمینه کردن نوسانات شیب‌یابی در سیستم‌های متغیر را تضمین می‌نمایند. (۴) یادگیری از تجارب تاریخی: فرآیند یادگیری مبتنی بر مدل‌های غیرسیاستی (Off-Policy) که قابلیت تغذیه آفلاین و استخراج الگو از سوابق تجربیات متوالی را برای عامل مهیا می‌سازد.

۴-۴-۲ ایده اصلی: شکل‌دهی تصادفی پاداش در طول بازپخش تجربه

متمایزترین عامل نوآوری سیستم در این است که برخلاف مکانیزم حافظه‌های سنتی که منحصر به نمونه‌های گذشته را به صورت نمونه‌برداری یکنواخت (Uniform Sampling) در فاز آموزش لحاظ می‌نمایند، مدل معرفی شده، زیرمجموعه‌ای تصادفی از تجربیات تاریخیچه‌دار که مستقیماً در انجام هدف کیفی شکست خورده‌اند (با اعطای مقدار $r = 0$) را استخراج نموده، تغییر داده (برچسب مجدد) و وانمود می‌کند این اعمال در وضعیت‌های پیشین با موفقیت‌آمیز همراه بوده‌اند (تخصیص $r = 1$).

این فرآیند به صورت مطلق و کور صورت نمی‌پذیرد؛ بلکه توسط عاملی با عنوان فاکتور شکل‌دهی ρ (ρ) کنترل شده تا میزان و نرخ تغییرات تصادفی را تنظیم نماید. فلسفه و بصیرت طراحی (Intuition) مستتر در

این تکنیک این است که تخصیص امتیازات مثبت و ثابت به استثناهای ناموفق پیشین، عاملی محیط‌شناسانه ایجاد می‌نماید تا به جای اجتناب از بخش‌های مبهم حالت‌ها به دلیل شکست قبلی، مجدداً آن‌ها را در دوره‌های آتی با انگیزه اکتشافه مواجه ارزیابی کرده و بدین ترتیب با غلبه بر ترس از افت پاداش، راه‌حل‌های جهانی و ناشناخته‌تر را کشف کند. این امر از فروافتادن مدل به تله‌های بهینه محلی که ناشی از عدم بررسی مجدد انتخاب‌های پرخطر گذشته است، جلوگیری می‌نماید.

۴-۳-۴ تابع شکل‌دهی پاداش (الگوریتم ۲)

مبانی دقیق کارکرد نظری سیستم در خصوص اصلاح پاداش تجربه‌ها، در الگوریتم؟؟ شرح داده شده است. این روند پردازشی با دریافت مجموعه‌ای از نمونه‌برداری‌های تصادفی در قالب یک مینی‌بچ (Minibatch) و اعمال فاکتور کنترل‌کننده ρ آغاز می‌گردد.

در این رویه پردازشی، مکانیزم در گام‌های ۱ تا ۳، ابتدا مجموعه عملگرهای مردود شده از منظر پاداش را بررسی می‌کند. اگر تعداد رویدادهای مردود شده حدنصاب لازم محاسبه شده از طریق ضریب ρ را داشته باشند، زیرمجموعه‌ای تصادفی شامل K مقدار از این دسته، گزینش شده و مقدار متغیر پاداش آن‌ها به عدد ۱ تغییر می‌یابد (Reshape) و نهایتاً دسته داده‌های به‌روزشده بازگردانده خواهند شد. استفاده از یک مقدار ثابت خوش‌بینانه نظیر استراتژی (تخصیص ۱) یک مسیر مستقیم و غیروابسته را مهیا نموده که با تغییر رفتار فرآیند یادگیری انسان‌ها شباهت دارد.

الگوریتم ۴-۱ شکل دهی پاداش (Reward Shaping)

ورودی: مینی بچ B ، فاکتور ضربی شکل دهی ρ

۱: $N \leftarrow |B|$

۲: $K \leftarrow \rho \times N$ {محاسبه تعداد تجربیاتی که باید شکل دهی شوند}

۳: شناسایی تجربیات ناموفق پیشین به شرط داشتن مقدار $r_i = 0$

۴: **if** تعداد کل تجربیات ناموفق مینی بچ $\geq K$ **then**

۵: انتخاب تصادفی متعادل از میان K تجربه ناموفق

۶: **for** هر تراکنش انتخاب شده نظیر $(s_i, a_i, \bullet, s_{i+1})$ **do**

۷: $r_i \leftarrow 1$ {شکل دهی یک شکست به موفقیت تصنعی}

۸: **for end**

۹: **else**

۱۰: تمام تجربیات ناموفق حاضر را با پاداش ثابت ۱ شکل دهی کن

۱۱: **if end**

۱۲: **return** جریان مینی بچ به روز شده B

۴-۴-۴ الگوریتم جامع و کلان RS-DRL (الگوریتم ۱)

الگوریتم؟؟ روند کامل سیستم هوشمند از ساختار شبکه عصبی تا حلقه های تعاملی با مکانیزم معرفی شده فوق را تبیین می نماید.

خطوط ۱ تا ۲ فرآیند راه اندازی، تثبیت پارامترهای پایه ای و تخصیص شیب های اولیه برای شبکه اصلی و شبکه هدف را مستند می نمایند. خطوط ۳ تا ۵ نشان دهنده حلقه های اجرای تو در تو اپیزودهای پیوسته زمان اجراست که با انتخاب های اتخاذی از سوی سیاست حریصانه خط ۶ (ϵ -greedy) هنجارهای تطبیقی را صورت بندی می نمایند. کلیه این تجربه های محیطی اجرا شده نیز در حافظه ی سیستم افزوده می گردند (خطوط ۷-۸). خط ۹ نمونه گیری اتفاقی (Sampling) را اعمال داشته، و پس از آن الگوریتم شماره ۲ (تغییر شکل پاداش) بر مدل فراخوانده می شود (خط ۱۱) تا ساختارها را تنظیم مجدد کند. نهایتاً با یافتن اهداف درختی خطاها، وزن دهی گرادیان جهت ارتقای دقت مدل، در خطوط ۱۲ تا ۱۴ بروز می گردد.

الگوریتم ۴-۲ الگوریتم یکپارچه یادگیری RS-DRL

- ۱: راه اندازی شبکه Q اصلی و تعیین وزن های تصادفی θ
- ۲: راه اندازی و تخصیص شبکه تثبیت شونده هدف با وزن های $\theta' = \theta$
- ۳: **for** هر اپیزود تعاملی **do**
- ۴: دریافت حالت اولیه محیط s
- ۵: **while** حلقه اپیزود تمام نشده است **do**
- ۶: انتخاب اقدام انطباقی a با استفاده از سیاست ϵ - گریدی
- ۷: اجرای اقدام a بر روی محیط، و دریافت پاداش r و حالت غایی حاصله s'
- ۸: ذخیره سازی این تراکنش به فرم (s, a, r, s') در حافظه بازپخش $\mathcal{D}$
- ۹: اخذ نمونه گیری یک مینی بچ رندوم B از $\mathcal{D}$
- ۱۰: **if** شرایط لازم برای بروزرسانی شکل دهی مهیا باشد **then**
- ۱۱: $B \leftarrow \text{RewardShaping}(B, \rho)$ {فراخوانی الگوریتم ؟؟}
- ۱۲: **if end**
- ۱۳: برآورد هدف تقریبی Q برای نمونه های داخل مینی بچ با شبکه ثابت
- ۱۴: اجرای کاهنده نزول گرادیان روی شبکه اصلی برای کمینه سازی اختلافات
- ۱۵: انتقال و به روزرسانی وزن های شبکه هدف θ' به صورت درصدی
- ۱۶: تخصیص وضعیت فعلی: $s' \leftarrow s$
- ۱۷: **while end**
- ۱۸: **for end**

۴-۴-۵ مقایسه با بازپخش تجربه با نگاه به گذشته (HER)

استراتژی های متداولی پیرامون کار با تجربیات مفقود سیستم در حوزه هوش مصنوعی توسعه یافته که مشهورترین مدل ها متأثر از استراتژی بازپخش تجربه با نگاه به گذشته یا HER (و نمونه اخیر Soft HER) می باشند. به منظور شفاف سازی ویژگی های کلیدی این طراحی و اثبات برتری آن در محیط های خودسازمانده، جدول ؟؟ جنبه های کلیدی تمایز این رویکردها را گردآوری نموده است.

همانطور که ارزیابی گردید، الگوریتم های برگرفته از چارچوب HER با وجود توانایی های شگرف جستجویی خود، نیازمند وابستگی های بسیار مهمی می باشند. در این متدها محقق باید برای الگوریتم، مسیر اهداف صریح و مقاصد کاملاً تعریف شده ای را برنامه ریزی نماید تا فرآیند برچسب گذاری مجدد (Goal Relabeling)

جدول ۴-۱: تحلیل مقایسه‌ای ویژگی‌های RS-DRL با راهکارهای مبتنی بر HER

وابسته به دانش دامنه‌ای	خاستگاه استراتژی شکل‌دهی	دامنه کاربرد و استقرار
دارای تسلط قطعی به محیط	برچسب‌زنی مجدد و صریح اهداف (Goal relabeling)	کاربرد محدود به محیط‌های غایت‌گرا
سلطه نسبی به پارامترهای مدل	برچسب‌زنی ملایم و تصادفی برای مقاصد	مقاصد کاملاً مشخص و معین در پیوسته
اساساً نامتکی و بدون نیاز	تخصیص تصادفی مقدار موفقیت‌آمیز	محیط‌های مبهم سیستم‌های خودوقتی

به درستی محقق شود. در مقابل استراتژی RS-DRL اساساً یک استراتژی خودکفا، مقاوم و مستقل است که بدون دخالت انسانی و در نبود دانش دامنه‌ای، نیازهای خود را تنها متکی به پارامترهای استخراج شده از رویکردهای احتمالی پیدا می‌کند و بنابراین مناسب‌ترین مدل برای شبکه‌های نامتقارن، محیط‌های نامشخص و پویایی‌های غیرایستای سیستم‌های خودوقتی قلمداد می‌گردد.

۴-۵ جزئیات کلیدی پیاده‌سازی برای بازتولیدپذیری

۴-۵-۱ ساخت حالت از داده‌های پایش شده

در سیستم مدل‌سازی شده برای اینکه متغیرهای پراکنده به الگویی معنادار جهت ارزیابی در زمان اجرا بدل شوند باید وضعیت سیستم را تحت قالب فضای حالت مهیا ساخت. مطابق با قواعد استخراج شده، داده‌های خام دریافتی مستقیماً به الگویی به فرمت زیر تبدیل می‌شوند:

$$S = \{(E, P, L) \mid E \in \mathbb{R}, P \in [0, 100], L \in [0, 100]\}$$

ایجاد ساختار وضعیت وابسته به سه ورودی اساسی بوده است:

۱. معیار انرژی (E): استنتاج شده از مقدار انرژی مصرف شده (به صورت مقادیر حقیقی شناور).
۲. معیار پکت‌لاس (P): ضریب درصدی بسته‌های مفقود و نابود شده، مقیاس‌بندی شده از بازه ۰ تا ۱۰۰.
۳. معیار تاخیر انتقال (L): درصد بالاترین سیگنال‌های دریافتی از مقیاس شبکه، بیانگر مدت زمان تأخیر از مبدأ به گره اصلی (تا بازه محدود ۱۰۰).

۴-۵-۲ اعتبارسنجی زمان اجرا با UPPAAL-SMC و ActivFORMS

اعمال استراتژی‌های جدید تطبیقی، به دلیل تبعیت از متدهای یادگیری که گاهی با عدم قطعیت‌هایی روبرو هستند، به تضمین ایمنی و تایید صلاحیت صوری (Formal Verification) نیاز دارد. به این دلیل، شبکه‌های پیش‌بینی شده از سوی عامل یادگیرنده، بلافاصله در کنترلر UPPAAL-SMC با بهره‌گرفتن از شبکه‌های مدل‌سازی اتوماتای زمان‌دار، از طریق اعتبارسنجی کنترل آماری مدل (Statistical Model Checking) تحلیل و در صورت رعایت ایمنی‌های الزامی، توسط ماشین مجازی واسط ActivFORMS جهت اجرا روی شبکه واقعی صادر می‌گردند.

۴-۵-۳ انتخاب و بهینه‌سازی ابرپارامترها

جهت استقرار بالاترین راندمان سیستم شبکه‌عصبی، فرآیند سیستماتیک جستجوی شبکه‌ای (Grid Search) برای کاوش جامع درون فضای تنظیمات تدارک دیده شده است. تنظیماتی نظیر تعیین نرخ یادگیری بهینه (η)، عامل تنزیل پاداش‌های بلندمدت (γ)، نرخ اکتشاف در فاز کاوشی (ϵ) و البته سرنوشت‌سازترین شاخص رساله یعنی فاکتور شکل‌دهی مقدار تجربی تصادفی (ρ)، همگی بر پایه مقایسه سرعت همگرایی کیفیت خط راهکارها و تضمین ثبات کیفیت سیستم کالبره و در مدل آزمایشگاهی تثبیت گردیده‌اند.

۴-۶ خلاصه فصل

در این فصل رساله با یک گذر ساختاریافته از نظریات تا گام‌های عملیاتی، معماری تمام عیاری جهت استقرار هوش مصنوعی تصمیم‌ساز و مدل‌سازی در بطن یک شبکه مدیریت خودوقتی، تبیین و مستدل گردید. یکپارچگی حلقه بازخورد معروف MAPE-K با یادگیری تقویتی این ظرفیت را به سیستم مدیریتی اعطا می‌کند تا گره‌های شبکه را بدون کنترل انسانی مهار و تنظیم نماید. در این راستا با معرفی شفاف قالب‌های الگوریتمی وابسته، نوآوری مکانیزم اختصاصی این رساله در خصوص تخصیص ارزش مثبت به تجربیات ناموفق سیستم ثبت شده در حافظه‌ی بازپخش (RS-DRL) و نقش بی‌نظیر فاکتور کنترل‌ی شکل‌دهی تشریح شد و نشان داده شد که استراتژی ابتکاری نه تنها نیازمند دانش از قبل دامن‌ی نرم‌افزار نیست، بلکه در مواجهه با چالش‌های سیستم‌های نوین نظیر HER دارای برتری قطعی اجرایی جهت ممانعت از همگرایی به استثنای محلی (Lo -cal Optima) می‌باشد. در فصل آتی به صورت عملی شواهد این برتری محاسباتی و زمان اجرا در مقایسه دقیق متدهای دیگر ارائه خواهد شد.

فصل ۵

ارزیابی تجربی

۵-۱ مقدمه

۵-۲ اهداف ارزیابی و سوالات تحقیق

۵-۳ تنظیمات آزمایشگاهی

۵-۳-۱ نمونه‌های مطالعه موردی: DeltaIoTv1، DeltaIoTv1.1 و DeltaIoTv2

۵-۳-۲ مجموعه داده‌ها: ردپاهای محیطی و پارامترهای رانش

۵-۳-۳ پلتفرم پیاده‌سازی: Gymnasium و Stable-Baselines3

۵-۴ روش‌های پایه و مقایسه

۵-۴-۱ روش Epsilon-Greedy DQN

۵-۴-۲ روش RS-DRL به همراه HER / Soft HER

۵-۴-۳ روش‌های DLASER، DLASER+ و ML4EAS

۵-۴-۴ روش مرجع جستجوی کامل (Exhaustive Search)

۵-۴-۵ توجیه انتخاب روش‌های پایه: محدودیت‌ها و پروتکل‌های مقایسه

۵-۵ معیارهای ارزیابی

فصل ۶

بحث، کارهای آینده و نتیجه‌گیری

۶-۱ مقدمه

۶-۲ بحث در مورد یافته‌های کلیدی

۶-۲-۱ نظریه‌پردازی مکانیزم: چرا RS-DRL کار می‌کند؟

۶-۲-۲ تحلیل تعاملات و مصالحه‌ها (به عنوان مثال، تاخیر در مقابل از دست رفتن

بسته)

۶-۲-۳ پیامدهای مهندسی سیستم‌های خودوفقی

۶-۳ محدودیت‌ها و تهدیدات اعتبار

۶-۳-۱ اعتبار داخلی، خارجی و سازه

۶-۳-۲ محدودیت‌های رویکرد RS-DRL (وابستگی به ρ ، فضاهاى عمل گسسته)

۶-۴ مسیرهایی برای تحقیقات آینده

۶-۴-۱ به سوی استراتژی‌های شکل‌دهی وفقی (تنظیم خودکار ρ)

۶-۴-۲ گسترش RS-DRL به دامنه‌های پیوسته و حساس به ایمنی

۶-۴-۳ اعتبارسنجی بین دامنه و تحلیل‌های نظری

پیوست آ

جریان‌های کاری کامل فرآیند

پیوست ب

لیست کامل الگوریتم‌ها

پیوست پ

نتایج تجربی گسترده

پیوست

مصنوعات پیاده‌سازی و پکیج بازتولید

Abstract:

guidelines) TMU by end the at required thesis, the of summary (English

Shap- Reward Learning, Reinforcement Deep Systems, Self-Adaptive **Keywords:**

Uncertainty ing.



University Modares Tarbiat
Engineering Computer and Electrical of Faculty

Deep Reward-Shaped Randomized for Learning Reinforcement in Uncertainty Managing Systems Self-Adaptive

Requirement the of Fulfillment Partial in Submitted Thesis A
Computer in Philosophy of Doctor of Degree the for
Engineering

By:
Kavianifar Alireza

Supervisor:
... Dr.
Advisor:
... Dr.

۲۰۲۶ February