



دانشگاه تربیت مدرس

دانشکده مهندسی برق و کامپیوتر

رساله دکتری در رشته مهندسی کامپیوتر

گرایش نرم افزار

یادگیری تقویتی عمیق با شکل دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم های خودوفقی

علیرضا کاویانی فر

استاد راهنما

دکتر ...

استاد مشاور

دکتر ...

بهمن ۱۴۰۴



تأییدی هیأت داوران جلسه‌ی دفاع از رساله

خانم / آقای علیرضا کاویانی فر رساله — واحدی خود را با عنوان یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم‌های خودوفقی در تاریخ بهمن ۱۴۰۴ ارائه کردند. اعضای هیأت داوران نسخه نهایی این رساله را از نظر فرم و محتوا تایید کرده است و پذیرش آنرا برای تکمیل درجه دکتری پیشنهاد می‌کنند.

آیین نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهشهای علمی دانشگاه تربیت مدرس

مقدمه: با عنایت به سیاست‌های پژوهشی و فناوری دانشگاه در راستای تحقق عدالت و کرامت انسانها که لازمه شکوفایی علمی و فنی است و رعایت حقوق مادی و معنوی دانشگاه و پژوهشگران، لازم است اعضای هیأت علمی، دانشجویان، دانش‌آموختگان و دیگر همکاران طرح، در مورد نتایج پژوهشهای علمی که تحت عناوین پایان‌نامه، رساله و طرحهای تحقیقاتی با هماهنگی دانشگاه انجام شده است، موارد زیر را رعایت نمایند:

ماده ۱- حق نشر و تکثیر پایان‌نامه/ رساله و درآمدهای حاصل از آنها متعلق به دانشگاه می باشد ولی حقوق معنوی پدید آورندگان محفوظ خواهد بود.

ماده ۲- انتشار مقاله یا مقالات مستخرج از پایان‌نامه/ رساله به صورت چاپ در نشریات علمی و یا ارائه در مجامع علمی باید به نام دانشگاه بوده و با تایید استاد راهنمای اصلی، یکی از اساتید راهنما، مشاور و یا دانشجو مسئول مکاتبات مقاله باشد. ولی مسئولیت علمی مقاله مستخرج از پایان‌نامه و رساله به عهده اساتید راهنما و دانشجو می باشد. تبصره: در مقالاتی که پس از دانش‌آموختگی بصورت ترکیبی از اطلاعات جدید و نتایج حاصل از پایان‌نامه/ رساله نیز منتشر می شود نیز باید نام دانشگاه درج شود.

ماده ۳- انتشار کتاب، نرم افزار و یا آثار ویژه (اثری هنری مانند فیلم، عکس، نقاشی و نمایشنامه) حاصل از نتایج پایان‌نامه/ رساله و تمامی طرحهای تحقیقاتی کلیه واحدهای دانشگاه اعم از دانشکده ها، مراکز تحقیقاتی، پژوهشکده ها، پارک علم و فناوری و دیگر واحدها باید با مجوز کتبی صادره از معاونت پژوهشی دانشگاه و براساس آئین نامه های مصوب انجام شود.

ماده ۴- ثبت اختراع و تدوین دانش فنی و یا ارائه یافته ها در جشنواره های ملی، منطقه ای و بین المللی که حاصل نتایج مستخرج از پایان‌نامه/ رساله و تمامی طرحهای تحقیقاتی دانشگاه باید با هماهنگی استاد راهنما یا مجری طرح از طریق معاونت پژوهشی دانشگاه انجام گیرد.

ماده ۵- این آیین نامه در ۵ ماده و یک تبصره در تاریخ ۸۷/۴/۱ در شورای پژوهشی و در تاریخ ۸۷/۴/۲۳ در هیأت رئیسه دانشگاه به تایید رسید و در جلسه مورخ ۸۷/۷/۱۵ شورای دانشگاه به تصویب رسیده و از تاریخ تصویب در شورای دانشگاه لازم الاجرا است.

اینجانب علیرضا کاویانی فر به شماره دانشجویی ... دانشجوی رشته مهندسی کامپیوتر مقطع تحصیلی دکتری دانشکده مهندسی برق و کامپیوتر متعهد می شوم کلیه نکات مندرج در آئین نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهش های علمی دانشگاه تربیت مدرس را در انتشار یافته های علمی مستخرج از

پ

پایان نامه / رساله تحصیلی خود رعایت نمایم. در صورت تخلف از مفاد آئین نامه فوق الاشعار به دانشگاه وکالت و نمایندگی می دهم که از طرف اینجانب نسبت به لغو امتیاز اختراع بنام بنده و یا هر گونه امتیاز دیگر و تغییر آن به نام دانشگاه اقدام نماید. ضمناً نسبت به جبران فوری ضرر و زیان حاصله بر اساس برآورد دانشگاه اقدام خواهم نمود و بدینوسیله حق هر گونه اعتراض را از خود سلب نمودم»

تاریخ و امضا:

آیین نامه چاپ پایان نامه (رساله) های دانشجویان دانشگاه تربیت

مدرس

نظر به اینکه چاپ و انتشار پایان نامه (رساله) های تحصیلی دانشجویان دانشگاه تربیت مدرس، مبین بخشی از فعالیتهای علمی - پژوهشی دانشگاه است بنابراین به منظور آگاهی و رعایت حقوق دانشگاه، دانش آموختگان این دانشگاه نسبت به رعایت موارد ذیل متعهد می شوند: ماده ۱: در صورت اقدام به چاپ پایان نامه (رساله) ی خود، مراتب را قبلاً به طور کتبی به «دفتر نشر آثار علمی» دانشگاه اطلاع دهد. ماده ۲: در صفحه سوم کتاب (پس از برگ شناسنامه) عبارت ذیل را چاپ کند: «کتاب حاضر، حاصل پایان نامه کارشناسی ارشد/ رساله دکتری نگارنده در رشته مهندسی کامپیوتر است که در بهمن ۱۴۰۴ در دانشکده مهندسی برق و کامپیوتر دانشگاه تربیت مدرس به راهنمایی سرکار خانم/جناب آقای دکتر ...، مشاوره سرکار خانم/جناب آقای دکتر ... از آن دفاع شده است.» ماده ۳: به منظور جبران بخشی از هزینه های انتشارات دانشگاه، تعداد یک درصد شمارگان کتاب (در هر نوبت چاپ) را به «دفتر نشر آثار علمی» دانشگاه اهدا کند. دانشگاه می تواند مازاد نیاز خود را به نفع مرکز نشر در معرض فروش قرار دهد. ماده ۴: در صورت عدم رعایت ماده ۳، ۵۰٪ بهای شمارگان چاپ شده را به عنوان خسارت به دانشگاه تربیت مدرس، تأدیه کند. ماده ۵: دانشجو تعهد و قبول می کند در صورت خودداری از پرداخت بهای خسارت، دانشگاه می تواند خسارت مذکور را از طریق مراجع قضایی مطالبه و وصول کند؛ به علاوه به دانشگاه حق می دهد به منظور استیفای حقوق خود، از طریق دادگاه، معادل وجه مذکور در ماده ۴ را از محل توقیف کتابهای عرضه شده نگارنده برای فروش، تأمین نماید. ماده ۶: اینجانب علیرضا کاویانی فر دانشجوی رشته مهندسی کامپیوتر مقطع دکتری تعهد فوق و ضمانت اجرایی آن را قبول کرده، به آن ملتزم می شوم.

استاد راهنما: دکتر ...

تاریخ:

امضا:

تقديم

(متن تقديم به خانواده، اساتيد و ...)

قدردانی

(متن تشکر و قدردانی از اساتید راهنما، مشاور و دوستان)

علیرضا کاویانی فر

بهمن ۱۴۰۴

چکیده

(خلاصه‌ای از چالش، راهکار و نتایج کلیدی در ۳۰۰ تا ۵۰۰ کلمه)

واژگان کلیدی: سیستم‌های خودوفقی، یادگیری تقویتی عمیق، شکل‌دهی پاداش، عدم قطعیت

فهرست مطالب

فهرست جداول

فهرست تصاویر

فهرست علائم و اختصارات

(لیست نمادهای ریاضی مانند ρ ، γ و اختصارات مانند DRL، SAS)

فصل ۱

مقدمه

۱-۱ مقدمه

در حوزه مهندسی سیستم‌های نرم‌افزاری معاصر، پیچیدگی به عنوان یکی از بارزترین ویژگی‌ها خودنمایی می‌کند. محیط عملیاتی پویا نقش محوری در شکل‌دهی به این پیچیدگی ایفا کرده و سیستم‌ها را مجبور می‌سازد تا با شرایط نامشخصی که معمولاً تنها پس از عملیاتی شدن بروز می‌کنند، دست و پنجه نرم کنند. علاوه بر این، چالش‌ها و منابع عدم قطعیت در سیستم‌های مختلف به شکل‌های گوناگونی نمود پیدا می‌کنند. به عنوان مثال، در سیستم‌های مستقر در محیط‌های پویا نظیر برنامه‌های اینترنت اشیا (IoT) در شهرهای هوشمند، تغییرات آب و هوایی تأثیر قابل توجهی می‌گذارد. همچنین محیط‌های ابری با تقاضای منابع متغیر، امنیت سایبری با تهدیدات نوظهور و مداوم، تجارت الکترونیک و شبکه‌های اجتماعی با رفتار غیرقابل پیش‌بینی کاربران، و سیستم‌های توزیع‌شده با تأخیر شبکه، خرابی سخت‌افزار و تغییرات زیرساختی روبه‌رو هستند.

سیستم‌های سنتی ایستا یا مبتنی بر قواعد، انعطاف‌پذیری لازم برای پاسخ به چنین تغییراتی در زمان اجرا را ندارند. در مقابل، سیستم‌های خودوقتی (SAS) مجهز به حلقه‌های بازخوردی هستند که به آن‌ها اجازه می‌دهد تا محیط و وضعیت خود سیستم را پایش کنند، انحرافات از رفتار مورد انتظار را تحلیل نمایند و به طور خودمختار استراتژی‌ها و تغییرات وقتی را برنامه‌ریزی و اجرا کنند.

هنگامی که سیستم با یک فضای وقتی و گزینه‌های تغییر بسیار گسترده مواجه می‌شود، وظیفه انتخاب یک گزینه وقتی که با اهداف سیستم همسو باشد، از نظر محاسباتی بسیار پرهزینه و دشوار، و در برخی موارد تقریباً غیرممکن می‌گردد. تمرکز این رساله بر سیستم‌هایی است که دارای فضای وقتی گسترده و بزرگ هستند و نیاز فوری به راهکارهای کارآمد جهت انتخاب گزینه‌های بهینه در زمان اجرا دارند.

۱-۲-۱ بیان مسئله و سوالات تحقیق

۱-۲-۱ مسئله تحقیق

روش‌های موجود برای مدیریت عدم قطعیت در سیستم‌های خودوفقی با محدودیت‌های قابل توجهی روبه‌رو هستند. به عنوان مثال، روش‌های مبتنی بر یادگیری ماشین نیازمند داده‌های آموزشی برجسته‌دار هستند که نمایانگر محیط سیستم باشند؛ به دست آوردن چنین داده‌هایی در زمان طراحی به دلیل عدم قطعیت فراوان بسیار دشوار است. از طرفی، روش‌های مبتنی بر جستجو (مانند الگوریتم‌های صعود تپه و الگوریتم‌های ژنتیک) با مشکلات مقیاس‌پذیری مواجه هستند و عملکرد آن‌ها با تغییر شرایط محیطی دچار افت محسوس می‌شود. یادگیری تقویتی عمیق (DRL) اگرچه ابزاری قدرتمند است، اما خود با چالش‌های اساسی مانند گیر افتادن در بهینه‌های محلی مواجه می‌باشد. بهینه‌های محلی به راه‌حل‌هایی اشاره دارند که تنها در یک منطقه محدود از فضای مسئله بهینه هستند و به صورت سراسری بهترین راه‌حل ممکن محسوب نمی‌شوند. در زمینه DRL، این بدان معناست که مدل ممکن است سیاستی را یاد بگیرد که تحت شرایط خاص به خوبی عملکرد مناسبی دارد، اما در صورت تغییر محیط قادر به تعمیم‌پذیری و حفظ عملکرد مطلوب نیست.

علاوه بر این، آموزش مجدد یا بازآموزی (Retraining) مدل در زمان اجرا فرآیندی پرهزینه است. بازآموزی شامل مراحل متعددی مانند جمع‌آوری داده‌های جدید، ارزیابی مجدد ساختار و پارامترهای مدل، و تست مدل به‌روزشده برای اطمینان از عملکرد بهتر آن نسبت به نسخه قبلی است. در طول این فرآیند، سیستم ممکن است به صورت غیربهینه عمل کند که در سیستم‌های حیاتی، این دوره عملکرد نامطلوب می‌تواند پیامدهای جبران‌ناپذیری به همراه داشته باشد.

بیان اصلی و خلاصه‌شده مسئله: ماهیت پویا و غیرقابل پیش‌بینی محیط‌هایی که سیستم‌های نرم‌افزاری در آن‌ها عمل می‌کنند، چالش‌های قابل توجهی را برای مدل‌های سنتی یادگیری تقویتی عمیق به وجود می‌آورد. این مدل‌ها به طور مکرر با مشکل بهینه‌های محلی دست و پنجه نرم کرده و نمی‌توانند در زمان مواجهه با شرایط متغیر به خوبی عملکرد خود را تعمیم دهند که این امر منجر به عملکرد نامطلوب سیستم و نیاز به بازآموزی‌های مکرر و زمان‌بر خواهد شد.

۱-۲-۲ سوالات تحقیق

با توجه به چالش‌ها و خلاءهای تحقیقاتی مطرح شده و بر اساس دستاوردهای مقاله پیشین [۹]، این رساله به دنبال پاسخگویی به سوالات اصلی زیر است:

۱. سوال اول: چگونه می‌توان یک روش مبتنی بر یادگیری تقویتی عمیق طراحی کرد که به طور موثری از

- بهینه‌های محلی در محیط‌های پویا، بدون نیاز به بازآموزی مکرر، فرار کند؟
۲. سوال دوم: چگونه می‌توان مکانیزم‌های شکل‌دهی پاداش (Reward Shaping) را با بازپخش تجربه (Experience Replay) ادغام کرد تا تعمیم‌پذیری سیستم در تغییرات شرایط محیطی بهبود یابد؟
۳. سوال سوم: چگونه روش پیشنهادی می‌تواند فضاهای افقی گسسته و بزرگ (از ۲۱۶ تا ۴۰۹۶ گزینه) را در حین حفظ عملکرد نزدیک به بهینه، به شکل کارآمدی مدیریت کند؟
۴. سوال چهارم: تا چه حد روش پیشنهادی (RS-DRL) از روش‌های موجود نظیر یادگیری ای‌گرایانه حریصانه (ϵ -greedy DQN)، DLASER و ML4EAS از منظر عملکرد مجانبی، سرعت همگرایی، و بهینه‌سازی چندهدفه، برتری و عملکرد بهتری از خود نشان می‌دهد؟

۳-۱ اهداف رساله

این رساله اهداف کلان و خرد زیر را در راستای توسعه تحقیقات پیشین [۱] دنبال می‌کند:

۱. طراحی و توسعه: طراحی یک معماری نوآورانه یادگیری تقویتی عمیق با شکل‌دهی پاداش تصادفی (RS-DRL) که به شکل یکپارچه‌ای با حلقه خودمختار MAPE-K در سیستم‌های خودوفقی ادغام شده باشد.
۲. نوآوری الگوریتمی: توسعه یک مکانیزم نوین شکل‌دهی پاداش که تجربیات ناموفق را در طول فرآیند بازپخش حافظه به صورت تصادفی بازطراحی می‌نماید تا اکتشاف (Exploration) را ترویج کرده و از همگرایی مدل در بهینه‌های محلی جلوگیری کند.
۳. مدل‌سازی صوری: مدل‌سازی صوری مسئله کنترل و وفقی‌سازی تحت عدم قطعیت که شامل فضای حالت (نظیر سطح انرژی، از دست رفتن بسته‌های شبکه، زمان تأخیر)، فضای عمل (گزینه‌های افقی گسسته) و توابع پاداش جهت بهینه‌سازی‌های تک‌هدفه و چندهدفه است.
۴. ارزیابی تجربی: ارزیابی راهکار توسعه‌یافته RS-DRL در تقابل با روش‌های پیشرفته‌ی فعلی (مانند Soft HER، HER، ϵ -greedy DQN، DLASER و ML4EAS) بر روی مطالعات موردی سیستم DeltaIoT با اندازه‌های مختلف از فضاهای تطبیق (از جمله ۲۱۶، ۱۲۹۶ و ۴۰۹۶ گزینه ممکن).
۵. تحلیل‌های آماری: ارائه ارزیابی‌های آماری دقیق (تست مستقل t-test، مقادیر p-value و فاصله‌های اطمینان) برای تصدیق برتری روش پیشنهادی.

۱-۴ نوآوری‌های رساله

۱-۴-۱ نوآوری اول: ارائه الگوریتم یادگیری تقویتی عمیق با شکل دهی تصادفی پاداش

(RS-DRL)

برخلاف بازپخش تجربه سنتی در یادگیری تقویتی، الگوریتم پیشنهاد شده در این رساله (RS-DRL) برخی از تجربیات ناموفق گذشته را بازطراحی کرده و با اعطای پاداش مثبت به آن‌ها (همانند پاداش‌های موفقیت)، فرآیند یادگیری انسانی از اشتباهات گذشته خود را شبیه‌سازی می‌کند. مکانیزم انتخاب تصادفی تجربیات ناموفق که به وسیله فاکتور شکل‌دهی ρ کنترل می‌شود، تجربیات مردود سیستم را با تخصیص پاداش خوش‌بینانه (به عنوان مثال تخصیص $1 \leftarrow r_i$) شبیه‌سازی موفقیت می‌نماید. این ترفند برای محیط‌های متنوع نیازی به تعاریف تخصصی و دانش دامنه خاص ندارد و موجب می‌شود تا: ۱) تعمیم‌پذیری را در طول محیط‌های متنوع تشویق نماید و ۲) فرآیند یادگیری را از طریق تبدیل اشتباهات گذشته به درس‌های با ارزش در تجربه‌های بعدی، به شدت تسریع کند. در مقایسه با روش‌هایی نظیر بازپخش تجربه با نگاه به گذشته (HER) و Soft HER که ملزم به داشتن دانش دامنه‌ای و داشتن هدف صریح برای برچسب‌زنی مجدد اهداف (Goal Relabeling) هستند، رویکرد ما در RS-DRL از استراتژی پاداش تصادفی و خوش‌بینانه و کاملاً مستقل از دانش حوزه‌ای بهره می‌برد.

۱-۴-۲ نوآوری دوم: یکپارچه‌سازی RS-DRL با معماری خودوفقی MAPE-K

نوآوری استراتژیک دیگر، ارائه چارچوب معماری تلفیقی شامل سیستم مدیریتی و سیستم مدیریت‌شونده است. معماری پیشنهادشده که با حلقه کنترل و بازخورد MAPE-K ادغام شده است، شامل چرخه ارزیابی و انتخاب ۹ مرحله‌ای در تعامل بین مؤلفه‌های مختلف آن در زمان اجرا خواهد بود. این اجزای کلیدی شامل مازول استخراج‌کننده ویژگی از داده‌های سنسورها، انتخابگر فضای گزینه (ε-greedy DQN)، تاییدکننده گزینه وفقی از طریق اعتبارسنجی مدل با موتور UPPAAL-SMC، محاسبه‌گر پاداش، حافظه بازپخش با در نظر گرفتن مکانیزم بدیع شکل‌دهی پاداش و مؤلفه آموزش مدل می‌باشد.

۱-۴-۳ نوآوری سوم: مدیریت موثر عدم قطعیت در فضاهای وفقی بزرگ و گسسته

به عنوان یک نوآوری اساسی در سطح ارزیابی و دستاوردهای سیستم، این راهکار نشان داده که پتانسیل چشم‌گیری در مدیریت و راهبری سیستم‌های با مقیاس‌پذیری فضاهای حالت و فضای عمل بالا، مانند شبکه‌های گسترده اینترنت اشیاء داراست. کاربریست رویکرد RS-DRL در پلتفرم DeltaIoT از طریق کاهش

چشم‌گیر هدررفت داده‌ها تا محدوده ۲۳.۲۲٪ نسبت به رقبای سرسختی مانند DLASER+ و بهبود ۰۷.۳۹ درصدی زمان تأخیر انتقال در شبکه، قابل توجه است. استفاده از فضای گسسته و فقی مقیاس‌پذیر در محیط‌های آزمایشگاهی شامل نسخه‌ی DeltaIoTv1 با ۲۱۶ گزینه، نسخه‌ی DeltaIoTv1.1 شامل ۱۲۹۶ گزینه و نسخه‌ی DeltaIoTv2 شامل ۴۰۹۶ حالت ممکن، کارایی و میزان پاداش مجانبی بهبود یافته و پایداری را نسبت به روش‌های پیشین نشان می‌دهد.

۱-۵ مروری بر فصول رساله

ساختار رساله به گونه‌ای طراحی شده است که به طور نظام‌مند روند توسعه، اجرا و ارزیابی رویکرد پیشنهادی را در اختیار خواننده قرار دهد. در ادامه، مرور خلاصه‌ای از هر یک از فصول آورده شده است:

فصل ۲: مبانی و پیشینه تحقیق

مفاهیم بنیادی مربوط به سیستم‌های خودوفقی، چالش‌های عدم قطعیت و مبانی مدل‌سازی آن در زمان اجرا، اصول سیستم‌های یادگیری تقویتی (MDP، یادگیری Q و DRL (به ویژه الگوریتم‌های DQN) به تفصیل شرح داده می‌شود. سپس کارهای مرتبط پیشین در مدیریت فضاها، بزرگ تطبیق، از روش‌های مبتنی بر یادگیری ماشین نظیر ML4EAS گرفته تا الگوریتم‌های اکتشافی جستجو و سایر روش‌های نوین مورد بررسی و ارزیابی قرار می‌گیرند.

فصل ۳: مدل سیستم و فرمول‌بندی مسئله

در این فصل، سیستم شبکه‌ی سنسورهای اینترنت اشیاء (DeltaIoT) به عنوان مطالعه‌ی موردی انگیزشی معرفی می‌شود. فضای حالت صوری شبکه شامل مفاهیمی پیرامون مصرف انرژی، از دست‌رفتگی بسته‌های داده و زمان تأخیر ($S = \{\text{Energy, Packet Loss, Latency}\}$) فرمول‌بندی شده و در ادامه، گزینه‌های فضای اعمال گسسته نیز مشخص و تدوین می‌گردد. در نهایت، توابع پاداش مربوط به سناریوهای بهینه‌سازی چندهدفه و تک‌هدفه به صورت ریاضی ارائه می‌شوند.

فصل ۴: روش پیشنهادی RS-DRL: معماری و الگوریتم

مرکز ثقل این رساله در این فصل واقع شده است که در آن، معماری پیشنهادی یکپارچه با کنترل‌کننده‌ی MAPE-K تبیین می‌گردد. الگوریتم پایه (RS-DRL)، به انضمام جزئیات دقیق مکانیزم شکل‌دهی پاداش‌های تصادفی با جزئیات الگوریتمی تشریح گردیده و پیاده‌سازی‌های مرتبط با اعتبارسنجی استراتژی‌های اجرایی پیش از پیاده‌سازی نهایی تغییرات توسط نرم‌افزار UPPAAL-SMC، برای تضمین پایداری سیستم، بحث و بررسی می‌شوند.

فصل ۵: ارزیابی تجربی

نحوه تخصیص محیط شبیه‌سازی، سناریوهای متعدد پیکربندی شبکه، و پروتکل‌های مقایسه‌ی جامع مدل RS-DRL با استراتژی‌های به‌روز رقیب نظیر ϵ -Greedy DQN، HER، Soft HER، DLASER، و ML4EAS در این فصل ارائه می‌گردد. ارائه‌ی شفاف معیارهای کلیدی دستاوردها شامل بررسی میزان ظرفیت عملکرد مجانبی سیستم، ارزیابی زمان مورد نیاز تقریبی برای رسیدن به آستانه قابل اتکا، و در نهایت کل مقادیر پاداش دریافتی در هر دوره‌ی آزمایش همراه با تأییدیه‌های تحلیل آماری و علمی مستند می‌باشند.

فصل ۶: بحث، کارهای آینده و نتیجه‌گیری

استلزامات نظری مرتبط با علت تفوقِ راهکار پیشنهادی بازبینی گردیده و کارایی مکانیزم از زوایای پراتیک صنعتی بحث می‌شود. در ادامه‌ی این فصل، به بررسی مصالحه‌ها، محدودیت‌ها و چالش‌های باقی‌مانده‌ی این معماری پرداخته شده و در نهایت، مسیرها و چارچوب‌هایی الهام‌بخش جهت بسط رویکرد فعلی در سیستم‌های پیوسته‌ی سایبرفیزیکی آینده پیشنهاد می‌گردد. فصل با نتیجه‌گیری کلی پیرامون مزیت‌های کاربردی راهکار نوین برای سیستم‌های عملیاتی بسته خواهد شد.

فصل ۲

مبانی و پیشینه تحقیق

۱-۲ مقدمه

هدف این فصل، ایجاد و بسط یک چارچوب و زیربنای نظری مستحکم است تا خواننده را از مفاهیم سطح بالا به سمت درک دقیق شکاف تحقیقاتی که این رساله آن را پر می‌کند، هدایت نماید. سیستم‌های نرم‌افزاری مدرن همواره با عدم قطعیت‌های مداوم مواجه هستند و باید در زمان اجرا به طور پیوسته ساختار و رفتار خود را با شرایط در حال تغییر وفق دهند. این فصل در ابتدا اصول اولیه سیستم‌های خوددوفقی و مؤلفه‌های آن را تشریح می‌کند، سپس به نقش یادگیری تقویتی و محدودیت‌های روش‌های سنتی در مقابله با فضا‌های بزرگ تصمیم‌گیری می‌پردازد و در نهایت با مروری ساختاریافته بر ادبیات تحقیق، علت نیاز به راهکار نوین RS-DRL را اثبات می‌نماید.

۲-۲ مبانی سیستم‌های خوددوفقی

۱-۲-۲ مفاهیم اصلی و الگوهای معماری

سیستم‌های خوددوفقی (Self-Adaptive Systems) یک رویکرد برجسته و مؤثر برای مقابله با عدم قطعیت به شمار می‌روند. ایده کلیدی در این سیستم‌ها، تجهیز آن‌ها به یک یا چند حلقه بازخوردی کنترلی است که به صورت مداوم مؤلفه‌های داخلی سیستم و محیط خارجی آن را پایش کرده و در صورت نیاز سیستم را با تغییرات منطبق می‌نمایند [؟].

مهمترین و شناخته‌شده‌ترین الگوی معماری برای پیاده‌سازی این سیستم‌ها، حلقه خودمختار MAPE-K است. همان‌طور که در فصل‌های بعدی با جزئیات بیشتر بررسی خواهد شد، این حلقه در کنار سیستم هدف

و منطق کسب‌وکار، جریان کنترلی زیر را اعمال می‌کند:

- **پایش (Monitor):** سنسورها وضعیت محیط فیزیکی، زیرساخت و خود سیستم را به صورت زمان حقیقی استخراج می‌کنند.
- **تحلیل (Analyze):** داده‌های پایش شده را پردازش کرده و مشخص می‌کند که آیا انحرافی از اهداف کیفی و کمی سیستم رخ داده است و نیاز به اعمال تغییر وجود دارد یا خیر.
- **برنامه‌ریزی (Plan):** در صورت نیاز تطبیق، راهکارها و استراتژی‌های موجود (گزینه‌های وفقی) مقایسه شده و گزینه بهینه برای شرایط فعلی برگزیده می‌شود.
- **اجرا (Execute):** استراتژی برنامه‌ریزی شده در قالب یک سری از دستورات اجرایی از طریق عملگرها (Actuators) بر روی سیستم اعمال می‌گردد.
- **دانش (Knowledge):** به عنوان حافظه مرکزی عمل کرده و اطلاعات، مدل‌ها و داده‌های بین چهار مرحله قبلی را هماهنگ و نگهداری می‌کند. راهکار پیشنهادی ما (RS-DRL) مستقیماً به عنوان هسته اصلی بخش برنامه‌ریزی در این الگو فعالیت می‌کند.

۲-۲-۲ چالش‌های عدم قطعیت در زمان اجرا

عدم قطعیت در سیستم‌های خودوفقی، به هرگونه انحراف از دانش قطعی اطلاق می‌شود که می‌تواند باعث کاهش اطمینان نسبت به تصمیمات زمان اجرا گردد [۱۰].

به عنوان نمونه‌های عینی، می‌توان به موارد گوناگونی در دامنه‌های مختلف اشاره کرد: در برنامه‌های مبتنی بر اینترنت اشیاء (IoT) که در محیط‌های شهری پراکنده هستند، تغییرات مداوم و غیرقابل پیش‌بینی آب و هوا منجر به افت کیفیت سیگنال و اختلال در ارسال اطلاعات سنسورها می‌شود. در محیط‌های ابری، نوسان شدید در تقاضای منابع از سوی کاربران، و در حوزه‌های امنیتی، ظهور بی‌وقفه و تصادفی حملات سایبری از مصادیق برجسته عدم قطعیت هستند.

اهمیت و چالش برانگیز بودن عدم قطعیت از آنجا نشأت می‌گیرد که مفروضات، پیکربندی‌ها و تصمیمات در نظر گرفته شده در فاز طراحی معماری نرم‌افزار را بی‌اعتبار می‌سازد. در نتیجه، سیستم باید قادر باشد با یادگیری آنلاین و پویا در زمان اجرا، اهداف اصلی خود را محقق نماید؛ وگرنه با نقض کیفیت خدمات خدمات سنگین احتمالی را تجربه خواهد نمود.

۲-۳ مدل سازی عدم قطعیت

۲-۳-۱ منابع عدم قطعیت

منابع عدم قطعیت به طور کلی در سه دسته وسیع طبقه بندی می شوند: نخست، نامشخص بودن موجودیت های محیطی نظیر پارازیت در حسگرها، نویزها و تغییرات جوی که از کنترل ساختار درونی سیستم خارج هستند. دوم، ماهیت غیرقابل اتکای منابع خود سیستم مثل نقص در قطعات زیربنایی، کاهش سریع سطح باتری یا مشکلات نرم افزاری تعاملات میان سرویس ها؛ و در نهایت عدم قطعیت در اهداف متغیر و ترجیحات نامشخص ذینفعان در محیط های تجاری.

۲-۳-۲ رویکردهای مدل سازی عدم قطعیت

جهت درک و محاسبه رفتار سیستم در هنگام بروز مقادیر ناشناخته، استفاده از مدل سازی های زمان اجرا (Runtime Models) ضروری به نظر می رسد. در شرایطی که فضای جستجو بسیار بزرگ و ریسک تصمیم گیری به دلیل شرایط مبهم بالاست، رویکرد پیشنهادی از مکانیزم های مدل سازی ریاضی صوری بهره گیری و پشتیبانی می کند.

در این راستا ابزارهایی مانند موتور UPPAAL-SMC و چارچوب ActivFORMS به کار گرفته می شوند. این زیرساخت ها با استفاده از اتوماتای زمان دار (Timed Automata) مدلی رفتاری از سیستم هدف و محیط آن را توسعه داده و از طریق روش های کنترل مدل آماری (Statistical Model Checking) می توانند به سرعت گزینه های وفقی پیشنهاد شده توسط سیستم هوشمند را پیش از اجرا در سیستم فیزیکی ارزیابی، تایید یا رد کنند. این قابلیت نقشی کلیدی در امنیت راهکار پیشنهادی (در بخش تاییدگر گزینه وفقی) این رساله ایفا می کند.

۲-۴ یادگیری تقویتی برای وفقی سازی

۲-۴-۱ اصول یادگیری تقویتی (MDP، یادگیری Q)

یادگیری تقویتی از طریق تعامل مستمر یک عامل (Agent) با محیط اطرافش بر پایه آزمون و خطا بنا شده است و این محیط به لحاظ ریاضی از طریق فرآیند تصمیم گیری مارکوف (MDP) فرموله می شود. فرآیند MDP خود شامل فضای حالت (State)، فضای عمل (Action) و توابع پاداش (Reward) است. در فرآیند تصمیم گیری مارکوف، برای هر حالت خاص، عامل عمل مشخصی را اتخاذ می کند و مطابق

با معادله مشهور بلمن (Bellman Equation) محیط ارزش عمل اتخاذ شده را در قالب یک پاداش ارزیابی می‌نماید و به وضعیت بعدی منتقل می‌شود. این مفهوم در سیستم‌های خودوفقی مانند محیط DeltaIoT به این صورت اعمال می‌گردد که وضعیت سیستم با معیارهایی نظیر انرژی ذخیره شده سیستم و تاخیر اندازه‌گیری شده فضای حالت را تشکیل می‌دهند و اقدام عامل، همان گزینه وفقی مورد انتخاب خواهد بود و محاسبه پاداش نیز طبق معادله بهینه‌سازی سیستم حاصل می‌گردد. نقش الگوریتم مشهور یادگیری Q ایجاد جدولی جامع برای تخصیص و پیدا کردن ارزش‌هاست تا مدل به سیاست بهینه همگرا شود.

۲-۴-۲ یادگیری تقویتی عمیق (DQN) برای فضاهای بزرگ

اما زمانی که با سیستم‌های واقعی که دارای فضای عمل گسسته ولی بسیار پهناور (برای مثال ۴۰۹۶ گزینه وفقی در شبکه‌های اینترنت اشیا) مواجه هستیم، استفاده از متد کلاسیک یادگیری Q با چالش نفرین ابعاد (Curse of Dimensionality) روبه‌رو می‌شود؛ زیرا ذخیره و بروزرسانی جدولی با میلیون‌ها حالت و عمل از لحاظ محاسباتی ناکارآمد و در بسیاری موارد غیرممکن است.

شبکه‌های Q عمیق (DQN) راهکاری هوشمندانه برای این محدودیت ارائه می‌دهند؛ آن‌ها به جای جداول، تابع ارزش کیفیت Q را با استفاده از شبکه‌های عصبی عمیق تقریب می‌زنند. برای غلبه بر بی‌ثباتی آموزش شبکه‌های عصبی در RL، مدل DQN از دو نوآوری برجسته بهره می‌برد: نخست استفاده از مکانیسم حافظه بازپخش تجربه (Experience Replay) که نمونه‌های آموزشی تصادفی‌سازی شده و باعث شکستن همبستگی زمانی متوالی می‌گردد؛ و دوم تعبیه هدف ثابت به واسطه شبکه هدف ثابت (Target Network) که بهبود تثبیت توابع هزینه را در هنگام محاسبه پیش‌بینی‌ها به دنبال دارد.

۲-۴-۳ مفهوم یادگیری مداوم در حلقه‌های وفقی

اصلی‌ترین کاربرد این رساله، ادغام مفهوم آموزش پیوسته و مداوم توسط عامل DQN در چارچوب معماری خودوفقی و به طور خاص درون حلقه MAPE-K (همانطور که در فصل ۴ و شکل ۴ از مقاله [۹] به تفصیل نشان داده خواهد شد) است. پس از جاگذاری در مؤلفه برنامه‌ریزی (Planner)، عامل یادگیرنده وضعیتی را به عنوان ورودی فضای حالت از مازول پایش دریافت نموده، استراتژی اقدام را برنامه‌ریزی کرده و بر اساس میزان موفقیت انتخابش از سوی مؤلفه تحلیل پاداش می‌گیرد. این ساختار تعاملی، سیستم خودوفقی را از پیکربندی ایستا به ساختار یادگیری پویا تبدیل می‌سازد.

۵-۲ کارهای مرتبط: مدیریت فضاها و فقی بزرگ

دستیابی به کارایی مناسب در مدیریت محیط‌های مبهم بسیار کلیدی است. برای تبیین عمیق این مباحث، در ادامه به مقایسه انتقادی دسته‌بندی‌های موجود می‌پردازیم.

۱-۵-۲ روش‌های مبتنی بر یادگیری ماشین (ML-based Methods)

اولین دسته‌بندی کارهای مرتبط در به‌کارگیری یادگیری ماشین نظارت‌شده و پیش‌بینی‌کننده با هدف هرس و کاهش فضای جستجو متمرکز است. رویکرد محققانی چون کین (Quin) و همکارانش [۱۰، ۱۱] و مدل یادگیری برای ارزیابی کیفی ماشین (ML4EAS) توسعه یافته توسط کاجی و بواناکا [۱۲] نشان می‌دهند که الگوریتم‌های طبقه‌بندی و رگرسیون قادرند تعداد زیادی از گزینه‌های غیربهبه را تا پیش از ارسال به مؤلفه تحلیل‌گر، غربال کنند.

نقد رویکرد: اگرچه این روش‌ها در کاهش اندازه محیط عمل خود کارا هستند، اما وجود وابستگی بنیادین به مجموعه داده‌های با برچسب آموزش دیده، نقص متدولوژی است. تهیه مجموعه داده در زمان توسعه که همسان با متغیرهای غیرمترقبه واقعیت باشد غیرعملی است. متعاقباً با بروز رانش مفهومی (Concept Drift) ناشی از تغییر مداوم شرایط محیطی، این مدل‌های پیش‌آموزش دیده، عملکرد تعمیم یافته و کارآمد خود را در برخورد با رویه‌های ناشناخته از دست می‌دهند.

۲-۵-۲ روش‌های مبتنی بر جستجو (Search-based Methods)

متدولوژی کلاسیک دیگر برای پیمایش سریع فضاها و وسیع جستجو استفاده از راهبردهای اکتشافی است. برای مثال استفاده کوکر (Coker) از الگوریتم صعود تپه (Hill Climbing) [۱۳] و برنامه‌ریزی‌های مبتنی بر الگوریتم ژنتیک (Genetic Programming) که به قلمرو مقالات کینر (Kinneer) و همکاران اختصاص دارد [۱۴، ۱۵، ۱۶]. همچنین شبیه‌سازی جستجو با استفاده از رویکرد تکامل چند هدفه نظیر MOEA توسط چن (Chen) [۱۷]، از کاربردهای متداول است.

نقد رویکرد: هرچند ویژگی انطباق خودکار بدون آموزش در این رویکرد به چشم می‌خورد، اما چالش مقیاس‌پذیری، مانع استقرار کامل آن‌ها در پروژه‌های بلادرنگ است. اجرای مجدد جمعیت تکاملی همچون ژنتیک برای یافتن سناریوی مطلوب در پی هر گونه تطابق زمانی، مستلزم محاسبات بی‌نهایت پرهزینه و ایجاد تاخیر زیاد است؛ موضوعی که در شبکه‌های حساس تاخیرپذیر غیرقابل تحمل است.

۳-۵-۲ روش‌های مبتنی بر یادگیری تقویتی (RL-based Methods)

پیشرفت‌های حاصل شده در اتوماسیون برخط سیستم‌ها با کارهای کیم و پارک [۹]، متزگر [۹] و مدل RLMC توسط کامارا [۹] به دلیل تعامل بی‌وقفه پویایی‌های آنلاین شناخته شده است که عمدتاً براساس کلاسیک الگوریتم Q-Learning توسعه یافتند.

نقد رویکرد: الگوریتم کلاسیک در ابعاد بزرگ، همانند شبکه‌ای با میلیاردها ماتریس برای مدل‌سازی از پای در می‌آید و ناتوان از رسیدگی است. حتی تلاش‌هایی که با مدل پایه ارزیابی ما یعنی معماری حریصانه کلاسیک DQN با استراتژی ϵ -greedy صورت پذیرفته است، کماکان با مشکل شدید محدودیت روبه‌رو است؛ زیرا مدل پایه عامل هوشمندی را پرورش می‌دهد که اغلب در نقاط و قله‌های بهینه‌های محلی (Local Optima) متوقف شده، مانع قابلیت یافتن قله‌های اصلی (Global Optima) در دینامیک شرایط محیط می‌گردد.

۴-۵-۲ شکل‌دهی پاداش و بازپخش تجربه با نگاه به گذشته (Reward Shaping & HER)

(HER)

بازپخش تجربه‌های ناموفق از موضوعات بسیار داغ در حوزه هوش مصنوعی بوده که مکانیزم مشهور یادگیری با نگاه به گذشته (HER) [۹] و مدل متأخر با رویکرد پاداش نرم‌تر (Soft HER) [۹] با استفاده از استراتژی برچسب‌گذاری مجدد هدف برای تجربیات ناموفق توانسته یادگیری محیط‌ها را سریع‌تر نمایند.

نقد رویکرد انطباق با این حوزه: برتری این مدل‌های عمیق کاملاً محدود به طراحی‌های وابسته به هدف و صریح (Goal-Conditioned Environments) می‌باشد. به عبارت دیگر عامل باید یک مکان یا وضعیت شفاف (مانند موقعیت سه‌بعدی ابزار مکانیکی) را تصرف کند؛ در حالی که کنترل‌کننده‌های سیستم‌های خودوفقی اساساً و غالباً اهدافی به عنوان متغیر قطعی را دنبال نمی‌کنند، بلکه نگه‌داشتن انرژی یا تاخیر شبکه در حداقل‌ها یک سیاست آستانه‌محور است که با استراتژی تغییر برچسب و ارزیابی در بازتولید HER با سازگاری اساسی تناقض دارد.

۲-۶ سنتز و شناسایی شکاف تحقیقاتی

با استناد به مطالب شرح داده شده و مروری جامع در کاستی مقالات پیشین، درمی‌یابیم که هیچ‌یک از دسته‌بندی‌های فعلی قادر به برطرف ساختن کل چالش‌ها به صورت جامع نبوده‌اند: راهکارهای یادگیری ماشین به پدیده‌های پیش‌بینی‌نشده محیط به دلیل فقدان آموزش آفلاین به شدت حساس و شکننده‌اند؛ مسیرهای اکتشاف جستجو با تاخیر غیرقابل پذیرش روبرو می‌باشند. حتی اگر از رویکردهای DRL پایه بهره بگیریم،

مستعد توقیف در استثنائات محلی بوده و قابلیت فراگیری جامع در مقابل نوسانات متغیر محیطی را متجلی نمی‌کنند. علاوه بر این ابزارهای پیشرفته مانند تخصیص مقاصد بازپخش گذشته امکان استفاده‌ی کارآمد مبتنی بر اهداف نامشخص سیستم خودوفقی را دارا نیستند.

بر این اساس یک شکاف علمی و عملی مشخص برای ابداع چارچوبی مبرهن مطرح است که دارای ویژگی‌های زیر باشد: (۱) تسلط اثربخش در فضاها و وسیع و گسترده و فقی بدون استفاده از جداول سنتی مقیاس ناپذیر، (۲) فراگیری هوشمندانه برخط بدون اجبار استفاده از داده‌های آموزش دیده‌ی گذشته، (۳) مقابله سرسختانه با بهینه‌های محلی بدون از دست دادن همگرایی و افت در محیط تغییر یافته (نیاز به شکل‌دهی استراتژی آموزش)، و (۴) قابلیت پیوستگی با نیازهای غیرخطی یک سیستم خودوفقی بدون تغییر پارادایم تحمیلی به مسائلی متمرکز به تعیین هدف.

پیشنهاد بنیادی ما در این رساله مبتنی بر ایجاد یک مکانیزم جدید تلفیقی تحت عنوان یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) است تا خلأ یاد شده کاملاً پر گشته و گامی کاربردی جهت ارتقای استقلال عوامل کنترلی نرم‌افزارهای پیچیده میسر گردد.

۲-۷ خلاصه فصل

این فصل در آغاز، با ترسیم بنیان‌های نظری مفاهیم یک سیستم پایدار و مکانیزم MAPE-K و تشریح ماهیت مدل‌سازی عدم قطعیت با ساختار زمان‌اجرا بنا گردید. به تبع آن ضمن تشریح کارکردهای یادگیری تقویتی متدهای عمیق پیوستگی استراتژی پیشنهادی، محدوده‌های فعلی در مقابله با چالش مقیاس‌پذیری نمایان شد. در خاتمه، بر پایه ارزیابی تحلیلی در سابقه کارهای تحقیقاتی پیشین مشخص گردید، فقدان یک مکانیزم هوشمند برای شکل‌دهی تصادفی برخط کاملاً مشهود است که در فصل آتی با مدل سیستم و فرمول‌سازی مسئله پیش‌نیازهای ساخت آن تنظیم می‌گردد.

فصل ۳

مدل سیستم و فرمول بندی مسئله

۱-۳ مقدمه

برای توسعه یک راهکار مبتنی بر یادگیری تقویتی به منظور مدیریت عدم قطعیت در سیستم های خودوفقی، ابتدا باید یک مدل صوری از مسئله وفقی سازی (تطابق) بنا نهیم. این فصل، مدل سیستم و فرمول بندی ریاضیاتی که بستر رویکرد پیشنهادی ما (RS-DRL) را تشکیل می دهد، ارائه می نماید. ما با معرفی DeltaIoT - یک نمونه بارز از شبکه های حسگر بی سیم که چالش های کلیدی فضا های وفقی بزرگ و عدم قطعیت های محیطی را به صورت آشکار به نمایش می گذارد - بحث را آغاز می کنیم.

سپس مسئله وفقی سازی را به عنوان یک فرآیند تصمیم گیری مارکوف (MDP) فرمول بندی کرده و فضای حالت، فضای عمل و تابع پاداش را برای سناریو های بهینه سازی تک هدفه و چند هدفه تعریف می کنیم. نهایتاً، مسئله یادگیری یک سیاست وفقی بهینه را که می بایست در شرایط متغیر زمان اجرا و به طور مداوم عمل کند، به صورت صوری بیان می نماییم.

۲-۳ مطالعه موردی انگیزشی: سیستم DeltaIoT

۱-۲-۳ مرور کلی سیستم و منابع عدم قطعیت

سیستم DeltaIoT یک شبکه حسگر بی سیم (WSN) با تعاملات پیچیده است که به صورت گسترده به عنوان یک محک استاندارد (Benchmark) برای ارزیابی سیستم های خودوفقی به کار می رود [۹]. این شبکه بسته به نسخه مورد استفاده، مابین ۱۵ تا ۳۷ گره (سنسور) دارد. دو منبع اصلی عدم قطعیت در این سیستم در زمان اجرا بروز می یابند:

۱. نویز و تداخل شبکه (Network Interference/Noise): تغییرات محیطی و مداخلات پیرامونی که موجب نوسانات پیش‌بینی‌نشده در کیفیت ارتباطات از -40dB تا +15dB می‌گردد.

۲. تغییرپذیری بار پیام‌ها (Message Load Variability): نوسان در تعداد پیام‌های تولید شده توسط هر سنسور (بین ۰ تا ۱۰ پیام) با الگوهای انتقال متفاوت در طول زمان.

همانطور که در مطالعات پیشین (و روند نشان داده شده در شکل ۲ مقاله مرجع) نمایان است، این عدم قطعیت‌ها باعث شکل‌گیری افت شدید عملکرد سیستم در طی چرخه‌های وفقی گشته و اهمیت حیاتی مکانیسم‌های تطابق پویا را برجسته می‌کنند.

۲-۲-۳ فضای وفقی و بازنمایی پیکربندی

فضای وفقی (Adaptation Space) دربرگیرنده مجموعه تمامی گزینه‌ها و پیکربندی‌های ممکن است که سیستم می‌تواند در زمان اجرا اتخاذ نماید. در DeltaIoT، سه نسخه متفاوت با مشخصاتی به شرح زیر طراحی گردیده است [۹]:

- DeltaIoTv1: شامل ۱۵ سنسور و دارای ۲۱۶ گزینه وفقی متمایز.
- DeltaIoTv1.1: شامل ۱۶ سنسور و دربرگیرنده ۱۲۹۶ گزینه وفقی است.
- DeltaIoTv2: نسخه وسیع‌تر این شبکه متشکل از ۳۷ سنسور که دارای فضای عظیم متشکل از ۴۰۹۶ تصمیم ممکن می‌باشد.

هریک از این گزینه‌های وفقی در حقیقت ترکیبی از پارامترهای مختلف هستند؛ نظیر سطوح توان انتقال انرژی (Transmission Power) برای سنسورهای مشخص و توزیع نسبی مسیرهای شبکه‌ای (Link Distribution). انتخاب یک ترکیب از این پارامترها، یک پیکربندی کاملاً جدید و واحد را شکل می‌دهد.

۳-۳ مدل صوری برای تصمیم‌گیری خودوفقی تحت عدم قطعیت

برای امکان‌پذیر کردن یادگیری تقویتی، نیاز به فرمول‌بندی مسأله تطابق شبکه در قالب یک فرآیند تصمیم‌گیری مارکوف (MDP) داریم که نمایانگر چهارگانه (S, A, R, P) است [۹].

۱-۳-۳ تعریف فضای حالت

فضای حالت مدل، وضعیت فعلی و پویای سیستم را با اندازه‌گیری سه معیار حیاتی عملکرد بازتاب می‌دهد. به بیان رسمی:

$$S = \{(E, P, L) \mid E \in \mathbb{R}, P \in [0, 100], L \in [0, 100]\}$$

که در آن:

- انرژی مصرفی (E): مقدار حقیقی نمایانگر انرژی کل مصرفی توسط تمام سنسورهای شبکه در چرخه پیشین است.
- تلفات بسته‌های شبکه (P): درصدی از پیام‌های تولید شده که در طول مسیر به مقصد (دروازه اصلی) از دست رفته‌اند (بین ۰ تا ۱۰۰ درصد).
- تاخیر ارسال (L): معیاری معادل زمان مورد نیاز جهت رسیدن اطلاعات از سنسورها به گیت‌وی (حداکثر بازه ۱۰۰).

این سه متغیر مقداری به این دلیل انتخاب شده‌اند که تصویر کاملی از نیازمندی‌های کیفی (QoS) شبکه را در یک سیستم توزیع شده با منابع محدود ارائه کرده و ارزیابی صحیحی برای عامل تصمیم‌گیرنده (Agent) فراهم می‌کنند.

۲-۳-۳ فضای عمل: گزینه‌های وفقی گسسته

فضای عمل شامل تمامی استراتژی‌ها و پیکربندی‌های ممکن به صورت مجموعه‌ای از گزینه‌های گسسته تعریف می‌شود:

$$A = \{a_1, a_2, \dots, a_n\}$$

همان‌طور که پیش‌تر اشاره شد، مقدار n بسته به ابعاد شبکه DeltaIoT برابر با ۲۱۶، ۱۲۹۶ یا ۴۰۹۶ در نظر گرفته می‌شود. هر عمل a_i نمایانگر یک پیکربندی مشخص از پارامترهای $\{p_{i1}, p_{i2}, \dots, p_{im}\}$ است که در آن هر پارامتر p_{ij} می‌تواند از مجموعه مقادیر محدود $\{v_{ij1}, v_{ij2}, \dots, v_{ijk}\}$ تبعیت کند. این پارامترها در واقع توان ارسال سنسورها، توزیع لینک‌ها و مسیر یابی هر سنسور را تغییر می‌دهند.

۳-۳-۳ فرمول بندی تابع پاداش

محاسبه صحیح تابع پاداش برای هدایت سیستم به سمت مقاصد از پیش تعیین شده، عاملی کلیدی محسوب می‌شود. بر اساس ماهیت سیستم و اهداف، ممکن است با بهینه‌سازی‌های تک‌هدفه، چندهدفه و یا اهداف آستانه‌ای مواجه شویم.

۱-۳-۳-۳ فرمول بندی پاداش چندهدفه

برای متوازن‌سازی رفتار سیستم حین برخورد با اهداف متعارض در طول چرخه خودوفقی، یک تابع پاداش بهینه‌سازی چندهدفه ارائه می‌گردد:

$$R = w_E \cdot \left(\frac{E_{max} - E}{E_{max} - E_{min}} \right) + w_P \cdot \left(\frac{P_{max} - P}{P_{max} - P_{min}} \right) + w_L \cdot \left(\frac{L_{max} - L}{L_{max} - L_{min}} \right)$$

در این نگاشت، ضرایب وزن‌دهی ($w_E + w_P + w_L = 1$) میزان اهمیت هر هدف را نشان می‌دهند و هر ترم موجود با استفاده از کران‌های بالا و پایین هر معیار محدودیت‌ها را بین بازه $[0, 1]$ نرمال‌سازی می‌کند.

۲-۳-۳-۳ فرمول بندی پاداش تک‌هدفه

زمانی که اولویت طراحی تنها برای غلبه بر یک مشکل واحد تعریف گردیده (مانند بهینه‌سازی صرفاً مصرف انرژی)، تابع فوق بدین شکل ساده‌سازی می‌گردد:

$$R = \left(\frac{E_{max} - E}{E_{max} - E_{min}} \right) \cdot w_E$$

در این معادله بقیه وزن‌ها معادل صفر در نظر گرفته شده‌اند که سبب هدایت بدون واسطه سیستم برای ارتقای سریع ویژگی هدف‌گذاری شده می‌شود.

۳-۳-۳-۳ پارامترهای پاداش برای اهداف آستانه‌ای (TTS و TT)

برای مسائلی که نیازمند کنترل مطلق اهدافی در سطح استثنای کیفی قابل قبول (Thresholds) هستند (که در جدول ۲ مقاله با نام‌های TTS و TT نام برده شده‌اند)، تخصیص مقادیر پاداش مشروطی به صورت دودویی (Binary) اعمال می‌گردد:

$$R = \begin{cases} 1 & \text{اگر } P < \theta_P \text{ و } L < \theta_L \\ 0 & \text{در غیر این صورت} \end{cases}$$

که در آن مقادیر مرزی θ_P و θ_L به عنوان آستانه‌های از پیش تعیین شده معرفی شده‌اند. جدول ۳-۱ خلاصه مقادیر TTS و TT (تنظیمات اهداف آستانه‌ای و ترکیبی) را پیرامون معماری این نسخه‌ها نمایش می‌دهد:

جدول ۳-۱: اهداف کیفی و آستانه‌ای (TTS و TT) سیستم DeltaIoT [۹]

نسخه DeltaIoT	تنظیمات هدف	تلفات بسته (Packet Loss)	تاخیر (Latency)	انرژی (Energy)
DeltaIoTv1	TTS	کمتر از ۱۰٪ (< ۱۰٪)	کمتر از ۵٪ (< ۵٪)	کمینه‌سازی
DeltaIoTv1	TT	کمتر از ۱۰٪ (< ۱۰٪)	-	کمینه‌سازی
DeltaIoTv2	TTS	کمتر از ۱۰٪ (< ۱۰٪)	کمتر از ۵٪ (< ۵٪)	کمینه‌سازی

۴-۳ بیان مسئله: یادگیری سیاست وفقی بهینه با عملیات مداوم در زمان

اجرا

با در نظر داشتن فرمول بندی MDP در نظر گرفته شده، مسئله نهایی ما یادگیری روال سیاست وفقی بهینه $\pi^* : S \rightarrow A$ است. انتظار سیستم از این سیاست به حداکثر رسانی ارزش پاداش‌های تجمعی تنزیل یافته (Cumulative Discounted Reward) است:

$$\pi^* = \arg \max_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid \pi \right]$$

در معادله فوق، مقدار $\gamma \in [0, 1)$ ضریب تنزیل را معرفی می‌نماید. عملکرد موثر این سیاست بهینه باید همواره به طور مداوم و لاینقطع در زمان اجرا عمل کند و مکرراً با چالش‌های زیر روبرو گردد:

۱. عدم قطعیت محیطی: بار متغیر پیام‌ها و همچنین تداخل‌های ناپایدار و اختلال متناوب خطوط.
۲. فضای عمل گسترده گسترده: مدیریت فضای مقیاس‌پذیری که بسته به نسخه شبکه می‌تواند تا سقف ۴۰۹۶ تصمیم ممکن وسیع باشد.
۳. پویایی غیرایستا (Non-stationary dynamics): نیاز به تطبیق مداوم و عدم کاهش سرعت واکنش به علت تغییرات شرایط از یک چرخه وفقی به چرخه بعدی (تخریب و کاهش عملکرد نشان داده شده در شکل ۲ مقاله مرجع).

۳-۵ خلاصه فصل

فرآیند صورت بندی و مدل سازی در این فصل، زمینه ساز توسعه راهکار عملی این رساله گشته است. ما در این بخش ابتدا مطالعه موردی سیستم DeltaIoT را شرح داده و ابعاد گوناگون فضای وقتی گسسته آن را تشریح نمودیم. در ادامه این مسأله با تمرکز به مدل تصمیم گیری مارکوف ساختاریافته شامل فضای وضعیت شبکه، اعمال تصمیم سازی و توابع پاداش های چندگانه برای بهینه سازی فرموله گردید.

تکمیل این چارچوب رسمی، قابلیت و ظرفیت یادگیری استراتژی های وقتی و منطبق با متد یادگیری تقویتی را فراهم می آورد. این پایه گذاری با اهمیت به ویژه به واسطه توصیف اهداف مشخص، در فصل آتی (به عنوان طراحی متد ابتکاری RS-DRL) زمینه ساز توسعه راهکار خروج از بهینه های محلی با بهره گیری از شکل دهی تصادفی پاداش برای مدیریت عدم قطعیت خواهد بود.

فصل ۴

روش پیشنهادی RS-DRL: معماری و مدل فرآیندی

۴-۱ مقدمه و چشم‌انداز معماری

در فصل پیشین نشان دادیم که مدل‌های مرسوم یادگیری تقویتی، توانایی لازم برای پاسخ‌گویی به فضاهای بسیار بزرگ و گسسته تطابق را در زمان اجرای سیستم‌های خودوقتی ندارند و رویکردهای موجود اغلب در قله‌های محلی (Local Optima) متوقف می‌شوند. همچنین آموزش مجدد مدل در زمان اجرا فرآیندی پرهزینه است و اتلاف وقت قابل توجهی برای یافتن گزینه‌های بهینه می‌طلبد.

این فصل به ارائه معماری و مدل فرآیندی سیستم خودوقتی مبتنی بر راهکار «یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش» (RS-DRL) اختصاص دارد. تمرکز اصلی این بخش بر سازمان‌دهی در سطح سیستم، جریان کنترلی زمان اجرا (Runtime) و الگوهای تعاملی مؤلفه‌هاست. به منظور ایجاد درک بهتری از نحوه غلبه بر پیچیدگی‌ها، ما از یک ساختار فرآیندگرا (Process-Oriented) استفاده کرده‌ایم—که در آن هر بخش منطقاً پاسخ می‌دهد: «در سیستم چه اتفاقی در حال رخ دادن است و چرا؟» چارچوب شناخته‌شده MAPE-K نیز در اینجا به عنوان یک لنز تشریحی عمل می‌کند تا بخش‌های گوناگون معماری را تفکیک نماید.

۴-۱-۱ مرور کلی بر روش پیشنهادی

روش RS-DRL یک متدولوژی نوین است که بر پایه ارتقای الگوریتم سنتی شبکه‌های دیپ‌کیو (DQN) طراحی شده تا فرآیند بازآموزی سیستم را، بدون نیاز به دانش قبلی یا تکیه بر آموزش‌های آفلاین دشوار، بهبود بخشد. ایده اصلی این روش، تعبیه یک مکانیزم شکل‌دهی پاداش بدیع (Reward Shaping) در طول فاز حافظه

بازپخش تجربه (Experience Replay) می‌باشد. نوآوری کلیدی نهفته در روش پیشنهادی آن است که سیستم زیرمجموعه‌ای از تجربیات شکست‌خورده را به صورت تصادفی به عنوان تجربیات موفق بازطراحی می‌کند تا در فضاهای مبهم با جسارت بیشتری به کاوش (Exploration) بپردازد.


۲-۴ معماری سطح سیستم و حلقه تطبیق (Adaptation Loop)

۱-۲-۴ سیستم مدیریت‌شده و سیستم مدیریت‌کننده

همان‌طور که در معماری سیستم‌های خودوقتی مرسوم است، رهیافت ما نیز از دو بخش مجزا و تفکیک‌شده تشکیل گردیده است:

۱. سیستم مدیریت‌شونده (Managed System): این بخش همان سیستم نرم‌افزاری پایه‌ای است که نیازمند فرآیند وفقی‌سازی (تطبیق) می‌باشد. در روند این رساله، پلتفرم DeltaIoT به عنوان یک شبکه حسگر بی‌سیم، تحت عنوان سیستم مدیریت‌شونده در نظر گرفته شده است که داده‌های محیطی زمان اجرا را تولید می‌نماید.

۲. سیستم مدیریت‌کننده (Managing System): این بخش شامل مکانیزم حلقه کنترل و بازخورد MAPE-K است که به صورت عمیقی با عامل یادگیری تقویتی RS-DRL ادغام یافته تا مدیریت پویای تصمیمات را بر عهده گیرد.



۲-۲-۴ چرخه پیوسته تطبیق (مراحل ۱ تا ۹)

ادغام یک مدل یادگیری تقویتی مانند RS-DRL درون یک سیستم حیاتی، نیازمند یک جریان یکپارچه و امن است. سیستم از طریق یک جریان تطبیقی ۹ مرحله‌ای عمل می‌کند:

۱. مرحله ۱: جمع‌آوری داده‌های زمان اجرا (Runtime data collection)

۲. مرحله ۲: ارسال تفکیک‌شده وضعیت به ماژول RS-DRL

۳. مرحله ۳: آموزش ناهمگام مدل و ذخیره‌سازی

۴. مرحله ۴: ارسال وضعیت به تحلیل‌گر (Analyzer)

۵. مرحله ۵: راه‌اندازی تطبیق توسط تحلیل‌گر

۶. مرحله ۶: بازیابی مدل آموزش‌دیده

۷. مرحله ۷: پیش‌بینی گزینه تطبیقی

۸. مرحله ۸: دریافت دستورالعمل‌های گزینش

۹. مرحله ۹: اجرای قطعی فرامین تطبیقی

یک تصمیم مهم معماری در این روند، جداسازی زمانی (Temporal Separation) قاطع بین «تطبیق زمان اجرا» (مراحل ۱، ۴-۹) و «یادگیری ناهمگام» (مراحل ۲-۳) است. این امر سبب می‌شود سیستم در زمان تأخیرهای مربوط به آموزش مدل‌ها مسدود نگردد و ثبات تضمین شود.

۳-۴ نگاشت معماری پیشنهادی به مدل مرجع MAPE-K

مدل RS-DRL به تنهایی یک معماری کلان محسوب نمی‌شود، بلکه درون حلقه مرجع MAPE-K به عنوان یک سرویس تصمیم‌یار جاسازی شده است. نگاشت مفهومی زیر نقش هر بخش از معماری ما را شفاف می‌نماید:

- پایش (Monitor): شامل مراحل ۱، ۲ و ۴؛ که در آن داده‌های زمان اجرا اخذ شده و بردار فضای حالت استخراج می‌گردد.

- **تحلیل (Analyze):** شامل مراحل ۴ و ۵؛ ارزیابی وضعیت سامانه نسبت به اهداف آستانه‌ای و نقض کیفیت خدمات.
 - **برنامه‌ریزی (Plan):** شامل مراحل ۵، ۶ و ۷؛ استفاده از مدل‌های پیش‌آموزش دیده RS-DRL برای استنتاج تخصصی و انتخاب گزینه‌های وفقی. در اینجا RS-DRL صرفاً به‌مثابه یک ماژول سرویس‌دهنده هوشمند درون برنامه‌ریز عمل می‌کند.
 - **اجرا (Execute):** مراحل ۸ و ۹؛ استقرار و اجرای بی‌درنگ پیکربندی‌های استخراج شده هدف در محیط فیزیکی سیستم مدیریت شونده.
 - **دانش (Knowledge):** مراحل ۳، ۶ و ۸؛ مخزن دانش ما به عنوان پایه همگام‌ساز مدل‌های آموزش‌یافته، تاریخچه فضای حالت محیط و لیست متغیرهای تطبیق در نظر گرفته می‌شود.
- در این نظام کنترلی، فعالیت‌ها با ماهیت‌های زمانی متفاوتی اجرا می‌گردند (همانند پایش پیوسته، تحلیل رویدادمحور و یادگیری کاملاً ناهمگام) که انعطاف‌پذیری سیستم را به حداکثر می‌رساند.

۴-۴ پایش زمان اجرا و ساخت فضای حالت

مراحل تشخیصی سیستم وابستگی شدیدی به درک دقیق محیط بلادرنج، با استفاده از مؤلفه‌های پایش دارند.

۱-۴-۴ جمع‌آوری داده‌ها و استخراج ویژگی

در فرآیند پایش (مرحله ۱ از چرخه تطبیق)، وضعیت فعلی محیط فیزیکی، زیرساخت و خود سیستم به شکل خام ثبت می‌گردد. داده‌های دریافتی از سنسورها معمولاً حاوی نویزهای گوناگونی است که مستلزم پیش‌پردازش (Preprocessing) و استخراج ویژگی برای رساندن به ابعاد یک استاندارد معنادار می‌باشند.

۲-۴-۴ ساخت بردار حالت (State Construction)

در سیستم مدل‌سازی شده پلتفرم DeltaIoT، متغیرهای محیطی استخراج‌شده مستقیماً به الگویی به فرمت زیر تبدیل می‌شوند تا بردار حالت شکل پذیرد:

$$S = \{(E, P, L) \mid E \in \mathbb{R}, P \in [0, 100], L \in [0, 100]\}$$

این نگاشت وابسته به سه ورودی اساسی است:

۱. معیار انرژی (E): استنتاج شده از کل مقدار انرژی مصرف شده (شناور حقیقی).

۲. معیار اتلاف بسته ($P - \text{Packet Loss}$): ضریب درصدی پیام‌های مفقود شده (بازه ۰ تا ۱۰۰).

۳. معیار تأخیر انتقال (L): درصد بالاترین سیگنال‌های دریافتی که بیانگر زمان تأخیر است.

با اتمام ساخت و اعتبارسنجی این بردار فضای حالت، این داده‌ها به عنوان ورودی مشترک برای فازهای بعدی سیستم ارسال خواهند شد.

۴-۵ تحلیل زمان اجرا و راه‌اندازی تطبیق

۴-۵-۱ ارزیابی اهداف کیفی در زمان اجرا

مؤلفه تحلیل‌گر پیرو مرحله ۴ از جریان تطبیقی، مقادیر استخراج‌شده از بردار حالت (نظیر P و L) را بررسی کرده و با خط‌مشی‌ها و محدودیت‌های کیفی توافق‌شده (QoS) مقایسه می‌کند.

۴-۵-۲ راه‌اندازی واکنشی (Triggering)

هنگامی که تحلیل‌گر در می‌یابد اهداف سیستم دچار نقض شده و یا در شرف انحراف می‌باشند (کاهش ظرفیت‌های ارتباطی یا افت شدید منابع)، به صورت رویدادمحور (Event-driven) فرمانی را برای مؤلفه برنامه‌ریز جهت راه‌اندازی تطبیق صادر می‌نماید (مرحله ۵).

۴-۶ برنامه‌ریزی زمان اجرا و پیش‌بینی گزینه تطبیقی

در این مقطع، هدف سیستم یافتن راه‌حل جبرانی از بین گزینه‌های بسیار وسیع (تعداد ۲۱۶، ۱۲۹۶ یا ۴۰۹۶ تصمیم ممکن) است که جستجوی خطی در آن‌ها ناممکن می‌باشد. اینجاست که DQN برای رفع چالش به کار بسته می‌شود.

۴-۶-۱ چرا از عوامل DQN استفاده شده است؟

برای شبکه‌های عظیم و گسسته، عوامل شبکه‌های Q عمیق انتخاب اول هستند به چهار دلیل: (۱) قابلیت پیمایش سریع فضاهای عمل گسسته. (۲) قابلیت بهره‌وری در یادگیری با حافظه بازپخش تجربه. (۳) استفاده

از شبکه‌های هدف ثابت (Target Networks) برای تقلیل نوسانات. ۴) امکان یادگیری در حالت غیرسیاستی (Off-Policy).

۴-۶-۲ بازایی مدل و استنتاج مقادیر Q

بازایی مدل: پس از دریافت سیگنال از تحلیل‌گر، برنامه‌ریز، آخرین نسخه آموزش دیده مدل RS-DRL را از پایگاه دانش فراخوانی می‌کند (مرحله ۶). **ارزایی گزینه‌ها (Pure Inference):** برنامه‌ریز بردار وضعیت را به عنوان ورودی به شبکه عصبی DQN می‌دهد تا مقدار ارزش (Q-value) تمام گزینه‌های تطبیقی در دسترس را تخمین بزند (مرحله ۷). این ارزایی مبتنی بر استنتاج زمان اجراست و در این گام هیچ فرآیند یادگیری صورت نمی‌پذیرد؛ بنابراین، تصمیم‌گیری در کسری از ثانیه رخ داده و سیستم با تأخیر مواجه نمی‌شود.

۴-۷ تأیید صورتی گزینه‌های تطبیقی (Verification)

اعمال استراتژی‌های جدید تطبیقی، به دلیل اتکا بر متدهای تقریب زننده نظیر شبکه‌های عصبی عمیق که در ذیل عدم قطعیت رفتار می‌کنند، همواره نیازمند تضمین ایمنی و تایید صلاحیت صورتی (Formal Verification) هستند. بدین منظور، تصمیم‌گیری پیشنهادی عاملی، بلافاصله در موتور کنترلر UPPAAL-SMC و با بهره‌گیری از شبکه‌های مدل‌سازی اتوماتای زمان‌دار، از طریق اعتبارسنجی آماری مدل (Statistical Model Checking) بررسی می‌گردد. چنان‌چه میزان مخاطره و شانس شکست رویکرد جدید بیشتر از حد آستانه باشد، تغییر متوقف شده، در غیر این صورت برای استقرار نهایی توسط فرآیندگر ActivFORMS به اجرا در می‌آید. این رویکرد به معنای تولید سیگنال پاداش صریح است که مستقیماً به عنوان نتیجه عمل (Reward Generation) ثبت می‌گردد.

۴-۸ اجرا و پیکربندی مجدد سیستم (Execution)

مؤلفه مجری پس از دریافت تاییدیه، برای پیاده‌سازی فیزیکی راهکار مداخله می‌کند. در این مقطع، مجری جزئیات تنظیمات سطح پایین و دستورالعمل‌های خاص آن گزینه تطبیقی را مجدد از پایگاه دانش دریافت می‌نماید (مرحله ۸) و به مجموعه‌ای از فرامین سیستمی قابل اجرا در محیط شبکه محلی (DeltaIoT) ترجمه کرده و روی زیرساخت فعال می‌کند (مرحله ۹). پس از اعمال تنظیمات جدید نظیر تغییر پارامترهای توان انتقال سیگنال روی سنسورها، چرخه بسته شده و سیستم مانیتورینگ کار خود را از سر می‌گیرد.

۴-۹ یادگیری ناهمگام RS-DRL و به روزرسانی سیاست

روند یادگیری مدل سیستم ما کاملاً ایزوله و مستقل از جریان پردازش زمان اجرا نگهداری شده و شامل فعالیت‌های بازپخش تجربه، محاسبه گرادیان، به روزرسانی وزن‌ها و تزریق مدل جدید به پایگاه دانش می‌باشد.

۴-۹-۱ مکانیزم تصادفی سازی و شکل دهی پاداش (Reward Shaping)

متمایزترین عامل سیستم در این است که برخلاف مکانیسم حافظه‌های سنتی که منحصرراً نمونه‌های گذشته را به صورت نمونه برداری یکنواخت (Uniform Sampling) ارزیابی می‌نمایند، مدل معرفی شده، زیرمجموعه‌ای تصادفی از تجربیات تاریخیچه‌دار که مستقیماً در انجام هدف کیفی شکست خورده‌اند ($r = 0$) را استخراج نموده، تغییر داده (برچسب مجدد) و وانمود می‌کند این اعمال با موفقیت آمیز همراه بوده‌اند (تخصیص $r = 1$). الگوریتم؟؟ فرآیند دقیق این تغییرات بر روی مینی‌بچ‌ها را نمایان می‌سازد. این رویه توسط فاکتور شکل دهی ρ کنترل می‌شود.

الگوریتم ۴-۱ شکل دهی پاداش تصادفی (Reward Shaping)

ورودی: مینی‌بچ B ، ضریب شکل دهی ρ

۱: $N \leftarrow |B|$

۲: $K \leftarrow \rho \times N$ {محاسبه تعداد تجربیاتی که باید شکل دهی شوند}

۳: شناسایی تجربیات ناموفق به شرط $r_i = 0$

۴: **if** تعداد تجربیات ناموفق مینی‌بچ $\geq K$ **then**

۵: انتخاب تصادفی از میان K تجربه ناموفق

۶: **for** هر تراکنش انتخاب شده $(s_i, a_i, \cdot, s_{i+1})$ **do**

۷: $r_i \leftarrow 1$ {شکل دهی شکست به موفقیت خوش بینانه}

۸: **for end**

۹: **else**

۱۰: پاداش تمام تجربیات ناموفق حاضر را به مقدار ۱ شکل دهی کن

۱۱: **if end**

۱۲: **return** جریان مینی‌بچ به روز شده B

۲-۹-۴ مقایسه با روش بازپخش تجربه نگاه به گذشته (HER)

روش HER یک مسیر مشهور در حوزه بازیابی مجدد بازپخش حافظه است، اما نیازمند وابستگی‌های شدیدی به تعاریف دقیق مقاصد سیستم (Goal-Conditioned) می‌باشد که تخصیص چنین اهدافی در سیستم‌های مبهم اینترنت اشیا محال است و HER نیازمند تغییرات تحمیلی پیچیده به مسأله می‌باشد. در قیاس با آن، رویکرد تصادفی‌سازی اختصاصی RS-DRL کاملاً رها از ویژگی‌های دامنه‌ای (Domain-Agnostic) عمل کرده و فقط براساس تخصیص توابع خوش‌بینانه کار می‌کند که اثربخشی دوچندانی را در پی خواهد داشت.

۳-۹-۴ الگوریتم جامع و کلان RS-DRL

الگوریتم؟؟ روند کامل به‌روزرسانی استراتژی آموزشی سیستم را نشان می‌دهد.

الگوریتم ۲-۴ الگوریتم یکپارچه یادگیری و به‌روزرسانی RS-DRL	
۱:	راه‌اندازی شبکه Q اصلی و شبکه هدف با وزن‌های مشابه $\theta = \theta'$
۲:	for هر اپیزود تعاملی do
۳:	دریافت حالت اولیه محیط s
۴:	while حلقه اپیزود تمام نشده است do
۵:	انتخاب اقدام انطباقی a با استفاده از سیاست ϵ -گریدی
۶:	اجرای اقدام a ، دریافت پاداش r (از اعتبارسنج) و حالت نهایی s'
۷:	ذخیره‌سازی تراکنش (s, a, r, s') در حافظه بازپخش $\mathcal{D}$
۸:	نمونه‌گیری مینی‌بچ رندوم B از $\mathcal{D}$
۹:	if شرایط لازم برای بروزرسانی شکل‌دهی مهیا باشد then
۱۰:	$B \leftarrow \text{RewardShaping}(B, \rho)$ {فراخوانی منطق شکل‌دهی تصادفی الگوریتم؟؟}
۱۱:	if end
۱۲:	محاسبه اختلافات هدف Q و کمینه‌سازی اختلافات با نزول گرادیان
۱۳:	انتقال درصدی وزن‌های شبکه هدف θ'
۱۴:	تنظیم الوضع فعلی: $s \leftarrow s'$
۱۵:	while end
۱۶:	for end

۴-۱۰ مدیریت دانش و هماهنگی فرآیندها

تمام این زیرسیستم‌های ناهمگن به واسطه یک معماری تعاملی و قراردادهای خواندن و نوشتن مستحکم در حافظه مشترک خود یعنی «مخزن دانش سیستم (Knowledge)» توازن می‌یابند. مدل‌های جدید جایگذاری می‌گردند و بهینه‌سازی‌ها پی در پی برای محیط‌های بلادرنگ اعمال می‌شوند، درحالی که کمترین میزان تداخل بین پایش زمان اجرای پیوسته و آموزش ناهمگام را در پی خواهند داشت.

۴-۱۱ خلاصه فصل

این فصل از طریق یک گذر ساختاریافته و فرآیندگرا از نظریات تا گام‌های عملیاتی، معماری تمام عیاری جهت استقرار هوش مصنوعی تصمیم‌ساز و مدل‌سازی در بطن یک شبکه مدیریت خودوقفی، تبیین نمود. یکپارچگی سیستم MAPE-K با یادگیری هوشمند این قابلیت را ایجاد کرد تا گره‌های شبکه با تصمیم‌گیری زمان‌اجرای مبتنی بر استنتاج خالص و همچنین تایید صوری مدل کنترل شوند. در کنار آن روند ناهمگام مدل یعنی رویکرد ابداعی این رساله به نام RS-DRL مستند گردید که به صورت تصادفی با تخصیص پاداش خوش‌بینانه تجربه ناموفق، از همگرایی به استثنای محلی (Local Optima) ممانعت کرده و سیستم را تشویق به کاوش جسورانه در محیط‌های غیرقابل پیش‌بینی می‌نماید. نشان داده شد این رویکرد اساساً مستقل از دانش از پیش تعیین شده دامنه بوده و دارای تفوق ساختاری نسبت به روش‌هایی چون HER می‌باشد. اثبات‌های عملیاتی این ادعا در فصل بعد که مربوط به ارزیابی تجربی است، با جزئیات تام ارائه می‌گردد.

فصل ۵

ارزیابی تجربی

۵-۱ مقدمه

ارزیابی تجربی نقش پررنگی در تأیید اثربخشی راهکارهای پیشنهادی در سیستم‌های خوددویتی ایفا می‌کند. به دلیل آنکه معماری نوین RS-DRL ادعا می‌کند که می‌تواند بدون نیاز به آموزش‌های پیشرفته و آفلاین، با مدیریت تجربیات ناموفق، بر پدیده بهینه‌های محلی غلبه کند، اعتبارسنجی تجربی این دستاوردها بسیار حیاتی است. در این فصل با بهره‌گیری از سناریوهای متعدد ارزیابی، قابلیت‌های راهکار پیشنهادی را در پلتفرم معتبر شبکه حسگرهای بی‌سیم DeltaIoT مورد سنجش جامع قرار می‌دهیم.

این فصل در راستای پاسخگویی به سوالات تحقیق مطرح شده در فصل اول سازماندهی گردیده و هدف اساسی آن نمایش و اثبات برتری این معماری نسبت به راهکارهای پایه و مرسوم موجود است. ساختار فصل بدین گونه است که در ابتدا اهداف ارزیابی تبیین گشته، سپس تنظیمات، مجموعه داده‌ها و محیط پیاده‌سازی معرفی می‌شوند؛ در گام‌های بعدی ضمن معرفی دقیق معیارهای سنجش، دستاوردها و نتایج به دست آمده در سناریوهای تک‌هدفه و چندهدفه و همچنین تحلیل مقیاس‌پذیری و ارزیابی آماری ارائه خواهد شد.

۵-۲ اهداف ارزیابی و سوالات تحقیق

انجام این ارزیابی تجربی همسو با پرسش‌های اساسی مطرح شده در فصل پیشین، اهداف مشخصی را دنبال می‌کند که در جدول؟؟ نقشه‌برداری شده‌اند:

جدول ۵-۱: هم‌راستایی اهداف ارزیابی با سوالات تحقیق

سوال تحقیق (RQ)	رویکرد ارزیابی
سوال اول: طراحی مکانیزم DRL برای خروج از بهینه‌های محلی	مقایسه منحنی‌های همگرایی (اشکال ۵ و ۶ در مقاله مرجع) در برابر روش‌های پایه و ارزیابی عملکرد مجانبی.
سوال دوم: ادغام شکل‌دهی پاداش با بازپخش تجربه	انجام مطالعه ابلیشن (Ablation Study) در برابر گونه‌های مختلف از جمله HER و Soft HER.
سوال سوم: مدیریت فضاها بزرگ و گسسته تطابق	اجرای تست مقیاس‌پذیری در بسترهای DeltaIoT v1 (۲۱۶ گزینه)، v1.1 (۱۲۹۶ گزینه) و v2 (۴۰۹۶ گزینه).
سوال چهارم: مقایسه RS-DRL با روش‌های پیشرفته موجود	تقابل با روش‌های استاندارد نظیر ϵ -greedy، DLASER+، DQN و ML4EAS (Tables 5-6).

۳-۵. تنظیمات آزمایشگاهی

به منظور فراهم نمودن قابلیت بازتولید (Reproducibility) آزمایش‌ها، جزئیات پیکربندی مطالعه موردی به دقت بیان می‌گردد.

۱-۳-۵ نمونه‌های مطالعه موردی

ما از پلتفرم DeltaIoT به عنوان بستر آزمایشگاهی بهره برده‌ایم. پیکربندی استقرار یافته برای شبکه‌های مورد بحث، مشخصات فضای حالت‌ها و پیچیدگی‌ها در جدول ۵-۲ خلاصه گردیده است:

جدول ۵-۲: نمونه‌های مورد مطالعه سیستم DeltaIoT

نمونه (نسخه)	تعداد سنسورها	اندازه فضای وفقی (گزینه‌ها)	گام‌های آموزش
DeltaIoT v1	۱۵	۲۱۶	۰۰۰،۱۰
DeltaIoT v1.1	۱۶	۲۹۶،۱	۸۰۰،۶۴
DeltaIoT v2	۳۷	۰۹۶،۴	متناسب با مقیاس شبکه

۲-۳-۵ مجموعه داده‌ها

جهت شبیه‌سازی شرایط در زمان اجرا، از ردپاهای محیطی (Traces) مرتبط با سیستم DeltaIoT استفاده شده که شامل اطلاعات چرخه‌های تطابق می‌باشند [۴]. این مجموعه داده، الگوهای تداخلات شبکه‌ای متغیر مابین -۴۰dB تا +۱۵dB را ثبت کرده و همچنین نوسانات مرتبط با بار ترافیک پیام‌ها (بین ۰ تا ۱۰ پیام به ازای هر سنسور) را در طول زمان شامل می‌شود.

۳-۳-۵ پلتفرم پیاده‌سازی

پلتفرم عملیاتی اجرا شده در این تحقیق شامل مجموعه‌ای از پیشرفته‌ترین چارچوب‌های محاسباتی است. برای ایجاد محیط یادگیری تقویتی از کتابخانه استاندارد Gymnasium بهره گرفته شد و پیاده‌سازی شبکه‌های DQN بر روی چارچوب مشهور Stable-Baselines3 انجام شده است. در دل این پیاده‌سازی، مکانیزم بومی شکل‌دهی پاداش تصادفی به صورت مستقیم به درون حافظه بازپخش (Replay Buffer) تزریق گشته است. به منظور اعتبارسنجی صوری و ایمنی گزینه‌های تطبیق‌یافته نیز موتور UPPAAL-SMC و مؤلفه واسط ActivFORMS نقش رابط‌های کنترلی را ایفا می‌کنند.

۴-۵ روش‌های پایه و مقایسه

جهت ارزیابی عملکرد و تفوق رویکرد RS-DRL، آن را با گستره‌ای از متدهای موجود بررسی نموده‌ایم. مقایسه در سه دسته‌بندی هدف‌گذاری به شرح زیر صورت گرفت:

- **مقاصد کمینه‌سازی (Minimization Goals):** برای این منظور مدل در برابر عامل استاندارد یادگیری پایه، نظیر ϵ -greedy DQN و همچنین در برابر ترکیبات RS-DRL با استراتژی‌های مشهوری چون HER (RS-DRL-with-HER) و Soft HER قرار گرفت.
- **مقاصد ترکیبی اهداف آستانه‌ای محدود (TTS Goal):** برای ارزیابی کیفی، الگوریتم‌های شناخته‌شده‌ای همچون DLASER+ و یک سیستم مرجع (Reference) که بر پایه جستجوی کامل و جامع تمامی حالت‌ها (Exhaustive Search) استوار بود، مورد ارزیابی قرار گرفت.
- **مقاصد آستانه‌ای مطلق (TT Goal):** راهکار پیشنهادی در تقابل با مدل‌های یادگیری پیشرفته همچون ML4EAS (Machine Learning for Evaluating Adaptation Space)، نسخه اولیه DLASER+، DLASER+ و روش مرجع سنجیده شد.

نکته کلیدی در خصوص انطباق روش‌های HER: ذکر این نکته حائز اهمیت است که مدل‌های HER و Soft HER اساساً برای محیط‌های مبتنی بر هدف‌های صریح (Goal-Conditioned Environments) طراحی و تنظیم گشته‌اند. با این وجود برای فراهم کردن بستر مقایسه علمی در محیط‌های نرم‌افزاری شبکه همانند DeltaIoT، ما این راهکارها را متناسب‌سازی کرده و با در نظر گرفتن آستانه‌های تعریف شده اهداف کیفی (QoS) به عنوان اهداف جایگزین (Proxy Goals)، فرآیند تغییر مرجع مجدد (Relabeling) را بر اساس آنها شبیه‌سازی کردیم.

۵-۵ معیارهای ارزیابی

در راستای متدولوژی‌های سنجش استاندارد موجود، ارزیابی این رساله بر محور دو گروه دسته‌بندی استوار گشته است:

۱-۵-۵ معیارهای عملکرد یادگیری عامل هوشمند

این معیارها برای بررسی روند یادگیری سیستم استفاده می‌شوند:

۱. **عملکرد مجانبی (Asymptotic Performance):** این سطح، وضعیت نهایی‌ترین ارزش و کیفیتی است که عامل پس از دریافت آموزش کافی به آن دست می‌یابد. اندازه‌گیری آن به طور معمول بر پایه محاسبه معدل پاداش به دست آمده روی تعداد محدودی از گام‌های نهایی چرخه امکان‌پذیر است.

۲. **زمان تا آستانه (Time to Threshold):** بیانگر تعداد گام‌های زمانی است که عامل نیازمند طی کردن است تا به یک مقدار پاداش از پیش تعیین‌شده همگرا گردد. به عنوان نمونه آستانه مورد قبول در جداول ارزیابی مقداری معادل ۹۰۰ در نظر گرفته شده است.

۳. **عملکرد کل (Total Performance):** تابعی برای ارزیابی جامع که از مجذور عملکرد مجانبی در طی زمان کم شده از جمع کل مقادیر پاداش اخذ شده به دست می‌آید. این فرمول به صورت زیر نمایش داده می‌شود:

$$TP = R_{\infty} \cdot T - \sum_{t=1}^T r_t$$

تفسیر این معیار: به دست آمدن مقادیر مثبت نشانگر آن است که منحنی یادگیری مدل همواره پایین‌تر از سطح آرمانی مجانبی بوده و میل به بهبود و رشد در طول زمان دارد. اما مقادیر منفی حاکی از اوج‌گیری اولیه و سپس افت و همگرایی به سطوح پایین‌تر عملکرد در زمان اجراست.

۲-۵-۵ معیارهای عملکرد سیستم

موارد زیر منعکس‌کننده خروجی نهایی سیستم در ساختار شبکه می‌باشند:

- **تلفات بسته‌های ارسالی (Packet Loss):** درصد پیغام‌هایی که با خطا مواجه شده و به مقصد نمی‌رسند.

- **تاخیر ارسال (Latency):** مدت زمان صرف‌شده برای انتقال اطلاعات به گره مرکزی.

- مصرف انرژی (Energy Consumption): مصرف نهایی انرژی در گره‌های سنسورها پس از اعمال وفقی‌سازی.

۵-۶ نتایج و تحلیل‌ها

این بخش به عنوان قلب ارزیابی رساله، نتایج استخراج شده از شبیه‌سازی‌ها را تدوین و تفکیک نموده است.

۵-۶-۱ منحنی‌های یادگیری و رفتار همگرایی

روند پیشرفت یادگیری الگوریتم در مقایسه با مدل پایه‌ای به وضوح برتری مکانیزم پیشنهادی را تصدیق می‌کند. در تحلیل رفتار شبکه با استفاده از DeltaIoTv1، مشاهده می‌گردد که رویکرد RS-DRL توانسته است ارزش مجانبی بسیار درخشان ۹۹۰۵.۰ را (با خطای انحراف معیار ۰.۲۶۸۰) کسب نموده و در مدت زمان نسبتاً کوتاه ۲۲۶۶ گام (با تحمل خطای ۱۵۰ پیش و پس) به آستانه مطلوب نفوذ کند. در نقطه‌ی مقابل، الگوریتم پایه‌ی حریصانه یعنی ϵ -greedy DQN نه تنها نتوانست از حد مجانبی ۴۵۵۹.۰ فراتر رود، بلکه هرگز موفق به فتح آستانه‌ی در نظر گرفته شده نیز نگردید. دلیل بنیادین این توفیق RS-DRL، آن است که مکانیزم شکل‌دهی تصادفی، به جای اکتفای تنها بر آموزش پایه، با تخصیص پاداش به تجربیات منحصراً ناموفق اجازه می‌دهد این مدل نه تنها به ثبات بالاتری بهبود یابد، بلکه در بالاترین سطح مجانبی با ثبات مطلوبی مستقر بماند و از بهینه‌های محلی فرار کند.

در فضای بسیار پیچیده‌تر با حضور ۱۲۹۶ گزینه تطبیق‌پذیر در بسته‌ی DeltaIoTv1.1، راهکار ما در ۱۹۲۹۶ گام به پاداش عالی ۸۹۸۳.۰ (± ۰.۹۳۲) نفوذ پیدا کرد، در حالی که همه مدل‌های رقیب عملکرد کل ضعیف‌تری را ثبت کرده و هرگز به خط آستانه نزدیک نشدند.

۵-۶-۲ مقایسه عملکرد به ازای هر هدف

به منظور درک دقیق جزئیات کارکرد عوامل کنترلی روی تک‌تک متغیرهای سیستم، به ارزیابی رویکرد پیشنهاد شده با انواع HER پرداختیم:

- بهینه‌سازی چندهدفه (Multi-objective): متد ما توانست به پاداشی معادل ۹۹۰۵.۰ (در شبکه اول) و ۸۹۸۳.۰ (در شبکه دوم) دست یابد در حالی که بهترین انواع HER منحصراً مقادیری مابین ۴۹.۰ الی ۶۱.۰ را ثبت نمودند. علت این افت فاحش در مدل‌های HER را باید در ماهیت وابستگی این

مدل‌ها به تعاریف و تخصیص اهداف صریح، در مقایسه با پویایی اهداف نامشخص اکوسیستم SAS جستجو نمود.

- **مصرف انرژی:** شاخص‌های ارزیابی، مصرف انرژی RS-DRL را با ثبت میانگین ۹۷۵۶.۰ (در v1) و ۹۳۰۱.۰ (در v1.1) بسیار متمایز از مدل‌های پایه (بازه‌ی ۳۹۰.۰ الی ۵۸۰.۰) نشان داد.
- **تلفات بسته‌ها (Packet Loss):** دستیابی راهکار توسعه‌یافته در نگهداری امنیت شبکه‌ها به عنوان عاملی در مرز نزدیک به حالت بهینه؛ ۹۸۵۰.۰ در شبکه اولیه و تغییر آن به وضعیت ۹۱۲۹.۰ در شبکه‌ی پیچیده‌تر دوم.
- **تاخیر (Latency):** شبکه مجهز به RS-DRL موفق‌ترین سرعت رکوردگیری را با معدل ۹۹۶۴.۰ و ۹۰۲۱.۰ منعکس کرد.

۵-۶-۳ ارزیابی مقایسه‌ای در برابر تمام روش‌های پایه

ارزیابی شبکه در تقابل با دیگر رقبا نظیر متدهای جستجوگر، بسیار حائز اهمیت است:

- **نتایج هدف TTS:** تحت شبکه اولیه، مدت RS-DRL از دست رفتگی بسته‌های حاوی پیغام را در مرز ۵۷۸.۱۰٪ متوقف نمود، در حالی که استفاده از ارزیابی جستجوی مرجع (Reference) درصد ۲۳.۱۴٪ و همچنین DLASER+ بالغ بر ۸۹.۱۲٪ اتلاف داشته‌اند. تاخیر ارسال با نرخ ۰.۹۷٪ بسیار بهتر از رقیب اصلی آن یعنی DLASER+ (با ثبت ۸۴۰.۰) کارنامه موفق‌تری از خود برجای گذاشت و متوازن با روش مرجع (۱۰۰.۰) بود. میزان مصرف انرژی (با مقدار ۸۸۲.۱۲) نیز نزدیک به رویکرد مرجع (۱۰۰.۱۳) و DLASER+ (۰.۲۰.۱۳) محاسبه گردید.
- **نتایج هدف TT:** راهکار ما در پلتفرم DeltaIoTv1، به تلفات بسیار کم شبکه (۱۵۳.۷٪) در مقابل بهترین رقیبش یعنی DLASER+ (۹۸۰.۷٪) رسید؛ همچنین در پلتفرم عظیم v2، موفق شد مقدار ۳۳۰.۹٪ را برای این فاکتور ثبت نماید در حالیکه بهترین سیستم هوش ماشینی فعلی (ML4EAS) مقداری معادل ۵۶۰.۱۰٪ ارائه داد.

تنها تفاوت موجود، تخصیص تاخیر در نسخه دوم بود (که RS-DRL تاخیر ۲۵۱.۰ را در مقایسه با ۱۰۰.۰ روش مرجع ثبت نمود)؛ که البته یک طراحی مبتنی بر خط‌مشی به جهت اولویت‌بندی انتقال شبکه و کاهش اتلاف به جای کاهش زمان تاخیر قلمداد می‌شود و نه یک شکست الگوریتمی.

۵-۶-۴ مطالعه ابلیشن: حساسیت به فاکتور شکل دهی ρ

یکی از دستاوردهای علمی مهم این متد، تخصیص استراتژیک ضریب مفقود به تجربیات گذشته بود. در الگوریتم، مقدار کنترل‌کننده ρ تعیین می‌کند تا چه تعداد از تجربیات ناکام ثبت شده در مینی‌بچ (ذخیره شده در حافظه‌ی سیستم)، با ضریب عدد یک (پاداش مثبت تصنعی) جایگزین شوند.

در صورتی که تجربه‌های شکست خورده موجود در حافظه بیشتر از نرخ انتخابی ما باشد، کاملاً به صورت تصادفی تعدادی انتخاب گشته و مجدد شکل دهی می‌گردند و در غیر این صورت روی تمامی آنها شکل دهی پیاده می‌گردد. نکات تحلیلی پیرامون فاکتور: ایجاد یک توازن کلیدی حول فاکتور بسیار مهم است. اگر ρ بیش از حد بالا باشد، عامل با نویز بالا مواجه خواهد شد. متقابلاً مقادیر بسیار پایین نیز به آن معناست که عامل استراتژی جسورانه‌ای برای خروج از بهینه‌های محلی نخواهد داشت و مشابه شبکه‌های پایه فریز می‌شود. این انتخاب تصادفی در کنار توزیع منطقی ρ ، از تناسب بیش از حد (Overfitting) حافظه نیز ممانعت به عمل می‌آورد.

۵-۶-۵ تحلیل مقیاس پذیری

مقایسه نتایج مدل حاکی از پیروزی پایدار آن است. تغییر از یک اکوسیستم ساده متشکل از ۲۱۶ گزینه به مقیاس بسیار وسیع با ۴۰۹۶ تصمیم ممکن، نشان داد مدل پیشنهادی رساله به نحوی قدرتمند برتری‌های خود را همچنان حفظ می‌کند و تنها زمان همگرایی یادگیری (جهش از ۲۲۶۶ به ۱۹۲۹۶ گام در نسخه v1.1) به تبع پویایی‌های اضافه شده افزایش یافته است.

۵-۷ اعتبارسنجی آماری

برای استواری یافته‌های این رساله، نتایج حاصله توسط آزمون‌های دقیق آماری اعتبارسنجی شده‌اند. روش‌شناسی توسعه یافته در ارزیابی شامل حداقل ۳۰ دور اجرای کاملاً مستقل با بذره‌های رندوم، انجام آزمون تی مستقل تک‌نمونه‌ای (One-sample t-tests) با ضریب خطای آلفای برابر ۰.۰۵، و تخصیص فواصل اطمینان ۹۵٪ به روش بوت‌استرپ است. فرمول ریاضی محاسبه آماری به این شکل تنظیم گردید:

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

خلاصه اعتبارسنجی‌ها (بر اساس مقادیر p): از بین مجموعاً ۲۸ مقایسه‌ی متمایز و شاخص، تعداد ۲۵ مقایسه کیفیت الگوریتم توسعه یافته در یک شرایط آماری فوق‌العاده قرار داشتند (۳.۸۹٪ تست‌ها معنادار

بودند). شگفتی زمانی کامل گشت که در پارامتر اتلاف بسته‌های شبکه (Packet Loss) تمام ۱۰۰٪ از تست‌ها ارزش بهبود معنادار ارائه دادند؛ به طور نمونه، احتمال وقوع تصادفی برتری آن برای متد TTS شبکه اول در مقابل مدل‌های DLASER+ و رویکرد مرجع کمتر از ۰۰۱.۰ برآورد گردید ($p < 0.001$). مواردی جزئی نیز که نتایج قابل توجهی نداشتند (مانند آزمون تاخیر که مقدار $p = 0.134$ در شبکه اولیه دریافت نمود یا مصرف انرژی که در حالت TTS مقداری معادل $p = 0.326$ ثبت کرد) عمدتاً به دلیل عملکرد متعادل با روش مرجع بوده و هیچگونه شواهدی مبنی بر تضعیف متد مورد بررسی به دست نمی‌دهد.

۵-۸ خلاصه فصل

این فصل به نحو جامعی توانست ادعاهای نوآوری رساله پیرامون مکانیزم شکل‌دهی یادگیری را تایید نماید. با مرور نتایج مشخص گردید: (۱) متد ابداعی RS-DRL با پایداری ویژه‌ای توانسته تمامی الگوریتم‌های پرآوازه و قدرتمند فعلی پیشین را در ابعاد بهبود عملکرد یادگیری کیفیت و کنترل سیستم شکست دهد. (۲) این برتری در حدود ۳۰.۸۹٪ مواقع توسط تست‌های اعتبارسنجی آماری تأیید گردیده‌اند (۲۵ مورد از ۲۸ مقایسه کلیدی). (۳) این متد ثابت نمود تغییر مقیاس گزینه‌های وفقی از ۲۱۶ به ۴۰۹۶ گزینه نمی‌تواند قابلیت‌های آن را مختل نماید. (۴) مکانیزم شکل‌دهی مجدد توانسته در مقایسه دقیق و عمیق، از وقوع توقف سیستم‌ها در تله‌های استثنای محلی جلوگیری کند و نهایتاً (۵) برخلاف متدهای رایج هم‌نوع پیشرفته خود نظیر مدل‌های HER، برای پویایی پایدار اساساً نیازمند تخصیص دانش سیستم‌ها با دامنه نامشخص (Domain-specific knowledge) و یا اهداف صریح از پیش مقدر نبوده است.

فصل ۶

بحث، کارهای آینده و نتیجه گیری

۱-۶ بحث در مورد یافته‌های کلیدی

این بخش با ترکیب نتایج اصلی و تشریح اهمیت آن‌ها، یافته‌های مستخرج از رساله را مورد ارزیابی عمیق قرار می‌دهد.

۱-۱-۶ نظریه پردازی مکانیزم: چرا RS-DRL کار می‌کند؟

همان‌طور که در نتایج ارزیابی تجربی (مندرج در فصل ۵ و با استناد به شکل‌های ۵ و ۶ در مقاله مرجع [؟]) نشان داده شد، یکی از مهم‌ترین نقاط قوت RS-DRL توانایی آن در فرار از بهینه‌های محلی است که یک چالش جدی و متداول در سیستم‌های DRL محسوب می‌شود. در محیط‌های پویا، پاداش متوسط مدل RS-DRL نه تنها به طور پیوسته افزایش می‌یابد، بلکه در وضعیت پایداری نسبت به رویکرد پایه ϵ -greedy DQN - که با نوسانات شدیدی همراه است و نمی‌تواند از راه‌حل‌های غیربهینه رهایی یابد - در سطحی بسیار بالاتر تثبیت می‌گردد.

اثربخشی رویکرد RS-DRL را می‌توان به سه مکانیزم به هم پیوسته زیر نسبت داد:

۱. اکتشاف از طریق تزریق پاداش خوش‌بینانه: با تغییر تدریجی و تصادفی تجربیات ناموفق گذشته ($r_i = 0$) به تجربیات موفق ($r_i = 1$)، عامل یادگیرنده سیگنال‌های تقویت‌کننده مثبتی را از اعمال و وضعیت‌هایی دریافت می‌کند که در شرایط عادی از اولویت خارج می‌شدند. این امر از همگرایی زودهنگام مدل به سیاست‌های غیربهینه که یکی از معضلات بنیادین DQN استاندارد است، ممانعت به عمل می‌آورد.

۲. شکستن همبستگی زمانی در الگوهای شکست: انتخاب تصادفی در فرآیند تغییر تجربیات مردود (که توسط پارامتر ρ کنترل می‌گردد) متغیری را معرفی می‌کند که مانع از حفظ بیش حد (Overfitting) عامل بر روی شرایط متوالی شکست می‌شود. این متغیر به ویژه در محیط‌های غیرایستایی (Non-stationary) که در آن‌ها شکست دیروز ممکن است استراتژی بهینه امروز تلقی گردد، بسیار راهگشا خواهد بود.

۳. یادگیری مستقل از دامنه (Domain-Agnostic): برخلاف روش‌های متکی به HER که مستلزم تعاریف صریح و قطعی از اهداف هستند، شکل‌دهی تصادفی RS-DRL بدون هیچ‌گونه نیاز به درک معنایی اهداف دامنه عمل می‌کند. این موضوع، اجرای آن را ذاتاً برای سیستم‌هایی انعطاف‌پذیر می‌سازد که با اهداف تلویحی و آستانه‌محور - که در سیستم‌های خودوفقی بسیار شایع می‌باشند - سروکار دارند.

۶-۱-۲ تحلیل تعاملات و مصالحه‌ها (به عنوان مثال، تاخیر در مقابل از دست رفتن بسته)

در جداول مقایسه‌ای پیشین (برای نمونه جدول ۶ در توصیفات ارزیابی)، مشاهده گردید که برای تخصیص هدف TTS در شبکه DeltaIoTv1، مدل RS-DRL به درستی به تاخیر متوازی دست پیدا کرد (مقدار ۰.۹۷۰ در برابر ۱۰۰۰۰ روش مرجع) و در مجموع عملکرد بسیار بهتری در مقایسه با DLASER+ نشان داد. با این وجود، برای شبکه DeltaIoTv2 تحت هدف TT مقدار تاخیر بالاتری حاصل شد (۲۵۱.۰ در برابر ۱۰۰۰۰ روش مرجع).

افزایش تاخیر در نسخه دوم شبکه برای مقاصد مربوط به TT نشان‌دهنده یک مصالحه (Trade-off) بسیار مهم در عملکرد عامل است: هنگامی که هدف کلیدی تعریف‌شده از سوی کاربر (مثلاً حفظ توانایی توان عملیاتی شبکه) با اولویت‌بندی به حداقل رساندن مشکل فقدان بسته توأم گردد، مدل هوشمند درمی‌یابد که باید به منظور جلوگیری از دست‌افتادگی پیام‌ها، به سمت مسیرهای قابل اعتمادتری متمایل شود که به صورت ذاتی کندتر هستند. در محیط‌های بهینه‌سازی چندهدفه، چنین مصالحه‌ای نه تنها یک نقطه ضعف و محدودیت به شمار نمی‌رود، بلکه از قضا یک رفتار برآمده و مطلوب از سوی عامل ارزیابی می‌گردد. چرا که در اینجا اولویت سیستم بر تضمین رساندن بسته‌ها بیش از حفظ سرعت بوده است و در کاربردهایی که صحت اطلاعات در آن‌ها اهمیت حیاتی دارد (مانند مانیتورینگ زیست‌محیطی یا سیستم‌های کنترل صنعتی) این تصمیم به عنوان عاقلانه‌ترین انتخاب مهندسی تلقی خواهد شد.

این رفتار کاملاً با اصول انتخاب بهینه در استراتژی‌های پرتو-اپتیمال (Pareto Optimality) همخوانی دارد. هنگامی که مرزهای متضاد انتخاب‌ها بررسی می‌گردند، تنظیمات دارای تأخیر بی‌نهایت کم‌تر عموماً ارتباط معناداری با نرخ بالای اتلاف بسته‌ها - به دلیل استراتژی‌های تهاجمی‌تر انتقال داده - نشان می‌دهند.

راهکار RS-DRL یاد می‌گیرد این خطِ مصالحه را با ظرافت طی کند و تصمیم‌ها را منطبق بر بستر نیاز و با تخصیص وزن‌های اختصاص یافته برای هر متغیر اخذ نماید.

۶-۱-۳ پیامدهای مهندسی سیستم‌های خودوفقی

ثبات، پایداری و همگرایی سریع متد RS-DRL عوامل حیاتی در محیط‌های پویایی هستند که مقیاس و شرایط آن‌ها به سرعت در حال جابجایی است. از طریق در هم تنیدگی مکانیزم شکل‌دهی پاداش، RS-DRL تضمین می‌نماید که عامل تصمیم‌ساز حتی بدون نیاز به بازآموزی و تخصیص پیکربندی‌های جدید به تغییرات پاسخ می‌دهد، در حالی که در اکثر DRL‌های استاندارد الزام به طی مجدد مسیر آموزش برای اداره کردن امور تغییر یافته، مشهود و گریزناپذیر است. این خصوصیت، این مدل را برای سامانه‌های برخط مانند سیستم‌های ابری و شبکه‌های اشیاء که استقرار و بروزرسانی خودکار استراتژی در آن‌ها واجب است، بسیار متمایز می‌سازد. به بیان دقیق‌تر، پیامدهای عملی این رهیافت برای مهندسی توسعه‌دهنده محیط‌های خودوفقی شامل موارد زیر است:

۱. کاهش قابل ملاحظه سربار عملیاتی: مدل‌های سنتی به هنگام برخورد با رانش و تغییر شرایط محیطی نیازمند صرف چرخه‌های متعدد بازآموزی پیاپی می‌باشند. در حالیکه ویژگی‌های تعمیم‌پذیری بالای RS-DRL امکان دور ماندن مستمر مدل از بروزرسانی‌های مجدد را فراهم می‌سازد که خود علاوه بر صرفه‌جویی شدید محاسباتی باعث جلوگیری از عملکرد ضعیف مدل در طی ادوار گذار بازآموزی می‌گردد.

۲. بی‌نیازی از داده‌های برجسب‌دار: برخلاف مدل‌هایی همانند ML4EAS یا DLASER+ که اتکای گسترده‌ای به تجمیع پیشین داده‌ها داشته‌اند، الگوریتم RS-DRL کاملاً آنلاین و در لحظه توسعه می‌یابد. این قابلیت نقطه قوت برجسته‌ای در محیط‌هایی محسوب می‌گردد که تهیه اطلاعات پیش‌آموزشی غیرممکن و پیش‌بینی‌ناپذیر است.

۳. پایداری و کاهش تخریب تدریجی کیفیت متناسب با گسترش: استواری معنادار کیفیت و عملکرد در مواجهه با نسخه‌ی ۲۰۱۶ - گزینه‌ای (نسخه v1)، گسترش ۱۲۹۶ - گزینه‌ای (نسخه v1.1) و مقیاس سرسام‌آور ۴۰۹۶ حالت ممکن (نسخه v2) مؤید آن است که این راهکار متناسب با میزان گستردگی شبکه قابل استقرار است. همچنین افزایش مقطع زمانی همگرایی مدل، به نسبت پیچیدگی فضای جستجو، شیئی کمتر از حالت خطی (Sublinear) دارد.

۴. تصمیم‌گیری شفاف و قابل مدل‌سازی: رویه‌های رفتارگونه‌ی عامل (همانند پدیده مصالحه در برخورد

با اتلاف دیتا و زمان توقف) به نحو کاملاً معنادار و قابل تعریفی مدل‌گستر و قابل توضیح می‌باشد که این ویژگی به مهندسان قدرت تحلیل مضاعف و قابلیت اطمینان بیشتری عرضه می‌نماید.

۲-۶ محدودیت‌ها و تهدیدات اعتبار (Threats to Validity)

مانند تمامی رهیافت‌های پژوهشی، متدولوژی معرفی شده با محدودیت‌هایی مواجه است که بررسی صریح روایی و صحت نتایج استخراج شده، بستر مناسب را برای پژوهش‌های مکمل آینده تبیین می‌نماید.

۱-۲-۶ اعتبار داخلی (Internal Validity)

۱. حساسیت نسبت به ابرپارامترها: فاکتور کنترل‌کننده‌ی شکل‌دهی تجربیات تصادفی (p)، متولی تنظیم نمودن درصد اختصاص تجربه‌های ناموفق تغییر یافته به نمونه‌های فرضی مثبت و امیدوارکننده است. با اینکه از طریق کاوش شبکه‌ای جامع (Grid Search) توانستیم مناسب‌ترین مقادیر ممکن برای بهینه‌سازی عملکرد یافت کنیم، لیکن این مقادیر می‌توانند به نسبت سایر سیستم‌ها و دامنه‌های متفاوت، دستخوش نوسان باشند. بدیهی‌ست چنانچه پارامتر بسیار بالا وضع گردد موجب اختلال در روند یادگیری گردیده و مقادیر ضعیف آن نیز سبب نقصان در عامل فشار اکتشاف خواهد گشت.

۲. نوسانات بذر تصادفی تولید ارقام (Random Seed Sensitivity): با وجود اجرای بیش از ۳۰ دور فرآیند آموزش مستقل همراه با صحت‌سنجی مستحکم آماری، ماهیت درگیر با احتمالات - چه در پویایی خود محیط و چه در بدنه تنظیم پاداش‌ها - سبب می‌شود تا خروجی‌های هر دوره آموزشی با درجات کوچکی از انحراف واریانس مواجه گردند. با این وصف، فواصل و حاشیه‌های اطمینان به دست آمده (قید شده در جداول فصل ۵) تبیین‌گر کمیت این نوسانات هستند.

۳. مفروضات بازده دودویی (Binary Reward Assumption): یکی از شرایط پیش‌نیاز به کار رفته در الگوریتم، اتکا بر مفروضات مرتبط با نتایج قطعی پیامدهای انطباقی به عنوان اهداف توفیق/سقوط مطلق دودویی (یا در مقیاس‌های استاندارد مشابه) است که نمی‌توان آن را به سهولت با کلیه نیازهای سیستم‌های ترکیبی غول‌پیکر وفق داد.

۲-۲-۶ اعتبار خارجی (External Validity)

۱. تعمیم‌پذیری ساختار و تخصیص حوزه (Domain Specificity): فرآیند تمرکز و سنجش نهایی ارزیابی این رساله منحصراً روی بستر محیط شبکه‌های متراکم و سنسورهای اینترنتی (DeltaIoT)

انجام شد. هرچند پلتفرم مذکور آینه‌ای از مشکلات اساسی سیستم‌های مدرن را به تصویر کشیده و تایید کیفیت کرده است، با این وصف، اعمال الگوریتم توسعه‌یافته بر دیگر شبکه‌های توزیع‌یافته، نیازمند اعتبارسنجی مستقلی خواهد بود.

۲. تمرکز بهینه بر شبکه‌های گسسته: تدوین و صورت‌بندی فعلی به نحوی طراحی گشته که متناسب با فضای تصمیم‌داری مدل‌های محدود گسسته پایه‌ریزی شود. لیکن اکثریت سیستم‌های پویا (مانند سیستم‌های مقیاس‌بندی و تنظیم ظرفیت پردازشی ابری) از پارامترهای پیوسته استفاده می‌نمایند و تنظیم معماری RS-DRL متناسب با متدهای کلاسیک پیوسته نظیر شبکه‌های DDPG ساختارهای بسط یافته مطالعاتی جدیدی را می‌طلبد.

۳. توسعه‌ی در حوزه‌های حساس ایمنی: استفاده از استراتژی خوش‌بینی بر روی اقداماتی که ذاتاً و در دنیای فیزیکی خطرناک بوده‌اند (همانند پلتفرم‌های هدایت اتومبیل‌های هوشمند و یا سیستم‌های دارورسانی)، بدون در نظر گرفتن شرط احتیاط، ممکن است باعث ترغیب ماشین به انجام فعالیت‌های منجر به حادثه گردد و افزودن حلقه‌های تکمیلی تایید صلاحیت بسیار با اهمیت است.

۳-۲-۶ اعتبار سازه (Construct Validity)

۱. شفافیت متریک‌ها: سنجش عملکرد عامل هوش از قبیل بررسی مجانبی ثبات کیفیت زمانی تا رسیدن به راندمان مطلوب آستانه، رویه‌هایی پذیرفته شده می‌باشند؛ اما معرفی فاکتورهای سنجشی جایگزین مانند نرخ رنجوری (رگرت) و شاخص پایداری ممکن است ابعاد ناشناخته دیگری را نمایان سازند.

۲. اصطکاک سنجشی مدل‌های جایگزین: از آنجا که مدل‌های برگرفته از HER نیازمند تنظیم صریح برچسب‌گذاری مقصد بوده‌اند، مقایسه صورت پذیرفته نیاز به در نظر گرفتن جایگزین‌های ضمنی کیفی داشت. هرچند مستندسازی اعمال شده بسیار متوازن بود ولی باید اذعان داشت که استفاده از این مقادیر تعدیل یافته معادل بهینه‌ای برای تمام ظرفیت موجود این دست از رقبا نمی‌تواند قلمداد گردد.

۳-۶ مسیرهایی برای تحقیقات آینده

۱-۳-۶ استراتژی‌های انطباقی و وفقی شکل‌دهی ρ

همان‌طور که در فصل بررسی چالش‌ها بحث گردید، اتکا به متغیر کنترل‌گر ρ برای الگوریتم ضروری است. ما در توسعه‌های آتی در نظر داریم با برنامه‌ریزی یک ساختار هوشمند برای تنظیم نرخ فاکتور کنترل‌کننده متناسب با فرآیندهای زمانی مدل پیشروی کنیم تا قابلیت استقرار در زمان اجرای سیستم را تسهیل نماییم. برخی از جهت‌گیری‌های تخصصی شامل موارد زیر می‌باشد:

۱. برنامه‌ریزی تنظیمی پویای پارامتر (ρ): به جای یک متغیر تنظیم شده دستی، از سازوکاری جهت ارتقا یا تخفیف متغیر بهره خواهیم جست؛ بدین گونه که در هنگامه موفقیت‌های مکرر و تسلط ماشین (فاز استثمار) از درصد فاکتور ρ کاسته شده و در هنگام درگیری مستمر ماشین و گرفتار شدن آن درون تله‌ی بهینه محلی که نرخ دریافت ارزش با فُتول روبرو می‌گردد به صورت پویا با ارتقای متغیر ضریب فشار فرار و اکتشاف تجربیات جدید تشدید شود. در این مسیر استفاده از مدل‌های فرا-یادگیری (Meta-Learning) نیز در خصوص استنتاج بهینه فاکتور مفید فایده خواهد بود.

۲. شکل‌دهی هوشمند بر پایه‌ی خطای عدم اطمینان: امکان به کارگیری ابزارهای ارزیابی تخمین اطمینان (مانند Dropout یا انواع مدل‌های انسامبل) در الگوریتم، مقدور می‌سازد تا آن دسته از تجربه‌های شکست خورده‌ای در چرخه‌ی تصادفی‌سازی اولویت یابند که سیستم درباره‌ی قطعیت خطاهای شان کمترین اطمینان و شناخت را در محیط غیرشناخته از خود نشان داده بود.

۳. اولویت‌بندی حافظه‌ی نمونه‌گیری: ادغام روش انتخاب هوشمند با الگوریتم‌های حافظه‌ی مبتنی بر اولویت (Prioritized Experience Replay)، عاملی را معرفی می‌کند تا زیرمجموعه‌های مردود شده‌ی مستعد جبران پس از اعمال شکل‌دهی، با فرکانس شانس بیشتری برای بازیابی توسط شبکه مجدداً احضار شوند.

۲-۳-۶ گسترش به دامنه‌های پیوسته و حساس به ایمنی

با عنایت به ماهیت پویای فضای نرم‌افزار، توسعه روش‌های حاضر بر مسائل نوین‌تر ضروری خواهد بود:

۱. فضای اعمال پیوسته (Continuous Action Spaces): بسط معماری متدیک فعلی در بطن متدهای قدرتمندتری نظیر سیستم‌های شیب‌سیاستی همانند متدهای PPO و SAC از اهداف توسعه‌ی اصلی

پژوهش است تا علاوه بر شکل‌دهی پاداش تصادفی، بتوان پارامترهای بدون گسستگی (همچون تنظیم منابع سخت‌افزاری پردازش در فضای ابری) را تنظیم نمود.

۲. اعمال محدودیت‌های تایید ایمنی (Safe Reshaping): برای رفع نگرانی مطرح شده در دامنه‌های حساس به ایمنی، در نظر داریم مکانیزمی با عنوان «شکل‌دهی ایمن» پدید آوریم که بازتولید تصادفی نتایج شکست‌خورده تنها زمانی مُیسّر گردد که خط‌مشی پیش‌بینی‌شده در مناطق ایمن تاییدشده قرار گیرد. ترکیب با ابزارهای اعتبارسنجی صوری (همچون UPPAAL-SMC استفاده شده در این تحقیق) از هدایت به وضعیت‌های ناایمن پیشگیری می‌کند.

۳. گسترش به سامانه‌های چند عاملی (Multi-Agent): برای مقابله با فضاهایی با پویایی بخش‌های تطبیقی در حال تعامل با هم، گسترش متد در چارچوبی صورت می‌پذیرد که چند عامل در هماهنگی استراتژی‌های کاوش همسان به شکل‌دهی پاداش‌های منسجم برای تحقق اهداف بزرگ عمل کنند.

۳-۳-۶ اعتبارسنجی بین‌دامنه و تحلیل‌های نظری

جهت بررسی فراگیری این استراتژی و ایجاد پایه‌های نظری قوی‌تر اهداف زیر دنبال خواهد گردید:

۱. پیکربندی شبکه‌های ابری (Cloud Auto-scaling): به‌کارگیری این رویکرد به جهت تخصیص و توزیع مقیاس ماشین‌های مجازی، و ارزیابی در برابر کارهای مرتبط دیگر در این محیط.

۲. هماهنگی وسایل نقلیه خودران (Autonomous Vehicles): آزمایش در محیط‌های شبیه‌سازی برای هماهنگ‌سازی و تطبیق الگوهای ترافیکی با محدودیت‌های ایمنی و اهداف چندگانه (زمان سفر، بهینه‌سازی انرژی و امنیت).

۳. تضمین تئوریک فرآیند همگرایی (Theoretical Analysis): بررسی اینکه آیا سیگنال پاداش شکل‌دهی‌شده ویژگی انقباضی و نگاشت ثابت برای یادگیری کیو (Q-Learning) را حفظ می‌کند، و محاسبه کران‌های خطای احتمالی انحراف ارزش Q نسبت به سیاست بهینه.

۴. کاهش حجم پیچیدگی نمونه‌ها (Sample Complexity Analytical Analysis): کمیت‌بندی تئوریک پیرامون اثربخشی شکل‌دهی پاداش بر تقلیل شمار نمونه‌های لازم برای دستیابی به خروجی‌های نزدیک به بهینه در قیاس با شبکه‌ی DQN استاندارد.

۴-۶ نتیجه‌گیری

۱-۴-۶ خلاصه بیان مسئله و راهکار پیشنهادی

این رساله در قامت دستاوردی متصل بر یکی از چالش‌های بنیادین سیستم‌های خودوقفی مقاصد خود را تنظیم نموده است؛ مدیریت عدم قطعیت در شبکه‌هایی که درون فضاها بزرگ و گسسته‌ی تطابق عمل می‌کنند. رویکردهای سنتی - اعم از مدل‌های مبتنی بر یادگیری ماشین، مدل‌های متکی بر جستجو و یا یادگیری تقویتی استاندارد - با محدودیت‌های شدیدی مواجه بوده‌اند؛ ویژگی‌هایی از قبیل نیاز مبرم به دیتای برچسب‌دار آفلاین، دست و پنجه نرم کردن با فقدان مقیاس‌پذیری و احتمال بالای توقف در بهینه‌های محلی برآمده از تغییر شرایط. ما استراتژی یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) را ارائه نمودیم؛ رویکردی نوین که مکانیسم تصادفی شکل‌دهی را درون جریان حافظه بازپخش عامل کیو (DQN) یکپارچه می‌نماید. با بهره‌گیری از زیرمجموعه‌ای از تجربیات ناکام فاز گذشته ($r_i = 0$) و اعمال تحول در پاداش و تبدیل آن به تجربه‌ای خوش‌بینانه ($r_i = 1$)، راهکار RS-DRL مشوق قدرتمند فرآیند اکتشاف بوده و از گرفتاری در استثنائات محلی جلوگیری می‌نماید، بدون آنکه کمترین الزامی برای تعریف و اختصاص قطعی اهداف مبتنی بر دانش از پیش تعیین‌شده دامنه، داشته باشد.

۲-۴-۶ مرور مشارکت‌ها و شواهد تجربی

یافته‌های مستخرج پژوهش که ارائه‌ی پاسخی قاطع بر پرسش‌های این رساله به شمار می‌آید شامل موارد کلیدی زیر است. جدول؟؟ خلاصه‌ای از این مشارکت‌ها و شواهد را نشان می‌دهد.

جدول ۶-۱: خلاصه‌ای از مشارکت‌های کلیدی و شواهد تجربی

مشارکت (Contribution)	شواهد (Evidence)	اهمیت (Significance)
شکل‌دهی پاداش نوین (Novel Reward Shaping)	توسعه الگوریتم ۲، نمایش در شکل‌های ۵ و ۶	امکان اکتشاف بدون نیاز به دانش دامنه سیستم
تطبیق و وفقی‌سازی مقیاس‌پذیر	مستخرج از جداول ۳ و ۴ (نسخه‌های v1 تا v2)	حفظ پایداری عملکرد با رشد گزینه‌ها از ۲۱۶ تا ۴۰۹۶ حالت
برتری و تفوق اثبات آماری	تحلیل جداول ۵ و ۶، معناداری ۲۵ از ۲۸ تست	دریافت $p < 0.001$ برای اکثر متریک‌های بهبود اتلاف بسته

مشارکت اول: ابداع ماشین نوین جهت شکل‌دهی پاداش توسعه الگوریتم تخصیص پاداش (طراحی الگوریتم ۲) که از طریق کنترل‌کننده‌ای با ضریب مشخص (ρ) عمل نموده و برخلاف رویکردهای غایت‌محور نظیر متدهای HER هیچگونه نیازی بر تعیین هدف آستانه‌ای با درک معنایی نداشته و مستقیماً روی سیستم‌های خودوقفی قابل راه‌اندازی است.

مشارکت دوم: یکپارچه‌سازی حلقه کنترل MAPE-K طراحی زیرسامانه‌ی متصل متشکل از چرخه ۹ مرحله‌ای که RS-DRL را با حلقه MAPE-K ترکیب می‌کرد؛ مجهز به ارزیابی برای تضمین اعتبار زمان اجرا با موتور کنترل UPPAAL-SMC و مؤلفه ActivFORMS برای اجرای وفقی.

مشارکت سوم: دستاوردهای تجربی در مقیاس اینترنت اشیاء دستاورد استقرار شبکه‌ی عامل بر بستر ۳ مقیاس وسیع (فضای محدود ۲۱۶، نسخه ۱۲۹۶ و نسخه منبسط ۴۰۹۶ تصمیم ممکن). دستیابی بی‌رقیب به نرخ مجانبی 0.0268 ± 0.9905 (در شبکه اولیه) و 0.0932 ± 0.8983 (در v1.1) که با قاطعیت ساختار کلاسیک ϵ -greedy DQN (با راندمان 0.2233 ± 0.4559) و مشابه‌های HER را مغلوب ساخت. ثبت کاهش شگفت‌انگیز توالی ۲۳.۲۲٪ برای نابودی بسته‌ها و ۰۷.۳۹٪ کاهش تأخیر شبکه نسبت به DLASER+ تحت اهداف TTS. این مقادیر از طریق نتایج آزمون t-test (موفقیت در ۳.۸۹٪ از ۲۸ مقایسه متمایز) اعتبار مطلق دریافت کرد.

مشارکت چهارم: بینش عمیق نظری و عملی اثبات و آشکارسازی اینکه مکانیزم روایی برای تزریق خوش‌بینی نه تنها راه‌حلی منطقی، خروج سیستم را از گیر افتادن مصون داشته، بلکه تحلیل الگوهای متضاد درون سیستمی نظیر (تأخیر متناقض با نرخ اتلاف بسته‌ها) نشان دادیم عامل استنتاج‌هایی به وسعت دانش طراحی چند-هدفه و سازگار با رفتار سیستم هوشمند اخذ کرده است و همزمان این ظرفیت برای تغییر سائز و پدیده‌ی مقیاس‌پذیری فضای عمل بسیار کارآمد بوده است.

۳-۴-۶ سخنان پایانی

از آنجا که سیستم‌های نرم‌افزاری به طور فزاینده‌ای در محیط‌هایی سرشار از عدم قطعیت، پویایی و مقیاس‌های بزرگ عمل می‌کنند، نیاز به مکانیسم‌های وفقی که بتوانند به طور کاملاً مستقل فرآیند یادگیری و تنظیم استراتژی را انجام دهند چشمگیرتر می‌شود. مدل هوشمند RS-DRL یک قدم استوار در جهت این چشم‌انداز تلقی می‌شود - روشی که نه تنها متکی به آموزش‌های مبتنی بر موفقیت است بلکه با ظرفیتی شایسته، از بطن اشتباهات پیشین درس‌های بسیار موثری اخذ می‌کند و به بیان دیگر کاستی‌های پیشین را به یک فرصت ارزنده تبدیل خواهد کرد.

اهمیت این تحقیقات مرزهای توسعه‌یافته در یک شبکه DeltaIoT را کاملاً در هم شکسته است. هر نوع معماری که توأمان با ۳ چالش بنیادین سیستم نرم‌افزار (استقرار محیط پیکربندی کلان، عدم قطعیت‌های متغیر شرایط و نیاز تطبیق زمان اجرا) دست و پنجه نرم کند، با تکیه بر متد معرفی‌شده در RS-DRL می‌تواند بر این معضل غلبه نماید، به گونه‌ای که سیستم‌های ابری، امنیت سایبری شبکه، کنترل برق هوشمند و هدایت پهپادهای یکپارچه از مصادیق این قابلیت‌ها هستند.

مأموریت نهایی آینده برای سیستم‌ها آن است که نه تنها مستمراً راهبری سیستم را هماهنگ بدانند بلکه فراتر از آن استراتژی را پیوسته غنی‌سازی نمایند – هدفی بزرگ که در شرف تحقق پیوسته است. رساله‌ی حاضر با اتکا بر راهکار ابداعی RS-DRL تلاش داشته خشت کوچکی اما ارزشمند رو به سوی این آرمان کلان مهندسی نرم‌افزار بنا کند.

کتاب نامه

- [1] A. Kavianifar *et al.*, “Randomized reward-shaped deep reinforcement learning for managing uncertainty in self-adaptive systems,” *Unpublished Thesis*, 2026.
- [2] F. Quin *et al.*, “Efficient analysis of large adaptation spaces in self-adaptive systems using machine learning,” in *2019 IEEE/ACM 14th International Symposium on Software Engineering for Adaptive and Self-Managing Systems (SEAMS)*, IEEE, 2019.
- [3] F. Quin, D. Weyns, and O. Gheibi, “Reducing large adaptation spaces in self-adaptive systems using machine learning,” *Journal of Systems and Software*, p.111341, 2022.
- [4] F. Kachi and C. Bouanaka, “A hybrid model for efficient decision-making in self-adaptive systems,” *Information and Software Technology*, vol.153, p.107063, 2023.
- [5] Z. Coker, D. Garlan, and C. L. Goues, “Sass: Self-adaptation using stochastic search,” in *10th International Symposium on Software Engineering for Adaptive and Self-Managing Systems, SEAMS 2015*, Institute of Electrical and Electronics Engineers Inc, 2015.
- [6] C. Kinneer *et al.*, “Managing uncertainty in self-adaptive systems with plan reuse and stochastic search,” in *ACM/IEEE 13th International Symposium on Software Engineering for Adaptive and Self-Managing Systems, SEAMS 2018, , co-located with International Conference on Software Engineering, ICSE 2018*, IEEE Computer Society, 2018.
- [7] C. Kinneer *et al.*, “Building reusable repertoires for stochastic self-* planners,” in *2020 IEEE International Conference on Autonomic Computing and Self-Organizing Systems (ACSOS)*, IEEE, 2020.
- [8] C. Kinneer, D. Garlan, and C. L. Goues, “Information reuse and stochastic search: Managing uncertainty in self-* systems,” *ACM Transactions on Autonomous and Adaptive Systems (TAAS)*, vol.15, no.1, pp.1–36, 2021.
- [9] T. Chen *et al.*, “Femosaa: Feature-guided and knee-driven multi-objective optimization for self-adaptive software,” *ACM Transactions on Software Engineering and Methodology*, vol.27, no.2, 2018.

- [10] D. Kim and S. Park, "Reinforcement learning-based dynamic adaptation planning method for architecture-based self-managed software," in *2009 ICSE Workshop on Software Engineering for Adaptive and Self-Managing Systems*, IEEE, 2009.
- [11] A. Metzger *et al.*, "Realizing self-adaptive systems via online reinforcement learning and feature-model-guided exploration," *Computing*, pp.1–22, 2022.
- [12] J. Cámara, H. Muccini, and K. Vaidhyanathan, "Quantitative verification-aided machine learning: A tandem approach for architecting self-adaptive iot systems," in *2020 IEEE International Conference on Software Architecture (ICSA)*, IEEE, 2020.
- [13] Q. He, L. Zhuang, and H. Li, "Soft hindsight experience replay," *arXiv preprint arXiv:2002.02089*, 2020.

پیوست آ

جریان‌های کاری کامل فرآیند

پیوست ب

لیست کامل الگوریتم‌ها

پیوست پ

نتایج تجربی گسترده

پیوست

مصنوعات پیاده‌سازی و پکیج بازتولید

Abstract:

guidelines) TMU by end the at required thesis, the of summary (English

Shap- Reward Learning, Reinforcement Deep Systems, Self-Adaptive **Keywords:**

Uncertainty ing.



University Modares Tarbiat
Engineering Computer and Electrical of Faculty

Deep Reward-Shaped Randomized for Learning Reinforcement in Uncertainty Managing Systems Self-Adaptive

Requirement the of Fulfillment Partial in Submitted Thesis A
Computer in Philosophy of Doctor of Degree the for
Engineering

By:
Kavianifar Alireza

Supervisor:
... Dr.
Advisor:
... Dr.

۲۰۲۶ February