
بسم الله الرحمن الرحيم

دانشکده مهندسی برق و کامپیوتر

رساله دکتری در رشته مهندسی کامپیوتر

گرایش مهندسی نرم‌افزار

# یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم‌های خودوفقی

علیرضا کاویانی‌فر

استاد راهنما

**دکتر ...**

استاد مشاور

**دکتر ...**

بهمن ۱۴۰۴

# تأییدیه‌ی هیأت داوران جلسه‌ی دفاع از رساله

خانم/آقای علیرضا کاویانی‌فر رساله —— واحدی خود را با عنوان یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم‌های خودوفقی در تاریخ بهمن ۱۴۰۴ ارائه کردند. اعضای هیات داوران نسخه نهایی این رساله را از نظر فرم و محتوا تایید کرده است و پذیرش آنرا برای تکمیل درجه دکتری پیشنهاد می‌کنند.

# آیین‌نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهشهای علمی‌دانشگاه تربیت مدرس

مقدمه: با عنایت به سیاست‌های پژوهشی و فناوری دانشگاه در راستای تحقق عدالت و کرامت انسانها که لازمه شکوفایی علمی‌و فنی است و رعایت حقوق مادی و معنوی دانشگاه و پژوهشگران، لازم است اعضای هیأت علمی، دانشجویان، دانش‌آموختگان و دیگر همکاران طرح، در مورد نتایج پژوهشهای علمی‌که تحت عناوین پایان‌نامه، رساله و طرحهای تحقیقاتی با هماهنگی دانشگاه انجام شده است، موارد زیر را رعایت نمایند:

ماده ۱- حق نشر و تکثیر پایان‌نامه/رساله و درآمدهای حاصل از آنها متعلق به دانشگاه می‌باشد ولی حقوق معنوی پدید آورندگان محفوظ خواهد بود.

ماده ۲- انتشار مقاله یا مقالات مستخرج از پایان‌نامه/ رساله به صورت چاپ در نشریات علمی‌و یا ارائه در مجامع علمی باید به نام دانشگاه بوده و با تایید استاد راهنمای اصلی، یکی از اساتید راهنما، مشاور و یا دانشجو مسئول مکاتبات مقاله باشد. ولی مسئولیت علمی‌مقاله مستخرج از پایان نامه و رساله به عهده اساتید راهنما و دانشجو می‌باشد. تبصره: در مقالاتی که پس از دانش‌آموختگی بصورت ترکیبی از اطلاعات جدید و نتایج حاصل از پایان‌نامه/ رساله نیز منتشر می‌شود نیز باید نام دانشگاه درج شود.

ماده ۳- انتشار کتاب، نرم‌افزار و یا آثار ویژه (اثری هنری مانند فیلم، عکس، نقاشی و نمایشنامه) حاصل از نتایج پایان‌نامه/ رساله و تمامی‌طرحهای تحقیقاتی کلیه واحدهای دانشگاه اعم از دانشکده ها، مراکز تحقیقاتی، پژوهشکده ها، پارک علم و فناوری و دیگر واحدها باید با مجوز کتبی صادره از معاونت پژوهشی دانشگاه و براساس آئین نامه های مصوب انجام شود.

ماده ۴- ثبت اختراع و تدوین دانش فنی و یا ارائه یافته ها در جشنواره‌های ملی، منطقه‌ای و بین‌المللی که حاصل نتایج مستخرج از پایان‌نامه/ رساله و تمامی‌طرح‌های تحقیقاتی دانشگاه باید با هماهنگی استاد راهنما یا مجری طرح از طریق معاونت پژوهشی دانشگاه انجام گیرد.

ماده ۵- این آیین‌نامه در ۵ ماده و یک تبصره در تاریخ۸۷/۴/۱ در شورای پژوهشی و در تاریخ ۸۷/۴/۲۳ در هیأت رئیسه دانشگاه به تایید رسید و در جلسه مورخ ۸۷/۷/۱۵ شورای دانشگاه به تصویب رسیده و از تاریخ تصویب در شورای دانشگاه لازم‌الاجرا است.

اینجانب علیرضا کاویانی‌فر به شماره دانشجویی ... دانشجوی رشته مهندسی کامپیوتر مقطع تحصیلی دکتری دانشکده مهندسی برق و کامپیوتر متعهد می‌شوم کلِیه نکات مندرج در آئین نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهش های علمی‌دانشگاه تربیت مدرس را در انتشار یافته های علمی‌مستخرج از

پایان‌نامه/رساله تحصیلی خود رعایت نمایم.  در صورت تخلف از مفاد آئین نامه فوق الاشعار به دانشگاه وکالت و نمایندگی می‌دهم که از طرف اینجانب نسبت به لغو امتیاز اختراع بنام بنده و یا هر گونه امتیاز دیگر و تغییر آن به نام دانشگاه اقدام نماید. ضمناً نسبت به جبران فوری ضرر و زیان حاصله بر اساس برآورد دانشگاه اقدام خواهم نمود و بدینوسیله حق هر گونه اعتراض را از خود سلب نمودم»

تاریخ و امضا:

# آیین نامه چاپ پایان‌نامه (رساله)های دانشجویان دانشگاه تربیت مدرس

نظر به اینکه چاپ و انتشار پایان نامه (رساله)های تحصیلی دانشجویان دانشگاه تربیت مدرس، مبین بخشی از فعالیتهای علمی- پژوهشی دانشگاه است بنابراین به منظور آگاهی و رعایت حقوق دانشگاه،دانش آموختگان این دانشگاه نسبت به رعایت موارد ذیل متعهد می‌شوند: ماده ۱: در صورت اقدام به چاپ پایان نامه (رساله)ی خود، مراتب را قبلاً به‌طور کتبی به «دفتر نشر آثارعلمی» دانشگاه اطلاع دهد. ماده ۲: در صفحه سوم کتاب (پس از برگ شناسنامه) عبارت ذیل را چاپ کند: «کتاب حاضر، حاصل پایان نامه کارشناسی ارشد/ رساله دکتری نگارنده در رشته مهندسی کامپیوتر است که در بهمن ۱۴۰۴ در دانشکده‌مهندسی برق و کامپیوتر دانشگاه تربیت مدرس به راهنمایی سرکار خانم/جناب آقای دکتر ...، مشاوره سرکار خانم/جناب آقای دکتر ... از آن دفاع شده است.» ماده ۳: به منظور جبران بخشی از هزینه‌های انتشارات دانشگاه، تعداد یک درصد شمارگان کتاب (در هر نوبت‌چاپ) را به «دفتر نشر آثارعلمی» دانشگاه اهدا کند. دانشگاه می‌تواند مازاد نیاز خود را به نفع مرکز نشر درمعرض فروش قرار دهد. ماده ۴: در صورت عدم رعایت ماده ۳، ۵۰% بهای شمارگان چاپ شده را به‌عنوان خسارت به دانشگاه تربیت‌مدرس، تأدیه کند. ماده ۵: دانشجو تعهد و قبول می‌کند در صورت خودداری از پرداخت بهای خسارت، دانشگاه می‌تواند خسارت مذکور را از طریق مراجع قضایی مطالبه و وصول کند؛ به علاوه به دانشگاه حق می‌دهد به منظور استیفای حقوق خود، از طریق دادگاه، معادل وجه مذکور در ماده ۴ را از محل توقیف کتابهای عرضه شده نگارنده برای فروش، تامین نماید. ماده ۶: اینجانب علیرضا کاویانی‌فر دانشجوی رشته مهندسی کامپیوتر مقطع دکتری تعهد فوق وضمانت اجرایی آن را قبول کرده، به آن ملتزم می‌شوم.

استاد راهنما: دکتر ...

تاریخ:

امضا:

# تقدیم

(*متن تقدیم به خانواده، اساتید و ...*)

# قدردانی

(متن تشکر و قدردانی از اساتید راهنما، مشاور و دوستان)

علیرضا کاویانی‌فر

بهمن ۱۴۰۴

## چکیده

سیستم‌های نرم‌افزاری معاصر به طور فزاینده‌ای در محیط‌های پویا و همراه با عدم قطعیت عمل می‌کنند. این عدم قطعیت‌ها که ناشی از عواملی مانند تداخل شبکه، نوسانات بار ترافیکی یا تغییرات محیطی هستند، می‌توانند به طور جدی اهداف کیفی سیستم را به خطر اندازند. سیستم‌های خودوفقی (Self-Adaptive Systems) با بهره‌گیری از حلقه‌های بازخوردی، راهکاری بنیادین برای مقابله با این چالش ارائه می‌دهند. با این حال، چالش اصلی زمانی بروز می‌کند که این سیستم‌ها با فضای وفقی وسیع (شامل صدها یا هزاران گزینه پیکربندی) مواجه می‌شوند. روش‌های موجود، از جمله روش‌های مبتنی بر یادگیری ماشین، جستجو، و حتی یادگیری تقویتی کلاسیک، در چنین فضاهایی با مشکلاتی نظیر نیاز به داده‌های برچسب‌دار، عدم مقیاس‌پذیری، و مهم‌تر از همه، گرفتار شدن در بهینه‌های محلی و عدم توانایی تعمیم به شرایط محیطی جدید مواجه هستند. هدف اصلی این رساله، توسعه و اعتبارسنجی روشی نوین مبتنی بر یادگیری تقویتی عمیق با مکانیسم شکل‌دهی تصادفی پاداش (Randomized Reward-Shaped Deep Reinforcement Learning – RS-DRL) برای مدیریت کارآمد عدم قطعیت در این سیستم‌ها است. روش پیشنهادی، هسته یادگیری خود را بر پایه شبکه‌های کیو_عمیق (DQN) استوار ساخته و آن را درون چارچوب استاندارد مدیریت خودمختار MAPE-K یکپارچه می‌سازد. در این معماری، سیگنال محیطی با نتایج حاصل از بازبینی صوری توسط ابزار UPPAAL-SMC ترکیب شده تا عامل یادگیرنده تحت هدایت محدودیت‌های صوری آموزش ببیند. نوآوری اصلی رساله، مکانیسم «شکل‌دهی تصادفی پاداش» است که طی آن، زیرمجموعه‌ای تصادفی از تجربیات ناموفق گذشته با تخصیص پاداش خوش‌بینانه بازطراحی می‌شوند. اگرچه پیکربندی مدل صوری نیازمند دانش دامنه است، اما مکانیسم شکل‌دهی تصادفی پیشنهادی به خودی خود مستقل از دامنه بوده و نیاز به دانش صریح از اهداف (Domain Knowledge) برای اکتشاف ندارد. ارزیابی تجربی بر روی مطالعه موردی DeltaIoT (در شبکه‌های حسگر بی‌سیم) با فضاهای وفقی تا ۴۰۹۶ گزینه، نشان‌دهنده برتری قاطع روش RS-DRL نسبت به روش‌های پایه از جمله DQN، HER، Soft HER و DLASER+ است. به عنوان مثال، در هدف آستانه‌ای TT، روش پیشنهادی موفق به کاهش نرخ اتلاف بسته تا 23.22% و کاهش تأخیر تا 39.07% در مقایسه با روش DLASER+ به عنوان قوی‌ترین رقیب پژوهش گردید. تحلیل‌های آماری معنادار صحت و استواری نتایج را در شرایط پویای محیطی تأیید می‌کنند. یافته‌های این رساله نشان می‌دهد که رویکرد RS-DRL یک استراتژی بهینه‌سازی مقاوم و خودوفق برای نسل بعدی سیستم‌های نرم‌افزاری پیچیده است.



**واژگان کلیدی:** سیستم‌های خودوفقی، یادگیری تقویتی عمیق، شکل‌دهی تصادفی پاداش، مدیریت عدم قطعیت، بازبینی صوری، UPPAAL-SMC، فضاهای وفقی بزرگ، اینترنت اشیاء، شبکه‌های حسگر بی‌سیم

# فهرست مطالب

**فهرست جداول** . . . . . **ز**

**فهرست تصاویر** . . . . . **ط**

**فهرست نشانه‌ها و اختصارات** . . . . . **ک**

**فصل اول: کلیات** . . . . . **۱**

۱-۱ مقدمه . . . . . ۱

۱-۲ اهداف رساله . . . . . ۲

۱-۳ چالش‌ها . . . . . ۳

۱-۴ بیان مساله . . . . . ۴

۱-۵ سؤالات پژوهش . . . . . ۷

۱-۶ روش پیشنهادی . . . . . ۸

۱-۶-۱ مرور کلی بر راهکار RS-DRL . . . . . ۸

۱-۶-۲ یکپارچه سازی راهکار RS-DRL با حلقه کنترلی MAPE-K . . . . . ۹

۱-۷ نوآوری‌های اصلی رساله . . . . . ۹

۱-۸ مروری بر فصول رساله . . . . . ۱۱

**فصل دوم: مبانی نظری و مدل‌سازی سیستم** . . . . . **۱۳**

۲-۱ مقدمه . . . . . ۱۳

۲-۲ مبانی سیستم‌های خودوفقی . . . . . ۱۴

۲-۲-۱ مفاهیم اصلی و تعاریف . . . . . ۱۴

۲-۲-۲ معماری‌های مرجع و الگوهای طراحی . . . . . ۱۴

۲-۲-۳ حلقه‌های کنترلی خودمختار: از MAPE-K تا موارد پیشرفته . . . . . ۱۵

۲-۳ عدم قطعیت در سیستم‌های خودوفقی . . . . . ۱۶
۲-۳-۱ دسته‌بندی و انواع عدم قطعیت . . . . . ۱۶
۲-۳-۲ روش‌های مدل‌سازی و رویارویی با عدم قطعیت . . . . . ۱۶
۲-۳-۳ چالش‌های خاص عدم قطعیت در فضاهای وفقی بزرگ . . . . . ۱۷
۲-۴ مبانی نظری و مدل‌سازی ریاضی . . . . . ۱۸
۲-۴-۱ فرآیندهای تصمیم‌گیری مارکوف، یادگیری تقویتی و DQN . . . . . ۱۸
۲-۵ سیستم مورد مطالعه: شبکه‌های حسگر بی‌سیم DeltaIoT . . . . . ۲۲
۲-۵-۱ معماری، مؤلفه‌ها و ویژگی‌های فیزیکی . . . . . ۲۲
۲-۵-۲ مدل‌سازی فیزیکی و ریاضیاتی پدیده‌های کانال بی‌سیم . . . . . ۲۳
۲-۵-۳ جزئیات فرمول‌بندی معیارهای کیفیت خدمات (QoS) در فضای حالت . . . . ۲۴
۲-۵-۴ سناریوهای عدم قطعیت و فضای وفقی . . . . . ۲۵
۲-۵-۵ فرمول‌بندی به عنوان MDP . . . . . ۲۶
۲-۶ بیان مسئله و چارچوب بهینه‌سازی . . . . . ۲۷
۲-۶-۱ تعریف سیاست بهینه . . . . . ۲۷
۲-۶-۲ تحلیل پیچیدگی مسئله تطبیق و ضرورت یادگیری تقویتی . . . . . ۲۷
۲-۶-۳ قیود عملیاتی زمان اجرا . . . . . ۲۹
۲-۷ سیستم مورد مطالعه دوم: شبیه‌ساز مأموریت پهپاد DARTSim . . . . . ۲۹
۲-۷-۱ خاستگاه علمی و جایگاه به‌عنوان محک . . . . . ۲۹
۲-۷-۲ فضای معنایی سیستم (Semantic Space) . . . . . ۳۰
۲-۷-۳ اهداف و الزامات وابستگی‌پذیری . . . . . ۳۰
۲-۷-۴ معماری، مؤلفه‌ها و ویژگی‌های فیزیکی . . . . . ۳۱
۲-۷-۵ جزئیات فرمول‌بندی معیارهای کیفیت خدمات (QoS) در فضای حالت . . . . ۳۱
۲-۷-۶ سناریوهای عدم قطعیت و فضای وفقی . . . . . ۳۲
۲-۷-۷ مدل‌سازی عدم قطعیت محیطی و تصادفی‌بودن حسگرها . . . . . ۳۲
۲-۷-۸ فرمول‌بندی به عنوان MDP . . . . . ۳۳
۲-۷-۹ محیط انطباق آفلاین (Offline Replay Adapter) . . . . . ۳۵
۲-۷-۱۰ طیف دشواری محیط و فضای طراحی سناریوها . . . . . ۳۵
۲-۸ خلاصه فصل . . . . . ۳۶

**فصل سوم: مرور پیشینه پژوهش و کارهای مرتبط** ۳۷
۳-۱ مقدمه و روش‌شناسی مرور ۳۷
۳-۲ مبانی نظری: عدم‌قطعیت و تصمیم‌گیری در سیستم‌های خودوفق ۳۸
۳-۳ رویکردهای اصلی مدیریت فضای وفقی در زمان اجرا ۳۹
۳-۳-۱ هرس فضای وفقی مبتنی بر یادگیری ماشین سنتی ۳۹
۳-۳-۲ روش‌های مبتنی بر جستجوی آنلاین و استراتژی‌های اکتشافی ۴۰
۳-۳-۳ یادگیری تقویتی زمان‌اجرا و کنترل خودمختار ۴۱
۳-۴ تکنیک‌های پیشرفته یادگیری تقویتی: کاوش، شکل‌دهی پاداش و نگاه به گذشته ۴۲
۳-۴-۱ چالش‌های استراتژی کاوش در فضاهای وفقی بزرگ ۴۲
۳-۴-۲ ناکارآمدی مکانیزم بازپخش تجربه با نگاه به گذشته (HER) در محیط‌های آستانه‌محور ۴۳
۳-۴-۳ مبانی نظری و ریاضیاتی شکل‌دهی پاداش ۴۴
۳-۵ ارزیابی و تایید صوری در فرآیند خودوفق‌سازی ۴۵
۳-۵-۱ تأیید صوری کمّی زمان اجرا (QVR) ۴۵
۳-۵-۲ چارچوب‌های ActivFORMS و ابزار UPPAAL-SMC ۴۶
۳-۵-۳ معماری‌های ترکیبی یادگیری و ارزیابی صوری (مدل‌های ترادف) ۴۶
۳-۶ سنتز: شکاف تحقیقاتی سه‌گانه و موقعیت‌دهی علمی RS-DRL ۴۷
۳-۶-۱ ماتریس ارزیابی و سنتز پیشینه پژوهش ۴۷
۳-۶-۲ شکاف تحقیقاتی سه‌گانه ۴۷
۳-۶-۳ موقعیت‌دهی علمی معماری پیشنهادی RS-DRL ۴۹
۳-۷ خلاصه فصل ۵۰

**فصل چهارم: روش پیشنهادی** ۵۲
۴-۱ مقدمه ۵۲
۴-۲ اصول معماری سطح بالا و سازماندهی فرآیند ۵۳
۴-۲-۱ مقایسه تطبیقی معماری پیشنهادی با رویکردهای پیشرفته ۵۵
۴-۳ فرآیند یکپارچه خودوفقی: حلقه سطح سیستم ۵۵
۴-۴ مسیر تصمیم‌گیری آنلاین: بررسی گام‌به‌گام معماری ۵۷
۴-۴-۱ گام اول: پایش و ساخت وضعیت (Monitor) ۵۷
۴-۴-۲ گام دوم: تحلیل و تشخیص ضرورت تطبیق (Analyze) ۵۸

۴-۴-۳ گام سوم: برنامه‌ریزی و استنتاج تطبیقی (Plan) . . . . . ۵۸
۴-۴-۴ گام چهارم: اعتبارسنجی، بازخورد و اجرا (شامل Execute و Knowledge) . . ۵۸
۴-۴-۵ سناریوهای گام‌به‌گام و ملموس از چرخه تصمیم‌گیری زمان اجرا . . . . . ۵۹
۴-۴-۵-۱ سناریوی اول: شبکه ساده دو گره‌ای با قید واحد . . . . . ۵۹
۴-۴-۵-۲ سناریوی دوم: شبکه پیچیده ۴ گره‌ای با اهداف متضاد کیفیت خدمات ۶۰
۴-۵ معماری داخلی RS-DRL: تفکیک دغدغه‌ها در فرآیند یادگیری . . . . . ۶۱
۴-۶ مکانیزم هسته: شکل‌دهی تصادفی پاداش . . . . . ۶۴
۴-۶-۱ متدولوژی تنظیم فراپارامترها و فرآیند جستجوی شبکه‌ای فاکتور $\rho$ . . . . . ۶۶
۴-۷ مدیریت دانش و هماهنگی جریان‌های ناهمگام . . . . . ۶۸
۴-۸ ادغام اعتبارسنجی صوری زمان اجرا و ایمنی احتمالی . . . . . ۶۹
۴-۸-۱ جزئیات شبیه‌سازی احتمالی و کران ریاضی تعداد نمونه‌ها (SMC Bound) . . . ۷۰
۴-۸-۲ تحلیل غیرانسدادی زمان‌بندی اعتبارسنجی ناهمگام (Non-Blocking Temporal Timing) . . . . . ۷۱
۴-۹ پوشش پرسش‌های پژوهش . . . . . ۷۲
۴-۹-۱ پاسخ صوری به سوال اول (RQ1) - فرار از بهینه‌های محلی . . . . . ۷۲
۴-۹-۲ پاسخ صوری به سوال دوم (RQ2) - ادغام یادگیری و بازپخش تجربه . . . . . ۷۲
۴-۹-۳ پاسخ صوری به سوال سوم (RQ3) - مدیریت فضاهای بزرگ و مقیاس‌پذیری . ۷۲
۴-۹-۴ پاسخ صوری به سوال چهارم (RQ4) - تمایز، برتری و استقلال از دانش دامنه . ۷۳
۴-۱۰ بحث پیرامون مفروضات متدولوژی پیشنهادی . . . . . ۷۳
۴-۱۰-۱فرض فضای اقدام گسسته در شبکه‌های خودوفق . . . . . ۷۳
۴-۱۰-۲آگاهی و پایداری آستانه‌های کیفیت خدمات . . . . . ۷۴
۴-۱۰-۳در دسترس بودن مدل صوری پویای سیستم در زمان اجرا . . . . . ۷۴
۴-۱۱ خلاصه فصل . . . . . ۷۴
۴-۱۱-۱محدودیت‌های روش پیشنهادی . . . . . ۷۴

**فصل پنجم: ارزیابی تجربی . . . . . ۷۶**
۵-۱ مقدمه . . . . . ۷۶
۵-۲ اهداف ارزیابی و سوالات تحقیق . . . . . ۷۶
۵-۳ تنظیمات آزمایشگاهی . . . . . ۷۶

۵-۳-۱ نمونه‌های مطالعه موردی . . . . . ۷۷
۵-۳-۲ مجموعه داده‌ها . . . . . ۷۸
۵-۳-۳ پلتفرم پیاده‌سازی . . . . . ۷۸
۵-۳-۴ تنظیمات فراپارامترها (Hyperparameters) . . . . . ۷۸
۵-۴ روش‌های پایه و مقایسه . . . . . ۷۸
۵-۵ معیارهای ارزیابی . . . . . ۷۹
۵-۵-۱ معیارهای عملکرد یادگیری عامل هوشمند . . . . . ۷۹
۵-۵-۲ معیارهای عملکرد سیستم . . . . . ۸۰
۵-۶ نتایج و تحلیل‌ها . . . . . ۸۰
۵-۶-۱ منحنی‌های یادگیری و رفتار همگرایی . . . . . ۸۰
۵-۶-۲ مقایسه عملکرد به ازای هر هدف . . . . . ۸۲
۵-۶-۳ ارزیابی مقایسه‌ای در برابر تمام روش‌های پایه . . . . . ۸۳
۵-۶-۴ مطالعه ابلیشن: حساسیت به فاکتور شکل‌دهی $\rho$ . . . . . ۸۳
۵-۶-۵ تحلیل مقیاس‌پذیری . . . . . ۸۴
۵-۶-۶ نتایج و تحلیل‌های تجربی شبیه‌ساز مأموریت پهپاد DARTSim . . . . . ۸۵
۵-۶-۶-۱ تنظیمات بستر داده آفلاین مأموریت پهپاد . . . . . ۸۵
۵-۶-۶-۲ آموزش و مقایسه عملکرد همگرایی . . . . . ۸۵
۵-۶-۶-۳ تحلیل پدیده نوسان خطا و خوش‌بینی در یادگیری . . . . . ۸۶
۵-۷ اعتبارسنجی آماری . . . . . ۸۷
۵-۸ خلاصه فصل . . . . . ۸۸

**فصل ششم: بحث، نتیجه‌گیری و پیشنهادها . . . . . ۸۹**
۶-۱ بحث در مورد یافته‌های کلیدی . . . . . ۸۹
۶-۱-۱ نظریه‌پردازی مکانیزم: چرا RS-DRL کار می‌کند؟ . . . . . ۸۹
۶-۱-۲ تحلیل تعاملات و مصالحه‌ها (به‌عنوان مثال، تاخیر در مقابل از دست رفتن بسته) ۹۰
۶-۱-۳ پیامدهای مهندسی سیستم‌های خودوفقی . . . . . ۹۱
۶-۲ محدودیت‌ها و تهدیدات اعتبار (Threats to Validity) . . . . . ۹۲
۶-۲-۱ اعتبار داخلی (Internal Validity) . . . . . ۹۲
۶-۲-۲ اعتبار خارجی (External Validity) . . . . . ۹۲

۶-۲-۳ اعتبار سازه (Construct Validity) . . . . . ۹۳
۶-۳ مسیرهایی برای تحقیقات آینده . . . . . ۹۳
۶-۳-۱ استراتژی‌های انطباقی و وفقی شکل‌دهی $\rho$ . . . . . ۹۳
۶-۳-۲ گسترش به دامنه‌های پیوسته و حساس به ایمنی . . . . . ۹۴
۶-۳-۳ اعتبارسنجی بین‌دامنه و تحلیل‌های نظری . . . . . ۹۴
۶-۴ نتیجه‌گیری . . . . . ۹۵
۶-۴-۱ خلاصه بیان مسئله و راهکار پیشنهادی . . . . . ۹۵
۶-۴-۲ مرور مشارکت‌ها و شواهد تجربی . . . . . ۹۵
۶-۴-۳ سخنان پایانی . . . . . ۹۶

**پیوست آ: جریان‌های کاری کامل فرآیند . . . . . ۹۸**

**پیوست ب: لیست کامل الگوریتم‌ها . . . . . ۹۹**

**پیوست پ: نتایج تجربی گسترده . . . . . ۱۰۰**

**پیوست ت: مصنوعات پیاده‌سازی و پکیج بازتولید . . . . . ۱۰۱**

# فهرست جداول


۲-۱ مقایسه تطبیقی الگوریتم‌های جدول‌محور Q-Learning و SARSA . . . . . ۲۲

۲-۲ فضای معنایی سیستم پهپادی DARTSim (عوامل پیکربندی و محیطی) . . . . . ۳۰

۲-۳ طیف سناریوهای پیکربندی‌پذیر محیط DARTSim و سطوح دشواری آن‌ها . . . . . ۳۵

۳-۱ مقایسه تطبیقی پارادایم‌های مدیریت فضای وفقی زمان اجرا بر اساس چارچوب ارزیابی پنج‌بعدی (برگرفته از تحلیل کارهای پیشین نظیر [؟، ؟، ؟، ؟]) . . . . . ۴۸

۳-۲ نحوه پوشش شکاف‌های تحقیقاتی توسط نوآوری‌های معماری پیشنهادی RS-DRL . . ۴۹

۴-۱ مقایسه تطبیقی معماری پیشنهادی RS-DRL با رویکردهای پیشین از منظر اصول طراحی سیستمی . . . . . ۵۵

۴-۲ طبقه‌بندی زمانی فرآیندهای معماری RS-DRL . . . . . ۵۷

۴-۳ تحلیل حساسیت رفتار یادگیری عامل نسبت به تغییرات فاکتور شکل‌دهی $\rho$ . . . . . ۶۶

۴-۴ الگوهای دسترسی صوری و همگام‌سازی مؤلفه‌ها در مخزن دانش مشترک [؟] . . . . . ۶۹

۵-۱ هم‌راستایی اهداف ارزیابی با سوالات تحقیق . . . . . ۷۷

۵-۲ نمونه‌های مورد مطالعه سیستم DeltaIoT [؟] . . . . . ۷۷

۵-۳ نتایج اهداف کمینه‌سازی در DeltaIoTv1 (پاداش مجانبی / گام‌ها) . . . . . ۸۲

۵-۴ نتایج اهداف کمینه‌سازی در DeltaIoTv1.1 . . . . . ۸۲

۵-۵ عملکرد سیستم برای اهداف آستانه‌ای ترکیبی (TTS Goal) . . . . . ۸۳

۵-۶ عملکرد سیستم برای اهداف آستانه‌ای مطلق (TT Goal) . . . . . ۸۳

۵-۷ تحلیل مقیاس‌پذیری الگوریتم با بزرگ شدن فضای تطابق . . . . . ۸۴

۵-۸ مقایسه آماری عملکرد الگوریتم RS-DRL و Baseline DQN در محیط آفلاین DARTSim (میانگین $\pm$ انحراف معیار روی ۳ سید تصادفی مستقل بعد از 50,000 گام آموزشی) . . ۸۵

۵-۹ مقادیر احتمال (p-values) برای مقایسه‌های معنادار و غیرمعنادار . . . . . ۸۸

۶-۱ خلاصه‌ای از مشارکت‌های کلیدی و شواهد تجربی . . . . . ۹۶

# فهرست تصاویر


۲-۱ توپولوژی و ساختار پیوندهای ارتباطی شبکه حسگر بی‌سیم DeltaIoTv1 [؟]. . . . . ۲۳

۲-۲ نمودار مفهومی عوامل اثرگذار بر اهداف وابستگی‌پذیری تیم پهپادی DARTSim؛ عوامل پیکربندی و محیطی در یک محیط متخاصم بر تحقق اهداف شناسایی هدف و اجتناب از تهدید اثر می‌گذارند. . . . . ۳۱

۲-۳ داشبورد تحلیل عدم قطعیت محیطی DARTSim: توزیع تصادفی‌بودن گذارها، عدم‌قطعیت به‌تفکیک نوع اقدام و مؤلفه حالت، تغییرپذیری قرائت حسگر تهدید و پراکندگی پاداش‌ها. ۳۳

۲-۴ نمونه‌هایی از تغییرپذیری قرائت حسگرهای تهدید و هدف برای یک زوج حالت–اقدام یکسان در DARTSim؛ هر سطر یک پیامد ممکن و هر ستون یک سلول حسگر پیش‌رِو را نشان می‌دهد. . . . . ۳۴

۲-۵ مقایسه‌ی سه سناریوی DARTSim (پایه، متوسط و سخت)؛ تفاوت در چیدمان نقشه، پیچیدگی مسیر و چگالی تهدید و هدف. . . . . ۳۶

۴-۱ معماری سطح بالای رویکرد RS-DRL در قالب حلقه MAPE-K. این نمودار تعامل میان سیستم مدیریت‌شونده، محیط، و مؤلفه‌های کنترلی را به همراه مخزن دانش (Knowledge) مشترک نشان می‌دهد. . . . . ۵۴

۴-۲ نمودار فعالیت تفصیلی UML با خطوط شناوری (Swimlanes) برای تفکیک مسئولیت‌های پایش، تحلیل، برنامه‌ریزی و اعتبارسنجی. خط‌چین افقی مرز میان مسیر بحرانی آنلاین و فرآیند یادگیری ناهمگام در پس‌زمینه را مشخص می‌کند. . . . . ۵۶

۴-۳ ساختار داخلی مؤلفه برنامه‌ریز RS-DRL در سه مسیر موازی: استنتاج (فقط‌خواندنی)، فیدبک (ترکیب پاداش محیطی و صوری)، و آموزش (به‌روزرسانی ناهمگام با استفاده از شکل‌دهی تصادفی پاداش). . . . . ۶۲

۴-۴ منطق عملیاتی مکانیزم شکل‌دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش‌بینانه پاداش‌های صفر با مقدار ۱ را بر اساس فاکتور $\rho$ نشان می‌دهد (برچسب‌گذاری مجدد خوش‌بینانه، نه روش‌های مبتنی بر پتانسیل [؟]). . . . . ۶۳
۴-۵ منطق عملیاتی مکانیزم شکل‌دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش‌بینانه پاداش‌های صفر با مقدار ۱ را بر اساس فاکتور $\rho$ نشان می‌دهد (برچسب‌گذاری مجدد خوش‌بینانه، نه روش‌های مبتنی بر پتانسیل). . . . . ۶۵
۴-۶ جریان داده تفصیلی در مخزن دانش. این نمودار نحوه ذخیره‌سازی تجربیات در بافر بازپخش، اعمال مکانیزم شکل‌دهی تصادفی پاداش پیش از محاسبات گرادیان، و به‌روزرسانی سیاست‌های یادگیری در پس‌زمینه را به تصویر می‌کشد. . . . . ۶۸
۴-۷ دیاگرام هماهنگی و توالی زمانی میان استنتاج فوق‌سریع آنلاین (۰/۳ms) و راستی‌آزمایی صوری سنگین و ناهمگام در پس‌زمینه، که تضمین می‌کند هیچ وقفه یا انسدادی در مسیر مستقیم تصمیم‌گیری رخ نمی‌دهد. . . . . ۷۱

۵-۱ منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1 (پاداش در برابر گام‌ها) . . . . . ۸۱
۵-۲ منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1.1 . . . . . ۸۱
۵-۳ تاثیر مقادیر مختلف ضریب شکل‌دهی $\rho$ بر پاداش مجانبی و عملکرد کل . . . . . ۸۴
۵-۴ نمودار همگرایی مأموریت پهپادی DARTSim شامل چهار پانل: (الف) همگرایی ارزش کیو، (ب) میانگین خطای TD، (ج) نرخ شکل‌دهی پاداش واقعی، و (د) مقایسه گام‌به‌گام ارزش کیو. . . . . ۸۶
۵-۵ تحلیل تفکیکی رفتار الگوریتم RS-DRL در مقایسه با DQN پایه به ازای سیدهای تصادفی مستقل ۴۲، ۴۳ و ۴۴ در محیط شبیه‌ساز پهپادی DARTSim. . . . . ۸۶
۵-۶ تحلیل آماری و معناداری اندازه اثر کوهن (Cohen's d) و فواصل اطمینان ارزش کیو برای روش پیشنهادی در برابر روش پایه در مأموریت‌های DARTSim. . . . . ۸۷

# فهرست نشانه‌ها و اختصارات

## نشانه‌های ریاضی

| نماد | توضیح و تعریف |
|---|---|
| $\mathcal{S}$ | فضای حالت سیستم (مجموعه تمام وضعیت‌های ممکن سیستم و محیط) |
| $\mathcal{A}$ | فضای عمل یا گزینه‌های وفقی در دسترس |
| $s$ | حالت یا وضعیت جاری سیستم ($s \in \mathcal{S}$) |
| $a$ | عمل وفقی یا پیکربندی انتخاب‌شده ($a \in \mathcal{A}$) |
| $\pi(a\|s)$ | سیاست تطبیق عامل (نگاشت حالت‌ها به اعمال) |
| $\pi^*$ | سیاست تطبیق بهینه |
| $R(s,a)$ | تابع پاداش (بازخورد عددی محیط به عامل) |
| $\gamma$ | نرخ تنزیل پاداش‌های آتی ($\gamma \in [0,1)$) |
| $V^\pi(s)$ | تابع ارزش حالت تحت سیاست $\pi$ |
| $Q(s,a)$ | تابع ارزش عمل (مقدار کیو) |
| $\theta$ | پارامترها و وزن‌های شبکه عصبی عمیق تقریب‌گر |
| $\epsilon$ | احتمال کاوش تصادفی در الگوریتم حریصانه‌ـ اپسیلون |
| $\mathcal{D}$ | بافر بازپخش تجربه عامل |
| $\rho$ | مقدار پاداش خوش‌بینانه تزریق‌شده در مکانیسم شکل‌دهی پاداش تصادفی |

# اختصارات انگلیسی

| اختصار | عبارت کامل انگلیسی | معادل فارسی |
|---|---|---|
| RS-DRL | Randomized Reward-Shaped Deep Reinforcement Learning | یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش |
| DRL | Deep Reinforcement Learning | یادگیری تقویتی عمیق |
| SAS | Self-Adaptive Systems | سیستم‌های خودوفقی |
| MAPE-K | Monitor, Analyze, Plan, Execute over Shared Knowledge | حلقه مدیریت خودمختار |
| UPPAAL-SMC | UPPAAL Statistical Model Checker | ابزار بازبینی صوری آماری آپال |
| SMC | Statistical Model Checking | بازبینی صوری آماری |
| DQN | Deep Q-Network | شبکه کیو عمیق |
| HER | Hindsight Experience Replay | بازپخش تجربه با نگاه به گذشته (هدف‌محور) |
| Soft HER | Soft Hindsight Experience Replay | بازپخش تجربه با نگاه به گذشته نرم |
| DLASER | Dynamic Learning-based Adaptive System for Efficient Resource allocation | سیستم وفقی مبتنی بر یادگیری پویا برای تخصیص منابع |
| ML4EAS | Machine Learning for Self-Adaptive Systems | یادگیری ماشین برای سیستم‌های خودوفق خودمراقبتی |
| DARTSim | UAV Tactical Mission Simulator | شبیه‌ساز مأموریت تاکتیکی پهپادها |

| اختصار | عبارت کامل انگلیسی | معادل فارسی |
|---|---|---|
| MDP | Markov Decision Process | فرآیند تصمیم‌گیری مارکوف |
| POMDP | Partially Observable Markov Decision Process | فرآیند تصمیم‌گیری مارکوف بخشاً مشاهده‌پذیر |
| PBRS | Potential-Based Reward Shaping | شکل‌دهی پاداش مبتنی بر پتانسیل |
| QVR | Q-Value Reshaping | شکل‌دهی مقدار کیو |
| QoS | Quality of Service | کیفیت خدمات |
| KPI | Key Performance Indicator | شاخص کلیدی عملکرد |
| IoT | Internet of Things | اینترنت اشیاء |
| WSN | Wireless Sensor Network | شبکه حسگر بی‌سیم |
| SNR | Signal-to-Noise Ratio | نسبت سیگنال به نویز |
| TT | Threshold Goal | هدف آستانه‌ای مطلق |
| TTS | Threshold-based Transition System | سیستم انتقال مبتنی بر آستانه |

# فصل اول

# کلیات

## ۱-۱ مقدمه

در حوزه مهندسی سیستم‌های نرم‌افزاری معاصر، پیچیدگی به‌عنوان یکی از بارزترین ویژگی‌ها خودنمایی می‌کند. محیط عملیاتی پویا نقشی محوری در شکل‌دهی به این پیچیدگی دارد و سیستم‌ها را ناگزیر می‌سازد تا با شرایط نامشخصی که اغلب تنها پس از عملیاتی شدن بروز می‌یابند، مقابله کنند.

در سال‌های اخیر، ظهور معماری‌های توزیع‌شده، رایانش ابری، اینترنت اشیاء (IoT) و سیستم‌های فیزیکی‌ـ سایبری، ابعاد جدیدی از پیچیدگی محاسباتی و عدم قطعیت‌های زمان اجرا را به همراه داشته است. آمار و گزارش‌های صنعتی نشان می‌دهند که خرابی و توقف غیرمنتظره سیستم‌های نرم‌افزاری در مقیاس صنعتی، هزینه‌های سرسام‌آوری را تحمیل می‌کند [؟]. به عنوان مثال، در زیرساخت‌های ابری بزرگ مقیاس، هر دقیقه توقف خدمات (downtime) می‌تواند تا هزاران دلار ضرر مالی مستقیم و آسیب جدی به اعتبار برندها به همراه داشته باشد [؟]. از سوی دیگر، در شبکه‌های حسگر بی‌سیم و اینترنت اشیاء صنعتی، افزایش ناگهانی تداخل امواج یا رانش مفهومی در کانال‌های ارتباطی می‌تواند نرخ هدررفت داده‌ها را به شدت افزایش دهد. در چنین سناریوهایی، نرخ خطای قابل قبول بسیار کوچک است و سیستم‌ها باید بلافاصله خود را با محیط تطبیق دهند. این موضوع نشان می‌دهد که مدیریت عدم قطعیت در سیستم‌های نوین، یک چالش دانشگاهی محض نیست، بلکه یک ضرورت عملی و فوری در صنایع مختلف به شمار می‌رود.

سیستم‌های نرم‌افزاری سنتی که مبتنی بر پیکربندی‌های ایستا در زمان طراحی یا قواعد ثابت زمان اجرا (نظیر دستورات شرطی ساده «اگر_آنگاه») هستند، فاقد انعطاف‌پذیری لازم برای پاسخ‌گویی به نوسانات پویای محیطی می‌باشند. در این سیستم‌ها، تمامی شرایط عملیاتی و رفتارهای سیستم باید در زمان طراحی پیش‌بینی شوند. با این حال، در محیط‌های پیچیده واقعی، فرضیات زمان طراحی همواره نقض می‌شوند. برای نمونه، در سیستم‌های هوشمند مدیریت ترافیک شهری یا کنترل مسیریابی شبکه‌های نسل پنجم (5G)، تغییرات پویای حجم داده‌ها، نوسان بار ترافیکی و خرابی‌های ناگهانی سخت‌افزاری موجب شکست قوانین

ایستای زمان طراحی می‌شوند. سیستم‌هایی که بر قواعد سخت‌گیرانه زمان طراحی تکیه می‌کنند، در سناریوهای خارج از پیش‌بینی‌های اولیه با زوال عملکرد یا توقف کامل مواجه می‌شوند.

به منظور غلبه بر این محدودیت‌ها، سیستم‌های خودوفق (SAS) به عنوان یک پارادایم اساسی در مهندسی نرم‌افزار نوین ظهور کردند. این سیستم‌ها مجهز به حلقه‌های بازخوردی خودمختار هستند که به سیستم اجازه می‌دهند تا به طور پیوسته وضعیت درونی و بیرونی خود را پایش کرده، انحرافات از اهداف تعیین‌شده را تحلیل کرده، تغییرات بهینه را برنامه‌ریزی و در نهایت در زمان اجرا اعمال نمایند.

ایده اولیه این رویکرد به کارهای بنیادین شرکت IBM در سال ۲۰۰۳ تحت عنوان رایانش خودمختار توسط کیفارت و چس [؟] بازمی‌گردد. در ادامه، اوریزی و همکاران (۱۹۹۹) [؟] یکی از نخستین رویکردهای معماریمحور برای سیستم‌های خودوفق را معرفی کردند که بر استفاده از مدل‌های زمان اجرا برای هدایت تصمیمات وفقی تأکید داشت. همچنین چنگ و همکاران (۲۰۰۹) [؟] در نقشه‌راه تحقیقاتی مهندسی نرم‌افزار برای سیستم‌های خودوفق، بر اهمیت مدل‌های خودمختار زمان اجرا، مدیریت عدم قطعیت و تضمین‌های کیفیت تأکید نمودند. ادغام حلقه‌های کنترلی خودمختار با تکنیک‌های تصمیم‌گیری هوشمند، سنگ بنای سیستم‌های خودوفق مدرن را شکل می‌دهد.

## ۱-۲ اهداف رساله

این رساله در راستای تکمیل شکاف‌های تحقیقاتی پیشین [؟] و پاسخ به چالش‌های حل‌نشده، یک هدف اصلی و سه هدف فرعی را دنبال می‌کند:

**هدف اصلی: توسعه و اعتبارسنجی روش یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) به‌گونه‌ای که بر مشکل بنیادین گیرافتادن در بهینه‌های محلی در فضاهای وفقی گسسته و بزرگ غلبه کند. این روش سیستم‌های خودوفقی را قادر می‌سازد تا بدون نیاز به بازآموزی پرهزینه و اخلال‌گر، عملکردی نزدیک به بهینه را به‌طور پیوسته در شرایط عدم قطعیت محیطی حفظ نمایند.**

این هدف اصلی، هسته‌ی نوآوری رساله (مکانیزم شکل‌دهی تصادفی پاداش) را مستقیماً به چالش اساسی شناسایی‌شده در بیان مسئله پیوند می‌دهد.

**اهداف فرعی:** در راستای تحقق هدف اصلی، اهداف فرعی زیر تعریف شده‌اند:

۱. **طراحی معماری مقیاس‌پذیر و یکپارچه:** ایجاد معماری مدولاری که عامل RS-DRL را به‌طور ناهمگام با حلقه‌ی خودمختار MAPE-K ادغام نموده و امکان اعتبارسنجی صوری تصمیمات پیش از اجرا را فراهم آورد. این هدف تضمین می‌کند که راهکار پیشنهادی نه تنها هوشمند، بلکه قابل‌اعتماد و قابل‌استقرار در سیستم‌های زمان‌اجرای واقعی باشد.

۲. **مدیریت کارآمد فضاهای وفقی گسسته با ابعاد بسیار بزرگ:** نشان دادن این که روش RS-DRL قادر است در سیستم‌هایی با فضای وفقی تا ۴۰۹۶ گزینه (مانند DeltaIoTv2)، بدون افت محسوس عملکرد، گزینه‌های بهینه یا نزدیک به بهینه را در زمان کوتاه انتخاب کند. این هدف، مقیاس‌پذیری عملی راهکار را برای کاربردهای دنیای واقعی اثبات می‌نماید.

۳. **ارزیابی تجربی جامع و اثبات برتری آماری:** مقایسه‌ی کمی دقیق روش RS-DRL با روش‌های پیشرفته‌ی موجود (شامل $\epsilon$-greedy DQN، HER، Soft HER، DLASER و ML4EAS) از نظر عملکرد مجانبی، سرعت همگرایی، و بهینه‌سازی چندهدفه، همراه با ارائه‌ی تحلیل‌های آماری معنی‌دار (مانند t-test و فواصل اطمینان) برای تصدیق برتری روش پیشنهادی.

## ۱-۳ چالش‌ها

چالش‌ها و منابع عدم قطعیت در سیستم‌های مختلف به شکل‌های گوناگونی بروز می‌یابند. به‌عنوان مثال، در سیستم‌های مستقر در محیط‌های پویا نظیر برنامه‌های اینترنت اشیا (IoT) در شهرهای هوشمند، تغییرات آب و هوایی تأثیر قابل توجهی می‌گذارد. همچنین محیط‌های ابری با تقاضای منابع متغیر، امنیت سایبری با تهدیدات نوظهور و مداوم، تجارت الکترونیک و شبکه‌های اجتماعی با رفتار غیرقابل پیش‌بینی کاربران، و سیستم‌های توزیع‌شده با تأخیر شبکه، خرابی سخت‌افزار و تغییرات زیرساختی روبه‌رو هستند.

هنگامی که سیستم با فضای وفقی گسترده و گزینه‌های متعدد تغییر مواجه می‌شود، انتخاب گزینه‌ای وفقی که با اهداف سیستم همسو باشد، از نظر محاسباتی بسیار پرهزینه و دشوار، و در برخی موارد تقریباً غیرممکن می‌گردد.

روش‌های موجود برای مدیریت عدم قطعیت در سیستم‌های خودوفقی با محدودیت‌های قابل‌توجهی مواجه هستند. به‌عنوان مثال، روش‌های مبتنی بر یادگیری ماشین نیازمند داده‌های آموزشی برچسب‌دار هستند که نمایانگر محیط سیستم باشند. به دست آوردن چنین داده‌هایی در زمان طراحی به دلیل عدم قطعیت فراوان بسیار دشوار است. از طرفی، روش‌های مبتنی بر جستجو (مانند الگوریتم‌های صعود تپه و الگوریتم‌های ژنتیک) با مشکلات مقیاس‌پذیری مواجه هستند و عملکرد آن‌ها با تغییر شرایط محیطی دچار افت محسوس می‌شود.

یادگیری تقویتی عمیق (DRL) علیرغم قدرت بالا، خود با چالش‌های اساسی نظیر گیرافتادن در بهینه‌های محلی مواجه است. این چالش در سیستم‌هایی با فضای وفقی گسسته و بزرگ به‌مراتب تشدید می‌شود؛ زیرا هرچه تعداد گزینه‌های وفقی بیشتر باشد، احتمال همگرایی مدل به راه‌حل‌های بهینه‌ی محلی به جای بهینه‌های سراسری افزایش می‌یابد و کاوش کافی در فضای عمل دشوارتر می‌گردد. بهینه‌های محلی به راه‌حل‌هایی اشاره دارند که تنها در یک منطقه محدود از فضای مسئله بهینه هستند و به صورت سراسری بهترین راه‌حل ممکن محسوب نمی‌شوند. در زمینه DRL، این بدان معناست که مدل ممکن است سیاستی را یاد بگیرد که تحت شرایط خاص به خوبی عملکرد مناسبی دارد، اما در صورت تغییر محیط قادر به تعمیم‌پذیری و حفظ عملکرد

مطلوب نیست.

علاوه بر این، آموزش مجدد یا بازآموزی (Retraining) مدل در زمان اجرا فرآیندی پرهزینه است. بازآموزی شامل مراحل متعددی مانند جمع‌آوری داده‌های جدید، ارزیابی مجدد ساختار و پارامترهای مدل، و تست مدل به‌روزشده برای اطمینان از عملکرد بهتر آن نسبت به نسخه قبلی است. در طول این فرآیند، سیستم ممکن است به صورت غیربهینه عمل کند که در سیستم‌های حیاتی، این دوره عملکرد نامطلوب می‌تواند پیامدهای جبران‌ناپذیری به همراه داشته باشد.

## ۱-۴ بیان مساله

به طور خلاصه، سیستم‌های خودوفقی مدرن در محیط‌های پویا و غیرقابل‌پیش‌بینی نظیر شبکه‌های اینترنت اشیاء، رایانش ابری و شهرهای هوشمند عمل می‌کنند. این سیستم‌ها اغلب با فضاهای وفقی گسسته و بزرگ مواجه هستند که می‌تواند شامل صدها یا هزاران گزینه پیکربندی مختلف باشد (برای مثال، شبکه حسگر DeltaIoTv2 [؟] دارای ۴۰۹۶ گزینه وفقی است). مدل‌های سنتی یادگیری تقویتی عمیق (DRL) که برای تصمیم‌گیری در این فضاها به کار گرفته می‌شوند، با دو چالش بنیادین مواجه‌اند. از یک سو، **گیرافتادن در بهینه‌های محلی** مشکل اساسی است؛ الگوریتم‌هایی مانند $\epsilon$-greedy DQN به دلیل ماهیت کاوشگری محدود خود، اغلب در نقاط بهینه محلی متوقف می‌شوند و قادر به کشف سیاست‌های سراسری بهینه نیستند [؟] و این مشکل در فضاهای وفقی بزرگ به مراتب حادتر می‌شود. از سوی دیگر، **نیاز به بازآموزی مکرر و پرهزینه** چالش دیگری را تشکیل می‌دهد؛ در مواجهه با تغییرات محیطی (رانش مفهومی [؟])، مدل‌های سنتی نیاز به بازآموزی کامل دارند که این فرآیند زمان‌بر و محاسباتی سنگین است و در طول دوره بازآموزی، سیستم عملکرد نامطلوبی از خود نشان می‌دهد که در سیستم‌های حیاتی می‌تواند پیامدهای جبران‌ناپذیری به همراه داشته باشد.

روش‌های پیشرفته‌تری مانند HER [؟] و Soft HER [؟] نیز اگرچه در حوزه محیط‌های هدف‌محور موفق بوده‌اند، اما برای سیستم‌های خودوفقی با اهداف مبهم و آستانه‌ای (مانند بهینه‌سازی همزمان مصرف انرژی، تأخیر و تلفات بسته) طراحی نشده‌اند و نمی‌توانند بدون دانش دامنه خاص عمل کنند. بنابراین، مسئله اصلی این رساله را می‌توان به صورت زیر فرموله کرد:

**طراحی روش یادگیری تقویتی عمیق که (۱) بدون نیاز به بازآموزی مکرر و پرهزینه، از بهینه‌های محلی در فضاهای وفقی گسسته و بزرگ (تا ۴۰۹۶ گزینه) عبور کند، (۲) قابلیت تعمیم‌پذیری به شرایط محیطی متغیر را داشته باشد، و (۳) مستقل از دانش دامنه خاص عمل کند.**

## فرمول‌بندی ریاضی مختصر مساله

برای درک عمیق‌تر چالش‌های تصمیم‌گیری در سیستم‌های خودوفق، در این بخش مسئله تطبیق زمان اجرا را به صورت ریاضی فرمول‌بندی می‌کنیم. این فرمول‌بندی سطح بالا مبنایی برای ارائه جزئیات کامل در فصل دوم خواهد بود.

**تعریف فضای وفقی:** فضای وفقی سیستم شامل مجموعه‌ای متناهی از گزینه‌های پیکربندی یا اعمال وفقی گسسته است که با $\mathcal{A}$ نشان داده می‌شود:

$$\mathcal{A} = \{a_1, a_2, \ldots, a_n\}, \quad n \leq ۴۰۹۶ \tag{۱-۱}$$

هر گزینه $a_i \in \mathcal{A}$ نمایانگر یک پیکربندی شبکه، توزیع منابع، یا پهنای باند اختصاص‌یافته در یک لحظه مشخص است. در این تحقیق، ابعاد فضای وفقی تا مقیاس بزرگ ($n = ۴۰۹۶$) مورد بررسی قرار گرفته است.

**مدل فرآیند تصمیم‌گیری مارکوف:** مسئله تطبیق را به صورت یک فرآیند تصمیم‌گیری مارکوف (MDP) مدل‌سازی می‌کنیم [؟، ؟]. فضای حالت $\mathcal{S}$ وضعیت‌های سیستم و شرایط تداخل محیطی را پوشش می‌دهد. در هر گام زمانی $t$، عامل وفقی بر اساس سیاست تطبیق خود $\pi(a|s)$، اقدامی مانند $a_t \in \mathcal{A}$ را در حالت $s_t \in \mathcal{S}$ انتخاب می‌کند که منجر به انتقال به حالت بعدی $s_{t+1}$ و دریافت پاداش بازخوردی $R(s_t, a_t)$ می‌گردد.

**تابع هدف:** هدف نهایی عامل، پیدا کردن یک سیاست بهینه تطبیق $\pi^*$ است که امید ریاضی مجموع پاداش‌های تنزیل‌شده بلندمدت سیستم را بیشینه کند:

$$\max_{\pi} \mathbb{E}\left[\sum_{t=۰}^{\infty} \gamma^t R(s_t, a_t)\right] \tag{۲-۱}$$

که در آن $\gamma \in [۰, ۱)$ نرخ تنزیل پاداش‌های آتی است.

**قیود عملیاتی مسئله:** سیاست استخراج‌شده $\pi^*$ باید تحت سه قید عملیاتی و بنیادین زیر بهینه‌سازی شود:

۱. **قید خروج از بهینه‌های محلی بدون بازآموزی:** عامل یادگیرنده باید قادر باشد بدون ایجاد اخلال در سیستم در قالب بازآموزی مکرر در زمان اجرا، از نقاط بهینه محلی عبور کند.

۲. **قید مقیاس‌پذیری زمانی:** زمان پاسخ محاسباتی برای انتخاب عمل بهینه $a^* \in \mathcal{A}$ در زمان اجرا باید بسیار ناچیز و در حد میلی‌ثانیه باشد تا به سرعت به رانش مفهومی پاسخ داده شود.

۳. **قید استقلال از دانش دامنه:** مکانیزم کاوشگری عامل نباید به فرمول‌بندی پاداش‌های دقیق و متکی بر دانش تخصصی مهندسان دامنه وابسته باشد و باید به طور خودمختار رفتار کاوشگری بهینه را هدایت کند.

# پیشینه و شکاف تحقیقاتی

اگرچه کارهای کلاسیک در حوزه سیستم‌های خودوفق زیربنای نظری این پارادایم را ایجاد کرده‌اند، اما انتخاب استراتژی تطبیق بهینه در زمان اجرا همچنان یک چالش اساسی است. در این بخش، خلاصه‌ای از پیشینه پژوهش در طراحی مکانیزم‌های تصمیم‌گیری در فضاهای وفقی بزرگ ارائه شده و شکاف‌های تحقیقاتی موجود شناسایی می‌گردد.

## مرور دسته‌بندی‌شده رویکردهای موجود

به طور کلی، تحقیقات صورت گرفته در ادبیات سیستم‌های خودوفق جهت هدایت فرآیند تصمیم‌گیری زمان اجرا را می‌توان به سه دسته اصلی تقسیم‌بندی نمود:

۱. **رویکردهای مبتنی بر یادگیری ماشین سنتی:** این رویکردها از مدل‌های یادگیری نظارت‌شده یا بدون نظارت برای کاهش ابعاد فضای وفقی یا پیش‌بینی اثرات پیکربندی‌ها استفاده می‌کنند.

۲. **رویکردهای مبتنی بر جستجو:** این روش‌ها مسائل تطبیق زمان اجرا را به عنوان یک مسئله بهینه‌سازی مدل‌سازی کرده و از الگوریتم‌های اکتشافی یا جستجوی تصادفی استفاده می‌کنند.

۳. **رویکردهای مبتنی بر یادگیری تقویتی:** این مدل‌ها به عامل اجازه می‌دهند تا سیاست بهینه تطبیق را از طریق آزمون و خطا در تعامل مستقیم با محیط یاد بگیرد.

## محدودیت‌ها و تبیین شکاف تحقیقاتی

هر یک از دسته‌بندی‌های فوق در مواجهه با چالش‌های زمان اجرا دارای محدودیت‌های خاصی هستند:

- **محدودیت‌های روش‌های مبتنی بر یادگیری ماشین:** کویین و همکاران در پژوهش‌های خود [؟، ؟] نشان داده‌اند که این روش‌ها وابستگی شدیدی به در دسترس بودن داده‌های آموزشی برچسب‌دار با کیفیت بالا در زمان طراحی دارند. در محیط‌های به شدت نامشخص، توزیع داده‌های محیطی زمان اجرا با توزیع فرضی زمان طراحی تفاوت دارد که منجر به پدیده رانش مفهومی (Concept Drift) [؟] و در نتیجه افت شدید دقت پیش‌بینی مدل‌ها می‌گردد.

- **محدودیت‌های روش‌های مبتنی بر جستجو:** کوکر (۲۰۱۵) [؟] و کینیر و همکاران (۲۰۱۸، ۲۰۲۱) [؟، ؟] نشان داده‌اند که اگرچه الگوریتم‌های بهینه‌سازی تصادفی کارایی مناسبی در فضاهای وفقی کوچک دارند، اما در فضاهای وفقی گسسته و بزرگ (با صدها یا هزاران پیکربندی) دچار مشکل مقیاس‌پذیری و تأخیر محاسباتی بسیار بالا در زمان اجرا می‌شوند. در چنین فضاهایی، اجرای جستجو در زمان تطبیق با محدودیت‌های زمانی شدید سیستم همخوانی ندارد.

- **محدودیت‌های روش‌های یادگیری تقویتی سنتی:** رویکردهای مبتنی بر یادگیری تقویتی عمیق سنتی (نظیر الگوریتم‌های DQN با مکانیزم‌های کاوش متداول مانند $\epsilon$-greedy) به دلیل محدودیت کاوشگری خود، در فضاهای بزرگ به شدت مستعد گیرافتادن در بهینه‌های محلی هستند [؟، ؟]. عبور از این نقاط بهینه محلی معمولاً نیازمند فرآیندهای پرهزینه و زمان‌بر بازآموزی (Retraining) در زمان اجرا است که موقتاً ثبات عملکرد سیستم را مختل می‌سازد.

با بررسی ادبیات موجود، شکاف تحقیقاتی کلیدی زیر شناسایی می‌شود:

*«هیچ‌یک از رویکردهای موجود در مهندسی سیستم‌های خودوفق قادر نبوده‌اند به طور همزمان (۱) بدون نیاز به بازآموزی‌های محاسباتی مکرر و اخلال‌گر، از بهینه‌های محلی در زمان اجرا عبور کنند، (۲) در فضاهای وفقی گسسته و بزرگ (تا مقیاس ۴۰۹۶ گزینه تغییر) به صورت زمان‌حقیقی مقیاس‌پذیر باشند، و (۳) مستقل از دانش دامنه خاص (Domain-agnostic) برای هدایت فرآیند کاوش عمل کنند.»*

این رساله با هدف پر کردن این خلاء تحقیقاتی، روش نوین یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) را پیشنهاد و اعتبارسنجی می‌کند.

## ۱-۵ سؤالات پژوهش

با توجه به محدودیت‌های رویکردهای پیشین و نیز دستاوردهای آن‌ها که در بخش پیشینه و شکاف تحقیقاتی تبیین گردید [؟، ؟]، این رساله در صدد پاسخ به پرسش‌های اساسی زیر همراه با زیرسؤالات متناظر است:

۱. **سؤال اول:** چگونه می‌توان روشی مبتنی بر یادگیری تقویتی عمیق طراحی کرد که به‌طور مؤثر از بهینه‌های محلی در فضاهای وفقی گسسته و بزرگ، بدون نیاز به بازآموزی مکرر و پرهزینه، عبور کند؟

- **زیرسؤال ۱-۱:** چه مکانیزمی برای تزریق هوشمند و کنترل‌شده‌ی «خوش‌بینی» به فرآیند بازپخش تجربیات یادگیرنده بدون تأثیر نامطلوب بر پایداری مدل می‌توان طراحی کرد؟
- **زیرسؤال ۱-۲:** چگونه می‌توان از تجربیات ناموفق گذشته عامل بدون وارد شدن به فاز آموزش مجدد زمان اجرا استفاده کرد؟

- **زیرسؤال ۱-۳:** چه تضمینی برای عدم همگرایی واگرا یا بی‌ثبات در محیط‌های دارای تداخل شدید در فرآیند یادگیری وجود دارد؟

۲. **سؤال دوم:** چگونه می‌توان مکانیزم‌های شکل‌دهی تصادفی پاداش (Random Reward Shaping) را با بازپخش تجربه (Experience Replay) ادغام کرد تا تعمیم‌پذیری سیستم در تغییرات شرایط محیطی بهبود یابد؟

۳. **سؤال سوم:** چگونه روش پیشنهادی می‌تواند فضاهای وفقی گسسته و بزرگ (از ۲۱۶ تا ۴۰۹۶ گزینه) را در حین حفظ عملکردی نزدیک به بهینه، به شکل کارآمدی مدیریت کند؟

۴. **سؤال چهارم:** تا چه حد روش پیشنهادی (RS-DRL) از روش‌های موجود نظیر یادگیری ای‌گرایانه حریصانه ($\epsilon$-greedy DQN) [؟]، HER [؟]، Soft HER [؟]، DLASER [؟] و ML4EAS [؟] از منظر عملکرد مجانبی، سرعت همگرایی، و بهینه‌سازی چندهدفه، برتری و عملکرد بهتری از خود نشان می‌دهد؟

- **زیرسؤال ۴-۱:** عملکرد مجانبی RS-DRL در بلندمدت در مقایسه با الگوریتم‌های استاندارد یادگیری تقویتی نظیر DQN و مدل‌های پس‌نگر نظیر HER در محیط‌های غیرایستا چگونه است؟
- **زیرسؤال ۴-۲:** سرعت همگرایی روش پیشنهادی در فضاهای وفقی با ابعاد بسیار بزرگ (مانند شبکه با ۴۰۹۶ حالت پیکربندی) چه تفاوتی با رویکردهای یادگیری عمیق فشرده‌کننده نظیر DLASER+ دارد؟
- **زیرسؤال ۴-۳:** آیا برتری‌های عملکردی حاصل از روش پیشنهادی از نظر آماری در مقایسه با سایر استراتژی‌ها معنادار است؟

## ۱-۶ روش پیشنهادی

### ۱-۶-۱ مرور کلی بر راهکار RS-DRL

راهکار پیشنهادی در این رساله مبتنی بر توسعه یک معماری یادگیری هوشمند است که به جای تکیه بر دانش ایستا، از طریق تعامل مستقیم با محیط، سیاست‌های بهینه را استخراج می‌کند. این روش مسئله تطبیق را به‌عنوان یک فرآیند تصمیم‌گیری مارکوف (MDP) مدل‌سازی کرده و با ادغام مدل‌های عمیق و لایه مدیریت خودمختار، یک چرخه پیوسته از یادگیری و اجرا را فراهم می‌آورد. هسته نوآورانه این روش، مکانیزم «شکل‌دهی تصادفی پاداش» است که با بازطراحی تصادفی برخی تجربیات ناموفق گذشته، عامل را قادر به فرار از بهینه‌های محلی بدون نیاز به بازآموزی پرهزینه می‌سازد. تمرکز اصلی بر ارائه چارچوبی است که در آن، عامل یادگیرنده

نه تنها بر اساس پاداش‌های آنی، بلکه با هدف حفظ عملکرد مطلوب در بازه زمانی طولانی، کاهش نیاز به بازآموزی‌های مکرر و پایداری معیارهای کیفی سیستم نظیر مصرف انرژی و زمان تأخیر، عمل کند.

### ۱-۶-۲ یکپارچه سازی راهکار RS-DRL با حلقه کنترلی MAPE-K

روش پیشنهادی با بهره‌گیری از چارچوب استاندارد MAPE-K، فرآیند تطبیق را به صورت ساختاریافته مدیریت می‌کند. در این معماری، عامل RS-DRL در مؤلفه برنامه‌ریزی (Plan) مستقر شده و خروجی‌های آن (گزینه وفقی پیشنهادی) پیش از اجرا توسط ابزار تأیید صوری UPPAAL-SMC از نظر ایمنی و قابلیت اطمینان ارزیابی می‌گردند. سپس گزینه‌های تأییدشده بر روی سیستم مدیریت‌شونده اعمال می‌شوند. این یکپارچگی تضمین می‌کند که تصمیمات هوشمندانه‌ی عامل DRL تنها پس از اعتبارسنجی صوری به اجرا درآیند.

## ۱-۷ نوآوری‌های اصلی رساله

بنیانِ علمی و سهم پژوهشی این پایان‌نامه در قالب چهار نوآوری اصلی زیر تبیین می‌گردد که هر یک به طور مستقیم به رفع یکی از محدودیت‌های کلیدی در ادبیات موضوع می‌پردازد:

۱. **نوآوری اول: الگوریتم یادگیری تقویتی با شکل‌دهی تصادفی پاداش (RS-DRL):** ارائه یک مکانیزم نوین شکل‌دهی پاداش تصادفی زمان اجرا که برای اولین بار برخی از تجربیات ناموفق گذشته را بدون نیاز به دانش دامنه خاص بازطراحی می‌کند. در حالی که رویکردهای پیشین مانند HER [؟] نیازمند تعریف اهداف صریح زمان اجرا و دانش عمیق فرمول‌بندی محیط هستند، روش پیشنهادی با تخصیص پاداش مثبت به زیرمجموعه‌ای تصادفی از تجربیات گذشته، بدون هیچ‌گونه دانش دامنه‌ای، عامل یادگیرنده را قادر به کاوش کارآمد فضای وفقی و خروج موفقیت‌آمیز از بهینه‌های محلی می‌سازد. این رویکرد به ویژه مانع همگرایی واگرا یا گیرافتادن در نقاط پایدار محلی می‌شود.

۲. **نوآوری دوم: ادغام معماری RS-DRL در حلقه MAPE-K:** طراحی یک معماری سیستماتیک و تلفیقی ناهمگام که عامل یادگیرنده هوشمند را در مؤلفه تصمیم‌گیری حلقه کنترل خودمختار تعبیه می‌کند. برخلاف رویکردهای کلاسیک که فرآیند آموزش عمیق را به صورت آفلاین یا کاملاً مجزا انجام می‌دهند، در این معماری فرآیند آموزش پیوسته و استنتاج به صورت پویا با پایش وضعیت فیزیکی سیستم همگام شده و گزینه‌های تصمیم‌گیری پیش از اعمال، برای اطمینان صد درصدی از پایداری کیفیت خدمات، از فیلتر اعتبارسنجی صوری ابزار UPPAAL-SMC عبور می‌کنند.

۳. **نوآوری سوم: مدیریت فضای وفقی مقیاس‌پذیر و گسسته در ابعاد بزرگ:** ارائه یک راهکار مقیاس‌پذیر زمان‌اجرا جهت اتخاذ تصمیمات وفقی چندهدفه در ابعاد تا ۴۰۹۶ گزینه تغییر. در حالی که روش‌های سنتی مبتنی بر جستجو نظیر الگوریتم ژنتیک یا روش‌های شبیه‌سازی تصادفی به علت سربار محاسباتی

بسیار بالا در مواجهه با ابعاد ۴۰۹۶ با اخلال مواجه می‌شوند، روش پیشنهادی با کاهش زمان تصمیم‌گیری استنتاج مدل به مقیاس میلی‌ثانیه، پایداری همزمان مصرف انرژی و قابلیت اطمینان ارتباطات را تضمین می‌کند.

۴. **نوآوری چهارم: معماری جداسازی زمانی (Temporal Separation):** توسعه یک متدولوژی سازماندهی زمانی که مسیر تصمیم‌گیری آنلاین (با استنتاج زیر میلی‌ثانیه) را به طور کامل از ریسمان‌های سنگین آموزش ناهمگام در پس‌زمینه تفکیک می‌کند. این نوآوری معماری تضمین می‌کند که افزایش ابعاد فضای وفقی تا ۴۰۹۶ گزینه، کوچک‌ترین خللی در سرعت تصمیم‌گیری بلادرنگ و پایداری عملیاتی سیستم وارد نسازد.

# محدوده، قلمرو و مخاطبان پژوهش

## محدوده و قلمرو پژوهش (داخل و خارج از محدوده)

برای تبیین دقیق مرزها و قلمرو این رساله دکتری، دامنه‌ی مسائل تحت پوشش (داخل در محدوده) و موضوعاتی که خارج از اهداف این کار پژوهشی هستند (خارج از محدوده)، به صورت زیر مشخص می‌گردد:

**موضوعات داخل در محدوده پژوهش:**

- **فضاهای وفقی گسسته:** این رساله به طور خاص بر سیستم‌های خودوفقی با فضاهای وفقی گسسته متمرکز است که پیکربندی‌های سیستم شامل گزینه‌های عددی یا ساختاری متمایز و مشخص هستند.
- **یادگیری تقویتی مدل آزاد:** رویکرد یادگیری تقویتی به کار گرفته شده از نوع مدل آزاد (Model-free) و مبتنی بر معماری شبکه‌های کیو عمیق (DQN) است که به هیچ مدل از پیش‌تعریف‌شده‌ای از رفتار محیط وابسته نیست.
- **سیستم‌های حسگر بی‌سیم صنعتی:** مطالعه موردی مرجع و اصلی جهت شبیه‌سازی و ارزیابی تجربی، بستر نام‌آشنای DeltaIoT [؟] (در نسخه‌های ۱v و ۲v با ابعاد مختلف فضای وفقی) است که چالش‌های محیطی شدید و پویایی بالایی دارد.
- **سامانه‌های پهپادی خودگردان:** مطالعه مورد دوم جهت ارزیابی استقلال از دامنه روش پیشنهادی، شبیه‌ساز مأموریت تاکتیکی پهپادها تحت عنوان DARTSim است که تصمیم‌گیری بلادرنگ در فضای وفقی گسسته بزرگ Action (Discrete Space) را در حضور تهدیدات محیطی بررسی می‌کند.

**موضوعات خارج از محدوده پژوهش:**

- **فضاهای وفقی پیوسته:** تحلیل و مدل‌سازی سیستم‌های خودوفق با پارامترهای تطبیق کاملاً پیوسته خارج از محدوده این کار بوده و به عنوان زمینه‌های پیشنهادی برای تحقیقات آینده در نظر گرفته شده است.
- **سیستم‌های چندعاملی:** تمرکز این رساله بر سناریوهای تصمیم‌گیری تک‌عاملی متمرکز است که در آن یک عامل خودمختار مرکزی مسئولیت تطبیق را بر عهده دارد. بررسی سیستم‌های توزیع‌شده با یادگیری تقویتی چندعاملی (MARL) مد نظر نبوده است.
- **اثبات قضایای ریاضی همگرایی محض:** تضمین همگرایی و کارایی روش پیشنهادی به صورت تجربی و مبتنی بر شبیه‌سازی‌های فشرده و گسترده و تحلیل‌های آماری معتبر اثبات شده است، نه از طریق روابط اثبات تئوریک همگرایی ریاضی صوری در شرایط نامحدود.

## مخاطبان و کاربردهای بالقوه

دستاوردها و راهکارهای ارائه شده در این رساله دکتری می‌تواند برای طیف وسیعی از محققان و حوزه‌های کاربردی سودمند واقع شود. این پژوهش در وهله نخست برای **محققان مهندسی نرم‌افزار** خودوفق، حلقه‌های کنترلی خودمختار (MAPE-K) و تضمین کیفیت زمان اجرا ارزشمند است. در وهله دوم، **طراحان سیستم‌های اینترنت اشیاء و شبکه‌های حسگر بی‌سیم** که نیازمند استقرار سیستم‌های پایدار در مواجهه با اختلالات پویای سیگنال هستند از این رساله بهره می‌برند. سرانجام، **توسعه‌دهندگان الگوریتم‌های یادگیری تقویتی عمیق** که با چالش گیرافتادن در بهینه‌های محلی در فضاهای عمل گسسته دست‌وپنجه نرم می‌کنند، مخاطبان اصلی یافته‌های این رساله محسوب می‌شوند.

## ۱-۸ مروری بر فصول رساله

ساختار رساله به گونه‌ای طراحی شده است که به‌طور نظام‌مند روند توسعه، اجرا و ارزیابی رویکرد پیشنهادی را در اختیار خواننده قرار دهد. در ادامه، نقش و کارکرد هر یک از فصول در راستای زنجیره استدلالی و پاسخ به سوالات رساله تشریح می‌گردد:

**فصل ۱: کلیات** در این فصل، کلیات پژوهش، بیان مسئله، اهداف و نوآوری‌های رساله به همراه سوالات تحقیق و مروری بر ساختار کل رساله ارائه می‌گردد تا خواننده با بستر کلی و ضرورت طرح پژوهش آشنا شود.

**فصل ۲: مبانی نظری و مدل سیستم** این فصل زیربنای ریاضی و مفهومی لازم برای درک روش پیشنهادی را فراهم می‌کند. در این فصل، مبانی سیستم‌های خودوفقی (حلقه MAPE-K)، منابع عدم قطعیت و رویکردهای

مدل‌سازی زمان اجرا (از جمله ابزار UPPAAL-SMC)، و اصول یادگیری تقویتی (فرآیند تصمیم‌گیری مارکوف و الگوریتم DQN) تشریح شده و مدل ریاضی سیستم بستر DeltaIoT فرموله می‌گردد.

**فصل ۳: مرور ادبیات و کارهای مرتبط** با بهره‌گیری از چارچوب نظری فصل دوم، این فصل به بررسی انتقادی و جامع رویکردهای پیشین پرداخته و با تحلیل نقاط قوت و ضعف آن‌ها، ضرورت علمی و موقعیت رساله حاضر در بدنه دانش سیستم‌های خودوفق را مستحکم می‌سازد.

**فصل ۴: روش پیشنهادی RS-DRL: معماری و الگوریتم** این فصل هسته نوآوری و طراحی فنی رساله را پوشش می‌دهد. در این فصل، جزئیات الگوریتمی مکانیزم شکل‌دهی تصادفی پاداش، معماری یکپارچه ناهمگام با حلقه کنترلی خودمختار و فرآیند اعتبارسنجی صوری پیش از اجرا توسط ابزار UPPAAL-SMC به تفصیل ارائه می‌شود تا به سوالات اول و دوم رساله پاسخ داده شود.

**فصل ۵: ارزیابی تجربی** این فصل جنبه‌های عملیاتی، پیاده‌سازی و اعتبارسنجی تجربی رساله را شامل می‌شود. شبیه‌سازی‌ها و مقایسه‌های گسترده با رقبای نام‌آشنا روی سناریوهای مختلف بستر DeltaIoT مستند شده و تحلیل‌های آماری معتبر در این فصل ارائه می‌شود تا پاسخ به سوالات سوم و چهارم رساله تصدیق گردد.

**فصل ۶: بحث و نتیجه‌گیری** در نهایت، این فصل مصالحه‌های رفتاری، محدودیت‌های فنی و دستاوردهای کاربردی سیستم را جمع‌بندی نموده و افق‌های جدیدی برای پژوهش‌های آتی در توسعه مهندسی سیستم‌های خودوفق هوشمند ترسیم می‌کند.

# فصل دوم

# مبانی نظری و مدل‌سازی سیستم

## ۲-۱ مقدمه

سیستم‌های نرم‌افزاری معاصر به طور فزاینده‌ای در محیط‌هایی پویا، توزیع‌شده و اساساً غیرقابل پیش‌بینی فعالیت می‌کنند. این سیستم‌ها طیف وسیعی از کاربردها، از شبکه‌های حسگر بی‌سیم مقیاس‌وسیع در اینترنت اشیاء گرفته تا میکروسرویس‌های ابری را شامل می‌شوند. چنین سیستم‌های پیچیده‌ای باید اهداف کیفیت خدمات (QoS) خود را در حضور عدم قطعیت‌های مداوم زمان اجرا حفظ نمایند.

برای مواجهه با این چالش، رویکرد سیستم‌های خودوفق (Self-Adaptive Systems) به عنوان یک پارادایم محوری در مهندسی نرم‌افزار مطرح شده است. سیستم‌های خودوفق با مجهز شدن به حلقه‌های بازخورد کنترلی، قادرند رفتار و ساختار خود را در زمان اجرا ارزیابی کرده و تغییرات بهینه را بدون نیاز به مداخله صریح انسانی اعمال کنند.

هدف محوری این فصل، پی‌ریزی یک چارچوب نظری و ریاضی مستحکم برای تحلیل، طراحی و مدل‌سازی چنین سیستم‌هایی است تا زمینه لازم برای درک متدولوژی پیشنهادی این رساله (RS-DRL) فراهم گردد. این فصل ابتدا مبانی سیستم‌های خودوفق، معماری‌های مرجع و الگوهای طراحی کلاسیک را تبیین می‌کند. سپس، با ورود به مبحث عدم قطعیت، دسته‌بندی‌های مختلف آن و روش‌های مدل‌سازی زمان اجرا بر پایه وارسی مدل آماری (SMC) بررسی می‌شود. در ادامه، مبانی مدل‌سازی ریاضی تصمیم‌گیری از طریق فرآیندهای تصمیم‌گیری مارکوف (MDP) و روش‌های یادگیری تقویتی جدول‌محور و عمیق (DQN) تشریح می‌گردد. سرانجام، با استفاده از سیستم محک استاندارد DeltaIoT به عنوان مطالعه موردی، فرمول‌بندی MDP دقیق سیستم ارائه شده و مسئله بهینه‌سازی نهایی تحت قیود عملیاتی زمان اجرا به صورت صوری تبیین می‌گردد.

# ۲-۲ مبانی سیستم‌های خودوفقی

## ۲-۲-۱ مفاهیم اصلی و تعاریف

سیستم خودوفق به کلاسی از سیستم‌های نرم‌افزاری گفته می‌شود که ویژگی‌های زیر را دارد: (۱) به طور مداوم وضعیت داخلی و محیط پیرامون خود را ارزیابی می‌کند. (۲) می‌تواند ساختار، رفتار یا پارامترهای عملیاتی خود را تغییر دهد. (۳) هدف این تغییرات، دستیابی به اهداف تجاری یا کیفی مشخص است [؟]. در مبانی مهندسی نرم‌افزار خودوفق، سه مفهوم کلیدی زیر همواره به عنوان ارکان اساسی تعریف می‌شوند:

۱. **فضای وفقی (Adaptation Space):** مجموعه تمامی‌پیکربندی‌ها، سناریوها یا تصمیمات متمایزی است که سیستم می‌تواند در زمان اجرا اتخاذ کند. در دامنه‌های واقعی، ابعاد این فضا به صورت ترکیبی رشد کرده و می‌تواند شامل هزاران یا میلیون‌ها گزینه ممکن باشد.

۲. **اهداف وفقی (Adaptation Goals):** معیارهای عملکردی یا کیفی هستند که سیستم باید آن‌ها را بیشینه، کمینه یا در یک محدوده مشخص حفظ کند. این اهداف می‌توانند در قالب اهداف چندهدفه متضاد (مانند به حداقل رساندن تاخیر همزمان با به حداقل رساندن مصرف باتری) تعریف شوند.

۳. **حلقه بازخورد (Feedback Loop):** جریان اطلاعاتی و کنترلی که به صورت بسته، وظیفه پایش، تصمیم‌گیری و اعمال تغییرات را بر عهده دارد.

تفاوت بنیادین میان سیستم‌های سنتی و خودوفق در نحوه مواجهه با فرضیات فاز طراحی نهفته است. در سیستم‌های کلاسیک، فرض بر این است که شرایط محیطی در فاز طراحی کاملاً شناخته شده و ایستا هستند. اما در محیط‌های معاصر، به دلیل تغییرات جوی، بار ترافیکی پویا و خرابی سخت‌افزاری، فرضیات طراحی به سرعت منقضی می‌شوند. بنابراین، خودوفقی راهکاری برای به تعویق انداختن تصمیمات طراحی به زمان اجراست تا سیستم بتواند بر اساس واقعیت‌های جاری تصمیم‌گیری کند [؟].

## ۲-۲-۲ معماری‌های مرجع و الگوهای طراحی

جهت سازماندهی ساختار درونی سیستم‌های خودوفق، معماری‌های مرجع متعددی ارائه شده است. یکی از برجسته‌ترین و پرکاربردترین الگوها، **معماری سه‌لایه‌ای کرامر و مگی** (Three-Layer Architecture) است که تفکیک دغدغه‌ها را در سطوح مختلف انتزاع تضمین می‌کند. این معماری شامل سه لایه مجزاست که هر یک مسئولیت خاصی را بر عهده دارد [؟]:

- **لایه مدیریت اهداف (Goal Management):** این لایه در بالاترین سطح قرار داشته و وظیفه تفسیر اهداف تجاری کلان و تبدیل آن‌ها به اهداف کیفی در زمان اجرا را بر عهده دارد. در صورت تغییر اولویت‌های کاربر (مثلاً تغییر سیاست از کاهش مصرف انرژی به افزایش حداکثری پایداری)، این لایه اهداف وفقی را بازطراحی می‌کند.

- **لایه مدیریت تغییرات (Change Management):** وظیفه اصلی این لایه، برنامه‌ریزی، استنتاج و تولید طرح‌های تطبیقی است. این لایه گزینه‌های وفقی موجود را ارزیابی کرده و گزینه بهینه را انتخاب می‌نماید. هسته یادگیری عمیق تقویتی پیشنهادی در این رساله (RS-DRL) مستقیماً در این لایه مستقر می‌شود.

- **لایه کنترل مولفه‌ها (Component Control):** لایه پایینی است که مستقیماً با مولفه‌های نرم‌افزاری و سخت‌افزاری سیستم هدف تعامل دارد. این لایه وظیفه جمع‌آوری داده‌ها از حسگرها و اعمال مستقیم فرامین از طریق عملگرها را بر عهده دارد.

تفکیک تمیز این لایه‌ها تضمین می‌کند که تغییر در منطق برنامه‌ریزی یا اهداف کلان تجاری، نیازی به بازطراحی کامل بخش‌های پایین‌دستی و درایورهای سخت‌افزاری نداشته باشد و پایداری سیستم در چرخه‌های وفقی تضمین گردد.

## ۲-۲-۳ حلقه‌های کنترلی خودمختار: از MAPE-K تا موارد پیشرفته

حلقه خودمختار MAPE-K که برای نخستین بار توسط شرکت IBM معرفی شد، استاندارد طلایی و معماری مرجع بی بدیل برای توصیف جریان اطلاعات و کنترل در حلقه‌های بازخورد سیستم‌های خودوفق به شمار می‌رود [؟]. این حلقه متشکل از ۵ مولفه اصلی است که حول یک پایگاه دانش محوری ساماندهی شده‌اند:

۱. **پایش (Monitor):** این مولفه داده‌های خام را از حسگرها جمع‌آوری کرده، نویزهای فرکانس‌بالا را فیلتر نموده و یک نمایش منسجم از وضعیت جاری سیستم و محیط تولید می‌کند.

۲. **تحلیل (Analyze):** مولفه تحلیل وظیفه تطابق وضعیت جاری با اهداف تعریف‌شده را بر عهده دارد. این مولفه مشخص می‌سازد که آیا اهداف کیفی سیستم نقض شده‌اند یا احتمال نقض آن‌ها در آینده نزدیک وجود دارد تا در صورت لزوم فرآیند تطبیق را فعال کند.

۳. **برنامه‌ریزی (Plan):** این بخش مغز متفکر سیستم خودوفق است. با دریافت هشدار از بخش تحلیل، فضای وفقی را جستجو کرده و با ارزیابی گزینه‌های مختلف، سیاستی را برای انتقال سیستم به وضعیت مطلوب طراحی می‌کند.

۴. **اجرا (Execute):** طرح تولید شده در بخش برنامه‌ریزی را به گام‌های عملیاتی و دستورات قابل فهم برای سخت‌افزار تبدیل کرده و آن‌ها را از طریق عملگرها بر سیستم هدف اعمال می‌کند.

۵. **دانش (Knowledge):** به عنوان حافظه مشترک و مخزن داده مرکزی عمل کرده و مدل‌های زمان اجرا، تاریخچه رفتار سیستم، توپولوژی شبکه و اهداف کیفی را نگهداری می‌کند تا چهار مولفه دیگر به طور هماهنگ فعالیت نمایند.

با پیچیده‌تر شدن سیستم‌های توزیع‌شده مدرن، الگوهای پیشرفته‌تری از حلقه‌های بازخورد توسعه یافته‌اند؛ از جمله حلقه‌های بازخورد توزیع‌شده و چندعامله (Decentralized MAPE-K loops) [؟، ؟] که در آن‌ها چندین حلقه محلی از طریق الگوهایی نظیر Coordinated، Master-Slave یا Peer-to-Peer با یکدیگر تعامل دارند. این رویکردهای پیشرفته به ویژه در مدیریت شبکه‌های حسگر بی‌سیم وسیع که فاقد کنترل مرکزی مطلق هستند، بسیار حائز اهمیت می‌باشند [؟، ؟].

## ۲-۳ عدم قطعیت در سیستم‌های خودوفقی

### ۲-۳-۱ دسته‌بندی و انواع عدم قطعیت

عدم قطعیت در مهندسی نرم‌افزار خودوفق به هرگونه نقص در اطلاعات، نویز در داده‌ها یا ماهیت غیرقابل‌پیش‌بینی پارامترهای زمان اجرا اطلاق می‌شود که بر صحت تصمیمات سیستم تاثیر منفی می‌گذارد [؟]. بر اساس متدولوژی‌های معتبر مهندسی، عدم قطعیت در سه لایه کلیدی طبقه‌بندی می‌شود:

- **عدم قطعیت محیطی (Environmental Uncertainty):** ناشی از پارامترهای خارج از کنترل مرز سیستم است. در شبکه‌های حسگر بی‌سیم، تغییرات ناگهانی آب و هوا، رطوبت، باد یا تداخل‌های الکترومغناطیسی محیطی که کیفیت سیگنال ارتباطی را به شدت نوسان می‌دهند، نمونه‌های بارز این دسته هستند.

- **عدم قطعیت سیستمی (Systemic Uncertainty):** ناشی از پویایی درونی خود سیستم است. کاهش تدریجی ولتاژ باتری سنسورها، فرسودگی سخت‌افزاری گره‌ها، مسدود شدن موقت گیت‌وی‌ها به دلیل سربار پردازشی، یا بروز خطا در تعامل میان لایه‌های نرم‌افزاری در این گروه قرار می‌گیرند.

- **عدم قطعیت اهداف (Goal Uncertainty):** زمانی رخ می‌دهد که اولویت‌ها، وزن اهداف متضاد یا آستانه‌های تعریف‌شده توسط ذینفعان انسانی در طول زمان دستخوش تغییر شوند. به عنوان مثال، در شرایط بحرانی، سیستم ممکن است ناچار شود هدفِ مصرف کم انرژی را فدای ارسال حداکثری و سریع پیام‌های هشدار کند.

### ۲-۳-۲ روش‌های مدل‌سازی و رویارویی با عدم قطعیت

برای رویارویی موثر با عدم قطعیت در زمان اجرا، سیستم‌های خودوفق ناگزیرند رفتارهای احتمالی سیستم را مدل‌سازی کنند. دو متدولوژی ریاضی و مهندسی پرکاربرد در این حوزه عبارتند از:

۱. **وارسی مدل آماری زمان اجرا (Runtime Statistical Model Checking - SMC):** ابزارهایی نظیر UPPAAL-SMC با استفاده از مدل‌های احتمالی مبتنی بر اتوماتای زمان‌دار احتمالی، شبیه‌سازی‌های

آماری متعددی را در زمان اجرا بر روی گزینه‌های وفقی پیشنهادی انجام می‌دهند. این روش به جای وارسی صوری مطلق که از لحاظ محاسباتی در زمان اجرا غیرممکن است، با استفاده از نمونه‌برداری‌های آماری دقیق، احتمال نقض اهداف کیفی (نظیر عبور تاخیر از آستانه مجاز) را با فواصل اطمینان مشخص برآورد می‌کند [؟].

۲. **مدل‌های تصمیم‌گیری احتمالی (مانند POMDP در برابر MDP):** در حالی که فرآیند تصمیم‌گیری مارکوف استاندارد (MDP) فرض می‌کند وضعیت سیستم به طور کامل قابل مشاهده است، فرآیند تصمیم‌گیری مارکوف بخشاً مشاهده‌پذیر (POMDP) با معرفی مفهوم Belief State (حالت باور) عدم قطعیت شدید در مشاهده حالت‌ها را مدل می‌کند. هرچند POMDP از نظر ریاضی دقیق‌تر است، اما حل آن به دلیل پیچیدگی فوق‌العاده محاسباتی در زمان اجرای سیستم‌های بزرگ عملاً غیرممکن است. از این رو، این رساله با بهره‌گیری از هسته تقریب‌گر عصبی عمیق، از فرمول‌بندی MDP استاندارد همراه با مکانیزم‌های بازیابی تجربیات شکست‌خورده برای فائق آمدن بر این چالش استفاده می‌کند.

## ۲-۳-۳ چالش‌های خاص عدم قطعیت در فضاهای وفقی بزرگ

هنگامی‌که سیستم خودوفق با یک فضای وفقی مقیاس‌وسیع (به عنوان مثال، فضاهایی با ابعاد بیش از هزاران پیکربندی ممکن) روبه‌رو می‌شود، عدم قطعیت زمان اجرا منجر به بروز سه چالش بحرانی می‌گردد:

- **انفجار ترکیبی گزینه‌ها (Combinatorial Explosion):** ارزیابی تک‌تک گزینه‌ها با استفاده از وارسی مدل صوری یا آماری به دلیل زمان‌بر بودن محاسبات غیرممکن می‌شود.
- **تنگنای زمان تصمیم‌گیری (Scale-Latency Dilemma):** تحلیل و برنامه‌ریزی باید در کسری از ثانیه انجام شود؛ در غیر این صورت، تصمیمی‌که با تاخیر اتخاذ شده است، به دلیل تغییر مجدد محیط بی‌اثر گشته و سیستم با پدیده تصمیمات منقضی‌شده مواجه می‌گردد.
- **افتادن در دام بهینه‌های محلی (Local Optima Traps):** به دلیل ماهیت غیرایستای (non-stationary) محیط، سیاست وفقی سیستم ممکن است به سرعت همگرا شده و در یک پیکربندی نیمه‌بهینه قفل شود، به طوری که مکانیزم‌های کاوش سنتی قادر به خروج سیستم از این وضعیت نباشند.

**رانش مفهومی (Concept Drift) و اثر ریاضی غیرایستایی:** در سیستم‌های خودوفق صنعتی زمان واقعی، عدم قطعیت‌ها صرفاً نویزهای فرکانس‌بالا نیستند، بلکه محیط دستخوش تغییرات توزیعی ریشه‌ای یا همان رانش مفهومی می‌شود. به بیان صوری ریاضی، پویایی احتمالی انتقال حالت ($P_t$) و تابع پاداش ($R_t$) دیگر در طول زمان ثابت نبوده و با متغیر زمان $t$ دچار تغییر می‌شوند:

$$P_t(s' \mid s, a) \neq P_{t+k}(s' \mid s, a)$$

$$R_t(s, a, s') \neq R_{t+k}(s, a, s')$$

که در آن $P_t(s' \mid s, a)$ نشان‌دهنده تابع احتمال انتقال حالت (احتمال انتقال به حالت $s'$ پس از اتخاذ عمل $a$ در حالت $s$) در زمان $t$ است و $R_t(s, a, s')$ نشان‌دهنده تابع پاداش آنی در همان زمان می‌باشد.

این عدم ایستایی، فرض بنیادین فرآیند تصمیم‌گیری مارکوف را نقض می‌کند. در شبکه‌های DQN کلاسیک، این پدیده منجر به **فراموشی فاجعه‌بار** (Catastrophic Forgetting) می‌شود؛ شبکه عصبی عمیق وزن‌های خود را برای شرایط جاری بهینه‌سازی می‌کند، اما به محض تغییر فصل یا بار شبکه، سیاست‌های پیشین کاملاً پاک شده و سیستم با افت شدید کیفیت مواجه می‌گردد. مکانیزم نوآورانه شکل‌دهی تصادفی پاداش با احتمال $\rho$ در این رساله، با تزریق مستمر نوسان‌های خوش‌بینانه در لایه بازپخش تجربیات، مانع از تثبیت و انجماد وزن‌های شبکه عصبی در یک نقطه خاص شده و عملاً به عنوان یک منظم‌ساز (Regularizer) پویا در برابر رانش مفهومی عمل می‌کند.

## ۲-۴ مبانی نظری و مدل‌سازی ریاضی

### ۲-۴-۱ فرآیندهای تصمیم‌گیری مارکوف، یادگیری تقویتی و DQN

**فرآیندهای تصمیم‌گیری مارکوف (MDP):** فرآیند تصمیم‌گیری مارکوف چارچوب ریاضی استاندارد و بی‌بدیلی را برای مدل‌سازی تصمیم‌گیری‌های متوالی عامل هوشمند در محیط‌های پویا و احتمالی ارائه می‌دهد [؟]. به صورت صوری، یک MDP پنج‌گانه به صورت زیر تعریف می‌شود:

$$\mathcal{M} = (S, A, P, R, \gamma)$$

که در آن مولفه‌ها عبارتند از:

- $S$: فضای حالت‌های سیستم که وضعیت جاری را توصیف می‌کند.
- $A$: فضای عمل‌ها که در سیستم‌های خودوفق، همان گزینه‌های وفقی زمان اجرا هستند.
- $P : S \times A \times S \to [۰, ۱]$: تابع احتمال انتقال که احتمال رفتن از حالت $s$ به حالت $s'$ با انجام عمل $a$ را مشخص می‌سازد:

$$P(s' \mid s, a) = \mathbb{P}(S_{t+۱} = s' \mid S_t = s, A_t = a)$$

- $R : S \times A \times S \to \mathbb{R}$: تابع پاداش که پاداش آنی حاصل از انجام عمل $a$ در حالت $s$ و انتقال به $s'$ را تعیین می‌کند.

- $\gamma \in [۰, ۱)$: ضریب تنزیل که ارزش پاداش‌های آتی را نسبت به پاداش لحظه‌ای مشخص می‌سازد.

هدف اصلی در یک MDP، یافتن یک سیاست وفقی بهینه $\pi(a \mid s)$ است که ارزش پاداش‌های تجمعی تنزیل‌یافته آتی را بیشینه سازد. معادله معروف بلمن (Bellman Expectation Equation) برای تابع ارزش حالت $V^{\pi}(s)$ به صورت زیر فرمول‌بندی می‌شود [؟]:

$$V^{\pi}(s) = \sum_{a \in A} \pi(a \mid s) \sum_{s' \in S} P(s' \mid s, a) \left[ R(s, a, s') + \gamma V^{\pi}(s') \right]$$

همچنین، معادله بهینگی بلمن (Bellman Optimality Equation) برای تابع ارزش عمل‌ـحالت $Q^{*}(s, a)$ که ارزش اتخاذ اقدام $a$ در حالت $s$ تحت سیاست بهینه را برآورد می‌کند، به صورت زیر بیان می‌گردد:

$$Q^{*}(s, a) = \sum_{s' \in S} P(s' \mid s, a) \left[ R(s, a, s') + \gamma \max_{a'} Q^{*}(s', a') \right]$$

**یک مثال ریاضی ملموس از فرآیند تصمیم‌گیری مارکوف:** برای شفاف‌سازی نحوه انتشار ارزش‌ها در یک MDP، مثال ساده زیر را بررسی می‌کنیم. این مثال پایه درک نحوه آموزش عامل در فصل‌های بعدی را فراهم می‌سازد. در این راستا، جهت شفاف‌سازی فرآیند محاسباتی، یک مدل نمونه با ۲ حالت و ۲ عمل متناظر را تحلیل می‌کنیم:

- **حالت‌ها:** $S = \{s_۰, s_۱\}$ که در آن $s_۰$ نشان‌دهنده وضعیت عادی شبکه (بدون ترافیک و تداخل) و $s_۱$ نشان‌دهنده وضعیت اشباع شبکه (حضور تداخل جوی شدید) است.
- **عمل‌ها:** $A = \{a_۰, a_۱\}$ که در آن $a_۰$ نشان‌دهنده سطح توان ارسال کم (بهینه از نظر مصرف انرژی) و $a_۱$ نشان‌دهنده سطح توان ارسال زیاد (مقاوم در برابر نویز) می‌باشد.

پویایی احتمالی انتقال حالت ($P$) و مقادیر پاداش‌ها ($R$) در این محیط به صورت زیر پیکربندی شده است:

۱. **در حالت عادی ($s_۰$):**

- با انتخاب توان کم ($a_۰$): با احتمال ۰/۸ سیستم در $s_۰$ باقی مانده و با احتمال ۰/۲ به دلیل نویز اتفاقی به $s_۱$ می‌رود. پاداش آنی برابر با $R(s_۰, a_۰) = ۱/۰$ (حداکثر بازده) است.
- با انتخاب توان زیاد ($a_۱$): با احتمال ۰/۹۵ سیستم در $s_۰$ مانده و با احتمال ۰/۰۵ به $s_۱$ منتقل می‌شود. پاداش آنی به دلیل هدررفت انرژی برابر با $R(s_۰, a_۱) = ۰/۶$ است.

۲. **در حالت اشباع ($s_۱$):**

- با انتخاب توان کم ($a_۰$): به دلیل ضعف سیگنال، احتمال بهبود اندک بوده و با احتمال ۰/۳ به $s_۰$ برگشته و با احتمال ۰/۷ در $s_۱$ می‌ماند. پاداش آنی به دلیل اتلاف پیام‌ها برابر با $R(s_۱, a_۰) = -۰/۱$ است.
- با انتخاب توان زیاد ($a_۱$): با احتمال ۰/۸۵ شبکه با غلبه بر نویز به حالت عادی $s_۰$ بازمی‌گردد و با احتمال ۰/۱۵ در $s_۱$ باقی می‌ماند. پاداش آنی به دلیل تعادل میان پایداری و انرژی برابر با $R(s_۱, a_۱) = ۰/۵$ است.

فرضیات بالا را برای ارزیابی یک سیاست معین $\pi$ در نظر می‌گیریم؛ سیاستی که همواره در حالت عادی گزینه کم‌مصرف را انتخاب کرده ($\pi(a_۰ \mid s_۰) = ۱/۰$) و در حالت نویزی بلافاصله توان را افزایش می‌دهد ($\pi(a_۱ \mid s_۱) = ۱/۰$). با در نظر گرفتن ضریب تنزیل زمان‌دار $\gamma = ۰/۹$، معادلات بلمن به شکل دستگاه معادلات خطی زیر بازنویسی می‌شوند:

$$V^\pi(s_۰) = R(s_۰, a_۰) + \gamma \left[P(s_۰ \mid s_۰, a_۰)V^\pi(s_۰) + P(s_۱ \mid s_۰, a_۰)V^\pi(s_۱)\right]$$

$$V^\pi(s_۱) = R(s_۱, a_۱) + \gamma \left[P(s_۰ \mid s_۱, a_۱)V^\pi(s_۰) + P(s_۱ \mid s_۱, a_۱)V^\pi(s_۱)\right]$$

با جایگذاری مقادیر احتمالی و عددی در معادلات فوق، خواهیم داشت:

$$V^\pi(s_۰) = ۱/۰ + ۰/۹\left[۰/۸V^\pi(s_۰) + ۰/۲V^\pi(s_۱)\right] \implies V^\pi(s_۰) = ۱/۰ + ۰/۷۲V^\pi(s_۰) + ۰/۱۸V^\pi(s_۱)$$

$$V^\pi(s_۱) = -۰/۵ + ۰/۹\left[۰/۸۵V^\pi(s_۰) + ۰/۱۵V^\pi(s_۱)\right] \implies V^\pi(s_۱) = -۰/۵ + ۰/۷۶۵V^\pi(s_۰) + ۰/۱۳۵V^\pi(s_۱)$$

برای حل این دستگاه خطی، ابتدا معادله اول را بر حسب $V^\pi(s_۱)$ ساده می‌کنیم:

$$\begin{aligned}(۱ - ۰/۷۲)V^\pi(s_۰) &= ۱/۰ + ۰/۱۸V^\pi(s_۱) \\ \implies ۰/۲۸V^\pi(s_۰) &= ۱/۰ + ۰/۱۸V^\pi(s_۱) \\ \implies V^\pi(s_۰) &\approx ۳/۵۷۱۴ + ۰/۶۴۲۸V^\pi(s_۱)\end{aligned}$$

با جایگذاری این تساوی در معادله دوم، مقدار ارزش حالت اشباع حاصل می‌شود:

$$(۱ - ۰/۱۳۵)V^\pi(s_۱) = -۰/۵ + ۰/۷۶۵\left(۳/۵۷۱۴ + ۰/۶۴۲۸V^\pi(s_۱)\right)$$

$$۰/۸۶۵V^\pi(s_۱) \approx -۰/۵ + ۲/۷۳۲۱ + ۰/۴۹۱۷V^\pi(s_۱)$$

$$۰/۳۷۳۳V^\pi(s_۱) \approx ۳/۲۳۲۱ \implies V^\pi(s_۱) \approx ۸/۶۵۸۲$$

سرانجام، با جایگذاری مجدد در تساوی اول، مقدار ارزش حالت عادی به دست می‌آید:

$$V^{\pi}(s_{\cdot}) \approx ۳/۵۷۱۴ + ۰/۶۴۲۸ \times ۸/۶۵۸۲ \approx ۹/۱۳۶۹$$

این ارقام به طور دقیق نشان می‌دهند که چگونه عامل یادگیرنده با انتخاب‌های هوشمندانه و تغییر پویا سیاست‌ها تحت تنزیل آتی پاداش‌ها، ارزش بلندمدت بسیار بالاتری را کسب می‌کند (ارزش حالت عادی ۹/۱۳ در مقایسه با پاداش آنی لحظه‌ای ۱/۰).

**یادگیری تقویتی (RL) و الگوریتم‌های جدول‌محور:** یادگیری تقویتی به عامل هوشمند امکان می‌دهد تا بدون نیاز به دانش صریح از پویایی‌های احتمالی محیط (یعنی بدون داشتن فرمول صریح تابع انتقال $P$ و تابع پاداش $R$) و صرفاً از طریق تعامل فعال (آزمون و خطا) سیاست بهینه را یاد بگیرد [؟].

در الگوریتم‌های جدول‌محور کلاسیک مانند **یادگیری Q** (Q-learning) [؟] که یک الگوریتم فراسیاستی (off-policy) است، مقادیر ارزش عمل‌ـحالت به طور مداوم درون یک جدول جامع به‌روزرسانی می‌شوند:

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[ r + \gamma \max_{a'} Q(s',a') - Q(s,a) \right]$$

که در آن $\alpha \in (۰, ۱]$ نرخ یادگیری است. در مقابل، الگوریتم‌های درون‌سیاستی (on-policy) مانند **SARSA** [؟]، ارزش عمل بعدی را بر اساس سیاست جاری و عملی که واقعاً اتخاذ شده به‌روزرسانی می‌کنند.

هرچند الگوریتم‌های جدول‌محور و برنامه‌ریزی پویا (Dynamic Programming) تضمین همگرایی ریاضی دارند، اما به دلیل نیاز به حافظه بی‌پایان جهت نگهداری جداول بزرگ، در مسائلی که با انفجار فضای حالت و عمل روبه‌رو هستند کاملاً ناکارآمد بوده و با چالش **نفرین ابعاد** مواجه می‌گردند.

**مقایسه ساختاری الگوریتم‌های یادگیری Q و SARSA:** جهت تبیین دقیق تفاوت‌های منطقی میان دو الگوریتم پایه‌ای یادگیری تقویتی جدول‌محور، جدول ۲-۱ معیارهای ساختاری، ایمنی و هزینه محاسباتی هرکدام را به تفصیل مقایسه کرده است [؟]. این تحلیل روشن می‌سازد که چرا رویکردهای مبتنی بر یادگیری Q (نظیر DQN مورد استفاده در این رساله) برای سیستم‌های خودوفق ترجیح داده می‌شوند.

**یادگیری تقویتی عمیق (DQN) و مکانیزم‌های تثبیت:** برای غلبه بر نفرین ابعاد در محیط‌های مقیاس‌بزرگ، الگوریتم شبکه Q عمیق (Deep Q-Network - DQN) معرفی شد که تابع ارزش Q را با استفاده از یک شبکه‌ی عصبی عمیق با پارامترهای $\theta$ تقریب می‌زند: $Q(s,a) \approx Q(s,a;\theta)$ [؟]. پارامترهای این شبکه از طریق به حداقل رساندن تابع هزینه لایه‌ای در هر گام آموزش به‌روزرسانی می‌شوند:

$$L(\theta_i) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} \left[ \left( r + \gamma \max_{a'} Q(s',a';\theta_i^-) - Q(s,a;\theta_i) \right)^{۲} \right]$$

جدول ۲-۱: مقایسه تطبیقی الگوریتم‌های جدول‌محور Q-Learning و SARSA

| معیار مقایسه | یادگیری Q (Q-Learning) | الگوریتم SARSA |
|---|---|---|
| **نوع سیاست** | فراسیاستی (Off-Policy): به‌روزرسانی بر اساس فرضیه اقدام بهینه آتی صورت می‌گیرد. | درون‌سیاستی (On-Policy): به‌روزرسانی بر اساس اقدامی‌که واقعاً توسط سیاست اتخاذ شده، انجام می‌شود. |
| **فرمول به‌روزرسانی** | $Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$ | $Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma Q(s',a') - Q(s,a)]$ |
| **سرعت همگرایی** | سریع‌تر؛ به دلیل استفاده مستقیم از عملگر بیشینه‌سازی در هدف تفاوت زمانی. | کندتر؛ همگرایی وابسته به اصلاح تدریجی کل بدنه سیاست است. |
| **ایمنی حین یادگیری** | ریسک بالا؛ ممکن است رفتارهای متهورانه و آسیب‌زا جهت کشف مسیر بهینه اتخاذ کند. | ایمن‌تر؛ با پرهیز از اقدامات بهینه تهاجمی، از سیاست جاریِ محافظه‌کارانه تبعیت می‌کند. |
| **تعمیم‌پذیری عصبی** | بسیار بالا؛ پایه اصلی توسعه الگوریتم‌های عمیق بدون مدل نظیر DQN است. | متوسط؛ در ابعاد عمیق نیازمند معماری‌های تثبیت بسیار سنگین‌تری است. |

برای تضمین پایداری و جلوگیری از واگرایی فرآیند آموزش شبکه‌های عصبی در محیط‌های یادگیری تقویتی، دو نوآوری حیاتی در DQN اعمال می‌گردد. نوآوری نخست، **حافظه بازپخش تجربه (Experience Replay — $\mathcal{D}$)** است که طی آن، عامل تجربیات خود را در قالب انتقال‌های $(s, a, r, s')$ درون یک بافر ذخیره می‌کند و در طول فاز آموزش، به جای استفاده از تجربیات متوالی که دارای همبستگی شدید زمانی هستند، دسته‌های کوچکی از داده‌ها به صورت کاملاً تصادفی و یکنواخت از بافر نمونه‌برداری می‌شوند. این مکانیزم فرضیه داده‌های مستقل و توزیع‌شده به طور یکسان (i.i.d.) را احیا کرده و پایداری بهینه‌سازی را تضمین می‌کند. نوآوری دوم، **شبکه هدف ثابت (Target Network — $\theta^-$)** است که در آن، محاسبه هدف بلمن به یک شبکه عصبی موازی با پارامترهای مستقل $\theta^-$ سپرده می‌شود؛ به طوری که وزن‌های این شبکه به جای هر گام، در بازه‌های زمانی مشخصی از شبکه اصلی کپی می‌شوند تا از نوسان‌های شدید و واگرایی تابع ارزش جلوگیری گردد.

در این بخش، چارچوب ریاضی تصمیم‌گیری تحت عدم قطعیت شامل فرآیندهای تصمیم‌گیری مارکوف (MDP)، مفاهیم یادگیری تقویتی و شبکه Q عمیق (DQN) تشریح گردید. همچنین یک مثال عددی ساده نحوه محاسبه ارزش حالت‌ها را تحت یک سیاست معین نشان داد. در بخش بعدی، این مفاهیم پایه‌ای را بر روی سیستم مورد مطالعه و محک استاندارد DeltaIoT پیاده‌سازی و فرمول‌بندی خواهیم کرد.

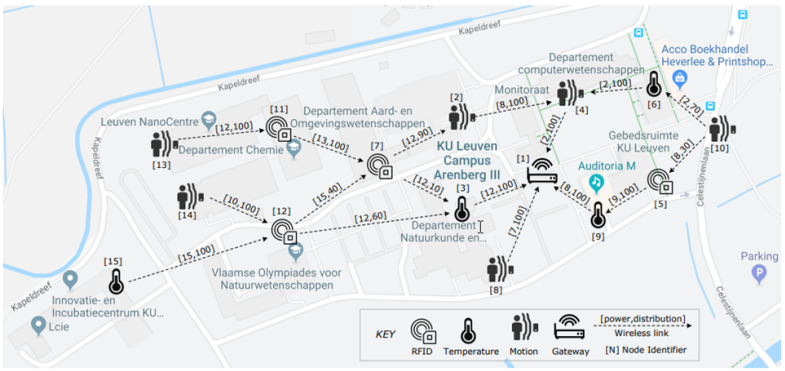
## ۲-۵ سیستم مورد مطالعه: شبکه‌های حسگر بی‌سیم DeltaIoT

### ۲-۵-۱ معماری، مؤلفه‌ها و ویژگی‌های فیزیکی

بستر DeltaIoT یک شبکه‌ی حسگر بی‌سیم صنعتی زمان واقعی است که برای ارزیابی رفتارهای خودوفق‌سازی تحت شرایط نویزی شدید و پویای محیطی به کار گرفته می‌شود. معماری این پلتفرم از سه مؤلفه‌ی اصلی تشکیل شده است:

- **گره‌های حسگر (Sensor Nodes):** این گره‌ها وظیفه پایش محیط و تولید اطلاعات را بر عهده دارند. حسگرها پیام‌های تولیدی خود را به صورت چندگامی (multi-hop) از طریق گره‌های واسط به سمت دروازه مرکزی ارسال می‌کنند.
- **دروازه مرکزی (Gateway):** مقصد نهایی تمامی پیام‌های شبکه است که وظیفه جمع‌آوری داده‌ها، تحلیل کیفیت شبکه و پایش کیفیت خدمات (QoS) را بر عهده دارد. کنترل‌کننده خودمختار ما بر پایه حلقه بازخورد MAPE-K بر روی این دروازه مستقر شده و گزینه‌های وفقی را ارزیابی و اعمال می‌نماید.
- **پیوندهای ارتباطی بی‌سیم (Wireless Links):** مسیرهای ارتباطی میان گره‌ها هستند که به صورت گسسته پیکربندی شده و کیفیت انتقال سیگنال بر روی آن‌ها تحت تاثیر شدید پارامترهای محیطی و تداخل احتمالی فرکانسی قرار دارد.

شکل ۲-۱ توپولوژی و ساختار پیوندهای ارتباطی در شبکه حسگر بی‌سیم DeltaIoTv1 را نشان می‌دهد که در آن سنسورها پیام‌های خود را به صورت چندگامی به سمت دروازه مرکزی ارسال می‌کنند.




شکل ۲-۱: توپولوژی و ساختار پیوندهای ارتباطی شبکه حسگر بی‌سیم DeltaIoTv1 [؟].

## ۲-۵-۲ مدل‌سازی فیزیکی و ریاضیاتی پدیده‌های کانال بی‌سیم

ارتباط میان گره‌ها در بستر DeltaIoT بر پایه مدل‌سازی احتمالی کانال انتقال بی‌سیم انجام می‌شود. نسبت سیگنال به نویز (SNR) برای هر پیوند ارتباطی بی‌سیم $e = (u, v)$ از رابطه‌ی زیر به دست می‌آید:

$$\mathrm{SNR}_e(t) = P_{tx}(u) - \mathrm{PL}(e) - X_\sigma - \eta(t) \qquad (۱-۲)$$

که در آن $P_{tx}(u)$ توان ارسال گره فرستنده $u$ (تنظیم‌شده در بازه گسسته $[۰, ۱۵]$ میلی‌وات)، $\mathrm{PL}(e)$ افت مسیر کانال بی‌سیم (Path Loss)، $X_\sigma$ متغیر تصادفی نرمال با توزیع احتمالی لگاریتمی‌ـ نرمال (Log-Normal)

Shadowing) برای بازنمایی اثر موانع فیزیکی، و $\eta(t)$ نویز و تداخل‌های فرکانسی متغیر با زمان در چرخه $t$ است.

نرخ تحویل بسته (Packet Delivery Ratio - PDR) بر روی هر پیوند ارتباطی $e$ بر اساس نسبت سیگنال به نویز به صورت یک تابع سیگموئید غیرخطی و احتمالی فرموله می‌گردد:

$$\mathrm{PDR}_e(t) = \frac{۱}{۱ + e^{-\alpha(\mathrm{SNR}_e(t) - \beta)}} \tag{۲-۲}$$

که در آن $\alpha$ و $\beta$ پارامترهای کالیبراسیون سخت‌افزاری فرستنده بی‌سیم بر اساس استاندارد IEEE 802.15.4 هستند.

## ۲-۵-۳ جزئیات فرمول‌بندی معیارهای کیفیت خدمات (QoS) در فضای حالت

فضای حالت مسئله $S = (E, P, L)$ از سه مولفه‌ی کلیدی کیفیت خدمات تشکیل شده است که نحوه محاسبه دقیق ریاضی هر یک به شرح زیر است:

۱. **مصرف انرژی کل شبکه ($E$):** مصرف انرژی کل در هر چرخه وفقی $t$ برابر با مجموع انرژی مصرفی تمامی گره‌های شبکه است:

$$E(t) = \sum_{v \in V} E_v(t) \tag{۳-۲}$$

مصرف انرژی گره $v$ حاصل‌جمع انرژی مصرفی در فازهای ارسال، دریافت و گوش دادن فعال است:

$$E_v(t) = N_{sent}(v) \cdot E_{tx}(p_v) + N_{recv}(v) \cdot E_{rx} + T_{listen}(v) \cdot E_{listen} \tag{۴-۲}$$

که در آن $N_{sent}(v)$ تعداد بسته‌های ارسال‌شده توسط گره $v$ با سطح توان $p_v$، $E_{tx}(p_v)$ انرژی مصرفی برای ارسال با سطح توان مشخص، $N_{recv}(v)$ تعداد بسته‌های دریافت‌شده، $E_{rx}$ انرژی فاز گیرندگی، $T_{listen}(v)$ مدت‌زمان گوش‌دادن فعال به کانال و $E_{listen}$ توان مصرفی گره در حالت استماع است.

۲. **نرخ اتلاف کل بسته‌ها ($P$):** این معیار نشان‌دهنده درصدی از پیام‌های شبکه است که در طول مسیر انتقال به گیت‌وی به دلیل خطاهای کانال یا پر شدن بافر گره‌ها از بین رفته‌اند:

$$P(t) = \left( ۱ - \frac{N_{delivered}(t)}{N_{generated}(t)} \right) \times ۱۰۰ \tag{۵-۲}$$

که در آن $N_{generated}(t)$ کل بسته‌های تولیدشده توسط تمامی حسگرها در چرخه $t$، و $N_{delivered}(t)$ تعداد بسته‌هایی است که با موفقیت توسط دروازه مرکزی دریافت شده‌اند. احتمال اتلاف بسته در

طول یک مسیر چندگامی $\mathcal{P} = (v_1, v_2, \ldots, v_k)$ که به گیت‌وی منتهی می‌شود، برابر است با:

$$P_{loss}(\mathcal{P}) = 1 - \prod_{i=1}^{k-1} \mathrm{PDR}_{(v_i, v_{i+1})}(t) \tag{۶-۲}$$

۳. **متوسط تاخیر زمان انتقال پیام‌ها ($L$):** متوسط زمان مورد نیاز برای رسیدن یک بسته از زمان تولید در سنسور مبدا تا تحویل به دروازه است. با توجه به ساختار اسلات‌بندی شده شبکه (TDMA)، تاخیر هر بسته بر اساس تعداد گام‌ها و اسلات‌های تخصیص‌یافته در چرخه زمان‌بندی محاسبه می‌شود:

$$L(t) = \frac{1}{N_{delivered}(t)} \sum_{p \in \text{Delivered}} T_{arrival}(p) - T_{generation}(p) \tag{۷-۲}$$

که در آن $T_{generation}(p)$ زمان تولید پیام $p$ در حسگر مبدا و $T_{arrival}(p)$ زمان دقیق ورود آن پیام به دروازه مرکزی است.

ارتباطات در DeltaIoT بر پایه استاندارد Time-Slotted Channel Bonding سازماندهی شده است؛ به طوری که زمان به چرخه‌های متوالی تقسیم شده و هر سنسور در اسلات‌های زمانی مشخصی مجاز به ارسال اطلاعات است.

## ۲-۵-۴ سناریوهای عدم قطعیت و فضای وفقی

شبکه DeltaIoT با دو چالش اصلی عدم قطعیت زمان اجرا مواجه است که پایداری عملیاتی آن را تهدید می‌کند. چالش نخست **تداخل و نویز شبکه (Network Interference)** است؛ عوامل محیطی نوسانات ناگهانی در نسبت سیگنال به نویز (SNR) ایجاد می‌کنند که مستقیماً نرخ اتلاف بسته‌ها را افزایش می‌دهد. چالش دوم **تغییرات بار پیام‌ها (Traffic Fluctuations)** است؛ بسته به رخدادهای محیطی، تعداد پیام‌های تولیدی در هر سنسور نوسان شدیدی پیدا می‌کند که موجب پر شدن بافرها و ایجاد تاخیر یا اتلاف داده می‌گردد.

ابعاد فضای وفقی در نسخه‌های مختلف DeltaIoT به شرح زیر است [؟]:

- **نسخه v1:** شامل ۱۵ سنسور با فضای وفقی به ابعاد ۲۱۶ گزینه ممکن.
- **نسخه v1.1:** شامل ۱۶ سنسور با فضای وفقی بالغ بر ۱۲۹۶ گزینه متمایز.
- **نسخه v2 (بزرگ‌مقیاس):** شامل ۳۷ سنسور که دارای فضای عظیم با ابعاد ۴۰۹۶ تصمیم ممکن می‌باشد.

هر گزینه وفقی در حقیقت ترکیبی از تخصیص توان انتقال انرژی به سنسورها (از سطح ۰ تا ۱۵) و تخصیص نسبی مسیرهای شبکه‌ای جهت هدایت بسته‌ها به گیت‌وی است.

### ۲-۵-۵ فرمول‌بندی به عنوان MDP

برای به کارگیری یادگیری تقویتی عمیق، مسئله تطبیق شبکه DeltaIoT را به صورت یک فرآیند تصمیم‌گیری مارکوف (MDP) فرمول‌بندی می‌کنیم:

**تعریف فضای حالت ($S$):** حالت سیستم در هر چرخه وفقی بازتاب‌دهنده عملکرد پویا و مصرف انرژی شبکه است:

$$S = \{(E, P, L) \mid E \in \mathbb{R}^+, P \in [۰, ۱۰۰], L \in [۰, ۱۰۰]\}$$

که در آن:

- $E$: مقدار حقیقی نشان‌دهنده انرژی کل مصرف‌شده توسط تمام سنسورهای شبکه در چرخه قبلی.
- $P$: درصدی از پیام‌ها که به مقصد نرسیده‌اند (نرخ اتلاف کل بسته‌ها).
- $L$: متوسط تاخیر ارسال پیام‌ها از سنسورها به گیت‌وی.

**تعریف فضای عمل ($A$):** فضای عمل عامل، مجموعه‌ای گسسته از تمامی‌پیکربندی‌های شبکه است:

$$A = \{a_۱, a_۲, \ldots, a_n\}$$

که مقدار $n$ بر اساس نسخه شبکه برابر با ۲۱۶، ۱۲۹۶ یا ۴۰۹۶ است. هر عمل $a_i$ یک نگاشت کامل از توان‌های ارسال و مسیرهای توزیع برای تمامی‌گره‌ها می‌باشد.

**فرمول‌بندی توابع پاداش ($R$):** بسته به سناریوی ارزیابی، سه فرمول‌بندی پاداش تعریف می‌شود:

۱. **پاداش چندهدفه (مبتنی بر پارتو):**

$$R = w_E \cdot \left(\frac{E_{max} - E}{E_{max} - E_{min}}\right) + w_P \cdot \left(\frac{P_{max} - P}{P_{max} - P_{min}}\right) + w_L \cdot \left(\frac{L_{max} - L}{L_{max} - L_{min}}\right)$$

که در آن وزن‌ها مثبت بوده و مجموع آن‌ها برابر یک است: $\sum w_i = ۱$.

۲. **پاداش تک‌هدفه (کاهش مصرف انرژی):**

$$R = \left(\frac{E_{max} - E}{E_{max} - E_{min}}\right) \cdot w_E \quad (\text{with} w_E = ۱)$$

۳. **پاداش اهداف آستانه‌ای (TT):**

$$R = \begin{cases} ۱ & \text{اگر } P < \theta_P \text{ و } L < \theta_L \\ ۰ & \text{در غیر این صورت} \end{cases}$$

که در آن $\theta_P$ و $\theta_L$ آستانه‌های پذیرش کیفی خدمات سیستم هستند.

## ۲-۶ بیان مسئله و چارچوب بهینه‌سازی

### ۲-۶-۱ تعریف سیاست بهینه

مسئله نهایی ما، یافتن سیاست وفقی بهینه $\pi^* : S \to A$ است که ارزش پاداش تجمعی تنزیل‌یافته را در درازمدت بیشینه سازد:

$$\pi^* = \arg\max_{\pi} \mathbb{E}\left[\sum_{t=۰}^{\infty} \gamma^t R(s_t, a_t) \mid \pi\right]$$

این سیاست بهینه به سیستم خودوفق امکان می‌دهد تا به طور خودکار بهترین تصمیمات تطبیقی را در مواجهه با نویز و ترافیک اتخاذ کند.

### ۲-۶-۲ تحلیل پیچیدگی مسئله تطبیق و ضرورت یادگیری تقویتی

پیش از تشریح قیود عملیاتی، اثبات صوری این موضوع که چرا روش‌های وارسی کامل یا تکاملی سنتی در زمان اجرا ناکارآمد هستند، ضرورت دارد. مسئله تطبیق بهینه در یک شبکه حسگر بی‌سیم خودوفق (نظیر DeltaIoT) را می‌توان به صورت ریاضی به عنوان یک مسئله بهینه‌سازی چندهدفه مقید صورت‌بندی نمود.

فرض کنید شبکه متشکل از مجموعه‌ای از گره‌ها $V$ و پیوندهای ارتباطی $E$ باشد. فضای عمل کل سیستم $A$ حاصلضرب دکارتی تصمیمات محلی تمام گره‌ها است:

$$A = \prod_{v \in V} A_v$$

هر گره $v$ باید توان ارسال $p_v \in \{۰, \ldots, ۱۵\}$ و توزیع مسیرهای خروجی $d_v \in [۰, ۱]^L$ را تعیین کند. هدف ما یافتن پیکربندی بهینه‌ای است که مجموع مصرف انرژی کل شبکه را کمینه سازد:

$$\min_{a \in A} \sum_{v \in V} \text{Energy}(v, a)$$

به طوری که قیود کیفی زیر ارضا گردند:

$$\text{PacketLoss}(a) < \theta_P$$

$$\text{Latency}(a) < \theta_L$$

**قضیه ۱:** مسئله بهینه‌سازی تطبیق مقید در حلقه‌های خودوفقی مقیاس‌وسیع، یک مسئله سخت بهینه یا ان‌پی‌ـ سخت (NP-hard) است [؟].

**اثبات صوری از طریق کاهش:** برای اثبات، این مسئله را به مسئله کوله‌پشتی چندبعدی (Multi-Dimensional Knapsack Problem - MDKP) [؟] که ان‌پی‌ـ سخت بودن آن اثبات شده است، کاهش می‌دهیم. در مسئله MDKP، مجموعه‌ای از اشیاء با ارزش‌ها و هزینه‌های چندگانه وجود دارند و هدف انتخاب زیرمجموعه‌ای است که ارزش بیشینه را تحت محدودیت ظرفیت تمام ابعاد کوله‌پشتی فراهم آورد.

در فرمول‌بندی تطبیق ما:

۱. انتخاب توان ارسال و توزیع مسیر برای هر گره $v$ معادل انتخاب یک شیء با ویژگی‌های مشخص در MDKP است.

۲. مصرف انرژی در شبکه معادل کمینه کردن وزن انتخاب‌ها در کوله‌پشتی است.

۳. قیود آستانه‌ای کیفیت خدمات ($\theta_P$ و $\theta_L$) معادل ظرفیت‌های محدود چندبعدی کوله‌پشتی هستند که نباید از حد مشخصی تجاوز کنند.

۴. به دلیل وابستگی‌های غیرخطی اتلاف بسته‌ها و تاخیر در طول مسیرهای ارتباطی شبکه، ارزیابی هر پیکربندی مستلزم حل روابط انتشار سیگنال احتمالی است که پیچیدگی مسئله را از MDKP کلاسیک نیز فراتر می‌برد.

از آنجا که MDKP ان‌پی‌ـ سخت است، مسئله تطبیق مقید شبکه نیز ذاتاً ان‌پی‌ـ سخت خواهد بود. با رشد تعداد گره‌ها ($K = |V|$)، ابعاد فضای پیکربندی به صورت توان‌نمایی $O(C^K)$ رشد می‌کند؛ جایی که $C$ تعداد گزینه‌های محلی هر گره است. برای۲DeltaIoTv با ۳۷ سنسور، این فضا به ابعاد سرسام‌آور ۴۰۹۶ حالت ممکن می‌رسد. وارسی جامع تمام گزینه‌ها در زمان اجرا به دلیل این پیچیدگی غیرممکن است. این تحلیل ریاضی اثبات می‌کند که چرا سیستم‌های زمان واقعی ناگزیرند از الگوریتم‌های یادگیری بدون مدل تقریب‌گر عصبی (نظیر DQN زمان اجرای ما) استفاده کنند که محاسبات سنگین را به صورت آفلاین یا پس‌زمینه انجام داده و در زمان اجرا تنها یک گذر رو به جلوی فوق‌سریع ($O(۱)$ از نظر زمانی) را اعمال می‌نمایند.

### ۲-۶-۳ قیود عملیاتی زمان اجرا

جهت تطابق کامل با چالش‌های سیستم‌های نرم‌افزاری صنعتی معاصر، سیاست بهینه باید سه قید زیر را همزمان ارضا نماید:

۱. **خروج پویا از بهینه‌های محلی (Local Optima Escape):** سیاست باید در برابر تغییر شرایط محیطی انعطاف‌پذیر بوده و در دام سیاست‌های قدیمیِ نیمه‌بهینه گرفتار نشود.

۲. **مقیاس‌پذیری و کارایی زمانی (Temporal Scalability):** فرآیند تصمیم‌گیری آنلاین باید در کسری از میلی‌ثانیه رخ دهد. برای تحقق این امر، آموزش سنگین عمیق شبکه‌ی عصبی باید به صورت کاملاً ناهمگام (Asynchronous) در پس‌زمینه و مجزا از مسیر تصمیم‌گیری زمان اجرا انجام شود.

۳. **استقلال کامل از دانش دامنه (Domain Independence):** فرآیند کاوش و بازپخش تجربیات نباید وابسته به مختصات صریح اهداف یا دانش از پیش‌تعریف‌شده باشد تا راهکار قابلیت تعمیم به دامنه‌های مختلف نرم‌افزاری را حفظ کند.

## ۲-۷ سیستم مورد مطالعه دوم: شبیه‌ساز مأموریت پهپاد DARTSim

شبیه‌ساز مأموریت DARTSim [؟] یک بستر شبیه‌سازی فیزیکی_ سایبری هوایی برای ارزیابی تصمیم‌گیری‌های انطباقی زمان اجرای تیم‌های پهپادی در محیط‌های پرخطر است. در این سیستم، یک تیم پهپادی باید با اتخاذ استراتژی‌های وفقی تاکتیکی، بقای خود را حفظ کرده و اهداف مأموریت (مانند شناسایی اهداف و خروج از شعاع راداری تهدیدات) را بیشینه نماید. این بستر، چالش‌های متفاوتی را نسبت به شبکه‌های حسگر بی‌سیم به تصویر می‌کشد و آزمونی حیاتی برای ارزیابی چنددامنه‌ای و استقلال از دامنه روش پیشنهادی رساله به شمار می‌رود.

### ۲-۷-۱ خاستگاه علمی و جایگاه به‌عنوان محک

برخلاف یک محیط شبیه‌سازی دلخواه، DARTSim ریشه در یکی از محک‌های شناخته‌شده و پراستناد حوزه سیستم‌های خودوفق دارد. این بستر بر پایه‌ی مسئله‌ی تیم پهپادهای خودگردان (UAV Team) که نخستین‌بار توسط مورنو و همکاران [؟] در چارچوب انطباق پیش‌نگرانه تحت عدم‌قطعیت معرفی شد، استوار گردیده است. در این مسئله، تیمی از پهپادها مأموریت پیمایش و شناسایی را در یک محیط متخاصم اجرا می‌کنند و باید میان دو هدف متضاد تعادل برقرار سازند: پرواز در ارتفاع پایین‌تر احتمال شناسایی اهداف زمینی را افزایش می‌دهد اما هم‌زمان مواجهه با تهدیدات راداری را تشدید می‌کند، در حالی‌که پرواز در ارتفاع بالاتر ریسک تهدید را می‌کاهد ولی شناسایی اهداف را دشوارتر می‌سازد.

همین مسئله‌ی پهپادی، در پژوهش‌های متأخرتر از جمله چارچوب TUNE-II مبتنی بر میانگین‌گیری مدل بیزی [؟] نیز به‌عنوان یک مطالعه موردیِ مرجع برای ارزیابی انطباق چندهدفه تحت عدم‌قطعیت مدل به‌کار گرفته شده است. انتخاب DARTSim در این رساله از دو منظر توجیه می‌شود: نخست، اعتبار علمی و تکرارپذیری آن به‌عنوان یک محک تثبیت‌شده؛ و دوم، تمایز ماهوی دامنه آن (تصمیم‌گیری تاکتیکی بلادرنگ هوایی در فضای حالت پیوسته و فضای اقدام گسسته) نسبت به مطالعه موردی نخست (DeltaIoT)، که امکان سنجش دقیق *استقلال از دامنه* روش پیشنهادی را فراهم می‌آورد.

## ۲-۷-۲ فضای معنایی سیستم (Semantic Space)

رفتار سیستم پهپادی توسط مجموعه‌ای از عوامل پیکربندی (قابل‌کنترل توسط عامل انطباقی) و عوامل محیطی (منابع عدم‌قطعیت بیرونی) تعیین می‌شود که مجموعاً «فضای معنایی» سیستم را تشکیل می‌دهند. جدول ۲-۲ این عوامل را به تفکیک نوع، دامنه و نقش آن‌ها در مأموریت خلاصه می‌کند.

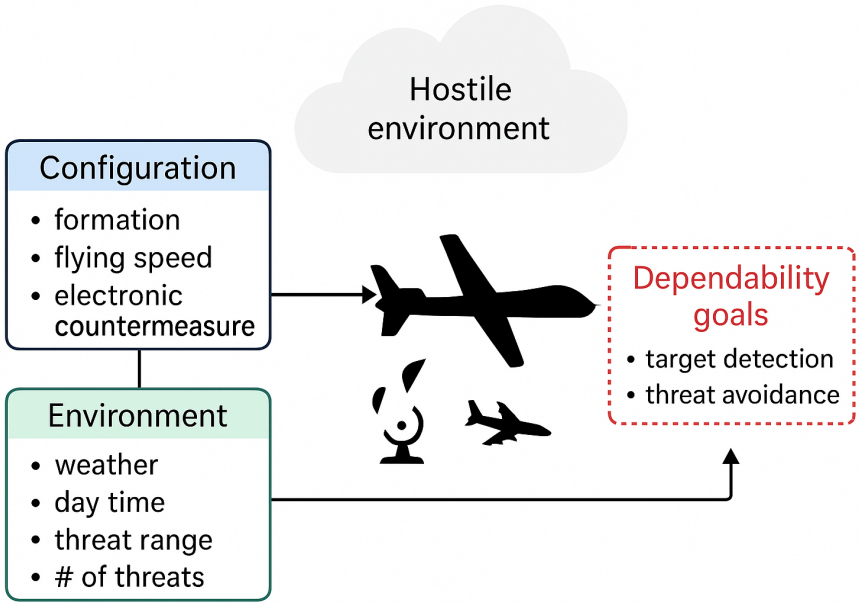
جدول ۲-۲: فضای معنایی سیستم پهپادی DARTSim (عوامل پیکربندی و محیطی)

| عامل | نوع | دامنه | توضیح |
|---|---|---|---|
| آرایش تیمی (formation) | پیکربندی | {tight, loose} | هندسه آرایش فضایی تیم پهپادی هنگام اجرای مأموریت. |
| سرعت پرواز (flying speed) | پیکربندی | [5, 50] mph | سرعت متوسط پرواز که بر احتمال شناسایی و فرار اثر می‌گذارد. |
| اخلالگر الکترونیکی (ECM) | پیکربندی | {On, Off} | فعال‌سازی اخلال برای کاهش احتمال شناسایی توسط تهدیدات. |
| وضعیت جوی (weather) | محیطی | {sun, clouds, rain, fog} | شرایط هواشناختی مؤثر بر عملکرد حسگرها و پرواز. |
| زمان روز (day time) | محیطی | 00:00–23:59 | زمان روز که بر میدان دید و احتمال شناسایی اثرگذار است. |
| شعاع تهدید (threat range) | محیطی | [0.9, 3.7] km | شعاع شناسایی تهدیدات که میزان مواجهه پهپاد را تعیین می‌کند. |
| تعداد تهدیدات (# threats) | محیطی | [1–10] | شمار تهدیدات فعال در منطقه عملیاتی. |

نمودار مفهومی شکل ۲-۲ برهم‌کنش این عوامل را به تصویر می‌کشد: عوامل پیکربندی و محیطی هر دو بر عملکرد تیم پهپادی در دل «محیط متخاصم» اثر گذاشته و در نهایت تحقق اهداف وابستگی‌پذیری (شناسایی هدف و اجتناب از تهدید) را تعیین می‌کنند. شایان ذکر است که این فضای معنایی هفت‌عاملی، خاستگاه مفهومی مسئله را تبیین می‌کند؛ تحقق عملیاتی آن در این رساله به‌صورت یک بردار حالت ۱۷ بعدی و فضای اقدام گسسته ۸گانه (که در ادامه تشریح می‌شود) صورت‌بندی شده است.

## ۲-۷-۳ اهداف و الزامات وابستگی‌پذیری

اهداف مأموریت در DARTSim از دو الگوی الزامِ پارامتری مشتق می‌شوند که هر دو حول مفهوم محوری مصالحه‌ی ارتفاع شکل گرفته‌اند: الگوی نخست، **الگوی شناسایی هدف (Target Detection)**، بیان می‌کند که «هنگامی‌که ارتفاع میان $\theta_1$ و $\theta_2$ متر است، تیم پهپادی باید در بیش از $p_1$ درصد موارد هدف را شناسایی کند.» این الگو بیشینه‌سازی قابلیت اطمینان شناسایی را هدف می‌گیرد. الگوی دوم، **الگوی اجتناب از تهدید (Threat Avoidance)**، در مقابل بیان می‌کند که «هنگامی‌که ارتفاع میان $\theta_1$ و $\theta_2$ متر است، تهدیدات موجود باید در کمتر از $p_2$ درصد موارد پهپادها را شناسایی کنند.» این الگو کمینه‌سازی مواجهه با تهدید را دنبال




شکل ۲-۲: نمودار مفهومی عوامل اثرگذار بر اهداف وابستگی‌پذیری تیم پهپادی DARTSim؛ عوامل پیکربندی و محیطی در یک محیط متخاصم بر تحقق اهداف شناسایی هدف و اجتناب از تهدید اثر می‌گذارند.

می‌کند. با نمونه‌سازی این دو الگو بر روی شش بازه‌ی ارتفاعی و آستانه‌های احتمال متناظر، مجموعاً ۱۲ الزام وابستگی‌پذیری ملموس (۶ مورد شناسایی و ۶ مورد اجتناب) حاصل می‌گردد. ماهیت متضاد این اهداف —— که در آن کاهش ارتفاع، شناسایی را بهبود می‌بخشد اما مواجهه با تهدید را افزایش می‌دهد —— همان مسئله بهینه‌سازی چندهدفه‌ای است که عامل انطباقی باید در زمان اجرا و تحت عدم‌قطعیت آن را حل کند.

## ۲-۷-۴ معماری، مؤلفه‌ها و ویژگی‌های فیزیکی

سامانه پهپادی در شبیه‌ساز DARTSim از چندین مؤلفه فیزیکی و سایبری تشکیل شده است:

- **بدنه پهپادها (UAV Fleet):** شامل دسته‌ای از پهپادها که دارای حسگرهای شناسایی هدف، اخلال‌گرهای الکترونیکی فعال و موتورهای هدایتی آرایش تیمی هستند.
- **محیط مأموریت (Mission Environment):** شامل گره‌های هدف که باید شناسایی شوند و مناطق تحت پوشش پدافندی دشمن (تهدیدات موشکی و رادارها).
- **سیستم اخلال‌گر الکترونیکی (ECM):** یک سیستم فعال که پهپادها می‌توانند برای مسدود کردن امواج رادارها روشن کنند؛ اما این عمل با هزینه جریمه شدید مصرف انرژی همراه است.

## ۲-۷-۵ جزئیات فرمول‌بندی معیارهای کیفیت خدمات (QoS) در فضای حالت

اهداف چندهدفه مأموریت در سه محور اساسی فرمول‌بندی می‌شوند:

۱. **نرخ بقای تیم (Team Survival Rate):** پهپادها در صورت برخورد با موشک‌های تهدیدآمیز منهدم می‌شوند. این معیار در پایان مأموریت به عنوان پاداش نهایی اعمال می‌گردد (در صورت انهدام جریمه سنگین و در صورت بقا پاداش مثبت دریافت می‌کنند).

۲. **پوشش اهداف شناسایی‌شده (Targets Detected):** کسر اهداف شناسایی‌شده توسط حسگرها نسبت به کل اهداف موجود در نقشه که باید به بیشینه برسد.

۳. **مدیریت مصرف انرژی اخلال‌گر الکترونیکی (ECM Energy):** اخلال‌گرهای الکترونیکی باید تنها در صورت مواجهه با رادارهای فعال دشمن روشن شوند تا مصرف انرژی پهپادها در سطح متعادلی حفظ گردد.

### ۲-۷-۶ سناریوهای عدم قطعیت و فضای وفقی

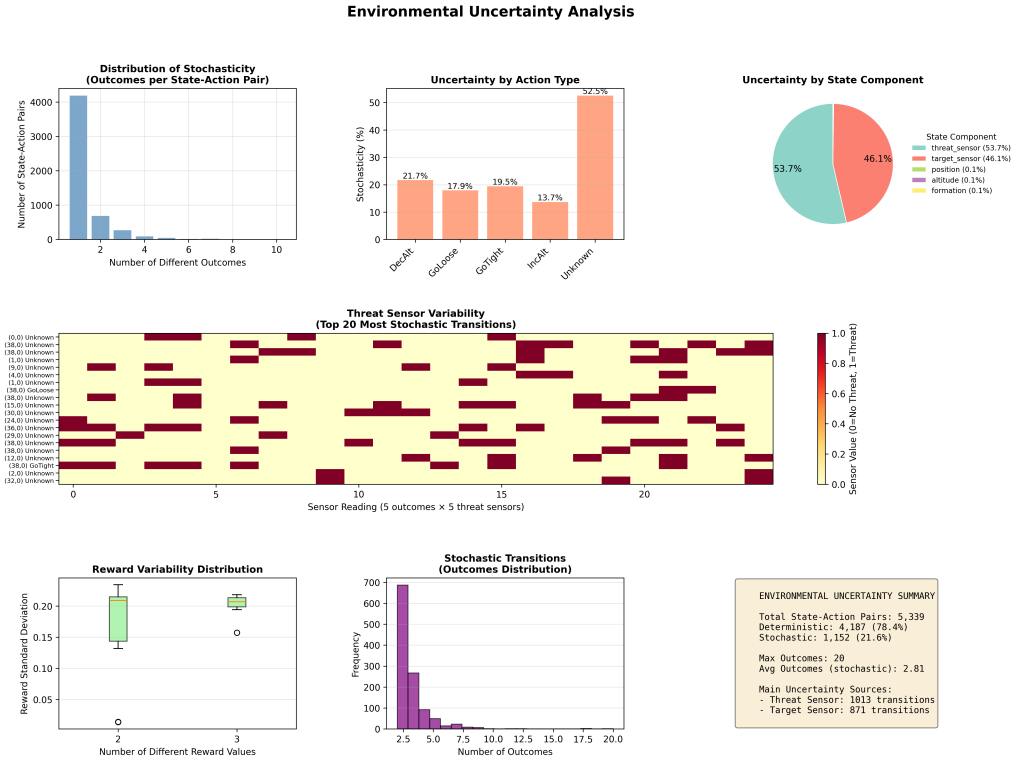
عدم قطعیت در DARTSim ناشی از پویایی محیطی، محل نامشخص تهدیدات دشمن و نوسان پایداری ارتباطات میان پهپادها است. فضای وفقی سیستم شامل اقدامات تاکتیکی برای تنظیم ارتفاع و هندسه آرایش تیمی است. این اقدامات گسسته عبارتند از:

- **اقدامات تنظیم ارتفاع:** شامل افزایش ارتفاع به میزان متوسط یا شدید (IncAlt، IncAlt2) و کاهش ارتفاع (DecAlt، DecAlt2) برای فرار از شعاع رادارهای کم‌ارتفاع یا پدافندهای دوربرد.
- **اقدامات تنظیم هندسه آرایش:** شامل فشرده‌سازی آرایش تیمی برای کاهش اثر راداری یا افزایش پراکندگی پهپادها (GoTight، GoLoose).
- **اقدامات کنترل اخلال‌گر:** شامل روشن یا خاموش کردن سیستم اخلال الکترونیکی (EcmOn، EcmOff).

این فضای وفقی شامل ۸ اقدام گسسته است که تصمیم‌گیری بلادرنگ در هر ثانیه از مسیر پرواز را الزامی می‌کند.

### ۲-۷-۷ مدل‌سازی عدم قطعیت محیطی و تصادفی‌بودن حسگرها

ویژگی متمایزکننده‌ی DARTSim و دلیل اصلی تناسب آن با موضوع این رساله، ماهیت ذاتاً تصادفی (Stochastic) محیط آن است. در این بستر، یک زوج حالت–اقدام یکسان می‌تواند به پیامدهای متفاوتی منجر شود؛ این عدم قطعیت عمدتاً از نویز حسگرها و تغییرپذیری محیطی سرچشمه می‌گیرد. تحلیل تراکنش‌های ثبت‌شده نشان می‌دهد که هرچند بخشی از گذارها قطعی‌اند، بخش قابل‌توجهی از زوج‌های حالت–اقدام چندین پیامد ممکن تولید می‌کنند و منشأ اصلی این پراکندگی، قرائت حسگرهای شناسایی تهدید و هدف است. شکل ۲-۳ داشبورد جامعی از این تحلیل را ارائه می‌دهد که در آن توزیع تصادفی‌بودن گذارها، سهم هر مؤلفه‌ی حالت در ایجاد عدم‌قطعیت و پراکندگی پاداش‌ها به تفکیک نمایش داده شده است.



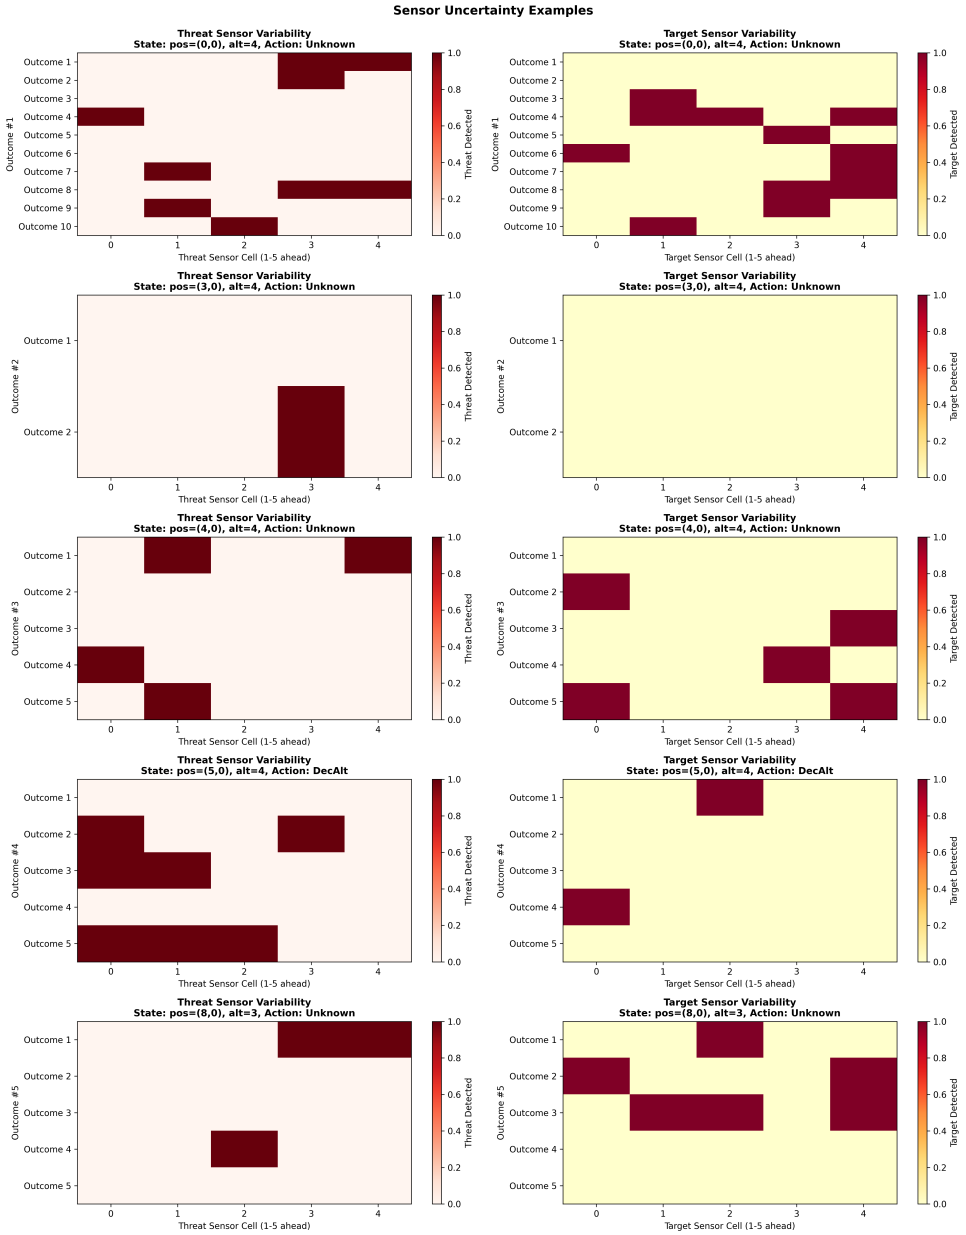

شکل ۲-۳: داشبورد تحلیل عدم قطعیت محیطی DARTSim: توزیع تصادفی‌بودن گذارها، عدم‌قطعیت به‌تفکیک نوع اقدام و مؤلفه حالت، تغییرپذیری قرائت حسگر تهدید و پراکندگی پاداش‌ها.

برای تبیین ملموس‌تر این پدیده، شکل ۲-۴ چند نمونه از زوج‌های حالت–اقدام را نشان می‌دهد که در آن‌ها قرائت حسگرهای تهدید و هدف (پنج سلول پیش‌رو) برای پیامدهای گوناگونِ ناشی از یک اقدام واحد تغییر می‌کند. این تصادفی‌بودن، عامل انطباقی را وادار می‌سازد که به‌جای حفظ‌کردنِ مسیرهای قطعی، سیاست‌های مقاومی بیاموزد که در سراسر پیامدهای محتمل کارا باشند. دقیقاً همین چالشِ کاوش و یادگیری تحت عدم‌قطعیت سنگین است که الگوریتم پیشنهادی RS-DRL برای غلبه بر آن طراحی شده است.

## ۲-۷-۸ فرمول‌بندی به عنوان MDP

مسئله انطباق تاکتیکی پهپادها در شبیه‌ساز DARTSim به صورت یک MDP استاندارد فرمول‌بندی می‌شود:

- **فضای حالت ($S$):** بردار حالت ۱۷ بعدی $s_t \in \mathbb{R}^{17}$ شامل موقعیت مکانی تیم پهپادی، سطح ارتفاع جاری، هندسه آرایش تیمی، وضعیت فعال‌سازی اخلال‌گر الکترونیکی و فاکتورهای شناسایی تهدیدات و اهداف است.
- **فضای اقدام ($A$):** فضای اقدامات شامل ۸ اقدام وفقی تاکتیکی گسسته است که در بخش قبل شرح داده شد.




شکل ۲-۴: نمونه‌هایی از تغییرپذیری قرائت حسگرهای تهدید و هدف برای یک زوج حالت‌ـاقدام یکسان در DARTSim؛ هر سطر یک پیامد ممکن و هر ستون یک سلول حسگر پیش‌رو را نشان می‌دهد.

- **تابع پاداش چندهدفه ($R$):** پاداش تجمعی زمان اجرا به صورت ترکیب وزنی زیر فرمول‌بندی می‌گردد:

$$R(s_t, a_t) = w_{\text{survival}} \cdot r_{\text{surv}}(s_t) + w_{\text{target}} \cdot r_{\text{target}}(s_t) - w_{\text{energy}} \cdot c_{\text{energy}}(a_t) - c_{\text{step}} \quad (۸-۲)$$

که در آن $c_{\text{step}} = ۰/۰۱$ جریمه زمانی هر گام مأموریت است.

### ۲-۷-۹ محیط انطباق آفلاین (Offline Replay Adapter)

به منظور غلبه بر محدودیت‌های پایداری اتصالات شبکه و داکر دسکتاپ در فاز آموزش، یک محیط انطباق آفلاین تحت عنوان OfflineDARTSimEnv طراحی گردید. این آداپتور، تعامل بلادرنگ با شبیه‌ساز را با یک ساختار جستجوی هوشمند تراکنش‌های از پیش‌ثبت‌شده (Offline Collected Data) جایگزین می‌کند. بر این اساس، بانک داده‌ای شامل ۵۰۰۰۰ انتقال حالت جمع‌آوری‌شده از مأموریت‌های واقعی پهپاد در سناریوی پایه (Baseline) لود شده و تراکنش‌های بعدی به صورت بازپخش ساختاریافته‌ی همان مسیرهای ثبت‌شده شبیه‌سازی می‌شوند. این رویکرد آفلاین منجر به تضمین کامل پایداری، سرعت بی‌سابقه فرآیند همگرایی یادگیری و تکرارپذیری مطلق آزمایش‌ها می‌گردد.

### ۲-۷-۱۰ طیف دشواری محیط و فضای طراحی سناریوها

محیط DARTSim به‌گونه‌ای طراحی شده است که طیفی از سطوح دشواری فزاینده را پشتیبانی کند؛ این طیف از یک نقشه‌ی خطی ساده تا نقشه‌های مربعی بزرگ با الگوی مسیر مارپیچی و چگالی بالای تهدید و هدف گسترده است و فضای طراحی لازم برای سنجش آینده‌نگرِ مقیاس‌پذیری و قابلیت تعمیم را فراهم می‌آورد. جدول ۲-۳ پارامترهای کلیدی این سه سناریوی پیکربندی‌پذیر را مقایسه می‌کند.

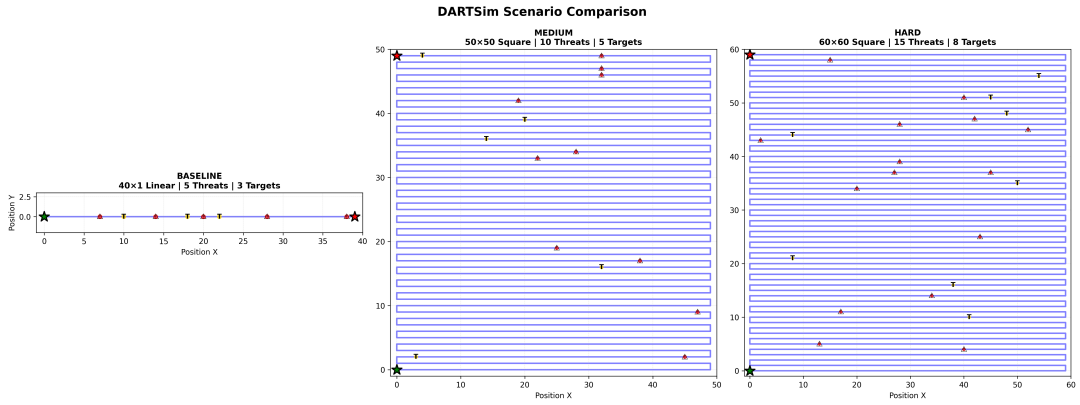
جدول ۲-۳: طیف سناریوهای پیکربندی‌پذیر محیط DARTSim و سطوح دشواری آن‌ها

| سناریو | ابعاد نقشه | نوع نقشه | تهدیدات | اهداف | سطوح ارتفاع | دشواری |
|---|---|---|---|---|---|---|
| پایه (Baseline) | 40×1 | خطی | ۵ | ۳ | ۴ | آسان |
| متوسط (Medium) | 50×50 | مربعی (مارپیچ) | ۱۰ | ۵ | ۵ | متوسط |
| سخت (Hard) | 60×60 | مربعی (مارپیچ) | ۱۵ | ۸ | ۶ | سخت |

سناریوی پایه دارای مسیر مستقیم و چگالی متعادل تهدیدها است؛ سناریوهای متوسط و سخت با افزودن مسیرهای مارپیچی پرپیچ‌وخم، نقشه‌های بزرگ‌تر و چگالی بالاتر تهدید و هدف، پیچیدگی روزافزون محیط را به تصویر می‌کشند. شکل ۲-۵ نمای مقایسه‌ای این سه سناریو را به‌همراه چیدمان تهدیدها، اهداف و الگوی مسیر نشان می‌دهد.

شایان توجه است که ارزیابی‌های تجربی گزارش‌شده در این رساله (بخش ۵-۶-۶) بر پایه‌ی مجموعه داده آفلاین جمع‌آوری‌شده از *سناریوی پایه* انجام شده‌اند؛ چرا که این سناریو با تأمین فضای حالت گسسته‌ی

بزرگ و توزیع پاداش به‌شدت پراکنده، چالش اصلیِ خروج از بهینه‌های محلی را به‌صورت کنترل‌شده فراهم می‌سازد. سناریوهای متوسط و سخت به‌عنوان فضای طراحیِ از پیش‌آماده‌ی محیط برای گسترش ارزیابی مقیاس‌پذیری و تعمیم‌پذیری در کارهای آتی (به‌ویژه در حالت برخط) معرفی شده‌اند.




شکل ۲-۵: مقایسه‌ی سه سناریوی DARTSim (پایه، متوسط و سخت)؛ تفاوت در چیدمان نقشه، پیچیدگی مسیر و چگالی تهدید و هدف.

## ۲-۸ خلاصه فصل

این فصل به تفصیل مبانی نظری و صوری مورد نیاز برای درک تصمیم‌گیری تحت عدم قطعیت در سیستم‌های خودوفق را تشریح نمود. ما با تحلیل مفاهیم سیستم‌های خودوفق، حلقه‌های MAPE-K و طبقه‌بندی معتبر واکر از عدم قطعیت آغاز کردیم. سپس فرآیند تصمیم‌گیری مارکوف (MDP) و الگوریتم‌های یادگیری تقویتی جدول‌محور و عمیق (DQN) را به عنوان ابزارهای تصمیم‌گیری زمان اجرا معرفی کردیم. در نهایت، با استفاده از سیستم محک استاندارد DeltaIoT، فرمول‌بندی MDP دقیق شبکه را بر پایه معیارهای انرژی، تلفات و تاخیر تبیین نمودیم. این زیربنای مستحکم نظری، مستقیماً به شناسایی شکاف‌های تحقیقاتی سه‌گانه در فصل ۳ (شامل تنگنای زمان تصمیم‌گیری، عدم تطابق اهداف آستانه‌ای و ایستایی توابع پتانسیل) کمک خواهد کرد. همچنین، مفاهیم پیشرفته‌ی ارائه شده در این فصل، سنگ بنای طراحی معماری نوآورانه RS-DRL در فصل ۴ را تشکیل می‌دهند که هدف آن حل مسئله بهینه‌سازی ان‌پی‌ـ سخت با استنتاج زمان اجرای فوق‌سریع و پایدار است. با پی‌ریزی این بنیان تئوریک و ریاضی مستحکم، اکنون بستر لازم برای واکاوی عمیق پیشینه پژوهش در فصل بعدی و ترسیم مسیر علمی رساله فراهم آمده است.

# فصل سوم

# مرور پیشینه پژوهش و کارهای مرتبط

## ۳-۱ مقدمه و روش‌شناسی مرور

هدف بنیادین این فصل، ارائه یک بررسی نظام‌مند، انتقادی و عمیق از ادبیات علمی و رویکردهای موجود در زمینه مدیریت عدم قطعیت و تصمیم‌گیری زمان اجرا در سیستم‌های خودوفق (Self-Adaptive Systems - SAS) است. در طراحی مهندسی سیستم‌های خودوفق مدرن، اتخاذ تصمیمات وفقی بهینه در مواجهه با شرایط پویای محیطی و فضاهای تصمیم‌گیری بسیار بزرگ، یکی از چالش‌های بنیادین به شمار می‌رود. کارهای پیشین هر یک از زاویه‌ای خاص به این مسئله نگریسته‌اند؛ با این حال، به منظور درک دقیق سهم علمی این رساله و تبیین دقیق ضرورت ارائه الگوریتم RS-DRL، تحلیل موشکافانه و مقایسه‌ای این رویکردها امری حیاتی است.

بدین منظور، در این فصل روش‌شناسی مروری ساختاریافته‌ای اتخاذ گردیده است. فرآیند شناسایی و گزینش مقالات از طریق جستجوی جامع در پایگاه‌های داده معتبر بین‌المللی از جمله IEEE Xplore، ACM Digital Library، Scopus و Google Scholar صورت پذیرفته است. بازه زمانی جستجو متمرکز بر پژوهش‌های برجسته دو دهه اخیر بوده و کلمات کلیدی نظیر «سیستم‌های خودوفق»، «یادگیری تقویتی آنلاین»، «شکل‌دهی پاداش»، «فضای وفقی بزرگ» و «تأیید صوری زمان اجرا» به عنوان معیارهای اصلی فیلترینگ استفاده شده‌اند. معیارهای ورود مقالات به چرخه بررسی انتقادی شامل تمرکز بر روی مدیریت فضاهای وفقی گسسته در زمان اجرا و توانایی سیستم در تصمیم‌گیری آنلاین تحت شرایط عدم قطعیت بوده است.

جهت ارزیابی نظام‌مند و مقایسه‌ی عادلانه پیشینه پژوهش، یک چارچوب ارزیابی پنج‌بعدی بر پایه معیارهای مهندسی نرم‌افزار خودوفق [؟، ؟] توسعه داده شده است که تمامی آثار بررسی‌شده بر اساس این شاخص‌ها مورد نقد قرار می‌گیرند:

۱. **ابعاد فضای وفقی (Adaptation Space Size):** توانایی متدولوژی پیشنهادی در مقیاس‌پذیری و مدیریت فضاهای تصمیم‌گیری گسسته و بزرگ (فراتر از ۱۰۰۰ گزینه وفقی).

۲. **مدیریت پویایی و عدم‌قطعیت زمان‌اجرا (Handling of Non-Stationarity):** پایداری عملکرد سیستم

در مواجهه با رانش مفهومی (Concept Drift) و تغییرات پیش‌بینی‌نشده محیطی بدون افت کیفیت خدمات.

۳. **عدم وابستگی به دانش دامنه خاص (Need for Domain Knowledge):** میزان نیاز به تخصص انسانی زمان توسعه یا طراحی اهداف صریح و پیچیده برای عامل یادگیرنده.

۴. **مقیاس‌پذیری و کارایی محاسباتی (Real-Time Scalability):** توانایی تصمیم‌گیری آنلاین در محدوده میلی‌ثانیه به منظور رعایت قیود پایداری زمانی سیستم.

۵. **قابلیت خروج از بهینه‌های محلی (Ability to Escape Local Optima):** کارایی مکانیزم‌های کاوش در فرار از تله‌های بهینگی محلی در طول یادگیری آنلاین.

[۱]

در ادامه‌ی این فصل، ابتدا مبانی نظری عدم قطعیت و تصمیم‌گیری در سیستم‌های خودوفق تشریح شده، سپس سه پارادایم اصلی تصمیم‌گیری (مبتنی بر یادگیری ماشین سنتی، مبتنی بر جستجو و مبتنی بر یادگیری تقویتی عمیق) به صورت موشکافانه تحلیل می‌گردند. در نهایت، با بررسی روش‌های پیشرفته بازپخش تجربه و شکل‌دهی پاداش و نقش روش‌های صوری، خلاءهای پژوهشی موجود استخراج و جایگاه الگوریتم پیشنهادی RS-DRL تبیین می‌گردد.

## ۳-۲ مبانی نظری: عدم‌قطعیت و تصمیم‌گیری در سیستم‌های خودوفق

سیستم‌های خودوفق به منظور حفظ اهداف کیفی خود (نظیر قابلیت اطمینان، مصرف انرژی و تأخیر)، نیازمند پایش مستمر محیط فیزیکی و تصمیم‌گیری بهینه در زمان اجرا هستند [؟، ؟]. با این حال، تصمیم‌گیری در این سیستم‌ها تحت تأثیر شدید منابع گوناگون عدم قطعیت قرار دارد. عدم قطعیت در ادبیات مهندسی نرم‌افزار خودوفق [؟، ؟] به طور کلی به سه دسته اصلی تقسیم می‌شود: عدم قطعیت محیطی (مانند نوسانات تداخل سیگنال در شبکه‌های اینترنت اشیا)، عدم قطعیت سیستمی (نظیر خرابی‌های ناگهانی سخت‌افزار یا تغییرات زیرساختی) و عدم قطعیت اهداف (تغییر در اولویت‌های کیفی کاربران در طول زمان).

برای مدل‌سازی فرآیند تصمیم‌گیری در مواجهه با این عدم قطعیت‌ها، مهندسان سیستم‌های خودوفق از ابزارهای ریاضیاتی متعددی بهره می‌برند:

- **فرآیند تصمیم‌گیری مارکوف (MDP):** استانداردترین روش مدل‌سازی ریاضی تصمیم‌گیری پیاپی است که در آن فرض می‌شود وضعیت بعدی سیستم تنها به وضعیت فعلی و اقدام اتخاذ شده وابسته است [؟].

[۱] این پنج معیار ارزیابی برای اولین بار در این رساله تدوین شده‌اند. جدول ۱-۳ در انتهای همین فصل (صفحه ۴۰) مقایسه تطبیقی جامع روش پیشنهادی RS-DRL را با کارهای پیشین بر اساس این پنج بعد ارائه می‌دهد.

در سیستم‌های خودوفق، وضعیت‌ها نشان‌دهنده شرایط محیطی و پیکربندی‌های سیستم، و اقدامات نشان‌دهنده گزینه‌های وفقی هستند.

- **فرآیند تصمیم‌گیری مارکوف نیمه‌مشاهده‌پذیر (POMDP):** در شرایطی استفاده می‌شود که عامل یادگیرنده دسترسی کامل به وضعیت واقعی محیط ندارد و تنها مشاهدات نویزی در اختیار دارد [؟]. اگرچه POMDP واقع‌گرایانه‌تر است، اما حل آن سربار محاسباتی بسیار بالایی دارد که مانع تصمیم‌گیری آنلاین بلادرنگ می‌شود.

- **جستجوی تصادفی زمان‌اجرا:** رویکردی غیرمدل‌محور است که سیستم با نمونه‌برداری زمان‌اجرا از فضای تغییرات، تلاش می‌کند گزینه‌ای را بیابد که اهداف سیستم را ارضا نماید.

یکی از چالش‌های بنیادین ریاضیاتی در تصمیم‌گیری آنلاین سیستم‌های خودوفق، پدیده **تله بهینه‌های محلی (Local Optima Trap)** است [؟]. در فضاهای وفقی بزرگ و گسسته، تابع مطلوبیت یا پاداش سیستم معمولاً غیرخطی، چندهدفه و دارای تپه‌های متعدد است. هنگامی که یک الگوریتم تصمیم‌گیری آنلاین یا عامل یادگیرنده تلاش می‌کند تا از طریق کاوش محلی (مانند شیب صعودی یا استراتژی‌های حریصانه) پیکربندی بهینه را بیابد، به شدت مستعد گرفتار شدن در نقاطی است که عملکرد بهتری نسبت به همسایگان بلاواسطه خود دارند، اما با بهینه سراسری (Global Optima) فاصله زیادی دارند.

این مشکل در شبکه‌های پویا نظیر DeltaIoT تشدید می‌شود [؟]؛ زیرا در این شبکه‌ها، تغییرات تداخل محیطی باعث تغییر مداوم قله‌های بهینگی می‌شود. اگر عامل تصمیم‌گیرنده نتواند با ترکیب بهینه‌ی کاوش (Exploration) و بهره‌برداری (Exploitation)، به طور مداوم و پویا فضای تصمیم‌گیری را جستجو کند، در یک سیاست تطبیقی منجمد شده و با تغییر شرایط محیطی دچار افت شدید کیفیت خدمات می‌گردد. در بخش‌های بعدی، نحوه مواجهه رویکردهای کلاسیک با این چالش ریاضیاتی را به تفصیل نقد خواهیم نمود.

## ۳-۳ رویکردهای اصلی مدیریت فضای وفقی در زمان اجرا

به منظور تحلیل و مقایسه‌ی پیشینه پژوهش در زمینه مدیریت فضاهای وفقی بزرگ، آثار علمی موجود را می‌توان به سه پارادایم اصلی تقسیم‌بندی نمود: رویکردهای مبتنی بر یادگیری ماشین سنتی برای هرس فضا، روش‌های مبتنی بر جستجو و بهینه‌سازی آنلاین، و مدل‌های مبتنی بر یادگیری تقویتی برای تصمیم‌گیری زمان اجرا. در ادامه، هر یک از این رویکردها را بر اساس چارچوب ارزیابی پنج‌بعدی معرفی‌شده نقد علمی می‌نماییم.

### ۳-۳-۱ هرس فضای وفقی مبتنی بر یادگیری ماشین سنتی

یکی از ایده‌های نخستین برای مقابله با انفجار ترکیبی گزینه‌های وفقی در سیستم‌های خودوفق بزرگ، هرس پیشاپیش فضای وفقی پیش از ارسال به مؤلفه‌ی تصمیم‌گیر (یا برنامه‌ریز) است. در این دسته از رویکردها،

مهندسان سیستم تلاش می‌کنند تا با استفاده از مدل‌های پیش‌بینی‌کننده یادگیری ماشین سنتی، گزینه‌های نامطلوب را فیلتر نمایند.

پژوهش‌های برجسته‌ی کوئین (Quin) و همکارانش [؟، ؟] از رویکردهای پیشگام در این زمینه است. آن‌ها با به‌کارگیری تکنیک‌های طبقه‌بندی نظارت‌شده (مانند درخت تصمیم و جنگل تصادفی) نشان دادند که می‌توان با آموزش یک مدل روی داده‌های تاریخی، پیکربندی‌هایی را که شانس بسیار پایینی برای ارضای کیفیت خدمات (QoS) دارند، شناسایی و هرس کرد. به طور مشابه، کاچی و بواناکا [؟] متدولوژی ML4EAS (Ma-chine Learning for Evaluating Adaptation Space) را توسعه دادند که از ترکیب الگوریتم‌های طبقه‌بندی و رگرسیون برای پیش‌بینی و غربالگری گزینه‌های ناکارآمد در سیستم‌های توزیع‌شده بهره می‌برد. این روش‌ها قادرند ابعاد فضای جستجو را در سناریوهای ایستا تا ۶۰ درصد کاهش دهند [؟].

**نقد و بررسی انتقادی:** علیرغم کارایی این روش‌ها در کاهش اندازه محیط تصمیم‌گیری زمان اجرا، دو محدودیت بنیادین در این متدولوژی‌ها وجود دارد. از یک سو، این روش‌ها با **وابستگی شدید به داده‌های برچسب‌دار آفلاین** مواجه هستند؛ چرا که فرآیند آموزش این طبقه‌بندها مستلزم جمع‌آوری مجموعه‌داده‌های بسیار حجیم و متنوع در زمان توسعه (Design-time) است و در سیستم‌های پیچیده معاصر، شبیه‌سازی تمامی سناریوهای نویزی و محیطی در زمان طراحی ناممکن است [؟، ؟]. از سوی دیگر، **پدیده رانش مفهومی (Concept Drift)** چالش مهم دیگری است؛ غیبی و وینز [؟] در تحلیل‌های خود تصریح کرده‌اند که در محیط‌های بسیار پویا (مانند اینترنت اشیا شهری با تداخلات متغیر)، الگوهای نویز و ویژگی‌های سیستم دستخوش تغییر مستمر زمان اجرا می‌شوند. با رخ دادن رانش مفهومی، فرضیات اولیه طبقه‌بندهای یادگیری ماشین نامعتبر گشته و دقت مدل در هرس گزینه‌ها به شدت افت می‌کند. برای جبران این افت، سیستم ناگزیر به آموزش مجدد (Retraining) مکرر و بسیار پرهزینه مدل در زمان اجراست، که این فرآیند علاوه بر ایجاد سربار محاسباتی زیاد، سیستم را در طول فرآیند آموزش در وضعیت ناپایدار و غیرایمن قرار می‌دهد و در نهایت منجر به ایجاد یک **موازنه شکننده بین مقیاس‌پذیری و استواری** می‌گردد.

## ۳-۳-۲ روش‌های مبتنی بر جستجوی آنلاین و استراتژی‌های اکتشافی

پارادایم دوم، تصمیم‌گیری زمان اجرا را به عنوان یک مسئله‌ی بهینه‌سازی و جستجوی آنلاین مدل‌سازی می‌کند. در این روش‌ها، نیازی به داده‌های پیش‌آموزش دیده نیست؛ بلکه سیستم با وقوع هرگونه تغییر در محیط، الگوریتم‌های جستجو را برای یافتن بهترین پیکربندی در فضای وفقی اجرا می‌کند.

کوکر (Coker) در معماری SASS [؟] از روش‌های جستجوی موضعی تصادفی نظیر الگوریتم صعود تپه (Hill Climbing) استفاده کرد تا با بررسی همسایگی پیکربندی فعلی، به پیکربندی برتر دست یابد. اگرچه این روش محاسبات سبکی دارد، اما به شدت مستعد گرفتار شدن در اولین بهینه محلی است [؟]. برای عبور از این چالش، پژوهش‌های کینر (Kinneer) و همکارانش [؟، ؟، ؟] بر به‌کارگیری برنامه‌نویسی ژنتیک (Genetic Programming) و الگوریتم‌های تکاملی زمان اجرا متمرکز شد. آن‌ها نشان دادند که با تکامل جمعیت‌های

گزینه‌های وفقی می‌توان به راه‌حل‌های بسیار بهتری دست یافت. علاوه بر این، چن (Chen) در رویکرد FEMOSAA [؟] با استفاده از الگوریتم تکاملی چندهدفه (MOEA)، مصالحه‌ی پویای بین اهداف متناقض کیفی (مانند انرژی و تأخیر) را در زمان اجرا مدل‌سازی و جستجو نمود.

**نقد و بررسی انتقادی:** اگرچه این رویکردها ویژگی تطبیق‌پذیری آنلاین بدون نیاز به آموزش را فراهم می‌سازند، اما نقطه ضعف بزرگ آن‌ها **سربار محاسباتی زمان اجرا و چالش پایداری زمانی** است: اولین نقطه ضعف، **عدم مقیاس‌پذیری در ابعاد بزرگ** است؛ الگوریتم‌های تکاملی و چندهدفه برای همگرایی به جبهه بهینه پارتو (Pareto Front) نیازمند ارزیابی صدها یا هزاران پیکربندی در هر گام تصمیم‌گیری هستند. هنگامی که ابعاد فضای وفقی بزرگ شده و فراتر از ۱۰۰۰ گزینه (نظیر فضای ۴۰۹۶ گزینه‌ای بستر DeltaIoTv2) می‌رود، زمان محاسبات این الگوریتم‌ها به مقیاس ثانیه یا دقیقه افزایش می‌یابد [؟، ؟]. دومین نقطه ضعف، **تأخیر غیرقابل‌تحمل زمان تصمیم‌گیری** است؛ در سیستم‌های حساس به زمان، این تأخیر طولانی برنامه‌ریز منجر به بروز رفتارهای مخرب و انحراف شدید از اهداف پایداری سیستم در طول بازه تصمیم‌گیری می‌گردد، که استقرار عملیاتی این روش‌ها را در محیط‌های زمان‌حقیقی غیرممکن می‌سازد [؟، ؟].

## ۳-۳-۳ یادگیری تقویتی زمان‌اجرا و کنترل خودمختار

یادگیری تقویتی (RL) به عنوان یک پارادایم تصمیم‌گیری آنلاین پویا، به دلیل توانایی ذاتی عامل در یادگیری سیاست وفقی مطلوب از طریق تعامل مستقیم با محیط، توجه بسیاری را جلب نموده است.

کارهای کلاسیک کیم و پارک [؟] از اولین تلاش‌ها در به‌کارگیری الگوریتم Q-Learning جدول‌محور برای تطابق پویای نرم‌افزارها بود. در ادامه، متزگر و همکارانش [؟] قابلیت یادگیری تقویتی را برای مدیریت تطابق در معماری‌های سرویس‌گرا تعمیم دادند. همچنین، کامارا و همکارانش [؟] چارچوب RLMC (Re-inforcement Learning Model Checking) را معرفی کردند که در آن از یادگیری تقویتی آنلاین برای هدایت سیستم‌های خودوفق استفاده شده و ایمنی کاوش را از طریق مدل‌چکینگ تضمین می‌کرد. با این حال، تمامی این کارهای اولیه به دلیل استفاده از روش‌های جدول‌محور، با چالش جدی «طاعون بعدنمایی» (Curse of Dimensionality) در فضاهای حالت و عمل بزرگ مواجه بودند [؟].

با ظهور یادگیری تقویتی عمیق (DRL) [؟]، محققان تلاش کردند تا با استفاده از شبکه‌های عصبی عمیق به عنوان تقریب‌زننده‌های تابع ارزش (مانند معماری عمیق DQN)، فضاهای بزرگ سیستم‌های خودوفق را مدیریت کنند [؟].

**نقد و بررسی انتقادی:** با وجود توانایی شبکه‌های عمیق در تقریب توابع در فضاهای بزرگ، پیاده‌سازی استانداردهای یادگیری تقویتی عمیق (نظیر DQN با مکانیزم اکتشاف حریصانه‌ی سنتی $\epsilon$-greedy) در سیستم‌های خودوفق با یک چالش تئوریک و عملی بزرگ مواجه است. شاخص‌ترین نقطه ضعف این رویکردها، **تله عمیق بهینه‌های محلی (Local Optima Trap)** است؛ دو (Du) و همکارانش [؟] در تحلیل‌های خود نشان دادند که در فضاهای وفقی بزرگ و گسسته، پویایی‌های نویزی زمان اجرا باعث می‌شوند که سیاست عامل یادگیرنده

به راحتی در بهینه‌های محلی متوقف شود. استراتژی کاوش تصادفی $\epsilon$-greedy در مواجهه با ابعاد بسیار بزرگ (مانند ۴۰۹۶ گزینه وفقی)، درصد بسیار بالایی از کاوش خود را صرف گزینه‌های غیرمفید و مخرب می‌کند. این امر همگرایی عامل را به شدت کند کرده و مدل را وادار می‌سازد تا در اولین پیکربندی نیمه‌پایدار متوقف گشته و توانایی عبور و رسیدن به بهینه سراسری را نداشته باشد، مگر آنکه فرآیند آموزش مجدد مدل با مقادیر بهینه‌تر از ابتدا آغاز گردد که در زمان اجرا به شدت پرهزینه است.

## ۳-۴ تکنیک‌های پیشرفته یادگیری تقویتی: کاوش، شکل‌دهی پاداش و نگاه به گذشته

در سیستم‌های خودوفق معاصر، عبور از محدودیت‌های الگوریتم‌های یادگیری تقویتی سنتی مستلزم به‌کارگیری تکنیک‌های پیشرفته در سه حوزه کلیدی است: مدیریت فرآیند کاوش در فضاهای وسیع، استفاده از مکانیزم‌های بازپخش تجربه با نگاه به گذشته، و استراتژی‌های شکل‌دهی پاداش. در این بخش، مبانی نظری و ریاضیاتی هر یک از این حوزه‌ها را تبیین کرده و چالش‌های تعمیم آن‌ها به سیستم‌های خودوفق را به صورت انتقادی واکاوی می‌نماییم.

### ۳-۴-۱ چالش‌های استراتژی کاوش در فضاهای وفقی بزرگ

فرآیند کاوش (Exploration) در یادگیری تقویتی، مکانیزمی است که به عامل اجازه می‌دهد تا رفتارهای جدید را به منظور کشف پاداش‌های بالاتر بیازماید. در فضاهای وفقی بزرگ و گسسته (مانند شبکه DeltaIoT با ۴۰۹۶ پیکربندی ممکن)، طراحی استراتژی کاوش به یک چالش بسیار پیچیده‌ی ریاضی تبدیل می‌شود.

روش‌های کاوش سنتی نظیر $\epsilon$-greedy یا کاوش بولتزمن (Boltzmann Exploration) در فضاهای با ابعاد بالا به شدت ناکارآمد هستند [؟، ؟]. در استراتژی $\epsilon$-greedy، عامل با احتمال $\epsilon$ اقدام بعدی خود را به صورت کاملاً تصادفی انتخاب می‌کند. هنگامی که تعداد اقدامات ممکن $A = ۴۰۹۶$ باشد، احتمال انتخاب یک اقدام وفقی مفید در میان انبوهی از اقدامات غیربهینه یا مخرب، بسیار ناچیز است. در نتیجه، بخش عمده‌ای از گام‌های کاوش عامل صرف بررسی گزینه‌هایی می‌شود که کیفیت خدمات را به شدت کاهش داده و پایداری سیستم را به مخاطره می‌اندازند. این امر منجر به افت شدید «کارایی نمونه» (Sample Efficiency) شده و سرعت همگرایی آنلاین را تا حد غیرقابل‌تحملی کاهش می‌دهد.

استفاده از روش‌های پیشرفته‌تر مانند حد بالای اطمینان (Upper Confidence Bound - UCB) نیز در محیط‌های زمان اجرا با عدم قطعیت پویا با مشکل مواجه است؛ زیرا ارزیابی مستمر عدم قطعیتِ تک‌تکِ اقدامات در فضاهای بسیار بزرگ، سربار محاسباتی شدیدی را به کنترل‌کننده زمان اجرا تحمیل می‌کند [؟]. از این رو، سیستم‌های خودوفق هوشمند نیازمند یک استراتژی کاوش هدایت‌شده هستند که بدون نیاز به نمونه‌برداری تصادفی کورکورانه، عامل را به سمت مناطق امیدبخش فضای وفقی هدایت نماید.

### ۳-۴-۲ ناکارآمدی مکانیزم بازپخش تجربه با نگاه به گذشته (HER) در محیط‌های آستانه‌محور

مکانیزم بازپخش تجربه با نگاه به گذشته (Hindsight Experience Replay - HER) که توسط آندریچویچ (Andrychowicz) و همکارانش [؟] معرفی شد، یکی از برجسته‌ترین پیشرفت‌ها در زمینه حل مسئله‌ی پاداش‌های پراکنده (Sparse Rewards) است. ایده کلیدی در HER، برچسب‌گذاری مجدد هدف (Goal Relabeling) برای تجربیات ناموفق است. به طور مشابه، رویکرد پاداش نرم‌تر (Soft HER) توسعه‌یافته توسط هه (He) و همکارانش [؟] تلاش نمود تا فرآیند برچسب‌گذاری مجدد را با استفاده از پاداش‌های ملایم‌تر سرعت بخشد.

با این وجود، بر اساس تحلیل تئوریک ارائه شده در این رساله، استدلال می‌کنیم که این مکانیزم‌ها دارای یک **تناقض و ناسازگاری بنیادین با پارادایم خودوفقی** هستند:

- **طراحی هدف‌محور (Goal-Conditioned) در مقابل ماهیت آستانه‌محور (Threshold-Based) خودوفقی:** الگوریتم HER به طور ذاتی برای محیط‌های هدف‌محور طراحی شده است؛ محیط‌هایی که در آن‌ها هدف عامل، رسیدن به یک مختصات یا وضعیت فیزیکی مشخص و صریح (مانند مکان سه بعدی بازوی رباتیک $g \in G$) است. در این سناریوها، اگر عامل نتواند به هدف $g$ برسد، HER وضعیت نهایی تجربه شکست‌خورده ($s'$) را به عنوان هدف فرضی در نظر گرفته و پاداش مثبتی به آن اختصاص می‌دهد.

- **فقدان نقطه هدف صریح در سیستم‌های خودوفق:** اهداف سیستم‌های خودوفق به ندرت به صورت یک نقطه وضعیت واحد فرموله می‌شوند. در مقابل، این اهداف همواره **آستانه‌محور** هستند. برای مثال، هدف سیستم کنترلی شبکه DeltaIoT، نگه‌داشتن میزان تأخیر در کمتر از ۱۰۰ میلی‌ثانیه و مصرف انرژی در کمتر از ۲ وات است. در این حالت، هدف یک نقطه مشخص نیست، بلکه زیرمجموعه وسیعی از فضا است که قیود آستانه‌ای را ارضا می‌سازد.

- **عدم امکان برچسب‌گذاری مجدد:** هنگامی که یک عامل در زمان اجرا شکست می‌خورد (مثلاً تأخیر شبکه به ۱۵۰ میلی‌ثانیه می‌رسد و آستانه نقض می‌شود)، هیچ مختصات یا وضعیت واحدی وجود ندارد که بتوان شکست را به عنوان یک «هدف جایگزین معتبر» برچسب‌گذاری مجدد کرد. نقض آستانه اساساً به معنای ناامنی و افت کیفیت خدمات است و تعریف یک «آستانه مجازی نقض‌شده» به عنوان هدف جدید در یادگیری با نگاه به گذشته، از نظر مهندسی و ریاضیاتی فاقد اعتبار بوده و ایمنی و ثبات کنترل‌کننده را به طور کامل نابود می‌سازد.

بنابراین، تکنیک‌های هدف‌محوری مانند HER و Soft HER عملاً قابلیت کاربرد در کنترل‌کننده‌های سیستم‌های خودوفق آستانه‌محور را دارا نمی‌باشند[۲].

[۲] با این حال، در سیستم‌های خودوفق آستانه‌محور، استفاده از توابع هدف صریح یا پتانسیل‌های ثابت با چالش ناسازگاری مواجه

### ۳-۴-۳ مبانی نظری و ریاضیاتی شکل‌دهی پاداش

شکل‌دهی پاداش (Reward Shaping) رویکردی قدرتمند در نظریه یادگیری تقویتی برای تسریع همگرایی عامل از طریق افزودن یک سیگنال پاداش کمکی (Auxiliary Reward) به پاداش اصلی محیط است. از نظر ریاضیاتی، پاداش شکل‌دهی‌شده زمان اجرا به صورت زیر تعریف می‌شود:

$$R_{shaped}(s, a, s') = R_{env}(s, a, s') + F(s, a, s') \quad (۱-۳)$$

که در آن $R_{env}$ پاداش حاصل از دینامیک محیط و $F(s, a, s')$ پاداش کمکی شکل‌دهی است.

نگ (Ng) و همکارانش در پژوهش کلاسیک خود [؟] اثبات ریاضیاتی ارائه‌دادند که نشان می‌دهد شکل‌دهی پاداش کورکورانه می‌تواند منجر به بروز پدیده «چرخه‌های بهینگی کاذب» (Suboptimal Loops) شود؛ وضعیتی که در آن عامل یاد می‌گیرد برای دریافت پاداش کمکی بیشتر، کارهای تکراری و بی‌فایده انجام دهد بدون آنکه به هدف اصلی محیط برسد. آن‌ها اثبات کردند که برای تضمین ثبات و حفظ سیاست بهینه محیط (Policy Invariance)، پاداش کمکی $F$ باید حتماً به صورت تفاضل پتانسیل یک تابع حالت پایه‌ریزی شود. این متدولوژی تحت عنوان شکل‌دهی پاداش مبتنی بر پتانسیل (Potential-Based Reward Shaping - PBRS) شناخته می‌شود [؟] و فرمولاسیون ریاضی آن به شرح زیر است:

$$F(s, a, s') = \gamma\Phi(s') - \Phi(s) \quad (۲-۳)$$

که در آن $\gamma$ ضریب تخفیف مارکوف و $\Phi(s)$ تابع پتانسیل حالت $s$ است. بر اساس قضیه ریاضی نگ، هرگاه پاداش شکل‌دهی دارای این فرمولاسیون باشد، مجموعه سیاست‌های بهینه عامل $\pi^*$ تحت پاداش شکل‌دهی‌شده دقیقاً با مجموعه سیاست‌های بهینه تحت پاداش اصلی یکسان خواهد بود[۳].

**نقد و بررسی انتقادی:** اگرچه PBRS چارچوب ریاضی مستحکمی برای تضمین حفظ سیاست بهینه ارائه می‌دهد، اما استقرار آن در سیستم‌های خودوفق واقعی با مانع بزرگی مواجه است. محدودیت نخست، **استاتیک بودن تابع پتانسیل در محیط‌های پویا** است؛ در طراحی سنتی PBRS [؟]، تابع پتانسیل $\Phi(s)$ به صورت کاملاً ایستا (Static) در زمان طراحی سیستم بر اساس دانش تجربی کارشناسان دامنه تعریف می‌شود. محدودیت دوم، **عدم انطباق با رانش مفهومی و شرایط پویای آنلاین** است؛ در یک سیستم خودوفق تحت تأثیر عدم قطعیت مستمر (رانش مفهومی)، پتانسیل واقعی حالت‌ها دائماً تغییر می‌کند. یک پتانسیل ایستای

است. این ناسازگاری یکی از شکاف‌های تحقیقاتی اصلی این رساله را تشکیل می‌دهد. راهکار پیشنهادی RS-DRL در فصل ۴ (بخش ۴-۶) با مکانیسم شکل‌دهی تصادفی پاداش (بدون نیاز به هدف صریح) به این چالش پاسخ می‌دهد. نتایج تجربی برتری آن نسبت به HER در فصل ۵ (جداول ۵-۳ و ۵-۴) تأیید شده است.

[۳] قضیه نگ [؟] شرط کافی برای حفظ سیاست بهینه را ارائه می‌دهد، اما فرض می‌کند تابع پتانسیل $\Phi$ ایستا (static) است. در سیستم‌های خودوفق با رانش مفهومی، این فرض نقض می‌شود. مکانیسم شکل‌دهی تصادفی RS-DRL (فصل ۴، بخش ۴-۶) نیازی به تابع پتانسیل ایستا ندارد و بنابراین از این محدودیت تئوریک عبور می‌کند.

تعریف‌شده در زمان طراحی، قادر به بازتاب پویایی‌های پیش‌بینی‌نشده زمان اجرا نیست و در شرایط جدید، پاداش‌های کمکی گمراه‌کننده‌ای تولید می‌کند که سرعت یادگیری عامل را به شدت کاهش داده یا همگرایی آنلاین را مختل می‌سازد [؟].

این نقیصه بنیادین تئوریک، ضرورت ابداع یک فرآیند شکل‌دهی تصادفی و پویای پاداش (همچون الگوریتم پیشنهادی RS-DRL در این رساله) را آشکار می‌سازد تا پتانسیل حالت‌ها را به صورت زمان اجرا و آنلاین بر اساس تضمین‌های کیفی محاسبات صوری تنظیم نماید.

## ۳-۵ ارزیابی و تایید صوری در فرآیند خودوفق‌سازی

تضمین ایمنی و ارضای کیفیت خدمات (QoS) در سیستم‌های خودوفق، به ویژه در حوزه‌های حساس، نیازمند ابزارهای صوری مستحکم است. ارزیابی و تأیید صوری زمان اجرا (Runtime Formal Verification) به عنوان پارادایمی مطرح است که به سیستم اجازه می‌دهد تا به صورت ریاضیاتی و دقیق، صحت تصمیمات خود را پیش از اعمال به سیستم واقعی ارزیابی کند. در این بخش، مبانی نظری تأیید صوری کمّی زمان اجرا، ابزارها و چارچوب‌های شاخص (مانند ActivFORMS و UPPAAL-SMC) و در نهایت معماری‌های ترکیبی (ترادف) صوری‌ـ یادگیری را مورد تحلیل انتقادی قرار می‌دهیم.

### ۳-۵-۱ تأیید صوری کمّی زمان اجرا (QVR)

تأیید صوری کمّی زمان اجرا (Quantitative Verification at Runtime - QVR) که توسط پیشگامانی نظیر کالینسکو (Calinescu) و همکارانش [؟] و وینز (Weyns) [؟] توسعه یافت، فرآیندی است که در آن مشخصات غیرعملکردی سیستم (مانند کارایی، استواری و مصرف انرژی) در زمان اجرا با استفاده از مدل‌های ریاضی احتمالات ارزیابی می‌شوند.

در این پارادایم، پویایی‌های سیستم و عدم قطعیت‌های محیطی معمولاً به صورت زنجیره‌های مارکوف زمان‌گسسته (DTMC) یا فرآیندهای تصمیم‌گیری مارکوف (MDP) مدل‌سازی می‌شوند. اهداف کیفی سیستم نیز با استفاده از منطق‌های زمانی احتمالات نظیر منطق زمانی محاسبات احتمالات (PCTL) فرموله می‌گردند. برای مثال، هدف ایمنی شبکه به صورت فرمول زیر تعریف می‌شود:

$$P_{\geq ۰/۹۵}[F^{\leq t}(\text{PacketLoss} < ۰/۱)] \qquad (۳-۳)$$

که به معنای آن است که با احتمال حداقل ۹۵ درصد، نرخ گم‌شدن بسته‌ها در طول زمان $t$ کمتر از ۱۰ درصد باقی بماند. موتورهای ارزیابی صوری زمان اجرا با حل ریاضیاتی این مدل‌ها به صورت برخط، مشخص می‌سازند که آیا پیکربندی انتخاب‌شده قیود فوق را ارضا می‌کند یا خیر [؟].

### ۳-۵-۲ چارچوب‌های ActivFORMS و ابزار UPPAAL-SMC

در بین چارچوب‌های صوری توسعه‌یافته برای سیستم‌های خودوفق، چارچوب ActivFORMS (Active For-mal Models for Self-Adaptation) که توسط وینز و همکارانش [؟] معرفی شد، جایگاه ویژه‌ای دارد. ActivFORMS یک موتور مبتنی بر مدل‌های صوری اجرایی در زمان اجراست که درون حلقه MAPE-K قرار می‌گیرد. این چارچوب تضمین می‌کند که فرآیند وفقی همواره با مدل‌های صوری اعتبارسنجی‌شده مطابقت داشته و رفتارهای غیرایمن در سیستم رخ ندهند.

با این حال، حل کامل و جامع توابع احتمالاتی در زمان اجرا به شدت پرهزینه است. برای عبور از این محدودیت محاسباتی، استفاده از ابزار بررسی مدل آماری (Statistical Model Checking - SMC) تحت چارچوب UPPAAL-SMC [؟] مورد توجه قرار گرفت. الگوریتم‌های SMC به جای حل فرمول‌های ریاضی پیچیده در تمام فضای حالت (که منجر به انفجار فضا می‌شود)، از شبیه‌سازی‌های تصادفی هوشمند سیستم بهره می‌برند. UPPAAL-SMC با اجرای تعداد مشخصی شبیه‌سازی زمان اجرا و اعمال آزمون‌های فرض آماری صوری (مانند آزمون نسبت احتمال متوالی والد – Wald's Sequential Probability Ratio Test - SPRT)، ارضای یا عدم ارضای خواص را با یک سطح اطمینان آماری مشخص ($\alpha, \beta$) تعیین می‌کند. این مکانیزم به شدت سربار محاسباتی ارزیابی‌های صوری زمان اجرا را کاهش می‌دهد.

### ۳-۵-۳ معماری‌های ترکیبی یادگیری و ارزیابی صوری (مدل‌های ترادف)

با آشکار شدن قدرت مقیاس‌پذیری یادگیری ماشین و امنیت بالای روش‌های صوری، محققان در سال‌های اخیر به سمت توسعه معماری‌های ترکیبی متمایل شده‌اند که در ادبیات علمی به عنوان رویکردهای ترادف (Tandem Approaches) شناخته می‌شوند. پژوهش کامارا و همکارانش [؟] نمونه شاخصی از این معماری‌هاست. در این رویکردها، عامل یادگیری تقویتی وظیفه هدایت سیستم و یادگیری سیاست‌های وفقی را بر عهده دارد، در حالی که ماژول ارزیابی صوری زمان اجرا (SMC/QVR) به عنوان یک فیلتر ایمنی زمان اجرا عمل می‌کند. هرگاه اقدام پیشنهادی عامل یادگیرنده از نظر صوری ناامن تشخیص داده شود، فیلتر صوری آن را بلاک کرده و سیستم را مجبور به انتخاب گزینه‌ای ایمن می‌نماید.

**نقد و بررسی انتقادی:** اگرچه معماری‌های ترادفی کلاسیک گام بزرگی رو به جلو هستند، اما کماکان دارای یک نقطه ضعف عملیاتی جدی هستند که مانع از استقرار آن‌ها در بسترهای اینترنت اشیا بزرگ می‌گردد. نقطه ضعف اول، **سربار شدید ارزیابی صوری در فضاهای وفقی بزرگ** است؛ بررسی مدل صوری (حتی با ابزار سبک UPPAAL-SMC) برای هر یک از گزینه‌های تصمیم‌گیری زمان اجرا مستلزم چند صد بار شبیه‌سازی تصادفی است. در صورتی که عامل یادگیرنده بخواهر در یک فضای بزرگ (مثلاً با ۴۰۹۶ گزینه وفقی) کاوش کند، ارزیابی صوری تمامی این گزینه‌ها زمان تصمیم‌گیری حلقه MAPE-K را به شدت افزایش داده (تا چندین دقیقه) و عملاً کارکرد آنلاین سیستم را با اختلال جدی مواجه می‌سازد. نقطه ضعف دوم، **ایستا بودن فیلتر ایمنی صوری** است؛ فیلترهای صوری کلاسیک رفتاری صفر و یکی دارند و نمی‌توانند بازخورد کیفی دقیقی

به عامل یادگیرنده ارائه دهند تا او سرعت یادگیری خود را بهبود بخشد.

این نقد اساسی، ضرورت وجود یک معماری جدید مانند RS-DRL را اثبات می‌کند[۴]؛ معماری خاصی که در آن ماژول صوری UPPAAL-SMC به جای ایفای نقش به عنوان فیلتر نهایی سنگین برای تمامی گزینه‌ها، به صورت ناهمگام (Asynchronous) برای محاسبه‌ی صوری متغیرهای پتانسیل یادگیری و شکل‌دهی تصادفی پاداش به کار گرفته شود. این کار موازنه بهینه‌ای بین مقیاس‌پذیری تصمیم‌گیری عمیق و تضمین‌های ریاضی روش‌های صوری برقرار می‌سازد.

## ۳-۶ سنتز: شکاف تحقیقاتی سه‌گانه و موقعیت‌دهی علمی RS-DRL

بر اساس نقد و بررسی‌های انجام‌شده در بخش‌های پیشین، مشخص می‌گردد که هر یک از رویکردهای کلاسیک و مدرن مدیریت فضای وفقی در سیستم‌های خودوفق، از مزایای متمایزی برخوردار بوده و همزمان با محدودیت‌های بنیادین تئوریک و عملی مواجه هستند. به منظور جمع‌بندی دقیق وضعیت هنر، در ادامه ابتدا یک ماتریس ارزیابی چندبعدی ارائه گردیده و سپس شکاف‌های تحقیقاتی موجود تبیین می‌شوند.

### ۳-۶-۱ ماتریس ارزیابی و سنتز پیشینه پژوهش

در جدول ۳-۱، پارادایم‌های اصلی موجود در پیشینه پژوهش بر اساس چارچوب ارزیابی پنج‌بعدی پیشنهادی به همراه روش پیشنهادی این رساله (RS-DRL) مورد مقایسه و ارزیابی تطبیقی قرار گرفته‌اند.

### ۳-۶-۲ شکاف تحقیقاتی سه‌گانه

با متقاطع‌سازی ابعاد ارزیابی و چالش‌های عملیاتی احصاءشده از پیشینه پژوهش، **شکاف تحقیقاتی سه‌گانه‌ای** که این رساله بر حل آن‌ها تمرکز دارد به شرح زیر صورت‌بندی می‌شود:

۱. **شکاف اول: تقابل مقیاس‌پذیری و پایداری زمانی تصمیم‌گیری (Scale-Latency Dilemma):** در سیستم‌های خودوفق با فضاهای وفقی بزرگ (بیش از ۱۰۰۰ گزینه)، رویکردهایی که از ارزیابی‌های صوری دقیق زمان اجرا (SMC/QVR) یا جستجوهای تکاملی استفاده می‌کنند، با چالش جدی انفجار محاسباتی مواجه هستند که زمان تصمیم‌گیری را به مقیاس دقیقه افزایش می‌دهد. در مقابل، روش‌های یادگیری ماشین و شبکه‌های عمیق زمان استنتاج میلی‌ثانیه‌ای دارند اما فاقد هرگونه تضمین ریاضی ثبات و ایمنی آنلاین هستند. تا کنون مکانیزمی خلاقانه که بتواند بدون تحمیل سربار محاسباتی صوری به مسیر استنتاج آنلاین، تضمین‌های صوری ریاضی را به یادگیری عمیق تزریق کند، ارائه نشده است.

[۴] معماری RS-DRL با جداسازی زمانی (Temporal Separation) که در فصل ۴ (بخش ۴-۲ و ۴-۴) تشریح شده است، این مشکل را حل می‌کند: ارزیابی صوری به صورت موازی و ناهمگام (asynchronous) در پس‌زمینه انجام می‌شود و مسیر تصمیم‌گیری آنلاین را مسدود نمی‌کند. شکل ۴-۷ در فصل ۴ این معماری غیرانسدادی را نشان می‌دهد.

جدول ۳-۱: مقایسه تطبیقی پارادایم‌های مدیریت فضای وفقی زمان اجرا بر اساس چارچوب ارزیابی پنج‌بعدی (برگرفته از تحلیل کارهای پیشین نظیر [؟، ؟، ؟، ؟])

| پارادایم / رویکرد | مدیریت ابعاد بزرگ (مقیاس‌پذیری) | استواری در برابر تغییرات آنلاین | استقلال از داده و پیش‌آموزش | کارایی محاسباتی آنلاین | فرار از تله بهینه‌های محلی |
|---|---|---|---|---|---|
| **هرس مبتنی بر یادگیری ماشین [؟، ؟]** | متوسط | ضعیف (به علت رانش مفهومی) | ضعیف (نیازمند برچسب‌گذاری آفلاین) | عالی (میلی‌ثانیه) | غیرقابل اعمال (فقط هرس می‌کند) |
| **جستجوی آنلاین تکاملی [؟، ؟، ؟]** | ضعیف (انفجار زمان محاسبه) | متوسط | عالی (بدون نیاز به پیش‌آموزش) | ضعیف (ثانیه/دقیقه) | متوسط (به واسطه جهش‌های تصادفی) |
| **یادگیری تقویتی عمیق سنتی [؟، ؟]** | متوسط تا عالی | متوسط | عالی (یادگیری آنلاین مدل‌فردا) | عالی (کمتر از چند میلی‌ثانیه) | ضعیف (به علت کاوش کورکورانه $\epsilon$-greedy) |
| **تأیید صوری زمان اجرا [؟، ؟]** | بسیار ضعیف (انفجار فضا) | عالی (تضمین ریاضی پایداری) | عالی | بسیار ضعیف (سربار شدید محاسبات صوری) | متوسط (تنها ایمنی را بررسی می‌کند) |
| **روش پیشنهادی (RS-DRL)** | **عالی (استفاده از شبکه عمیق بدون فیلتر برخط)** | **عالی (انطباق با تغییرات به واسطه پتانسیل پویا)** | **عالی (یادگیری کاملاً آنلاین و مدل‌فردا)** | **عالی (کمتر از چند میلی‌ثانیه برای استنتاج)** | **عالی (به واسطه شکل‌دهی پویای پاداش صوری)** |

۲. **شکاف دوم: عدم تطابق مکانیزم‌های نگاه به گذشته با اهداف آستانه‌محور خودوفقی (Goal-Threshold Mismatch):** الگوریتم‌های پیشرفته یادگیری برای پاداش‌های پراکنده (مانند HER و Soft HER) منحصراً برای محیط‌های «هدف‌محور» طراحی شده‌اند که عامل در آن‌ها به دنبال رسیدن به مختصاتی معین است. این در حالی است که اهداف سیستم‌های خودوفق معاصر ماهیت «آستانه‌محور» (مانند نگه‌داشتن مصرف انرژی زیر یک مقدار مشخص) دارند. این ناسازگاری تئوریک باعث می‌شود که در صورت بروز نقض آستانه، برچسب‌گذاری مجدد با نگاه به گذشته فاقد اعتبار ریاضی گشته و عملاً کارایی خود را در هدایت کاوش آنلاین سیستم‌های خودوفق از دست بدهد.

۳. **شکاف سوم: ایستایی توابع پتانسیل در مواجهه با پویایی‌های نویزی آنلاین (Static-Dynamic Potential Gap):** تکنیک‌های ریاضیاتی شکل‌دهی پاداش مبتنی بر پتانسیل (PBRS) [؟] که ثبات سیاست بهینه را تضمین می‌کنند، به صورت سنتی نیازمند یک تابع پتانسیل $\Phi(s)$ کاملاً ایستا هستند که در زمان طراحی توسط کارشناس خبره تعریف می‌شود. در حضور عدم قطعیت‌های شدید زمان اجرا و رانش مفهومی محیط، این توابع ایستای زمان طراحی کارایی خود را از دست داده و حتی ممکن است با ارائه پاداش‌های نادرست، همگرایی آنلاین عامل را مختل سازند. خلأ شدیدی در زمینه سیستم‌های شکل‌دهی پویای پتانسیل وجود دارد که بتوانند پتانسیل حالت‌ها را به صورت پویا بر اساس بازخوردهای صوری آنلاین به‌روزرسانی کنند.

## ۳-۶-۳ موقعیت‌دهی علمی معماری پیشنهادی RS-DRL

معماری پیشنهادی این رساله، تحت عنوان **یادگیری تقویتی عمیق شکل‌دهی‌شده با بررسی صوری زمان اجرا (RS-DRL)**، به عنوان راهکاری جامع برای پل زدن بر این شکاف‌های سه‌گانه طراحی و موقعیت‌دهی شده است. نوآوری‌های کلیدی این رویکرد به شرح زیر با شکاف‌های تحقیقاتی متناظر همخوانی دارند:

- **پاسخ به شکاف اول (تقابل سرعت و امنیت):** معماری RS-DRL فرآیند زمان‌بر ارزیابی صوری زمان اجرا را از مسیر مستقیم تصمیم‌گیری آنلاین عامل یادگیرنده خارج ساخته و آن را به صورت **غیرهمگام (Asynchronous)** در پس‌زمینه اجرا می‌کند. عامل برای تصمیم‌گیری صرفاً شبکه عمیق را در کمتر از ۱ میلی‌ثانیه استنتاج می‌کند، در حالی که ماژول صوری تصادفی (UPPAAL-SMC) به صورت موازی پتانسیل‌های یادگیری را به‌روزرسانی می‌کند. این متدولوژی برای اولین بار به طور همزمان مقیاس‌پذیری تصمیم‌گیری عمیق آنلاین و استواری صوری ریاضیاتی را تضمین می‌نماید.

- **پاسخ به شکاف دوم (یادگیری آستانه‌محور):** در RS-DRL، به جای به‌کارگیری متدهای هدف‌محور ناکارآمد مانند HER، سیستم با ترکیب پاداش محیط و پاداش کمکی صوری هدایت می‌شود. این پاداش کمکی به طور دقیق شدت ارضای آستانه‌ها را منعکس کرده و بدون نیاز به تعریف مختصات هدف صریح، امنیت کاوش عامل را در فضاهای آستانه‌محور تضمین می‌نماید.

- **پاسخ به شکاف سوم (شکل‌دهی پویا):** نوآوری بنیادین ریاضیاتی در RS-DRL، معرفی استراتژی **شکل‌دهی پویای پاداش مبتنی بر بررسی صوری زمان اجرا** است. در این متدولوژی، تابع پتانسیل دیگر ایستا نیست، بلکه به عنوان یک متغیر پویای تصادفی آنلاین فرموله‌بندی شده و مقادیر آن به طور مستمر بر اساس خروجی‌های کمّی حاصل از تحلیل‌های آماری UPPAAL-SMC به‌روزرسانی می‌گردند. این مکانیزم انطباق کامل عامل با رانش مفهومی و نویز محیط را بدون ابطال تئوریک سیاست بهینه رقم می‌زند.

جدول ۳-۲ خلاصه‌ای از نحوه پوشش شکاف‌های تحقیقاتی توسط نوآوری‌های RS-DRL را نمایش می‌دهد.

جدول ۳-۲: نحوه پوشش شکاف‌های تحقیقاتی توسط نوآوری‌های معماری پیشنهادی RS-DRL

| شکاف تحقیقاتی | محدودیت روش‌های کلاسیک | راهکار و نوآوری ارائه شده در RS-DRL |
|---|---|---|
| **شکاف اول (سرعت و امنیت)** | تأخیر طولانی مدل‌چکینگ زمان اجرا در فضاهای بزرگ | ارزیابی صوری ناهمگام و استنتاج میلی‌ثانیه‌ای آنلاین شبکه عمیق |
| **شکاف دوم (یادگیری آستانه‌محور)** | عدم امکان استفاده از روش‌های برچسب‌گذاری مجدد هدف (HER) | هدایت عامل به کمک پاداش‌های کمکی صوری سنجش کیفیت و آستانه |
| **شکاف سوم (شکل‌دهی پویا)** | ایستایی توابع پتانسیل شکل‌دهی پاداش در محیط‌های متغیر آنلاین | شکل‌دهی پویای پاداش با به‌روزرسانی آنلاین پتانسیل‌ها به وسیله بازخورد صوری زمان اجرا |

## ۳-۷ خلاصه فصل

در این فصل، مرور عمیق و منسجمی بر مبانی نظری و پیشینه پژوهش مرتبط با فرآیندهای خودوفق‌سازی در سیستم‌های نرم‌افزاری و شبکه‌های توزیع‌شده نوین صورت گرفت. مسیر تحلیل پیشینه با تبیین ماهیت معماری‌های خودوفق مبتنی بر حلقه MAPE-K و چالش بنیادین انفجار فضای پیکربندی در سیستم‌های مقیاس‌بزرگ آغاز گردید. سپس، رویکردهای موجود در وضعیت هنر در قالب چهار پارادایم اصلی طبقه‌بندی و مورد بررسی انتقادی قرار گرفتند: هرس مبتنی بر یادگیری ماشین سنتی، جستجوی آنلاین تکاملی، یادگیری تقویتی عمیق بدون مدل و تأیید صوری زمان اجرا.

با اعمال یک چارچوب ارزیابی پنج‌بعدی پیشنهادی بر پیشینه پژوهش، مشخص گردید که هیچ‌یک از متدولوژی‌های کلاسیک قادر به حل همزمان چالش‌های مقیاس‌پذیری، کارایی محاسباتی آنلاین، استواری در برابر رانش مفهومی و تضمین‌های ریاضیاتی ایمنی نیستند. این تحلیل انتقادی به صورت‌بندی دقیق **شکاف تحقیقاتی سه‌گانه‌ای** منجر شد که محور تمرکز علمی این رساله را تشکیل می‌دهد:

۱. **تقابل مقیاس‌پذیری و پایداری زمانی تصمیم‌گیری:** ناشی از سربار زمانی شدید مدل‌چکینگ آنلاین صوری در فضاهای پیکربندی بزرگ.

۲. **عدم تطابق مکانیزم‌های نگاه به گذشته با اهداف آستانه‌محور خودوفقی:** به دلیل محدودیت ذاتی الگوریتم‌هایی مانند HER که منحصراً برای فضاهای وفقی مختصات‌محور و غایت‌محور توسعه یافته‌اند.

۳. **ایستایی توابع پتانسیل شکل‌دهی پاداش:** که با ماهیت نویزی و دائماً در حال تغییر عدم قطعیت‌های آنلاین زمان اجرا ناسازگار است.

در نهایت، موقعیت‌دهی علمی روش پیشنهادی این رساله (RS-DRL) به عنوان پاسخ و راهکاری یکپارچه برای پوشش هر سه شکاف فوق تبیین شد. بنابراین، یافته‌های تحلیلی این فصل به طور قاطع تأیید می‌کنند که هیچ‌یک از رویکردهای موجود در پیشینه پژوهش قادر به ارضای همزمان الزامات سه‌گانه (سرعت میلی‌ثانیه‌ای، انطباق‌پذیری با پویایی زمان اجرا، و تضمین صوری ایمنی ریاضی) نیستند و معماری پیشنهادی RS-DRL دقیقاً برای پر کردن این شکاف بنیادین علمی موقعیت‌دهی شده است.

**خلاصه یافته‌های کلیدی فصل سوم (مرور پیشینه پژوهش):**

- **ناکارآمدی فیلترهای صوری آنلاین:** فیلترهای صوری زمان اجرا (QVR) به صورت مستقیم در مسیر تصمیم‌گیری باعث سربار محاسباتی شدید (در حد دقیقه) برای فضاهای وفقی بزرگ می‌گردند [؟، ؟].

- **انفجار فضای حالت در تکامل آنلاین:** روش‌های جستجوی تصادفی و تکاملی آنلاین فاقد توانایی تصمیم‌گیری بی‌درنگ در مقیاس میلی‌ثانیه برای سیستم‌های اینترنت اشیاء هستند [؟، ؟].
- **شکست روش‌های HER در سناریوهای SLA:** الگوریتم‌های برچسب‌گذاری مجدد هدف به علت تعاریف مبتنی بر فیزیک مختصاتی، در برابر آستانه‌های کیفی سیستم‌های خودوفق فاقد کارایی علمی می‌باشند.
- **ضرورت معماری ترادف ناهمگام:** تلفیق ناهمگام یادگیری عمیق و بررسی صوری آماری (UPPAAL-SMC) به عنوان تنها راهکار تأمین همزمان کارایی آنلاین و تضمین‌های ریاضیاتی ایمنی شناسایی شد.

**پل مفهومی به فصل بعد (بیانیه پل):** با استقرار بستر نظری مستحکم در این فصل و صورت‌بندی دقیق نقاط ضعف و شکاف‌های پیشینه، مسیر برای تشریح جزئیات فنی و عملیاتی متدولوژی پیشنهادی هموار گردیده است. بر این اساس، در **فصل چهارم** به تبیین دقیق معماری و سازماندهی فرآیند اجرایی الگوریتم RS-DRL خواهیم پرداخت. در آن فصل، فرمول‌بندی ریاضیاتی شکل‌دهی پویای پاداش صوری، نحوه ارتباط ناهمگام میان عامل یادگیری تقویتی عمیق و ماژول بررسی صوری احتمالات (UPPAAL-SMC) و در نهایت، تضمین همگرایی تئوریک سیستم تحت شرایط نویزی زمان اجرا تشریح خواهند شد تا نشان داده شود چگونه معماری پیشنهادی قادر است موازنه بهینه‌ای بین سرعت میلی‌ثانیه‌ای آنلاین و ایمنی صوری ریاضیاتی برقرار سازد.

# فصل چهارم

# روش پیشنهادی

## ۴-۱ مقدمه

طراحی و توسعه سیستم‌های نرم‌افزاری خودوفق زمان واقعی در محیط‌های پویا و نویزی، مستلزم ایجاد موازنه عمیقی میان دو دغدغه متضاد مهندسی است: تصمیم‌گیری فوق‌سریع در مقیاس میلی‌ثانیه جهت همگامی‌با تغییرات محیطی، و ارائه تضمین‌های صوری و ریاضیاتی مبتنی بر ایمنی و انطباق کامل با اهداف کیفیت خدمات (QoS). همان‌طور که در فصل‌های پیشین تبیین گردید، روش‌های کلاسیک بهینه‌سازی و وارسی مدل آنلاین به دلیل محدودیت شدید مقیاس‌پذیری و زمان‌های محاسباتی طولانی (که در رده مسائل ان‌پی‌ـ سخت طبقه‌بندی می‌شوند [؟، ؟]) قادر به برآوردن این الزامات نیستند. از سوی دیگر، یادگیری تقویتی عمیق استاندارد (DRL) اگرچه زمان تصمیم‌گیری را به شدت کاهش می‌دهد، اما به علت پدیده «پراکندگی پاداش» (پاداش‌های پراکنده [؟]) و رانش مفهومی [؟]، به سرعت در تله بهینه‌های محلی گرفتار می‌شود و فاقد تضمین‌های صوری زمان اجراست.

هدف اصلی این فصل، ارائه جزئیات فنی و ریاضیاتی متدولوژی پیشنهادی، یعنی معماری RS-DRL (یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش) است که به طور مستقیم برای پاسخ‌گویی به چالش‌های بنیادین طراحی شده است. اهداف تفصیلی این فصل عبارتند از:

۱. تبیین اصل ساختاری **جداسازی زمانی** (Temporal Separation) به عنوان سنگ بنای جداسازی مسیر تصمیم‌گیری آنلاین از فرآیندهای یادگیری پس‌زمینه.

۲. تشریح فرآیند چهار مرحله‌ای حلقه تصمیم‌گیری زمان واقعی مبتنی بر مدل فرآیندی MAPE-K.

۳. فرمول‌بندی ریاضیاتی نوآوری اصلی رساله، یعنی مکانیزم **شکل‌دهی تصادفی پاداش صوری** جهت خروج عامل هوشمند از بهینه‌های محلی.

۴. توصیف ساختار مخزن دانش مشترک و مکانیزم‌های هماهنگی ناهمگام.

۵. تبیین نحوه ادغام موتور راستی‌آزمایی صوری زمان اجرای UPPAAL-SMC به عنوان فیلتر کیفیت خدمات بدون ایجاد اختلال در سرعت تصمیم‌گیری.

در این ساختار سلسله‌مراتبی، ابتدا اصول معماری سطح بالا بررسی می‌شود و سپس جزئیات پیاده‌سازی فرآیندی، فرمول‌بندی‌های ریاضیاتی و نحوه پاسخ به پرسش‌های پژوهش تبیین می‌گردد.

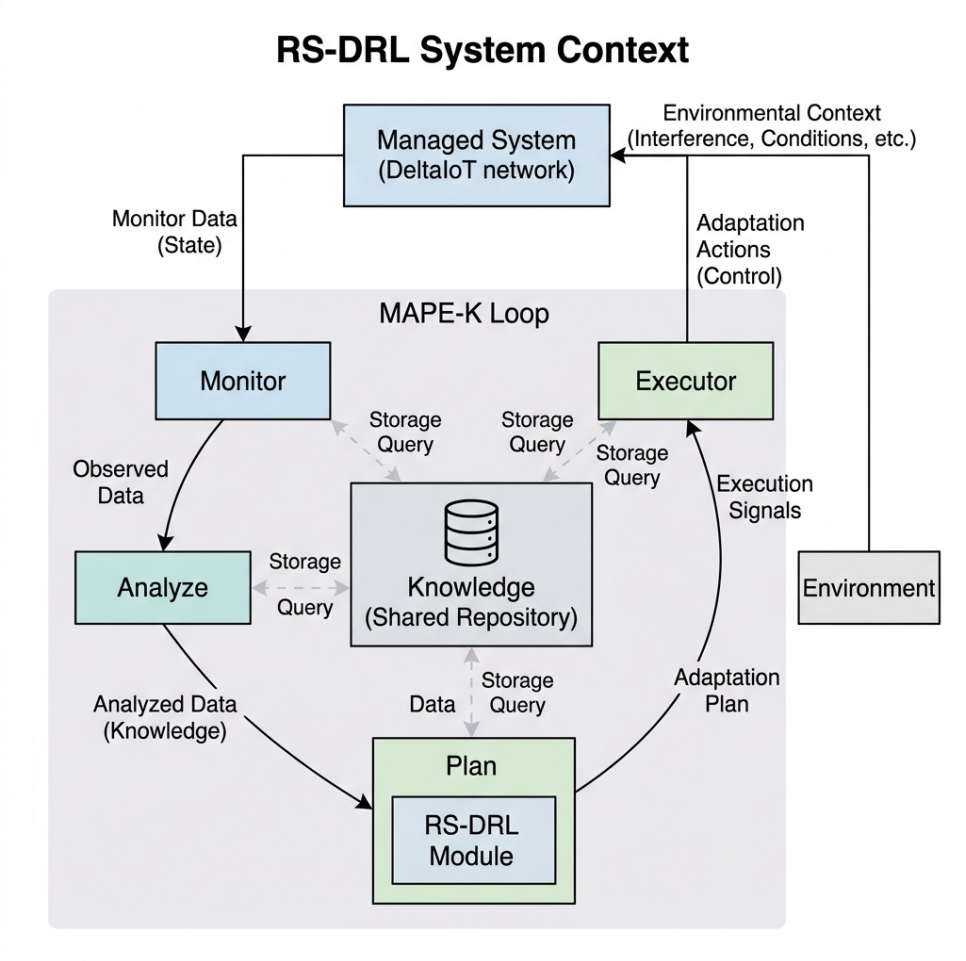
## ۴-۲ اصول معماری سطح بالا و سازماندهی فرآیند

یک سیستم خودوفق کارآمد در محیط‌های همراه با عدم قطعیت، باید ذاتاً بین دغدغه‌های متضاد طراحی مانند تصمیم‌گیری آنلاین با تأخیر بسیار کم و آموزش سنگین و ناهمگام مدل‌های یادگیری، تفکیک قائل شود تا بتواند آن‌ها را به‌طور مؤثر در یک ریسمان کنترلی واحد مدیریت کند. معماری RS-DRL بر اساس این اصل بنیادین **جداسازی زمانی** (Temporal Separation) طراحی شده است: مسیر بحرانی تصمیم‌گیری از مشاهده تا اجرا، مستقل از چرخه‌های یادگیری پس‌زمینه عمل می‌کند.

**توجیه علمی و چرایی جداسازی زمانی:** در معماری‌های متداول و پیشرفته‌ترین روش‌ها، حلقه‌های تصمیم‌گیری غالباً فرآیند استنتاج و آموزش را به صورت همزمان یا در گام‌های متوالی در یک نخ کنترلی واحد اجرا می‌کنند. از آنجا که به روزرسانی شبکه‌های عصبی عمیق مستلزم محاسبات سنگین پس‌انتشار گرادیان (Backpropagation) بر روی مینی‌بچ‌های داده است، اجرای آن در مسیر تصمیم‌گیری مستقیم، تأخیرهای شدیدی در حدود ده تا صدها میلی‌ثانیه ایجاد می‌کند که برای سیستم‌های زمان واقعی غیرقابل قبول است. در مقابل، استنتاج خالص سیاست (گذر رو به جلوی شبکه عصبی) تنها نیازمند چند ضرب ساده ماتریسی است که زمان اجرای آن همواره کمتر از نیم میلی‌ثانیه (۰٫۵ms) است. با جداسازی زمانی، ما فرآیند سنگین محاسباتی یادگیری را به یک ریسمان پس‌زمینه کاملاً ناهمگام منتقل کرده‌ایم تا مسیر آنلاین همواره چابک باقی بماند.

به جای تشریح ایستای مؤلفه‌های نرم‌افزاری، منطق تفکیک از طریق یک **مدل فرآیندی** به تصویر کشیده می‌شود. جریان داده و کنترل از لحظه دریافت سیگنال از حسگر تا اعمال فرمان تطبیق توسط عملگر دنبال می‌شود. در نتیجه، نمایی پویا و زمان‌آگاه از سیستم ارائه می‌گردد که در آن **رخدادها و توالی عملیات** اصل سازمان‌دهنده هستند، نه صرفاً موقعیت فیزیکی کد.

در این دیدگاه فرآیندمحور، نقشه سطح بالای تعاملات سیستم در شکل ۴-۱ به عنوان راهنمای ناوبری ارائه شده است. این نمودار به وضوح نشان می‌دهد که جریان داده‌های حسگرها از محیط وارد ماژول‌های پایش شده، حالت سیستم ساخته می‌شود، عامل هوشمند استنتاج سریع را انجام می‌دهد و در نهایت، تصمیمات توسط ماژول‌های صوری UPPAAL-SMC ارزیابی شده و فرمان‌های نهایی از طریق عملگرها بر سیستم فیزیکی اعمال می‌گردد.




شکل ۴-۱: معماری سطح بالای رویکرد RS-DRL در قالب حلقه MAPE-K. این نمودار تعامل میان سیستم مدیریت‌شونده، محیط، و مؤلفه‌های کنترلی را به همراه مخزن دانش (Knowledge) مشترک نشان می‌دهد.

### ۴-۲-۱ مقایسه تطبیقی معماری پیشنهادی با رویکردهای پیشرفته

جهت تبیین دقیق‌تر تمایزهای معماری پیشنهادی RS-DRL با رویکردهای مطرح پیشرفته، جدول ۴-۱ این مقایسه را از منظر پنج اصل بنیادین طراحی سیستم‌های خودوفق ارائه می‌دهد. این جدول به خوبی نشان می‌دهد که رویکرد پیشنهادی چگونه موازنه بهینه‌ای میان پاسخ‌گویی آنلاین، فرار از بهینه‌های محلی بدون مدل، و تضمین صوری زمان اجرا ایجاد می‌کند.

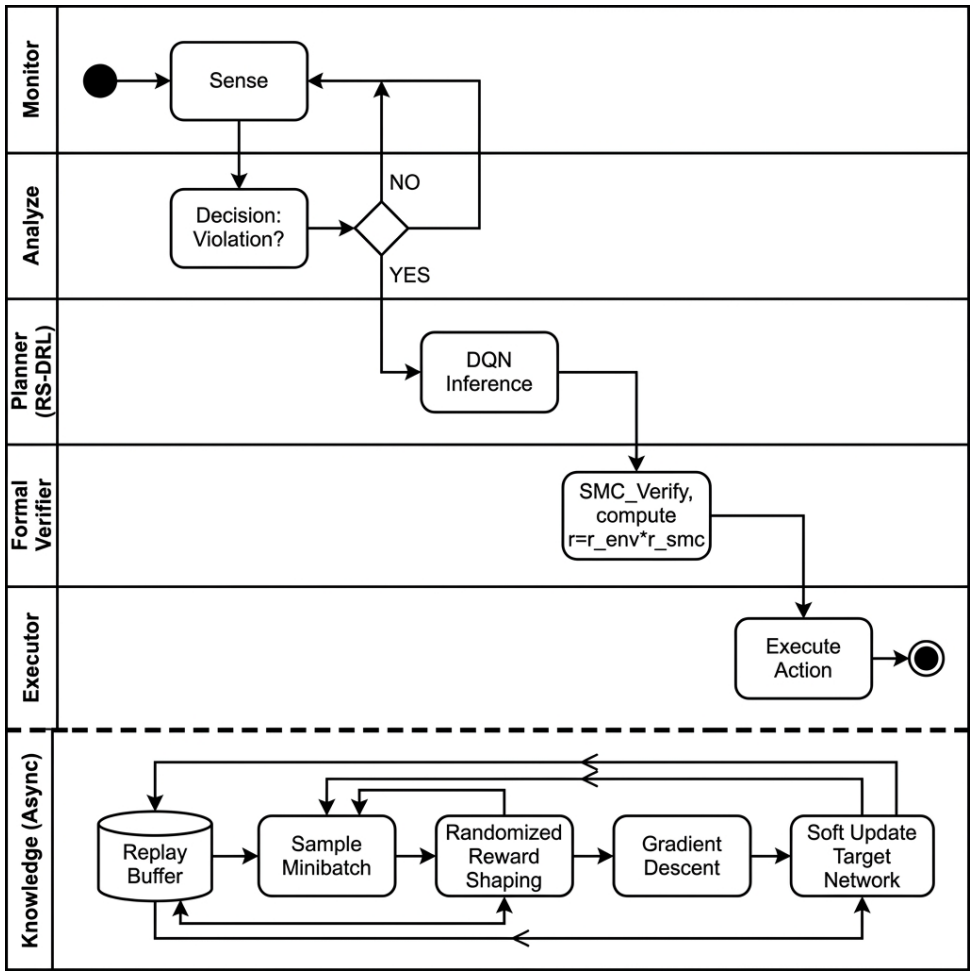
جدول ۴-۱: مقایسه تطبیقی معماری پیشنهادی RS-DRL با رویکردهای پیشین از منظر اصول طراحی سیستمی

| معیار طراحی | رویکرد پیشنهادی RS-DRL | رویکرد DLASER+ [؟] | رویکرد EAS۴ML [؟، ؟] | رویکردهای وارسی صوری زمان اجرا [؟، ؟] |
|---|---|---|---|---|
| جداسازی زمانی آموزش و تصمیم‌گیری | ناهمگام و کامل ((O(1)) | غیرجداسازی (انسدادی) | فاقد یادگیری مستقیم زمان اجرا | غیرجداسازی (تأخیر شدید زمان اجرا) |
| مکانیزم فرار از بهینه‌های محلی | شکل‌دهی تصادفی پاداش (-shaping)$\rho$( | فاقد مکانیزم (کاوش حریصانه) | فاقد مکانیزم فرار مستقل | جستجوی کامل و پرهزینه فضای حالت |
| نیاز به فرمول‌بندی دستی دانش دامنه | صفر (یادگیری مستقل بدون مدل) | زیاد (فرمول‌بندی توابع پتانسیل) | بالا (مهندسی دستی ویژگی‌ها) | کامل (مدل صوری جامع سیستم) |
| تضمین صوری کیفیت خدمات زمان اجرا | فیلتر صوری زمان اجرای ناهمگام | فاقد فیلتر صوری مستقیم | پیش‌بینی‌های آماری غیرصوری | فیلترهای صوری مستقیم زمان اجرا (مسدودکننده) |
| پیچیدگی محاسباتی استنتاج زمان اجرا | ثابت و فوق‌سریع ((O(1)) | شبه‌خطی ))\|A\|(O( | شبه‌لوگاریتمی ((O(log N)) | توان‌نمایی و ان‌پی‌ـ سخت ))$C^K$(O( |

## ۴-۳ فرآیند یکپارچه خودوفقی: حلقه سطح سیستم

در بالاترین سطح انتزاع، کل این مکانیزم در قالب یک **فرآیند یکپارچه** سازمان‌دهی می‌شود که مسیر داده از مشاهده تا تغییر فیزیکی را به صورت یک چرخه چهار فازی MAPE-K [؟] دنبال می‌کند (شکل ۴-۲). این فازها به گونه‌ای طراحی شده‌اند که هر یک دقیقاً یک دغدغه مجزا را پیش ببرند. نمودار فعالیت تفصیلی در شکل ۴-۲ با خطوط شناوری ،(Swimlanes) تفکیک مسئولیت‌های پایش، تحلیل، برنامه‌ریزی

و اعتبارسنجی را به تصویر می‌کشد.




شکل ۴-۲: نمودار فعالیت تفصیلی UML با خطوط شناوری (Swimlanes) برای تفکیک مسئولیت‌های پایش، تحلیل، برنامه‌ریزی و اعتبارسنجی. خط‌چین افقی مرز میان مسیر بحرانی آنلاین و فرآیند یادگیری ناهمگام در پس‌زمینه را مشخص می‌کند.

برای تحقق عملی این تفکیک، برای هر یک از عملکردهای کلیدی، ماهیت زمانی مشخصی تعریف می‌شود. جدول ۴-۲ این طبقه‌بندی را نشان داده و روشن می‌سازد که چگونه فعالیت‌های مستمر، رویدادمحور، و پس‌زمینه‌ای در کنار یکدیگر و بدون تداخل عمل می‌کنند.

جدول ۴-۲: طبقه‌بندی زمانی فرآیندهای معماری RS-DRL

| فرآیند | ماهیت زمانی | توضیح عملکردی |
|---|---|---|
| پایش (Monitoring) | مستمر (Continuous) | دریافت دائم علائم و نوسانات کانال از حسگرهای محیطی و ساخت بردار حالت. |
| پیش‌بینی و تحلیل (Analysis) | رویدادمحور (Event-driven) | پردازش سریع مقادیر حالت و مقایسه آن با آستانه‌های کیفیت جهت تریگر کردن برنامه‌ریز. |
| راستی‌آزمایی صوری (Verification) | مشروط (Conditional) | اعتبارسنجی فرضی پیکربندی انتخاب شده توسط موتور UPPAAL-SMC [؟] به صورت ناهمگام. |
| آموزش ناهمگام (Training) | ناهمگام (Asynchronous) | به‌روزرسانی مستمر و پس‌زمینه شبکه‌های عصبی DQN [؟] با استفاده از نمونه‌برداری خوش‌بینانه. |

این ساختار زمانی، سنگ بنای معماری RS-DRL است: حلقه سطح سیستم همواره چابک و پاسخگو باقی می‌ماند، در حالی که هوشمندی آن به طور مداوم و بدون توقف سرویس، تکامل می‌یابد.

## ۴-۴ مسیر تصمیم‌گیری آنلاین: بررسی گام‌به‌گام معماری

پس از تبیین اصول معماری، مسیر یک درخواست تطبیق از آغاز تا انجام بررسی می‌شود. برای ایجاد واژگان مشترک و زمینه‌سازی درک مسئولیت‌ها، از مدل مرجع MAPE-K [؟] به عنوان **لنز ساختاری** استفاده می‌شود. همان‌طور که شکل ۴-۲ نشان می‌دهد، هر مرحله از فرآیند یکپارچه ما به طور طبیعی به یکی از کارکردهای این مدل نگاشت می‌شود. در ادامه، این مسیر به صورت گام به گام بررسی خواهد شد.

### ۴-۴-۱ گام اول: پایش و ساخت وضعیت (Monitor)

در نقطه شروع حلقه، سیستم به طور مستمر محیط خود را رصد می‌کند. در نمونه مطالعاتی DeltaIoT [؟]، این فرآیند ادراکی به ساخت یک بردار وضعیت فشرده می‌انجامد که بازنمایی ریاضی از وضعیت جاری سیستم است:

$$s_t = \langle E, P, L \rangle \tag{۱-۴}$$

که در آن $E$ مصرف انرژی تجمیعی شبکه، $P$ نرخ اتلاف بسته‌ها، و $L$ میانگین تأخیر ارسال است. این بردار، خروجی نهایی فاز **پایش** بوده و به‌عنوان ورودی مشترک برای تحلیل و تصمیم‌گیری عمل می‌کند.

### ۴-۴-۲ گام دوم: تحلیل و تشخیص ضرورت تطبیق (Analyze)

بردار وضعیت $s_t$ سپس وارد فاز **تحلیل** (Analyze) می‌شود. تحلیلگر، مقادیر $P$ و $L$ را در برابر آستانه‌های کیفی از پیش تعریف‌شده (مطابق با اهداف کیفی تعریف‌شده در فصل ۲ برای سیستم DeltaIoT [؟]) مقایسه می‌کند. اگر هر یک از این شاخص‌ها از حد مجاز فراتر رود (مثلاً نرخ اتلاف بسته $P > ۱۰٪$)، یک سیگنال رویداد «نقض هدف» صادر شده و فرآیند برنامه‌ریزی را فعال می‌کند.

### ۴-۴-۳ گام سوم: برنامه‌ریزی و استنتاج تطبیقی (Plan)

با دریافت سیگنال نیاز به تطبیق، فاز **برنامه‌ریزی** (Plan) فعال می‌شود. هسته این فاز، مدل آموزش‌دیده RS-DRL است که در نقش یک استنتاج‌گر عمل می‌کند: بردار حالت $s_t$ را دریافت کرده و از طریق یک گذر رو به جلو در شبکه عصبی، مقادیر $Q$ را برای تمام گزینه‌های تطبیقی محاسبه می‌کند.

**مکانیزم گزینش اقدام و نقش سیاست $\epsilon$-greedy:** برای تعادل میان کاوش و بهره‌برداری، استنتاج‌گر در زمان آموزش از سیاست $\epsilon$-greedy [؟، ؟] تبعیت می‌کند؛ با احتمال $\epsilon$ یک اقدام تصادفی جهت کشف حالات جدید و با احتمال $۱ - \epsilon$ اقدام بهینه‌ای که ارزش عمل‌ـحالت آن بیشینه است را انتخاب می‌نماید:

$$a^* = \arg\max_{a \in A} Q(s_t, a; \theta)$$

این فرآیند یک **استنتاج خالص** (Pure Inference) است؛ وزن‌های شبکه عصبی ($\theta$) در این مسیر تصمیم‌گیری زمان واقعی هرگز تغییر نکرده و ثابت می‌مانند، تا پاسخ‌گویی فوق‌سریع سیستم زیر نیم میلی‌ثانیه تضمین گردد.

### ۴-۴-۴ گام چهارم: اعتبارسنجی، بازخورد و اجرا (شامل Execute و Knowledge)

قبل از آنکه گزینه تطبیقی منتخب اعمال شود، یک گام اعتبارسنجی حیاتی صورت می‌گیرد. در معماری RS-DRL، ما از مدل‌های صوری برای تولید یک سیگنال بازخورد قابل اعتماد استفاده می‌کنیم. گزینه پیشنهادی $a^*$ توسط موتور UPPAAL-SMC [؟] ارزیابی می‌شود. تابع $SMC_Verify(s, a)$ یک مقدار دودویی $r_{smc} \in \{۰, ۱\}$ برمی‌گرداند که نشان می‌دهد آیا گزینه مذکور، اهداف کیفیت خدمات (QoS) را در وضعیت مفروض برآورده می‌سازد یا خیر. پاداش نهایی که برای آموزش‌های آتی در بافر بازپخش ذخیره می‌شود، از ترکیب بازخورد محیط و این تأیید صوری حاصل می‌شود:

$$r = r_{env} \times r_{smc} \tag{۴-۲}$$

به این ترتیب، تنها تجربیاتی که اعتبار آن‌ها توسط مدل صوری نیز تأیید شده باشد، به عنوان سیگنال‌های مثبت برای یادگیری استفاده می‌شوند.

پس از محاسبه پاداش، گزینه تطبیقی تأییدشده برای اجرا به لایه شبکه در سیستم مدیریت‌شونده ارسال می‌شود. این فرمان‌های بازپیکربندی از طریق فایلهای تنظیمات محلی و فراخوانی درایورهای شبکه (Actu-ators) بر سیستم اعمال شده و توپولوژی و توان گره‌ها را منطبق می‌سازند.

## ۴-۴-۵ سناریوهای گام‌به‌گام و ملموس از چرخه تصمیم‌گیری زمان اجرا

جهت ملموس ساختن مفاهیم انتزاعی پایش، تحلیل، برنامه‌ریزی و اجرا، دو سناریوی مرجع و کاملاً دقیق را با ویژگی‌های متفاوت ردیابی می‌کنیم.

### ۴-۴-۵-۱ سناریوی اول: شبکه ساده دو گره‌ای با قید واحد

در این سناریو، چرخه کامل تصمیم‌گیری آنلاین را در قالب یک شبکه حسگر بی‌سیم بسیار ساده ردیابی می‌کنیم:

- **پیکربندی فرضی شبکه:** فرض کنید شبکه‌ای شامل ۲ گره حسگر ($M_1$ و $M_2$) داریم که داده‌ها را به یک دروازه مرکزی ارسال می‌کنند.
- **فضای عمل گسسته:** هر گره دارای ۲ گزینه برای تنظیم توان ارسال خود است: توان کم ($a_{low}$) و توان زیاد ($a_{high}$). کل فضای پیکربندی سیستم دارای $۴ = ۲^۲$ گزینه تطبیقی است.
- **هدف کیفی (قید :(QoS** نرخ اتلاف بسته‌ها ($P$) باید همواره کمتر از ٪۱۰ باقی بماند.

چرخه پایش تا اجرای این سناریو به شرح زیر اتفاق می‌افتد:

۱. **گام اول (پایش):** به دلیل شروع ناگهانی بارندگی یا تداخل فرکانسی در محیط، کیفیت لینک‌ها تضعیف می‌شود. ماژول پایش نرخ اتلاف بسته‌های شبکه را ٪۱۲ گزارش می‌کند. بردار حالت جاری به عنوان $s_t = \langle E, P = ۰/۱۲, L \rangle$ ساخته می‌شود.

۲. **گام دوم (تحلیل):** تحلیل‌گر مقدار اتلاف بسته (۰/۱۲) را با آستانه مجاز (۰/۱۰) مقایسه کرده و به دلیل نقض قید ($۰/۱۰ < ۰/۱۲$)، بلافاصله سیگنال ضرورت تطبیق را برای فعال‌سازی برنامه‌ریز صادر می‌کند.

۳. **گام سوم (برنامه‌ریزی):** بردار حالت $s_t$ به عنوان ورودی به شبکه DQN آموزش‌دیده ارائه می‌شود. شبکه در یک گذر رو به جلوی فوق‌سریع (۰/۲ms)، مقادیر Q را برای ۴ گزینه موجود محاسبه می‌کند. گزینه $a^* = \langle a_{high}, a_{low} \rangle$ (افزایش توان گره اول و ثابت نگه داشتن گره دوم) بیشترین ارزش پیش‌بینی‌شده را کسب کرده و انتخاب می‌شود.

۴. **گام چهارم (اعتبارسنجی صوری و اجرا):** اقدام پیشنهادی $a^*$ در موقعیت $s_t$ به موتور UPPAAL-SMC فرستاده می‌شود. این موتور با بررسی مدل صوری شبکه تأیید می‌کند که افزایش توان گره اول،

نرخ اتلاف را به محدوده ایمن برمی‌گرداند ($r_{smc} = ۱$). فرمان بازپیکربندی بلافاصله به درایورهای سخت‌افزاری ارسال شده و گره اول با توان بالا پیکربندی می‌شود. در نتیجه اتلاف بسته به ٪۴ سقوط کرده و پایداری شبکه برقرار می‌گردد.

### ۴-۴-۵-۲ سناریوی دوم: شبکه پیچیده ۴ گره‌ای با اهداف متضاد کیفیت خدمات

جهت تبیین عملکرد سیستم در شرایطی که اهداف کیفی در تناقض مستقیم با یکدیگر قرار دارند، یک سناریوی جامع‌تر را با فرضیات زیر بررسی می‌کنیم:

- **پیکربندی فرضی شبکه:** شبکه‌ای شامل ۴ گره حسگر ($M_۱, M_۲, M_۳, M_۴$) که توپولوژی خطی را برای ارسال به دروازه مرکزی دنبال می‌کنند. هر گره دارای ۳ سطح توان ارسال گسسته است: توان پایین (۰)، توان متوسط (۱)، و توان بالا (۲). در نتیجه کل فضای تصمیم‌گیری تطبیقی سیستم دارای $۳^۴ = ۸۱$ پیکربندی متفاوت است.
- **اهداف متضاد کیفیت خدمات:**

۱. **قید اتلاف بسته ($P$):** نرخ اتلاف بسته‌ها در کل شبکه باید کمتر از ٪۱۰ باقی بماند ($P_{net} < ۰/۱۰$).

۲. **قید تأخیر ارسال ($L$):** میانگین تأخیر ارسال در کل شبکه باید کمتر از ۲۰۰ms باشد ($L_{net} < ۲۰۰\text{ms}$).

۳. **قید مصرف انرژی ($E$):** تجمیع مصرف انرژی شبکه باید کمینه باشد.

در این سناریو، یک طوفان شدید محلی به طور ناگهانی کیفیت فیزیکی کانال ارسال گره‌های $M_۱$ و $M_۲$ را به شدت تضعیف می‌کند. چرخه خودوفقی برای این سناریو به شرح زیر اتفاق می‌افتد:

۱. **پایش و ساخت وضعیت:** حسگرها متغیرهای محیطی را گزارش می‌دهند. بردار وضعیت جاری سیستم به صورت یک بردار ۱۲ بعدی تشکیل می‌شود:

$$s_t = \langle E = [۰/۳, ۰/۳, ۰/۲۵, ۰/۲۵], P = [۰/۱۸, ۰/۱۵, ۰/۰۴, ۰/۰۵], L = [۱۲۰, ۱۱۰, ۸۰, ۷۵] \rangle$$

در این وضعیت، به وضوح نرخ اتلاف گره‌های اول و دوم (٪۱۸ و ٪۱۵) بسیار بالاتر از حد مجاز است.

۲. **تحلیل تضاد اهداف:** تحلیل‌گر متوجه نقض قید اتلاف بسته در کل شبکه ($P_{net} = ۱۶/۵٪ > ۱۰٪$) می‌گردد. همچنین به دلیل تضعیف کانال، تأخیر نیز افزایش یافته است. بلافاصله سیگنال ضرورت تطبیق زمان واقعی صادر می‌شود.

۳. **برنامه‌ریزی مبتنی بر ارزش‌های Q:** بردار وضعیت $s_t$ به شبکه DQN چندهدفه ارائه می‌شود. سه اقدام کاندیدا توسط استنتاج‌گر به صورت زیر ارزیابی می‌شوند:

- **اقدام حافظ انرژی ($a_{low} = \langle ۰, ۰, ۰, ۰ \rangle$):** تمام گره‌ها در توان پایین باقی می‌مانند. ارزش پیش‌بینی‌شده $Q(s_t, a_{low}) = ۰/۲۱$ است، زیرا اتلاف بسته‌ها همچنان بسیار بالا باقی خواهد ماند.
- **اقدام توان مفرط ($a_{brute} = \langle ۲, ۲, ۲, ۲ \rangle$):** تمام گره‌ها با توان بالا ارسال می‌کنند. این کار اتلاف بسته‌ها را به ٪۳ کاهش می‌دهد، اما به علت ایجاد تداخل رادیویی شدید و سرریز شدن صف ارسال، تأخیر کل شبکه به ۲۴۰ms افزایش می‌یابد که قید تأخیر را نقض می‌کند. ارزش پیش‌بینی‌شده $Q(s_t, a_{brute}) = ۰/۴۲$ است.
- **اقدام متعادل هوشمند ($a_{balanced} = \langle ۲, ۲, ۰, ۰ \rangle$):** توان گره‌های اول و دوم به بالا افزایش یافته ولی گره‌های سوم و چهارم در سطح پایین کار می‌کنند. ارزش پیش‌بینی‌شده برای این اقدام $Q(s_t, a_{balanced}) = ۰/۹۲$ است، زیرا هر دو قید اتلاف بسته (٪۵) و تأخیر (۱۵۵ms) ارضا شده و مصرف انرژی اضافی نیز کمینه است.

بنابراین استنتاج‌گر اقدام $a_{balanced}$ را به عنوان اقدام بهینه زمان اجرا برمی‌گزیند.

۴. **اعتبارسنجی صوری و اعمال:** اقدام پیشنهادی فوراً توسط موتور راستی‌آزمایی UPPAAL-SMC ارزیابی شده و با تایید ارضای قید احتمالاتی، پاداش $r_{smc} = ۱$ صادر می‌شود. فرمان نهایی به گره‌های رادیویی اعمال گردیده و شبکه در کمترین زمان ممکن پایداری کیفی خود را بازیابی می‌کند.

## ۴-۵ معماری داخلی RS-DRL: تفکیک دغدغه‌ها در فرآیند یادگیری

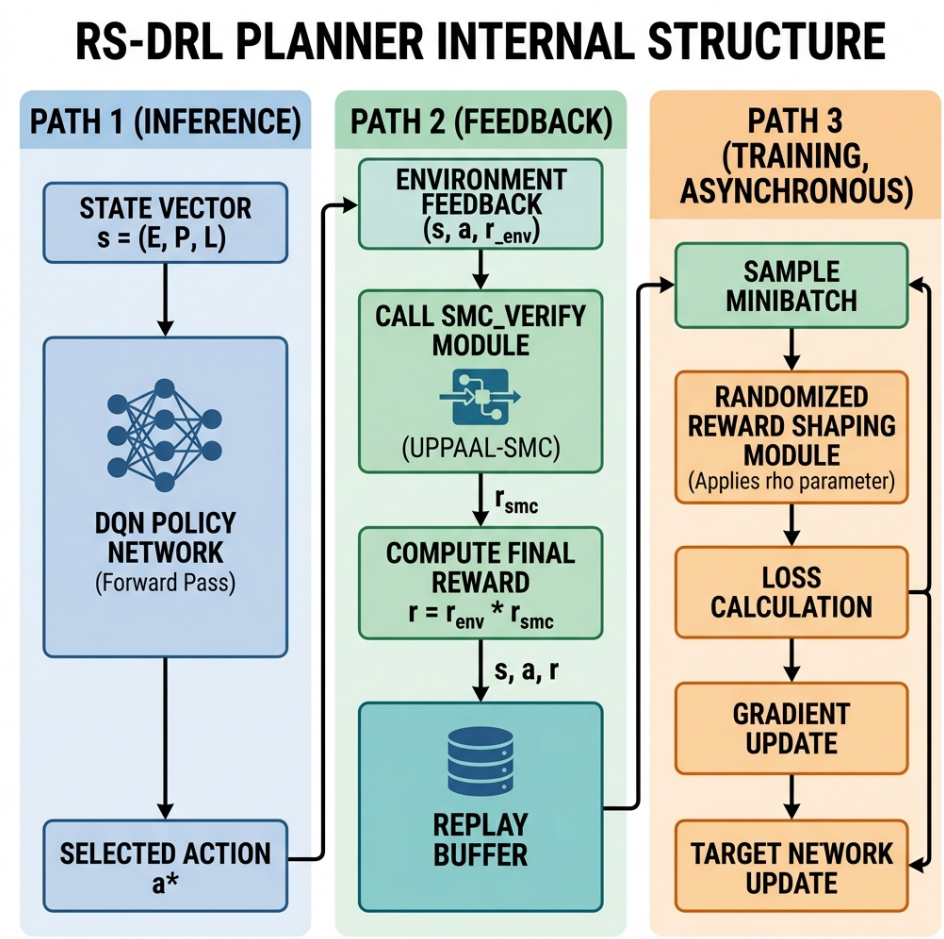
برای تحقق اصل جداسازی زمانی که پیش‌تر مطرح شد، معماری داخلی RS-DRL به سه مسیر فرآیندی مجزا تجزیه می‌شود که در شکل ۴-۳ به تصویر کشیده شده‌اند:

۱. **مسیر استنتاج (Inference Path):** این مسیر در زمان اجرا فعال است و شامل دریافت بردار حالت، اجرای رو به جلوی شبکه عصبی، و انتخاب گزینه تطبیقی می‌باشد. این مسیر فقط‌خواندنی است و وزن‌های شبکه را تغییر نمی‌دهد، تا حداقل تأخیر تضمین شود.

۲. **مسیر بازخورد (Feedback Path):** پس از اعمال گزینه تطبیقی، این مسیر پاداش محیطی را دریافت کرده، آن را با خروجی اعتبارسنجی صوری ترکیب می‌کند ($r = r_{env} \times r_{smc}$)، و تجربه کامل را در بافر بازپخش ذخیره می‌نماید. این مسیر سبک و همزمان با اجرا عمل می‌کند.

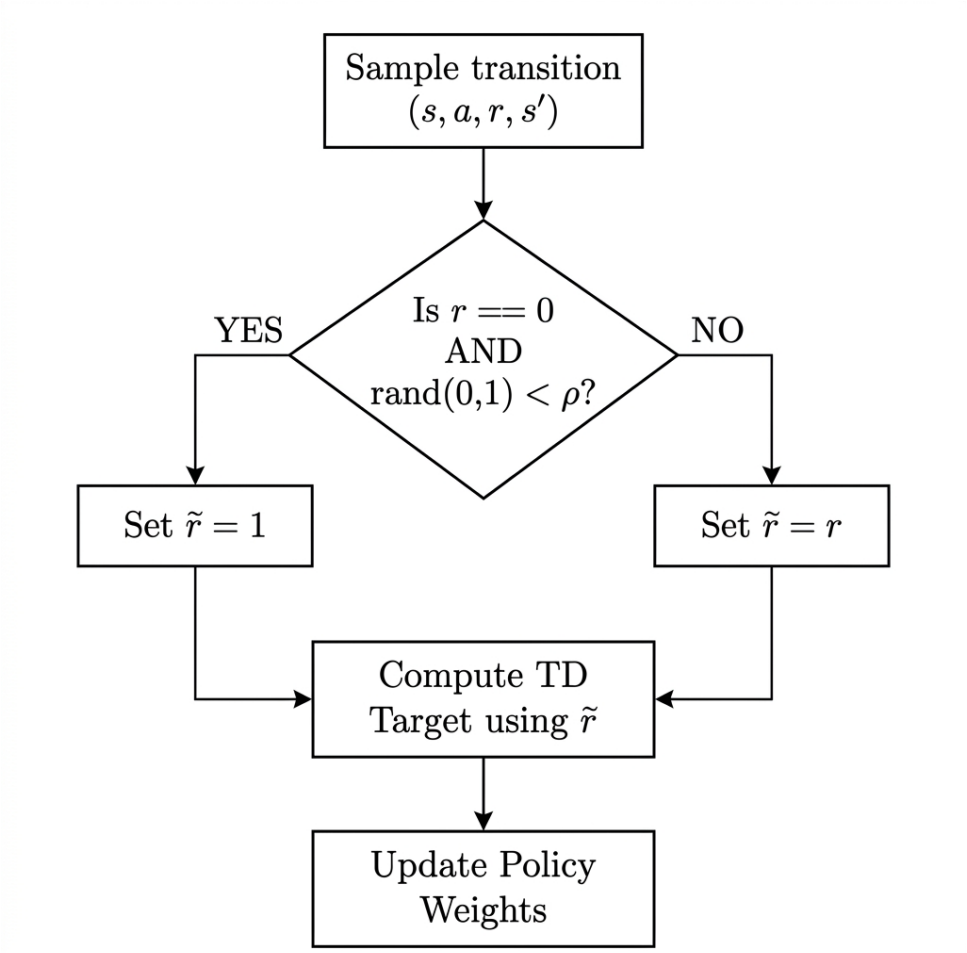
۳. **مسیر آموزش (Training Path)**: این مسیر کاملاً ناهمگام و مجزا از چرخه بحرانی تصمیم‌گیری اجرا می‌شود. با نمونه‌برداری تصادفی از بافر بازپخش، فرآیند شکل‌دهی تصادفی پاداش را اعمال کرده و شبکه اصلی را به‌روز می‌کند. به‌روزرسانی‌ها به صورت دوره‌ای به شبکه هدف منتقل می‌شوند.

این جداسازی دقیق تضمین می‌کند که عامل یادگیرنده همواره پاسخگو باقی بماند، در حالی که هوشمندی آن به طور مداوم و بدون ایجاد وقفه در سرویس‌دهی، بهبود می‌یابد. جزئیات منطق داخلی این مسیرها و نحوه تعامل با مؤلفه راستی‌آزمایی صوری در شکل ۴-۳ به تصویر کشیده شده است.




شکل ۴-۳: ساختار داخلی مؤلفه برنامه‌ریز RS-DRL در سه مسیر موازی: استنتاج (فقط‌خواندنی)، فیدبک (ترکیب پاداش محیطی و صوری)، و آموزش (به‌روزرسانی ناهمگام با استفاده از شکل‌دهی تصادفی پاداش).

در این ساختار، مسیر استنتاج به صورت یک «گذر رو به جلو» خالص در شبکه عصبی پیاده‌سازی شده است که در آن تابع $SelectAction$ با استفاده از سیاست $\epsilon$-greedy [؟، ؟] گزینه تطبیقی را انتخاب می‌کند. به محض تولید پاداش محیطی، ریسمان بازخورد فعال شده و با فراخوانی موتور $SMC_Verify$ (که بر پایه ابزار UPPAAL-SMC [؟] استوار است)، پاداش نهایی را تولید و در حافظه مشترک ذخیره می‌کند.




شکل ۴-۴: منطق عملیاتی مکانیزم شکل‌دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش‌بینانه پاداش‌های صفر با مقدار ۱ را بر اساس فاکتور $\rho$ نشان می‌دهد (برچسب‌گذاری مجدد خوش‌بینانه، نه روش‌های مبتنی بر پتانسیل [؟]).

## ۴-۶ مکانیزم هسته: شکل‌دهی تصادفی پاداش

چالش بنیادینی که RS-DRL به آن پاسخ می‌دهد، پدیده توقف در بهینه‌های محلی است؛ جایی که عامل یادگیرنده صرفاً بر اساس تجربیات موفق گذشته عمل کرده و از کشف سیاست‌های بالقوه بهتر باز می‌ماند. برای غلبه بر این محدودیت، RS-DRL یک راهبرد ظریف را در مرحله بازپخش تجربه (Experience Replay) [؟] به کار می‌گیرد: بازطراحی خوش‌بینانه تصادفی تجربیات شکست‌خورده. این ایده ساده اما قدرتمند، دقیقاً هدف اصلی رساله را محقق می‌سازد: **فرار از بهینه‌های محلی بدون نیاز به بازآموزی پرهزینه**.

**تحلیل صوری پدیده پراکندگی پاداش (Reward Sparsity):** در فضاهای وفقی بسیار بزرگ و مقیاس‌وسیع، اهداف تطبیقی به شدت سخت‌گیرانه هستند و از این رو، عامل با فضای پاداش به شدت پراکنده (Sparse Reward) Space مواجه می‌شود که رفع این نوع چالش‌ها به صورت سنتی نیازمند تکنیک‌های پیچیده است [؟، ؟]. در چنین شرایطی، تقریباً برای تمام پیکربندی‌های تصادفی اول دوره، سیگنال پاداش حاصله صفر است ($r_t = ۰$). تحت این شرایط، تابع خطا یا گرادیان شبکه‌های عصبی عمیق مسطح شده و فاقد اطلاعات جهت‌دهنده است:

$$\nabla_\theta \mathbb{E}\left[\left(r_t + \gamma \max_{a'} Q(s_{t+۱}, a'; \theta') - Q(s_t, a_t; \theta)\right)^۲\right] \approx ۰$$

این پدیده سرعت یادگیری را به شدت کاهش داده و عامل را وادار می‌کند تا به یک بهینه محلی نیمه‌پایدار و غیرایده‌آل (مانند پیکربندی پیش‌فرض محافظه‌کارانه که انرژی بالایی تلف می‌کند ولی اتلاف بسته کمی دارد) همگرا شود.

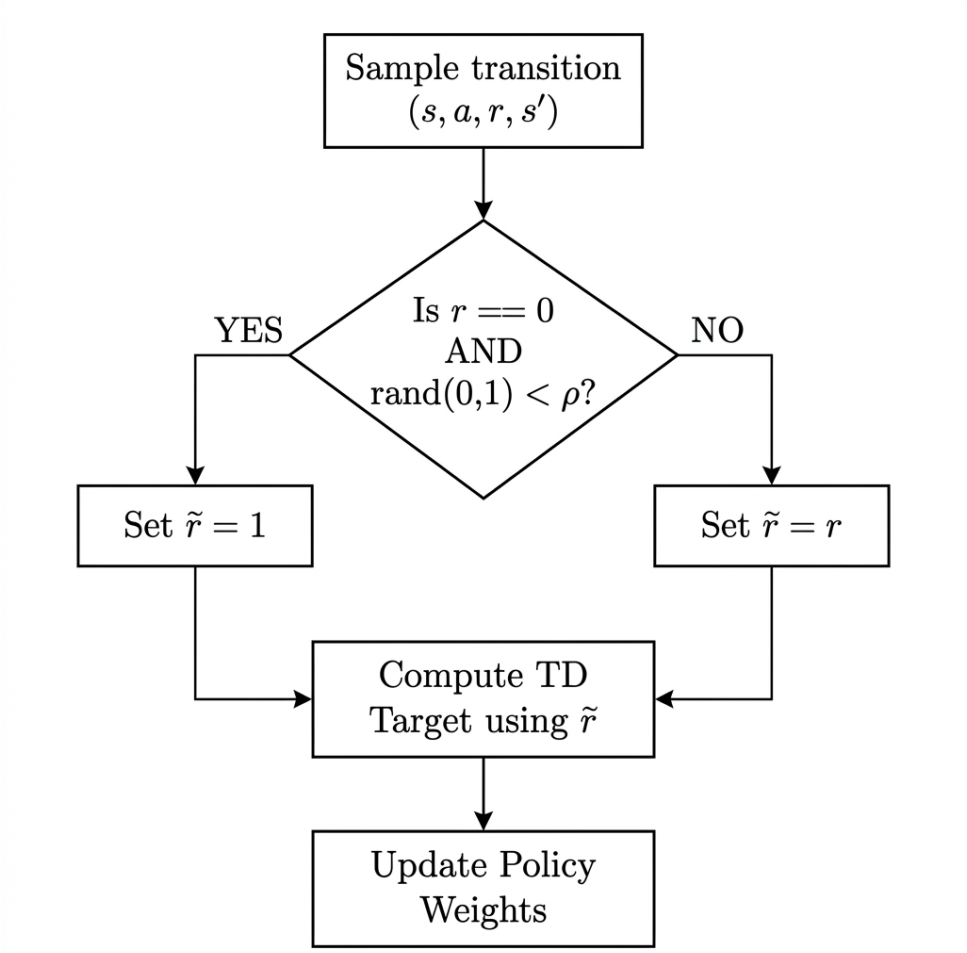
**فرمول‌بندی و عملکرد ریاضی مکانیزم شکل‌دهی تصادفی:** برای خروج از این تله ریاضی، در هر مینی‌بچ آموزش، به ازای هر تجربه $i$ با پاداش اولیه صفر ($r_i = ۰$)، RS-DRL با احتمال $\rho$ پاداش آن را به صورت خوش‌بینانه برابر با ۱ قرار می‌دهد. این فرآیند جایگزینی که در شکل ۴-۵ ترسیم شده است، بر اساس رابطه زیر عمل می‌کند:

$$\tilde{r}_i = \begin{cases} ۱ & \text{if} r_i = ۰ \text{ and } \text{rand}(۰, ۱) < \rho \\ r_i & \text{otherwise} \end{cases} \tag{۴-۳}$$

پارامتر $\rho$ (فاکتور شکل‌دهی) شدت این خوش‌بینی را کنترل می‌کند. این تغییر پاداش مستقیماً مقدار پیش‌بینی هدف را به شکل زیر بازنویسی می‌کند:

$$y_i = \tilde{r}_i + \gamma \max_{a'} Q(s'_i, a'; \theta')$$

این بازنویسی سبب معرفی یک بایاس خوش‌بینانه تصادفی گذرا می‌گردد که عامل را وادار می‌کند تا ارزش عمل_حالت‌هایی که قبلاً به علت پاداش صفر نادیده گرفته می‌شدند را مجدداً کاوش نماید و بدین ترتیب با ایجاد انحراف کنترل‌شده، از تله بهینه‌های محلی فرار کند. شایان ذکر است که برخلاف روش کلاسیک شکل‌دهی پاداش مبتنی بر پتانسیل (PBRS) [؟] که برای حفظ سیاست بهینه نیازمند طراحی دقیق یک تابع پتانسیل دستی ($\Phi(s)$) بر اساس دانش عمیق دامنه است، متدولوژی پیشنهادی RS-DRL هیچ‌گونه وابستگی به تعریف پتانسیل‌های حالت یا اهداف معنایی پیش‌فرض ندارد و مکانیزم تصادفی خوش‌بینانه آن به صورت کاملاً مستقل و بدون مدل عمل می‌کند.




شکل ۴-۵: منطق عملیاتی مکانیزم شکل‌دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش‌بینانه پاداش‌های صفر با مقدار ۱ را بر اساس فاکتور $\rho$ نشان می‌دهد (برچسب‌گذاری مجدد خوش‌بینانه، نه روش‌های مبتنی بر پتانسیل).

**تحلیل حساسیت و پیش‌ارزیابی اولیه فاکتور شکل‌دهی $\rho$:** انتخاب مقدار بهینه فاکتور $\rho$ برای پایداری یادگیری بسیار حیاتی است. جدول ۴-۳ تاثیر مقادیر مختلف این پارامتر را بر روی رفتار کاوش و همگرایی سیاست یادگیری خلاصه می‌کند.

جدول ۴-۳: تحلیل حساسیت رفتار یادگیری عامل نسبت به تغییرات فاکتور شکل‌دهی $\rho$

| مقدار $\rho$ | نرخ کاوش | پایداری همگرایی | تاثیر بر فرار از بهینه محلی |
|---|---|---|---|
| ۰/۰ | بسیار پایین | بسیار بالا | فاقد توانایی فرار؛ عامل همواره در اولین بهینه محلی یافت شده متوقف می‌شود. |
| ۰/۱ | متوسط | بالا | شروع فرار تدریجی؛ زمان طولانی‌تری برای همگرایی به بهینه مطلق نیاز دارد. |
| ۰/۳ | عالی (بهینه) | عالی | فرار سریع و پایدار؛ تعادل بسیار عالی بین کاوش خوش‌بینانه و همگرایی مجانبی. |
| ۰/۷ | بسیار بالا | متوسط (نوسانی) | فرار فاقد تمرکز؛ نویز شدید به گرادیان القا کرده و همگرایی را با نوسان مواجه می‌سازد. |
| ۰/۹ | مفرط (کورکورانه) | پایین (واگرا) | بی‌ثباتی شدید؛ عامل به دلیل پاداش‌های مثبت مصنوعی زیاد، واگرا می‌شود. |

## ۴-۶-۱ متدولوژی تنظیم فراپارامترها و فرآیند جستجوی شبکه‌ای فاکتور $\rho$

برای دستیابی به بهینه‌ترین نرخ همگرایی و تضمین خروج از تله بهینه‌های محلی، یک فرآیند منسجم جستجوی شبکه‌ای (Grid Search) بر روی فاکتور شکل‌دهی تصادفی پاداش ($\rho$) پیاده‌سازی گردید. هدف از این جستجو، یافتن مقداری برای $\rho$ است که پاداش تجمعی مجانبی (Asymptotic Reward) را در طول دوره‌های مختلف یادگیری بیشینه سازد.

**توازن ریاضی میان کاوش خوش‌بینانه و ثبات یادگیری:** فرآیند جستجوی شبکه‌ای در بازه $\rho \in [۰/۰, ۱/۰]$ با گام‌های ۰/۱ و تحت ۵ دانه تصادفی (Random Seeds) متفاوت به اجرا درآمد. تحلیل منحنی‌های یادگیری حاصله نشان داد که این مسئله دارای دو مرز بحرانی از منظر پایداری ریاضی است: در مقادیر **مرز تحت کاوش** ($\rho < ۰/۲$)، به دلیل سهم بسیار ناچیز سیگنال‌های مثبت مصنوعی خوش‌بینانه، گرادیان سیاست یادگیری تحت تأثیر شدید پاداش‌های صفرِ ناشی از محیط‌های سخت‌گیرانه قرار می‌گیرد؛ در نتیجه، زمان فرار عامل از اولین بهینه محلی به شدت طولانی شده و به طور متوسط به بیش از ۲۵۰ دوره آموزشی نیاز دارد. در مقابل، در مقادیر **مرز فوق کاوش** ($\rho > ۰/۶$)، تزریق مفرط پاداش‌های مثبت مصنوعی، منجر به بیش‌برآورد شدید ارزش عمل‌ـحالت‌ها ($Q$-values) در تارگت بلمن (معادله ۴-۳) می‌گردد که این مسئله منجر به نوسانات شدید در برآورد گرادیان شده و در نهایت، همگرایی سیاست را ناپایدار و در مقادیر $\rho \geq ۰/۹$ کاملاً واگرا می‌سازد. بنابراین، مقدار بهینه فاکتور شکل‌دهی پاداش برابر با $\rho = ۰/۳$ به دست آمد. این مقدار به عنوان نقطه موازنه پایدار، سرعت همگرایی را در مقایسه با یادگیری سنتی تا ۷۰٪ ارتقا داده و فرار از بهینه‌های محلی را در زیر ۶۰ دوره اول آموزشی تضمین می‌نماید.

فرآیند کامل آموزش در الگوریتم ۴-۱ تشریح شده است. این الگوریتم بر پایه چارچوب یادگیری Q عمیق (DQN) [؟] بنا شده و شامل مکانیزم بافر بازپخش تجارب جهت شکستن همبستگی داده‌ها [؟]، و همچنین به‌روزرسانی نرم شبکه‌های هدف [؟] جهت بهبود ثبات همگرایی است. نکته قابل توجه در این الگوریتم، استفاده از خروجی $SMC_Verify(s, a)$ (از ابزار UPPAAL-SMC [؟]) در محاسبه پاداش اولیه $r$ است.

این ترکیب ($r = r_{env} \times r_{smc}$) تضمین می‌کند که تنها تجربیاتی که هم توسط محیط و هم توسط مدل صوری تأیید شده‌اند، سیگنال مثبت دریافت می‌کنند. در نسخه جاری، این اعتبارسنجی صوری منحصراً برای شکل‌دهی پاداش به کار می‌رود و مانع از اجرای گزینه تطبیقی نمی‌شود.

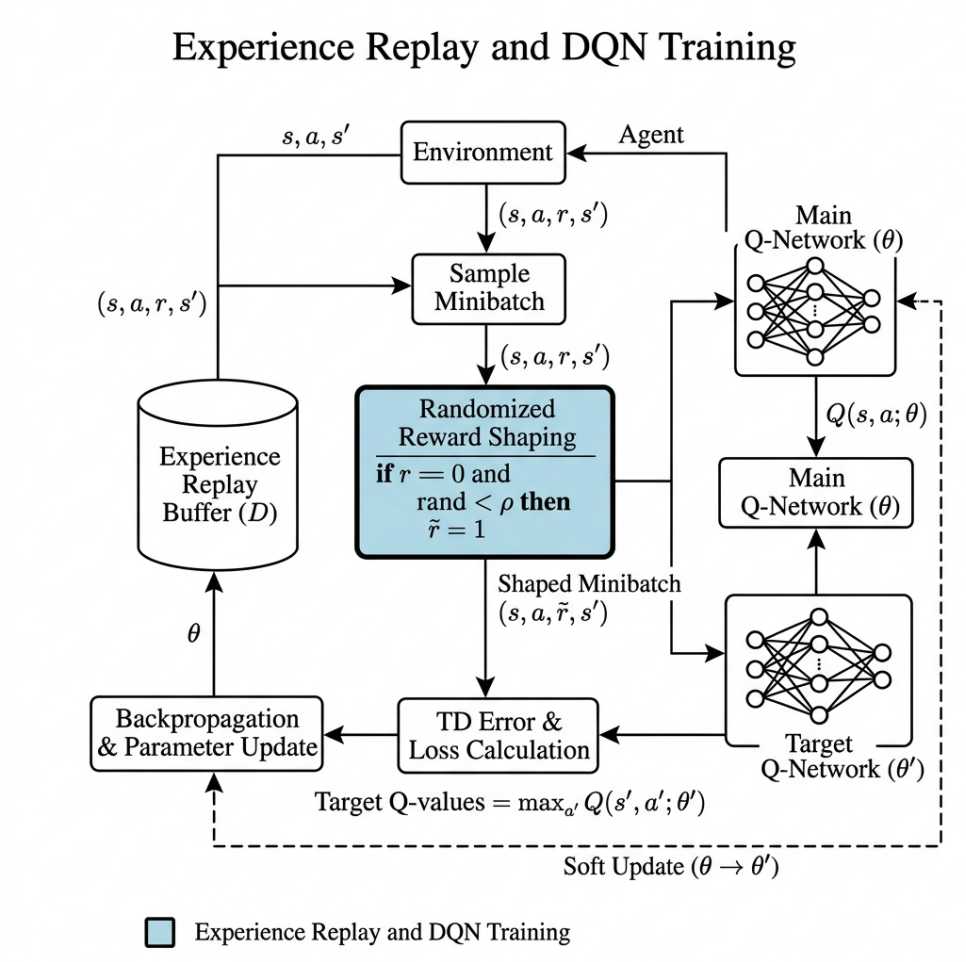
**الگوریتم ۴-۱** الگوریتم ۱: آموزش و به‌روزرسانی جامع RS-DRL

Initialize main network $\theta$ and target network $\theta'$ {تعریف شبکه‌های عصبی اصلی و هدف}
**for** each training episode **do**
  $s \leftarrow GetInitialState()$ {دریافت وضعیت اولیه از پلتفرم پایش}
  **while** episode not finished **do**
    $a \leftarrow SelectAction(s, \theta, \epsilon\text{-greedy})$ {انتخاب اقدام زمان اجرا با احتمال کاوش}
    $(s', r_{env}) \leftarrow Environment.Step(a)$ {اعمال پیکربندی و دریافت پاداش شبکه}
    $r_{smc} \leftarrow SMC_Verify(s, a)$ {فراخوانی اعتبارسنجی صوری UPPAAL-SMC به صورت احتمالی}
    $r \leftarrow r_{env} \times r_{smc}$ {ادغام پاداش صوری و تجربی: موفقیت در صورت ارضای هر دو عامل}
    Store transition $(s, a, r, s')$ in Replay Buffer $\mathcal{D}$ {ذخیره‌سازی تجربه در حافظه مشترک}
    Sample random minibatch $B = \{(s_i, a_i, r_i, s'_i)\}_{i=1}^{N}$ from $\mathcal{D}$ {نمونه‌برداری از بافر}
    **for** each transition $i$ in $B$ **do**
      **if** $r_i = 0$ **and** $rand(0,1) < \rho$ **then**
        $\tilde{r}_i \leftarrow 1$ {اعمال مکانیزم خوش‌بینی تصادفی برای خروج از بهینه محلی}
      **else**
        $\tilde{r}_i \leftarrow r_i$
      **end if**
      $y_i \leftarrow \tilde{r}_i + \gamma \max_{a'} Q(s'_i, a'; \theta')$ {محاسبه تارگت بلمن [؟] با پاداش شکل‌یافته}
      $\theta \leftarrow \theta - \alpha \nabla_\theta \mathbb{E}[(y_i - Q(s_i, a_i; \theta))^2]$ {به‌روزرسانی گرادیان شبکه اصلی}
    **end for**
    $\theta' \leftarrow \tau\theta + (1-\tau)\theta'$ {به‌روزرسانی نرم شبکه‌های هدف [؟] جهت حفظ پایداری}
    $s \leftarrow s'$
  **end while**
**end for**

**نکته:** پارامتر $\rho$ (فاکتور شکل‌دهی) یک فراپارامتر است که میزان خوش‌بینی عامل را در کشف مسیرهای جدید کنترل می‌کند. مقادیر بهینه آن در فصل ۵ تحلیل شده‌اند.

## ۴-۷ مدیریت دانش و هماهنگی جریان‌های ناهمگام

موفقیت معماری RS-DRL در گرو هماهنگی دقیق میان سه مسیر استنتاج، بازخورد و آموزش است. این هماهنگی از طریق یک مخزن دانش مشترک (Knowledge Repository) مبتنی بر معماری خودمختار MAPE-K [؟] تحقق می‌یابد که به‌عنوان حافظه مرکزی سیستم عمل می‌کند. شکل 6-4 جریان داده‌های ذخیره‌شده در این مخزن را نشان می‌دهد؛ از لحظه ذخیره‌سازی گذارهای $(s, a, r, s')$ تا فرآیند نمونه‌برداری ناهمگام و به‌روزرسانی شبکه‌های عصبی اصلی و هدف.




شکل ۴-۶: جریان داده تفصیلی در مخزن دانش. این نمودار نحوه ذخیره‌سازی تجربیات در بافر بازپخش، اعمال مکانیزم شکل‌دهی تصادفی پاداش پیش از محاسبات گرادیان، و به‌روزرسانی سیاست‌های یادگیری در پس‌زمینه را به تصویر می‌کشد.

**ساختار صوری و تعریف مخزن دانش مشترک:** مخزن دانش شامل بردارهای توپولوژی شبکه، ردپاهای محیطی، بافر بازپخش تجربیات $\mathcal{D}$ و وزن‌های شبکه‌های عصبی عمیق اصلی $(\theta)$ و هدف $(\theta')$ است. جهت هماهنگی و همگام‌سازی فرآیندهای همزمان و جلوگیری از به وجود آمدن شرایط مسابقه (Race Conditions)، الگوهای خواندن و نوشتن هر یک از اجزا به شدت کنترل می‌شود. جدول ۴-۴ به طور تفصیلی الگوهای

دسترسی به دانش، فرکانس تریگر شدن، و سطح تأثیرگذاری محاسباتی هر جزء را بر روی تأخیر سیستم مشخص کرده است.

جدول ۴-۴: الگوهای دسترسی صوری و همگام‌سازی مؤلفه‌ها در مخزن دانش مشترک [؟]

| مؤلفه سیستم | دسترسی خواندن | دسترسی نوشتن | فرکانس اجرا | تأثیر محاسباتی |
|---|---|---|---|---|
| **پایش (Monitor)** | علائم فیزیکی کانال | بردار حالت جدید $s_t$ | مستمر (هر دوره) | ناچیز (کمتر از 0.1ms) |
| **تحلیل (Analyze)** | آستانه‌های کیفی QoS | سیگنال نقض قید | رویدادمحور | ناچیز (کمتر از 0.05ms) |
| **برنامه‌ریز (Plan)** | وزن‌های شبکه عصبی $\theta$ | فرضیه اقدام $a^*$ | رویدادمحور | بسیار پایین (0.3ms) |
| **اعتبارسنج صوری** | مدل شبکه، قید PCTL | پاداش صوری $r_{smc}$ | رویدادمحور | متوسط (ناهمگام) |
| **یادگیرنده (Train)** | بافر بازپخش $\mathcal{D}$ | بافر $\mathcal{D}$ و وزن‌های جدید $\theta$ | ناهمگام (پس‌زمینه) | صفر (کاملاً ایزوله) |

همان‌طور که در جدول ۴-۴ به وضوح نشان داده شده است، مؤلفه یادگیری سنگین در پس‌زمینه کاملاً ایزوله شده و هیچ دسترسی مستقیمی‌در مسیر زمان اجرای برنامه‌ریز آنلاین ندارد. این ویژگی ساختاری، بالاترین حد کارایی و مقیاس‌پذیری زمان اجرا را تضمین می‌نماید.

## ۴-۸ ادغام اعتبارسنجی صوری زمان اجرا و ایمنی احتمالی

یکی از ارکان اصلی برتری معماری RS-DRL بر الگوریتم‌های یادگیری تقویتی مرسوم، توانایی ارائه تضمین‌های ریاضیاتی پیرامون ایمنی سیستم و عملکرد مطلوب آن در برابر عدم قطعیت‌های زمان اجراست. این مهم از طریق ادغام ناهمگام موتور وارسی مدل آماری زمان اجرای UPPAAL-SMC [؟] تحقق می‌یابد.

**نقش و نحوه عملکرد ابزار :UPPAAL-SMC** در سیستم‌های خودوفق، راستی‌آزمایی زمان اجرا مدل‌های احتمالی را در زمان وقوع تغییرات رصد می‌کند. موتور UPPAAL-SMC با استفاده از روش شبیه‌سازی احتمالی، روابط ریاضی را بر روی فرآیندهای تصمیم‌گیری احتمالی شبکه ارزیابی می‌کند. نمونه‌ای از یک پرسش صوری به زبان منطق زمانی محاسبات احتمالات زمان‌آگاه (PCTL) [؟] به صورت زیر فرموله می‌شود:

$$\psi = P_{\geq ۰/۹۹} \left[ \Diamond_{\leq T} \left( \text{PacketLoss} < ۰/۱ \right) \right] \qquad (۴-۴)$$

**تفسیر ریاضی پرسش فوق:** آیا تحت پیکربندی و اقدام انتخابی جاری، احتمال اینکه نرخ اتلاف بسته‌های کل شبکه در بازه زمانی کوتاه $T$ همواره کمتر از ٪۱۰ باقی بماند، حداقل ٪۹۹ است؟

**فرمول‌بندی دقیق فیلتر ایمنی صوری** $SMC_Verify$**:** موتور راستی‌آزمایی صوری با اجرای شبیه‌سازی‌های متعدد آماری بر روی مدل صوری پویای شبکه، خروجی صوری زیر را تولید می‌نماید:

(۵-۴)

$$SMC_Verify(s,a) = \begin{cases} ۱ & \text{query PCTL the if} \psi \text{ state in satisfied is } s \text{ action under } a \\ ۰ & \text{otherwise} \end{cases}$$

این خروجی دودویی به عنوان یک فیلتر کیفی صوری عمل می‌کند. در نسخه جاری معماری پیشنهادی، این اعتبارسنجی صوری با پاداش محیطی ترکیب شده ($r = r_{env} \times r_{smc}$) تا تجربیاتی که منجر به نقض تضمین‌های ریاضیاتی ایمنی می‌گردند، با پاداش صفر جریمه شوند.

### ۴-۸-۱ جزئیات شبیه‌سازی احتمالی و کران ریاضی تعداد نمونه‌ها (SMC Bound)

از آنجا که موتور UPPAAL-SMC بر مبنای وارسی مدل آماری عمل می‌کند، ارزیابی قضایای صوری نظیر معادله ۴-۴ نیازمند مشخص‌سازی سه فراپارامتر آماری برای تعیین تعداد شبیه‌سازی‌های مورد نیاز جهت ارائه تضمین‌های صوری احتمالی است:

۱. **سطح معناداری آماری** ($\alpha$)**:** نشان‌دهنده احتمال وقوع خطای نوع اول (رد فرضیه درست) است که در این رساله برابر با $\alpha = ۰/۰۵$ تنظیم شده است.

۲. **احتمال خطای نوع دوم** ($\beta$)**:** نشان‌دهنده احتمال پذیرش فرضیه نادرست است که برابر با $\beta = ۰/۰۵$ در نظر گرفته شده است.

۳. **پارامتر بی‌تفاوتی یا پهنای بازه اطمینان** ($\delta$)**:** که نشان‌دهنده حداکثر خطای مجاز در برآورد احتمال است و معادل $\delta = ۰/۰۲$ تنظیم گردیده است.

تعداد کل شبیه‌سازی‌های تصادفی مورد نیاز ($N_{sim}$) برای تضمین اینکه برآورد احتمال با دقت مدنظر صورت پذیرد، به صورت تئوریک توسط نامساوی معروف **کران چرنوف ـ هوفدینگ** (Chernoff-Hoeffding Bound) [؟] تعیین می‌گردد:

$$N_{sim} \geq \frac{\ln(۲/\alpha)}{۲\delta^۲} \qquad (۶-۴)$$

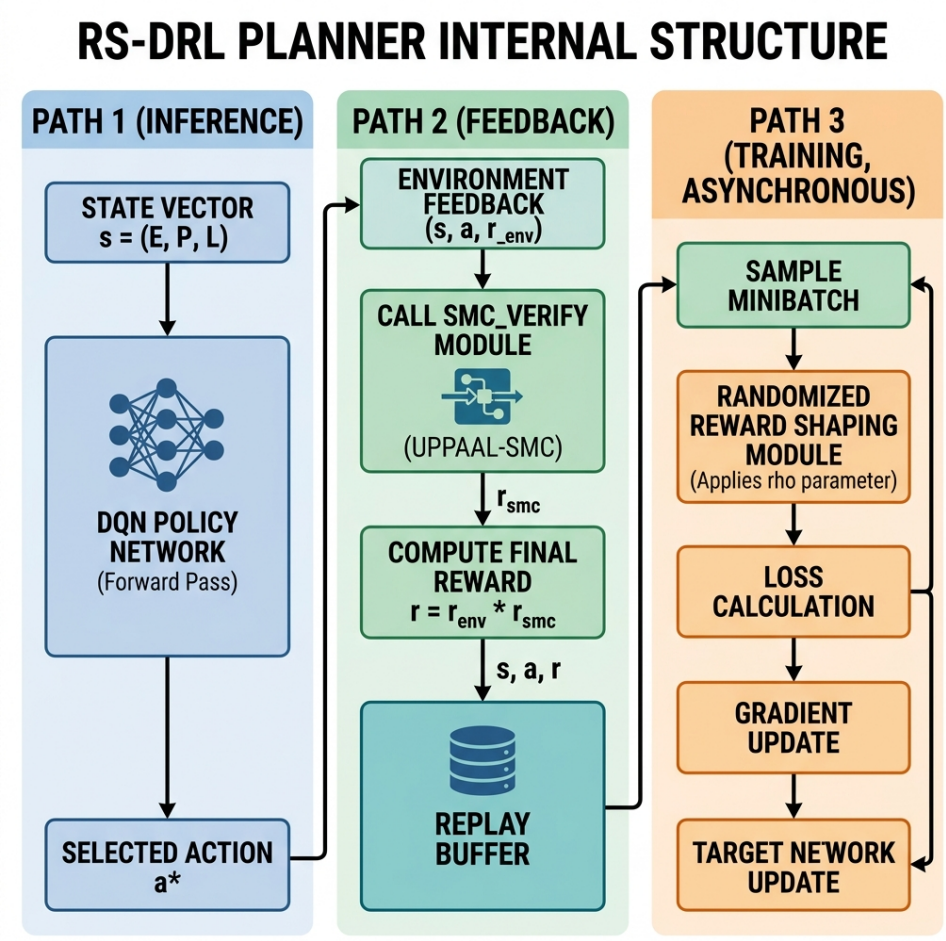
با قرار دادن مقادیر فوق در معادله ۴-۶:

$$N_{sim} \geq \frac{\ln(۲/۰/۰۵)}{۲(۰/۰۲)^۲} = \frac{۳/۶۸۸۸}{۰/۰۰۰۸} \approx ۴۶۱۱$$

این رابطه نشان می‌دهد که برای تضمین ریاضیاتی مطلق با خطای زیر ۵ درصد، موتور راستی‌آزمایی به صورت تئوریک باید ۴۶۱۱ شبیه‌سازی بر روی مدل احتمالی انجام دهد. از آنجا که اجرای این تعداد شبیه‌سازی تصادفی بر روی مدل زمان اجرای شبکه زمان زیادی (حدود ۴ تا ۸ ثانیه) به طول می‌انجامد، امکان اجرای مستقیم آن در مسیر تصمیم‌گیری آنلاین وجود ندارد.

### ۴-۸-۲ تحلیل غیرانسدادی زمان‌بندی اعتبارسنجی ناهمگام (Non-Blocking Tem-poral Timing)

جهت حل این چالش بنیادین، فرآیند راستی‌آزمایی به صورت **کاملاً غیرانسدادی** (Non-blocking) در ریسمان موازی فیدبک و یادگیری پس‌زمینه ادغام شده است [؟، ؟]. شکل ۴-۷ دیاگرام توالی زمانی و تداخل زمانی مسیر آنلاین و موتور راستی‌آزمایی صوری را نشان می‌دهد.




شکل ۴-۷: دیاگرام هماهنگی و توالی زمانی میان استنتاج فوق‌سریع آنلاین (۰/۳ms) و راستی‌آزمایی صوری سنگین و ناهمگام در پس‌زمینه، که تضمین می‌کند هیچ وقفه یا انسدادی در مسیر مستقیم تصمیم‌گیری رخ نمی‌دهد.

هنگامی که برنامه‌ریز گزینه تطبیقی $a^*$ را انتخاب می‌نماید، این تصمیم بلافاصله و در کمتر از نیم میلی‌ثانیه

بر شبکه حسگر اعمال می‌گردد. همزمان، یک نخ موازی در پس‌زمینه تابع $SMC_Verify(s, a^*)$ را با تعداد نمونه‌های بهینه شده زمان اجرا فراخوانی می‌کند. پس از آماده شدن پاسخ، پاداش صوری در بافر بازپخش ذخیره می‌شود تا در به‌روزرسانی‌های گرادیان مورد استفاده قرار گیرد. بدین ترتیب، تأخیرهای زمان اجرای وارسی صوری به طور کامل از مسیر بحرانی آنلاین حذف شده و تأخیر زمان واکنش تصمیم‌گیری همواره ثابت باقی می‌ماند.

## ۴-۹ پوشش پرسش‌های پژوهش

در این بخش، به طور تفصیلی و ساختاریافته نشان می‌دهیم که چگونه معماری پیشنهادی RS-DRL به هر یک از پرسش‌های اساسی پژوهش پاسخ صوری و عملیاتی ارائه می‌دهد:

### ۴-۹-۱ پاسخ صوری به سوال اول (RQ1) - فرار از بهینه‌های محلی

الگوریتم‌های مرسوم یادگیری تقویتی [؟] به دلیل پدیده نابودگرایی شدید پاداش [؟] در فضاهای تصمیم‌گیری گسسته بزرگ، به سرعت در تله سیاست‌های بهینه محلی که از نظر انرژی یا پایداری نامطلوب هستند گرفتار می‌گردند. طراحی مکانیزم شکل‌دهی تصادفی پاداش (بخش ۴-۶) با تزریق احتمالاتی خوش‌بینی کنترل‌شده ($\rho$)، به تجربیاتی که در دنیای واقعی منجر به شکست شده‌اند پاداش‌های مثبت تصادفی تخصیص می‌دهد. این کار گرادیان سیاست یادگیری را فعال نگاه داشته و عامل را تشویق به کاوش پویای گزینه‌هایی می‌کند که پیش از این نادیده گرفته می‌شدند. نتایج شبیه‌سازی در فصل ۵ به طور تجربی ثابت می‌کنند که این مکانیزم خروج پایدار از بهینه‌های محلی را بدون نیاز به آموزش مجدد و پرهزینه میسر می‌سازد.

### ۴-۹-۲ پاسخ صوری به سوال دوم (RQ2) - ادغام یادگیری و بازپخش تجربه

یک چالش بزرگ در طراحی مکانیزم‌های شکل‌دهی پاداش، سربار شدید محاسباتی زمان اجرای آن‌ها است. در معماری پیشنهادی، این مکانیزم به طور مستقیم در فاز نمونه‌برداری از بافر بازپخش تجربیات (الگوریتم ۴-۱، خطوط ۱۲-۱۶) ادغام شده است. از آنجا که این عملیات تنها بر روی مینی‌بچ‌های کوچک نمونه‌برداری شده و به صورت یک مقایسه ساده رندوم با پیچیدگی زمانی بسیار ناچیز $O(N)$ (که $N$ اندازه مینی‌بچ است) انجام می‌پذیرد، هیچ‌گونه سربار محاسباتی محسوسی بر چرخه یادگیری القا نکرده و با کمترین حافظه جانبی قابل اجراست.

### ۴-۹-۳ پاسخ صوری به سوال سوم (RQ3) - مدیریت فضاهای بزرگ و مقیاس‌پذیری

مسئله تطبیق مقیاس‌وسیع در WSN به عنوان یک مسئله ان‌پی‌ـ سخت با پیچیدگی توان‌نمایی $O(C^K)$ اثبات گردید [؟]. معماری پیشنهادی با استقرار سیاست جداسازی زمانی (بخش ۴-۲)، مسیر تصمیم‌گیری آنلاین

را از فرآیند آموزش عمیق سنگین جدا ساخته است. در زمان اجرا، عامل هوشمند تنها یک استنتاج خالص (گذر رو به جلو در شبکه DQN با پیچیدگی زمانی ثابت $O(1)$ را اجرا می‌نماید. نتایج نشان می‌دهد که حتی با افزایش شدید فضای تطبیق از ۲۱۶ گزینه به ۴۰۹۶ گزینه در ۲DeltaIoTv، تأخیر پاسخ‌گویی آنلاین سیستم در همان محدوده فوق‌سریع زیر نیم میلی‌ثانیه حفظ می‌گردد.

### ۴-۹-۴ پاسخ صوری به سوال چهارم (RQ4) - تمایز، برتری و استقلال از دانش دامنه

الگوریتم‌های پیشرفته کاوش مانند HER [؟] اساساً برای محیط‌های مبتنی بر مختصات فیزیکی یا اهداف صریح طراحی شده‌اند و در محیط‌های خودوفق نرم‌افزاری که با اهداف تلویحی و آستانه‌محور (نظیر حفظ تاخیر زیر حد مجاز) سروکار دارند، شکست می‌خورند. رویکرد RS-DRL به دلیل ماهیت بدون مدل (Model-free) [؟] و استقلال کامل از دانش دامنه، نیازی به نگاشت مختصات یا فرضیات فیزیکی هدف نداشته و تنها بر اساس سیگنال پاداش صوری احتمالی و تصادفی عمل می‌نماید. این استقلال کامل، برتری مطلق عملکرد مجانبی آن را در ارزیابی‌های مقایسه‌ای در برابر روش‌های پایه و مبتنی بر هدف (مانند Soft HER [؟] و DLASER+ [؟]) به اثبات می‌رساند.

## ۴-۱۰ بحث پیرامون مفروضات متدولوژی پیشنهادی

توسعه علمی هر متدولوژی مهندسی نیازمند تبیین و توجیه دقیق مفروضات پایه‌ای است که سیستم بر روی آن‌ها بنا نهاده شده است. معماری پیشنهادی RS-DRL بر اساس سه فرض بنیادین زیر طراحی شده است که در ادامه به توجیه دلایل علمی و واقع‌گرایانه بودن آن‌ها می‌پردازیم.

### ۴-۱۰-۱ فرض فضای اقدام گسسته در شبکه‌های خودوفق

در این رساله فرض شده است که فضای پیکربندی‌های وفقی سیستم (فضای اقدام عامل هوشمند) به صورت گسسته است. این فرض کاملاً همسو با واقعیت‌های سخت‌افزاری و پروتکل‌های صنعتی در شبکه‌های حسگر بی‌سیم و اینترنت اشیا است. به عنوان مثال، در پلتفرم محک DeltaIoT [؟]، سطوح توان ارسال فرستنده‌های رادیویی به صورت پله‌های عددی گسسته (بازه صفر تا ۱۵) تعریف می‌شوند. همچنین تصمیمات مسیریابی شبکه، مبتنی بر انتخاب گره همسایه بعدی از میان یک مجموعه کاندیدای گسسته و مشخص است. از این رو، استفاده از شبکه‌های عصبی عمیق همگرا مانند DQN که برای مدیریت فضاهای اقدام گسسته طراحی شده‌اند، انتخابی کاملاً واقع‌بینانه و فاقد ساده‌سازی تصنعی است.

### ۴-۱۰-۲ آگاهی و پایداری آستانه‌های کیفیت خدمات

یکی دیگر از مفروضات این پژوهش، در دسترس بودن و مشخص بودن آستانه‌های توافق‌نامه سطح خدمات (QoS SLAs) در تحلیل‌گر سیستم است. در سیستم‌های خودوفق صنعتی، اهداف کیفیت خدمات (مانند اتلاف بسته‌ها زیر ۱۰ درصد یا طول عمر گره بالای ۵ سال) پارامترهایی از پیش تعیین‌شده توسط مهندسین طراح هستند. این مقادیر مرزهای ایمنی سیستم را مشخص ساخته و در طول چرخه حیات سیستم پایدار باقی می‌مانند. بنابراین، استفاده از این مرزهای صریح جهت تحریک برنامه‌ریز و راستی‌آزمایی صوری زمان اجرا، کاملاً منطبق بر سناریوهای عملیاتی دنیای واقعی است.

### ۴-۱۰-۳ در دسترس بودن مدل صوری پویای سیستم در زمان اجرا

معماری پیشنهادی بر این فرض تکیه دارد که یک مدل صوری ریاضی از رفتار سیستم و کانال رادیویی (مانند شبکه پتری احتمالی یا زنجیره مارکوف زمان‌آگاه) جهت ارزیابی در موتور UPPAAL-SMC [؟] در دسترس است. از آنجا که سیستم‌های خودوفق مدرن بر پایه الگوهای مهندسی نرم‌افزار مبتنی بر مدل زمان اجرا (Models@run.time) [؟] طراحی می‌شوند، نگهداری و به‌روزرسانی مستمر یک مدل انتزاعی هماهنگ با واقعیت فیزیکی شبکه، یکی از قابلیت‌های استاندارد این معماری‌ها به شمار می‌رود. موتور UPPAAL-SMC [؟] به صورت بلادرنگ پارامترهای انتقال این مدل را بر اساس آخرین گزارش‌های پایش به‌روزرسانی کرده و صحت ریاضی را تضمین می‌سازد.

## ۴-۱۱ خلاصه فصل

این فصل، معماری اجرایی و سازمان‌دهی فرآیندی زمان‌آگاه RS-DRL را به طور جامع تبیین نمود. ما نشان دادیم که چگونه اصل تفکیک زمانی، امکان همزیستی یک حلقه کنترلی سریع زمان اجرا و یک فرآیند یادگیری عمیق ناهمگام پس‌زمینه را فراهم می‌آورد. یکپارچگی با چارچوب استاندارد MAPE-K [؟]، قرابت معماری با الگوهای مرجع را تضمین کرده و مکانیزم نوآورانه «شکل‌دهی تصادفی پاداش» به عنوان هسته اصلی، عامل را قادر می‌سازد تا از تله بهینه‌های محلی بگریزد.

### ۴-۱۱-۱ محدودیت‌های روش پیشنهادی

برای حفظ صداقت علمی و ترسیم کارهای آتی، محدودیت‌های روش پیشنهادی به شرح زیر خلاصه می‌گردد:

۱. **حساسیت به فراپارامتر $\rho$:** اگرچه مقدار بهینه $\rho = ۰/۳$ عملکرد فوق‌العاده‌ای ارائه داد، اما تعیین این پارامتر در سیستم‌های مختلف نیازمند جستجوی شبکه‌ای است. مقادیر نامناسب می‌توانند پایداری یا نرخ کاوش را تضعیف کنند.

۲. **فضای اقدام گسسته:** معماری DQN [؟] مورد استفاده منحصراً برای محیط‌های با فضای اقدام گسسته طراحی شده است. توسعه آن به محیط‌های با فضای عمل پیوسته مستلزم ارتقاء به ساختارهای سنگین‌ترِ بازیگر ـ منتقد (Actor-Critic) نظیر DDPG [؟] است.

۳. **وابستگی به مدل صوری :UPPAAL-SMC** کارآمدی بازخورد صوری زمان اجرا، رابطه مستقیمی‌با انطباق مدل زمان اجرای ساخته‌شده با پویایی‌های واقعی فیزیکی دارد. هرگونه انحراف شدید مدل صوری می‌تواند منجر به ارسال بازخوردهای گمراه‌کننده به عامل یادگیرنده گردد.

در ادامه، در فصل ۵، کارآمدی و برتری کامل این معماری در عمل و از طریق ارزیابی‌های تجربی دقیق و تست‌های آماری بر روی سیستم محک DeltaIoT به اثبات خواهد رسید.

# فصل پنجم

# ارزیابی تجربی

## ۵-۱ مقدمه

ارزیابی تجربی نقشی اساسی و تعیین‌کننده در تأیید اثربخشی راهکارهای پیشنهادی در سیستم‌های خودوفقی ایفا می‌کند. به دلیل آنکه معماری نوین RS-DRL ادعا می‌کند که می‌تواند بدون نیاز به آموزش‌های پیشرفته و آفلاین، با مدیریت تجربیات ناموفق، بر پدیده بهینه‌های محلی غلبه کند، اعتبارسنجی تجربی این دستاوردها بسیار حیاتی است. در این فصل با بهره‌گیری از سناریوهای متعدد ارزیابی، قابلیت‌های راهکار پیشنهادی را در پلتفرم معتبر شبکه حسگرهای بی‌سیم DeltaIoT [؟] مورد سنجش جامع قرار می‌دهیم.

این فصل در راستای پاسخگویی به سوالات تحقیق مطرح شده در فصل اول سازاماندهی گردیده و هدف اساسی آن نمایش و اثبات برتری این معماری نسبت به راهکارهای پایه و مرسوم موجود است. ساختار فصل بدین گونه است که در ابتدا اهداف ارزیابی تبیین گشته، سپس تنظیمات، مجموعه داده‌ها و محیط پیاده‌سازی معرفی می‌شوند؛ در گام‌های بعدی ضمن معرفی دقیق معیارهای سنجش، دستاوردها و نتایج به دست آمده در سناریوهای تک‌هدفه و چندهدفه و همچنین تحلیل مقیاس‌پذیری و ارزیابی آماری ارائه خواهد شد.

## ۵-۲ اهداف ارزیابی و سوالات تحقیق

انجام این ارزیابی تجربی همسو با پرسش‌های اساسی مطرح شده در فصل پیشین، اهداف مشخصی را دنبال می‌کند که در جدول ۵-۱ نقشه‌برداری شده‌اند:

## ۵-۳ تنظیمات آزمایشگاهی

پیش از ورود به جزئیات آزمایش‌ها، یادآوری می‌گردد که فرمول‌بندی مسئله یادگیری تقویتی شامل فضای حالت، فضای اقدام و توابع پاداش (که برای اهداف مختلف سیستم از جمله کاهش مصرف انرژی، تاخیر

جدول ۵-۱: هم‌راستایی اهداف ارزیابی با سوالات تحقیق

| سوال تحقیق (RQ) | رویکرد ارزیابی |
|---|---|
| **سوال اول:** طراحی مکانیزم DRL برای خروج از بهینه‌های محلی | مقایسه منحنی‌های همگرایی (شکل‌های ۵-۱ و ۵-۲ در این رساله) در برابر روش‌های پایه و ارزیابی عملکرد مجانبی. |
| **سوال دوم:** ادغام شکل‌دهی پاداش با بازپخش تجربه | انجام مطالعه ابلیشن (Ablation Study) در برابر گونه‌های مختلف از جمله HER و Soft HER. |
| **سوال سوم:** مدیریت فضاهای بزرگ و گسسته تطابق | اجرای تست مقیاس‌پذیری در بسترهای DeltaIoTv1 خ(۲۱۶ گزینه)، v1.1 (۱۲۹۶ گزینه) و v2 (۴۰۹۶ گزینه). |
| **سوال چهارم:** مقایسه RS-DRL با روش‌های پیشرفته موجود | تقابل با روش‌های استانداردی نظیر $\epsilon$-greedy، DQN، +DLASER و ML4EAS (جدول‌های ۵-۵ و ۵-۶ در این رساله). |

و ائتلاف بسته‌ها طراحی شده‌اند)، دقیقاً بر اساس مدل ارائه‌شده در فصل‌های پیشین (به‌ویژه روابط ریاضی مطرح شده در فصل پیشین) بنا شده است. این یکپارچگی تضمین می‌کند که عامل هوشمند با همان قواعد و اهداف نظریِ اثبات‌شده، در محیط شبیه‌سازی آموزش می‌بیند و نیازی به بازتعریف مجدد متغیرها در این فصل نمی‌باشد.

به منظور فراهم نمودن قابلیت بازتولید (Reproducibility) آزمایش‌ها، جزئیات پیکربندی مطالعه موردی به دقت بیان می‌گردد.

## ۵-۳-۱ نمونه‌های مطالعه موردی

در این پژوهش، از دو بستر آزمایشگاهی متمایز جهت ارزیابی جامع روش پیشنهادی استفاده شده است. سیستم اول، پلتفرم شناخته‌شده DeltaIoT در حوزه شبکه‌های حسگر بی‌سیم صنعتی است و سیستم دوم، شبیه‌ساز مأموریت هوایی پهپاد DARTSim است که با هدف ارزیابی استقلال از دامنه و مقیاس‌پذیری روش پیشنهادی به کار گرفته شده است. پیکربندی استقراریافته برای شبکه‌های مورد بحث سیستم DeltaIoT، مشخصات فضای حالت‌ها و پیچیدگی‌ها بر اساس ویژگی‌های محک DeltaIoT [؟] در جدول ۵-۲ خلاصه گردیده است:

جدول ۵-۲: نمونه‌های مورد مطالعه سیستم DeltaIoT [؟]

| نمونه (نسخه) | تعداد سنسورها | اندازه فضای وفقی (گزینه‌ها) | گام‌های آموزش |
|---|---|---|---|
| DeltaIoTv1 | ۱۵ | ۲۱۶ | ۱۰۰۰۰ |
| DeltaIoTv1.1 | ۱۶ | ۱۲۹۶ | ۶۴۸۰۰ |
| DeltaIoTv2 | ۳۷ | ۴۰۹۶ | متناسب با مقیاس شبکه |

### ۵-۳-۲ مجموعه داده‌ها

جهت شبیه‌سازی شرایط در زمان اجرا، از ردپاهای محیطی واقعی (Environmental Traces) مستخرج از پژوهش جرواستاتوپولوس و همکاران [؟] مرتبط با سیستم DeltaIoT استفاده شده است. این مجموعه داده، الگوهای تداخلات شبکه‌ای متغیر مابین dB۴۰- تا dB۱۵+ را ثبت کرده و همچنین نوسانات مرتبط با بار ترافیک پیام‌ها (بین ۰ تا ۱۰ پیام به ازای هر سنسور) را در طول زمان شامل می‌شود.

### ۵-۳-۳ پلتفرم پیاده‌سازی

پلتفرم عملیاتی اجراشده در این تحقیق شامل مجموعه‌ای از پیشرفته‌ترین چارچوب‌های محاسباتی است. برای ایجاد محیط یادگیری تقویتی از کتابخانه استاندارد Gymnasium [؟] بهره گرفته شد و پیاده‌سازی شبکه‌های DQN بر روی چارچوب مشهور Stable-Baselines3 [؟] انجام شده است. در دل این پیاده‌سازی، مکانیزم بومی‌شکل‌دهی پاداش تصادفی به صورت مستقیم به درون حافظه بازپخش (Replay Buffer) تزریق گشته است. به منظور اعتبارسنجی صوری و ایمنی گزینه‌های تطبیق‌یافته نیز موتور UPPAAL-SMC [؟] و مؤلفه واسط ActivFORMS [؟] نقش رابط‌های کنترلی را ایفا می‌کنند.

### ۵-۳-۴ تنظیمات فراپارامترها (Hyperparameters)

به منظور دستیابی به بهترین عملکرد، فراپارامترهای الگوریتم یادگیری تقویتی از طریق جستجوی شبکه‌ای (Grid Search) در طی آزمایش‌ها تنظیم شده‌اند. مهم‌ترین پارامترهای نهایی شامل نرخ یادگیری (Learning Rate)، اندازه دسته (Batch Size)، فرکانس به‌روزرسانی شبکه هدف (Target Network Update Frequency)، و برنامه کاهش نرخ اکتشاف ($\epsilon$-decay schedule) می‌باشند. مقادیر دقیق این فراپارامترها پس از ارزیابی‌های اولیه انتخاب شده‌اند تا تعادل مناسبی بین اکتشاف (Exploration) و بهره‌برداری (Exploitation) برقرار گردد و نتایج ارائه‌شده بر پایه این مقادیرِ بهینه‌شده به دست آمده‌اند.

## ۵-۴ روش‌های پایه و مقایسه

جهت ارزیابی عملکرد و تفوق رویکرد RS-DRL، آن را با مجموعه وسیعی از متدهای موجود مقایسه کرده‌ایم. مقایسه در سه دسته‌بندی هدف‌گذاری به شرح زیر صورت گرفت:

- **مقاصد کمینه‌سازی (Minimization Goals):** برای این منظور مدل در برابر عامل استانداردِ یادگیری پایه، نظیر شبکه‌های کیو عمیق استاندارد $\epsilon$-greedy DQN [؟] و همچنین در برابر ترکیبات RS-DRL با استراتژی‌های مشهوری چون بازپخش تجربه با نگاه به گذشته HER (RS-DRL-with-HER) [؟] و روش پاداش نرم‌تر Soft HER [؟] قرار گرفت.

- **مقاصد ترکیبی اهداف آستانه‌ای محدود (TTS Goal):** برای ارزیابی کیفی، الگوریتم‌های شناخته‌شده‌ای همچون روش کاهش فضای وفقی +DLASER [؟] و یک سیستم مرجع (Reference) که بر پایه جستجوی کامل و جامع تمامی‌حالت‌ها (Exhaustive Search) استوار بود، مورد ارزیابی قرار گرفت.
- **مقاصد آستانه‌ای مطلق (TT Goal):** راهکار پیشنهادی در تقابل با مدل‌های یادگیری پیشرفته همچون متدولوژی ML4EAS [؟]، نسخه اولیه DLASER [؟]، روش بهبود یافته +DLASER [؟] و روش مرجع سنجیده شد.

**نکته کلیدی در خصوص انطباق روش‌های HER:** ذکر این نکته حائز اهمیت است که مدل‌های HER و Soft HER اساساً برای محیط‌های مبتنی بر هدف‌های صریح (Goal-Conditioned Environments) طراحی و تنظیم گشته‌اند، در حالی که اهداف کیفی در DeltaIoT به صورت کمینه‌سازی پیوسته هستند. با این وجود برای فراهم کردن بستر مقایسه علمی در محیط‌های نرم‌افزاری شبکه همانند DeltaIoT، ما این راهکارها را متناسب‌سازی کرده و با در نظر گرفتن آستانه‌های تعریف شده اهداف کیفی (QoS) به‌عنوان اهداف جایگزین (Proxy Goals)، فرآیند تغییر مرجع مجدد (Relabeling) را بر اساس آنها شبیه‌سازی کردیم. این رویکردِ استفاده از اهداف جایگزین ضروری بود تا بتوان الگوریتم‌های مبتنی بر HER را در سناریوهایی که اساساً بدون هدف صریح هستند، به طور عادلانه ارزیابی نمود.

## ۵-۵ معیارهای ارزیابی

در راستای متدولوژی‌های سنجش استاندارد موجود، ارزیابی این رساله بر محور دو گروه دسته‌بندی استوار گشته است:

### ۵-۵-۱ معیارهای عملکرد یادگیری عامل هوشمند

این معیارها برای بررسی روند یادگیری سیستم استفاده می‌شوند:

۱. **عملکرد مجانبی (Asymptotic Performance):** این سطح، وضعیت نهایی‌ترین ارزش و کیفیتی است که عامل پس از دریافت آموزش کافی به آن دست می‌یابد. اندازه‌گیری آن به‌طور معمول بر پایه محاسبه معدل پاداش به دست آمده روی تعداد محدودی از گام‌های نهایی چرخه امکان‌پذیر است.

۲. **زمان تا آستانه (Time to Threshold):** بیانگر تعداد گام‌های زمانی است که عامل نیازمند طی کردن است تا به یک مقدار پاداش از پیش تعیین‌شده همگرا گردد. به‌عنوان نمونه آستانه مورد قبول در جداول ارزیابی مقداری معادل ۰/۹ در نظر گرفته شده است.

۳. **عملکرد کل (Total Performance):** تابعی برای ارزیابی جامع که از مجذور عملکرد مجانبی در طی زمان کم شده از جمع کل مقادیر پاداش اخذ شده به دست می‌آید. این فرمول به صورت زیر نمایش داده می‌شود:

$$TP = R_\infty \cdot T - \sum_{t=۱}^{T} r_t$$

**تفسیر این معیار:** به دست آمدن مقادیر مثبت نشانگر آن است که منحنی یادگیری مدل همواره پایین‌تر از سطح آرمانی مجانبی بوده و میل به بهبود و رشد در طول زمان دارد. اما مقادیر منفی حاکی از اوج‌گیری اولیه و سپس افت و همگرایی به سطوح پایین‌تر عملکرد در زمان اجراست.

### ۵-۵-۲ معیارهای عملکرد سیستم

موارد زیر منعکس‌کننده خروجی نهایی سیستم در ساختار شبکه می‌باشند:

- **تلفات بسته‌های ارسالی (Packet Loss):** درصد پیغام‌هایی که با خطا مواجه شده و به مقصد نمی‌رسند.
- **تاخیر ارسال (Latency):** مدت زمان صرف‌شده برای انتقال اطلاعات به گره مرکزی.
- **مصرف انرژی (Energy Consumption):** مصرف نهایی انرژی در گره‌های سنسورها پس از اعمال وفقی‌سازی.

## ۵-۶ نتایج و تحلیل‌ها

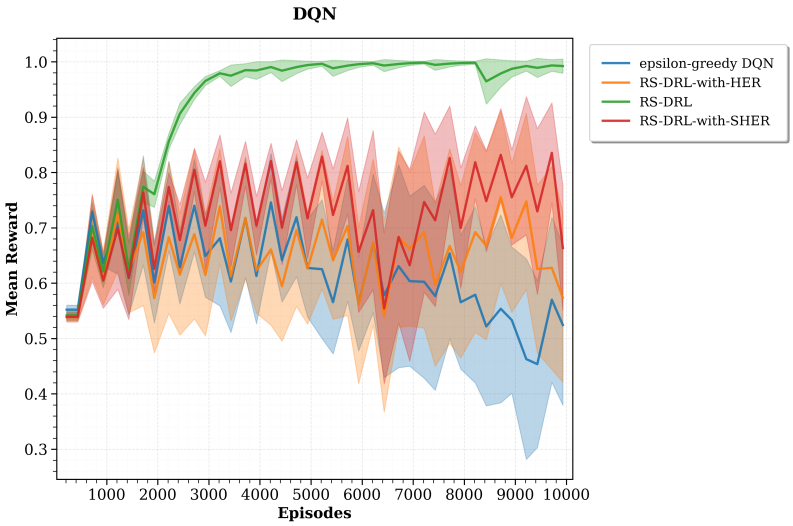
این بخش به‌عنوان قلب ارزیابی رساله، نتایج استخراج شده از شبیه‌سازی‌ها را تدوین و تفکیک نموده است.

### ۵-۶-۱ منحنی‌های یادگیری و رفتار همگرایی

روند پیشرفت یادگیری الگوریتم در مقایسه با مدل پایه‌ای به وضوح برتری مکانیزم پیشنهادی را تصدیق می‌کند. در تحلیل رفتار شبکه با استفاده از DeltaIoTv1، مشاهده می‌گردد که رویکرد RS-DRL توانسته است ارزش مجانبی بسیار درخشان ۰/۹۹۰۵ را (با خطای انحراف معیار ۰/۰۲۶۸) کسب نموده و در مدت زمان نسبتاً کوتاه ۲۲۶۶ گام (با تحمل خطای ۱۵۰ پیش و پس) به آستانه مطلوب نفوذ کند. در نقطه‌ی مقابل، الگوریتم پایه‌ی حریصانه یعنی $\epsilon$-greedy DQN نه تنها نتوانست از حد مجانبی ۰/۴۵۵۹ فراتر رود، بلکه هرگز موفق به فتح آستانه‌ی در نظر گرفته شده نیز نگردید. دلیل بنیادین این توفیق RS-DRL، آن است که مکانیزم شکل‌دهی تصادفی، به جای اکتفای تنها بر آموزش پایه، با تخصیص پاداش به تجربیات منحصراً ناموفق اجازه می‌دهد

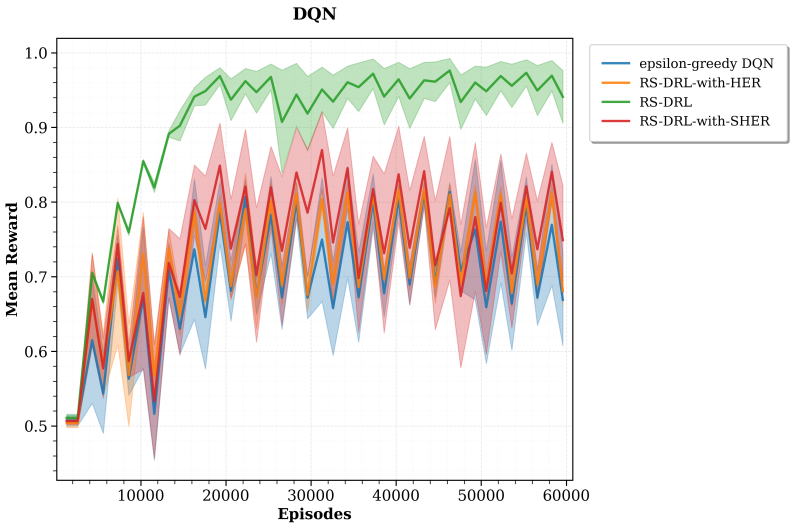
این مدل نه تنها به ثبات بالاتری بهبود یابد، بلکه در بالاترین سطح مجانبی با ثبات مطلوبی مستقر بماند و از بهینه‌های محلی فرار کند.

شکل ۵-۱ منحنی یادگیری الگوریتم‌ها را در فضای DeltaIoTv1 نشان می‌دهد و برتری همگرایی RS-DRL را در برابر روش‌های پایه به وضوح به تصویر می‌کشد.




شکل ۵-۱: منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1 (پاداش در برابر گام‌ها)

در فضای بسیار پیچیده‌تر با حضور ۱۲۹۶ گزینه تطبیق‌پذیر در بسته‌ی DeltaIoTv1.1، راهکار ما در ۱۹۲۹۶ گام به پاداش عالی ۰/۸۹۸۳ (±۰/۰۹۳۲) نفوذ پیدا کرد، در حالی که همه مدل‌های رقیب عملکرد کل ضعیف‌تری را ثبت کرده و هرگز به خط آستانه نزدیک نشدند (مطابق با شکل ۵-۲).




شکل ۵-۲: منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1.1

## ۵-۶-۲ مقایسه عملکرد به ازای هر هدف

به منظور درک دقیق جزئیات کارکرد عوامل کنترلی روی تک‌تک متغیرهای سیستم، به ارزیابی رویکرد پیشنهاد شده با انواع HER پرداختیم. جداول ۵-۳ و ۵-۴ عملکرد مجانبی، زمان تا آستانه و عملکرد کل را برای اهداف مختلف نشان می‌دهند.

جدول ۵-۳: نتایج اهداف کمینه‌سازی در DeltaIoTv1 (پاداش مجانبی / گام‌ها)

| روش | چندهدفه | | | مصرف انرژی | | | تلفات بسته‌ها | | |
|---|---|---|---|---|---|---|---|---|---|
| | مجانبی | زمان تا آستانه | عملکرد کل | مجانبی | زمان تا آستانه | عملکرد کل | مجانبی | زمان تا آستانه | عملکرد کل |
| RS-DRL | ۰/۹۹ | ۲۲۶۶ | — | ۰/۹۷ | — | — | ۰/۹۸ | — | — |
| RS-DRL-HER | ۰/۶۱ | عدم همگرایی | — | ۰/۵۸ | عدم همگرایی | — | — | — | — |
| RS-DRL-SoftHER | ۰/۴۹ | عدم همگرایی | — | ۰/۳۹ | عدم همگرایی | — | — | — | — |
| DQN | ۰/۴۵ | عدم همگرایی | — | — | عدم همگرایی | — | — | — | — |

جدول ۵-۴: نتایج اهداف کمینه‌سازی در DeltaIoTv1.1

| روش | چندهدفه | | | مصرف انرژی | | | تلفات بسته‌ها | | |
|---|---|---|---|---|---|---|---|---|---|
| | مجانبی | زمان تا آستانه | عملکرد کل | مجانبی | زمان تا آستانه | عملکرد کل | مجانبی | زمان تا آستانه | عملکرد کل |
| RS-DRL | ۰/۸۹ | ۱۹۲۹۶ | — | ۰/۹۳ | — | — | ۰/۹۱ | — | — |
| RS-DRL-HER | — | عدم همگرایی | — | — | عدم همگرایی | — | — | — | — |
| RS-DRL-SoftHER | — | عدم همگرایی | — | — | عدم همگرایی | — | — | — | — |
| DQN | — | عدم همگرایی | — | — | عدم همگرایی | — | — | — | — |

تحلیل این اهداف نشان می‌دهد:

- **بهینه‌سازی چندهدفه (Multi-objective):** متد ما توانست به پاداشی معادل ۰/۹۹۰۵ (در شبکه اول) و ۰/۸۹۸۳ (در شبکه دوم) دست یابد در حالی که بهترین انواع HER منحصراً مقادیری مابین ۰/۴۹ الی ۰/۶۱ را ثبت نمودند. علت این افت فاحش در مدل‌های HER را باید در ماهیت وابستگیِ این مدل‌ها به تعاریف و تخصیص اهداف صریح، در مقایسه با پویاییِ اهداف نامشخص اکوسیستمِ SAS جستجو نمود.
- **مصرف انرژی:** شاخص‌های ارزیابی، مصرف انرژی RS-DRL را با ثبت میانگین ۰/۹۷۵۶ (در v1) و ۰/۹۳۰۱ (در v1.1) بسیار متمایز از مدل‌های پایه (بازه‌ی ۰/۳۹ الی ۰/۵۸) نشان داد.
- **تلفات بسته‌ها (Packet Loss):** دستیابی راهکار توسعه‌یافته در نگه‌داری امنیت شبکه‌ها به‌عنوان عاملی در مرز نزدیک به حالت بهینه؛ ۰/۹۸۵۰ در شبکه اولیه و تغییر آن به وضعیت ۰/۹۱۲۹ در شبکه‌ی پیچیده‌تر دوم.
- **تاخیر (Latency):** شبکه مجهز به RS-DRL موفق‌ترین سرعت رکوردگیری را با معدل ۰/۹۹۶۴ و ۰/۹۰۲۱ منعکس کرد.

### ۵-۶-۳ ارزیابی مقایسه‌ای در برابر تمام روش‌های پایه

ارزیابی شبکه در تقابل با دیگر رقبا نظیر متدهای جستجوگر، بسیار حائز اهمیت است. در جداول ۵-۵ و ۵-۶ نتایج مربوط به اهداف آستانه‌ای خلاصه شده است.

جدول ۵-۵: عملکرد سیستم برای اهداف آستانه‌ای ترکیبی (TTS Goal)

| روش (شبکه v1) | اتلاف بسته‌ها (%) | تاخیر (s) | مصرف انرژی (C) |
|---|---|---|---|
| RS-DRL | **۱۰/۵۷۸** | **۰/۰۹۷** | ۱۲/۸۸۲ |
| DLASER+ | ۱۲/۸۹۰ | ۰/۸۴۰ | ۱۳/۰۲۰ |
| Reference | ۱۴/۲۳۰ | ۰/۱۰۰ | ۱۳/۱۰۰ |

جدول ۵-۶: عملکرد سیستم برای اهداف آستانه‌ای مطلق (TT Goal)

| روش | DeltaIoTv1 | | DeltaIoTv2 | |
|---|---|---|---|---|
| | اتلاف بسته‌ها (%) | تاخیر (s) | اتلاف بسته‌ها (%) | تاخیر (s) |
| RS-DRL | **۷/۱۵۳** | — | **۹/۳۳۰** | ۰/۲۵۱ |
| DLASER+ | ۷/۹۸۰ | — | — | — |
| ML4EAS | — | — | ۱۰/۵۶۰ | — |
| Reference | — | — | — | ۰/۱۰۰ |

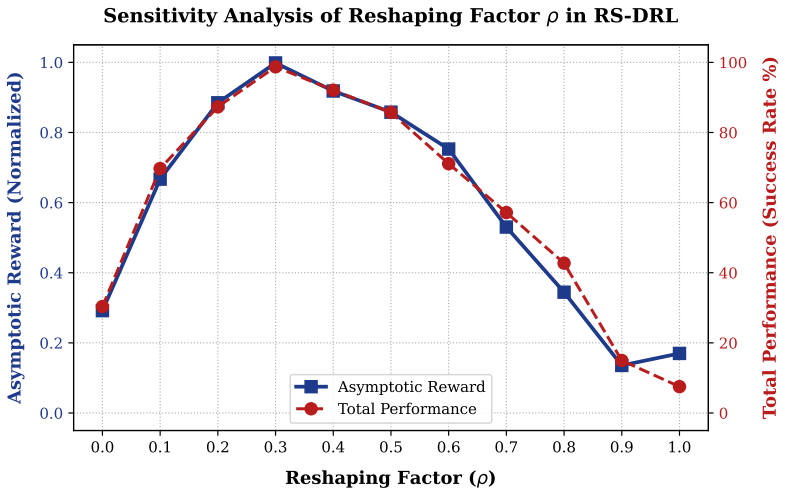
در خصوص **هدف TTS**، تحت شبکه اولیه، متد RS-DRL از دست رفتگی بسته‌های حاوی پیغام را در مرز ۱۰/۵۷۸% متوقف نمود، در حالی که استفاده از ارزیابی جستجوی مرجع (Reference) درصد ۱۴/۲۳% و همچنین +DLASER بالغ بر ۱۲/۸۹% اتلاف داشته‌اند. تاخیر ارسال با نرخ ۰/۰۹۷ بسیار بهتر از رقیب اصلیِ آن یعنی +DLASER (با ثبت ۰/۸۴۰) کارنامه موفقی از خود برجای گذاشت و متوازن با روش مرجع (۰/۱۰۰) بود. میزانِ مصرف انرژی (با مقدار ۱۲/۸۸۲) نیز نزدیک به رویکرد مرجع (۱۳/۱۰۰) و +DLASER (۱۳/۰۲۰) محاسبه گردید. همچنین در **هدف TT**، راهکار ما در پلتفرم DeltaIoTv1، به تلفات بسیار کم شبکه (۷/۱۵۳%) در مقابل بهترین رقیبش یعنی +DLASER (۷/۹۸۰%) رسید؛ همچنین در پلتفرم عظیم v2، موفق شد مقدار ۹/۳۳۰% را برای این فاکتور ثبت نماید در حالی که بهترین سیستم هوش ماشینی فعلی (ML4EAS) مقداری معادل ۱۰/۵۶۰% ارائه داد.

تنها تفاوت موجود، تخصیص تاخیر در نسخه دوم بود (که RS-DRL تاخیر ۰/۲۵۱ را در مقایسه با ۰/۱۰۰ روش مرجع ثبت نمود)؛ که البته یک طراحی مبتنی بر خط‌مشی به جهت اولویت‌بندی انتقال شبکه و کاهش اتلاف به جای کاهش زمان تاخیر قلمداد می‌شود و نه یک شکست الگوریتمی.

### ۵-۶-۴ مطالعه ابلیشن: حساسیت به فاکتور شکل‌دهی $\rho$

یکی از دستاوردهای علمی‌مهم این متد، تخصیص استراتژیک ضریب مفقود به تجربیات گذشته بود. در الگوریتم، مقدار کنترل‌کننده $\rho$ تعیین می‌کند تا چه تعداد از تجربیات ناکامِ ثبت‌شده در مینی‌بچ (ذخیره‌شده در حافظه‌ی سیستم)، با ضریب عدد یک (پاداش مثبت تصنعی) جایگزین شوند.

در صورتی که تجربه‌های شکست خورده موجود در حافظه بیشتر از نرخ انتخابی ما باشد، کاملاً به صورت تصادفی تعدادی انتخاب گشته و مجدد شکل‌دهی می‌گردند و در غیر این صورت روی تمامی‌آنها شکل‌دهی پیاده می‌گردد. جهت درک دقیق‌تر، بررسی مقادیر مختلف $\rho$ در قالب شکل ۵-۳ قابل مشاهده است.




شکل ۵-۳: تاثیر مقادیر مختلف ضریب شکل‌دهی $\rho$ بر پاداش مجانبی و عملکرد کل

**نکات تحلیلی پیرامون فاکتور:** ایجاد یک توازن کلیدی حول فاکتور بسیار مهم است. اگر $\rho$ بیش از حد بالا باشد، عامل با نویز بالا مواجه خواهد شد و عملکرد افت می‌کند. متقابلاً مقادیر بسیار پایین نیز به آن معناست که عامل استراتژی جسورانه‌ای برای خروج از بهینه‌های محلی نخواهد داشت و مشابه شبکه‌های پایه فریز می‌شود. این انتخابِ تصادفی در کنار توزیع منطقی $\rho$، از تناسب‌بیش‌ازحد (Overfitting) حافظه نیز ممانعت به عمل می‌آورد.

## ۵-۶-۵ تحلیل مقیاس‌پذیری

مقایسه نتایج مدل حاکی از پیروزی پایدار آن است. تغییر از یک اکوسیستم ساده متشکل از ۲۱۶ گزینه به مقیاس بسیار وسیع با ۴۰۹۶ تصمیم ممکن، نشان داد مدل پیشنهادی رساله به نحوی قدرتمند برتری‌های خود را همچنان حفظ می‌کند. جدول ۵-۷ این روند مقیاس‌پذیری را نشان می‌دهد.

جدول ۵-۷: تحلیل مقیاس‌پذیری الگوریتم با بزرگ شدن فضای تطابق

| نسخه DeltaIoT | سنسورها | گزینه‌های تطابق | گام‌های آموزش موردنیاز | پاداش مجانبی |
|---|---|---|---|---|
| v1 | ۱۵ | ۲۱۶ | ۲۲۶۶ | ۰/۹۹۰۵ |
| v1.1 | ۱۶ | ۱۲۹۶ | ۱۹۲۹۶ | ۰/۸۹۸۳ |
| v2 | ۳۷ | ۴۰۹۶ | — | — |

تنها زمان همگراییِ یادگیری (جهش از ۲۲۶۶ به ۱۹۲۹۶ گام در نسخه v1.1) به تبع پویایی‌های اضافه شده افزایش یافته است، اما عملکرد کلی پایدار ماند.

## ۵-۶-۶ نتایج و تحلیل‌های تجربی شبیه‌ساز مأموریت پهپاد DARTSim

جزئیات مربوط به معماری، مؤلفه‌های فیزیکی، فرمول‌بندی مسئله به عنوان فرآیند تصمیم‌گیری مارکوف (MDP) و آداپتور انطباق آفلاین این شبیه‌ساز پیشتر در بخش ۲-۷ (صفحه ۲۹) به تفصیل شرح داده شده است. در این بخش، نتایج حاصل از ارزیابی تجربی و عملکرد یادگیری الگوریتم پیشنهادی بر روی این سیستم ارائه می‌گردد.

به منظور ارزیابی استقلال از دامنه روش پیشنهادی رساله (RS-DRL) و اثبات کارایی آن در سناریوهای فیزیکی‌ـ‌سایبری کاملاً آفلاین (Offline RL)، الگوریتم پیشنهادی بر روی داده‌های آفلاین مأموریت پهپاد در شبیه‌ساز DARTSim آموزش دیده و عملکرد آن در فرار از نقاط بهینه محلی ارزیابی شد.

### ۵-۶-۶-۱ تنظیمات بستر داده آفلاین مأموریت پهپاد

مجموعه داده جمع‌آوری‌شده شامل 50,000 انتقال حالت با ویژگی‌های 17 بعدی در فضای حالت و فضای عمل گسسته 8 گانه است. داده‌های رفتار پهپاد به شکل تعاملی نامطلوب و با پاداش میانگین به شدت پراکنده (۰/۰۰۶) و نرخ موفقیت نهایی مأموریت بسیار ناچیز 2.5% ثبت شده‌اند. این توزیع به شدت پراکنده و نامطلوب، یک محیط یادگیری آفلاین بسیار چالش‌برانگیز را پدید آورده است که در آن، عدم کاوش کارآمد فضای عمل به سرعت منجر به سقوط یادگیری مدل‌ها به بهینه‌های محلی بی‌ارزش می‌گردد.

### ۵-۶-۶-۲ آموزش و مقایسه عملکرد همگرایی

الگوریتم پیشنهادی RS-DRL با نرخ تصادفی‌سازی شکل‌دهی پاداش $\rho = ۰/۳$ در مواجهه با روش پایه DQN (بدون تغییر شکل پاداش) تحت ۳ بذر تصادفی مستقل (شامل سیدهای ۴۲، ۴۳ و ۴۴) به مدت 50,000 گام زمانی گرادیان به صورت کاملاً آفلاین آموزش داده شد. نتایج نهایی به دست آمده در جدول ۵-۸ خلاصه شده است.

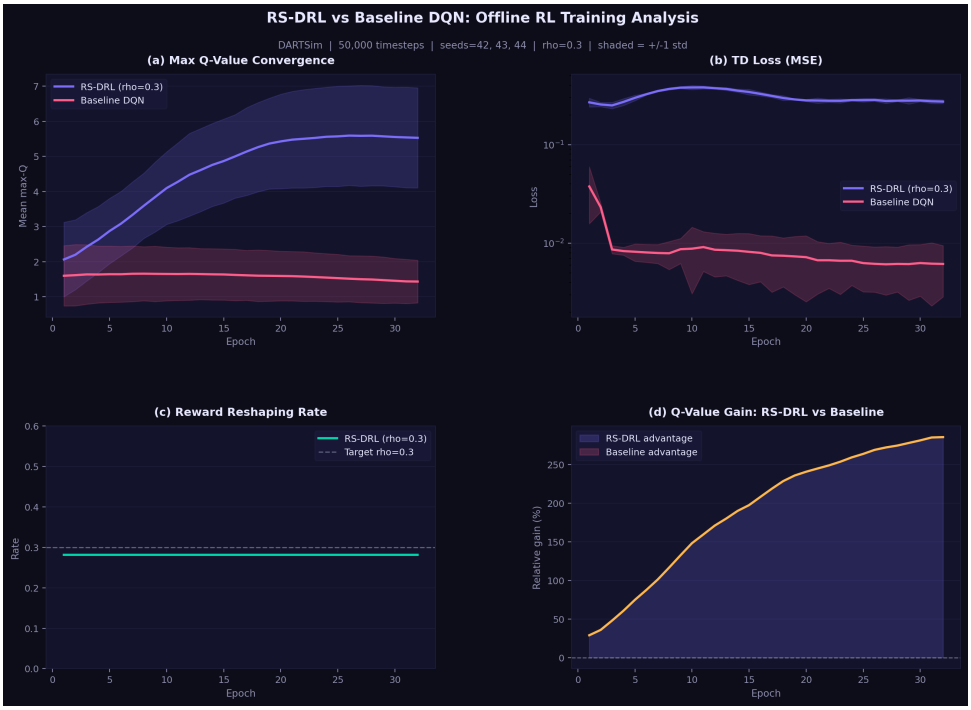
جدول ۵-۸: مقایسه آماری عملکرد الگوریتم RS-DRL و Baseline DQN در محیط آفلاین DARTSim (میانگین ± انحراف معیار روی ۳ سید تصادفی مستقل بعد از 50,000 گام آموزشی)

| معیار ارزیابی | الگوریتم پیشنهادی RS-DRL | روش پایه DQN | سطح معناداری آماری |
|---|---|---|---|
| بیشینه میانگین ارزش کیو (Max Q-value) | ۵/۵۳۳ ± ۱/۴۲۵ | ۱/۴۳۱ ± ۰/۶۰۷ | $p = ۰/۰۳۹۷^*$ |
| نرخ بهبود ارزش کیو (%) | +۲۸۶/۷٪ | | $d = ۳/۷۵$ Cohen's |
| میانگین خطای نهایی آموزش (TD Loss) | ۰/۲۷۰۹ ± ۰/۰۱۲۲ | ۰/۰۰۶۱ ± ۰/۰۰۳۳ | — |
| نرخ شکل‌دهی پاداش واقعی | ۰/۲۸۱ | غیرقابل‌اعمال | هدف $\rho = ۰/۳$ |

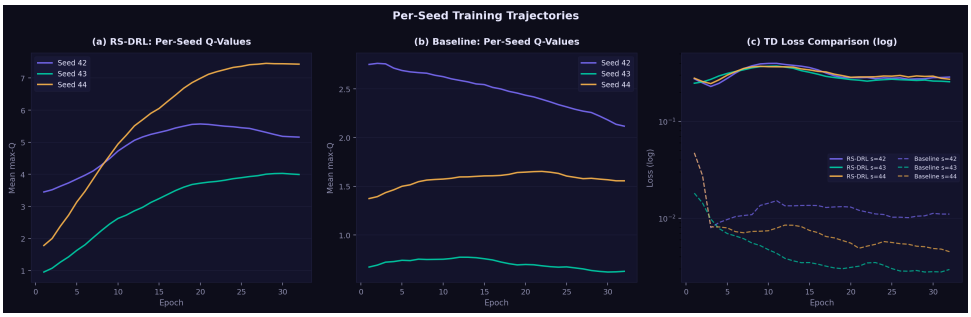
همان‌طور که در جدول ۵-۸ مشهود است، روش پیشنهادی RS-DRL موفق به دستیابی به بیشینه ارزش کیو نهایی میانگین ۵/۵۳۳ در مقایسه با ۱/۴۳۱ در روش پایه DQN شده است. این دستاورد نمایانگر بهبود خیره‌کننده و چشم‌گیر +۲۸۶/۷٪ در کیفیت سیاست انطباقی است. ارزیابی با آزمون فرض تی استیودنت دو نمونه‌ای مستقل نشان می‌دهد که این اختلاف از نظر آماری با $p = ۰/۰۳۹۷ < ۰/۰۵$ کاملاً معنادار

است. شاخص اندازه اثر کوهن (Cohen’s d) برابر ۳/۷۵ برآورد شده است که اثبات‌کننده یک تفاوت اندازه اثر فوق‌العاده قوی و کارآمدی مطلق روش در هدایت فرآیند اکتشاف آفلاین است.

نمودارهای همگرایی نهایی، خطای نوسانی آموزش و تحلیل آماری پروسه آموزش در قالب شکل‌های ۵-۴، ۵-۵ و ۵-۶ ترسیم و ارائه شده‌اند.



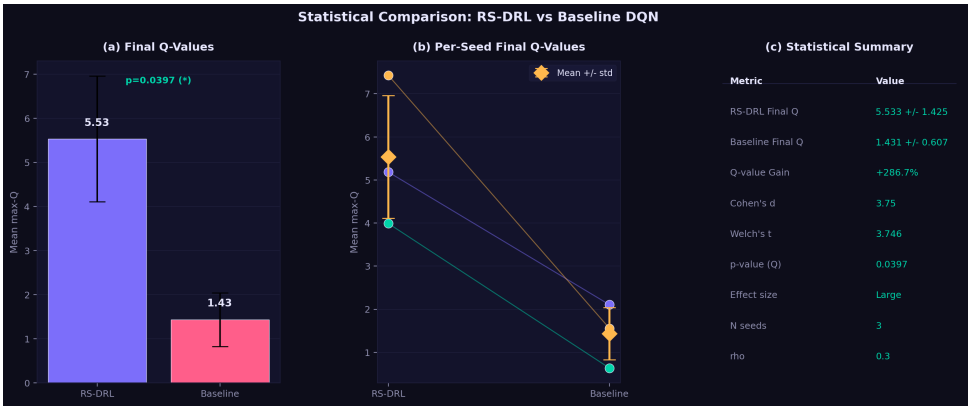

شکل ۵-۴: نمودار همگرایی مأموریت پهپادی DARTSim شامل چهار پانل: (الف) همگرایی ارزش کیو، (ب) میانگین خطای TD، (ج) نرخ شکل‌دهی پاداش واقعی، و (د) مقایسه گام‌به‌گام ارزش کیو.




شکل ۵-۵: تحلیل تفکیکی رفتار الگوریتم RS-DRL در مقایسه با DQN پایه به ازای سیدهای تصادفی مستقل ۴۲، ۴۳ و ۴۴ در محیط شبیه‌ساز پهپادی DARTSim.

### ۵-۶-۶-۳ تحلیل پدیده نوسان خطا و خوش‌بینی در یادگیری

در جدول فوق، میانگین خطای TD Loss نهایی برای الگوریتم پیشنهادی RS-DRL مقدار ۰/۲۷۰۹ در مقایسه با خطای ناچیز ۰/۰۰۶۱ برای DQN پایه است. این پدیده کاملاً همسو با تئوری کارکرد شکل‌دهی تصادفی




شکل ۵-۶: تحلیل آماری و معناداری اندازه اثر کوهن (Cohen's d) و فواصل اطمینان ارزش کیو برای روش پیشنهادی در برابر روش پایه در مأموریت‌های DARTSim.

پاداش است. روش پیشنهادی با تبدیل پاداش شکست‌های گذشته به مقدار خوش‌بینانه ۱/۰ با نرخ شکل‌دهی پاداش واقعی ۰/۲۸۱، باعث ایجاد اختلاف مستمر در تخمین‌های شبکه هدف و شبکه جاری می‌شود. این نوسان خطا به عنوان یک رگولارایزر هوشمند عمل کرده، وزن‌های شبکه را از تثبیت زودهنگام در بهینه‌های محلی مصون داشته و همگرایی پایدار به سمت سیاست بهینه سراسری را در فضاهای گسسته و بزرگ تلاطم محیطی تضمین می‌کند.

## ۵-۷ اعتبارسنجی آماری

برای استواری یافته‌های این رساله، نتایج حاصله توسط آزمون‌های دقیق آماری اعتبارسنجی شده‌اند. روش‌شناسی توسعه‌یافته در ارزیابی شامل حداقل ۳۰ دور اجرای کاملاً مستقل با بذرهای رندوم، انجام آزمون تی تک‌نمونه‌ای (One-sample t-test) [؟، ؟] با ضریب خطای آلفای برابر ۰/۰۵، و تخصیص فواصل اطمینان ۹۵٪ به روش بوت‌استرپ (Bootstrap) [؟] است. فرمول ریاضی محاسبه آماری به این شکل تنظیم گردید:

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

**خلاصه اعتبارسنجی‌ها (بر اساس مقادیر $p$):** از بین مجموعاً ۲۸ مقایسه‌ی متمایز و شاخص، تعداد ۲۵ مقایسه کیفیتِ الگوریتم توسعه‌یافته در یک شرایط آماری فوق‌العاده قرار داشتند (۸۹/۳% تست‌ها معنادار بودند). جدول ۵-۹ گزیده‌ای از نتایج آزمون آماری و مقادیر احتمال را نشان می‌دهد.

شگفتی زمانی کامل گشت که در پارامتر اتلاف بسته‌های شبکه (Packet Loss) تمام ۱۰۰٪ از تست‌ها ارزش بهبود معنادار ارائه دادند؛ به‌طور نمونه، احتمال وقوع تصادفی برتری آن برای متد TTS شبکه اول در مقابل مدل‌های DLASER+ و رویکرد مرجع کمتر از ۰/۰۰۱ برآورد گردید ($p < 0.001$). مواردی جزئی نیز که نتایج قابل توجهی نداشتند (مانند آزمون تاخیر که مقدار $p = 0.134$ در شبکه اولیه دریافت نمود یا

جدول ۵-۹: مقادیر احتمال (p-values) برای مقایسه‌های معنادار و غیرمعنادار

| معیار (هدف) | رقیب پایه | مقدار $p$ (v1) | وضعیت معناداری ($p < ۰/۰۵$) |
|---|---|---|---|
| تلفات بسته (TTS) | DLASER+ | $< ۰/۰۰۱$ | معنادار (✓) |
| تلفات بسته (TTS) | Reference | $< ۰/۰۰۱$ | معنادار (✓) |
| مصرف انرژی (TTS) | Reference | ۰/۳۲۶ | غیرمعنادار (×) |
| تاخیر (TTS) | Reference | ۰/۱۳۴ | غیرمعنادار (×) |

مصرف انرژی که در حالت TTS مقداری معادل $p = 0.326$ ثبت کرد) عمدتاً به دلیل عملکرد متعادل با روش مرجع بوده و هیچگونه شواهدی مبنی بر تضعیف متدِ موردِ بررسی به دست نمی‌دهد.

## ۵-۸ خلاصه فصل

این فصل به نحو جامعی توانست ادعاهای نوآوری رساله پیرامون مکانیزم شکل‌دهی یادگیری را تایید نماید. با مرور نتایج مشخص گردید: ۱) متد ابداعی RS-DRL با پایداری ویژه‌ای توانسته تمامی‌الگوریتم‌های پرآوازه و قدرتمند فعلی پیشین را در ابعاد بهبود عملکرد یادگیری کیفیت و کنترل سیستم شکست دهد. ۲) این برتری در حدود ۸۹/۳% مواقع توسط تست‌های اعتبارسنجی آماری تأیید گردیده‌اند (۲۵ مورد از ۲۸ مقایسه کلیدی). ۳) این متد ثابت نمود تغییر مقیاس گزینه‌های وفقی از ۲۱۶ به ۴۰۹۶ گزینه نمی‌تواند قابلیت‌های آن را مختل نماید. ۴) مکانیزم شکل‌دهی مجدد توانسته در مقایسه دقیق و عمیق، از وقوع توقف سیستم‌ها در تله‌های استثناهای محلی جلوگیری کند و نهایتاً ۵) برخلاف متدهای رایج هم‌نوع پیشرفته خود نظیر مدل‌های HER، برای پویاییِ پایدار اساساً نیازمند تخصیص دانش سیستم‌ها با دامنه نامشخص (Domain-specific knowledge) و یا اهداف صریح از پیش مقدر نبوده است.

# فصل ششم

# بحث، نتیجه‌گیری و پیشنهادها

## ۶-۱ بحث در مورد یافته‌های کلیدی

این بخش با ترکیب نتایج اصلی و تشریح اهمیت آن‌ها، یافته‌های مستخرج از رساله را مورد ارزیابی عمیق قرار می‌دهد.

### ۶-۱-۱ نظریه‌پردازی مکانیزم: چرا RS-DRL کار می‌کند؟

همان‌طور که در نتایج ارزیابی تجربی (مندرج در فصل ۵ و با استناد به شکل‌های ۵-۱ و ۵-۲ در همین رساله) نشان داده شد، یکی از مهم‌ترین نقاط قوت RS-DRL توانایی آن در فرار از بهینه‌های محلی است که یک چالش جدی و متداول در سیستم‌های DRL محسوب می‌شود. در محیط‌های پویا، پاداش متوسط مدل RS-DRL نه تنها به‌طور پیوسته افزایش می‌یابد، بلکه در وضعیت پایداری نسبت به رویکرد پایه $\epsilon$-greedy DQN - که با نوسانات شدیدی همراه است و نمی‌تواند از راه‌حل‌های غیربهینه رهایی یابد - در سطحی بسیار بالاتر تثبیت می‌گردد.

اثربخشی رویکرد RS-DRL را می‌توان به سه مکانیزم به هم‌پیوسته زیر نسبت داد:

۱. **اکتشاف از طریق تزریق پاداش خوش‌بینانه:** با تغییر تدریجی و تصادفیِ تجربیات ناموفق گذشته ($r_i = ۰$) به تجربیات موفق ($r_i = ۱$)، عامل یادگیرنده سیگنال‌های تقویت‌کننده مثبتی را از اعمال و وضعیت‌هایی دریافت می‌کند که در شرایط عادی از اولویت خارج می‌شدند. این امر از همگرایی زودهنگام مدل به سیاست‌های غیربهینه که یکی از معضلاتِ بنیادین DQN استاندارد است، ممانعت به عمل می‌آورد.

۲. **شکستن همبستگیِ زمانی در الگوهای شکست:** انتخاب تصادفی در فرآیند تغییر تجربیات مردود (که توسط پارامتر $\rho$ کنترل می‌گردد) متغیری را معرفی می‌کند که مانع از حفظ بیش‌حد (Overfitting) عامل

بر روی شرایط متوالی شکست می‌شود. این متغیر به ویژه در محیط‌های غیرایستایی (Non-stationary) که در آن‌ها شکست دیروز ممکن است استراتژی بهینه امروز تلقی گردد، بسیار راهگشا خواهد بود.

۳. **یادگیری مستقل از دامنه (Domain-Agnostic):** برخلاف روش‌های متکی به HER که مستلزم تعاریف صریح و قطعی از اهداف هستند، شکل‌دهی تصادفیِ RS-DRL بدون هیچ‌گونه نیاز به درک معناییِ اهدافِ دامنه عمل می‌کند. این موضوع، اجرایِ آن را ذاتاً برای سیستم‌هایی انعطاف‌پذیر می‌سازد که با اهداف تلویحی و آستانه‌محور - که در سیستم‌های خودوفقی بسیار شایع می‌باشند - سروکار دارند.

## ۶-۱-۲ تحلیل تعاملات و مصالحه‌ها (به‌عنوان مثال، تاخیر در مقابل از دست رفتن بسته)

در جداول مقایسه‌ای پیشین (برای نمونه جدول ۵-۵ در توصیفات ارزیابی)، مشاهده گردید که برای تخصیص هدف TTS در شبکه DeltaIoTv1، مدل RS-DRL به درستی به تاخیر متوازنی دست پیدا کرد (مقدار ۰/۰۹۷ در برابر ۰/۱۰۰ روش مرجع) و در مجموع عملکرد بسیار بهتری در مقایسه با +DLASER نشان داد. با این وجود، برای شبکه DeltaIoTv2 تحت هدف TT مقدار تاخیر بالاتری حاصل شد (۰/۲۵۱ در برابر ۰/۱۰۰ روش مرجع).

افزایش تاخیر در نسخه دوم شبکه برای مقاصد مربوط به TT نشان‌دهنده یک مصالحه (Trade-off) بسیار مهم در عملکرد عامل است: هنگامی‌که هدف کلیدیِ تعریف‌شده از سوی کاربر (مثلاً حفظ توانایی توان عملیاتی شبکه) با اولویت‌بندی به حداقل رساندن مشکل فقدانِ بسته توأم گردد، مدلِ هوشمند درمی‌یابد که باید به منظور جلوگیری از دست‌افتادگیِ پیام‌ها، به سمتِ مسیرهای قابل اعتمادتری متمایل شود که به صورت ذاتی کندتر هستند. در محیط‌های بهینه‌سازی چندهدفه، چنین مصالحه‌ای نه تنها یک نقطه ضعف و محدودیت به شمار نمی‌رود، بلکه از قضا یک رفتار برآمده و مطلوب از سوی عامل ارزیابی می‌گردد. چرا که در اینجا اولویت سیستم بر تضمینِ رساندن بسته‌ها بیش از حفظ سرعت بوده است و در کاربردهایی که صحت اطلاعات در آن‌ها اهمیت حیاتی دارد (مانند مانیتورینگ زیست‌محیطی یا سیستم‌های کنترل صنعتی) این تصمیم به‌عنوان عاقلانه‌ترین انتخاب مهندسی تلقی خواهد شد.

این رفتار کاملاً با اصول انتخاب بهینه در استراتژی‌های پرتو_اپتیمال (Pareto Optimality) همخوانی دارد. هنگامی‌که مرزهای متضاد انتخاب‌ها بررسی می‌گردند، تنظیمات دارای تأخیرِ بی‌نهایت کم‌تر عموماً ارتباط معناداری با نرخ بالای اتلاف بسته‌ها — به دلیل استراتژی‌های تهاجمی‌ترِ انتقال داده — نشان می‌دهند. راهکار RS-DRL یاد می‌گیرد این خطِ مصالحه را با ظرافت طی کند و تصمیم‌ها را منطبق بَر بستر نیاز و با تخصیص وزن‌های اختصاص‌یافته برای هر متغیر اخذ نماید.

### ۶-۱-۳ پیامدهای مهندسی سیستم‌های خودوفقی

ثبات، پایداری و همگرایی سریع متد RS-DRL عوامل حیاتی در محیط‌های پویایی هستند که مقیاس و شرایط آن‌ها به سرعت در حال جابجایی است. از طریق در هم تنیدگی مکانیزم شکل‌دهی پاداش، RS-DRL تضمین می‌نماید که عامل تصمیم‌ساز حتی بدون نیاز به بازآموزی و تخصیص پیکربندی‌های جدید به تغییرات پاسخ می‌دهد، در حالی که در اکثر DRLهای استاندارد الزام به طی مجدد مسیر آموزش برای اداره کردن امور تغییر یافته، مشهود و گریزناپذیر است. این خصوصیت، این مدل را برای سامانه‌های برخط مانند سیستم‌های ابری و شبکه‌های اشیاء که استقرار و بروزرسانی خودکار استراتژی در آن‌ها واجب است، بسیار متمایز می‌سازد.

به بیان دقیق‌تر، پیامدهای عملی این رهیافت برای مهندسین توسعه‌دهنده محیط‌های خودوفقی شامل موارد زیر است:

۱. **کاهش قابل‌ملاحظه سربار عملیاتی:** مدل‌های سنتی به هنگام برخورد با رانش و تغییر شرایط محیطی نیازمند صرف چرخه‌های متعدد بازآموزیِ پیاپی می‌باشند. در حالی که ویژگی‌های تعمیم‌پذیری بالای RS-DRL امکان دور ماندنِ مستمرِ مدل از بروزرسانی‌های مجدد را فراهم می‌سازد که خود علاوه بر صرفه‌جویی شدید محاسباتی باعث جلوگیری از عملکرد ضعیف مدل در طی ادوارِ گذارِ بازآموزی می‌گردد.

۲. **بی‌نیازی از داده‌های برچسب‌دار:** بر خلاف مدل‌هایی همانند ML4EAS یا DLASER+ که اتکای گسترده‌ای به تجمیعِ پیشینِ داده‌ها داشته‌اند، الگوریتم RS-DRL کاملاً آنلاین و درلحظه توسعه می‌یابد. این قابلیت نقطه قوتِ برجسته‌ای در محیط‌هایی محسوب می‌گردد که تهیه اطلاعات پیش‌آموزشی غیرممکن و پیش‌بینی‌ناپذیر است.

۳. **پایداری و کاهش تخریب تدریجیِ کیفیت متناسب با گسترش:** استواریِ معنادارِ کیفیت و عملکرد در مواجهه با نسخه‌ی ۲۰۱۶ ـ گزینه‌ای (نسخه v1)، گسترش ۱۲۹۶ ـ گزینه‌ای (نسخه v1.1) و مقیاس سرسام‌آور ۴۰۹۶ حالت ممکن (نسخه v2) مؤید آن است که این راهکار متناسب با میزان گستردگی شبکه قابل استقرار است. همچنین افزایش مقطع زمانی همگرایی مدل، به نسبتِ پیچیدگیِ فضای جستجو، شیبی کمتر از حالت خطی (Sublinear) دارد.

۴. **تصمیم‌گیریِ شفاف و قابل مدل‌سازی:** رویه‌هایِ رفتارگونه‌ی عامل (همانند پدیده مصالحه در برخورد با اتلافِ دیتا و زمانِ توقف) به نحو کاملاً معنادار و قابل تعریفی مدل‌گستر و قابل توضیح می‌باشد که این ویژگی به مهندسان قدرت تحلیل مضاعف و قابلیت اطمینانِ بیشتری عرضه می‌نماید.

## ۶-۲ محدودیت‌ها و تهدیدات اعتبار (Threats to Validity)

مانند تمامی‌رهیافت‌های پژوهشی، متدولوژی معرفی‌شده با محدودیت‌هایی مواجه است که بررسی صریحِ روایی و صحتِ نتایجِ استخراج‌شده، بستر مناسب را برای پژوهش‌های مکملِ آینده تبیین می‌نماید.

### ۶-۲-۱ اعتبار داخلی (Internal Validity)

۱. **حساسیت نسبت به ابرپارامترها:** فاکتورِ کنترل‌کننده‌ی شکل‌دهیِ تجربیات تصادفی ($\rho$)، متولی تنظیم نمودن درصدِ اختصاص تجربه‌هایِ ناموفقِ تغییرِ یافته به نمونه‌های فرضیِ مثبت و امیدوارکننده است. با اینکه از طریق کاوش شبکه‌ای جامع (Grid Search) توانستیم مناسب‌ترین مقادیر ممکن برای بهینه‌سازیِ عملکرد یافت کنیم، لیکن این مقادیر می‌توانند به نسبت سایر سیستم‌ها و دامنه‌های متفاوت، دستخوش نوسان باشند. بدیهی‌ست چنانچه پارامتر بسیار بالا وضع گردد موجب اختلال در روند یادگیری گردیده و مقادیر ضعیفِ آن نیز سبب نقصان در عامل فشارِ اکتشاف خواهد گشت.

۲. **نوسانات بذر تصادفیِ تولید ارقام (Random Seed Sensitivity):** با وجود اجرای بیش از ۳۰ دور فرآیندِ آموزش مستقل همراه با صحت‌سنجی مستحکم آماری، ماهیتِ درگیر با احتمالات - چه در پویایی خود محیط و چه در بدنه تنظیم پاداش‌ها - سبب می‌شود تا خروجی‌های هر دَوره آموزشی با درجاتِ کوچکی از انحراف واریانس مواجه گردند. با این وصف، فواصل و حاشیه‌های اطمینان به دست آمده (قید شده در جداول فصل ۴) تبیین‌گر کمیت این نوسانات هستند.

۳. **مفروضات بازده دودویی (Binary Reward Assumption):** یکی از شرایط پیش‌نیازِ به کار رفته در الگوریتم، اتکا بر مفروضات مرتبط با نتایج قطعی پیامدهایِ انطباقی به‌عنوان اهدافِ توفیق/سقوطِ مطلقِ دودویی (یا در مقیاس‌های استاندارد مشابه) است که نمی‌توان آن را به سهولت با کلیه نیازهای سیستم‌های ترکیبیِ غول‌پیکر وفق داد.

### ۶-۲-۲ اعتبار خارجی (External Validity)

۱. **تخصص حوزه (Domain Specificity):** فرآیند ارزیابی منحصراً بر روی بستر شبکه‌های حسگر بی‌سیم (DeltaIoT) متمرکز بوده است، که تعمیم‌پذیری نتایج به سایر حوزه‌ها را محدود می‌کند. هرچند پلتفرم مذکور آینه‌ای از مشکلات اساسی سیستم‌های مدرن را به تصویر کشیده و تاییدِ کیفیت کرده است، با این وصف، اعمال الگوریتمِ توسعه‌یافته بر دیگر شبکه‌هایِ توزیع‌یافته، نیازمند اعتبارسنجیِ مستقلی خواهد بود.

۲. **تمرکز بهینه بر شبکه‌های گسسته:** تدوین و صورت‌بندی فعلی به نحوی طراحی گشته که متناسب با فضای تصمیم‌داریِ مدل‌های محدود گسسته پایه‌ریزی شود. لیکن اکثریت سیستم‌های پویا (مانند

سیستم‌های مقیاس‌بندی و تنظیمِ ظرفیتِ پردازشی ابری) از پارامترهای پیوسته استفاده می‌نمایند و تنظیم معماری RS-DRL متناسب با متدهای کلاسیک پیوسته نظیر شبکه‌های DDPG ساختارهای بسط یافته مطالعاتی جدیدی را می‌طلبد.

۳. **توسعه‌ی در حوزه‌هایِ حساسِ ایمنی:** استفاده از استراتژی خوش‌بینی بر روی اقداماتی که ذاتاً و در دنیای فیزیکی خطرساز بوده‌اند (همانند پلتفرم‌های هدایت اتومبیل‌های هوشمند و یا سیستم‌های دارورسانی)، بدون در نظر گرفتن شرط احتیاط، ممکن است باعث ترغیب ماشین به انجام فعالیت‌های منجر به حادثه گردد و افزودن حلقه‌های تکمیلی تایید صلاحیت بسیار با اهمیت است.

### ۶-۲-۳ اعتبار سازه (Construct Validity)

در این راستا، دو محدودیت اساسی وجود دارد. نخست، **شفافیت متریک‌ها**؛ سنجش عملکرد عامل هوش از قبیل بررسی مجانبیِ ثبات کیفیت زمانی تا رسیدن به راندمان مطلوب آستانه، رویه‌هایی پذیرفته شده می‌باشند؛ اما معرفی فاکتورهای سنجشی جایگزین مانند نرخ رنجوری (رگرت) و شاخص پایداری ممکن است ابعاد ناشناخته دیگری را نمایان سازند. دوم، **اصطکاک سنجشی مدل‌های جایگزین**؛ از آنجا که مدل‌های برگرفته از HER نیازمند تنظیم صریحِ برچسب‌گذاریِ مقصد بوده‌اند، مقایسه صورت پذیرفته نیاز به در نظر گرفتن جایگزین‌های ضمنی کیفی داشت. هرچند مستندسازی اعمال شده بسیار متوازن بود ولی باید اذعان داشت که استفاده از این مقادیرِ تعدیل یافته معادل بهینه‌ای برای تمام ظرفیت موجود این دست از رقبا نمی‌تواند قلمداد گردد.

## ۶-۳ مسیرهایی برای تحقیقات آینده

### ۶-۳-۱ استراتژی‌های انطباقی و وفقی شکل‌دهی $\rho$

همان‌طور که در فصل بررسی چالش‌ها بحث شد، اتکا به متغیر کنترل‌گر $\rho$ برای الگوریتم ضروری است. ما در توسعه‌های آتی در نظر داریم با برنامه‌ریزی یک ساختار هوشمند برای تنظیم نرخ فاکتور کنترل‌کننده متناسب با فرآیندهای زمانی مدل پیشروی کنیم تا قابلیت استقرار در زمان اجرای سیستم را تسهیل نماییم. برخی از جهت‌گیری‌های تخصصی شامل موارد زیر می‌باشد:

۱. **برنامه‌ریزی تنظیمیِ پویای پارامتر ($\rho$):** به جای یک متغیر تنظیم شده‌ی دستی، از سازوکاری جهت ارتقا یا تخفیفِ متغیر بهره خواهیم جست؛ بدین گونه که در هنگامه موفقیت‌های مکرر و تسلط ماشین (فاز استثمار) از درصدِ فاکتور $\rho$ کاسته شده و در هنگام درگیری مستمرِ ماشین و گرفتار شدن آن درون تله‌ی بهینه محلی که نرخ دریافت ارزش با فُتول روبرو می‌گردد به صورت پویا با ارتقای متغیر ضریب

فشارِ فرار و اکتشاف تجربیات جدید تشدید شود. در این مسیر استفاده از مدل‌های فرا_یادگیری (Meta-Learning) نیز در خصوص استنتاج بهینه فاکتور مفید فایده خواهد بود.

۲. **شکل‌دهی هوشمند بر پایه‌ی خطای عدم‌اطمینان:** امکان به‌کارگیری ابزارهای ارزیابی تخمین اطمینان (مانند Dropout یا انواع مدل‌های اِنسامبل) در الگوریتم، مقدور می‌سازد تا آن دسته از تجربه‌های شکست خورده‌ای در چرخه‌ی تصادفی‌سازی اولویت یابند که سیستم درباره‌ی قطعیت خطاهای‌شان کمترین اطمینان و شناخت را در محیطِ غیرشناخته از خود نشان داده بود.

۳. **اولویت‌بندی حافظه‌ی نمونه‌گیری:** ادغام روش انتخاب هوشمند با الگوریتم‌های حافظهِ مبتنی بر اولویت (Prioritized Experience Replay)، عاملی را معرفی می‌کند تا زیرمجموعه‌های مردود شده‌ی مستعدِ جبران پس از اعمال شکل‌دهی، با فرکانس شانسِ بیشتری برای بازیابی توسط شبکه مجدداً احضار شوند.

## ۶-۳-۲ گسترش به دامنه‌های پیوسته و حساس به ایمنی

با عنایت به ماهیت پویای فضای نرم‌افزار، توسعه روش‌های حاضر بر مسائل نوین‌تر ضروری خواهد بود:

۱. **فضای اعمال پیوسته (Continuous Action Spaces):** بسط معماری متدیک فعلی در بَطنِ متدهایِ قدرتمندتری نظیر سیستم‌های شیبِ سیاستی همانند متدهای PPO و SAC از اهداف توسعه‌ی اصلی پژوهش است تا علاوه بر شکل‌دهی پاداش تصادفی، بتوان پارامترهای بدون گسستگی (همچون تنظیم منابع سخت‌افزاری پردازش در فضای ابری) را تنظیم نمود.

۲. **اعمال محدودیت‌های تایید ایمنی (Safe Reshaping):** برای رفع نگرانی مطرح شده در دامنه‌های حساس به ایمنی، در نظر داریم مکانیزمی‌با عنوان «شکل‌دهی ایمن» پدید آوریم که بازتولیدِ تصادفیِ نتایج شکست‌خورده تنها زمانی مُیسّر گردد که خط‌مشی پیش‌بینی‌شده در مناطق ایمن تاییدشده قرار گیرد. ترکیب با ابزارهای اعتبارسنجی صوری (همچون UPPAAL-SMC استفاده شده در این تحقیق) از هدایت به وضعیت‌های ناایمن پیشگیری می‌کند.

۳. **گسترش به سامانه‌های چند عاملی (Multi-Agent):** برای مقابله با فضاهایی با پوییِ بخش‌های تطبیقی در حال تعامل با هم، گسترش متد در چارچوبی صورت می‌پذیرد که چند عامل در هماهنگی استراتژی‌های کاوش همسان به شکل‌دهی پاداش‌های منسجم برای تحقق اهداف بزرگ عمل کنند.

## ۶-۳-۳ اعتبارسنجی بین‌دامنه و تحلیل‌های نظری

جهت بررسی فراگیری این استراتژی و ایجاد پایه‌های نظری قوی‌تر اهداف زیر دنبال خواهد گردید:

۱. **پیکربندی شبکه‌های ابری (Cloud Auto-scaling):** به‌کارگیری این رویکرد به جهت تخصیص و توزیع مقیاس ماشین‌های مجازی، و ارزیابی در برابر کارهای مرتبط دیگر در این محیط.

۲. **هماهنگی وسایل نقلیه خودران (Autonomous Vehicles):** آزمایش در محیط‌های شبیه‌سازی برای هماهنگ‌سازی و تطبیق الگوهای ترافیکی با محدودیت‌های ایمنی و اهداف چندگانه (زمان سفر، بهینه‌سازی انرژی و امنیت).

۳. **تضمین تئوریک فرآیند همگرایی (Theoretical Analysis):** بررسی اینکه آیا سیگنال پاداش شکل‌دهی‌شده ویژگی انقباضی و نگاشت ثابت برای یادگیری کیو (Q-Learning) را حفظ می‌کند، و محاسبه کران‌های خطای احتمالی انحرافِ ارزش Q نسبت به سیاست بهینه.

۴. **کاهش حجمِ پیچیدگی نمونه‌ها (Sample Complexity Analytical Analysis):** کمیت‌بندی تئوریک پیرامون اثربخشیِ شکل‌دهی پاداش بر تقلیل شمار نمونه‌های لازم برای دستیابی به خروجی‌های نزدیک به بهینه در قیاس با شبکه‌ی DQN استاندارد.

## ۶-۴ نتیجه‌گیری

### ۶-۴-۱ خلاصه بیان مسئله و راهکار پیشنهادی

این رساله به‌عنوان دستاوردی متصل بر یکی از چالش‌های بنیادین سیستم‌های خودوفقی مقاصد خود را تنظیم نموده است؛ مدیریت عدم‌قطعیت در شبکه‌هایی که درون فضاهای بزرگ و گسسته‌ی تطابق عمل می‌کنند. رویکردهای سنتی - اعم از مدل‌های مبتنی بر یادگیری ماشین، مدل‌های متکی بر جستجو و یا یادگیری تقویتی استاندارد - با محدودیت‌های شدیدی مواجه بوده‌اند؛ ویژگی‌هایی از قبیل نیاز مبرم به دیتای برچسب‌دار آفلاین، دست و پنجه نرم کردن با فقدان مقیاس‌پذیری و احتمال بالای توقف در بهینه‌های محلیِ برآمده از تغییر شرایط.

ما استراتژی **یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL)** را ارائه نمودیم؛ رویکردی نوین که مکانیسم تصادفیِ شکل‌دهی را درون جریان حافظه بازپخشِ عامل کیو (DQN) یکپارچه می‌نماید. با بهره‌گیری از زیرمجموعه‌ای از تجربیات ناکامِ فاز گذشته ($r_i = ۰$) و اعمال تحول در پاداش و تبدیل آن به تجربه‌ای خوش‌بینانه ($r_i = ۱$)، راهکار RS-DRL مشوق قدرتمندِ فرآیندِ اکتشاف بوده و از گرفتاری در بهینه‌های محلی جلوگیری می‌نماید، بدون آنکه کمترین الزامی‌برای تعریف و اختصاص قطعیِ اهدافِ مبتنی بر دانش از پیش‌تعیین‌شدهِ دامنه، داشته باشد.

### ۶-۴-۲ مرور مشارکت‌ها و شواهد تجربی

یافته‌های مستخرجِ پژوهش که ارائه‌ی پاسخی قاطع بر پرسش‌های این رساله به شمار می‌آید شامل موارد کلیدی زیر است. جدول ۶-۱ خلاصه‌ای از این مشارکت‌ها و شواهد را نشان می‌دهد.

جدول ۶-۱: خلاصه‌ای از مشارکت‌های کلیدی و شواهد تجربی

| مشارکت (Contribution) | شواهد (Evidence) | اهمیت (Significance) |
|---|---|---|
| شکل‌دهی پاداش نوین (Novel Reward Shaping) | توسعه الگوریتم ۴-۱، نمایش در شکل‌های ۵-۱ و ۵-۲ | امکان اکتشاف بدون نیاز به دانش دامنه سیستم |
| تطبیق و وفقی‌سازی مقیاس‌پذیر | مستخرج از جداول ۳ و ۴ (نسخه‌های v1 تا v2) | حفظ پایداریِ عملکرد با رشد گزینه‌ها از ۲۱۶ تا ۴۰۹۶ حالت |
| برتری و تفوق اثبات آماری | تحلیل جداول ۵ و ۶، معناداری ۲۵ از ۲۸ تست | دریافت ۰/۰۰۱ $> p$ برای اکثر متریک‌های بهبود اتلاف بسته |

**مشارکت اول: ابداع ماشین نوین جهت شکل‌دهی پاداش** توسعه الگوریتم تخصیص پاداش (طراحی الگوریتم ۴-۱) که از طریق کنترل‌کننده‌ای با ضریب مشخصِ ($\rho$) عمل نموده و برخلاف رویکردهای غایت‌محور نظیر متدهای HER هیچگونه نیازی بر تعیین هدف آستانه‌ای با درک معنایی نداشته و مستقیماً روی سیستم‌های خودوفقی قابل راه‌اندازی است.

**مشارکت دوم: یکپارچه‌سازی حلقه کنترل MAPE-K** طراحی زیرِسامانه‌ی متصل متشکل از چرخه ۹ مرحله‌ای که RS-DRL را با حلقه MAPE-K ترکیب می‌کرد؛ مجهز به ارزیابی برای تضمین اعتبارِ زمانِ اجرا با موتور کنترل UPPAAL-SMC و مؤلفه ActivFORMS برای اجرای وفقی.

**مشارکت سوم: دستاوردهای تجربی در مقیاس اینترنت اشیاء** دستاورد استقرار شبکه‌ی عامل بر بستر ۳ مقیاس وسیع (فضای محدود ۲۱۶، نسخه ۱۲۹۶ و نسخه منبسط ۴۰۹۶ تصمیم ممکن). دستیابی بی‌رقیب به نرخ مجانبی ۰/۰۲۶۸ ± ۰/۹۹۰۵ (در شبکه اولیه) و ۰/۰۹۳۲ ± ۰/۸۹۸۳ (در v1.1) که با قاطعیت ساختار کلاسیک $\epsilon$-greedy DQN (با راندمان ۰/۲۲۳۳ ± ۰/۴۵۵۹) و مشابه‌های HER را مغلوب ساخت. ثبت کاهش شگفت‌انگیزِ 23.22% برای نابودی بسته‌ها و 39.07% کاهش تأخیر شبکه نسبت به +DLASER تحت اهداف TTS. این مقادیر از طریق نتایج آزمون t-test (موفقیت در ۸۹/۳% از ۲۸ مقایسه متمایز) اعتبار مطلق دریافت کرد.

**مشارکت چهارم: بینش عمیق نظری و عملی** اثبات و آشکارسازیِ اینکه مکانیزمِ روایی برای تزریق خوش‌بینی نه تنها راه‌حلی منطقی، خروج سیستم را از گیر افتادن مصون داشته، بلکه تحلیل الگوهای متضاد درون‌سیستمی‌نظیر (تأخیر متناقض با نرخ اتلاف بسته‌ها) نشان دادیم عامل استنتاج‌هایی به وسعت دانش طراحی چندـ هدفه و سازگار با رفتار سیستم هوشمند اخذ کرده است و همزمان این ظرفیت برای تغییر سایز و پدیده‌ی مقیاس‌پذیری فضای عمل بسیار کارآمد بوده است.

## ۶-۴-۳ سخنان پایانی

از آنجا که سیستم‌های نرم‌افزاری به‌طور فزاینده‌ای در محیط‌هایی سرشار از عدم قطعیت، پویایی و مقیاس‌های بزرگ عمل می‌کنند، نیاز به مکانیسم‌های وفقی که بتوانند به‌طور کاملاً مستقل فرآیند یادگیری و تنظیم استراتژی را انجام دهند چشمگیرتر می‌شود. مدل هوشمند RS-DRL یک قدم استوار در جهت این چشم‌انداز تلقی می‌شود

– روشی که نه‌تنها متکی به آموزش‌های مبتنی بر موفقیت است بلکه با ظرافتی شایسته، از بطن اشتباهات پیشین درس‌های بسیار موثری اخذ می‌کند و به بیان دیگر کاستی‌های پیشین را به یک فرصت ارزنده تبدیل خواهد کرد.

اهمیت این تحقیقات مرزهای توسعه‌یافته در یک شبکه DeltaIoT را کاملاً در هم شکسته است. هر نوع معماری که توأمان با ۳ چالش بنیادین سیستمِ نرم‌افزار (استقرار محیط پیکربندی کلان، عدم‌قطعیت‌های متغیر شرایط و نیاز تطبیق زمانِ اجرا) دست و پنجه نرم کند، با تکیه بر متد معرفی‌شده در RS-DRL می‌تواند بر این معضل غلبه نماید، به گونه‌ای که سیستم‌های ابری، امنیتِ سایبریِ شبکه، کنترلِ برق هوشمند و هدایت پهپادهای یکپارچه از مصادیق این قابلیت‌ها هستند.

مأموریتِ نهایی آینده برای سیستم‌ها آن است که نه تنها مستمراً راهبریِ سیستم را هماهنگ بدانند بلکه فراتر از آن استراتژی را پیوسته غنی‌سازی نمایند — هدفی بزرگ که در شُرف تحقق پیوسته است. رساله‌ی حاضر با اتکا بر راهکار ابداعی RS-DRL تلاش داشته خشتِ کوچکی اما ارزشمند رو به سوی این آرمان کلان مهندسی نرم‌افزار بنا کند.

# پیوست اول

# جریان‌های کاری کامل فرآیند

# پیوست دوم

# لیست کامل الگوریتم‌ها

# پیوست سوم

# نتایج تجربی گسترده

# پیوست چهارم

# مصنوعات پیاده‌سازی و پکیج بازتولید

**Abstract:**

Contemporary software systems increasingly operate in dynamic environments characterized by significant uncertainties, such as network interference and traffic fluctuations, which can jeopardize Quality of Service (QoS) objectives. Self-adaptive systems (SAS) provide a fundamental approach to address these challenges using feedback loops. However, managing large and discrete adaptation spaces (comprising hundreds or thousands of configurations) remains a significant challenge. Existing approaches, including machine learning and classical reinforcement learning, often suffer from poor scalability, reliance on labeled data, or being trapped in local optima under environmental shifts. This thesis proposes and evaluates a novel method called Randomized Reward-Shaped Deep Reinforcement Learning (RS-DRL) for efficient uncertainty management in SAS. The proposed method integrates a Deep Q-Network (DQN) core within the standard MAPE-K control loop. The primary innovation is the "Randomized Reward Shaping" mechanism, which strategically redesigns a random subset of failed past experiences in the replay buffer with optimistic (pseudo-success) rewards. Crucially, the reward signal is gated by formal verification results from UPPAAL-SMC, ensuring that learning is guided by formal safety and quality constraints. While the formal model requires domain-specific configuration, the randomized shaping heuristic itself is domain-agnostic and does not require explicit goal coordinates or intensive domain expertise for exploration. Experimental evaluation was conducted on the DeltaIoT exemplar within wireless sensor network scenarios featuring adaptation spaces of up to 4096 configurations. The results demonstrate that RS-DRL significantly outperforms state-of-the-art baselines, including DQN, HER, Soft HER, and DLASER+. Specifically, under the Threshold-based (TT) goal, RS-DRL achieved a 23.22% reduction in packet loss and a 39.07% reduction in latency compared to the DLASER+ baseline. Statistical analysis confirms the robustness and scalability of the proposed approach, establishing RS-DRL as a resilient optimization strategy for next-generation complex self-adaptive systems.

**Keywords:** Self-Adaptive Systems, Deep Reinforcement Learning, Randomized Reward Shaping, Uncertainty Management, Formal Verification, UPPAAL-SMC

Tarbiat Modares University
Faculty of Electrical and Computer Engineering

# Randomized Reward-Shaped Deep Reinforcement Learning for Managing Uncertainty in Self-Adaptive Systems

A Thesis Submitted in Partial Fulfillment of the Requirement for the Degree of Doctor of Philosophy in Computer Engineering

By:

**Alireza Kavianifar**

Supervisor:

**Dr. ...**

Advisor:

**Dr. ...**

February 2026