





دانشگاه تربیت مدرس

دانشکده مهندسی برق و کامپیوتر

رساله دکتری در رشته مهندسی کامپیوتر

گرایش نرم افزار

یادگیری تقویتی عمیق با شکل دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم های خودوفقی

علیرضا کاویانی فر

استاد راهنما

دکتر ...

استاد مشاور

دکتر ...

بهمن ۱۴۰۴

تأییدیهی هیأت داوران جلسهی دفاع از رساله

خانم/آقای علیرضا کاویانی فر رساله — واحدی خود را با عنوان یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم‌های خودوفقی در تاریخ بهمن ۱۴۰۴ ارائه کردند. اعضای هیأت داوران نسخه نهایی این رساله را از نظر فرم و محتوا تایید کرده است و پذیرش آنرا برای تکمیل درجه دکتری پیشنهاد می‌کنند.

آیین نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهشهای علمی دانشگاه تربیت مدرس

مقدمه: با عنایت به سیاست های پژوهشی و فناوری دانشگاه در راستای تحقق عدالت و کرامت انسانها که لازمه شکوفایی علمی و فنی است و رعایت حقوق مادی و معنوی دانشگاه و پژوهشگران، لازم است اعضای هیأت علمی، دانشجویان، دانش آموختگان و دیگر همکاران طرح، در مورد نتایج پژوهشهای علمی که تحت عناوین پایان نامه، رساله و طرحهای تحقیقاتی با هماهنگی دانشگاه انجام شده است، موارد زیر را رعایت نمایند:

ماده ۱- حق نشر و تکثیر پایان نامه/رساله و درآمدهای حاصل از آنها متعلق به دانشگاه می باشد ولی حقوق معنوی پدید آورندگان محفوظ خواهد بود.

ماده ۲- انتشار مقاله یا مقالات مستخرج از پایان نامه/رساله به صورت چاپ در نشریات علمی و یا ارائه در مجامع علمی باید به نام دانشگاه بوده و با تایید استاد راهنمای اصلی، یکی از اساتید راهنما، مشاور و یا دانشجو مسئول مکاتبات مقاله باشد. ولی مسئولیت علمی مقاله مستخرج از پایان نامه و رساله به عهده اساتید راهنما و دانشجو می باشد. تبصره: در مقالاتی که پس از دانش آموختگی بصورت ترکیبی از اطلاعات جدید و نتایج حاصل از پایان نامه/رساله نیز منتشر می شود نیز باید نام دانشگاه درج شود.

ماده ۳- انتشار کتاب، نرم افزار و یا آثار ویژه (اثری هنری مانند فیلم، عکس، نقاشی و نمایشنامه) حاصل از نتایج پایان نامه/رساله و تمامی طرحهای تحقیقاتی کلیه واحدهای دانشگاه اعم از دانشکده ها، مراکز تحقیقاتی، پژوهشکده ها، پارک علم و فناوری و دیگر واحدها باید با مجوز کتبی صادره از معاونت پژوهشی دانشگاه و براساس آئین نامه های مصوب انجام شود.

ماده ۴- ثبت اختراع و تدوین دانش فنی و یا ارائه یافته ها در جشنواره های ملی، منطقه ای و بین المللی که حاصل نتایج مستخرج از پایان نامه/رساله و تمامی طرحهای تحقیقاتی دانشگاه باید با هماهنگی استاد راهنما یا مجری طرح از طریق معاونت پژوهشی دانشگاه انجام گیرد.

ماده ۵- این آیین نامه در ۵ ماده و یک تبصره در تاریخ ۸۷/۴/۱ در شورای پژوهشی و در تاریخ ۸۷/۴/۲۳ در هیأت رئیسه دانشگاه به تایید رسید و در جلسه مورخ ۸۷/۷/۱۵ شورای دانشگاه به تصویب رسیده و از تاریخ تصویب در شورای دانشگاه لازم الاجرا است.

اینجانب علیرضا کاویانی فر به شماره دانشجویی ... دانشجوی رشته مهندسی کامپیوتر مقطع تحصیلی دکتری دانشکده مهندسی برق و کامپیوتر متعهد می شوم کلیه نکات مندرج در آئین نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهش های علمی دانشگاه تربیت مدرس را در انتشار یافته های علمی مستخرج از

پ

پایان نامه/رساله تحصیلی خود رعایت نمایم. در صورت تخلف از مفاد آئین نامه فوق الاشعار به دانشگاه وکالت و نمایندگی می دهم که از طرف اینجانب نسبت به لغو امتیاز اختراع بنام بنده و یا هر گونه امتیاز دیگر و تغییر آن به نام دانشگاه اقدام نماید. ضمناً نسبت به جبران فوری ضرر و زیان حاصله بر اساس برآورد دانشگاه اقدام خواهم نمود و بدینوسیله حق هر گونه اعتراض را از خود سلب نمودم»

تاریخ و امضا:

آیین نامه چاپ پایان نامه (رساله) های دانشجویان دانشگاه تربیت

مدرس

نظر به اینکه چاپ و انتشار پایان نامه (رساله) های تحصیلی دانشجویان دانشگاه تربیت مدرس، مبین بخشی از فعالیتهای علمی- پژوهشی دانشگاه است بنابراین به منظور آگاهی و رعایت حقوق دانشگاه، دانش آموختگان این دانشگاه نسبت به رعایت موارد ذیل متعهد می شوند: ماده ۱: در صورت اقدام به چاپ پایان نامه (رساله) ی خود، مراتب را قبلاً به طور کتبی به «دفتر نشر آثار علمی» دانشگاه اطلاع دهد. ماده ۲: در صفحه سوم کتاب (پس از برگ شناسنامه) عبارت ذیل را چاپ کند: «کتاب حاضر، حاصل پایان نامه کارشناسی ارشد/ رساله دکتری نگارنده در رشته مهندسی کامپیوتر است که در بهمن ۱۴۰۴ در دانشکده مهندسی برق و کامپیوتر دانشگاه تربیت مدرس به راهنمایی سرکار خانم/جناب آقای دکتر ...، مشاوره سرکار خانم/جناب آقای دکتر ... از آن دفاع شده است.» ماده ۳: به منظور جبران بخشی از هزینه های انتشارات دانشگاه، تعداد یک درصد شمارگان کتاب (در هر نوبت چاپ) را به «دفتر نشر آثار علمی» دانشگاه اهدا کند. دانشگاه می تواند مازاد نیاز خود را به نفع مرکز نشر در معرض فروش قرار دهد. ماده ۴: در صورت عدم رعایت ماده ۳، ۵۰٪ بهای شمارگان چاپ شده را به عنوان خسارت به دانشگاه تربیت مدرس، تأدیه کند. ماده ۵: دانشجو تعهد و قبول می کند در صورت خودداری از پرداخت بهای خسارت، دانشگاه می تواند خسارت مذکور را از طریق مراجع قضایی مطالبه و وصول کند؛ به علاوه به دانشگاه حق می دهد به منظور استیفای حقوق خود، از طریق دادگاه، معادل وجه مذکور در ماده ۴ را از محل توقیف کتابهای عرضه شده نگارنده برای فروش، تامین نماید. ماده ۶: اینجانب علیرضا کاویانی فر دانشجوی رشته مهندسی کامپیوتر مقطع دکتری تعهد فوق و ضمانت اجرایی آن را قبول کرده، به آن ملتزم می شوم.

استاد راهنما: دکتر ...

تاریخ:

امضا:

تقديم

(متن تقديم به خانواده، اساتيد و ...)

قدردانی

(متن تشکر و قدردانی از اساتید راهنما، مشاور و دوستان)

علیرضا کاویانی فر

بهمن ۱۴۰۴

چکیده

سیستم‌های نرم‌افزاری معاصر به طور فزاینده‌ای در محیط‌های پویا و همراه با عدم قطعیت عمل می‌کنند. این عدم قطعیت‌ها که ناشی از عواملی مانند تداخل شبکه، نوسانات بار ترافیکی یا تغییرات محیطی هستند، می‌توانند به طور جدی اهداف کیفی سیستم را به خطر اندازند. سیستم‌های خودوفقی (Self-Adaptive Systems) با بهره‌گیری از حلقه‌های بازخوردی، راهکاری بنیادین برای مقابله با این چالش ارائه می‌دهند. با این حال، چالش اصلی زمانی بروز می‌کند که این سیستم‌ها با فضای وفقی وسیع (شامل صدها یا هزاران گزینه پیکربندی) مواجه می‌شوند. روش‌های موجود، از جمله روش‌های مبتنی بر یادگیری ماشین، جستجو، و حتی یادگیری تقویتی کلاسیک، در چنین فضاهایی با مشکلاتی نظیر نیاز به داده‌های برجسب‌دار، عدم مقیاس‌پذیری، و مهم‌تر از همه، گرفتار شدن در بهینه‌های محلی و عدم توانایی تعمیم به شرایط محیطی جدید مواجه هستند. هدف اصلی این رساله، توسعه و اعتبارسنجی روشی نوین مبتنی بر یادگیری تقویتی عمیق با مکانیسم شکل‌دهی تصادفی پاداش (Randomized Reward-Shaped Deep Reinforcement Learning - RS-DRL) برای مدیریت کارآمد عدم قطعیت در این سیستم‌ها است. روش پیشنهادی، هسته یادگیری خود را بر پایه شبکه‌های کیو-عمیق (DQN) استوار ساخته و آن را درون چارچوب استاندارد مدیریت خودمختار MAPE-K یکپارچه می‌سازد. در این معماری، سیگنال محیطی با نتایج حاصل از بازبینی صوری توسط ابزار UPPAAL-SMC ترکیب شده تا عامل یادگیرنده تحت هدایت محدودیت‌های صوری آموزش ببیند. نوآوری اصلی رساله، مکانیسم «شکل‌دهی تصادفی پاداش» است که طی آن، زیرمجموعه‌ای تصادفی از تجربیات ناموفق گذشته با تخصیص پاداش خوش‌بینانه بازطراحی می‌شوند. اگرچه پیکربندی مدل صوری نیازمند دانش دامنه است، اما مکانیسم شکل‌دهی تصادفی پیشنهادی به خودی خود مستقل از دامنه بوده و نیاز به دانش صریح از اهداف (Domain Knowledge) برای اکتشاف ندارد. ارزیابی تجربی بر روی مطالعه موردی DeltaIoT (در شبکه‌های حسگر بی‌سیم) با فضاهای وفقی تا ۴۰۹۶ گزینه، نشان‌دهنده برتری قاطع روش RS-DRL نسبت به روش‌های پایه از جمله DQN، HER، Soft HER و DLASER+ است. به عنوان مثال، در هدف آستانه‌ای TT، روش پیشنهادی موفق به کاهش نرخ اتلاف بسته تا ۲۲/۲۳٪ و کاهش تأخیر تا ۰۷/۳۹٪ در مقایسه با روش DLASER+ به عنوان قوی‌ترین رقیب پژوهش گردید. تحلیل‌های آماری معنادار صحت و استواری نتایج را در شرایط پویای محیطی تأیید می‌کنند. یافته‌های این رساله نشان می‌دهد که رویکرد RS-DRL یک استراتژی بهینه‌سازی مقاوم و خودوفق برای نسل بعدی سیستم‌های نرم‌افزاری پیچیده است.

واژگان کلیدی: سیستم‌های خودوفقی، یادگیری تقویتی عمیق، شکل‌دهی تصادفی پاداش، مدیریت عدم قطعیت، بازبینی صوری، UPPAAL-SMC، فضاهای وفقی بزرگ، اینترنت اشیاء، شبکه‌های حسگر بی‌سیم

فهرست مطالب

ث	تقدیم
ز	فهرست جداول
ژ	فهرست تصاویر
س	فهرست نشانه‌ها و اختصارات

۱	۱ کلیات
۱	۱-۱ مقدمه
۱	۲-۱ اهداف رساله
۲	۳-۱ چالش‌ها
۳	۴-۱ بیان مسئله
۴	۵-۱ سوالات تحقیق
۵	۶-۱ روش پیشنهادی
۵	۱-۶-۱ مرور کلی بر راهکار RS-DRL
۵	۲-۶-۱ یکپارچه‌سازی با حلقه کنترل MAPE-K
۶	۷-۱ نوآوری‌های اصلی رساله
۶	۸-۱ مروری بر فصول رساله
۸	۲ مبانی نظری و مدل‌سازی سیستم
۸	۱-۲ مقدمه
۸	۲-۲ مبانی سیستم‌های خوددوفقی
۸	۱-۲-۲ مفاهیم اصلی و الگوهای معماری

۹	۲-۲-۲ چالش‌های عدم قطعیت در زمان اجرا
۱۰	۳-۲ مدل‌سازی عدم قطعیت در سیستم‌های خودوفقی
۱۰	۱-۳-۲ منابع عدم قطعیت
۱۰	۲-۳-۲ رویکردهای مدل‌سازی در زمان اجرا
۱۰	۳-۳-۲ مطالعه موردی انگیزشی: سیستم DeltaIoT
۱۱	۱-۳-۳-۲ مرور کلی سیستم و منابع عدم قطعیت
۱۱	۲-۳-۳-۲ فضای وفقی و بازنمایی پیکربندی
۱۲	۴-۲ یادگیری تقویتی برای وفقی‌سازی
۱۲	۱-۴-۲ اصول یادگیری تقویتی (MDP، یادگیری Q)
۱۲	۲-۴-۲ یادگیری تقویتی عمیق (DQN) برای فضاهای بزرگ
۱۳	۳-۴-۲ مفهوم یادگیری مداوم در حلقه‌های وفقی
۱۳	۴-۴-۲ مدل صوری برای تصمیم‌گیری تحت عدم قطعیت (ویژه DeltaIoT)
۱۴	۱-۴-۴-۲ تعریف فضای حالت
۱۴	۲-۴-۴-۲ فضای عمل: گزینه‌های وفقی گسسته
۱۴	۳-۴-۴-۲ فرمول‌بندی تابع پاداش
۱۵	۵-۲ بیان مسئله: یادگیری سیاست وفقی بهینه با عملیات مداوم
۱۶	۶-۲ خلاصه فصل

۳ مرور ادبیات و کارهای مرتبط

۱۷	۱-۳ مقدمه
۱۷	۲-۳ کارهای مرتبط: مدیریت فضاهای وفقی بزرگ
۱۷	۱-۲-۳ روش‌های مبتنی بر یادگیری ماشین (ML-based Methods)
۱۸	۲-۲-۳ روش‌های مبتنی بر جستجو (Search-based Methods)
۱۸	۳-۲-۳ روش‌های مبتنی بر یادگیری تقویتی (RL-based Methods)
	۴-۲-۳ شکل‌دهی پاداش و بازپخش تجربه با نگاه به گذشته (& Reward Shaping)
۱۹	(HER)
۱۹	۳-۳ سنتز و شناسایی شکاف تحقیقاتی
۲۰	۴-۳ خلاصه فصل

۴ روش پیشنهادی

۲۱

- ۱-۴ اصول معماری و سازماندهی فرآیند اجرایی ۲۱
- ۲-۴ فرآیند یکپارچه خودوفقی: حلقه سطح سیستم ۲۳
- ۳-۴ مسیر تصمیم‌گیری آنلاین: یک پیاده‌روی در معماری ۲۵
- ۱-۳-۴ گام اول: پایش و ساخت وضعیت (Monitor) ۲۵
- ۲-۳-۴ گام دوم: تحلیل و تشخیص ضرورت تطبیق (Analyze) ۲۵
- ۳-۳-۴ گام سوم: برنامه‌ریزی و استنتاج تطبیقی (Plan) ۲۶
- ۴-۳-۴ گام چهارم: اعتبارسنجی، بازخورد و اجرا (Execute به همراه Knowledge) .. ۲۶
- ۴-۴ معماری داخلی RS-DRL: تفکیک دغدغه‌ها در فرآیند یادگیری ۲۶
- ۵-۴ مکانیزم هسته: شکل‌دهی تصادفی پاداش ۲۸
- ۶-۴ مدیریت دانش و هماهنگی جریان‌ات نا همگام ۳۱
- ۷-۴ پوشش پرسش‌های پژوهش ۳۲
- ۸-۴ خلاصه فصل ۳۲

۵ ارزیابی تجربی

۳۴

- ۱-۵ مقدمه ۳۴
- ۲-۵ اهداف ارزیابی و سوالات تحقیق ۳۴
- ۳-۵ تنظیمات آزمایشگاهی ۳۵
- ۱-۳-۵ نمونه‌های مطالعه موردی ۳۵
- ۲-۳-۵ مجموعه داده‌ها ۳۶
- ۳-۳-۵ پلتفرم پیاده‌سازی ۳۶
- ۴-۳-۵ تنظیمات فرامترها (Hyperparameters) ۳۶
- ۴-۵ روش‌های پایه و مقایسه ۳۶
- ۵-۵ معیارهای ارزیابی ۳۷
- ۱-۵-۵ معیارهای عملکرد یادگیری عامل هوشمند ۳۷
- ۲-۵-۵ معیارهای عملکرد سیستم ۳۸
- ۶-۵ نتایج و تحلیل‌ها ۳۸
- ۱-۶-۵ منحنی‌های یادگیری و رفتار همگرایی ۳۸
- ۲-۶-۵ مقایسه عملکرد به ازای هر هدف ۴۰

۴۱	۳-۶-۵ ارزیابی مقایسه‌ای در برابر تمام روش‌های پایه
۴۲	۴-۶-۵ مطالعه ابلیشن: حساسیت به فاکتور شکل دهی ρ
۴۲	۵-۶-۵ تحلیل مقیاس‌پذیری
۴۳	۷-۵ اعتبارسنجی آماری
۴۴	۸-۵ خلاصه فصل

۴۵	۶ بحث، نتیجه‌گیری و پیشنهادها
۴۵	۱-۶ بحث در مورد یافته‌های کلیدی
۴۵	۱-۱-۶ نظریه‌پردازی مکانیزم: چرا RS-DRL کار می‌کند؟
	۲-۱-۶ تحلیل تعاملات و مصالحه‌ها (به‌عنوان مثال، تاخیر در مقابل از دست رفتن بسته)
۴۶	۳-۱-۶ پیامدهای مهندسی سیستم‌های خودوقتی
۴۸	۲-۶ محدودیت‌ها و تهدیدات اعتبار (Threats to Validity)
۴۸	۱-۲-۶ اعتبار داخلی (Internal Validity)
۴۸	۲-۲-۶ اعتبار خارجی (External Validity)
۴۹	۳-۲-۶ اعتبار سازه (Construct Validity)
۵۰	۳-۶ مسیرهایی برای تحقیقات آینده
۵۰	۱-۳-۶ استراتژی‌های انطباقی و وفقی شکل دهی ρ
۵۰	۲-۳-۶ گسترش به دامنه‌های پیوسته و حساس به ایمنی
۵۱	۳-۳-۶ اعتبارسنجی بین‌دامنه و تحلیل‌های نظری
۵۲	۴-۶ نتیجه‌گیری
۵۲	۱-۴-۶ خلاصه بیان مسئله و راهکار پیشنهادی
۵۲	۲-۴-۶ مرور مشارکت‌ها و شواهد تجربی
۵۳	۳-۴-۶ سخنان پایانی

۵۵	کتاب‌نامه
----	-----------

۵۷	آ جریان‌های کاری کامل فرآیند
----	------------------------------

۵۸	ب لیست کامل الگوریتم‌ها
----	-------------------------

فهرست جداول

۲۳	۱-۴ طبقه‌بندی زمانی فرآیندهای معماری RS-DRL
۳۲	۲-۴ قراردادهای تعاملی و همگام‌سازی جریان‌ات آنلاین و ناهمگام
۳۵	۱-۵ هم‌راستایی اهداف ارزیابی با سوالات تحقیق
۳۵	۲-۵ نمونه‌های مورد مطالعه سیستم DeltaIoT
۴۰	۳-۵ نتایج اهداف کمینه‌سازی در DeltaIoTv1 (پاداش مجانبی / گام‌ها)
۴۰	۴-۵ نتایج اهداف کمینه‌سازی در DeltaIoTv1.1
۴۱	۵-۵ عملکرد سیستم برای اهداف آستانه‌ای ترکیبی (TTS Goal)
۴۱	۶-۵ عملکرد سیستم برای اهداف آستانه‌ای مطلق (TT Goal)
۴۲	۷-۵ تحلیل مقیاس‌پذیری الگوریتم با بزرگ شدن فضای تطابق
۴۳	۸-۵ مقادیر احتمال (p-values) برای مقایسه‌های معنادار و غیرمعنادار
۵۲	۱-۶ خلاصه‌ای از مشارکت‌های کلیدی و شواهد تجربی

فهرست تصاویر

- ۱-۴ معماری سطح بالای رویکرد RS-DRL در قالب حلقه MAPE-K این نمودار تعامل میان سیستم مدیریت شونده، محیط، و مؤلفه‌های کنترلی را به همراه مخزن دانش (Knowl) edge مشترک نشان می‌دهد. ۲۲
- ۲-۴ نمودار فعالیت تفصیلی UML با خطوط شناوری (Swimlanes) برای تفکیک مسئولیت‌های پایش، تحلیل، برنامه‌ریزی و اعتبارسنجی. خط‌چین افقی مرز میان مسیر بحرانی آنالین و فرآیند یادگیری ناهمگام در پس‌زمینه را مشخص می‌کند. ۲۴
- ۳-۴ ساختار داخلی مؤلفه برنامه‌ریز RS-DRL در سه مسیر موازی: استنتاج (فقط‌خواندنی)، فیدبک (ترکیب پاداش محیطی و صوری)، و آموزش (به‌روزرسانی ناهمگام با استفاده از شکل‌دهی تصادفی پاداش). ۲۷
- ۴-۴ منطق عملیاتی مکانیزم شکل‌دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش‌بینانه پاداش‌های صفر با مقدار ۱ را بر اساس فاکتور ρ نشان می‌دهد (برچسب‌گذاری مجدد خوش‌بینانه، نه روش‌های مبتنی بر پتانسیل). ۲۸
- ۵-۴ جریان داده تفصیلی در مخزن دانش. این نمودار نحوه ذخیره‌سازی تجربیات در بافر بازپخش، اعمال مکانیزم شکل‌دهی تصادفی پاداش پیش از محاسبات گرادینان، و به‌روزرسانی سیاست‌های یادگیری در پس‌زمینه را به تصویر می‌کشد. ۳۱
- ۱-۵ منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1 (پاداش در برابر گام‌ها) ۳۹
- ۲-۵ منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1.1 ۳۹
- ۳-۵ تاثیر مقادیر مختلف ضریب شکل‌دهی ρ بر پاداش مجانبی و عملکرد کل ۴۲

فهرست نشانه‌ها و اختصارات

(لیست نمادهای ریاضی مانند ρ ، γ و اختصارات مانند DRL، SAS)

فصل ۱

کلیات

۱-۱ مقدمه

در حوزه مهندسی سیستم‌های نرم‌افزاری معاصر، پیچیدگی به عنوان یکی از بارزترین ویژگی‌ها خودنمایی می‌کند. محیط عملیاتی پویا نقشی محوری در شکل‌دهی به این پیچیدگی دارد و سیستم‌ها را ناگزیر می‌سازد تا با شرایط نامشخصی که اغلب تنها پس از عملیاتی شدن بروز می‌یابند، مقابله کنند.

سیستم‌های سنتی ایستا یا مبتنی بر قواعد، انعطاف‌پذیری لازم برای پاسخ به چنین تغییراتی در زمان اجرا را ندارند. در مقابل، سیستم‌های خودوقفی (SASs) مجهز به حلقه‌های بازخوردی هستند که به آن‌ها اجازه می‌دهد تا محیط و وضعیت خود سیستم را پایش کنند، انحرافات از رفتار مورد انتظار را تحلیل نمایند و به‌طور خودمختار استراتژی‌ها و تغییرات و فقی را برنامه‌ریزی و اجرا کنند.

تمرکز این رساله بر سیستم‌هایی با فضای و فقی گسسته و بزرگ است که نیاز فوری به راهکارهایی کارآمد برای انتخاب گزینه‌های بهینه در زمان اجرا دارند.

۲-۱ اهداف رساله

این رساله در راستای تکمیل شکاف‌های تحقیقاتی پیشین [۱] و پاسخ به چالش‌های حل‌نشده، یک هدف اصلی و سه هدف فرعی را دنبال می‌کند:

هدف اصلی

توسعه و اعتبارسنجی روش یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) به گونه‌ای که بر مشکل بنیادین گیرافتادن در بهینه‌های محلی در فضاها و فقی گسسته و بزرگ غلبه کند. این روش سیستم‌های خودوفقی را قادر می‌سازد تا بدون نیاز به بازآموزی پرهزینه و اخلاص گر، عملکردی نزدیک به بهینه را به طور پیوسته در شرایط عدم قطعیت محیطی حفظ نمایند.

این هدف اصلی، هسته‌ی نوآوری رساله (مکانیزم شکل‌دهی تصادفی پاداش) را مستقیماً به چالش اساسی شناسایی شده در بیان مسئله پیوند می‌دهد.

اهداف فرعی

در راستای تحقق هدف اصلی، اهداف فرعی زیر تعریف شده‌اند:

۱. طراحی معماری مقیاس‌پذیر و یکپارچه: ایجاد معماری مدولاری که عامل RS-DRL را به طور ناهمگام با حلقه‌ی خودمختار MAPE-K ادغام نموده و امکان اعتبارسنجی صوری تصمیمات پیش از اجرا را فراهم آورد. این هدف تضمین می‌کند که راهکار پیشنهادی نه تنها هوشمند، بلکه قابل اعتماد و قابل استقرار در سیستم‌های زمان‌اجرای واقعی باشد.

۲. مدیریت کارآمد فضاها و فقی گسسته با ابعاد بسیار بزرگ: نشان دادن این که روش RS-DRL قادر است در سیستم‌هایی با فضای و فقی تا ۴۰۹۶ گزینه (مانند DeltaIoT2)، بدون افت محسوس عملکرد، گزینه‌های بهینه یا نزدیک به بهینه را در زمان کوتاه انتخاب کند. این هدف، مقیاس‌پذیری عملی راهکار را برای کاربردهای دنیای واقعی اثبات می‌نماید.

۳. ارزیابی تجربی جامع و اثبات برتری آماری: مقایسه‌ی کمی دقیق روش RS-DRL با روش‌های پیشرفته‌ی موجود (شامل ϵ -greedy DQN، HER، Soft HER، DLASER و ML4EAS) از نظر عملکرد مجانبی، سرعت همگرایی، و بهینه‌سازی چندهدفه، همراه با ارائه‌ی تحلیل‌های آماری معنی‌دار (مانند t-test و فواصل اطمینان) برای تصدیق برتری روش پیشنهادی.

۱-۳ چالش‌ها

چالش‌ها و منابع عدم قطعیت در سیستم‌های مختلف به شکل‌های گوناگونی بروز می‌یابند. به عنوان مثال، در سیستم‌های مستقر در محیط‌های پویا نظیر برنامه‌های اینترنت اشیا (IoT) در شهرهای هوشمند، تغییرات

آب و هوایی تأثیر قابل توجهی می‌گذارد. همچنین محیط‌های ابری با تقاضای منابع متغیر، امنیت سایبری با تهدیدات نوظهور و مداوم، تجارت الکترونیک و شبکه‌های اجتماعی با رفتار غیرقابل پیش‌بینی کاربران، و سیستم‌های توزیع شده با تأخیر شبکه، خرابی سخت‌افزار و تغییرات زیرساختی روبه‌رو هستند. هنگامی که سیستم با فضای افقی گسترده و گزینه‌های متعدد تغییر مواجه می‌شود، انتخاب گزینه‌ای افقی که با اهداف سیستم همسو باشد، از نظر محاسباتی بسیار پرهزینه و دشوار، و در برخی موارد تقریباً غیرممکن می‌گردد.

روش‌های موجود برای مدیریت عدم قطعیت در سیستم‌های خودافقی با محدودیت‌های قابل توجهی مواجه هستند. به عنوان مثال، روش‌های مبتنی بر یادگیری ماشین نیازمند داده‌های آموزشی برچسب‌دار هستند که نمایانگر محیط سیستم باشند. به دست آوردن چنین داده‌هایی در زمان طراحی به دلیل عدم قطعیت فراوان بسیار دشوار است. از طرفی، روش‌های مبتنی بر جستجو (مانند الگوریتم‌های صعود تپه و الگوریتم‌های ژنتیک) با مشکلات مقیاس‌پذیری مواجه هستند و عملکرد آن‌ها با تغییر شرایط محیطی دچار افت محسوس می‌شود. یادگیری تقویتی عمیق (DRL) علیرغم قدرت بالا، خود با چالش‌های اساسی نظیر گیرافتادن در بهینه‌های محلی مواجه است. این چالش در سیستم‌هایی با فضای افقی گسسته و بزرگ به مراتب تشدید می‌شود؛ زیرا هرچه تعداد گزینه‌های افقی بیشتر باشد، احتمال همگرایی مدل به راه‌حل‌های بهینه‌ی محلی به جای بهینه‌های سراسری افزایش می‌یابد و کاوش کافی در فضای عمل دشوارتر می‌گردد. بهینه‌های محلی به راه‌حل‌هایی اشاره دارند که تنها در یک منطقه محدود از فضای مسئله بهینه هستند و به صورت سراسری بهترین راه‌حل ممکن محسوب نمی‌شوند. در زمینه DRL، این بدان معناست که مدل ممکن است سیاستی را یاد بگیرد که تحت شرایط خاص به خوبی عملکرد مناسبی دارد، اما در صورت تغییر محیط قادر به تعمیم‌پذیری و حفظ عملکرد مطلوب نیست.

علاوه بر این، آموزش مجدد یا بازآموزی (Retraining) مدل در زمان اجرا فرآیندی پرهزینه است. بازآموزی شامل مراحل متعددی مانند جمع‌آوری داده‌های جدید، ارزیابی مجدد ساختار و پارامترهای مدل، و تست مدل به‌روزشده برای اطمینان از عملکرد بهتر آن نسبت به نسخه قبلی است. در طول این فرآیند، سیستم ممکن است به صورت غیربهینه عمل کند که در سیستم‌های حیاتی، این دوره عملکرد نامطلوب می‌تواند پیامدهای جبران‌ناپذیری به همراه داشته باشد.

۱-۴ بیان مسئله

سیستم‌های خودافقی مدرن در محیط‌های پویا و غیرقابل پیش‌بینی نظیر شبکه‌های اینترنت اشیاء، رایانش ابری و شهرهای هوشمند عمل می‌کنند. این سیستم‌ها اغلب با فضاهای افقی گسسته و بزرگ مواجه هستند که

می‌تواند شامل صدها یا هزاران گزینه پیکربندی مختلف باشد (برای مثال، شبکه حسگر DeltaIoTv2 دارای ۴۰۹۶ گزینه افقی است).

مدل‌های سنتی یادگیری تقویتی عمیق (DRL) که برای تصمیم‌گیری در این فضاها به کار گرفته می‌شوند، با دو چالش بنیادین مواجه‌اند:

۱. **گیرافتادن در بهینه‌های محلی:** الگوریتم‌هایی مانند ϵ -greedy DQN به دلیل ماهیت کاوشگری محدود خود، اغلب در نقاط بهینه محلی متوقف می‌شوند و قادر به کشف سیاست‌های سراسری بهینه نیستند [۲]. این مشکل در فضاهای افقی بزرگ به مراتب حادتر می‌شود.

۲. **نیاز به بازآموزی مکرر و پرهزینه:** در مواجهه با تغییرات محیطی (رانش مفهومی [۳])، مدل‌های سنتی نیاز به بازآموزی کامل دارند. این فرآیند زمان‌بر، محاسباتی سنگین است و در طول دوره بازآموزی، سیستم عملکرد نامطلوبی از خود نشان می‌دهد که در سیستم‌های حیاتی می‌تواند پیامدهای جبران‌ناپذیری به همراه داشته باشد.

روش‌های پیشرفته‌تری مانند HER و Soft HER نیز اگرچه در حوزه محیط‌های هدف‌محور موفق بوده‌اند، اما برای سیستم‌های خودوفقی با اهداف مبهم و آستانه‌ای (مانند بهینه‌سازی همزمان مصرف انرژی، تأخیر و تلفات بسته) طراحی نشده‌اند و نمی‌توانند بدون دانش دامنه خاص عمل کنند. بنابراین، مسئله اصلی این رساله را می‌توان به صورت زیر فرموله کرد:

طراحی روش یادگیری تقویتی عمیق که (۱) بدون نیاز به بازآموزی مکرر و پرهزینه، از بهینه‌های محلی در فضاهای افقی گسسته و بزرگ (تا ۴۰۹۶ گزینه) عبور کند، (۲) قابلیت تعمیم‌پذیری به شرایط محیطی متغیر را داشته باشد، و (۳) مستقل از دانش دامنه خاص عمل کند.

۵-۱ سوالات تحقیق

با توجه به محدودیت‌های رویکردهای پیشین و نیز دستاوردهای آن‌ها که در بخش چالش‌ها تبیین گردید [۱]، این رساله در صدد پاسخ به پرسش‌های اساسی زیر است:

۱. **سوال اول:** چگونه می‌توان روشی مبتنی بر یادگیری تقویتی عمیق طراحی کرد که به‌طور مؤثر از بهینه‌های محلی در فضاهای افقی گسسته و بزرگ، بدون نیاز به بازآموزی مکرر و پرهزینه، عبور کند؟

۲. سوال دوم: چگونه می‌توان مکانیزم‌های شکل‌دهی تصادفی پاداش (Random Reward Shaping) را با بازپخش تجربه (Experience Replay) ادغام کرد تا تعمیم‌پذیری سیستم در تغییرات شرایط محیطی بهبود یابد؟

۳. سوال سوم: چگونه روش پیشنهادی می‌تواند فضاهاى وفقى گسسته و بزرگ (از ۲۱۶ تا ۴۰۹۶ گزینه) را در حین حفظ عملکردی نزدیک به بهینه، به شکل کارآمدی مدیریت کند؟

۴. سوال چهارم: تا چه حد روش پیشنهادی (RS-DRL) از روش‌های موجود نظیر یادگیری ای‌گرایانه حریصانه (ϵ -greedy DQN)، HER، Soft HER، DLASER و ML4EAS از منظر عملکرد مجانبی، سرعت همگرایی، و بهینه‌سازی چندهدفه، برتری و عملکرد بهتری از خود نشان می‌دهد؟

۱-۶ روش پیشنهادی

۱-۶-۱ مرور کلی بر راهکار RS-DRL

راهکار پیشنهادی در این رساله مبتنی بر توسعه یک معماری یادگیری هوشمند است که به جای تکیه بر دانش ایستا، از طریق تعامل مستقیم با محیط، سیاست‌های بهینه را استخراج می‌کند. این روش مسئله تطبیق را به‌عنوان یک فرآیند تصمیم‌گیری مارکوف (MDP) مدل‌سازی کرده و با ادغام مدل‌های عمیق و لایه مدیریت خودمختار، یک چرخه پیوسته از یادگیری و اجرا را فراهم می‌آورد. هسته نوآورانه این روش، مکانیزم «شکل‌دهی تصادفی پاداش» است که با بازطراحی تصادفی برخی تجربیات ناموفق گذشته، عامل را قادر به فرار از بهینه‌های محلی بدون نیاز به بازآموزی پرهزینه می‌سازد. تمرکز اصلی بر ارائه چارچوبی است که در آن، عامل یادگیرنده نه تنها بر اساس پاداش‌های آنی، بلکه با هدف حفظ عملکرد مطلوب در بازه زمانی طولانی، کاهش نیاز به بازآموزی‌های مکرر و پایداری معیارهای کیفی سیستم نظیر مصرف انرژی و زمان تأخیر، عمل کند.

۱-۶-۲ یکپارچه‌سازی با حلقه کنترلی MAPE-K

روش پیشنهادی با بهره‌گیری از چارچوب استاندارد MAPE-K، فرآیند تطبیق را به صورت ساختاریافته مدیریت می‌کند. در این معماری، عامل RS-DRL در مؤلفه برنامه‌ریزی (Plan) مستقر شده و خروجی‌های آن (گزینه وفقی پیشنهادی) پیش از اجرا توسط ابزار تأیید صوری UPPAAL-SMC از نظر ایمنی و قابلیت اطمینان ارزیابی می‌گردند. سپس گزینه‌های تأییدشده بر روی سیستم مدیریت‌شونده اعمال می‌شوند. این یکپارچگی تضمین می‌کند که تصمیمات هوشمندانه‌ی عامل DRL تنها پس از اعتبارسنجی صوری به اجرا درآیند.

۱-۷ نوآوری‌های اصلی رساله

بنیان علمی و سهم پژوهشی این پایان‌نامه در قالب سه نوآوری اصلی زیر تبیین می‌گردد که هدف نهایی آن‌ها بهبود همگرایی و تعمیم‌پذیری در سیستم‌های خودوفقی است:

۱. نوآوری اول: الگوریتم یادگیری تقویتی با شکل‌دهی تصادفی پاداش (RS-DRL): ارائه یک مکانیزم

نویسنده که برخلاف روش‌های سنتی، برخی از تجربیات ناموفق گذشته را به صورت تصادفی بازطراحی می‌کند. با تخصیص پاداش مثبت به این تجربیات، فرآیند یادگیری تسریع یافته و از همگرایی مدل به بهینه‌های محلی جلوگیری می‌شود؛ بدین ترتیب، مدل بدون نیاز به بازآموزی مکرر و پرهزینه در برابر تغییرات محیطی مقاوم می‌گردد. این رویکرد الهام‌گرفته از یادگیری انسانی از اشتباهات است و بدون نیاز به دانش دامنه خاص، تعمیم‌پذیری مدل را در محیط‌های متنوع افزایش می‌دهد.

۲. نوآوری دوم: ادغام معماری RS-DRL در حلقه MAPE-K: طراحی یک معماری تلفیقی که در آن

فرآیند آموزش و استنتاج مدل عمیق به صورت ناهمگام با حلقه کنترل استاندارد سیستم‌های خودوفقی هماهنگ شده است. برخلاف رویکردهای پیشین که یادگیری را تنها به صورت همزمان یا آفلاین انجام می‌دهند، این معماری اجازه می‌دهد تا دانش آموخته شده در حافظه بازپخش به‌طور پیوسته در اتخاذ تصمیمات و فقی زمان اجرا نقش ایفا کند.

۳. نوآوری سوم: مدیریت فضای فقی مقیاس‌پذیر و گسسته: ارائه راهکاری کارآمد برای هدایت و

انتخاب پیکربندی در سیستم‌هایی با ابعاد بسیار بزرگ (تا ۴۰۹۶ گزینه‌ی فقی). در حالی که روش‌های سنتی مبتنی بر جستجو (مانند الگوریتم‌های ژنتیک و صعود تپه) در این ابعاد با چالش نفرین ابعاد و افت کارایی مواجه می‌گردند، این روش نشان داده است که می‌تواند با حفظ پایداری و بهبود چشم‌گیر معیارهایی نظیر زمان تأخیر و هدررفت داده‌ها، بر این چالش‌ها در محیط‌های پویای اینترنت اشیا غلبه نماید.

۱-۸ مروری بر فصول رساله

ساختار رساله به گونه‌ای طراحی شده است که به‌طور نظام‌مند روند توسعه، اجرا و ارزیابی رویکرد پیشنهادی را در اختیار خواننده قرار دهد. در ادامه، مرور خلاصه‌ای از هر یک از فصول آورده شده است:

فصل ۱: کلیات

در این فصل، کلیات پژوهش، بیان مسئله، اهداف و نوآوری‌های رساله به همراه سوالات تحقیق و مروری بر ساختار کل رساله ارائه می‌گردد.

فصل ۲: مبانی نظری و مدل سیستم

در این فصل، مفاهیم بنیادین نظری و مدل صوری سیستم ارائه می‌گردد. این فصل شامل مبانی سیستم‌های خودوفقی (حلقه K-MAPE)، منابع عدم قطعیت و رویکردهای مدل‌سازی زمان اجرا (از جمله ابزار-UPPAAL SMC)، و اصول یادگیری تقویتی (فرآیند تصمیم‌گیری مارکوف و الگوریتم DQN) است. سپس، سیستم شبکه‌ی DeltaIoT به عنوان مطالعه‌ی موردی معرفی شده و فضای حالت، فضای عمل و توابع پاداش به صورت ریاضی فرمول‌بندی می‌شوند. در نهایت، مسئله بهینه‌سازی سیاست وفقی به صورت صوری بیان می‌گردد.

فصل ۳: مرور ادبیات و کارهای مرتبط

با بهره‌گیری از چارچوب نظری فصل دوم، این فصل یک بررسی انتقادی و جامع از رویکردهای موجود برای مدیریت عدم قطعیت در سیستم‌های خودوفقی ارائه می‌دهد. روش‌های پیشین در سه دسته اصلی بررسی شده و با شناسایی شکاف تحقیقاتی، ضرورت ارائه‌ی راهکار نوین RS-DRL توجیه می‌گردد.

فصل ۴: روش پیشنهادی RS-DRL: معماری و الگوریتم

این فصل به تشریح دقیق الگوریتم RS-DRL اختصاص دارد. جزئیات الگوریتمی مکانیزم شکل‌دهی تصادفی پاداش، نحوه مدیریت حافظه بازپخش، و فرآیند آموزش عامل یادگیرنده به تفصیل بیان می‌گردد. همچنین نحوه اعتبارسنجی گزینه‌های وفقی پیش از اجرا توسط ابزار UPPAAL-SMC برای تضمین پایداری سیستم مورد بررسی قرار می‌گیرد.

فصل ۵: ارزیابی تجربی

نحوه تخصیص محیط شبیه‌سازی، سناریوهای متعدد پیکربندی شبکه، و پروتکل‌های مقایسه‌ی جامع مدل RS-DRL با استراتژی‌های رقیب در این فصل ارائه می‌گردد. ارائه‌ی شفاف معیارهای کلیدی دستاوردها شامل عملکرد مجانبی، سرعت همگرایی و تحلیل‌های آماری در این فصل مستند شده‌اند.

فصل ۶: بحث و نتیجه‌گیری

در این فصل، به بررسی مصالحه‌ها، محدودیت‌ها و چالش‌های باقی‌مانده پرداخته شده و نتیجه‌گیری کلی پیرامون مزیت‌های کاربردی راهکار نوین ارائه می‌شود. همچنین مسیرهایی جهت بسط رویکرد فعلی در آینده پیشنهاد می‌گردد.

فصل ۲

مبانی نظری و مدل سازی سیستم

۱-۲ مقدمه

هدف این فصل، ارائه‌ی چارچوب نظری مستحکمی است که درک صحیح راهکار پیشنهادی RS-DRL را ممکن می‌سازد. سیستم‌های نرم‌افزاری مدرن همواره با عدم قطعیت‌های مداوم مواجه هستند و باید در زمان اجرا به‌طور پیوسته ساختار و رفتار خود را با شرایط در حال تغییر وفق دهند. این فصل در ابتدا اصول اولیه سیستم‌های خودوفقی و مؤلفه‌های آن را تشریح می‌کند، سپس منابع عدم قطعیت و روش‌های مدل‌سازی آن را معرفی می‌نماید. در ادامه، با معرفی سیستم DeltaIoT به‌عنوان یک مطالعه موردی عینی، مبانی یادگیری تقویتی و الگوریتم DQN را در قالب این سیستم فرموله کرده و در نهایت مسئله اصلی رساله را به صورت صوری بیان می‌کنیم.

۲-۲ مبانی سیستم‌های خودوفقی

۱-۲-۲ مفاهیم اصلی و الگوهای معماری

سیستم‌های خودوفقی (Self-Adaptive Systems) یک رویکرد برجسته و مؤثر برای مقابله با عدم قطعیت به شمار می‌روند. ایده کلیدی در این سیستم‌ها، تجهیز آن‌ها به یک یا چند حلقه بازخوردی کنترلی است که به صورت مداوم مؤلفه‌های داخلی سیستم و محیط خارجی آن را پایش کرده و در صورت نیاز سیستم را با تغییرات منطبق می‌نمایند [۱].

مهمترین و شناخته‌شده‌ترین الگوی معماری برای پیاده‌سازی این سیستم‌ها، حلقه خودمختار MAPE-K است. این حلقه در کنار سیستم هدف و منطق کسب‌وکار، جریان کنترلی زیر را اعمال می‌کند:

- **پایش (Monitor):** سنسورها وضعیت محیط فیزیکی، زیر ساخت و خود سیستم را به صورت زمان حقیقی استخراج می کنند.
- **تحلیل (Analyze):** داده های پایش شده را پردازش کرده و مشخص می کند که آیا انحرافی از اهداف کیفی و کمی سیستم رخ داده است و نیاز به اعمال تغییر وجود دارد یا خیر.
- **برنامه ریزی (Plan):** در صورت نیاز تطبیق، راهکارها و استراتژی های موجود (گزینه های وفقی) مقایسه شده و گزینه بهینه برای شرایط فعلی برگزیده می شود.
- **اجرا (Execute):** استراتژی برنامه ریزی شده در قالب یک سری از دستورات اجرایی از طریق عملگرها (Actuators) بر روی سیستم اعمال می گردد.
- **دانش (Knowledge):** به عنوان حافظه مرکزی عمل کرده و اطلاعات، مدل ها و داده های بین چهار مرحله قبلی را هماهنگ و نگهداری می کند. راهکار پیشنهادی ما (RS-DRL) مستقیماً به عنوان هسته اصلی بخش برنامه ریزی در این الگو فعالیت می کند.

۲-۲-۲ چالش های عدم قطعیت در زمان اجرا

عدم قطعیت در سیستم های خودوفقی، به هرگونه انحراف از دانش قطعی اطلاق می شود که می تواند باعث کاهش اطمینان نسبت به تصمیمات زمان اجرا گردد [۱].

به عنوان نمونه های عینی، می توان به موارد گوناگونی در دامنه های مختلف اشاره کرد: در برنامه های مبتنی بر اینترنت اشیا (IoT) که در محیط های شهری پراکنده هستند، تغییرات مداوم و غیرقابل پیش بینی آب و هوا منجر به افت کیفیت سیگنال و اختلال در ارسال اطلاعات سنسورها می شود. در محیط های ابری، نوسان شدید در تقاضای منابع از سوی کاربران، و در حوزه های امنیتی، ظهور بی وقفه و تصادفی حملات سایبری از مصادیق برجسته عدم قطعیت هستند.

اهمیت و چالش برانگیز بودن عدم قطعیت از آنجا نشأت می گیرد که مفروضات، پیکربندی ها و تصمیمات در نظر گرفته شده در فاز طراحی معماری نرم افزار را بی اعتبار می سازد. در نتیجه، سیستم باید قادر باشد با یادگیری آنلاین و پویا در زمان اجرا، اهداف اصلی خود را محقق نماید؛ وگرنه با نقض کیفیت خدمات صدمات سنگین احتمالی را تجربه خواهد نمود.

۳-۲ مدل سازی عدم قطعیت در سیستم های خودوقتی

۱-۳-۲ منابع عدم قطعیت

منابع عدم قطعیت به طور کلی در سه دسته وسیع طبقه بندی می شوند: نخست، نامشخص بودن موجودیت های محیطی نظیر پارازیت در حسگرها، نویزها و تغییرات جوی که از کنترل ساختار درونی سیستم خارج هستند. دوم، ماهیت غیرقابل اتکای منابع خود سیستم مثل نقص در قطعات زیربنایی، کاهش سریع سطح باتری یا مشکلات نرم افزاری تعاملات میان سرویس ها؛ و در نهایت عدم قطعیت در اهداف متغیر و ترجیحات نامشخص ذینفعان در محیط های تجاری.

۲-۳-۲ رویکردهای مدل سازی در زمان اجرا

جهت درک و محاسبه رفتار سیستم در هنگام بروز مقادیر ناشناخته، استفاده از مدل سازی های زمان اجرا (Run-time Models) ضروری به نظر می رسد. در شرایطی که فضای جستجو بسیار بزرگ و مخاطره تصمیم گیری به دلیل شرایط مبهم بالاست، رویکرد پیشنهادی از مکانیزم های مدل سازی ریاضی صوری بهره گیری و پشتیبانی می کند.

در این راستا ابزارهایی مانند موتور UPPAAL-SMC (Statistical Model Checking) — واریسی مدل آماری) و چارچوب ActivFORMS به کار گرفته می شوند. این زیرساخت ها با استفاده از اتوماتای زمان دار (Timed Automata) مدلی رفتاری از سیستم هدف و محیط آن را توسعه داده و از طریق روش های واریسی مدل آماری می توانند به سرعت گزینه های وقتی پیشنهاد شده توسط سیستم هوشمند را پیش از اجرا در سیستم فیزیکی ارزیابی، تایید یا رد کنند. در واقع، این روش با برآورد آماری احتمال نقض اهداف کیفی خدمات (QoS)، امنیت تصمیمات را تضمین می کند. این قابلیت نقشی کلیدی در امنیت راهکار پیشنهادی (در بخش تاییدگر گزینه وقتی) این رساله ایفا می کند.

۳-۳-۲ مطالعه موردی انگیزشی: سیستم DeltaIoT

برای عینی تر ساختن این مفاهیم انتزاعی در یک محیط عملیاتی، در ادامه سیستم DeltaIoT را معرفی می کنیم؛ یک شبکه حسگر بی سیم که به عنوان یک معیار استاندارد، چالش های اصلی فضاهای وقتی بزرگ و عدم قطعیت های محیطی را به خوبی به تصویر می کشد.

۲-۳-۳-۱ مرور کلی سیستم و منابع عدم قطعیت

سیستم DeltaIoT یک شبکه حسگر بی سیم (WSN) با تعاملات پیچیده است که به صورت گسترده به عنوان یک محک استاندارد (Benchmark) برای ارزیابی سیستم های خودوقتی به کار می رود [۱]. این شبکه بسته به نسخه مورد استفاده، مابین ۱۵ تا ۳۷ گره (سنسور) دارد. دو منبع اصلی عدم قطعیت در این سیستم در زمان اجرا بروز می یابند:

۱. نویز و تداخل شبکه (Network Interference/Noise): تغییرات محیطی و مداخلات پیرامونی که

موجب نوسانات پیش بینی نشده در کیفیت ارتباطات از -40dB تا +15dB می گردد.

۲. تغییرپذیری بار پیام ها (Message Load Variability): نوسان در تعداد پیام های تولید شده توسط

هر سنسور (بین ۰ تا ۱۰ پیام) با الگوهای انتقال متفاوت در طول زمان.

همانطور که در مطالعات پیشین (و روند نشان داده شده در شکل ۲ مقاله مرجع) نمایان است، این عدم قطعیت ها باعث شکل گیری افت شدید عملکرد سیستم در طی چرخه های وفقی گشته و اهمیت حیاتی مکانیسم های تطابق پویا را برجسته می کنند.

۲-۳-۳-۲ فضای وفقی و بازنمایی پیکربندی

فضای وفقی (Adaptation Space) دربرگیرنده مجموعه تمامی گزینه ها و پیکربندی های ممکن است که سیستم می تواند در زمان اجرا اتخاذ نماید. در DeltaIoT، سه نسخه متفاوت با مشخصاتی به شرح زیر طراحی گردیده است [۱]:

• **DeltaIoTv1**: شامل ۱۵ سنسور و دارای ۲۱۶ گزینه وفقی متمایز.

• **DeltaIoTv1.1**: شامل ۱۶ سنسور و دربرگیرنده ۱۲۹۶ گزینه وفقی است.

• **DeltaIoTv2**: نسخه وسیع تر این شبکه متشکل از ۳۷ سنسور که دارای فضای عظیم متشکل از ۴۰۹۶ تصمیم ممکن می باشد. توجه داشته باشید که ابعاد این فضا از ترکیب سطوح مختلف توان انتقال و توزیع مسیرهای شبکه حاصل شده است.

هریک از این گزینه های وفقی در حقیقت ترکیبی از پارامترهای مختلف هستند؛ نظیر سطوح توان انتقال انرژی (Transmission Power) برای سنسورهای مشخص و توزیع نسبی مسیرهای شبکه ای (Link Distribution). انتخاب یک ترکیب از این پارامترها، یک پیکربندی کاملاً جدید و واحد را شکل می دهد.

۲-۴ یادگیری تقویتی برای وفقی سازی

۱-۲-۴ اصول یادگیری تقویتی (MDP، یادگیری Q)

یادگیری تقویتی از طریق تعامل مستمر یک عامل (Agent) با محیط اطرافش بر پایه آزمون و خطا بنا شده است و این محیط به لحاظ ریاضی از طریق فرآیند تصمیم گیری مارکوف (MDP) فرموله می شود. فرآیند MDP خود شامل فضای حالت (State)، فضای عمل (Action) و توابع پاداش (Reward) است. فرآیند تصمیم گیری مارکوف، برای هر حالت خاص، عامل عمل مشخصی را اتخاذ می کند و مطابق با معادله مشهور بلمن (Bellman Equation) محیط ارزش عمل اتخاذ شده را در قالب یک پاداش ارزیابی می نماید و به وضعیت بعدی منتقل می شود. این مفهوم در سیستم های خودوفقی مانند محیط DeltaIoT به این صورت اعمال می گردد که وضعیت سیستم با معیارهایی نظیر انرژی ذخیره شده سیستم و تاخیر اندازه گیری شده فضای حالت را تشکیل می دهند و اقدام عامل، همان گزینه وفقی مورد انتخاب خواهد بود و محاسبه پاداش نیز طبق معادله بهینه سازی سیستم حاصل می گردد. نقش الگوریتم مشهور یادگیری Q ایجاد جدولی جامع برای تخصیص و پیدا کردن ارزش هاست تا مدل به سیاست بهینه همگرا شود.

۲-۴-۲ یادگیری تقویتی عمیق (DQN) برای فضاهای بزرگ

اما زمانی که با سیستم های واقعی که دارای فضای عمل گسسته ولی بسیار پهناور (برای مثال ۴۰۹۶ گزینه وفقی در شبکه های اینترنت اشیا) مواجه هستیم، استفاده از متد کلاسیک یادگیری Q با چالش نفرین ابعاد (Curse of Dimensionality) روبه رو می شود؛ زیرا ذخیره و بروزرسانی جدولی با میلیون ها حالت و عمل از لحاظ محاسباتی ناکارآمد و در بسیاری موارد غیرممکن است.

شبکه های Q عمیق (DQN) راهکاری هوشمندانه برای این محدودیت ارائه می دهند؛ آن ها به جای جداول، تابع ارزش کیفیت Q را با استفاده از شبکه های عصبی عمیق تقریب می زنند. برای غلبه بر بی ثباتی آموزش شبکه های عصبی در RL، مدل DQN از دو نوآوری برجسته بهره می برد: نخست استفاده از مکانیسم حافظه بازپخش تجربه (Experience Replay) که نمونه های آموزشی تصادفی سازی شده و باعث شکستن همبستگی زمانی متوالی می گردد؛ و دوم تعبیه هدف ثابت به واسطه شبکه هدف ثابت (Target Network) که بهبود تثبیت توابع هزینه را در هنگام محاسبه پیش بینی ها به دنبال دارد.

علیرغم موفقیت DQN در فضاهای بزرگ، این الگوریتم ها به طور ذاتی مستعد گیر افتادن در بهینه های محلی هستند، به ویژه زمانی که محیط غیرایستا (non-stationary) باشد. دلیل اصلی آن استراتژی کاوش ϵ -greedy است که پس از همگرایی اولیه، کاوش مؤثر را متوقف می کند. در سیستم های خودوفقی با فضای

وفقی بزرگ، این مشکل حادث می شود، زیرا تغییرات محیطی می توانند سیاست بهینه را جابهجا کنند، در حالی که عامل همچنان در سیاست قدیمی گیر افتاده است. روش پیشنهادی این رساله (RS-DRL) در فصل ۴ با معرفی مکانیزم شکل دهی تصادفی پاداش به این چالش می پردازد.

۳-۴-۲ مفهوم یادگیری مداوم در حلقه های وفقی

اصلی ترین کاربرد این رساله، ادغام مفهوم آموزش پیوسته و مداوم توسط عامل DQN در چارچوب معماری خودوفقی و به طور خاص درون حلقه MAPE-K (همانطور که در فصل های آتی به تفصیل نشان داده خواهد شد) است. پس از جاگذاری در مؤلفه برنامه ریزی (Planner)، عامل یادگیرنده وضعیتی را به عنوان ورودی فضای حالت از مازول پایش دریافت نموده، استراتژی اقدام را برنامه ریزی کرده و بر اساس میزان موفقیت انتخابش از سوی مؤلفه تحلیل پاداش می گیرد. این ساختار تعاملی، سیستم خودوفقی را از پیکربندی ایستا به ساختار یادگیری پویا تبدیل می سازد. مفهوم یادگیری مداوم در اینجا به معنای به روزرسانی ناهمگام (Asynchronous) شبکه عصبی در پس زمینه است؛ به طوری که عامل همزمان با عملکرد سیستم، از تجربیات جدید برای بهبود تدریجی سیاست خود بهره می برد.

در فصل ۳، روش های موجود شکل دهی پاداش (مانند HER) مرور خواهند شد، و در فصل ۴، نوآوری این رساله یعنی شکل دهی تصادفی پاداش به عنوان راهکاری برای غلبه بر بهینه های محلی معرفی می گردد.

۴-۴-۲ مدل صوری برای تصمیم گیری تحت عدم قطعیت (ویژه DeltaIoT)

با تبیین مبانی نظری فرآیند تصمیم گیری مارکوف و شبکه های DQN، اکنون این چارچوب را برای سیستم DeltaIoT پیاده سازی می کنیم. در ادامه، فضای حالت، فضای عمل و توابع پاداش اختصاصی که در طول این رساله مورد استفاده قرار می گیرند، تعریف خواهند شد.

برای امکان پذیر کردن یادگیری تقویتی، نیاز به فرمول بندی مسأله تطابق شبکه در قالب یک فرآیند تصمیم گیری مارکوف (MDP) داریم که نمایانگر چهارگانه (S, A, R, P) است [۱]. در اینجا P نمایش دهنده تابع احتمال انتقال است؛ هرچند در روش های یادگیری تقویتی مدل آزاد مانند DQN، عامل بدون نیاز به دانستن صریح P و مستقیماً از طریق تعامل با محیط یاد می گیرد.

۱-۴-۴-۲ تعریف فضای حالت

فضای حالت مدل، وضعیت فعلی و پویای سیستم را با اندازه گیری سه معیار حیاتی عملکرد بازتاب می دهد. به بیان رسمی:

$$S = \{(E, P, L) \mid E \in \mathbb{R}, P \in [0, 100], L \in [0, 100]\}$$

که در آن:

- انرژی مصرفی (E): مقدار حقیقی نمایانگر انرژی کل مصرفی توسط تمام سنسورهای شبکه در چرخه پیشین است.
- تلفات بسته های شبکه (P): درصدی از پیام های تولید شده که در طول مسیر به مقصد (دروازه اصلی) از دست رفته اند (بین ۰ تا ۱۰۰ درصد).
- تاخیر ارسال (L): معیاری معادل زمان مورد نیاز جهت رسیدن اطلاعات از سنسورها به گیت وی (حداکثر بازه ۱۰۰).

۲-۴-۴-۲ فضای عمل: گزینه های وفقی گسسته

فضای عمل شامل تمامی استراتژی ها و پیکربندی های ممکن به صورت مجموعه ای از گزینه های گسسته تعریف می شود:

$$A = \{a_1, a_2, \dots, a_n\}$$

مقدار n بسته به ابعاد شبکه DeltaIoT برابر با ۲۱۶، ۱۲۹۶ یا ۴۰۹۶ در نظر گرفته می شود. هر عمل a_i نمایانگر یک پیکربندی مشخص از پارامترهای $\{p_{i1}, p_{i2}, \dots, p_{im}\}$ است.

۳-۴-۴-۲ فرمول بندی تابع پاداش

بر اساس ماهیت سیستم و اهداف، از فرمول بندی های زیر استفاده می شود:

پاداش چندهدفه:

$$R = w_E \cdot \left(\frac{E_{max} - E}{E_{max} - E_{min}} \right) + w_P \cdot \left(\frac{P_{max} - P}{P_{max} - P_{min}} \right) + w_L \cdot \left(\frac{L_{max} - L}{L_{max} - L_{min}} \right)$$

وزن ها (w_i) مقادیر مثبتی هستند که معمولاً به گونه ای انتخاب می شوند که مجموع آن ها برابر یک باشد ($\sum w_i = 1$) تا مقدار کل پاداش در بازه $[0, 1]$ باقی بماند. مقادیر max و min نیز کران های عملیاتی هر معیار هستند که از داده های شبیه سازی استخراج شده اند.

پاداش تک هدفه:

$$R = \left(\frac{E_{max} - E}{E_{max} - E_{min}} \right) \cdot w_E$$

در پاداش تک هدفه، تنها هدف بیشینه سازی بهره وری مصرف انرژی است و ضریب w_E معمولاً برابر ۱ در نظر گرفته می شود.

اهداف آستانه ای (TTS و TT): تخصیص مقادیر پاداش مشروط به صورت دودویی:

$$R = \begin{cases} 1 & \text{اگر } P < \theta_P \text{ و } L < \theta_L \\ 0 & \text{در غیر این صورت} \end{cases}$$

که در آن θ_P و θ_L به ترتیب آستانه های پذیرش برای تلفات بسته و تاخیر هستند؛ برای مثال در ارزیابی های فصل ۵، مقادیر ۱۰٪ و ۵۰ میلی ثانیه منظور شده اند.

۲-۵ بیان مسئله: یادگیری سیاست وفقی بهینه با عملیات مداوم

پس از تعریف دقیق مؤلفه های MDP، اکنون می توانیم مسئله اصلی بهینه سازی را که روش پیشنهادی RS-DRL به دنبال حل آن است، به صورت صوری بیان کنیم. مسأله نهایی ما یادگیری سیاست وفقی بهینه $\pi^* : S \rightarrow A$ است که ارزش پاداش های تجمعی تنزیل یافته را حداکثر نماید:

$$\pi^* = \arg \max_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid \pi \right]$$

که در آن $\gamma \in [0, 1]$ ضریب تنزیل (Discount Factor) است و میزان اهمیت پاداش های آتی را نسبت به پاداش لحظه ای مشخص می کند.

با این حال، مسئله اصلی این رساله فراتر از بهینه سازی استاندارد است و باید سه قید عملیاتی را برآورده سازد:

۱. مقابله با بهینه‌های محلی: سیاست وفقی باید توانایی خروج از بهینه‌های محلی را بدون بازآموزی کامل داشته باشد، چرا که محیط به طور مداوم در حال تغییر است (non-stationary).
 ۲. فضای عمل گسسته و بسیار بزرگ: تعداد گزینه‌های وفقی می‌تواند تا ۴۰۹۶ حالت باشد (مانند DeltaIoTv2) که روش‌های جدول‌محور را غیرعملی می‌سازد.
 ۳. عدم وابستگی به دانش دامنه: برخلاف روش‌های مبتنی بر هدف (مانند HER)، راهکار پیشنهادی نباید به اهداف صریح یا آستانه‌های از پیش تعریف شده وابسته باشد.
- بنابراین، مسئله نهایی یافتن سیاستی است که نه تنها پاداش تجمعی را بیشینه کند، بلکه در شرایط فوق نیز پایدار و کارا باقی بماند.
- این سیاست باید همواره به‌طور مداوم در زمان اجرا عمل کرده و با چالش‌های عدم قطعیت محیطی، فضای عمل گسسته گسترده و پویایی غیرایستا (تغییر شرایط از یک چرخه به چرخه بعدی) مقابله نماید.

۲-۶ خلاصه فصل

این فصل چارچوب نظری و مدل‌سازی مورد نیاز برای درک رویکرد پیشنهادی را ترسیم نمود. ما با اصول سیستم‌های خودوفقی و الگوی MAPE-K آغاز کردیم و سپس منابع عدم قطعیت و روش‌های مدل‌سازی زمان اجرا را بررسی نمودیم. با استفاده از DeltaIoT به عنوان یک مطالعه موردی عینی، مسئله وفقی‌سازی را در قالب فرآیند تصمیم‌گیری مارکوف (MDP) فرموله کردیم که شامل تعریف دقیق فضای حالت (انرژی، تلفات، تاخیر)، فضای عمل (تا ۴۰۹۶ گزینه) و توابع پاداش چندهدفه بود. در نهایت، هدف بهینه‌سازی را به عنوان یادگیری یک سیاست وفقی برای عملیات مداوم در زمان اجرا بیان کردیم. این زیربنای صوری و عملیاتی، امکان نقد و بررسی دقیق‌تر کارهای پیشین در فصل ۳ و ارائه متدولوژی نوآورانه RS-DRL در فصل‌های آتی را فراهم می‌سازد.

فصل ۳

مرور ادبیات و کارهای مرتبط

۱-۳ مقدمه

هدف این فصل، ارائه یک بررسی انتقادی و جامع از رویکردهای موجود برای مدیریت عدم قطعیت در سیستم‌های خودوفقی است. با بهره‌گیری از مفاهیم نظری معرفی شده در فصل قبل، کارهای پیشین دسته‌بندی و نقاط قوت و ضعف هر رویکرد به دقت تحلیل می‌شود. این فصل نشان می‌دهد که چرا هیچ‌یک از رویکردهای موجود به تنهایی قادر به رفع چالش‌های جامع مدیریت فضاها و فقی بزرگ و گسسته در محیط‌های پویا و مبهم نیستند، و بدین ترتیب ضرورت ارائه‌ی راهکار نوین RS-DRL را اثبات خواهد نمود.

۲-۳ کارهای مرتبط: مدیریت فضاها و فقی بزرگ

دستیابی به کارایی مناسب در مدیریت محیط‌های مبهم بسیار کلیدی است. برای تبیین عمیق این مباحث، در ادامه به مقایسه انتقادی دسته‌بندی‌های موجود می‌پردازیم.

۱-۲-۳ روش‌های مبتنی بر یادگیری ماشین (ML-based Methods)

اولین دسته‌بندی کارهای مرتبط در به‌کارگیری یادگیری ماشین نظارت‌شده و پیش‌بینی‌کننده با هدف هرس و کاهش فضای جستجو متمرکز است. رویکرد محققانی چون کین (Quin) و همکارانش [۴، ۵] و مدل یادگیری برای ارزیابی کیفی ماشین (ML4EAS) توسعه یافته توسط کاجی و بواناکا [۶] نشان می‌دهند که الگوریتم‌های طبقه‌بندی و رگرسیون قادرند تعداد زیادی از گزینه‌های غیربهبهینه را تا پیش از ارسال به مؤلفه تحلیل‌گر، غربال کنند.

نقد رویکرد: اگرچه این روش‌ها در کاهش اندازه محیط عمل خود کارا هستند، اما وجود وابستگی بنیادین به مجموعه داده‌های با برجسب آموزش دیده، نقص متدولوژی است. تهیه مجموعه داده در زمان توسعه که همسان با متغیرهای غیرمترقبه واقعیت باشد غیرعملی است. متعاقباً با بروز رانش مفهومی (Concept Drift) ناشی از تغییر مداوم شرایط محیطی، این مدل‌های پیش‌آموزش دیده، عملکرد تعمیم یافته و کارآمد خود را در برخورد با رویه‌های ناشناخته از دست می‌دهند.

۲-۲-۳ روش‌های مبتنی بر جستجو (Search-based Methods)

متدولوژی کلاسیک دیگر برای پیمایش سریع فضاها و وسیع جستجو استفاده از راهبردهای اکتشافی است. برای مثال کوکر (Coker) از الگوریتم صعود تپه (Hill Climbing) استفاده کرده است [۷] و برنامه‌ریزی‌های مبتنی بر الگوریتم ژنتیک (Genetic Programming) که به قلمرو مقالات کینر (Kinneer) و همکاران اختصاص دارد [۸، ۹، ۱۰]. همچنین شبیه‌سازی جستجو با استفاده از رویکرد تکامل چند هدفه نظیر MOEA توسط چن (Chen) [۱۱]، از کاربردهای متداول است.

نقد رویکرد: هرچند ویژگی انطباق خودکار بدون آموزش در این رویکرد به چشم می‌خورد، اما چالش مقیاس‌پذیری، مانع استقرار کامل آن‌ها در پروژه‌های بلادرنگ است. اجرای مجدد جمعیت تکاملی همچون ژنتیک برای یافتن سناریوی مطلوب در پی هر گونه تطابق زمانی، مستلزم محاسبات بی‌نهایت پرهزینه و ایجاد تاخیر زیاد است؛ موضوعی که در شبکه‌های حساس تاخیرپذیر غیرقابل تحمل است.

۳-۲-۳ روش‌های مبتنی بر یادگیری تقویتی (RL-based Methods)

پیشرفت‌های حاصل شده در اتوماسیون برخط سیستم‌ها با کارهای کیم و پارک [۱۲]، متزگر [۱۳] و مدل RLMC توسط کامارا [۱۴] به دلیل تعامل بی‌وقفه پویایی‌های آنلاین شناخته شده است که عمدتاً براساس کلاسیک الگوریتم Q-Learning توسعه یافتند.

نقد رویکرد: الگوریتم کلاسیک در ابعاد بزرگ، همانند شبکه‌ای با میلیاردها ماتریس برای مدل‌سازی از پای در می‌آید و ناتوان از رسیدگی است. حتی تلاش‌هایی که با مدل پایه ارزیابی ما یعنی معماری حریصانه کلاسیک DQN با استراتژی ϵ -greedy صورت پذیرفته است، کماکان با مشکل شدید محدودیت روبه‌رو است؛ زیرا مدل پایه عامل هوشمندی را پرورش می‌دهد که اغلب در نقاط و قله‌های بهینه‌های محلی (Local Optima) متوقف شده، مانع قابلیت یافتن قله‌های اصلی (Global Optima) در دینامیک شرایط محیط می‌گردد.

۴-۲-۳ شکل دهی پاداش و بازپخش تجربه با نگاه به گذشته (Reward Shaping & HER)

بازپخش تجربه‌های ناموفق از موضوعات پرمباحثه و کلیدی در حوزه هوش مصنوعی است که مکانیزم مشهور یادگیری با نگاه به گذشته (HER) [۱۵] و مدل متأخر با رویکرد پاداش نرم‌تر (Soft HER) [۱۶] با استفاده از استراتژی برچسب‌گذاری مجدد هدف برای تجربیات ناموفق توانسته یادگیری محیط‌ها را سریع‌تر نمایند. نقد انطباق این رویکرد با حوزه خودوفقی: برتری این مدل‌های عمیق کاملاً محدود به طراحی‌های وابسته به هدف و صریح (Goal-Conditioned Environments) می‌باشد. به عبارت دیگر عامل باید یک مکان یا وضعیت شفاف (مانند موقعیت سه‌بعدی ابزار مکانیکی) را تصرف کند؛ در حالی که کنترل‌کننده‌های سیستم‌های خودوفقی اساساً و غالباً اهدافی به‌عنوان متغیر قطعی را دنبال نمی‌کنند، بلکه نگاه داشتن انرژی یا تاخیر شبکه در حداقل‌ها یک سیاست آستانه‌محور است که با استراتژی تغییر برچسب و ارزیابی در بازتولید HER با سازگاری اساسی تناقض دارد.

۳-۳ سنتز و شناسایی شکاف تحقیقاتی

با استناد به مطالب شرح داده شده و مروری جامع در کاستی مقالات پیشین، درمی‌یابیم که هیچ‌یک از دسته‌بندی‌های فعلی قادر به برطرف ساختن کل چالش‌ها به صورت جامع نبوده‌اند: راهکارهای یادگیری ماشین به پدیده‌های پیش‌بینی‌نشده محیط به دلیل فقدان آموزش آفلاین به شدت حساس و شکننده‌اند؛ مسیرهای اکتشاف جستجو با تاخیر غیرقابل قبولی مواجه می‌باشند. حتی اگر از رویکردهای مستعد DRL استفاده شود، روش‌های پایه مستعد توقیف در بهینه‌های محلی بوده و قابلیت فراگیری جامع در مقابل نوسانات متغیر محیطی را متجلی نمی‌کنند. علاوه بر این ابزارهای پیشرفته مانند تخصیص مقاصد بازپخش گذشته امکان استفاده‌ی کارآمد مبتنی بر اهداف نامشخص سیستم خودوفقی را دارا نیستند.

بر این اساس یک شکاف علمی و عملی مشخص برای ابداع چارچوبی مبرهن مطرح است که دارای ویژگی‌های زیر باشد: (۱) تسلط اثربخش در فضاها و وسیع و گسسته و فقی بدون استفاده از جداول سنتی مقیاس ناپذیر، (۲) فراگیری هوشمندانه برخط بدون اجبار استفاده از داده‌های آموزش دیده‌ی گذشته، (۳) مقابله سرسختانه با بهینه‌های محلی بدون از دست دادن همگرایی و افت در محیط تغییر یافته (نیاز به شکل‌دهی استراتژی آموزش)، و (۴) قابلیت پیوستگی با نیازهای غیرخطی یک سیستم خودوفقی بدون تغییر پارادایم تحمیلی به مسائلی متمرکز به تعیین هدف.

پیشنهاد بنیادی ما در این رساله مبتنی بر ایجاد یک مکانیزم جدید تلفیقی تحت عنوان یادگیری تقویتی

عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) است تا خلأ یاد شده کاملاً پر گشته و گامی کاربردی جهت ارتقای استقلال عوامل کنترلی نرم‌افزارهای پیچیده میسر گردد.

۳-۴ خلاصه فصل

این فصل با بهره‌گیری از پایه نظری ارائه‌شده در فصل دوم، مروری انتقادی و ساختاریافته بر ادبیات تحقیق ارائه داد. رویکردهای موجود برای مدیریت عدم قطعیت در سیستم‌های خودوفقی در سه دسته اصلی بررسی و مقایسه شدند. مشخص گردید که روش‌های غیرعامل‌محور با محدودیت‌های اساسی روبه‌رو هستند. با شناسایی این شکاف تحقیقاتی، ضرورت ارائه‌ی راهکار RS-DRL به روشنی توجیه گردید. فصل بعدی (فصل ۴) جزئیات معماری و الگوریتم پیشنهادی RS-DRL را ارائه می‌دهد.

فصل ۴


روش پیشنهادی

۴-۱ اصول معماری و سازماندهی فرآیند اجرایی

یک سیستم خوددوفق کارآمد در محیط‌های همراه با عدم قطعیت، باید ذاتاً بین دغدغه‌های متضاد طراحی مانند تصمیم‌گیری آنلاین با تأخیر بسیار کم و آموزش سنگین و ناهمگام مدل‌های یادگیری، تفکیک قائل شود تا بتواند آن‌ها را به‌طور مؤثر در یک ریسمان کنترلی واحد مدیریت کند. معماری RS-DRL بر اساس این اصل بنیادین جداسازی زمانی (Temporal Separation) طراحی شده است: مسیر بحرانی تصمیم‌گیری از مشاهده تا اجرا، مستقل از چرخه‌های یادگیری پس‌زمینه عمل می‌کند.

به جای تشریح ایستای مؤلفه‌های نرم‌افزاری، این فصل این منطق تفکیک را از طریق یک مدل فرآیندی به تصویر می‌کشد. ما جریان داده و کنترل را از لحظه دریافت سیگنال از حسگر تا اعمال فرمان تطبیق توسط عملگر دنبال می‌کنیم. به این ترتیب، یک نمای پویا و زمان‌آگاه از سیستم ارائه می‌شود که در آن اصل سازمان‌دهنده، رخدادهای و توالی عملیات است، نه صرفاً موقعیت فیزیکی کد.

برای هدایت خواننده در این دیدگاه فرآیندمحور، نقشه سلسله‌مراتبی در شکل ۴-۱ به عنوان یک راهنمای ناوبری عمل کرده و چارچوب کلی تعاملات سیستم را ترسیم می‌کند. این چارچوب، زمینه‌ساز تجزیه فرآیند یکپارچه خوددوفقی به فازهای تفصیلی «ادراک/یادگیری» و «تصمیم‌گیری/اجرا» در بخش‌های آتی شده و مسیر بسط آن‌ها به زیرفرآیندهای دقیق‌تری مانند راستی‌آزمایی صوری و شکل‌دهی پاداش را هموار می‌سازد. این سازمان‌دهی سلسله‌مراتبی تضمین می‌کند که پیچیدگی سیستم به شکلی نظام‌مند مدیریت شده و خواننده همواره جایگاه خود را در ساختار کلی معماری درک می‌کند.



شکل ۴-۱: معماری سطح بالای رویکرد RS-DRL در قالب حلقه MAPE-K این نمودار تعامل میان سیستم مدیریت شونده، محیط، و مؤلفه‌های کنترلی را به همراه مخزن دانش (Knowledge) مشترک نشان می‌دهد.

۲-۴ فرآیند یکپارچه خودوفقی: حلقه سطح سیستم

آنچه معماری RS-DRL را از یک اجتماع ساده از مؤلفه‌ها متمایز می‌کند، یک تصمیم بنیادین در سطح سیستم است: جداسازی زمانی (Temporal Separation) بین مسیر بحرانی تصمیم‌گیری و فعالیت‌های سنگین یادگیری. این اصل تضمین می‌کند که پاسخ‌های تطبیقی در مقیاس میلی‌ثانیه باقی بمانند، در حالی که بهبود مستمر سیاست‌ها به صورت ناهمگام در پس‌زمینه رخ می‌دهد.

در بالاترین سطح انتزاع، کل این مکانیزم در قالب یک فرآیند یکپارچه سازمان‌دهی می‌شود که مسیر داده از مشاهده تا تغییر فیزیکی را به صورت یک چرخه چهار فازی دنبال می‌کند (شکل ۴-۲). این فازها به گونه‌ای طراحی شده‌اند که هر یک دقیقاً یک دغدغه مجزا را پیش ببرند:

۱. ادراک و ساخت وضعیت: دریافت مستمر علائم محیطی و فشرده‌سازی آن‌ها در یک بردار حالت که بازنمایی دقیقی از شرایط کنونی سیستم ارائه می‌دهد.

۲. تحلیل و برنامه‌ریزی تطبیقی: تشخیص لحظه‌ای نقض اهداف کیفی و استنتاج سریع بهترین گزینه تطبیقی توسط مدل آموزش‌دیده.


۳. اعتبارسنجی و تولید بازخورد: ارزیابی گزینه پیشنهادی در برابر مدل صوری سیستم و تولید سیگنال پاداشی که بعداً در فرآیند یادگیری ناهمگام استفاده خواهد شد.

۴. اجرای قطعی: اعمال پیکربندی جدید بر روی سیستم مدیریت‌شونده از طریق عملگرها، بدون ایجاد اختلال در عملکرد جاری.

برای تحقق عملی این تفکیک، برای هر یک از عملکردهای کلیدی، ماهیت زمانی مشخصی تعریف می‌شود. جدول ۴-۱ این طبقه‌بندی را نشان داده و روشن می‌سازد که چگونه فعالیت‌های مستمر، رویدادمحور، و پس‌زمینه‌ای در کنار یکدیگر و بدون تداخل عمل می‌کنند.

جدول ۴-۱: طبقه‌بندی زمانی فرآیندهای معماری RS-DRL

فرآیند	ماهیت زمانی	توضیح عملکردی
پایش (Monitoring)	مستمر (Continuous)	پایش دائمی علائم حیاتی شبکه
پیش‌بینی (Prediction)	رویدادمحور (Event-driven)	واکنش سریع به تریگرهای تحلیل‌گر
راستی‌آزمایی (Verification)	مشروط (Conditional)	اعتبارسنجی گزینه‌ها پیش از اجرا
آموزش (Training)	ناهمگام (Asynchronous)	به‌روزرسانی سیاست‌ها در پس‌زمینه



شکل ۴-۲: نمودار فعالیت تفصیلی UML با خطوط شناوری (Swimlanes) برای تفکیک مسئولیت‌های پایش، تحلیل، برنامه‌ریزی و اعتبارسنجی. خط‌چین افقی مرز میان مسیر بحرانی آنالیز و فرآیند یادگیری ناهمگام در پس‌زمینه را مشخص می‌کند.

این ساختار زمانی، سنگ بنای معماری RS-DRL است: حلقه سطح سیستم همواره چابک و پاسخگو باقی می‌ماند، در حالی که هوشمندی آن به طور مداوم و بدون توقف سرویس، تکامل می‌یابد.

۳-۴ مسیر تصمیم‌گیری آنلاین: یک پیاده‌روی در معماری

پس از تبیین اصول معماری، اکنون مسیر یک درخواست تطبیق را از آغاز تا انجام دنبال می‌کنیم. برای فراهم‌سازی یک واژگان مشترک و زمینه‌سازی برای درک مسئولیت‌ها، از مدل مرجع MAPE-K به عنوان یک لنز ساختاری استفاده می‌کنیم. همان‌طور که شکل ۴-۲ نشان می‌دهد، هر مرحله از فرآیند یکپارچه ما به طور طبیعی به یکی از کارکردهای این مدل نگاشت می‌شود، بدون آنکه در دام انطباق تحت‌اللفظی با آن گرفتار شویم.

در ادامه، این مسیر را گام به گام و با لنز MAPE-K طی می‌کنیم.

۱-۳-۴ گام اول: پایش و ساخت وضعیت (Monitor)

در نقطه شروع حلقه، سیستم به طور مستمر محیط خود را رصد می‌کند. در نمونه مطالعاتی DeltaIoT، این فرآیند ادراکی به ساخت یک بردار وضعیت فشرده می‌انجامد که بازنمایی ریاضی از وضعیت جاری سیستم است:

$$s_t = \langle E, P, L \rangle \quad (1-4)$$

که در آن E مصرف انرژی تجمیعی شبکه، P نرخ اتلاف بسته‌ها، و L میانگین تأخیر ارسال است. این بردار، خروجی نهایی فاز پایش (Monitor) بوده و به عنوان ورودی مشترک برای تحلیل و تصمیم‌گیری عمل می‌کند.

۲-۳-۴ گام دوم: تحلیل و تشخیص ضرورت تطبیق (Analyze)

بردار وضعیت s_t سپس وارد فاز تحلیل (Analyze) می‌شود. تحلیلگر، مقادیر P و L را در برابر آستانه‌های کیفی از پیش تعریف‌شده (مطابق با اهداف کیفی تعریف‌شده در فصل ۲ برای سیستم DeltaIoT) مقایسه می‌کند. اگر هر یک از این شاخص‌ها از حد مجاز فراتر رود، یک سیگنال رویداد «نقض هدف» صادر شده و فرآیند برنامه‌ریزی را فعال می‌کند.

۴-۳-۳ گام سوم: برنامه‌ریزی و استنتاج تطبیقی (Plan)

با دریافت سیگنال نیاز به تطبیق، فاز برنامه‌ریزی (Plan) فعال می‌شود. هسته این فاز، مدل آموزش دیده RS-DRL است که در نقش یک استنتاج‌گر عمل می‌کند: بردار حالت s_t را دریافت کرده و از طریق یک گذر رو به جلو در شبکه عصبی، مقادیر Q را برای تمام گزینه‌های تطبیقی محاسبه می‌کند. این فرآیند یک استنتاج خالص (Pure Inference) است؛ وزن‌های شبکه در این مسیر بحرانی تغییر نمی‌کنند، تا پاسخ‌گویی آنی سیستم تضمین شود.

۴-۳-۴ گام چهارم: اعتبارسنجی، بازخورد و اجرا (Execute به همراه Knowledge)

قبل از آنکه گزینه تطبیقی برنده اعمال شود، یک گام اعتبارسنجی حیاتی صورت می‌گیرد. در معماری RS-DRL، ما از مدل‌های صوری برای تولید یک سیگنال بازخورد قابل اعتماد استفاده می‌کنیم. گزینه پیشنهادی a^* توسط موتور UPPAAL-SMC ارزیابی می‌شود. تابع $SMC_Verify(s, a)$ یک مقدار دودویی $r_{smc} \in \{0, 1\}$ برمی‌گرداند که نشان می‌دهد آیا گزینه مذکور، اهداف کیفیت خدمات (QoS) را در وضعیت مفروض برآورده می‌سازد یا خیر. پاداش نهایی که برای آموزش‌های آتی در بافر بازپخش ذخیره می‌شود، از ترکیب بازخورد محیط و این تأیید صوری حاصل می‌شود $(r = r_{env} \times r_{smc})$. به این ترتیب، تنها تجربیاتی که اعتبار آن‌ها توسط مدل صوری نیز تأیید شده باشد، به عنوان سیگنال‌های مثبت برای یادگیری استفاده می‌شوند. پس از محاسبه پاداش، گزینه تطبیقی تأییدشده برای اجرا به لایه شبکه در سیستم مدیریت‌شونده ارسال می‌شود. شکل ۴-۲ این مرحله نهایی را نشان می‌دهد که در آن فرمان‌های بازپیکربندی از طریق عملگرها اعمال شده و سیستم را با شرایط جدید منطبق می‌سازند.

۴-۴ معماری داخلی RS-DRL: تفکیک دغدغه‌ها در فرآیند یادگیری

برای تحقق اصل جداسازی زمانی که پیش‌تر مطرح شد، معماری داخلی RS-DRL به سه مسیر فرآیندی مجزا تجزیه می‌شود که در شکل ۴-۳ به تصویر کشیده شده‌اند:

۱. **مسیر استنتاج (Inference Path):** این مسیر در زمان اجرا فعال است و شامل دریافت بردار حالت، اجرای رو به جلوی شبکه عصبی، و انتخاب گزینه تطبیقی می‌باشد. این مسیر فقط خواندنی است و وزن‌های شبکه را تغییر نمی‌دهد، تا حداقل تأخیر تضمین شود.


۲. **مسیر بازخورد (Feedback Path):** پس از اعمال گزینه تطبیقی، این مسیر پاداش محیطی را دریافت کرده، آن را با خروجی اعتبارسنجی صوری ترکیب می‌کند $(r = r_{env} \times r_{smc})$ ، و تجربه کامل را در

بافر بازپخش ذخیره می‌نماید. این مسیر سبک و همزمان با اجرا عمل می‌کند.

۳. مسیر آموزش (Training Path): این مسیر کاملاً ناهمگام و مجزا از چرخه بحرانی تصمیم‌گیری اجرا می‌شود. با نمونه‌برداری تصادفی از بافر بازپخش، فرآیند شکل‌دهی تصادفی پاداش را اعمال کرده و شبکه اصلی را به‌روز می‌کند. به‌روزرسانی‌ها به صورت دوره‌ای به شبکه هدف منتقل می‌شوند.

این جداسازی دقیق تضمین می‌کند که عامل یادگیرنده همواره پاسخگو باقی بماند، در حالی که هوشمندی آن به طور مداوم و بدون ایجاد وقفه در سرویس‌دهی، بهبود می‌یابد. جزئیات منطق داخلی این مسیرها و نحوه تعامل با مؤلفه راستی‌آزمایی صوری در شکل ۴-۳ به تصویر کشیده شده است.


RS-DRL PLANNER INTERNAL STRUCTURE



شکل ۴-۳: ساختار داخلی مؤلفه برنامه‌ریز RS-DRL در سه مسیر موازی: استنتاج (فقط خواندنی)، فیدبک (ترکیب پاداش محیطی و صوری)، و آموزش (به‌روزرسانی ناهمگام با استفاده از شکل‌دهی تصادفی پاداش).

در این ساختار، مسیر استنتاج به صورت یک «گذر رو به جلو» خالص در شبکه عصبی پیاده‌سازی شده است که در آن تابع $SelectAction$ با استفاده از سیاست greedy-گزینه تطبیقی را انتخاب می‌کند. به محض تولید پاداش محیطی، ریسمان بازخورد فعال شده و با فراخوانی موتور SMC_Verify ، پاداش

نهایی را تولید و در حافظه مشترک ذخیره می‌کند.



شکل ۴-۴: منطق عملیاتی مکانیزم شکل‌دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش‌بینانه پاداش‌های صفر با مقدار ۱ را بر اساس فاکتور ρ نشان می‌دهد (برچسب‌گذاری مجدد خوش‌بینانه، نه روش‌های مبتنی بر پتانسیل).

۴-۵ مکانیزم هسته: شکل‌دهی تصادفی پاداش

چالش بنیادینی که RS-DRL به آن پاسخ می‌دهد، پدیده توقف در بهینه‌های محلی است؛ جایی که عامل یادگیرنده صرفاً بر اساس تجربیات موفق گذشته عمل کرده و از کشف سیاست‌های بالقوه بهتر باز می‌ماند. برای غلبه بر این محدودیت، RS-DRL یک راهبرد ظریف را در مرحله بازپخش تجربه (Experience Replay) به کار می‌گیرد: بازطراحی خوش‌بینانه تصادفی تجربیات شکست‌خورده. این ایده ساده اما قدرتمند، دقیقاً هدف اصلی رساله را محقق می‌سازد: فرار از بهینه‌های محلی بدون نیاز به بازآموزی پرهزینه.

به طور رسمی، در هر مینی‌بچ آموزش، به ازای هر تجربه i با پاداش اولیه صفر ($r_i = 0$)، RS-DRL با احتمال ρ پاداش آن را به صورت خوش‌بینانه برابر با ۱ قرار می‌دهد. این فرآیند جایگزینی که در شکل ۴-۴

ترسیم شده است، بر اساس رابطه زیر عمل می‌کند:

$$\tilde{r}_i = \begin{cases} 1 & \text{if } r_i = 0 \text{ and } \text{rand}(0, 1) < \rho \\ r_i & \text{otherwise} \end{cases} \quad (2-4)$$

پارامتر ρ (فاکتور شکل دهی) شدت این خوش بینی را کنترل می‌کند: مقدار بیش از حد بزرگ، نویز مخربی به فرآیند یادگیری تزریق می‌کند، و مقدار بسیار کوچک، مکانیزم را بی‌اثر می‌سازد. در ارزیابی‌های تجربی (فصل ۵)، حساسیت عملکرد به این پارامتر تحلیل خواهد شد.

فرآیند کامل آموزش در الگوریتم ۴-۱ تشریح شده است. نکته قابل توجه در این الگوریتم، استفاده از خروجی SMC_Verify (از ابزار UPPAAL-SMC) در محاسبه پاداش اولیه r است. این ترکیب ($r = r_{smc} \times r_{env}$) تضمین می‌کند که تنها تجربیاتی که هم توسط محیط و هم توسط مدل صوری تأیید شده‌اند، سیگنال مثبت دریافت می‌کنند. در نسخه جاری، این اعتبارسنجی صوری منحصراً برای شکل دهی پاداش به کار می‌رود و مانع از اجرای گزینه تطبیقی نمی‌شود؛ ارتقای آن به یک لایه فیلترینگ سخت، به عنوان یک کار آینده در فصل ۶ مطرح خواهد شد.

الگوریتم ۴-۱ آموزش و بهروزرسانی جامع RS-DRL

```

1: Initialize main network  $\theta$  and target network  $\theta'$ 
2: for each training episode do
3:    $s \leftarrow GetInitialState()$ 
4:   while episode not finished do
5:      $a \leftarrow SelectAction(s, \theta, \epsilon\text{-greedy})$ 
6:      $(s', r_{env}) \leftarrow Environment.Step(a)$ 
7:      $r_{smc} \leftarrow SMC\_Verify(s, a)$  {UPPAAL-SMC:  $r_{smc} \in \{0, 1\}$  confirms QoS}
8:      $r \leftarrow r_{env} \times r_{smc}$  {Reward=1 only if env AND formal model both confirm success}
9:     Store transition  $(s, a, r, s')$  in Replay Buffer  $\mathcal{D}$ 
10:    Sample random minibatch  $B = \{(s_i, a_i, r_i, s'_i)\}_{i=1}^N$  from  $\mathcal{D}$ 
11:    for each transition  $i$  in  $B$  do
12:      if  $r_i = 0$  and  $rand(0, 1) < \rho$  then
13:         $\tilde{r}_i \leftarrow 1$  {Random Optimistic Shaping}
14:      else
15:         $\tilde{r}_i \leftarrow r_i$ 
16:      end if
17:       $y_i \leftarrow \tilde{r}_i + \gamma \max_{a'} Q(s'_i, a'; \theta')$  {TD target with shaped reward}
18:       $\theta \leftarrow \theta - \alpha \nabla_{\theta} \mathbb{E}[(y_i - Q(s_i, a_i; \theta))^2]$ 
19:    end for
20:     $\theta' \leftarrow \tau \theta + (1 - \tau) \theta'$  {Soft update of target network}
21:     $s \leftarrow s'$ 
22:  end while
23: end for


```

نکته: پارامتر ρ (فاکتور شکل دهی) یک ابرپارامتر است که میزان خوش بینی عامل را در کشف مسیرهای جدید کنترل می کند. مقادیر بهینه آن در فصل ۵ تحلیل شده اند.

۴-۶ مدیریت دانش و هماهنگی جریان‌ات ناهمگام

موفقیت معماری RS-DRL در گرو هماهنگی دقیق میان سه مسیر استنتاج، بازخورد و آموزش است. این هماهنگی از طریق یک مخزن دانش مشترک (Knowledge Repository) تحقق می‌یابد که به‌عنوان حافظه مرکزی سیستم عمل می‌کند. شکل 4-5 جریان داده‌های ذخیره‌شده در این مخزن را نشان می‌دهد؛ از لحظه ذخیره‌سازی گذارهای (s, a, r, s') تا فرآیند نمونه‌برداری ناهمگام و به‌روزرسانی شبکه‌های عصبی اصلی و هدف.

Experience Replay and DQN Training



□ Experience Replay and DQN Training

شکل ۴-۵: جریان داده تفصیلی در مخزن دانش. این نمودار نحوه ذخیره‌سازی تجربیات در بافر بازیخش، اعمال مکانیزم شکل‌دهی تصادفی پاداش پیش از محاسبات گرادیان، و به‌روزرسانی سیاست‌های یادگیری در پس‌زمینه را به تصویر می‌کشد.

جدول ۴-۲ الگوی دسترسی هر فرآیند به این مخزن، زمان‌بندی اجرای آن، و تأثیر آن بر تأخیر سیستم را خلاصه می‌کند. همان‌طور که مشاهده می‌شود، فرآیند آموزش با دسترسی خواندن/نوشتن در فضایی کاملاً ایزوله اجرا شده و هیچ تأثیری بر مسیر بحرانی تصمیم‌گیری ندارد. این ویژگی، سنگ بنای مقیاس‌پذیری و پاسخ‌گویی بلادرنگ سیستم است.

جدول ۴-۲: قراردادهای تعاملی و همگام‌سازی جریانات آنلاین و ناهمگام

فرآیند	دسترسی به دانش	زمان‌بندی	تأثیر بر تأخیر
استنتاج (Inference)	فقط خواندنی	رویداد محور	ناچیز (میلی ثانیه)
فیدبک (Reward)	نوشتنی	انتهای گام	بسیار کم
آموزش (Training)	خواندن/نوشتن	ایزوله (ناهمگام)	صفر

۷-۴ پوشش پرسش‌های پژوهش

در این بخش، به طور تفصیلی نشان می‌دهیم که چگونه طراحی ارائه‌شده، به پرسش‌های اصلی پژوهش پاسخ می‌دهد:

- پاسخ به ۱RQ (فرار از بهینه‌های محلی): مکانیزم شکل‌دهی تصادفی پاداش (بخش ۴-۵) با تزریق خوش‌بینی کنترل‌شده، عامل را قادر می‌سازد تا از تله سیاست‌های زیربینه رها شود.
- پاسخ به ۲RQ (ادغام یادگیری و بازپخش): این فرآیند به طور مستقیم در مرحله نمونه‌برداری از بافر بازپخش (الگوریتم ۴-۱، خطوط ۱۲-۱۶) ادغام شده و سربار محاسباتی ناچیزی دارد.
- پاسخ به ۳RQ (مقیاس‌پذیری): جداسازی زمانی مسیر استنتاج (شکل ۴-۳) تضمین می‌کند که حتی در فضاهای حالت بسیار بزرگ، تأخیر پاسخ‌گویی آنلاین سیستم افزایش نمی‌یابد.
- پاسخ به ۴RQ (تمایز و برتری): عدم نیاز به دانش دامنه و استقلال از مدل‌های هدف‌محور، این رویکرد را نسبت به روش‌هایی نظیر HER متمایز می‌سازد (تحلیل تجربی در فصل ۵).

۸-۴ خلاصه فصل

این فصل، معماری اجرایی RS-DRL را نه به عنوان مجموعه‌ای از مؤلفه‌های نرم‌افزاری، بلکه به عنوان یک مدل فرآیندی زمان‌آگاه و منضبط تبیین کرد. ما نشان دادیم که چگونه اصل تفکیک زمانی، امکان همزیستی یک حلقه کنترلی سریع و یک فرآیند یادگیری عمیق ناهمگام را فراهم می‌آورد. یکپارچگی با چارچوب MAPE-K، قرابت معماری با الگوهای استاندارد خودوفقی را تضمین کرده و در عین حال، مکانیزم «شکل‌دهی تصادفی پاداش» به عنوان هسته نوآورانه، عامل را قادر می‌سازد تا از تله بهینه‌های محلی بگریزد. در ادامه، در فصل ۵،

کارآمدی این معماری در عمل و از طریق ارزیابی‌های تجربی دقیق بر روی سیستم DeltaIoT به اثبات خواهد رسید.

فصل ۵

ارزیابی تجربی

۱-۵ مقدمه

ارزیابی تجربی نقشی اساسی و تعیین‌کننده در تأیید اثربخشی راهکارهای پیشنهادی در سیستم‌های خودوفقی ایفا می‌کند. به دلیل آنکه معماری نوین RS-DRL ادعا می‌کند که می‌تواند بدون نیاز به آموزش‌های پیشرفته و آفلاین، با مدیریت تجربیات ناموفق، بر پدیده بهینه‌های محلی غلبه کند، اعتبارسنجی تجربی این دستاوردها بسیار حیاتی است. در این فصل با بهره‌گیری از سناریوهای متعدد ارزیابی، قابلیت‌های راهکار پیشنهادی را در پلتفرم معتبر شبکه حسگرهای بی‌سیم DeltaIoT مورد سنجش جامع قرار می‌دهیم.

این فصل در راستای پاسخگویی به سوالات تحقیق مطرح شده در فصل اول سازماندهی گردیده و هدف اساسی آن نمایش و اثبات برتری این معماری نسبت به راهکارهای پایه و مرسوم موجود است. ساختار فصل بدین گونه است که در ابتدا اهداف ارزیابی تبیین گشته، سپس تنظیمات، مجموعه داده‌ها و محیط پیاده‌سازی معرفی می‌شوند؛ در گام‌های بعدی ضمن معرفی دقیق معیارهای سنجش، دستاوردها و نتایج به دست آمده در سناریوهای تک‌هدفه و چندهدفه و همچنین تحلیل مقیاس‌پذیری و ارزیابی آماری ارائه خواهد شد.

۲-۵ اهداف ارزیابی و سوالات تحقیق

انجام این ارزیابی تجربی همسو با پرسش‌های اساسی مطرح شده در فصل پیشین، اهداف مشخصی را دنبال می‌کند که در جدول ۵-۱ نقشه‌برداری شده‌اند:

جدول ۵-۱: هم‌راستایی اهداف ارزیابی با سوالات تحقیق

سوال تحقیق (RQ)	رویکرد ارزیابی
سوال اول: طراحی مکانیزم DRL برای خروج از بهینه‌های محلی	مقایسه منحنی‌های همگرایی (اشکال ۵ و ۶ در مقاله مرجع) در برابر روش‌های پایه و ارزیابی عملکرد مجانبی.
سوال دوم: ادغام شکل‌دهی پاداش با بازپخش تجربه	انجام مطالعه ابلیشن (Ablation Study) در برابر گونه‌های مختلف از جمله HER و Soft HER.
سوال سوم: مدیریت فضاها بزرگ و گسسته تطابق	اجرای تست مقیاس‌پذیری در بسترهای DeltaIoT v1 (۲۱۶ گزینه)، v1.1 (۱۲۹۶ گزینه) و v2 (۴۰۹۶ گزینه).
سوال چهارم: مقایسه RS-DRL با روش‌های پیشرفته موجود	تقابل با روش‌های استاندارد نظیر ϵ -greedy، DLASER+، DQN و ML4EAS (Tables 5-6).

۳-۵. تنظیمات آزمایشگاهی

پیش از ورود به جزئیات آزمایش‌ها، یادآوری می‌گردد که فرمول‌بندی مسئله یادگیری تقویتی شامل فضای حالت، فضای اقدام و توابع پاداش (که برای اهداف مختلف سیستم از جمله کاهش مصرف انرژی، تاخیر و اتلاف بسته‌ها طراحی شده‌اند)، دقیقاً بر اساس مدل ارائه‌شده در فصل‌های پیشین (به‌ویژه روابط ریاضی مطرح شده در فصل پیشین) بنا شده است. این یکپارچگی تضمین می‌کند که عامل هوشمند با همان قواعد و اهداف نظری اثبات‌شده، در محیط شبیه‌سازی آموزش می‌بیند و نیازی به بازتعریف مجدد متغیرها در این فصل نمی‌باشد.

به منظور فراهم نمودن قابلیت بازتولید (Reproducibility) آزمایش‌ها، جزئیات پیکربندی مطالعه موردی به دقت بیان می‌گردد.

۱-۳-۵. نمونه‌های مطالعه موردی

ما از پلتفرم DeltaIoT به‌عنوان بستر آزمایشگاهی بهره برده‌ایم. پیکربندی استقرار یافته برای شبکه‌های مورد بحث، مشخصات فضای حالت‌ها و پیچیدگی‌ها در جدول ۵-۲ خلاصه گردیده است:

جدول ۵-۲: نمونه‌های مورد مطالعه سیستم DeltaIoT

نمونه (نسخه)	تعداد سنسورها	اندازه فضای وفقی (گزینه‌ها)	گام‌های آموزش
DeltaIoT v1	۱۵	۲۱۶	۰۰۰،۱۰
DeltaIoT v1.1	۱۶	۲۹۶،۱	۸۰۰،۶۴
DeltaIoT v2	۳۷	۰۹۶،۴	متناسب با مقیاس شبکه

۲-۳-۵ مجموعه داده‌ها

جهت شبیه‌سازی شرایط در زمان اجرا، از ردپاهای محیطی (Traces) مرتبط با سیستم DeltaIoT استفاده شده که شامل اطلاعات چرخه‌های تطابق می‌باشند [۱]. این مجموعه داده، الگوهای تداخلات شبکه‌ای متغیر مابین -40 dB تا $+15\text{ dB}$ را ثبت کرده و همچنین نوسانات مرتبط با بار ترافیک پیام‌ها (بین ۰ تا ۱۰ پیام به ازای هر سنسور) را در طول زمان شامل می‌شود.

۳-۳-۵ پلتفرم پیاده‌سازی

پلتفرم عملیاتی اجرا شده در این تحقیق شامل مجموعه‌ای از پیشرفته‌ترین چارچوب‌های محاسباتی است. برای ایجاد محیط یادگیری تقویتی از کتابخانه استاندارد Gymnasium بهره گرفته شد و پیاده‌سازی شبکه‌های DQN بر روی چارچوب مشهور Stable-Baselines3 انجام شده است. در دل این پیاده‌سازی، مکانیزم بومی شکل‌دهی پاداش تصادفی به صورت مستقیم به درون حافظه بازپخش (Replay Buffer) تزریق گشته است. به منظور اعتبارسنجی صوری و ایمنی گزینه‌های تطبیق‌یافته نیز موتور UPPAAL-SMC و مؤلفه واسط ActivFORMS نقش رابط‌های کنترلی را ایفا می‌کنند.

۴-۳-۵ تنظیمات فرایارامتراها (Hyperparameters)

به منظور دستیابی به بهترین عملکرد، فرایارامترهای الگوریتم یادگیری تقویتی از طریق جستجوی شبکه‌ای (Grid Search) در طی آزمایش‌ها تنظیم شده‌اند. مهم‌ترین پارامترهای نهایی شامل نرخ یادگیری (Learning Rate)، اندازه دسته (Batch Size)، فرکانس به‌روزرسانی شبکه هدف (Target Network Update Frequency)، و برنامه کاهش نرخ اکتشاف (ϵ -decay schedule) می‌باشند. مقادیر دقیق این فرایارامتراها پس از ارزیابی‌های اولیه انتخاب شده‌اند تا تعادل مناسبی بین اکتشاف (Exploration) و بهره‌برداری (Exploitation) برقرار گردد و نتایج ارائه‌شده بر پایه این مقادیر بهینه‌شده به دست آمده‌اند.

۴-۵ روش‌های پایه و مقایسه

جهت ارزیابی عملکرد و تفوق رویکرد RS-DRL، آن را با مجموعه وسیعی از متدهای موجود مقایسه کرده‌ایم. مقایسه در سه دسته‌بندی هدف‌گذاری به شرح زیر صورت گرفت:

• مقاصد کمینه‌سازی (Minimization Goals): برای این منظور مدل در برابر عامل استاندارد یادگیری

پایه، نظیر ϵ -greedy DQN و همچنین در برابر ترکیبات RS-DRL با استراتژی‌های مشهوری چون HER

(RS-DRL-with-HER) و Soft HER قرار گرفت.

● مقاصد ترکیبی اهداف آستانه‌ای محدود (TTS Goal): برای ارزیابی کیفی، الگوریتم‌های شناخته‌شده‌ای همچون DLASER+ و یک سیستم مرجع (Reference) که بر پایه جستجوی کامل و جامع تمامی حالت‌ها (Exhaustive Search) استوار بود، مورد ارزیابی قرار گرفت.

● مقاصد آستانه‌ای مطلق (TT Goal): راهکار پیشنهادی در تقابل با مدل‌های یادگیری پیشرفته همچون ML4EAS (Machine Learning for Evaluating Adaptation Space)، نسخه اولیه DLASER+، DLASER+ و روش مرجع سنجیده شد.

نکته کلیدی در خصوص انطباق روش‌های HER: ذکر این نکته حائز اهمیت است که مدل‌های HER و Soft HER اساساً برای محیط‌های مبتنی بر هدف‌های صریح (Goal-Conditioned Environments) طراحی و تنظیم گشته‌اند، در حالی که اهداف کیفی در DeltaIoT به صورت کمینه‌سازی پیوسته هستند. با این وجود برای فراهم کردن بستر مقایسه علمی در محیط‌های نرم‌افزاری شبکه همانند DeltaIoT، ما این راهکارها را متناسب‌سازی کرده و با در نظر گرفتن آستانه‌های تعریف شده اهداف کیفی (QoS) به عنوان اهداف جایگزین (Proxy Goals)، فرآیند تغییر مرجع مجدد (Relabeling) را بر اساس آنها شبیه‌سازی کردیم. این رویکرد استفاده از اهداف جایگزین ضروری بود تا بتوان الگوریتم‌های مبتنی بر HER را در سناریوهایی که اساساً بدون هدف صریح هستند، به طور عادلانه ارزیابی نمود.

۵-۵ معیارهای ارزیابی

در راستای متدولوژی‌های سنجش استاندارد موجود، ارزیابی این رساله بر محور دو گروه دسته‌بندی استوار گشته است:

۵-۵-۱ معیارهای عملکرد یادگیری عامل هوشمند

این معیارها برای بررسی روند یادگیری سیستم استفاده می‌شوند:

۱. عملکرد مجانبی (Asymptotic Performance): این سطح، وضعیت نهایی‌ترین ارزش و کیفیتی است که عامل پس از دریافت آموزش کافی به آن دست می‌یابد. اندازه‌گیری آن به‌طور معمول بر پایه محاسبه معدل پاداش به دست آمده روی تعداد محدودی از گام‌های نهایی چرخه امکان‌پذیر است.

۲. زمان تا آستانه (Time to Threshold): بیانگر تعداد گام‌های زمانی است که عامل نیازمند طی کردن است تا به یک مقدار پاداش از پیش تعیین شده همگرا گردد. به عنوان نمونه آستانه مورد قبول در جداول ارزیابی مقداری معادل ۹۰۰ در نظر گرفته شده است.

۳. عملکرد کل (Total Performance): تابعی برای ارزیابی جامع که از مجذور عملکرد مجانبی در طی زمان کم شده از جمع کل مقادیر پاداش اخذ شده به دست می‌آید. این فرمول به صورت زیر نمایش داده می‌شود:

$$TP = R_{\infty} \cdot T - \sum_{t=1}^T r_t$$

تفسیر این معیار: به دست آمدن مقادیر مثبت نشانگر آن است که منحنی یادگیری مدل همواره پایین‌تر از سطح آرمانی مجانبی بوده و میل به بهبود و رشد در طول زمان دارد. اما مقادیر منفی حاکی از اوج‌گیری اولیه و سپس افت و همگرایی به سطوح پایین‌تر عملکرد در زمان اجراست.

۵-۲-۵ معیارهای عملکرد سیستم

موارد زیر منعکس‌کننده خروجی نهایی سیستم در ساختار شبکه می‌باشند:

- تلفات بسته‌های ارسالی (Packet Loss): درصد پیغام‌هایی که با خطا مواجه شده و به مقصد نمی‌رسند.
- تاخیر ارسال (Latency): مدت زمان صرف شده برای انتقال اطلاعات به گره مرکزی.
- مصرف انرژی (Energy Consumption): مصرف نهایی انرژی در گره‌های سنسورها پس از اعمال وفقی‌سازی.

۵-۶ نتایج و تحلیل‌ها


این بخش به عنوان قلب ارزیابی رساله، نتایج استخراج شده از شبیه‌سازی‌ها را تدوین و تفکیک نموده است.

۵-۶-۱ منحنی‌های یادگیری و رفتار همگرایی

روند پیشرفت یادگیری الگوریتم در مقایسه با مدل پایه‌ای به وضوح برتری مکانیزم پیشنهادی را تصدیق می‌کند. در تحلیل رفتار شبکه با استفاده از DeltaIoTv1، مشاهده می‌گردد که رویکرد RS-DRL توانسته است ارزش


مجانبی بسیار درخشان 9905.0 را (با خطای انحراف معیار 0.268) کسب نموده و در مدت زمان نسبتاً کوتاه 2266 گام (با تحمل خطای 150 پیش و پس) به آستانه مطلوب نفوذ کند. در نقطه‌ی مقابل، الگوریتم پایه‌ی حریصانه یعنی ϵ -greedy DQN نه تنها نتوانست از حد مجانبی 4559.0 فراتر رود، بلکه هرگز موفق به فتح آستانه‌ی در نظر گرفته شده نیز نگردید. دلیل بنیادین این توفیق RS-DRL، آن است که مکانیزم شکل‌دهی تصادفی، به جای اکتفای تنها بر آموزش پایه، با تخصیص پاداش به تجربیات منحصرأ ناموفق اجازه می‌دهد این مدل نه تنها به ثبات بالاتری بهبود یابد، بلکه در بالاترین سطح مجانبی با ثبات مطلوبی مستقر بماند و از بهینه‌های محلی فرار کند.

شکل ۵-۱ منحنی یادگیری الگوریتم‌ها را در فضای DeltaIoTv1 نشان می‌دهد و برتری همگرایی RS-DRL را در برابر روش‌های پایه به وضوح به تصویر می‌کشد.



شکل ۵-۱: منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1 (پاداش در برابر گام‌ها)

در فضای بسیار پیچیده‌تر با حضور 1296 گزینه تطبیق‌پذیر در بسته‌ی DeltaIoTv1.1، راهکار ما در 19296 گام به پاداش عالی 8983.0 ± 0.932 نفوذ پیدا کرد، در حالی که همه مدل‌های رقیب عملکرد کل ضعیف‌تری را ثبت کرده و هرگز به خط آستانه نزدیک نشدند (مطابق با شکل ۵-۲).



شکل ۵-۲: منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1.1

۵-۶-۲ مقایسه عملکرد به ازای هر هدف

به منظور درک دقیق جزئیات کارکرد عوامل کنترلی روی تک تک متغیرهای سیستم، به ارزیابی رویکرد پیشنهاد شده با انواع HER پرداختیم. جداول ۳-۵ و ۴-۵ عملکرد مجانبی، زمان تا آستانه و عملکرد کل را برای اهداف مختلف نشان می‌دهند.

جدول ۳-۵: نتایج اهداف کمیته‌سازی در DeltaIoTv1 (پاداش مجانبی / گام‌ها)

روش ^{*۲}	چندهدفه		مصرف انرژی		تلفات بسته‌ها	
	مجانبی	زمان تا آستانه	عملکرد کل	مجانبی	زمان تا آستانه	عملکرد کل
RS-DRL	۹۹.۰	۲۲۶۶	—	۹۷.۰	—	—
RS-DRL-HER	۶۱.۰	عدم همگرایی	—	۵۸.۰	عدم همگرایی	—
RS-DRL-SoftHER	۴۹.۰	عدم همگرایی	—	۳۹.۰	عدم همگرایی	—
DQN	۴۵.۰	عدم همگرایی	—	—	عدم همگرایی	—

جدول ۴-۵: نتایج اهداف کمیته‌سازی در DeltaIoTv1.1

روش ^{*۲}	چندهدفه		مصرف انرژی		تلفات بسته‌ها	
	مجانبی	زمان تا آستانه	عملکرد کل	مجانبی	زمان تا آستانه	عملکرد کل
RS-DRL	۸۹.۰	۱۹۲۹۶	—	۹۳.۰	—	—
RS-DRL-HER	—	عدم همگرایی	—	—	عدم همگرایی	—
RS-DRL-SoftHER	—	عدم همگرایی	—	—	عدم همگرایی	—
DQN	—	عدم همگرایی	—	—	عدم همگرایی	—

تحلیل این اهداف نشان می‌دهد:

- **بهینه‌سازی چندهدفه (Multi-objective):** متد ما توانست به پاداشی معادل ۹۹۰۵۰.۰ (در شبکه اول) و ۸۹۸۳۰.۰ (در شبکه دوم) دست یابد در حالی که بهترین انواع HER منحصراً مقادیری مابین ۴۹.۰ الی ۶۱.۰ را ثبت نمودند. علت این افت فاحش در مدل‌های HER را باید در ماهیت وابستگی این مدل‌ها به تعاریف و تخصیص اهداف صریح، در مقایسه با پویایی اهداف نامشخص اکوسیستم SAS جستجو نمود.
- **مصرف انرژی:** شاخص‌های ارزیابی، مصرف انرژی RS-DRL را با ثبت میانگین ۹۷۵۶.۰ (در v1) و ۹۳۰۱۰.۰ (در v1.1) بسیار متمایز از مدل‌های پایه (بازه‌ی ۳۹.۰ الی ۵۸.۰) نشان داد.
- **تلفات بسته‌ها (Packet Loss):** دستیابی راهکار توسعه‌یافته در نگه‌داری امنیت شبکه‌ها به عنوان عاملی در مرز نزدیک به حالت بهینه؛ ۹۸۵۰۰.۰ در شبکه اولیه و تغییر آن به وضعیت ۹۱۲۹۰.۰ در شبکه‌ی پیچیده‌تر دوم.
- **تاخیر (Latency):** شبکه مجهز به RS-DRL موفق‌ترین سرعت رکوردگیری را با معدل ۹۹۶۴۰.۰ و ۹۰۲۱۰.۰ منعکس کرد.

۵-۶-۳ ارزیابی مقایسه‌ای در برابر تمام روش‌های پایه

ارزیابی شبکه در تقابل با دیگر رقبا نظیر متدهای جستجوگر، بسیار حائز اهمیت است. در جداول ۵-۵ و ۵-۶ نتایج مربوط به اهداف آستانه‌ای خلاصه شده است.

جدول ۵-۵: عملکرد سیستم برای اهداف آستانه‌ای ترکیبی (TTS Goal)

روش (شبکه v1)	اتلاف بسته‌ها (%)	تاخیر (s)	مصرف انرژی (C)
RS-DRL	۵۷۸.۱۰	۰۹۷.۰	۸۸۲.۱۲
DLASER+	۸۹۰.۱۲	۸۴۰.۰	۰۲۰.۱۳
Reference	۲۳۰.۱۴	۱۰۰.۰	۱۰۰.۱۳

جدول ۵-۶: عملکرد سیستم برای اهداف آستانه‌ای مطلق (TT Goal)

روش*۲	DeltaIoTv1		DeltaIoTv2	
	اتلاف بسته‌ها (%)	تاخیر (s)	اتلاف بسته‌ها (%)	تاخیر (s)
RS-DRL	۱۵۳.۷	—	۳۳۰.۹	۲۵۱.۰
DLASER+	۹۸۰.۷	—	—	—
ML4EAS	—	—	۵۶۰.۱۰	—
Reference	—	—	—	۱۰۰.۰


• **نتایج هدف TTS:** تحت شبکه اولیه، متد RS-DRL از دست رفتگی بسته‌های حاوی پیغام را در مرز ۵۷۸.۱۰٪ متوقف نمود، در حالی که استفاده از ارزیابی جستجوی مرجع (Reference) درصد ۲۳.۱۴٪ و همچنین DLASER+ بالغ بر ۸۹.۱۲٪ اتلاف داشته‌اند. تاخیر ارسال با نرخ ۰۹۷.۰ بسیار بهتر از رقیب اصلی آن یعنی DLASER+ (با ثبت ۸۴۰.۰) کارنامه موفق‌تری از خود برجای گذاشت و متوازن با روش مرجع (۱۰۰.۰) بود. میزان مصرف انرژی (با مقدار ۸۸۲.۱۲) نیز نزدیک به رویکرد مرجع (۱۰۰.۱۳) و DLASER+ (۰۲۰.۱۳) محاسبه گردید.

• **نتایج هدف TT:** راهکار ما در پلتفرم DeltaIoTv1، به تلفات بسیار کم شبکه (۱۵۳.۷٪) در مقابل بهترین رقیب یعنی DLASER+ (۹۸۰.۷٪) رسید؛ همچنین در پلتفرم عظیم v2، موفق شد مقدار ۳۳۰.۹٪ را برای این فاکتور ثبت نماید در حالی که بهترین سیستم هوش ماشینی فعلی (ML4EAS) مقداری معادل ۵۶۰.۱۰٪ ارائه داد.

تنها تفاوت موجود، تخصیص تاخیر در نسخه دوم بود (که RS-DRL تاخیر ۲۵۱.۰ را در مقایسه با ۱۰۰.۰ روش مرجع ثبت نمود)؛ که البته یک طراحی مبتنی بر خط‌مشی به جهت اولویت‌بندی انتقال شبکه و کاهش اتلاف به جای کاهش زمان تاخیر قلمداد می‌شود و نه یک شکست الگوریتمی.

۵-۶-۴ مطالعه ابلیشن: حساسیت به فاکتور شکل دهی ρ

یکی از دستاوردهای علمی مهم این متد، تخصیص استراتژیک ضریب مفقود به تجربیات گذشته بود. در الگوریتم، مقدار کنترل‌کننده ρ تعیین می‌کند تا چه تعداد از تجربیات ناکام ثبت شده در مینی بچ (ذخیره شده در حافظه‌ی سیستم)، با ضریب عدد یک (پاداش مثبت تصنعی) جایگزین شوند. در صورتی که تجربه‌های شکست خورده موجود در حافظه بیشتر از نرخ انتخابی ما باشد، کاملاً به صورت تصادفی تعدادی انتخاب گشته و مجدد شکل دهی می‌گردند و در غیر این صورت روی تمامی آنها شکل دهی پیاده می‌گردد. جهت درک دقیق‌تر، بررسی مقادیر مختلف ρ در قالب شکل ۵-۳ قابل مشاهده است.



شکل ۵-۳: تاثیر مقادیر مختلف ضریب شکل دهی ρ بر پاداش مجانبی و عملکرد کل

نکات تحلیلی پیرامون فاکتور: ایجاد یک توازن کلیدی حول فاکتور بسیار مهم است. اگر ρ بیش از حد بالا باشد، عامل با نویز بالا مواجه خواهد شد و عملکرد افت می‌کند. متقابلاً مقادیر بسیار پایین نیز به آن معناست که عامل استراتژی جسورانه‌ای برای خروج از بهینه‌های محلی نخواهد داشت و مشابه شبکه‌های پایه فریز می‌شود. این انتخاب تصادفی در کنار توزیع منطقی ρ ، از تناسب بیش از حد (Overfitting) حافظه نیز ممانعت به عمل می‌آورد.

۵-۶-۵ تحلیل مقیاس پذیری

مقایسه نتایج مدل حاکی از پیروزی پایدار آن است. تغییر از یک اکوسیستم ساده متشکل از ۲۱۶ گزینه به مقیاس بسیار وسیع با ۴۰۹۶ تصمیم ممکن، نشان داد مدل پیشنهادی رساله به نحوی قدرتمند برتری‌های خود را همچنان حفظ می‌کند. جدول ۵-۷ این روند مقیاس‌پذیری را نشان می‌دهد.

جدول ۵-۷: تحلیل مقیاس‌پذیری الگوریتم با بزرگ شدن فضای تطابق

نسخه DeltaIoT	سنسورها	گزینه‌های تطابق	گام‌های آموزش مورد نیاز	پاداش مجانبی
v1	۱۵	۲۱۶	۲۲۶۶	۹۹۰۵.۰
v1.1	۱۶	۱۲۹۶	۱۹۲۹۶	۸۹۸۳.۰
v2	۳۷	۴۰۹۶	—	—

تنها زمان همگرایی یادگیری (جهش از ۲۲۶۶ به ۱۹۲۹۶ گام در نسخه v1.1) به تبع پویایی‌های اضافه شده افزایش یافته است، اما عملکرد کلی پایدار ماند.

۷-۵ اعتبارسنجی آماری

برای استواری یافته‌های این رساله، نتایج حاصله توسط آزمون‌های دقیق آماری اعتبارسنجی شده‌اند. روش‌شناسی توسعه‌یافته در ارزیابی شامل حداقل ۳۰ دور اجرای کاملاً مستقل با بذره‌های رندوم، انجام آزمون تی مستقل تک‌نمونه‌ای (One-sample t-tests) با ضریب خطای آلفای برابر ۰.۰۵، و تخصیص فواصل اطمینان ۹۵٪ به روش بوت‌استرپ است. فرمول ریاضی محاسبه آماری به این شکل تنظیم گردید:

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

خلاصه اعتبارسنجی‌ها (بر اساس مقادیر p): از بین مجموعاً ۲۸ مقایسه‌ی متمایز و شاخص، تعداد ۲۵ مقایسه کیفیت الگوریتم توسعه‌یافته در یک شرایط آماری فوق‌العاده قرار داشتند (۳.۸۹٪ تست‌ها معنادار بودند). جدول ۸-۵ گزیده‌ای از نتایج آزمون آماری و مقادیر احتمال را نشان می‌دهد.

جدول ۸-۵: مقادیر احتمال (p-values) برای مقایسه‌های معنادار و غیرمعنادار

معیار (هدف)	رقیب پایه	مقدار p (v1)	وضعیت معناداری ($p < ۰/۰۵$)
تلفات بسته (TTS)	DLASER+	$< ۰/۰۰۱$	معنادار (✓)
تلفات بسته (TTS)	Reference	$< ۰/۰۰۱$	معنادار (✓)
مصرف انرژی (TTS)	Reference	۰/۳۲۶	غیرمعنادار (×)
تاخیر (TTS)	Reference	۰/۱۳۴	غیرمعنادار (×)

شگفتی زمانی کامل گشت که در پارامتر اتلاف بسته‌های شبکه (Packet Loss) تمام ۱۰۰٪ از تست‌ها ارزش بهبود معنادار ارائه دادند؛ به‌طور نمونه، احتمال وقوع تصادفی برتری آن برای متد TTS شبکه اول در مقابل مدل‌های DLASER+ و رویکرد مرجع کمتر از ۰.۰۰۱ برآورد گردید ($p < 0.001$). مواردی جزئی نیز که نتایج قابل توجهی نداشتند (مانند آزمون تاخیر که مقدار $p = 0.134$ در شبکه اولیه دریافت نمود یا مصرف انرژی که در حالت TTS مقداری معادل $p = 0.326$ ثبت کرد) عمدتاً به دلیل عملکرد متعادل با روش مرجع بوده و هیچ‌گونه شواهدی مبنی بر تضعیف متد مورد بررسی به دست نمی‌دهد.

۵-۸ خلاصه فصل

این فصل به نحو جامعی توانست ادعاهای نوآوری رساله پیرامون مکانیزم شکل‌دهی یادگیری را تایید نماید. با مرور نتایج مشخص گردید: (۱) متد ابداعی RS-DRL با پایداری ویژه‌ای توانسته تمامی الگوریتم‌های پرآوازه و قدرتمند فعلی پیشین را در ابعاد بهبود عملکرد یادگیری کیفیت و کنترل سیستم شکست دهد. (۲) این برتری در حدود ۳۰.۸۹٪ مواقع توسط تست‌های اعتبارسنجی آماری تأیید گردیده‌اند (۲۵ مورد از ۲۸ مقایسه کلیدی). (۳) این متد ثابت نمود تغییر مقیاس گزینه‌های وفقی از ۲۱۶ به ۴۰۹۶ گزینه نمی‌تواند قابلیت‌های آن را مختل نماید. (۴) مکانیزم شکل‌دهی مجدد توانسته در مقایسه دقیق و عمیق، از وقوع توقف سیستم‌ها در تله‌های استثنای محلی جلوگیری کند و نهایتاً (۵) برخلاف متدهای رایج هم‌نوع پیشرفته خود نظیر مدل‌های HER، برای پویایی پایدار اساساً نیازمند تخصیص دانش سیستم‌ها با دامنه نامشخص (Domain-specific knowledge) و یا اهداف صریح از پیش مقدر نبوده است.

فصل ۶

بحث، نتیجه‌گیری و پیشنهادها

۱-۶ بحث در مورد یافته‌های کلیدی

این بخش با ترکیب نتایج اصلی و تشریح اهمیت آن‌ها، یافته‌های مستخرج از رساله را مورد ارزیابی عمیق قرار می‌دهد.

۱-۱-۶ نظریه‌پردازی مکانیزم: چرا RS-DRL کار می‌کند؟

همان‌طور که در نتایج ارزیابی تجربی (مندرج در فصل ۵ و با استناد به شکل‌های ۵ و ۶ در مقاله مرجع [۱]) نشان داده شد، یکی از مهم‌ترین نقاط قوت RS-DRL توانایی آن در فرار از بهینه‌های محلی است که یک چالش جدی و متداول در سیستم‌های DRL محسوب می‌شود. در محیط‌های پویا، پاداش متوسط مدل RS-DRL نه تنها به‌طور پیوسته افزایش می‌یابد، بلکه در وضعیت پایداری نسبت به رویکرد پایه ϵ -greedy DQN - که با نوسانات شدیدی همراه است و نمی‌تواند از راه‌حل‌های غیربهینه رهایی یابد - در سطحی بسیار بالاتر تثبیت می‌گردد.

اثربخشی رویکرد RS-DRL را می‌توان به سه مکانیزم به هم پیوسته زیر نسبت داد:

۱. اکتشاف از طریق تزریق پاداش خوش‌بینانه: با تغییر تدریجی و تصادفی تجربیات ناموفق گذشته ($r_i = 0$) به تجربیات موفق ($r_i = 1$)، عامل یادگیرنده سیگنال‌های تقویت‌کننده مثبتی را از اعمال و وضعیت‌هایی دریافت می‌کند که در شرایط عادی از اولویت خارج می‌شدند. این امر از همگرایی زودهنگام مدل به سیاست‌های غیربهینه که یکی از معضلات بنیادین DQN استاندارد است، ممانعت به عمل می‌آورد.

۲. شکستن همبستگی زمانی در الگوهای شکست: انتخاب تصادفی در فرآیند تغییر تجربیات مردود (که توسط پارامتر ρ کنترل می‌گردد) متغیری را معرفی می‌کند که مانع از حفظ بیش حد (Overfitting) عامل بر روی شرایط متوالی شکست می‌شود. این متغیر به ویژه در محیط‌های غیرایستایی (Non-stationary) که در آن‌ها شکست دیروز ممکن است استراتژی بهینه امروز تلقی گردد، بسیار راهگشا خواهد بود.

۳. یادگیری مستقل از دامنه (Domain-Agnostic): برخلاف روش‌های متکی به HER که مستلزم تعاریف صریح و قطعی از اهداف هستند، شکل‌دهی تصادفی RS-DRL بدون هیچ‌گونه نیاز به درک معنایی اهداف دامنه عمل می‌کند. این موضوع، اجرای آن را ذاتاً برای سیستم‌هایی انعطاف‌پذیر می‌سازد که با اهداف تلویحی و آستانه‌محور - که در سیستم‌های خودوفقی بسیار شایع می‌باشند - سروکار دارند.

۶-۱-۲ تحلیل تعاملات و مصالحه‌ها (به‌عنوان مثال، تأخیر در مقابل از دست رفتن بسته)

در جداول مقایسه‌ای پیشین (برای نمونه جدول ۶ در توصیفات ارزیابی)، مشاهده گردید که برای تخصیص هدف TTS در شبکه DeltaIoTv1، مدل RS-DRL به درستی به تأخیر متوازی دست پیدا کرد (مقدار ۰.۹۷۰ در برابر ۱۰۰۰۰ روش مرجع) و در مجموع عملکرد بسیار بهتری در مقایسه با DLASER+ نشان داد. با این وجود، برای شبکه DeltaIoTv2 تحت هدف TT مقدار تأخیر بالاتری حاصل شد (۲۵۱.۰ در برابر ۱۰۰۰۰ روش مرجع).

افزایش تأخیر در نسخه دوم شبکه برای مقاصد مربوط به TT نشان‌دهنده یک مصالحه (Trade-off) بسیار مهم در عملکرد عامل است: هنگامی که هدف کلیدی تعریف‌شده از سوی کاربر (مثلاً حفظ توانایی توان عملیاتی شبکه) با اولویت‌بندی به حداقل رساندن مشکل فقدان بسته توأم گردد، مدل هوشمند درمی‌یابد که باید به منظور جلوگیری از دست‌افتادگی پیام‌ها، به سمت مسیرهای قابل اعتمادتری متمایل شود که به صورت ذاتی کندتر هستند. در محیط‌های بهینه‌سازی چندهدفه، چنین مصالحه‌ای نه تنها یک نقطه ضعف و محدودیت به شمار نمی‌رود، بلکه از قضا یک رفتار برآمده و مطلوب از سوی عامل ارزیابی می‌گردد. چرا که در اینجا اولویت سیستم بر تضمین رساندن بسته‌ها بیش از حفظ سرعت بوده است و در کاربردهایی که صحت اطلاعات در آن‌ها اهمیت حیاتی دارد (مانند مانیتورینگ زیست‌محیطی یا سیستم‌های کنترل صنعتی) این تصمیم به‌عنوان عاقلانه‌ترین انتخاب مهندسی تلقی خواهد شد.

این رفتار کاملاً با اصول انتخاب بهینه در استراتژی‌های پرتو-اپتیمال (Pareto Optimality) همخوانی دارد. هنگامی که مرزهای متضاد انتخاب‌ها بررسی می‌گردند، تنظیمات دارای تأخیر بی‌نهایت کم‌تر عموماً ارتباط معناداری با نرخ بالای اتلاف بسته‌ها - به دلیل استراتژی‌های تهاجمی‌تر انتقال داده - نشان می‌دهند.

راهکار RS-DRL یاد می‌گیرد این خطِ مصالحه را با ظرافت طی کند و تصمیم‌ها را منطبق بر بستر نیاز و با تخصیص وزن‌های اختصاص یافته برای هر متغیر اخذ نماید.

۶-۱-۳ پیامدهای مهندسی سیستم‌های خودوفقی

ثبات، پایداری و همگرایی سریع متد RS-DRL عوامل حیاتی در محیط‌های پویایی هستند که مقیاس و شرایط آن‌ها به سرعت در حال جابجایی است. از طریق در هم تنیدگی مکانیزم شکل‌دهی پاداش، RS-DRL تضمین می‌نماید که عامل تصمیم‌ساز حتی بدون نیاز به بازآموزی و تخصیص پیکربندی‌های جدید به تغییرات پاسخ می‌دهد، در حالی که در اکثر DRL‌های استاندارد الزام به طی مجدد مسیر آموزش برای اداره کردن امور تغییر یافته، مشهود و گریزناپذیر است. این خصوصیت، این مدل را برای سامانه‌های برخط مانند سیستم‌های ابری و شبکه‌های اشیاء که استقرار و بروزرسانی خودکار استراتژی در آن‌ها واجب است، بسیار متمایز می‌سازد. به بیان دقیق‌تر، پیامدهای عملی این رهیافت برای مهندسين توسعه‌دهنده محیط‌های خودوفقی شامل موارد زیر است:

۱. کاهش قابل ملاحظه سربار عملیاتی: مدل‌های سنتی به هنگام برخورد با رانش و تغییر شرایط محیطی نیازمند صرف چرخه‌های متعدد بازآموزی پیاپی می‌باشند. در حالی که ویژگی‌های تعمیم‌پذیری بالای RS-DRL امکان دور ماندن مستمر مدل از بروزرسانی‌های مجدد را فراهم می‌سازد که خود علاوه بر صرفه‌جویی شدید محاسباتی باعث جلوگیری از عملکرد ضعیف مدل در طی ادوار گذار بازآموزی می‌گردد.

۲. بی‌نیازی از داده‌های برجسب‌دار: برخلاف مدل‌هایی همانند ML4EAS یا DLASER+ که اتکای گسترده‌ای به تجمیع پیشین داده‌ها داشته‌اند، الگوریتم RS-DRL کاملاً آنلاین و در لحظه توسعه می‌یابد. این قابلیت نقطه قوت برجسته‌ای در محیط‌هایی محسوب می‌گردد که تهیه اطلاعات پیش‌آموزشی غیرممکن و پیش‌بینی‌ناپذیر است.

۳. پایداری و کاهش تخریب تدریجی کیفیت متناسب با گسترش: استواری معنادار کیفیت و عملکرد در مواجهه با نسخه‌ی ۲۰۱۶ - گزینه‌ای (نسخه v1)، گسترش ۱۲۹۶ - گزینه‌ای (نسخه v1.1) و مقیاس سرسام‌آور ۴۰۹۶ حالت ممکن (نسخه v2) مؤید آن است که این راهکار متناسب با میزان گستردگی شبکه قابل استقرار است. همچنین افزایش مقطع زمانی همگرایی مدل، به نسبت پیچیدگی فضای جستجو، شیبی کمتر از حالت خطی (Sublinear) دارد.

۴. تصمیم‌گیری شفاف و قابل مدل‌سازی: رویه‌های رفتارگونه‌ی عامل (همانند پدیده مصالحه در برخورد

با اتلاف دیتا و زمان توقف) به نحو کاملاً معنادار و قابل تعریفی مدل‌گستر و قابل توضیح می‌باشد که این ویژگی به مهندسان قدرت تحلیل مضاعف و قابلیت اطمینان بیشتری عرضه می‌نماید.

۲-۶ محدودیت‌ها و تهدیدات اعتبار (Threats to Validity)

مانند تمامی رهیافت‌های پژوهشی، متدولوژی معرفی شده با محدودیت‌هایی مواجه است که بررسی صریح روایی و صحت نتایج استخراج شده، بستر مناسب را برای پژوهش‌های مکمل آینده تبیین می‌نماید.

۱-۲-۶ اعتبار داخلی (Internal Validity)

۱. حساسیت نسبت به ابرپارامترها: فاکتور کنترل‌کننده‌ی شکل‌دهی تجربیات تصادفی (p)، متولی تنظیم نمودن درصد اختصاص تجربه‌های ناموفق تغییر یافته به نمونه‌های فرضی مثبت و امیدوارکننده است. با اینکه از طریق کاوش شبکه‌ای جامع (Grid Search) توانستیم مناسب‌ترین مقادیر ممکن برای بهینه‌سازی عملکرد یافت کنیم، لیکن این مقادیر می‌توانند به نسبت سایر سیستم‌ها و دامنه‌های متفاوت، دستخوش نوسان باشند. بدیهی‌ست چنانچه پارامتر بسیار بالا وضع گردد موجب اختلال در روند یادگیری گردیده و مقادیر ضعیف آن نیز سبب نقصان در عامل فشار اکتشاف خواهد گشت.

۲. نوسانات بذر تصادفی تولید ارقام (Random Seed Sensitivity): با وجود اجرای بیش از ۳۰ دور فرآیند آموزش مستقل همراه با صحت‌سنجی مستحکم آماری، ماهیت درگیر با احتمالات - چه در پویایی خود محیط و چه در بدنه تنظیم پاداش‌ها - سبب می‌شود تا خروجی‌های هر دوره آموزشی با درجات کوچکی از انحراف واریانس مواجه گردند. با این وصف، فواصل و حاشیه‌های اطمینان به دست آمده (قید شده در جداول فصل ۴) تبیین‌گر کمیت این نوسانات هستند.

۳. مفروضات بازده دودویی (Binary Reward Assumption): یکی از شرایط پیش‌نیاز به کار رفته در الگوریتم، اتکا بر مفروضات مرتبط با نتایج قطعی پیامدهای انطباقی به‌عنوان اهداف توفیق/سقوط مطلق دودویی (یا در مقیاس‌های استاندارد مشابه) است که نمی‌توان آن را به سهولت با کلیه نیازهای سیستم‌های ترکیبی غول‌پیکر وفق داد.

۲-۲-۶ اعتبار خارجی (External Validity)

۱. تخصص حوزه (Domain Specificity): فرآیند ارزیابی منحصرراً بر روی بستر شبکه‌های حسگر بی‌سیم (DeltaIoT) متمرکز بوده است، که تعمیم‌پذیری نتایج به سایر حوزه‌ها را محدود می‌کند. هرچند

پلتفرم مذکور آینه‌ای از مشکلات اساسی سیستم‌های مدرن را به تصویر کشیده و تایید کیفیت کرده است، با این وصف، اعمال الگوریتم توسعه‌یافته بر دیگر شبکه‌های توزیع‌یافته، نیازمند اعتبارسنجی مستقلی خواهد بود.

۲. تمرکز بهینه بر شبکه‌های گسسته: تدوین و صورت‌بندی فعلی به نحوی طراحی گشته که متناسب با فضای تصمیم‌داری مدل‌های محدود گسسته پایه‌ریزی شود. لیکن اکثریت سیستم‌های پویا (مانند سیستم‌های مقیاس‌بندی و تنظیم ظرفیت پردازشی ابری) از پارامترهای پیوسته استفاده می‌نمایند و تنظیم معماری RS-DRL متناسب با متدهای کلاسیک پیوسته نظیر شبکه‌های DDPG ساختارهای بسط یافته مطالعاتی جدیدی را می‌طلبد.

۳. توسعه‌ی در حوزه‌های حساس ایمنی: استفاده از استراتژی خوش‌بینی بر روی اقداماتی که ذاتاً و در دنیای فیزیکی خطرناک بوده‌اند (همانند پلتفرم‌های هدایت اتومبیل‌های هوشمند و یا سیستم‌های دارورسانی)، بدون در نظر گرفتن شرط احتیاط، ممکن است باعث ترغیب ماشین به انجام فعالیت‌های منجر به حادثه گردد و افزودن حلقه‌های تکمیلی تایید صلاحیت بسیار با اهمیت است.

۳-۲-۶ اعتبار سازه (Construct Validity)

۱. شفافیت متریک‌ها: سنجش عملکرد عامل هوش از قبیل بررسی مجانبی ثبات کیفیت زمانی تا رسیدن به راندمان مطلوب آستانه، رویه‌هایی پذیرفته شده می‌باشند؛ اما معرفی فاکتورهای سنجشی جایگزین مانند نرخ رنجوری (رگرت) و شاخص پایداری ممکن است ابعاد ناشناخته دیگری را نمایان سازند.

۲. اصطکاک سنجشی مدل‌های جایگزین: از آنجا که مدل‌های برگرفته از HER نیازمند تنظیم صریح برچسب‌گذاری مقصد بوده‌اند، مقایسه صورت پذیرفته نیاز به در نظر گرفتن جایگزین‌های ضمنی کیفی داشت. هرچند مستندسازی اعمال شده بسیار متوازن بود ولی باید اذعان داشت که استفاده از این مقادیر تعدیل یافته معادل بهینه‌ای برای تمام ظرفیت موجود این دست از رقبا نمی‌تواند قلمداد گردد.

۳-۶ مسیرهایی برای تحقیقات آینده

۱-۳-۶ استراتژی‌های انطباقی و وفقی شکل‌دهی ρ

همان‌طور که در فصل بررسی چالش‌ها بحث شد، اتکا به متغیر کنترل‌گر ρ برای الگوریتم ضروری است. ما در توسعه‌های آتی در نظر داریم با برنامه‌ریزی یک ساختار هوشمند برای تنظیم نرخ فاکتور کنترل‌کننده متناسب با فرآیندهای زمانی مدل پیشروی کنیم تا قابلیت استقرار در زمان اجرای سیستم را تسهیل نماییم. برخی از جهت‌گیری‌های تخصصی شامل موارد زیر می‌باشد:

۱. برنامه‌ریزی تنظیمی پویای پارامتر (ρ): به جای یک متغیر تنظیم شده دستی، از سازوکاری جهت ارتقا یا تخفیف متغیر بهره خواهیم جست؛ بدین گونه که در هنگامه موفقیت‌های مکرر و تسلط ماشین (فاز استعمار) از درصد فاکتور ρ کاسته شده و در هنگام درگیری مستمر ماشین و گرفتار شدن آن درون تله‌ی بهینه محلی که نرخ دریافت ارزش با فُتول روبرو می‌گردد به صورت پویا با ارتقای متغیر ضریب فشار فرار و اکتشاف تجربیات جدید تشدید شود. در این مسیر استفاده از مدل‌های فرا-یادگیری (Meta-Learning) نیز در خصوص استنتاج بهینه فاکتور مفید فایده خواهد بود.

۲. شکل‌دهی هوشمند بر پایه‌ی خطای عدم اطمینان: امکان به کارگیری ابزارهای ارزیابی تخمین اطمینان (مانند Dropout یا انواع مدل‌های انسامبل) در الگوریتم، مقدور می‌سازد تا آن دسته از تجربه‌های شکست خورده‌ای در چرخه‌ی تصادفی‌سازی اولویت یابند که سیستم درباره‌ی قطعیت خطاهای شان کمترین اطمینان و شناخت را در محیط غیرشناخته از خود نشان داده بود.

۳. اولویت‌بندی حافظه‌ی نمونه‌گیری: ادغام روش انتخاب هوشمند با الگوریتم‌های حافظه‌ی مبتنی بر اولویت (Prioritized Experience Replay)، عاملی را معرفی می‌کند تا زیرمجموعه‌های مردود شده‌ی مستعد جبران پس از اعمال شکل‌دهی، با فرکانس شانس بیشتری برای بازیابی توسط شبکه مجدداً احضار شوند.

۲-۳-۶ گسترش به دامنه‌های پیوسته و حساس به ایمنی

با عنایت به ماهیت پویای فضای نرم‌افزار، توسعه روش‌های حاضر بر مسائل نوین‌تر ضروری خواهد بود:

۱. فضای اعمال پیوسته (Continuous Action Spaces): بسط معماری متدیک فعلی در بطن متدهای قدرتمندتری نظیر سیستم‌های شیب‌سیاستی همانند متدهای PPO و SAC از اهداف توسعه‌ی اصلی

پژوهش است تا علاوه بر شکل‌دهی پاداش تصادفی، بتوان پارامترهای بدون گسستگی (همچون تنظیم منابع سخت‌افزاری پردازش در فضای ابری) را تنظیم نمود.

۲. اعمال محدودیت‌های تایید ایمنی (Safe Reshaping): برای رفع نگرانی مطرح شده در دامنه‌های حساس به ایمنی، در نظر داریم مکانیزمی با عنوان «شکل‌دهی ایمن» پدید آوریم که بازتولید تصادفی نتایج شکست‌خورده تنها زمانی مُیسّر گردد که خط‌مشی پیش‌بینی‌شده در مناطق ایمن تاییدشده قرار گیرد. ترکیب با ابزارهای اعتبارسنجی صوری (همچون UPPAAL-SMC استفاده شده در این تحقیق) از هدایت به وضعیت‌های ناایمن پیشگیری می‌کند.

۳. گسترش به سامانه‌های چند عاملی (Multi-Agent): برای مقابله با فضاهایی با پویایی بخش‌های تطبیقی در حال تعامل با هم، گسترش متد در چارچوبی صورت می‌پذیرد که چند عامل در هماهنگی استراتژی‌های کاوش همسان به شکل‌دهی پاداش‌های منسجم برای تحقق اهداف بزرگ عمل کنند.

۳-۳-۶ اعتبارسنجی بین‌دامنه و تحلیل‌های نظری

جهت بررسی فراگیری این استراتژی و ایجاد پایه‌های نظری قوی‌تر اهداف زیر دنبال خواهد گردید:

۱. پیکربندی شبکه‌های ابری (Cloud Auto-scaling): به‌کارگیری این رویکرد به جهت تخصیص و توزیع مقیاس ماشین‌های مجازی، و ارزیابی در برابر کارهای مرتبط دیگر در این محیط.

۲. هماهنگی وسایل نقلیه خودران (Autonomous Vehicles): آزمایش در محیط‌های شبیه‌سازی برای هماهنگ‌سازی و تطبیق الگوهای ترافیکی با محدودیت‌های ایمنی و اهداف چندگانه (زمان سفر، بهینه‌سازی انرژی و امنیت).

۳. تضمین تئوریک فرآیند همگرایی (Theoretical Analysis): بررسی اینکه آیا سیگنال پاداش شکل‌دهی‌شده ویژگی انقباضی و نگاشت ثابت برای یادگیری کیو (Q-Learning) را حفظ می‌کند، و محاسبه کران‌های خطای احتمالی انحراف ارزش Q نسبت به سیاست بهینه.

۴. کاهش حجم پیچیدگی نمونه‌ها (Sample Complexity Analytical Analysis): کمیت‌بندی تئوریک پیرامون اثربخشی شکل‌دهی پاداش بر تقلیل شمار نمونه‌های لازم برای دستیابی به خروجی‌های نزدیک به بهینه در قیاس با شبکه‌ی DQN استاندارد.

۴-۶ نتیجه‌گیری

۱-۴-۶ خلاصه بیان مسئله و راهکار پیشنهادی

این رساله به‌عنوان دستاوردی متصل بر یکی از چالش‌های بنیادین سیستم‌های خودوفقی مقاصد خود را تنظیم نموده است؛ مدیریت عدم قطعیت در شبکه‌هایی که درون فضاها بزرگ و گسسته‌ی تطابق عمل می‌کنند. رویکردهای سنتی - اعم از مدل‌های مبتنی بر یادگیری ماشین، مدل‌های متکی بر جستجو و یا یادگیری تقویتی استاندارد - با محدودیت‌های شدیدی مواجه بوده‌اند؛ ویژگی‌هایی از قبیل نیاز مبرم به دیتای برچسب‌دار آفلاین، دست و پنجه نرم کردن با فقدان مقیاس‌پذیری و احتمال بالای توقف در بهینه‌های محلی برآمده از تغییر شرایط. ما استراتژی یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) را ارائه نمودیم؛ رویکردی نوین که مکانیسم تصادفی شکل‌دهی را درون جریان حافظه بازپخش عامل کیو (DQN) یکپارچه می‌نماید. با بهره‌گیری از زیرمجموعه‌ای از تجربیات ناکام فاز گذشته ($r_i = 0$) و اعمال تحول در پاداش و تبدیل آن به تجربه‌ای خوش‌بینانه ($r_i = 1$)، راهکار RS-DRL مشوق قدرتمند فرآیند اکتشاف بوده و از گرفتاری در بهینه‌های محلی جلوگیری می‌نماید، بدون آنکه کمترین الزامی برای تعریف و اختصاص قطعی اهداف مبتنی بر دانش از پیش تعیین‌شده دامنه، داشته باشد.

۲-۴-۶ مرور مشارکت‌ها و شواهد تجربی

یافته‌های مستخرج پژوهش که ارائه‌ی پاسخی قاطع بر پرسش‌های این رساله به شمار می‌آید شامل موارد کلیدی زیر است. جدول ۶-۱ خلاصه‌ای از این مشارکت‌ها و شواهد را نشان می‌دهد.

جدول ۶-۱: خلاصه‌ای از مشارکت‌های کلیدی و شواهد تجربی

مشارکت (Contribution)	شواهد (Evidence)	اهمیت (Significance)
شکل‌دهی پاداش نوین (Novel Reward Shaping)	توسعه الگوریتم ۴-۱، نمایش در شکل‌های ۵ و ۶	امکان اکتشاف بدون نیاز به دانش دامنه سیستم
تطبیق و وفقی‌سازی مقیاس‌پذیر	مستخرج از جداول ۳ و ۴ (نسخه‌های v1 تا v2)	حفظ پایداری عملکرد با رشد گزینه‌ها از ۲۱۶ تا ۴۰۹۶ حالت
برتری و تفوق اثبات آماری	تحلیل جداول ۵ و ۶، معناداری ۲۵ از ۲۸ تست	دریافت $p < 0.001$ برای اکثر متریک‌های بهبود اتلاف بسته

مشارکت اول: ابداع ماشین نوین جهت شکل‌دهی پاداش توسعه الگوریتم تخصیص پاداش (طراحی الگوریتم ۴-۱) که از طریق کنترل‌کننده‌ای با ضریب مشخص (ρ) عمل نموده و برخلاف رویکردهای غایت‌محور نظیر متدهای HER هیچگونه نیازی بر تعیین هدف آستانه‌ای با درک معنایی نداشته و مستقیماً روی سیستم‌های خودوفقی قابل راه‌اندازی است.

مشارکت دوم: یکپارچه‌سازی حلقه کنترل MAPE-K طراحی زیرسامانه‌ی متصل متشکل از چرخه ۹ مرحله‌ای که RS-DRL را با حلقه MAPE-K ترکیب می‌کرد؛ مجهز به ارزیابی برای تضمین اعتبار زمان اجرا با موتور کنترل UPPAAL-SMC و مؤلفه ActivFORMS برای اجرای واقعی.

مشارکت سوم: دستاوردهای تجربی در مقیاس اینترنت اشیاء دستاورد استقرار شبکه‌ی عامل بر بستر ۳ مقیاس وسیع (فضای محدود ۲۱۶، نسخه ۱۲۹۶ و نسخه منبسط ۴۰۹۶ تصمیم ممکن). دستیابی بی‌رقیب به نرخ مجانبی 0.268 ± 0.9905 (در شبکه اولیه) و 0.932 ± 0.8983 (در v1.1) که با قاطعیت ساختار کلاسیک ϵ -greedy DQN (با راندمان 0.2233 ± 0.4559) و مشابه‌های HER را مغلوب ساخت. ثبت کاهش شگفت‌انگیز ۲۲/۲۳٪ برای نابودی بسته‌ها و ۰۷/۳۹٪ کاهش تأخیر شبکه نسبت به DLASER+ تحت اهداف TTS. این مقادیر از طریق نتایج آزمون t-test (موفقیت در ۳۰۸۹٪ از ۲۸ مقایسه متمایز) اعتبار مطلق دریافت کرد.

مشارکت چهارم: بینش عمیق نظری و عملی اثبات و آشکارسازی اینکه مکانیزم روایی برای تزریق خوش‌بینی نه تنها راه‌حلی منطقی، خروج سیستم را از گیر افتادن مصون داشته، بلکه تحلیل الگوهای متضاد درون سیستمی نظیر (تأخیر متناقض با نرخ اتلاف بسته‌ها) نشان دادیم عامل استنتاج‌هایی به وسعت دانش طراحی چند-هدفه و سازگار با رفتار سیستم هوشمند اخذ کرده است و همزمان این ظرفیت برای تغییر سبک و پدیده‌ی مقیاس‌پذیری فضای عمل بسیار کارآمد بوده است.

۳-۴-۶ سخنان پایانی

از آنجا که سیستم‌های نرم‌افزاری به‌طور فزاینده‌ای در محیط‌هایی سرشار از عدم قطعیت، پویایی و مقیاس‌های بزرگ عمل می‌کنند، نیاز به مکانیسم‌های واقعی که بتوانند به‌طور کاملاً مستقل فرآیند یادگیری و تنظیم استراتژی را انجام دهند چشمگیرتر می‌شود. مدل هوشمند RS-DRL یک قدم استوار در جهت این چشم‌انداز تلقی می‌شود - روشی که نه تنها متکی به آموزش‌های مبتنی بر موفقیت است بلکه با ظرفیتی شایسته، از بطن اشتباهات پیشین درس‌های بسیار موثری اخذ می‌کند و به بیان دیگر کاستی‌های پیشین را به یک فرصت ارزنده تبدیل خواهد کرد.

اهمیت این تحقیقات مرزهای توسعه‌یافته در یک شبکه DeltaIoT را کاملاً در هم شکسته است. هر نوع معماری که توأمان با ۳ چالش بنیادین سیستم نرم‌افزار (استقرار محیط پیکربندی کلان، عدم قطعیت‌های متغیر شرایط و نیاز تطبیق زمان اجرا) دست و پنجه نرم کند، با تکیه بر متد معرفی‌شده در RS-DRL می‌تواند بر این معضل غلبه نماید، به گونه‌ای که سیستم‌های ابری، امنیت سایبری شبکه، کنترل برق هوشمند و هدایت پهپادهای یکپارچه از مصادیق این قابلیت‌ها هستند.

مأموریت نهایی آینده برای سیستم‌ها آن است که نه تنها مستمراً راهبری سیستم را هماهنگ بدانند بلکه فراتر از آن استراتژی را پیوسته غنی‌سازی نمایند — هدفی بزرگ که در شرف تحقق پیوسته است. رساله‌ی حاضر با اتکا بر راهکار ابداعی RS-DRL تلاش داشته خشت کوچکی اما ارزشمند رو به سوی این آرمان کلان مهندسی نرم‌افزار بنا کند.

کتاب نامه

- [1] A. Kavianifar *et al.*, “Randomized reward-shaped deep reinforcement learning for managing uncertainty in self-adaptive systems,” *Unpublished Thesis*, 2026.
- [2] G. Du, Y. Wang, Y. Liu, X. Wu, and L. Ma, “Alleviating local optima and enhancing path planning: A deep reinforcement learning approach for autonomous exploration,” in *International Conference on Autonomous Unmanned Systems*, (Singapore), pp.124–133, Springer Nature Singapore, September 2023.
- [3] O. Gheibi and D. Weyns, “Dealing with drift of adaptation spaces in learning-based self-adaptive systems using lifelong self-adaptation,” *ACM Transactions on Autonomous and Adaptive Systems*, vol.19, no.1, pp.1–57, 2024.
- [4] F. Quin *et al.*, “Efficient analysis of large adaptation spaces in self-adaptive systems using machine learning,” in *2019 IEEE/ACM 14th International Symposium on Software Engineering for Adaptive and Self-Managing Systems (SEAMS)*, IEEE, 2019.
- [5] F. Quin, D. Weyns, and O. Gheibi, “Reducing large adaptation spaces in self-adaptive systems using machine learning,” *Journal of Systems and Software*, p.111341, 2022.
- [6] F. Kachi and C. Bouanaka, “A hybrid model for efficient decision-making in self-adaptive systems,” *Information and Software Technology*, vol.153, p.107063, 2023.
- [7] Z. Coker, D. Garlan, and C. L. Goues, “Sass: Self-adaptation using stochastic search,” in *10th International Symposium on Software Engineering for Adaptive and Self-Managing Systems, SEAMS 2015*, Institute of Electrical and Electronics Engineers Inc, 2015.
- [8] C. Kinneer *et al.*, “Managing uncertainty in self-adaptive systems with plan reuse and stochastic search,” in *ACM/IEEE 13th International Symposium on Software Engineering for Adaptive and Self-Managing Systems, SEAMS 2018, , co-located with International Conference on Software Engineering, ICSE 2018*, IEEE Computer Society, 2018.
- [9] C. Kinneer *et al.*, “Building reusable repertoires for stochastic self-* planners,” in *2020 IEEE International Conference on Autonomic Computing and Self-Organizing Systems (ACSOS)*, IEEE, 2020.

- [10] C. Kinneer, D. Garlan, and C. L. Goues, "Information reuse and stochastic search: Managing uncertainty in self-* systems," *ACM Transactions on Autonomous and Adaptive Systems (TAAS)*, vol.15, no.1, pp.1–36, 2021.
- [11] T. Chen *et al.*, "Femosaa: Feature-guided and knee-driven multi-objective optimization for self-adaptive software," *ACM Transactions on Software Engineering and Methodology*, vol.27, no.2, 2018.
- [12] D. Kim and S. Park, "Reinforcement learning-based dynamic adaptation planning method for architecture-based self-managed software," in *2009 ICSE Workshop on Software Engineering for Adaptive and Self-Managing Systems*, IEEE, 2009.
- [13] A. Metzger *et al.*, "Realizing self-adaptive systems via online reinforcement learning and feature-model-guided exploration," *Computing*, pp.1–22, 2022.
- [14] J. Cámara, H. Muccini, and K. Vaidhyanathan, "Quantitative verification-aided machine learning: A tandem approach for architecting self-adaptive iot systems," in *2020 IEEE International Conference on Software Architecture (ICSA)*, IEEE, 2020.
- [15] M. Andrychowicz, F. Wolski, A. Ray, J. Schneider, R. Fong, P. Welinder, B. McGrew, J. Tobin, P. Abbeel, and W. Zaremba, "Hindsight experience replay," in *Advances in Neural Information Processing Systems*, vol.30, 2017.
- [16] Q. He, L. Zhuang, and H. Li, "Soft hindsight experience replay," *arXiv preprint arXiv:2002.02089*, 2020.

پیوست آ

جریان‌های کاری کامل فرآیند

پیوست ب

لیست کامل الگوریتم‌ها

پیوست پ

نتایج تجربی گسترده

پیوست

مصنوعات پیاده‌سازی و پکیج بازتولید

Abstract:

Contemporary software systems increasingly operate in dynamic environments characterized by significant uncertainties, such as network interference and traffic fluctuations, which can jeopardize Quality of Service (QoS) objectives. Self-adaptive systems (SAS) provide a fundamental approach to address these challenges using feedback loops. However, managing large and discrete adaptation spaces (comprising hundreds or thousands of configurations) remains a significant challenge. Existing approaches, including machine learning and classical reinforcement learning, often suffer from poor scalability, reliance on labeled data, or being trapped in local optima under environmental shifts. This thesis proposes and evaluates a novel method called Randomized Reward-Shaped Deep Reinforcement Learning (RS-DRL) for efficient uncertainty management in SAS. The proposed method integrates a Deep Q-Network (DQN) core within the standard MAPE-K control loop. The primary innovation is the “Randomized Reward Shaping” mechanism, which strategically redesigns a random subset of failed past experiences in the replay buffer with optimistic (pseudo-success) rewards. Crucially, the reward signal is gated by formal verification results from UPPAAL-SMC, ensuring that learning is guided by formal safety and quality constraints. While the formal model requires domain-specific configuration, the randomized shaping heuristic itself is domain-agnostic and does not require explicit goal coordinates or intensive domain expertise for exploration. Experimental evaluation was conducted on the DeltaIoT exemplar within wireless sensor network scenarios featuring adaptation spaces of up to 4096 configurations. The results demonstrate that RS-DRL significantly outperforms state-of-the-art baselines, including DQN, HER, Soft HER, and DLASER+. Specifically, under the Threshold-based (TT) goal, RS-DRL achieved a 23.22% reduction in packet loss and a 39.07% reduction in latency compared to the DLASER+ baseline. Statistical analysis confirms the robustness and scalability of the proposed approach, establishing RS-DRL as a resilient optimization strategy for next-generation complex self-adaptive systems.

Keywords: Self-Adaptive Systems, Deep Reinforcement Learning, Randomized Reward Shaping, Uncertainty Management, Formal Verification, UPPAAL-SMC



Tarbiat Modares University
Faculty of Electrical and Computer Engineering

Randomized Reward-Shaped Deep Reinforcement Learning for Managing Uncertainty in Self-Adaptive Systems

**A Thesis Submitted in Partial Fulfillment of the Requirement for the Degree
of Doctor of Philosophy in Computer Engineering**

By:
Alireza Kavianifar

Supervisor:

Dr. ...

Advisor:

Dr. ...

February 2026