
بسم الله الرحمن الرحيم

دانشکده مهندسی برق و کامپیوتر

رساله دکتری در رشته مهندسی کامپیوتر

گرایش مهندسی نرم‌افزار

یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم‌های خودوفق

علیرضا کاویانی‌فر

استاد راهنما

دکتر ...

استاد مشاور

دکتر ...

بهمن ۱۴۰۴

تأییدیه‌ی هیأت داوران جلسه‌ی دفاع از رساله

خانم/آقای علیرضا کاویانی‌فر رساله — واحدی خود را با عنوان یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش برای مدیریت عدم قطعیت در سیستم‌های خودوفق در تاریخ بهمن ۱۴۰۴ارائه کردند. اعضای هیات داوران نسخه نهایی این رساله را از نظر فرم و محتوا تایید کرده است و پذیرش آنرا برای تکمیل درجه دکتری پیشنهاد می‌کنند.

آیین‌نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهشهای علمی‌دانشگاه تربیت مدرس

مقدمه: با عنایت به سیاست‌های پژوهشی و فناوری دانشگاه در راستای تحقق عدالت و کرامت انسانها که لازمه شکوفایی علمی‌و فنی است و رعایت حقوق مادی و معنوی دانشگاه و پژوهشگران، لازم است اعضای هیأت علمی، دانشجویان، دانش‌آموختگان و دیگر همکاران طرح، در مورد نتایج پژوهشهای علمی‌که تحت عناوین پایان‌نامه، رساله و طرحهای تحقیقاتی با هماهنگی دانشگاه انجام شده است، موارد زیر را رعایت نمایند:

ماده ۱- حق نشر و تکثیر پایان‌نامه/رساله و درآمدهای حاصل از آنها متعلق به دانشگاه می‌باشد ولی حقوق معنوی پدید آورندگان محفوظ خواهد بود.

ماده ۲- انتشار مقاله یا مقالات مستخرج از پایان‌نامه/ رساله به صورت چاپ در نشریات علمی‌و یا ارائه در مجامع علمی باید به نام دانشگاه بوده و با تایید استاد راهنمای اصلی، یکی از اساتید راهنما، مشاور و یا دانشجو مسئول مکاتبات مقاله باشد. ولی مسئولیت علمی‌مقاله مستخرج از پایان نامه و رساله به عهده اساتید راهنما و دانشجو می‌باشد. تبصره: در مقالاتی که پس از دانش‌آموختگی بصورت ترکیبی از اطلاعات جدید و نتایج حاصل از پایان‌نامه/ رساله نیز منتشر می‌شود نیز باید نام دانشگاه درج شود.

ماده ۳- انتشار کتاب، نرم‌افزار و یا آثار ویژه (اثری هنری مانند فیلم، عکس، نقاشی و نمایشنامه) حاصل از نتایج پایان‌نامه/ رساله و تمامی‌طرحهای تحقیقاتی کلیه واحدهای دانشگاه اعم از دانشکده ها، مراکز تحقیقاتی، پژوهشکده ها، پارک علم و فناوری و دیگر واحدها باید با مجوز کتبی صادره از معاونت پژوهشی دانشگاه و براساس آئین نامه های مصوب انجام شود.

ماده ۴- ثبت اختراع و تدوین دانش فنی و یا ارائه یافته ها در جشنواره‌های ملی، منطقه‌ای و بین‌المللی که حاصل نتایج مستخرج از پایان‌نامه/ رساله و تمامی‌طرح‌های تحقیقاتی دانشگاه باید با هماهنگی استاد راهنما یا مجری طرح از طریق معاونت پژوهشی دانشگاه انجام گیرد.

ماده ۵- این آیین‌نامه در ۵ ماده و یک تبصره در تاریخ۸۷/۴/۱ در شورای پژوهشی و در تاریخ ۸۷/۴/۲۳ در هیأت رئیسه دانشگاه به تایید رسید و در جلسه مورخ ۸۷/۷/۱۵ شورای دانشگاه به تصویب رسیده و از تاریخ تصویب در شورای دانشگاه لازم‌الاجرا است.

اینجانب علیرضا کاویانی‌فر به شماره دانشجویی ... دانشجوی رشته مهندسی کامپیوتر مقطع تحصیلی دکتری دانشکده مهندسی برق و کامپیوتر متعهد می‌شوم کلِیه نکات مندرج در آئین نامه حق مالکیت مادی و معنوی در مورد نتایج پژوهش های علمی‌دانشگاه تربیت مدرس را در انتشار یافته های علمی‌مستخرج از

پایان‌نامه/رساله تحصیلی خود رعایت نمایم. در صورت تخلف از مفاد آئین نامه فوق الاشعار به دانشگاه وکالت و نمایندگی می‌دهم که از طرف اینجانب نسبت به لغو امتیاز اختراع بنام بنده و یا هر گونه امتیاز دیگر و تغییر آن به نام دانشگاه اقدام نماید. ضمناً نسبت به جبران فوری ضرر و زیان حاصله بر اساس برآورد دانشگاه اقدام خواهم نمود و بدینوسیله حق هر گونه اعتراض را از خود سلب نمودم»

تاریخ و امضا:

آیین نامه چاپ پایان‌نامه (رساله)های دانشجویان دانشگاه تربیت مدرس

نظر به اینکه چاپ و انتشار پایان نامه (رساله)های تحصیلی دانشجویان دانشگاه تربیت مدرس، مبین بخشی از فعالیتهای علمی- پژوهشی دانشگاه است بنابراین به منظور آگاهی و رعایت حقوق دانشگاه،دانش آموختگان این دانشگاه نسبت به رعایت موارد ذیل متعهد می‌شوند: ماده ۱: در صورت اقدام به چاپ پایان نامه (رساله)ی خود، مراتب را قبلاً به‌طور کتبی به «دفتر نشر آثارعلمی» دانشگاه اطلاع دهد. ماده ۲: در صفحه سوم کتاب (پس از برگ شناسنامه) عبارت ذیل را چاپ کند: «کتاب حاضر، حاصل پایان نامه کارشناسی ارشد/ رساله دکتری نگارنده در رشته مهندسی کامپیوتر است که در بهمن ۱۴۰۴ در دانشکده‌مهندسی برق و کامپیوتر دانشگاه تربیت مدرس به راهنمایی سرکار خانم/جناب آقای دکتر ...، مشاوره سرکار خانم/جناب آقای دکتر ... از آن دفاع شده است.» ماده ۳: به منظور جبران بخشی از هزینه‌های انتشارات دانشگاه، تعداد یک درصد شمارگان کتاب (در هر نوبت‌چاپ) را به «دفتر نشر آثارعلمی» دانشگاه اهدا کند. دانشگاه می‌تواند مازاد نیاز خود را به نفع مرکز نشر درمعرض فروش قرار دهد. ماده ۴: در صورت عدم رعایت ماده ۳، ۵۰% بهای شمارگان چاپ شده را به‌عنوان خسارت به دانشگاه تربیت‌مدرس، تأدیه کند. ماده ۵: دانشجو تعهد و قبول می‌کند در صورت خودداری از پرداخت بهای خسارت، دانشگاه می‌تواند خسارت مذکور را از طریق مراجع قضایی مطالبه و وصول کند؛ به علاوه به دانشگاه حق می‌دهد به منظور استیفای حقوق خود، از طریق دادگاه، معادل وجه مذکور در ماده ۴ را از محل توقیف کتابهای عرضه شده نگارنده برای فروش، تامین نماید. ماده ۶: اینجانب علیرضا کاویانی‌فر دانشجوی رشته مهندسی کامپیوتر مقطع دکتری تعهد فوق وضمانت اجرایی آن را قبول کرده، به آن ملتزم می‌شوم.

استاد راهنما: دکتر ...

تاریخ:

امضا:

تقدیم

(*متن تقدیم به خانواده، اساتید و ...*)

قدردانی

(متن تشکر و قدردانی از اساتید راهنما، مشاور و دوستان)

علیرضا کاویانی‌فر

بهمن ۱۴۰۴

چکیده

سیستم‌های نرم‌افزاری خودوفق در محیط‌های فیزیکی‌ـ سایبری و توزیع‌شده، در فاز برنامه‌ریزی حلقه خودمختار MAPE-K با یک «سه‌گانه برنامه‌ریزی» مواجه هستند: مهلت‌های زمانی سخت میلی‌ثانیه‌ای، فضاهای وفقی مقیاس‌بزرگ با بیش از ٪۹۰ داده‌های شکست در لاگ‌های عملیاتی، و شکاف واقعیت میان مدل‌های جانشین تحلیلی و فیزیک اجرا. این رساله برای غلبه بر این چالش‌ها، یک چارچوب معماری پیشرفته مبتنی بر یادگیری تقویتی عمیق را در دو سطح تکاملی پیشنهاد و اعتبارسنجی می‌کند. در سطح نخست، روش پایه‌ای RS-DRL با ترکیب شبکه کیو عمیق (DQN)، تزریق تصادفی پاداش خوش‌بینانه در بازپخش تجارب گذشته و بازبینی صوری ناهمگام با UPPAAL-SMC، عبور خودمختار از بهینه‌های محلی را در فضاهای وفقی تا ۴۰۹۶ گزینه محقق می‌سازد. در سطح دوم، برای پاسخ‌گویی به مهلت‌های کنترلی سخت (۲۰ تا ۵۰ میلی‌ثانیه) در سیستم‌های فیزیکی‌ـ سایبری، معماری دوسطحی RS-DRL^{+} بر پایه دو الگوی مهندسی نرم‌افزار پیشنهادی توسعه یافته است: الگوی سنتز آفلاین هدایت‌شده با مشخصه (SG-OS شامل روش‌های MU-RS-DRL و CM-RS-DRL) که با تعریف حاشیه بازیابی چندقیدی $\mathcal{M}(s,a)$ و مشوق‌های مطلوبیت عملیاتی، سقوط‌های فاجعه‌بار را حذف و پاداش‌ها را متناسب با عمق انطباق مقیاس‌بندی می‌کند؛ و الگوی اعتبارسنجی کشسان با قرارداد در هر زمان (CA-EPV) در قالب ماژول PG-ALR که استنتاج نامی زیر میلی‌ثانیه‌ای (۰/۴۸۵ ms) ارائه داده و در شرایط تنش محیطی، پالایش دفاعی را بر زیرفضای حساسیت مقادیر شاپلی درختی (TreeSHAP) مقید می‌سازد، به‌طوری‌که با اثبات صوری کران کاردینالیتی $|\mathcal{N}(a.)| \leq 2m+1$ بر روی m بعد حساسیت و K قید کیفی، پیچیدگی وارسی به $\mathcal{O}(m \cdot K)$ و تأخیر کل زمان اجرا به طور قطعی زیر ۳/۵ ms محدود می‌گردد. ارزیابی تجربی بر روی بستر DeltaIoT نشان‌دهنده کاهش ۲۳/۲۲ درصدی اتلاف بسته و ۳۹/۰۷ درصدی تأخیر در مقایسه با روش‌های پیشرفته نظیر DLASER+ است. همچنین، در ۲,۰۰۰ پرواز ۶ درجه آزادی حلقه‌بسته در شبیه‌ساز DARTSim، معماری RS-DRL^{+} با دستیابی به نرخ موفقیت ٪۷۰/۵ (در برابر ٪۶۵/۰ سپرهای ایمنی مرسوم)، کاهش ۳۱ درصدی در واریانس عملیاتی و رعایت قطعی مهلت‌های زمانی، شکاف واقعیت مدل‌ـ تاـ فیزیک را مهار ساخت. یافته‌های این پژوهش، راهکاری عام، مقیاس‌پذیر و اثبات‌پذیر برای مهندسی سیستم‌های خودوفق خودمختار فراهم می‌آورد.

واژگان کلیدی: سیستم‌های خودوفق، یادگیری تقویتی عمیق، شکل‌دهی پاداش، سیستم‌های فیزیکی‌ـ سایبری، اعتبارسنجی در هر زمان، شکاف واقعیت، بازبینی صوری، UPPAAL-SMC، فضاهای وفقی بزرگ، DARTSim، DeltaIoT

فهرست مطالب

فهرست جداول . . . . . **ز**

فهرست تصاویر . . . . . **ط**

فهرست نشانه‌ها و اختصارات . . . . . **ل**

فصل اول: کلیات **۱**

۱-۱ مقدمه ۱

۱-۲ اهداف رساله ۲

۱-۳ چالش‌ها ۴

۱-۴ بیان مساله ۵

۱-۵ سؤالات پژوهش ۸

۱-۶ روش پیشنهادی ۱۰

۱-۶-۱ مرور کلی بر راهکار دوسطحی: روش پایه‌ای RS-DRL و معماری $RS\text{-}DRL^{+}$. ۱۰

۱-۶-۲ یکپارچه‌سازی با حلقه کنترلی MAPE-K ۱۱

۱-۷ نوآوری‌های اصلی رساله ۱۱

۱-۸ مروری بر فصول رساله ۱۴

فصل دوم: مبانی نظری و مدل‌سازی سیستم **۱۷**

۲-۱ مقدمه ۱۷

۲-۲ مبانی سیستم‌های خودوفق ۱۸

۲-۲-۱ مفاهیم اصلی و تعاریف ۱۸

۲-۲-۲ معماری‌های مرجع و الگوهای طراحی ۱۸

۲-۲-۳ حلقه‌های کنترلی خودمختار: از MAPE-K تا موارد پیشرفته ۱۹

۲-۳ عدم قطعیت در سیستم‌های خودوفق ۲۰
۲-۳-۱ دسته‌بندی و انواع عدم قطعیت ۲۰
۲-۳-۲ روش‌های مدل‌سازی و رویارویی با عدم قطعیت ۲۰
۲-۳-۳ چالش‌های خاص عدم قطعیت در فضاهای وفقی بزرگ ۲۱
۲-۴ مبانی نظری و مدل‌سازی ریاضی ۲۲
۲-۴-۱ فرآیندهای تصمیم‌گیری مارکوف و مدل‌سازی ریاضی تصمیم‌گیری ترتیبی ۲۲
۲-۴-۲ یادگیری تقویتی عمیق و سازوکار شبکه‌های کیو عمیق DQN ۲۵
۲-۵ سیستم مورد مطالعه: شبکه‌های حسگر بی‌سیم DeltaIoT ۲۷
۲-۵-۱ معماری، مؤلفه‌ها و ویژگی‌های فیزیکی ۲۷
۲-۵-۲ مدل‌سازی فیزیکی و ریاضیاتی پدیده‌های کانال بی‌سیم ۲۷
۲-۵-۳ جزئیات فرمول‌بندی معیارهای کیفیت خدمات در فضای حالت ۲۸
۲-۵-۴ سناریوهای عدم قطعیت و فضای وفقی ۳۰
۲-۵-۵ فرمول‌بندی به عنوان MDP ۳۰
۲-۶ فرمول‌بندی مسئله بهینه‌سازی انطباق و تحلیل پیچیدگی محاسباتی ۳۱
۲-۶-۱ تحلیل پیچیدگی مسئله انطباق و اثبات ان‌پی‌ـ‌سختی ۳۲
۲-۶-۲ قیود عملیاتی زمان اجرا در سیستم‌های خودوفق ۳۳
۲-۷ سیستم مورد مطالعه دوم: شبیه‌ساز مأموریت پهپاد DARTSim ۳۴
۲-۷-۱ خاستگاه محک، معماری فیزیکی و مؤلفه‌های پروازی ناوگان پهپادی ۳۴
۲-۷-۲ فضای معنایی، اهداف قابلیت اعتماد و معیارهای کیفیت خدمات ۳۵
۲-۷-۳ سناریوهای عدم قطعیت، تلاطم محیطی و فضای وفقی تاکتیکی ۳۶
۲-۷-۴ فرمول‌بندی مأموریت پرواز در قالب فرآیند تصمیم‌گیری مارکوف ۳۸
۲-۷-۵ محیط انطباق آفلاین و طیف دشواری سناریوها ۳۹
۲-۸ خلاصه فصل ۴۰

فصل سوم: مرور پیشینه پژوهش و کارهای مرتبط ۴۲
۳-۱ مقدمه و روش‌شناسی مرور ۴۲
۳-۲ چارچوب تحلیل ادبیات: ابعاد عدم‌قطعیت و تصمیم‌گیری زمان‌اجرا ۴۳
۳-۳ رویکردهای اصلی مدیریت فضای وفقی در زمان اجرا ۴۴
۳-۳-۱ هرس فضای وفقی مبتنی بر یادگیری ماشین سنتی ۴۵

۳-۳-۲ روش‌های مبتنی بر جستجوی آنلاین و راهبردهای اکتشافی ۴۶
۳-۳-۳ یادگیری تقویتی زمان‌اجرا و کنترل خودمختار ۴۷
۳-۴ روش‌های پیشرفته یادگیری تقویتی: کاوش، شکل‌دهی پاداش و نگاه به گذشته ۴۸
۳-۴-۱ چالش‌های راهبرد کاوش در فضاهای وفقی بزرگ ۴۸
۳-۴-۲ ناکارآمدی سازوکار بازپخش تجربه با نگاه به گذشته در محیط‌های آستانه‌محور . ۴۹
۳-۴-۳ مبانی نظری و ریاضیاتی شکل‌دهی پاداش ۵۰
۳-۵ ارزیابی و تایید صوری در فرآیند خودوفق‌سازی ۵۱
۳-۵-۱ تأیید صوری کمّی زمان‌اجرا و چارچوب‌های ActivFORMS ۵۱
۳-۵-۲ معماری‌های ترکیبی یادگیری و ارزیابی صوری (مدل‌های ترادف) ۵۲
۳-۶ سنتز: شکاف تحقیقاتی سه‌گانه و موقعیت‌دهی علمی RS-DRL ۵۳
۳-۶-۱ ماتریس ارزیابی و سنتز پیشینه پژوهش ۵۳
۳-۶-۲ شکاف تحقیقاتی سه‌گانه ۵۳
۳-۶-۳ موقعیت‌دهی علمی معماری پیشنهادی RS-DRL ۵۵
۳-۷ خلاصه فصل ۵۶

فصل چهارم: روش پیشنهادی ۵۹
۴-۱ مقدمه ۵۹
۴-۲ معماری کلان چارچوب پایه‌ای RS-DRL و اصول فرآیندی انطباق ۶۱
۴-۲-۱ مرزهای سیستم و تعامل با محیط پیرامون ۶۱
۴-۲-۲ گردش فرآیندی و تفکیک زمانی وظایف حلقه انطباق ۶۲
۴-۳ جریان داده و گام‌های اجرایی تصمیم‌گیری آنلاین ۶۵
۴-۳-۱ گام اول: پایش و ساخت وضعیت ۶۶
۴-۳-۲ گام دوم: تحلیل و تشخیص ضرورت انطباق ۶۶
۴-۳-۳ گام سوم: برنامه‌ریزی و استنتاج انطباقی ۶۶
۴-۳-۴ گام چهارم: اعتبارسنجی صوری بازخورد و اجرای فرامین ۶۷
۴-۳-۵ ردیابی گام‌به‌گام چرخه انطباق در قالب سناریوهای مرجع ۶۸
۴-۳-۵-۱ سناریوی اول: شبکه دو گره‌ای با قید کیفیت خدمات تک‌هدفه . . ۶۸
۴-۳-۵-۲ سناریوی دوم: شبکه چهار گره‌ای با اهداف متضاد کیفیت خدمات ۶۸
۴-۴ معماری داخلی برنامه‌ریز و مسیرهای سه‌گانه کنترلی ۶۹

۴-۴-۱ الگوی همگام‌سازی چندریسمانی و مدیریت همزمانی بدون قفل ۷۱
۴-۵ سازوکار شکل‌دهی تصادفی پاداش و فرار از بهینه‌های محلی ۷۱
۴-۵-۱ مبانی نظری و فرمول‌بندی ریاضی شکل‌دهی پاداش ۷۲
۴-۵-۲ تحلیل حساسیت پارامتر ρ و الگوریتم یادگیری RS-DRL ۷۴
۴-۶ مدیریت مخزن دانش و هماهنگی جریان‌های همزمان ۷۷
۴-۷ اعتبارسنجی صوری زمان اجرا با وارسی مدل آماری UPPAAL-SMC ۷۸
۴-۷-۱ جزئیات شبیه‌سازی احتمالی و کران ریاضی تعداد نمونه‌ها ۷۹
۴-۷-۲ تحلیل زمان‌بندی اعتبارسنجی غیرانسدادی در پس‌زمینه ۸۰
۴-۸ چالش‌های سیستم‌های فیزیکی–سایبری و سه‌گانه برنامه‌ریزی ۸۰
۴-۹ معماری دوسطحی سیستم RS-DRL^{+} ۸۱
۴-۹-۱ سطح آنلاین: حلقه کنترلی بلادرنگ و تصمیم‌گیری زمان اجرا ۸۲
۴-۹-۲ سطح آفلاین: بازپخش تجارب و سنتز سیاست با فرمول‌بندی TD-Loss ۸۲
۴-۱۰ الگوی سنتز آفلاین هدایت‌شده با مشخصه‌ها (SG-OS) ۸۳
۴-۱۰-۱ شکل‌دهی پاداش هدایت‌شده با حاشیه بازیابی و مطلوبیت (MU-RS-DRL) . . ۸۴
۴-۱۰-۲ بافرسازی حاشیه اطمینان برای پایداری در مرزها (CM-RS-DRL) ۸۶
۴-۱۱ الگوی اعتبارسنجی کشسان و هرزمانی مبتنی بر قرارداد (CA-EPV) ۸۶
۴-۱۱-۱ ساختار ماژول PG-ALR و سلسله‌مراتب تصمیم‌گیری سه‌مرحله‌ای ۸۶
۴-۱۱-۲ تحلیل صوری پیچیدگی محاسباتی و اثبات گزاره ۱ (کران اندازه فضای کاندیداها) ۸۷
۴-۱۱-۳ قاعده انتخاب محافظت‌شده و اثبات گزاره ۲ (تضمین عدم افت ایمنی) ۹۰
۴-۱۱-۴ قراردادهای عام معماری و نمونه‌سازی در دامنه‌های کاربردی ۹۲
۴-۱۱-۵ پیکربندی فراپارامترها و مشخصات معماری شبکه عصبی ۹۳
۴-۱۱-۶ الگوریتم جامع آموزش آفلاین و تصمیم‌گیری هرزمانی RS-DRL^{+} ۹۳
۴-۱۲ نگاشت معماری و پاسخ به پرسش‌های پژوهش (RQ1 تا RQ6) ۹۵
۴-۱۳ بحث پیرامون مفروضات و محدودیت‌های روش ۹۶
۴-۱۴ خلاصه فصل ۹۶

فصل پنجم: ارزیابی تجربی ۹۸
۵-۱ مقدمه ۹۸
۵-۲ اهداف ارزیابی و سوالات تحقیق ۹۹

۵-۳ تنظیمات آزمایشگاهی و مشخصات بسترها ۹۹
۵-۳-۱ مشخصات بستر نرم‌افزاری، سخت‌افزاری و ردپاهای تجربی ۹۹
۵-۳-۲ کالیبراسیون و تنظیمات فراپارامترها ۱۰۱
۵-۴ روش‌های پایه و مقایسه ۱۰۱
۵-۵ معیارهای ارزیابی عملکرد یادگیری و کارایی سیستمی ۱۰۲
۵-۶ ارزیابی تجربی چارچوب پایه‌ای RS-DRL در بستر DeltaIoT ۱۰۳
۵-۶-۱ منحنی‌های یادگیری و رفتار همگرایی: خروج از بهینه‌های محلی (RQ1) . . . ۱۰۳
۵-۶-۲ مقایسه عملکرد به ازای هر هدف و تعمیم‌پذیری (RQ1 و RQ2) ۱۰۳
۵-۶-۳ ارزیابی مقایسه‌ای در برابر تمام روش‌های پایه (RQ4) ۱۰۵
۵-۶-۴ مطالعه تفکیک اثر و ابلیشن: حساسیت به ضریب شکل‌دهی ρ (RQ2) . . . ۱۰۶
۵-۶-۵ تحلیل مقیاس‌پذیری در فضاهای وفقی بزرگ تا ۴۰۹۶ گزینه (RQ3) ۱۰۷
۵-۶-۶ جمع‌بندی دستاوردهای چارچوب پایه‌ای و ضرورت گذار به معماری RS-DRL^{+} ۱۰۷
۵-۷ ارزیابی ناوگان پهپادی در محیط فیزیکی‌ـ‌سایبری DARTSim ۱۰۸
۵-۷-۱ تنظیمات ارزیابی پروازی حلقه‌ـ‌بسته: ۲,۰۰۰ پرواز در ۲۰۰ سناریو ۱۰۸
۵-۷-۲ ایمنی اجرای فیزیکی در برابر انطباق جانشین: مهار شکاف واقعیت (RQ6) . . ۱۱۰
۵-۷-۳ تحلیل چندسطحی رواداری دالان پروازی: مقایسه سطوح v_1، v_2 و v_3 (RQ1 و RQ6) ۱۱۲
۵-۷-۴ مطلوبیت عملیاتی و کاهش نوسانات تصمیم‌گیری تحت لاگ‌های شکست . . . ۱۱۳
۵-۷-۵ کارایی محاسباتی زمان اجرا، مصرف حافظه و رعایت مهلت زمانی کنترل پرواز (RQ5) ۱۱۴
۵-۷-۶ سربار آماده‌سازی آفلاین و تحلیل بازه استهلاک آن (RQ4) ۱۱۶
۵-۷-۷ مطالعه تفکیک اثر در DARTSim و تحلیل بعد حساسیت m (RQ3، RQ5 و RQ6) ۱۱۷
۵-۸ ارزیابی انتقال‌پذیری و تعمیم الگوهای معماری به بستر DeltaIoT (RQ2، RQ3 و RQ6) . ۱۱۸
۵-۸-۱ نتایج اعمال RS-DRL^{+} بر شبکه حسگر ۱۱۹
۵-۸-۲ دستورالعمل‌های انتخاب مهندسی برای انتقال به دامنه‌های جدید ۱۲۱
۵-۹ اعتبارسنجی آماری جامع فرضیه‌ها (RQ1 تا RQ6) ۱۲۱
۵-۹-۱ روش‌شناسی آزمون‌های فرض ناپارامتری و تصحیح خطای خانواده ۱۲۱
۵-۹-۲ تحلیل آماری فرضیه‌ها، مقایسات زوجی و اندازه‌های اثر ۱۲۲

۵-۱۰ خلاصه فصل ۱۲۳

فصل ششم: بحث، نتیجه‌گیری و پیشنهادها ۱۲۵

۶-۱ بحث در مورد یافته‌های کلیدی ۱۲۵

۶-۱-۱ نظریه‌پردازی سازوکار: چرا RS-DRL کار می‌کند؟ ۱۲۵

۶-۱-۲ تحلیل مصالحه‌های مهندسی و تعاملات چندمعیاره اهداف ۱۲۶

۶-۱-۳ پیامدهای مهندسی نرم‌افزار برای توسعه سیستم‌های خودوفق ۱۲۷

۶-۲ محدودیت‌ها و تهدیدات اعتبار ۱۲۸

۶-۲-۱ اعتبار داخلی ۱۲۸

۶-۲-۲ اعتبار خارجی و تعمیم‌پذیری ۱۲۸

۶-۲-۳ اعتبار سازه ۱۲۹

۶-۳ مسیرهایی برای تحقیقات آینده ۱۲۹

۶-۴ نتیجه‌گیری و مرور دستاوردها ۱۳۰

۶-۴-۱ خلاصه بیان مسئله و راهکار دوسطحی پیشنهادی ۱۳۰

۶-۴-۲ مرور مشارکت‌ها و شواهد تجربی ۱۳۰

۶-۴-۳ جمع‌بندی نهایی و چشم‌انداز کلی پژوهش ۱۳۱

مراجع ۱۳۲

پیوست آ: جریان‌های کاری کامل فرآیند ۱۳۷

پیوست ب: لیست کامل الگوریتم‌ها ۱۳۸

پیوست پ: نتایج تجربی گسترده ۱۳۹

پیوست ت: مصنوعات پیاده‌سازی و پکیج بازتولید ۱۴۰

فهرست جداول

۱-۱ نگاشت جامع فصول رساله در برابر نوآوری‌ها، مسائل فرعی، پرسش‌های پژوهش و مقالات علمی مستخرج ۱۶

۱-۲ مقایسه تطبیقی الگوریتم‌های جدول‌محور Q-Learning و SARSA ۲۶

۲-۲ فضای معنایی سیستم پهپادی DARTSim (عوامل پیکربندی و محیطی) ۳۵

۲-۳ طیف سناریوهای پیکربندی‌پذیر محیط DARTSim و سطوح دشواری آن‌ها ۴۰

۱-۳ مقایسه تطبیقی پارادایم‌های مدیریت فضای وفقی زمان اجرا بر اساس چارچوب ارزیابی پنج‌بعدی (برگرفته از تحلیل کارهای پیشین نظیر [۱۰، ۱۲، ۳۵، ۹]) ۵۴

۲-۳ نحوه پوشش شکاف‌های تحقیقاتی توسط نوآوری‌های معماری پیشنهادی RS-DRL . . . ۵۶

۱-۴ طبقه‌بندی زمانی و مشخصات عملیاتی فرآیندهای معماری RS-DRL متناظر با خطوط شناوری شکل ۴-۲ . . . . . ۶۳

۲-۴ ماتریس توجیه تصمیمات کلیدی معماری پیشنهادی RS-DRL در برابر چالش‌های طراحی سیستمی ۶۵

۳-۴ تحلیل حساسیت رفتار یادگیری عامل نسبت به تغییرات ضریب شکل‌دهی ρ ۷۴

۴-۴ الگوهای دسترسی صوری و همگام‌سازی مؤلفه‌ها در مخزن دانش مشترک [۲] ۷۸

۵-۴ قراردادهای معماری مستقل از دامنه الگوهای SG-OS و CA-EPV در برابر نمونه‌سازی‌های تجربی ۹۳

۶-۴ کاتالوگ تفصیلی فراپارامترها و پیکربندی معماری شبکه‌های عصبی در بسترهای ارزیابی . ۹۴

۱-۵ هم‌راستایی اهداف ارزیابی تجربی با سوالات شش‌گانه تحقیق ۹۹

۲-۵ مشخصات تطبیقی دو بستر ارزیابی تجربی: ناوگان پهپادی DARTSim در برابر شبکه حسگر DeltaIoT ۱۰۰

۳-۵ نمونه‌های مورد مطالعه سیستم DeltaIoT [۲۷] ۱۰۰

۵-۴ نتایج اهداف کمینه‌سازی در DeltaIoTv1 (پاداش مجانبی / گام‌ها) ۱۰۴
۵-۵ نتایج اهداف کمینه‌سازی در DeltaIoTv1.1 . . . . . ۱۰۴
۵-۶ عملکرد سیستم برای اهداف آستانه‌ای ترکیبی TTS ۱۰۵
۵-۷ عملکرد سیستم برای اهداف آستانه‌ای مطلق TT ۱۰۵
۵-۸ تحلیل مقیاس‌پذیری الگوریتم با بزرگ شدن فضای تطابق ۱۰۷
۵-۹ مقایسه عملکرد جامع ۱۲ روش برنامه‌ریز (۱۰ الگوریتم انطباقی و ۲ خط پایه) در پروازهای حلقه‌ـ بسته DARTSim: انطباق مدل جانشین، موفقیت پرواز فیزیکی در دو سطح رواداری سخت‌گیرانه ($v_۳$، $N = ۲۰۰$) و ملایم ($v_۱$، $N = ۲۰$)، کیفیت عملیاتی (d_{norm})، تأخیر آنلاین و مصالحه حاکم بر روش. ۱۱۰
۵-۱۰ کارایی محاسباتی زمان اجرا: تحلیل آماری تأخیر تصمیم‌گیری آنلاین و ردپای حافظه مصرفی پویا در ۲۰۰ سناریوی عملیاتی ۱۱۵
۵-۱۱ مطالعه تفکیک اثر بعد حساسیت تصویر شاپلی در ماژول PG-ALR ۱۱۸
۵-۱۲ نتایج آزمون‌های فرض آماری ناپارامتری: مقادیر p ویلکاکسون و مک‌نمار و اندازه اثر وارگا‌ـ دلانی ($\hat{A}_{۱۲}$) در ارزیابی مأموریت ناوگان پهپادی DARTSim ($N = ۲۰۰$) . . . ۱۲۲
۵-۱۳ نتایج آزمون‌های فرض آماری، مقادیر p و اندازه‌های اثر کوهن در هر دو بستر ارزیابی . . ۱۲۳

۶-۱ خلاصه‌ای از مشارکت‌های کلیدی، شواهد تجربی و اهمیت علمی رساله ۱۳۱

فهرست تصاویر

۲-۱ توپولوژی و ساختار پیوندهای ارتباطی شبکه حسگر بی‌سیم DeltaIoTv1 [۲۶]. ۲۸

۲-۲ نمودار مفهومی عوامل اثرگذار بر اهداف قابلیت اعتماد تیم پهپادی DARTSim؛ عوامل پیکربندی و محیطی در یک محیط متخاصم بر تحقق اهداف شناسایی هدف و اجتناب از تهدید اثر می‌گذارند. ۳۶

۲-۳ داشبورد تحلیل عدم قطعیت محیطی DARTSim: توزیع تصادفی‌بودن گذارها، عدم‌قطعیت به‌تفکیک نوع اقدام و مؤلفه حالت، تغییرپذیری قرائت حسگر تهدید و پراکندگی پاداش‌ها. ۳۷

۲-۴ نمونه‌هایی از تغییرپذیری قرائت حسگرهای تهدید و هدف برای یک زوج حالت–اقدام یکسان در DARTSim؛ هر سطر یک پیامد ممکن و هر ستون یک سلول حسگر پیش‌رِو را نشان می‌دهد. ۳۸

۲-۵ مقایسه‌ی سه سناریوی DARTSim (پایه، متوسط و سخت)؛ تفاوت در چیدمان نقشه، پیچیدگی مسیر و چگالی تهدید و هدف. ۴۰

۴-۱ معماری سطح بالای رویکرد RS-DRL در قالب حلقه MAPE-K. این نمودار تعامل میان سیستم مدیریت‌شونده، محیط، و مؤلفه‌های کنترلی را به همراه مخزن دانش مشترک نشان می‌دهد. ۶۲

۴-۲ نمودار فعالیت تفصیلی UML فرآیند خودوفقی RS-DRL؛ تفکیک وظایف پنج‌گانه مسیر زمان اجرای آنلاین (پایش، تحلیل، برنامه‌ریزی، اعتبارسنجی صوری و اجرا) و فرآیند یادگیری ناهمگام در مخزن دانش در قالب ۶ خط شناوری. خط‌چین افقی، مرز عدم‌انسداد میان مسیر کنترل بلادرنگ و محاسبات یادگیری پس‌زمینه را نشان می‌دهد. ۶۴

۴-۳ ساختار داخلی مؤلفه برنامه‌ریز RS-DRL در سه مسیر موازی: استنتاج (فقط‌خواندنی)، بازخورد (ترکیب پاداش محیطی و صوری)، و آموزش (به‌روزرسانی در پس‌زمینه با استفاده از شکل‌دهی تصادفی پاداش). ۷۰

۴-۴ منطق عملیاتی سازوکار شکل‌دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش‌بینانه پاداش‌های صفر با مقدار ۱ را بر اساس ضریب ρ نشان می‌دهد (برچسب‌گذاری مجدد خوش‌بینانه، نه روش‌های مبتنی بر پتانسیل [۴۱]). ۷۳
۴-۵ جریان داده تفصیلی در مخزن دانش ۷۷
۴-۶ نمای کلان معماری دوسطحی $^{+}$RS-DRL: خط لوله آموزش آفلاین با شکل‌دهی پاداش حساس به حاشیه در سطح پایین، و حلقه کنترلی MAPE-K مجهز به برنامه‌ریز سلسله‌مراتبی سه‌مرحله‌ای PG-ALR در سطح آنلاین برای کنترل خودگردان سیستم‌های فیزیکی ـ سایبری با نمونه‌سازی در بستر پهپادی DARTSim. ۸۲
۴-۷ درخت رده‌بندی و سیر تکاملی روش‌های تصمیم‌گیری در سیستم‌های خودوفق: از بهینه‌سازی مبتنی بر جستجو و سپرهای صوری ایستا تا یادگیری تقویتی عمیق بدون هدایت، چارچوب پایه‌ای RS-DRL و معماری دوسطحی تعمیم‌یافته $^{+}$RS-DRL. ۸۳
۴-۸ مقایسه سازوکار شکل‌دهی پاداش در MU-RS-DRL در برابر RS-DRL پایه‌ای: (الف) تغییر پیوسته احتمال بر اساس تعداد الزامات ارضاشده و حاشیه بازیابی؛ (ب) مقیاس‌بندی پاداش خوش‌بینانه متناسب با مطلوبیت مأموریت. ۸۵
۴-۹ نمودار جریان سلسله‌مراتب تصمیم‌گیری ماژول PG-ALR ۸۸

۵-۱ منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1 (پاداش در برابر گام‌ها) ۱۰۴
۵-۲ منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1.1 . . . . . ۱۰۴
۵-۳ تاثیر مقادیر مختلف ضریب شکل‌دهی ρ بر پاداش مجانبی و عملکرد کل ۱۰۶
۵-۴ سناریوی مأموریت شناسایی ناوگان پهپادی DARTSim در محیط پرخطر: (چپ) فضای پروازی همراه با رادارهای متخاصم، سیستم‌های موشکی، موانع فیزیکی و تلاطم شدید باد؛ (راست) نگاشت معنایی میان متغیرهای قابل‌کنترل ($\mathcal{CF}$)، عوامل محیطی ($\mathcal{OF}$) و ۱۲ الزام قابلیت اعتماد مأموریت (R_0 تا R_{11}). ۱۰۸
۵-۵ مقایسه نرخ موفقیت پرواز فیزیکی و مهار شکاف واقعیت ۱۱۱
۵-۶ ردپای تله‌متری واقعی پرواز فیزیکی در برابر پیش‌بینی مدل‌های جانشین در حضور باد ناگهانی: (الف) توزیع سرعت هوایی و ناپایداری آیرودینامیکی شدید تحت سپر سنتی، (ب) سقوط ۱۱ درصدی سپر در گذر از جانشین به پرواز واقعی، و (ج) پایداری نرخ موفقیت روش پیشنهادی تحت چگالی‌های فزاینده رادارهای متخاصم. ۱۱۲

۵-۷ مقایسه نرخ بقای پرواز فیزیکی حلقه‌ـ بسته ناوگان پهپادی DARTSim در سه رژیم رواداری دالان پروازی ملایم (v_1)، متوسط (v_2) و سخت‌گیرانه (v_3): پایداری روش‌های مبتنی بر RS-DRL$^+$ در برابر افت شدید عملکرد الگوریتم‌های جستجوی کلاسیک در شرایط تلاطم شدید. ۱۱۳
۵-۸ نمودار جعبه‌ای کیفیت انطباق و مطلوبیت عملیاتی (d_{norm}) در پروازهای فیزیکی: مقایسه مطلوبیت روش‌های سنتز آفلاین هدایت‌شده و کاهش ۳۱ درصدی واریانس عملیاتی در مقایسه با روش RS-DRL پایه‌ای. ۱۱۴
۵-۹ مقایسه زمان پاسخ‌گویی فاز برنامه‌ریزی در برابر خط قرمز مهلت زمانی کنترل پرواز (۲۰ تا ۵۰ میلی‌ثانیه): نمایش تأخیر زیر میلی‌ثانیه‌ای مسیر سریع و تأخیر کمتر از ۳/۵ میلی‌ثانیه‌ای پالایش مرحله ۳ در RS-DRL$^+$. ۱۱۵
۵-۱۰ جبهه مصالحه پارتو میان تأخیر تصمیم‌گیری آنلاین (مقیاس لگاریتمی، کمتر بهتر) و بقای پرواز فیزیکی در DARTSim (بیشتر بهتر): بهینگی پارتوی معماری‌های RS-DRL$^+$ و MU-RS-DRL در مقایسه با سایر خطوط پایه. ۱۱۶
۵-۱۱ تحلیل مصالحه میان زمان آماده‌سازی آفلاین و صرفه‌جویی آنلاین ۱۱۷
۵-۱۲ منحنی یادگیری و همگرایی سریع‌تر RS-DRL$^+$ در مقایسه با RS-DRL پایه‌ای و روش‌های رقیب در بستر شبکه حسگر DeltaIoT. ۱۱۹
۵-۱۳ جبهه مصالحه پارتو میان اتلاف بسته و مصرف انرژی در DeltaIoTv1: مقایسه RS-DRL$^+$ با جستجوی جامع مرجع و روش‌های پایه. ۱۲۰

فهرست نشانه‌ها و اختصارات

نشانه‌های ریاضی

نماد	توضیح و تعریف
$\mathcal{S}$	فضای حالت سیستم (مجموعه تمام وضعیت‌های ممکن سیستم و محیط)
$\mathcal{A}$	فضای عمل یا گزینه‌های وفقی در دسترس
s	حالت یا وضعیت جاری سیستم ($s \in \mathcal{S}$)
a	عمل وفقی یا پیکربندی انتخاب‌شده ($a \in \mathcal{A}$)
$\pi(a\|s)$	سیاست انطباق عامل (نگاشت حالت‌ها به اعمال)
π^*	سیاست انطباق بهینه
$R(s,a)$	تابع پاداش (بازخورد عددی محیط به عامل)
γ	نرخ تنزیل پاداش‌های آتی ($\gamma \in [۰,۱)$)
$V^\pi(s)$	تابع ارزش حالت تحت سیاست π
$Q(s,a)$	تابع ارزش عمل (مقدار کیو)
θ	پارامترها و وزن‌های شبکه عصبی عمیق تقریب‌گر
ϵ	احتمال کاوش تصادفی در الگوریتم حریصانه‌ـ اپسیلون
$\mathcal{D}$	بافر بازپخش تجربه عامل
ρ	ضریب یا احتمال شکل‌دهی پاداش تصادفی در روش RS-DRL
$\mathcal{M}(s,a)$	حاشیه بازیابی شکست در روش MU-RS-DRL
$\mathcal{U}_{\text{inc}}(a)$	مشوق مطلوبیت عملیاتی اقدام وفقی
$\tilde{r}_{\text{opt}}$	پاداش بهینه‌بینانه پویا مقیاس‌بندی‌شده با مطلوبیت
$\bar{\mathcal{B}}(s,a)$	بافر حاشیه اطمینان نرمال‌شده در روش CM-RS-DRL
$\mathcal{E}(of)$	شاخص شدت تنش محیطی در فیلتر زمان اجرا
$\mathcal{N}(a.)$	همسایگی ۱ـ گام پالایش موضعی در زیرفضای حساسیت
m	تعداد ابعاد انتخابی با بالاترین حساسیت توضیح‌پذیر (TreeSHAP)

اختصارات انگلیسی

اختصار	عبارت کامل انگلیسی	معادل فارسی
RS-DRL	Randomized Reward-Shaped Deep Reinforcement Learning	یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش
RS-DRL^{+}	Enhanced Reward-Shaped Deep Reinforcement Learning	یادگیری تقویتی عمیق با شکل‌دهی هدایت‌شده پاداش و پالایش در هر زمان
SG-OS	Specification-Guided Offline Synthesis	الگوی سنتز آفلاین هدایت‌شده با مشخصه
CA-EPV	Contract-Anytime Elastic Plan-Phase Verification	الگوی اعتبارسنجی کشسان فاز برنامه‌ریزی با قرارداد در هر زمان
PG-ALR	Policy-Guided Anytime Local Refinement	ماژول پالایش محلی هدایت‌شده با سیاست در هر زمان
MU-RS-DRL	Margin- and Utility-guided Reward Shaping	شکل‌دهی پاداش هدایت‌شده با حاشیه بازیابی و مطلوبیت
CM-RS-DRL	Confidence-Margin Buffering Reward Shaping	شکل‌دهی پاداش با بافر حاشیه اطمینان
DRL	Deep Reinforcement Learning	یادگیری تقویتی عمیق
SAS	Self-Adaptive Systems	سیستم‌های خودوفق
MAPE-K	Monitor, Analyze, Plan, Execute over Shared Knowledge	حلقه مدیریت خودمختار
UPPAAL-SMC	UPPAAL Statistical Model Checker	ابزار بازبینی صوری آماری آپال
SMC	Statistical Model Checking	بازبینی صوری آماری
DQN	Deep Q-Network	شبکه کیو عمیق
HER	Hindsight Experience Replay	بازپخش تجربه با نگاه به گذشته (هدف‌محور)
Soft HER	Soft Hindsight Experience Replay	بازپخش تجربه با نگاه به گذشته نرم

اختصار	عبارت کامل انگلیسی	معادل فارسی
DLASER	Deep Learning for Adaptation Space Reduction	کاهش فضای وفقی با یادگیری عمیق
ML4EAS	Machine Learning for Efficient Adaptation Space Reduction	کاهش کارآمد فضای وفقی با یادگیری ماشین
DARTSim	UAV Tactical Mission Simulator	شبیه‌ساز مأموریت تاکتیکی پهپادها
CPS	Cyber-Physical Systems	سیستم‌های فیزیکی–سایبری
NFR	Non-Functional Requirement	الزام کیفی و غیرکارکردی
TreeSHAP	Tree-based Shapley Additive Explanations	توضیح‌پذیری افزایشی شاپلی مبتنی بر درخت
ECM	Electronic Countermeasures	اقدامات متقابل الکترونیکی
6-DOF	Six Degrees of Freedom	شش درجه آزادی دینامیک فیزیکی پرواز
MDP	Markov Decision Process	فرآیند تصمیم‌گیری مارکوف
POMDP	Partially Observable Markov Decision Process	فرآیند تصمیم‌گیری مارکوف بخشاً مشاهده‌پذیر
PBRS	Potential-Based Reward Shaping	شکل‌دهی پاداش مبتنی بر پتانسیل
QVR	Quantitative Verification at Runtime	تأیید صوری کمّی زمان اجرا
QoS	Quality of Service	کیفیت خدمات
KPI	Key Performance Indicator	شاخص کلیدی عملکرد
IoT	Internet of Things	اینترنت اشیاء
WSN	Wireless Sensor Network	شبکه حسگر بی‌سیم
SNR	Signal-to-Noise Ratio	نسبت سیگنال به نویز
TT	Threshold Goal	هدف آستانه‌ای مطلق
TTS	Threshold-based Transition System	سیستم انتقال مبتنی بر آستانه

فصل اول

کلیات

۱-۱ مقدمه

در حوزه مهندسی سیستم‌های نرم‌افزاری معاصر، پیچیدگی به‌عنوان یکی از بارزترین ویژگی‌ها خودنمایی می‌کند. محیط عملیاتی پویا نقشی محوری در شکل‌دهی به این پیچیدگی دارد و سیستم‌ها را ناگزیر می‌سازد تا با شرایط نامشخصی که اغلب تنها پس از عملیاتی شدن بروز می‌یابند، مقابله کنند.

در سال‌های اخیر، ظهور معماری‌های توزیع‌شده، رایانش ابری، اینترنت اشیاء (IoT)[1] و سیستم‌های فیزیکی‌ـ سایبری، ابعاد جدیدی از پیچیدگی محاسباتی و عدم قطعیت‌های زمان اجرا را به همراه داشته است. آمار و گزارش‌های صنعتی نشان می‌دهند که خرابی و توقف غیرمنتظره سیستم‌های نرم‌افزاری در مقیاس صنعتی، هزینه‌های سرسام‌آوری را تحمیل می‌کند [۱]. به عنوان مثال، در زیرساخت‌های ابری بزرگ مقیاس، هر دقیقه توقف خدمات[2] می‌تواند تا هزاران دلار ضرر مالی مستقیم و آسیب جدی به اعتبار برندها به همراه داشته باشد [۱]. از سوی دیگر، در شبکه‌های حسگر بی‌سیم و اینترنت اشیاء صنعتی، افزایش ناگهانی تداخل امواج یا رانش مفهومی[3] در کانال‌های ارتباطی می‌تواند نرخ هدررفت داده‌ها را به شدت افزایش دهد. در چنین سناریوهایی، نرخ خطای قابل قبول بسیار کوچک است و سیستم‌ها باید بلافاصله با محیط انطباق یابند. این موضوع نشان می‌دهد که مدیریت عدم قطعیت در سیستم‌های مدرن، یک چالش دانشگاهی محض نیست، بلکه یک ضرورت عملی و فوری در صنایع مختلف به شمار می‌رود.

سیستم‌های نرم‌افزاری سنتی که مبتنی بر پیکربندی‌های ایستا در زمان طراحی یا قواعد ثابت زمان اجرا (نظیر دستورات شرطی ساده «اگر ـ آنگاه») هستند، فاقد انعطاف‌پذیری لازم برای پاسخ‌گویی به نوسانات پویای محیطی می‌باشند. در این سیستم‌ها، تمامی شرایط عملیاتی و رفتارهای سیستم باید در زمان طراحی پیش‌بینی شوند. با این حال، در محیط‌های پیچیده واقعی، فرضیات زمان طراحی همواره نقض می‌شوند. برای نمونه،

[1] Internet of Things

[2] Downtime

[3] Concept Drift

در سیستم‌های هوشمند مدیریت ترافیک شهری یا کنترل مسیریابی شبکه‌های نسل پنجم (5G)[۴]، تغییرات پویای حجم داده‌ها، نوسان بار ترافیکی و خرابی‌های ناگهانی سخت‌افزاری موجب شکست قوانین ایستای زمان طراحی می‌شوند. سیستم‌هایی که بر قواعد سخت‌گیرانه زمان طراحی تکیه می‌کنند، در سناریوهای خارج از پیش‌بینی‌های اولیه با زوال عملکرد یا توقف کامل مواجه می‌شوند.

به منظور غلبه بر این محدودیت‌ها، سیستم‌های خودوفق (SAS)[۵] به عنوان یک پارادایم اساسی در مهندسی نرم‌افزار مدرن ظهور کردند. این سیستم‌ها مجهز به حلقه‌های بازخوردی خودمختار هستند که به سیستم اجازه می‌دهند تا به طور پیوسته وضعیت درونی و بیرونی خود را پایش کرده، انحرافات از اهداف تعیین‌شده را تحلیل کرده، تغییرات بهینه را برنامه‌ریزی و در نهایت در زمان اجرا اعمال نمایند.

ایده اولیه این رویکرد به کارهای بنیادین شرکت IBM[۶] در سال ۲۰۰۳ تحت عنوان رایانش خودمختار[۷] توسط کیفارت و چس[۸] [۲] بازمی‌گردد. در ادامه، اوریزی و همکاران[۹] (۱۹۹۹) [۳] یکی از نخستین رویکردهای معماریمحور برای سیستم‌های خودوفق را معرفی کردند که بر استفاده از مدل‌های زمان اجرا برای هدایت تصمیمات وفقی تأکید داشت. همچنین چنگ و همکاران[۱۰] (۲۰۰۹) [۴] در نقشه‌راه تحقیقاتی مهندسی نرم‌افزار برای سیستم‌های خودوفق، بر اهمیت مدل‌های خودمختار زمان اجرا، مدیریت عدم قطعیت و تضمین‌های کیفیت تأکید نمودند. ادغام حلقه‌های کنترلی خودمختار با روش‌های تصمیم‌گیری هوشمند، سنگ بنای سیستم‌های خودوفق مدرن را شکل می‌دهد.

۱-۲ اهداف رساله

این رساله در راستای تکمیل شکاف‌های تحقیقاتی پیشین [۴] و پاسخ به چالش‌های حل‌نشده در سیستم‌های خودوفق نرم‌افزاری و فیزیکی‌ـ‌سایبری، یک هدف اصلی جامع و چهار هدف فرعی تکاملی را دنبال می‌کند:

هدف اصلی:

توسعه، تعمیم و اعتبارسنجی چارچوب معماری یادگیری تقویتی عمیق با شکل‌دهی هدایت‌شده پاداش و اعتبارسنجی در هر زمان (RS-DRL[۱۱] و RS-DRL$^+$) به‌گونه‌ای که هم‌زمان بر مشکل بنیادین گیرافتادن در بهینه‌های محلی در فضاهای وفقی بزرگ، سه‌گانه برنامه‌ریزی بلادرنگ در سیستم‌های فیزیکی‌ـ‌سایبری (مهلت‌های زمانی سخت ۲۰ تا ۵۰ میلی‌ثانیه، غلبه شدید داده‌های شکست در لاگ‌های آفلاین، و شکاف

[4] Fifth Generation of Cellular Networks
[5] Self-Adaptive Systems
[6] International Business Machines
[7] Autonomic Computing
[8] Jeffrey O. Kephart and David M. Chess
[9] Peyman Oreizy et al.
[10] Betty H. C. Cheng et al.
[11] Randomized Reward-Shaped Deep Reinforcement Learning

واقعیت مدل‌های جانشین تا فیزیک اجرا) غلبه نموده و پایداری اهداف کیفی چندگانه را بدون نیاز به بازآموزی‌های پرهزینه تضمین کند.

اهداف فرعی: در راستای تحقق هدف اصلی، اهداف فرعی زیر در قالب دو فاز تکاملی تعریف شده‌اند:

۱. **طراحی روش پایه‌ای شکل‌دهی پاداش و معماری تفکیک زمانی در MAPE-K:** ایجاد سازوکار شکل‌دهی تصادفی پاداش در بافر بازپخش تجربیات برای فرار خودمختار از نقاط بهینه محلی در فضاهای وفقی گسسته بزرگ، همراه با یکپارچه‌سازی در چارچوب حلقه MAPE-K[12] و اعتبارسنجی صوری آماری توسط ابزار UPPAAL-SMC[13] در سیستم‌های با کیفیت خدمات نرم[14] نظیر شبکه‌های حسگر بی‌سیم.

۲. **توسعه الگوی سنتز آفلاین هدایت‌شده با مشخصه‌ها (SG-OS):** طراحی سازوکارهای شکل‌دهی پاداش حساس به حاشیه بازیابی (MU-RS-DRL) و بافر حاشیه اطمینان (CM-RS-DRL) به منظور فیلتر کردن شکست‌های فاجعه‌بار و غیرقابل‌جبران در لاگ‌های داده با عدم توازن شدید (بیش از ۹۰٪ شکست) و مقیاس‌بندی پاداش‌های خوش‌بینانه متناسب با عمق انطباق و مطلوبیت مأموریت.

۳. **توسعه الگوی اعتبارسنجی کشسان فاز برنامه‌ریزی با قرارداد در هر زمان (CA-EPV):** ایجاد ساختار تصمیم‌گیری سلسله‌مراتبی سه‌مرحله‌ای (PG-ALR) که پیشنهاد نامی سیاست را در زمان زیر میلی‌ثانیه ارائه داده و در شرایط تنش محیطی، اعتبارسنجی را به همسایگی ۱ ـ گام بر روی زیرفضای حساسیت تحلیل شاپلی (TreeSHAP)[15] مقید سازد تا رعایت مهلت زمانی سخت (زیر ۳/۵ میلی‌ثانیه در برابر سقف ۲۰ تا ۵۰ میلی‌ثانیه) به صورت ریاضی تضمین گردد.

۴. **ارزیابی تجربی گسترده دوگانه و مهار شکاف واقعیت:** ارزیابی جامع روش بر روی دو بستر آزمایشی شاخص: بستر شبکه‌های حسگر DeltaIoT[16] (با ابعاد تا ۴۰۹۶ گزینه وفقی) در مقایسه با ۶ روش پیشرفته، و اجرای ۲,۰۰۰ سناریوی پرواز فیزیکی حلقه‌ـبسته در شبیه‌ساز مأموریت ناوگان پهپادی DARTSim[17] جهت اثبات مهار شکاف واقعیت مدل‌های جانشین تا فیزیک اجرا و ارائه الگوهای انتقال بین‌دامنه‌ای.

[12] Monitor, Analyze, Plan, Execute over Shared Knowledge

[13] ابزار وارسی مدل آماری UPPAAL-SMC: https://uppaal.org/

[14] Soft Quality of Service

[15] Tree-based Shapley Additive Explanations

[16] بستر DeltaIoT: https://people.cs.kuleuven.be/~danny.weyns/software/DeltaIoT/

[17] شبیه‌ساز ناوگان پهپادی DARTSim (CMU-SEI): https://github.com/cps-sei/dartsim

۱-۳ چالش‌ها

چالش‌ها و منابع عدم قطعیت در سیستم‌های مختلف به شکل‌های گوناگونی بروز می‌یابند. در سیستم‌های اینترنت اشیاء و شبکه‌های حسگر، تغییرات آب و هوایی، نویز کانال‌های بی‌سیم و نوسانات بار ترافیکی موجب افت کیفیت خدمات (QoS)[۱۸] می‌شوند. از سوی دیگر، در سیستم‌های فیزیکی‌ـ سایبری بلادرنگ (CPS)[۱۹] نظیر ناوگان پهپادهای خودگردان تاکتیکی، عدم قطعیت‌های محیطی نظیر تلاطم بادهای ناگهانی، تغییرات سطح دید و سیستم‌های پدافند راداری متخاصم، بقای فیزیکی کل سیستم را در معرض خطر قرار می‌دهند.

هنگامی که این سیستم‌ها با فضاهای وفقی گسترده شامل صدها یا هزاران پیکربندی مواجه می‌شوند، فرآیند تصمیم‌گیری با محدودیت‌های بنیادینی روبه‌رو می‌گردد. روش‌های مبتنی بر یادگیری ماشین سنتی وابستگی شدیدی به داده‌های برچسب‌دار زمان طراحی دارند که با وقوع رانش مفهومی در زمان اجرا دچار افت شدید می‌گردند. روش‌های مبتنی بر جستجو (مانند الگوریتم‌های ژنتیک و صعود تپه) با انفجار ابعادی مواجه شده و زمان پاسخ‌گویی آن‌ها به ثانیه‌ها یا حتی دقایق افزایش می‌یابد که به هیچ وجه پاسخ‌گوی سیستم‌های حساس به زمان نیست.

یادگیری تقویتی عمیق (DRL)[۲۰] علیرغم سرعت استنتاج بالا، در مواجهه با سیستم‌های خودوفق با چالش‌های بنیادین زیر دست‌به‌گریبان است:

- **گیرافتادن در بهینه‌های محلی:** در فضاهای وفقی بزرگ، الگوریتم‌های متداول به دلیل کاوش ناکافی به‌سرعت در دام سیاست‌های نیمه‌بهینه گرفتار می‌شوند.
- **نیاز به بازآموزی‌های پرهزینه زمان اجرا:** مواجهه با شرایط محیطی جدید معمولاً مستلزم بازآموزی کامل شبکه عصبی است که فرآیندی زمان‌بر و اخلال‌گر در عملکرد بلادرنگ سیستم به شمار می‌رود.
- **فروپاشی ارزش در لاگ‌های با غلبه شکست:** در سناریوهای مأموریتی پرخطر، بیش از ۹۰٪ از رکوردهای ثبت‌شده در لاگ‌ها مربوط به نقض الزامات کیفی است. الگوریتم‌های استاندارد یادگیری تقویتی در چنین محیط‌هایی یا دچار فروپاشی مقادیر کیو می‌شوند یا به دام سیاست‌های محافظه‌کارانه منفعل (مانند توقف کامل یا پرواز با سرعت حداقل) می‌افتند.
- **شکاف واقعیت میان مدل‌های جانشین و فیزیک اجرا:**[۲۱] برای پاسخ‌گویی در مهلت‌های زمانی سخت، طراحان ناچارند از مدل‌های جانشین تقریب‌گر[۲۲] استفاده کنند. این مدل‌ها به دلیل چشم‌پوشی از عوامل دینامیکی پیچیده نظیر تأخیر عملگرها و جفت‌شدگی‌های آیرودینامیکی، در شرایط حدی و مانورهای پرخطر دچار خطا می‌شوند. در نتیجه، سپرهای ایمنی زمان اجرا[۲۳] که کورکورانه به این پیش‌بینی‌ها

[18] Quality of Service
[19] Cyber-Physical Systems
[20] Deep Reinforcement Learning
[21] Sim-to-Real / Reality Gap
[22] Surrogate Models
[23] Runtime Safety Shields

اعتماد می‌کنند، پیکربندی‌هایی را برمی‌گزینند که در فیزیک واقعی منجر به شکست مأموریت یا سقوط می‌گردد.

۱-۴ بیان مساله

به طور فشرده، سیستم‌های خودوفق در دو طیف متمایز نیازمند مدیریت عدم قطعیت هستند: سیستم‌های با کیفیت خدمات نرم با چرخه‌های چند دقیقه‌ای، و سیستم‌های فیزیکی_سایبری بلادرنگ[۲۴] با حلقه‌های کنترلی ۲۰ تا ۵۰ میلی‌ثانیه‌ای.

در این رده از سیستم‌های فیزیکی_سایبری، فاز برنامه‌ریزی[۲۵] در حلقه MAPE-K با یک «**سه‌گانه برنامه‌ریزی بلادرنگ**»[۲۶] مواجه است که تحقق هم‌زمان هر سه ضلع آن تا پیش از این رساله ناممکن می‌نمود:

۱. **مهلت‌های زمانی سخت بلادرنگ:**[۲۷]
هر تصمیم انطباقی در سیستم‌هایی نظیر کنترل پرواز پهپاد باید در بازه ۲۰ تا ۵۰ میلی‌ثانیه قطعی شود. روش‌های مبتنی بر جستجوی آنلاین زمان‌اجرا (نظیر NSGA-III) ثانیه‌ها طول می‌کشند؛ حتی روش‌های مبتنی بر جستجوی تقلیلی روی ویژگی‌های حساس (نظیر XDA-II) میانگین تأخیری معادل ۶۲/۶ میلی‌ثانیه دارند که خارج از مهلت زمانی سخت پروازی است.

۲. **الزامات قابلیت اعتماد**[۲۸] **چندهدفه تحت عدم توازن شدید شکست:** سیستم باید همزمان دوازده الزام کیفی و ایمنی متضاد را ارضا کند، در حالی که در لاگ‌های بازپخش مأموریت، بیش از ٪۹۰/۹۸ از انتقال‌ها حداقل یکی از الزامات را نقض کرده‌اند. سازوکارهای شکل‌دهی پاداش تصادفی اولیه با یکسان دیدن تمامی شکست‌ها، سقوط‌های مرگبار را مشابه خطاهای جزئی بازطراحی می‌کنند که منجر به افت مطلوبیت مأموریت می‌گردد.

۳. **شکاف واقعیت مدل‌های جانشین تا فیزیک اجرا:**[۲۹] برای دور زدن شبیه‌سازی سنگین، الگوریتم‌ها به ارزیابی مدل‌های طبقه‌بند جانشین با آستانه‌های مشخص تکیه می‌کنند. این طبقه‌بندها نوسانات توربولانس و تأخیر عملگرها را نادیده می‌گیرند. در نتیجه، سپرهای ایمنی که تنها به نمرات جانشین اکتفا می‌کنند، گزینه‌هایی را تایید می‌نمایند که در فیزیک پرواز به شکست قطعی منجر می‌شوند.

بنابراین، مسئله بنیادین این رساله به شرح زیر تعریف می‌گردد:

[24] Hard-Real-Time Cyber-Physical Systems
[25] Plan Phase in MAPE-K
[26] Real-Time Planning Trilemma
[27] Strict Real-Time Deadlines
[28] Dependability
[29] Surrogate-to-Physics Reality Gap

طراحی، تعمیم و اثبات صوری یک معماری یکپارچه یادگیری تقویتی عمیق خودوفق که (۱) بدون بازآموزی اخلال‌گر، از نقاط بهینه محلی در فضاهای وفقی بزرگ عبور کند، (۲) با سنتز آفلاین هدایت‌شده با مشخصه، عدم توازن شدید شکست لاگ‌ها را مهار نماید، (۳) با اعتبارسنجی کشسان در هر زمان، مهلت زمانی پاسخ‌گویی زیر ۳/۵ میلی‌ثانیه را تضمین کند، و (۴) شکاف واقعیت میان مدل‌های جانشین و فیزیک اجرای سیستم را به حداقل برساند.

فرمول‌بندی ریاضی مختصر مساله

برای درک عمیق‌تر چالش‌های تصمیم‌گیری در سیستم‌های خودوفق، در این بخش مسئله انطباق زمان اجرا را به صورت ریاضی فرمول‌بندی می‌کنیم. این فرمول‌بندی سطح بالا مبنایی برای ارائه جزئیات کامل در فصل دوم خواهد بود.

تعریف فضای وفقی: فضای وفقی سیستم شامل مجموعه‌ای متناهی از گزینه‌های پیکربندی یا اعمال وفقی گسسته است که با $\mathcal{A}$ نشان داده می‌شود:

$$\mathcal{A} = \{a_۱, a_۲, \ldots, a_n\}, \quad n \leq ۴۰۹۶ \tag{۱-۱}$$

هر گزینه $a_i \in \mathcal{A}$ نمایانگر یک پیکربندی شبکه، توزیع منابع، یا پهنای باند اختصاص‌یافته در یک لحظه مشخص است. در این تحقیق، ابعاد فضای وفقی تا مقیاس بزرگ ($n = ۴۰۹۶$) مورد بررسی قرار گرفته است.

مدل فرآیند تصمیم‌گیری مارکوف: مسئله انطباق را به صورت یک فرآیند تصمیم‌گیری مارکوف (MDP)[۳۰] مدل‌سازی می‌کنیم [۵، ۶]. فضای حالت $\mathcal{S}$ وضعیت‌های سیستم و شرایط تداخل محیطی را پوشش می‌دهد. در هر گام زمانی t، عامل وفقی بر اساس سیاست انطباق خود $\pi(a|s)$، اقدامی مانند $a_t \in \mathcal{A}$ را در حالت $s_t \in \mathcal{S}$ انتخاب می‌کند که منجر به انتقال به حالت بعدی $s_{t+۱}$ و دریافت پاداش بازخوردی $R(s_t, a_t)$ می‌گردد.

تابع هدف: هدف نهایی عامل، پیدا کردن یک سیاست بهینه انطباق π^* است که امید ریاضی مجموع پاداش‌های تنزیل‌شده بلندمدت سیستم را بیشینه کند:

$$\max_{\pi} \mathbb{E}\left[\sum_{t=۰}^{\infty} \gamma^t R(s_t, a_t)\right] \tag{۲-۱}$$

[30] Markov Decision Process

که در آن $\gamma \in [۰, ۱)$ نرخ تنزیل پاداش‌های آتی است.

قیود عملیاتی مسئله: سیاست استخراج‌شده π^* باید تحت سه قید عملیاتی و بنیادین زیر بهینه‌سازی شود:

۱. **قید خروج از بهینه‌های محلی بدون بازآموزی:** عامل یادگیرنده باید قادر باشد بدون ایجاد اخلال در سیستم در قالب بازآموزی مکرر در زمان اجرا، از نقاط بهینه محلی عبور کند.

۲. **قید مقیاس‌پذیری زمانی:** زمان پاسخ محاسباتی برای انتخاب عمل بهینه $a^* \in \mathcal{A}$ در زمان اجرا باید بسیار ناچیز و در حد میلی‌ثانیه باشد تا به سرعت به رانش مفهومی پاسخ داده شود.

۳. **قید استقلال از دانش دامنه:** سازوکار کاوشگری عامل نباید به فرمول‌بندی پاداش‌های دقیق و متکی بر دانش تخصصی مهندسان دامنه وابسته باشد و باید به طور خودمختار رفتار کاوشگری بهینه را هدایت کند.

پیشینه و شکاف تحقیقاتی

اگرچه کارهای کلاسیک در حوزه سیستم‌های خودوفق زیربنای نظری این پارادایم را ایجاد کرده‌اند، اما انتخاب راهبرد یا سیاست انطباق بهینه در زمان اجرا همچنان یک چالش اساسی است. در این بخش، خلاصه‌ای از پیشینه پژوهش در طراحی سازوکارهای تصمیم‌گیری در فضاهای وفقی بزرگ ارائه شده و شکاف‌های تحقیقاتی موجود شناسایی می‌گردد.

تحلیل تطبیقی رویکردهای موجود و تبیین شکاف تحقیقاتی

به طور کلی، تحقیقات صورت گرفته در ادبیات سیستم‌های خودوفق جهت هدایت فرآیند تصمیم‌گیری زمان اجرا در سه پارادایم اصلی قابل طبقه‌بندی و تحلیل انتقادی هستند:

۱. رویکردهای مبتنی بر یادگیری ماشین سنتی: این دسته از روش‌ها از مدل‌های یادگیری نظارت‌شده یا بدون نظارت برای کاهش ابعاد فضای وفقی یا پیش‌بینی اثرات پیکربندی‌ها بهره می‌گیرند. با این حال، کویین و همکاران[31] در پژوهش‌های خود [۷، ۸] نشان داده‌اند که این روش‌ها وابستگی شدیدی به در دسترس بودن داده‌های آموزشی برچسب‌دار با کیفیت بالا در زمان طراحی دارند. در محیط‌های پویا و نامشخص زمان اجرا، توزیع داده‌های محیطی با توزیع مفروض زمان طراحی دچار واگرایی شده که منجر به پدیده رانش مفهومی [۹] و در نتیجه افت شدید دقت پیش‌بینی مدل‌ها می‌گردد.

۲. رویکردهای مبتنی بر جستجوی آنلاین: این روش‌ها مسائل انطباق زمان اجرا را به عنوان یک مسئله بهینه‌سازی فرمول‌بندی کرده و از الگوریتم‌های اکتشافی یا جستجوی تصادفی سود می‌جویند. کوکر[32] [۱۰]

[31] Federico Quin et al.

[32] Zachary Coker et al.

و کینیر و همکاران[۳۳] [۱۱، ۱۲] نشان داده‌اند که اگرچه الگوریتم‌های بهینه‌سازی تصادفی در فضاهای وفقی کوچک کارآمد هستند، اما در فضاهای وفقی گسسته و بزرگ (با صدها یا هزاران پیکربندی) دچار معضل مقیاس‌پذیری و تأخیر محاسباتی بسیار بالا در زمان اجرا می‌شوند؛ به طوری که زمان انطباق با مهلت‌های سخت بلادرنگ سیستم به هیچ وجه همخوانی ندارد.

۳. رویکردهای یادگیری تقویتی سنتی: این مدل‌ها به عامل اجازه می‌دهند تا سیاست بهینه انطباق را از طریق آزمون و خطا در تعامل مستقیم با محیط فراگیرد. با این وجود، رویکردهای کلاسیک یادگیری تقویتی عمیق (نظیر الگوریتم‌های DQN[۳۴] با کاوش ϵ-greedy) به دلیل محدودیت کاوشگری خود، در فضاهای وفقی بزرگ به شدت مستعد افتادن در بهینه‌های محلی هستند [۱۳، ۱۴]. عبور از این بهینه‌های محلی در روش‌های سنتی نیازمند فرآیندهای پرهزینه و زمان‌بر بازآموزی[۳۵] در زمان اجرا است که موقتاً پایداری و ثبات عملکرد سیستم را مختل می‌سازد.

با بررسی ادبیات موجود، شکاف تحقیقاتی کلیدی زیر شناسایی می‌شود:

«هیچ‌یک از رویکردهای موجود در مهندسی سیستم‌های خودوفق قادر نبوده‌اند به طور همزمان (۱) بدون نیاز به بازآموزی‌های محاسباتی مکرر و اخلال‌گر، از بهینه‌های محلی در زمان اجرا عبور کنند، (۲) در فضاهای وفقی گسسته و بزرگ (تا مقیاس ۴۰۹۶ گزینه تغییر) در زمان اجرا مقیاس‌پذیر باشند، و (۳) مستقل از دانش دامنه خاص[۳۶] برای هدایت فرآیند کاوش عمل کنند.»

این رساله با هدف پر کردن این خلاء تحقیقاتی، روش پایه‌ای یادگیری تقویتی عمیق با شکل‌دهی تصادفی پاداش (RS-DRL) و معماری تعمیم‌یافته دوسطحی (RS-DRL^{+}) را پیشنهاد و اعتبارسنجی می‌کند.

۱-۵ سؤالات پژوهش

با توجه به محدودیت‌های رویکردهای پیشین و سه‌گانه برنامه‌ریزی تبیین‌شده در سیستم‌های خودوفق فیزیکی- سایبری و توزیع‌شده، این رساله در صدد پاسخ به شش پرسش اساسی زیر به همراه زیرسؤالات متناظر است:

۱. **سؤال اول (خروج از بهینه‌های محلی):** چگونه می‌توان روشی مبتنی بر یادگیری تقویتی عمیق طراحی کرد که به‌طور مؤثر از بهینه‌های محلی در فضاهای وفقی گسسته و بزرگ، بدون نیاز به بازآموزی مکرر و پرهزینه در زمان اجرا، عبور کند؟

- **زیرسؤال ۱-۱:** چه سازوکاری برای تزریق کنترل‌شده‌ی خوش‌بینی به فرآیند بازپخش تجربیات یادگیرنده بدون ایجاد بی‌ثباتی در برازش تقریب‌گر عصبی می‌توان ابداع نمود؟

[33] Chase Kinneer et al.

[34] Deep Q-Network

[35] Retraining

[36] Domain-agnostic

- **زیرسؤال ۱-۲:** چگونه می‌توان از تجربیات ناموفق گذشته عامل بدون نیاز به ورود به فاز آموزش مجدد آنلاین استفاده کرد؟
- **زیرسؤال ۱-۳:** چه تضمینی برای عدم واگرایی یا نوسان مخرب در مقادیر کیو در محیط‌های دارای تداخل شدید وجود دارد؟

۲. **سؤال دوم (ادغام شکل‌دهی پاداش و تعمیم‌پذیری):** چگونه می‌توان سازوکارهای شکل‌دهی پاداش تصادفی[۳۷] را با بازپخش تجربه[۳۸] ادغام کرد تا تعمیم‌پذیری سیستم در مواجهه با شرایط محیطی نادیده بهبود یابد؟

۳. **سؤال سوم (مدیریت فضاهای وفقی بسیار بزرگ):** چگونه روش پیشنهادی می‌تواند فضاهای وفقی گسسته و بسیار بزرگ (از ۲۱۶ تا ۴۰۹۶ گزینه پیکربندی) را در حین حفظ عملکردی نزدیک به بهینه، در زمان اجرا مدیریت نماید؟

۴. **سؤال چهارم (ارزیابی مقایسه‌ای در سیستم‌های با کیفیت خدمات نرم):** تا چه حد روش پایه‌ای RS-DRL در شبکه‌های حسگر توزیع‌شده DeltaIoT نسبت به ۶ خط پایه موجود نظیر ϵ-greedy DQN [۱۵]، HER[۳۹] [۱۶]، Soft HER [۱۷]، DLASER+[۴۰] [۱۸]، ML4EAS[۴۱] [۷، ۸] و پیکربندی مرجع ایستا[۴۲] برتری آماری معنادار از نظر همگرایی و مصالحه‌های چندهدفه نشان می‌دهد؟

- **زیرسؤال ۴-۱:** عملکرد مجانبی RS-DRL در سناریوهای غیرایستا در مقایسه با روش‌های رقیب چگونه است؟
- **زیرسؤال ۴-۲:** آیا برتری‌های عملکردی در مقیاس ۴۰۹۶ گزینه وفقی از دیدگاه آماری با اندازه اثر کوهن[۴۳] معنادار است؟

۵. **سؤال پنجم (رعایت مهلت‌های زمانی سخت و اعتبارسنجی در هر زمان - RQ5):** چگونه می‌توان فاز برنامه‌ریزی حلقه کنترلی را با الگوهای اعتبارسنجی در هر زمان (CA-EPV) ساختاردهی نمود تا ضمن ارائه پاسخ‌های نامی زیر میلی‌ثانیه‌ای (۰/۴۸ میلی‌ثانیه)، پالایش موضعی گزینه‌ها بر روی زیرفضای حساسیت تحلیل شاپلی درختی مقید شده و تأخیر کل برنامه‌ریزی به طور قطعی زیر ۳/۵ میلی‌ثانیه (بسیار کمتر از مهلت زمانی سخت ۲۰ تا ۵۰ میلی‌ثانیه‌ای در سیستم‌های پروازی) باقی بماند؟

[37] Randomized Reward Shaping
[38] Experience Replay
[39] Hindsight Experience Replay
[40] Deep Learning for Adaptation Space Reduction (Extended)
[41] Machine Learning for Efficient Adaptation Space Reduction
[42] Reference Baseline
[43] Jacob Cohen's d Effect Size

- **زیرسؤال ۵-۱:** چگونه می‌توان با قضیه کران کاردینالیتی حساسیت، تعداد گزینه‌های کاندیدای زمان اجرا را به کران $|\mathcal{N}(a_\cdot)| \leq ۲m+۱$ مقید کرده و مرتبه ارزیابی‌های زمان اجرا را از کل فضای وفقی به مرتبه خطی متغیرهای حساس $\mathcal{O}(m \cdot K)$ کاهش داد؟
- **زیرسؤال ۵-۲:** چه سازوکاری تضمین می‌کند که پالایش موضعی در هر زمان، گزینه وفقی سازگار با الزامات را هرگز به گزینه‌ای ناسازگار تبدیل نکند (تضمین عدم افت ایمنی)؟

۶. **سؤال ششم (مهار شکاف واقعیت و عدم توازن شدید شکست در سیستم‌های فیزیکی‌ـسایبری - RQ6):** الگوی سنتز آفلاین هدایت‌شده با مشخصه (SG-OS) چگونه با تعریف حاشیه بازیابی شکست $\mathcal{M}(s,a)$ و مشوق‌های مطلوبیت، سقوط‌های مرگبار را فیلتر نموده و در مقایسه با سپرهای ایمنی زمان اجرا که با اتکای صرف به مدل‌های جانشین در فیزیک پرواز دچار افت عملکرد می‌شوند، شکاف واقعیت مدل‌ـتا‌ـفیزیک را در محیط‌های حلقه‌ـبسته پروازی مهار می‌سازد؟

۱-۶ روش پیشنهادی

۱-۶-۱ مرور کلی بر راهکار دوسطحی: روش پایه‌ای RS-DRL و معماری RS-DRL$^+$

راهکار ارائه‌شده در این رساله، یک معماری دوسطحی تکاملی برای تصمیم‌گیری خودوفق تحت عدم قطعیت است. در سطح نخست، چارچوب RS-DRL توسعه داده شده است که مسئله انطباق را به صورت یک فرآیند تصمیم‌گیری مارکوف مدل کرده و با شکل‌دهی تصادفی پاداش در فاز بازپخش تجربه، کاوش هدفمند را بدون دانش صریح دامنه میسر می‌سازد.

در سطح دوم، جهت رفع سه‌گانه برنامه‌ریزی در سیستم‌های فیزیکی‌ـسایبری بلادرنگ، معماری تعمیم‌یافته RS-DRL$^+$ به عنوان یک راهکار دوپایه‌ای مبتنی بر دو الگوی معماری مهندسی نرم‌افزار ارائه شده است:

۱. **الگوی سنتز آفلاین هدایت‌شده با مشخصه‌ها (SG-OS):** این الگو در فاز آموزش آفلاین مستقر شده و شامل دو فرمول‌بندی MU-RS-DRL (هدایت‌شده با حاشیه بازیابی شکست و مطلوبیت عملیاتی) و CM-RS-DRL (بافرسازی حاشیه اطمینان) است. این الگو شکست‌های فاجعه‌بار غیرقابل‌جبران را حذف کرده و پاداش‌ها را به صورت پیوسته متناسب با عمق انطباق مقیاس‌بندی می‌کند.

۲. **الگوی اعتبارسنجی کشسان فاز برنامه‌ریزی با قرارداد در هر زمان (CA-EPV):** این الگو در ماژول PG-ALR پیاده‌سازی شده و فرآیند تصمیم‌گیری زمان اجرا را به سه مرحله تفکیک می‌کند: پیشنهاد نامی زیر میلی‌ثانیه‌ای (مرحله ۱)، گیت حاشیه و تنش محیطی در مسیر سریع (مرحله ۲)، و پالایش موضعی ۱ـ گام مقید به ابعاد حساسیت توضیح‌پذیر TreeSHAP با قطعیت زمانی زیر ۳/۵ میلی‌ثانیه (مرحله ۳).

۱-۶-۲ یکپارچه‌سازی با حلقه کنترلی MAPE-K

در این معماری، مؤلفه‌های یادگیری و اعتبارسنجی درون حلقه استاندارد MAPE-K تعبیه شده‌اند. مؤلفه برنامه‌ریزی مجهز به دو مسیر سریع[۴۴] و پالایش موضعی[۴۵] است که تصمیمات را پیش از ارسال به مؤلفه اجرا[۴۶] بر اساس اولویت‌بندی ریسک اعتبارسنجی می‌نماید. در سیستم‌های با کیفیت خدمات نرم، این اعتبارسنجی توسط ابزار مدل‌چکینگ آماری UPPAAL-SMC پشتیبانی می‌شود و در سیستم‌های فیزیکی‌ـ سایبری بلادرنگ، توسط مدل‌های جانشین برداریِ مقید به قرارداد در هر زمان اجرا می‌گردد.

۱-۷ نوآوری‌های اصلی رساله

بنیانِ علمی و سهم پژوهشی این پایان‌نامه در قالب شش نوآوری اصلی زیر تبیین می‌گردد:

۱. **نوآوری اول: الگوریتم یادگیری تقویتی با شکل‌دهی تصادفی پاداش RS-DRL:** ارائه یک سازوکار پیشنهادی شکل‌دهی پاداش در بازپخش تجربیات گذشته بدون نیاز به دانش دامنه خاص، که با تزریق هدفمند خوش‌بینی به شکست‌ها، عامل یادگیرنده را قادر به خروج موفق از نقاط بهینه محلی در فضاهای وفقی بزرگ می‌سازد.

۲. **نوآوری دوم: یکپارچه‌سازی حلقه MAPE-K با موتور اعتبارسنجی صوری UPPAAL-SMC:** طراحی معماری یکپارچه‌ای که تصمیم‌گیری بلادرنگ را با اعتبارسنجی صوری پیش از اجرا همگام ساخته و اطمینان صد درصدی از پایبندی به الزامات کیفیت خدمات در سیستم‌های توزیع‌شده را فراهم می‌آورد.

۳. **نوآوری سوم: مدیریت مقیاس‌پذیر فضاهای وفقی تا ابعاد ۴۰۹۶ گزینه:** توسعه راهکار بهینه‌سازی چندهدفه که در مواجهه با ابعاد عظیم پیکربندی در شبکه حسگر DeltaIoTv2، تصمیمات انطباقی را در کسری از میلی‌ثانیه بدون افت کیفیت اتخاذ می‌نماید.

۴. **نوآوری چهارم: معماری تفکیک زمانی:**[۴۷] سازماندهی ساختار محاسباتی به‌گونه‌ای که استنتاج بلادرنگ در زمان اجرا را به طور کامل از محاسبات سنگین بازآموزی شبکه در پس‌زمینه مستقل می‌سازد.

۵. **نوآوری پنجم: الگوی سنتز آفلاین هدایت‌شده با مشخصه‌ها (SG-OS):** ابداع سازوکارهای MU-RS-DRL و CM-RS-DRL که با تعریف حاشیه بازیابی $\mathcal{M}(s,a)$ و مشوق مطلوبیت $\mathcal{U}_{\text{inc}}(a)$، برای نخستین بار عدم توازن شدید شکست (بیش از ۹۰٪) در لاگ‌های بازپخش را حل نموده و مانع گرفتار شدن عامل در تله سیاست‌های انفعالی می‌گردد.

[44] Fast Path
[45] Refinement Path
[46] Execute Phase in MAPE-K
[47] Temporal Separation Architecture

۶. **نوآوری ششم: الگوی اعتبارسنجی کشسان با قرارداد در هر زمان (CA-EPV) و مهار شکاف واقعیت:** طراحی ماژول تصمیم‌گیری PG-ALR با اثبات صوری گزاره ۱ (کران کاردینالیتی $|\mathcal{N}(a_\cdot)| \leq ۲m + ۱$ با پیچیدگی $\mathcal{O}(m \cdot K)$) و گزاره ۲ (تضمین عدم افت ایمنی)، که زمان اعتبارسنجی را مستقل از ابعاد فضای وفقی به زیر ۳/۵ میلی‌ثانیه محدود ساخته و شکاف واقعیت میان مدل‌های جانشین و فیزیک پرواز حلقه‌ـ بسته را مهار می‌نماید.

محدوده، قلمرو و مخاطبان پژوهش

محدوده، قلمرو و مخاطبان پژوهش

برای تبیین دقیق مرزها و قلمرو این رساله دکتری، دامنه‌ی مسائل تحت پوشش و موضوعات خارج از محدوده به صورت مدون تبیین می‌گردد:

قلمرو و موضوعات تحت پوشش: تمرکز بنیادین این پژوهش بر سیستم‌های خودوفق با فضاهای وفقی گسسته است که گزینه‌های پیکربندی متعددی از مقیاس‌های کوچک تا فضاهای بسیار بزرگ (تا ۴۰۹۶ گزینه در شبکه حسگر DeltaIoT و ۶۰ پیکربندی در شبیه‌ساز مأموریت ناوگان پهپادی DARTSim) را در بر می‌گیرند. متدولوژی یادگیری بر پایه مدل‌های تقویتی بدون مدل نظیر DQN و شبکه‌های عصبی عمیق با بافرهای بازپخش تجربه آفلاین و آنلاین استوار است. بسترهای ارزیابی دوگانه شامل سیستم‌های حسگر بی‌سیم صنعتی (به عنوان نماینده الزامات کیفیت خدمات نرم، اتلاف بسته و مصرف انرژی) و سیستم‌های فیزیکی‌ـ سایبری بلادرنگ (شبیه‌ساز مأموریت ۶ درجه آزادی پهپادها با ۱۲ الزام قابلیت اعتماد متضاد و مهلت‌های سخت ۲۰ تا ۵۰ میلی‌ثانیه‌ای) می‌باشند. همچنین، از منظر صوری، اثبات ریاضی کران‌های کاردینالیتی اعتبارسنجی ($\mathcal{O}(m \cdot K)$) و تضمین عدم افت انطباق با مشخصه‌ها تحت خطای کالیبراسیون مدل‌های جانشین در دامنه مستقیم این پژوهش قرار دارد.

موضوعات خارج از محدوده پژوهش: در تقابل با قلمرو فوق، بهینه‌سازی پارامترهای پیوسته نامحدود که نیازمند الگوریتم‌های آکتورـ کریتیک پیوسته (SAC)[۴۸] هستند، در حیطه اهداف بلندمدت و کارهای آتی تعریف شده است. همچنین، این رساله بر یک حلقه مدیریت متمرکز تاکتیکی تمرکز دارد و هماهنگی کاملاً نامتمرکز و چندعاملی توزیع‌شده (MARL)[۴۹] در شبکه‌های نامتقارن خارج از دامنه فعلی است. در نهایت، اثبات تئوریک همگرایی مجانبی سراسری نامحدود برای تقریب‌گرهای غیرخطی به عنوان یک مسئله باز در تئوری یادگیری تقویتی محسوب شده و در این رساله، عملکرد مجانبی به صورت تجربی و مبتنی بر ۲,۰۰۰

[48] Soft Actor-Critic

[49] Multi-Agent Reinforcement Learning

پرواز و آزمون‌های فرضیه آماری معتبر اثبات شده است (هرچند کران‌های زمان اجرا و پایداری فاز پالایش به صورت صوری و قطعی اثبات گردیده‌اند).

مخاطبان و کاربردهای بالقوه: دستاوردها و الگوهای معماری ارائه‌شده در این رساله برای سه گروه عمده سودمند واقع خواهد شد: نخست، مهندسان و محققان سیستم‌های خودوفق جهت استقرار حلقه‌های کنترلی خودمختار MAPE-K که نیازمند تصمیم‌گیری تضمین‌شده در محیط‌های عدم قطعیت با الزامات کیفی چندگانه هستند؛ دوم، طراحان سیستم‌های فیزیکی‌ـ سایبری، خودروهای خودمختار و حوزه هوافضا برای پیاده‌سازی و استقرار سازوکارهای انطباق بلادرنگ با رعایت قطعی مهلت‌های زمانی سخت (زیر ۵۰ میلی‌ثانیه)؛ و سوم، پژوهشگران یادگیری تقویتی کاربردی جهت حل معضل عدم توازن داده‌های شکست در لاگ‌های عملیاتی و مهار شکاف واقعیت مدل‌های جانشین در زمان اجرا.

۱-۸ مروری بر فصول رساله

این بخش نقشه راه ساختاری و تکاملی فصول باقی‌مانده رساله را تبیین می‌نماید. ساختار رساله به گونه‌ای طراحی شده است که هر یک از فصول، پیوندی منسجم و مستقیم میان چالش‌های سه‌گانه برنامه‌ریزی (مسائل فرعی ۱ تا ۳)، نوآوری‌ها و مشارکت‌های شش‌گانه، و مقالات علمی مستخرج برقرار سازد. در ادامه، دامنه تمرکز و اهداف هر یک از فصول به تفصیل تشریح شده است:

فصل ۲ (مبانی نظری و مدل‌سازی سیستم): این فصل به تبیین دقیق زیربنای ریاضی و قلمرو نظری پژوهش اختصاص دارد. در این فصل، فرمول‌بندی فرآیند تصمیم‌گیری مارکوف، اصول یادگیری تقویتی عمیق، سازوکار حلقه‌های خودوفق خودمختار MAPE-K و مدل‌های جانشین تحلیلی ارائه شده و ویژگی‌های معماری دو بستر ارزیابی تجربی—شامل شبکه حسگر بی‌سیم چندگامی DeltaIoT و شبیه‌ساز مأموریت تاکتیکی ناوگان پهپادی DARTSim—به دقت مدل‌سازی می‌گردند. مباحث این فصل زیربنای نظری لازم برای نوآوری‌های ۱، ۲ و ۶ را پایه‌گذاری نموده و فرمول‌بندی ریاضی مسائل فرعی ۱ (فضاهای مقیاس‌بزرگ) و ۳ (شکاف واقعیت و مهلت‌های زمانی) را فراهم می‌سازد.

فصل ۳ (پیشینه پژوهش و کارهای مرتبط): در این فصل، مرور انتقادی و نظام‌مندی بر ادبیات پیشین در پنج محور بنیادین انجام می‌پذیرد: روش‌های کلاسیک مدیریت فضاهای وفقی بزرگ، کاربرد یادگیری ماشین در سیستم‌های خودوفق، تکنیک‌های شکل‌دهی پاداش در یادگیری تقویتی، الگوهای اعتبارسنجی در هر زمان، و سپرهای ایمنی زمان اجرا. با ارائه ماتریس مقایسه‌ای جامع و آسیب‌شناسی شکست سپرهای ایستا در مواجهه با عدم قطعیت‌های فیزیکی، شکاف‌های تحقیقاتی موجود استخراج شده و ضرورت علمی نوآوری‌های ۱، ۳، ۵ و ۶ اثبات می‌گردد.

فصل ۴ (معماری پیشنهادی دوسطحی: چارچوب پایه‌ای RS-DRL و معماری پیشرفته RS-DRL$^+$): این فصل به ارائه تفصیلی متدولوژی و مشارکت‌های اصلی رساله می‌پردازد. در سطح نخست، چارچوب پایه‌ای RS-DRL مبتنی بر شکل‌دهی تصادفی پاداش در بازپخش تجربه و بازبینی صوری ناهمگام UPPAAL-SMC تبیین می‌شود. در سطح دوم، برای پاسخ‌گویی به مهلت‌های کنترلی سخت (۲۰ تا ۵۰ میلی‌ثانیه) در سیستم‌های فیزیکی–سایبری، معماری دوسطحی RS-DRL$^+$ بر پایه دو الگوی معماری پیشنهادی مهندسی نرم‌افزار ارائه می‌گردد: الگوی سنتز آفلاین هدایت‌شده با مشخصه (SG-OS شامل روش‌های MU-RS-DRL و CM-RS-DRL) جهت حذف سقوط‌های فاجعه‌بار با حاشیه بازیابی چندقیدی $\mathcal{M}(s,a)$، و الگوی اعتبارسنجی کشسان با قرارداد در هر زمان (CA-EPV در قالب ماژول PG-ALR) جهت تحدید فضای وارسی دفاعی بر زیرفضای حساسیت مقادیر شاپلی درختی. همچنین، اثبات صوری گزاره ۱ (پیچیدگی زمانی $\mathcal{O}(m \cdot K)$ با کران کاردینالیتی $|\mathcal{N}(a.)| \leq 2m+1$) و قضیه ۱ (تضمین صوری عدم افت ایمنی) در این فصل ارائه شده است. این فصل مستقیماً نوآوری‌های ۱، ۲، ۴، ۵ و ۶ را محقق ساخته و پاسخ تحلیلی به پرسش‌های RQ1، RQ2، RQ3، RQ5 و RQ6 ارائه می‌دهد. بخش عمده‌ای از دستاوردهای این فصل در قالب مقاله پژوهشی اصیل در مجله معتبر بین‌المللی ACM Transactions on Autonomous and Adaptive Systems (TAAS) [۱۹] به

چاپ رسیده است.

فصل ۵ (ارزیابی تجربی و تحلیل نتایج): این فصل اعتبارسنجی تجربی چندوجهی، بنچ‌مارک‌های تطبیقی و آزمون‌های معناداری آماری را گزارش می‌کند. ارزیابی‌ها در سه بخش سازمان‌دهی شده‌اند: (۱) ارزیابی عملکرد روش پایه‌ای RS-DRL بر روی شبکه حسگر DeltaIoT تا مقیاس ۴۰۹۶ گزینه وفقی در مقایسه با ۶ روش خط پایه پیشرفته، و دستیابی به کاهش ۲۳/۲۲ درصدی اتلاف بسته و ۳۹/۰۷ درصدی تأخیر؛ (۲) ارزیابی جامع ۲,۰۰۰ پرواز ۶ درجه آزادی حلقه‌بسته فیزیکی در شبیه‌ساز DARTSim، اثبات مهار کامل شکاف واقعیت مدل‌ـ تاـ فیزیک (ارتقای بقای مأموریت به ٪۷۰/۵ در مقایسه با ٪۶۵/۰ سپرهای ایمنی مرسوم)، کاهش ۳۱ درصدی در واریانس عملیاتی و رعایت قطعی مهلت‌های زمانی زیر ۳/۵ میلی‌ثانیه؛ و (۳) آزمون‌های فرض آماری ناپارامتری ویلکاکسون[۵۰]، اندازه‌های اثر کوهن و تصحیح هولم‌ـ بونفرونی[۵۱]. این فصل به نوآوری‌های ۱ تا ۶ اختصاص داشته، پاسخ تجربی کامل به پرسش‌های پژوهش (RQ1 تا RQ6) را فراهم می‌سازد و نتایج تجربی مستندشده در مقاله مجله ACM TAAS [۱۹] را در بر دارد.

فصل ۶ (نتیجه‌گیری و افق‌های پژوهش‌های آتی): در نهایت، این رساله با جمع‌بندی مشارکت‌ها و نوآوری‌های ارائه‌شده، تبیین درس‌آموخته‌ها و مصالحه‌های عملیاتی مهندسی نرم‌افزار، و تحلیل تهدیدهای روایی خاتمه می‌یابد. همچنین، سه افق توسعه بنیادین شامل یادگیری تقویتی چندعاملی توزیع‌شده در شبکه‌های نامتقارن، یادگیری مداوم مادام‌العمر در سیستم‌های فیزیکی‌ـ سایبری و تعمیم اعتبارسنجی در هر زمان به فضاهای اکشن پیوسته نامحدود به عنوان مسیرهای تحقیقاتی آتی ترسیم می‌گردند.

در راستای یکپارچه‌سازی ساختاری رساله، جدول ۱-۱ ارتباط میان فصول، نوآوری‌های متناظر، مسائل فرعی سه‌گانه برنامه‌ریزی، پرسش‌های پژوهش و انتشارات علمی مستخرج را خلاصه می‌نماید.

---

[50] Frank Wilcoxon Signed-Rank Test

[51] Sture Holm and Carlo Emilio Bonferroni Family-Wise Error Rate Correction

جدول ۱-۱: نگاشت جامع فصول رساله در برابر نوآوری‌ها، مسائل فرعی، پرسش‌های پژوهش و مقالات علمی مستخرج

فصل	عنوان و تمرکز محوری	نوآوری‌ها و مشارکت‌ها	مسائل فرعی و پرسش‌ها	انتشارات علمی مستخرج
۱	کلیات و تبیین مسئله	تبیین سه‌گانه برنامه‌ریزی، اهداف و ساختار رساله	معرفی مسائل فرعی ۱ تا ۳ و پرسش‌های RQ1–RQ6	—
۲	مبانی نظری و مدل‌سازی سیستم	زیربنای ریاضی نوآوری‌های ۱، ۲ و ۶ (MDP، DRL، MAPE-K)	فرمول‌بندی مسائل ۱ و ۳ (فضاهای بزرگ و مهلت سخت)	پیش‌نیاز نظری رساله
۳	مرور ادبیات و کارهای مرتبط	تحلیل انتقادی و شناسایی شکاف‌ها در ۵ محور اصلی	زمینه‌سازی مسائل فرعی ۱، ۲ و ۳	سنتز انتقادی ادبیات
۴	معماری پیشنهادی دوسطحی (RS-DRL و RS-DRL^{+})	نوآوری‌های ۱، ۲، ۴، ۵ و ۶ (SG-OS، CA-EPV، اثبات قضیه ۱ و ۲)	حل تحلیلی مسائل فرعی ۱، ۲ و ۳ (پاسخ به RQ1، RQ2، RQ3، RQ5 و RQ6)	مقاله منتشرشده در مجله ACM TAAS [۱۹]
۵	ارزیابی تجربی و تحلیل نتایج	اعتبارسنجی تجربی نوآوری‌های ۱ تا ۶ (DeltaIoT و ۲,۰۰۰ پرواز DARTSim)	اعتبارسنجی تجربی مسائل ۱، ۲ و ۳ (پاسخ تجربی به RQ1–RQ6)	نتایج تجربی مقاله ACM TAAS [۱۹]
۶	نتیجه‌گیری و کارهای آتی	جمع‌بندی مشارکت‌ها، تحلیل مصالحه‌ها و تهدیدهای روایی	تحلیل پایانی مسائل و ترسیم افق‌های توسعه آتی	—

فصل دوم

مبانی نظری و مدل‌سازی سیستم

۲-۱ مقدمه

سیستم‌های نرم‌افزاری معاصر به طور فزاینده‌ای در محیط‌هایی پویا، توزیع‌شده و اساساً غیرقابل پیش‌بینی فعالیت می‌کنند. این سیستم‌ها طیف وسیعی از کاربردها، از شبکه‌های حسگر بی‌سیم مقیاس‌وسیع در اینترنت اشیاء گرفته تا میکروسرویس‌های ابری را شامل می‌شوند. چنین سیستم‌های پیچیده‌ای باید اهداف کیفیت خدمات (QoS)[۱] خود را در حضور عدم قطعیت‌های مداوم زمان اجرا حفظ نمایند.

برای مواجهه با این چالش، رویکرد سیستم‌های خودوفق[۲] به عنوان یک پارادایم محوری در مهندسی نرم‌افزار مطرح شده است. سیستم‌های خودوفق با مجهز شدن به حلقه‌های بازخورد کنترلی، قادرند رفتار و ساختار خود را در زمان اجرا ارزیابی کرده و تغییرات بهینه را بدون نیاز به مداخله صریح انسانی اعمال کنند.

هدف محوری این فصل، پی‌ریزی یک چارچوب نظری و ریاضی مستحکم برای تحلیل، طراحی و مدل‌سازی سیستم‌های خودوفق است تا زمینه لازم برای درک راهکار دوسطحی پیشنهادی این رساله (روش پایه‌ای RS-DRL و معماری تعمیم‌یافته RS-DRL$^+$) فراهم گردد. این فصل ابتدا مبانی سیستم‌های خودوفق، معماری‌های مرجع و الگوهای طراحی را تبیین می‌کند. سپس، با ورود به مبحث عدم قطعیت، دسته‌بندی‌های محیطی، سیستمی، اهداف و به ویژه پدیده شکاف واقعیت مدل‌های جانشین[۳] در سیستم‌های فیزیکی‌ـ‌سایبری تشریح می‌شود. در ادامه، مبانی مدل‌سازی ریاضی تصمیم‌گیری از طریق فرآیندهای تصمیم‌گیری مارکوف (MDP)[۴] و شبکه‌های کیو عمیق (DQN)[۵] ارائه می‌گردد. در بخش‌های پایانی، دو سیستم محک شاخص رساله به صورت صوری مدل‌سازی می‌شوند: نخست، شبکه حسگر بی‌سیم DeltaIoT[۶] به عنوان نماینده

[1] Quality of Service
[2] Self-Adaptive Systems
[3] Sim-to-Real / Reality Gap
[4] Markov Decision Process
[5] Deep Q-Network
[۶] بستر DeltaIoT: https://people.cs.kuleuven.be/~danny.weyns/software/DeltaIoT/

سیستم‌های توزیع‌شده با کیفیت خدمات نرم و ابعاد وفقی بزرگ؛ و دوم، شبیه‌ساز مأموریت ناوگان پهپادی DARTSim[۷] به عنوان نماینده سیستم‌های فیزیکی_سایبری بلادرنگ با مهلت‌های کنترلی سخت، داده‌های شکست شدید در لاگ‌ها، و الزامات قابلیت اعتماد چندگانه.

۲-۲ مبانی سیستم‌های خودوفق

۲-۲-۱ مفاهیم اصلی و تعاریف

سیستم خودوفق به کلاسی از سیستم‌های نرم‌افزاری گفته می‌شود که ویژگی‌های زیر را دارد: (۱) به طور مداوم وضعیت داخلی و محیط پیرامون خود را ارزیابی می‌کند. (۲) می‌تواند ساختار، رفتار یا پارامترهای عملیاتی خود را تغییر دهد. (۳) هدف این تغییرات، دستیابی به اهداف تجاری یا کیفی مشخص است [۲]. در مبانی مهندسی نرم‌افزار خودوفق، سه مفهوم کلیدی به عنوان ارکان اساسی تعریف می‌شوند: **فضای وفقی**[۸] که مجموعه تمامی پیکربندی‌ها، سناریوها یا تصمیمات متمایز قابل اتخاذ در زمان اجراست و در دامنه‌های واقعی ابعاد آن به صورت ترکیبی تا هزاران یا میلیون‌ها گزینه رشد می‌کند؛ **اهداف وفقی**[۹] که معیارهای عملکردی یا کیفی چندگانه و بعضاً متضادی هستند که سیستم باید آن‌ها را ارضا یا بهینه‌سازی کند؛ و **حلقه بازخورد**[۱۰] که جریان اطلاعاتی و کنترلی بسته‌ای را برای پایش مستمر، استنتاج تصمیم و اعمال به‌موقع تغییرات شکل می‌دهد.

تفاوت بنیادین میان سیستم‌های سنتی و خودوفق در نحوه مواجهه با فرضیات فاز طراحی نهفته است. در سیستم‌های کلاسیک، فرض بر این است که شرایط محیطی در فاز طراحی کاملاً شناخته شده و ایستا هستند. اما در محیط‌های معاصر، به دلیل تغییرات جوی، بار ترافیکی پویا و خرابی سخت‌افزاری، فرضیات طراحی به سرعت منقضی می‌شوند. بنابراین، خودوفق‌سازی راهکاری برای به تعویق انداختن تصمیمات طراحی به زمان اجراست تا سیستم بتواند بر اساس واقعیت‌های جاری تصمیم‌گیری کند [۳].

۲-۲-۲ معماری‌های مرجع و الگوهای طراحی

جهت سازماندهی ساختار درونی سیستم‌های خودوفق، معماری‌های مرجع متعددی ارائه شده است. یکی از برجسته‌ترین و پرکاربردترین الگوها، **معماری سه‌لایه‌ای کرامر و مگی**[۱۱] است که تفکیک دغدغه‌ها را در سطوح مختلف انتزاع تضمین می‌کند [۲۰]: **لایه مدیریت اهداف**[۱۲] در بالاترین سطح قرار داشته و وظیفه تفسیر اهداف تجاری کلان و تبدیل آن‌ها به اهداف کیفی در زمان اجرا را بر عهده دارد (مثلاً در صورت تغییر

[۷] شبیه‌ساز ناوگان پهپادی DARTSim (CMU-SEI): https://github.com/cps-sei/dartsim

[8] Adaptation Space

[9] Adaptation Goals

[10] Feedback Loop

[11] Three-Layer Architecture (Jeff Kramer and Jeff Magee)

[12] Goal Management Layer

اولویت کاربر از کاهش مصرف انرژی به افزایش حداکثری پایداری)؛ **لایه مدیریت تغییرات**[۱۳] وظیفه اصلی برنامه‌ریزی، استنتاج و تولید طرح‌های انطباق بر پایه ارزیابی گزینه‌های وفقی موجود را عهده‌دار است که هسته تصمیم‌گیری یادگیری تقویتی عمیق پیشنهادی در این رساله (RS-DRL و معماری RS-DRL^{+}) مستقیماً در این لایه مستقر شده و هماهنگی میان آموزش آفلاین و استنتاج بلادرنگ را برقرار می‌سازد؛ و نهایتاً **لایه کنترل مولفه‌ها**[۱۴] مستقیماً با مولفه‌های نرم‌افزاری و درایورهای سخت‌افزاری سیستم هدف تعامل داشته و وظیفه جمع‌آوری داده‌ها از حسگرها و اعمال مستقیم فرامین از طریق عملگرها را بر عهده دارد. تفکیک تمیز این لایه‌ها تضمین می‌کند که تغییر در منطق برنامه‌ریزی، نیازی به بازطراحی بخش‌های پایین‌دستی نداشته باشد.

۲-۲-۳ حلقه‌های کنترلی خودمختار: از MAPE-K تا موارد پیشرفته

حلقه خودمختار MAPE-K[۱۵] که برای نخستین بار توسط شرکت IBM معرفی شد، استاندارد طلایی و معماری مرجع بی‌بدیل برای توصیف جریان اطلاعات و کنترل در حلقه‌های بازخورد سیستم‌های خودوفق به شمار می‌رود [۲]. این حلقه متشکل از ۵ مولفه اصلی است که حول یک پایگاه دانش محوری ساماندهی شده‌اند: مؤلفه **پایش**[۱۶] داده‌های خام را از حسگرها جمع‌آوری کرده، نویزهای فرکانس‌بالا را فیلتر نموده و نمایشی منسجم از وضعیت جاری تولید می‌کند؛ مؤلفه **تحلیل**[۱۷] وضعیت پایش‌شده را با اهداف کیفی تطبیق داده و در صورت نقض یا خطر نقض آستانه‌ها، فرآیند انطباق را فعال می‌سازد؛ بخش **برنامه‌ریزی**[۱۸] به عنوان مغز متفکر سیستم، فضای وفقی را ارزیابی کرده و سیاستی بهینه برای گذار به وضعیت مطلوب طراحی می‌کند؛ مؤلفه **اجرا**[۱۹] طرح تولیدشده را به دستورات قابل فهم برای سخت‌افزار تبدیل نموده و از طریق عملگرها اعمال می‌نماید؛ و سرانجام مؤلفه **دانش**[۲۰] به عنوان حافظه مشترک و مخزن داده مرکزی، مدل‌های زمان اجرا، تاریخچه رفتار، توپولوژی شبکه و اهداف کیفی را جهت فعالیت هماهنگ سایر مؤلفه‌ها نگهداری می‌کند.

با پیچیده‌تر شدن سیستم‌های توزیع‌شده مدرن، الگوهای پیشرفته‌تری از حلقه‌های بازخورد توسعه یافته‌اند؛ از جمله حلقه‌های بازخورد توزیع‌شده و چندعامله[۲۱] [۲۱، ۲۲] که در آن‌ها چندین حلقه محلی از طریق الگوهایی نظیر Coordinated، Master-Slave یا Peer-to-Peer با یکدیگر تعامل دارند. این رویکردهای پیشرفته به ویژه در مدیریت شبکه‌های حسگر بی‌سیم وسیع که فاقد کنترل مرکزی مطلق هستند، بسیار حائز اهمیت می‌باشند [۲۱، ۲۲].

[13] Change Management Layer
[14] Component Control Layer
[15] Monitor, Analyze, Plan, Execute over Shared Knowledge
[16] Monitor Component
[17] Analyze Component
[18] Plan Component
[19] Execute Component
[20] Knowledge Component
[21] Decentralized MAPE-K Loops

۲-۳ عدم قطعیت در سیستم‌های خودوفق

۲-۳-۱ دسته‌بندی و انواع عدم قطعیت

عدم قطعیت در مهندسی نرم‌افزار خودوفق به هرگونه کاستی در اطلاعات، نویز داده‌ها یا ماهیت پیش‌بینی‌ناپذیر پارامترهای زمان اجرا اطلاق می‌شود که بر صحت تصمیمات سیستم اثر منفی می‌گذارد [۴]. بر اساس روش‌شناسی‌های معتبر مهندسی، عدم قطعیت در چهار لایه کلیدی طبقه‌بندی می‌شود: نخست، **عدم قطعیت محیطی**[۲۲] که ناشی از پارامترهای خارج از مرز سیستم نظیر تغییرات جوی، تلاطم باد یا نوسانات سیگنال به نویز در کانال بی‌سیم است؛ دوم، **عدم قطعیت سیستمی**[۲۳] که از پویایی درونی خود سیستم نظیر افت ولتاژ باتری، فرسودگی سخت‌افزاری یا تراکم صفوف ناشی می‌شود؛ سوم، **عدم قطعیت اهداف**[۲۴] که ناشی از تغییر اولویت‌ها، اوزان کیفی یا آستانه‌های تعریف‌شده توسط ذینفعان در طول زمان است؛ و چهارم، **عدم قطعیت شکاف واقعیت** که در سیستم‌های فیزیکی‌ـ‌سایبری بلادرنگ پدیدار می‌شود، چرا که تصمیم‌گیری بر پایه مدل‌های جانشین تحلیلی صورت می‌گیرد اما به علت خطای کالیبراسیون ذاتی ($\Delta_{\text{gap}} \leq \epsilon_k$) در مواجهه با دینامیک‌های غیرخطی پرواز و آشفتگی‌ها، سپرهای ایمنی سنتی دچار شکست در پرواز فیزیکی می‌شوند.

۲-۳-۲ روش‌های مدل‌سازی و رویارویی با عدم قطعیت

برای رویارویی موثر با عدم قطعیت در زمان اجرا، سیستم‌های خودوفق ناگزیرند رفتارهای احتمالی سیستم را مدل‌سازی کنند. در این حوزه، دو رهیافت و روش‌شناسی ریاضی و مهندسی پرکاربرد مطرح است: رهیافت نخست، **وارسی مدل آماری زمان اجرا (SMC)**[۲۵] با ابزارهایی نظیر UPPAAL-SMC[۲۶] است که با استفاده از مدل‌های اتوماتای زمان‌دار احتمالی و شبیه‌سازی‌های آماری مونت‌کارلو در زمان اجرا، احتمال نقض اهداف کیفی را با فواصل اطمینان مشخص برآورد می‌کند [۲۳]؛ و رهیافت دوم، **مدل‌های تصمیم‌گیری احتمالی** نظیر POMDP در برابر MDP است که فرآیند تصمیم‌گیری مارکوف بخشاً مشاهده‌پذیر[۲۷] با مفهوم حالت باور[۲۸] را به کار می‌گیرد. هرچند POMDP از نظر ریاضی جامع است، اما به دلیل پیچیدگی سرسام‌آور محاسباتی در زمان اجرای سیستم‌های بزرگ عملاً غیرقابل حل است؛ از این رو، این رساله با بهره‌گیری از هسته تقریب‌گر عصبی عمیق، از فرمول‌بندی MDP استاندارد همراه با سازوکارهای بازیابی تجربیات شکست‌خورده برای فائق آمدن بر این چالش استفاده می‌کند.

---

[22] Environmental Uncertainty

[23] Systemic Uncertainty

[24] Goal Uncertainty

[25] Runtime Statistical Model Checking

[۲۶] ابزار بررسی مدل آماری UPPAAL-SMC: https://uppaal.org/

[27] Partially Observable Markov Decision Process (POMDP)

[28] Belief State

۲-۳-۳ چالش‌های خاص عدم قطعیت در فضاهای وفقی بزرگ

هنگامی‌که سیستم خودوفق با یک فضای وفقی مقیاس‌وسیع (با ابعاد بیش از هزاران پیکربندی ممکن) روبه‌رو می‌شود، عدم قطعیت زمان اجرا منجر به بروز سه چالش اساسی می‌گردد: نخست، **انفجار ترکیبی گزینه‌ها**[۲۹] که ارزیابی جامع تک‌تک پیکربندی‌ها با مدل‌های صوری یا آماری را ناممکن می‌سازد؛ دوم، **تنگنای زمان تصمیم‌گیری**[۳۰] که ایجاب می‌کند تحلیل و برنامه‌ریزی در کسری از ثانیه انجام شود تا سیستم با پدیده تصمیمات منقضی‌شده مواجه نگردد؛ و سوم، **افتادن در دام بهینه‌های محلی**[۳۱] که در آن به دلیل ماهیت غیرایستای محیط، سیاست وفقی سیستم به سرعت در یک پیکربندی نیمه‌بهینه قفل شده و کاوشگری سنتی توان خروج از آن را ندارد.

رانش مفهومی و اثر ریاضی غیرایستایی: در سیستم‌های خودوفق صنعتی بلادرنگ، عدم قطعیت‌ها صرفاً نویزهای فرکانس‌بالا نیستند، بلکه محیط دستخوش تغییرات توزیعی ریشه‌ای یا همان رانش مفهومی[۳۲] می‌شود. به بیان صوری ریاضی، پویایی احتمالی انتقال حالت (P_t) و تابع پاداش (R_t) دیگر در طول زمان ثابت نبوده و با متغیر زمان t دچار تغییر می‌شوند:

$$P_t(s' \mid s, a) \neq P_{t+k}(s' \mid s, a)$$

$$R_t(s, a, s') \neq R_{t+k}(s, a, s')$$

که در آن $P_t(s' \mid s, a)$ نشان‌دهنده تابع احتمال انتقال حالت (احتمال انتقال به حالت s' پس از اتخاذ عمل a در حالت s) در زمان t است و $R_t(s, a, s')$ نشان‌دهنده تابع پاداش آنی در همان زمان می‌باشد.

این عدم ایستایی، فرض بنیادین فرآیند تصمیم‌گیری مارکوف را نقض می‌کند. در شبکه‌های DQN کلاسیک، این پدیده منجر به **فراموشی فاجعه‌بار**[۳۳] می‌شود؛ شبکه عصبی عمیق وزن‌های خود را برای شرایط جاری بهینه‌سازی می‌کند، اما به محض تغییر فصل یا بار شبکه، سیاست‌های پیشین کاملاً پاک شده و سیستم با افت شدید کیفیت مواجه می‌گردد. سازوکار نوآورانه شکل‌دهی تصادفی پاداش با احتمال ρ در این رساله، با تزریق مستمر نوسان‌های خوش‌بینانه در لایه بازپخش تجربیات، مانع از تثبیت و انجماد وزن‌های شبکه عصبی در یک نقطه خاص شده و عملاً به عنوان یک منظم‌ساز[۳۴] پویا در برابر رانش مفهومی عمل می‌کند.

[29] Combinatorial Explosion
[30] Scale-Latency Dilemma
[31] Local Optima Traps
[32] Concept Drift
[33] Catastrophic Forgetting
[34] Regularizer

۲-۴ مبانی نظری و مدل‌سازی ریاضی

در این بخش، زیربنای ریاضی استاندارد برای مدل‌سازی تصمیم‌گیری ترتیبی، سازوکارهای یادگیری تقویتی و شبکه‌های عصبی عمیق تشریح می‌گردد. این مبانی، بستر صوری لازم را برای فرمول‌بندی مسائل وفقی در سیستم‌های نرم‌افزاری و سیستم‌های فیزیکی–سایبری فراهم می‌سازند.

۲-۴-۱ فرآیندهای تصمیم‌گیری مارکوف و مدل‌سازی ریاضی تصمیم‌گیری ترتیبی

فرآیندهای تصمیم‌گیری مارکوف: فرآیند تصمیم‌گیری مارکوف چارچوب ریاضی استاندارد و بی‌بدیلی را برای مدل‌سازی تصمیم‌گیری‌های متوالی عامل هوشمند در محیط‌های پویا و احتمالی ارائه می‌دهد [۵]. به صورت صوری، یک MDP پنج‌گانه به صورت زیر تعریف می‌شود:

$$\mathcal{M} = (S, A, P, R, \gamma)$$

که در آن مولفه‌ها عبارتند از:

- S: فضای حالت‌های سیستم که وضعیت جاری را توصیف می‌کند.
- A: فضای عمل‌ها که در سیستم‌های خودوفق، همان گزینه‌های وفقی زمان اجرا هستند.
- $P : S \times A \times S \to [۰, ۱]$: تابع احتمال انتقال که احتمال رفتن از حالت s به حالت s' با انجام عمل a را مشخص می‌سازد:

$$P(s' \mid s, a) = \mathbb{P}(S_{t+۱} = s' \mid S_t = s, A_t = a)$$

- $R : S \times A \times S \to \mathbb{R}$: تابع پاداش که پاداش آنی حاصل از انجام عمل a در حالت s و انتقال به s' را تعیین می‌کند.
- $\gamma \in [۰, ۱)$: ضریب تنزیل که ارزش پاداش‌های آتی را نسبت به پاداش لحظه‌ای مشخص می‌سازد.

هدف اصلی در یک MDP، یافتن یک سیاست وفقی بهینه $\pi(a \mid s)$ است که ارزش پاداش‌های تجمعی تنزیل‌یافته آتی را بیشینه سازد. معادله معروف بلمن[۳۵] برای تابع ارزش حالت $V^{\pi}(s)$ به صورت زیر فرمول‌بندی می‌شود [۶]:

$$V^{\pi}(s) = \sum_{a \in A} \pi(a \mid s) \sum_{s' \in S} P(s' \mid s, a) \left[R(s, a, s') + \gamma V^{\pi}(s') \right]$$

[35] Bellman Expectation Equation (Richard E. Bellman)

همچنین، معادله بهینگی بلمن[۳۶] برای تابع ارزش عمل‌ـحالت $Q^*(s,a)$ که ارزش اتخاذ اقدام a در حالت s تحت سیاست بهینه را برآورد می‌کند، به صورت زیر بیان می‌گردد:

$$Q^*(s,a) = \sum_{s' \in S} P(s' \mid s,a) \left[R(s,a,s') + \gamma \max_{a'} Q^*(s',a') \right]$$

یک مثال ریاضی ملموس از فرآیند تصمیم‌گیری مارکوف: برای شفاف‌سازی نحوه انتشار ارزش‌ها در یک MDP، مثال ساده زیر را بررسی می‌کنیم. این مثال پایه درک نحوه آموزش عامل در فصل‌های بعدی را فراهم می‌سازد. در این راستا، جهت شفاف‌سازی فرآیند محاسباتی، یک مدل نمونه با ۲ حالت و ۲ عمل متناظر را تحلیل می‌کنیم:

- **حالت‌ها:** $S = \{s_۰, s_۱\}$ که در آن $s_۰$ نشان‌دهنده وضعیت عادی شبکه (بدون ترافیک و تداخل) و $s_۱$ نشان‌دهنده وضعیت اشباع شبکه (حضور تداخل جوی شدید) است.
- **عمل‌ها:** $A = \{a_۰, a_۱\}$ که در آن $a_۰$ نشان‌دهنده سطح توان ارسال کم (بهینه از نظر مصرف انرژی) و $a_۱$ نشان‌دهنده سطح توان ارسال زیاد (مقاوم در برابر نویز) می‌باشد.

پویایی احتمالی انتقال حالت (P) و مقادیر پاداش‌ها (R) در این محیط به صورت زیر پیکربندی شده است:

۱. **در حالت عادی ($s_۰$):**

- با انتخاب توان کم ($a_۰$): با احتمال ۰/۸ سیستم در $s_۰$ باقی مانده و با احتمال ۰/۲ به دلیل نویز اتفاقی به $s_۱$ می‌رود. پاداش آنی برابر با $R(s_۰, a_۰) = ۱/۰$ (حداکثر بازده) است.
- با انتخاب توان زیاد ($a_۱$): با احتمال ۰/۹۵ سیستم در $s_۰$ مانده و با احتمال ۰/۰۵ به $s_۱$ منتقل می‌شود. پاداش آنی به دلیل هدررفت انرژی برابر با $R(s_۰, a_۱) = ۰/۶$ است.

۲. **در حالت اشباع ($s_۱$):**

- با انتخاب توان کم ($a_۰$): به دلیل ضعف سیگنال، احتمال بهبود اندک بوده و با احتمال ۰/۳ به $s_۰$ برگشته و با احتمال ۰/۷ در $s_۱$ می‌ماند. پاداش آنی به دلیل اتلاف پیام‌ها برابر با $R(s_۱, a_۰) = ۰/۱$ است.
- با انتخاب توان زیاد ($a_۱$): با احتمال ۰/۸۵ شبکه با غلبه بر نویز به حالت عادی $s_۰$ بازمی‌گردد و با احتمال ۰/۱۵ در $s_۱$ باقی می‌ماند. پاداش آنی به دلیل تعادل میان پایداری و انرژی برابر با $R(s_۱, a_۱) = ۰/۵$ است.

[36] Bellman Optimality Equation

فرضیات بالا را برای ارزیابی یک سیاست معین π در نظر می‌گیریم؛ سیاستی که همواره در حالت عادی گزینه کم‌مصرف را انتخاب کرده ($\pi(a_۰ \mid s_۰) = ۱/۰$) و در حالت نویزی بلافاصله توان را افزایش می‌دهد ($\pi(a_۱ \mid s_۱) = ۱/۰$). با در نظر گرفتن ضریب تنزیل زمان‌دار $\gamma = ۰/۹$، معادلات بلمن به شکل دستگاه معادلات خطی زیر بازنویسی می‌شوند:

$$V^\pi(s_۰) = R(s_۰, a_۰) + \gamma \left[P(s_۰ \mid s_۰, a_۰)V^\pi(s_۰) + P(s_۱ \mid s_۰, a_۰)V^\pi(s_۱)\right]$$

$$V^\pi(s_۱) = R(s_۱, a_۱) + \gamma \left[P(s_۰ \mid s_۱, a_۱)V^\pi(s_۰) + P(s_۱ \mid s_۱, a_۱)V^\pi(s_۱)\right]$$

با جایگذاری مقادیر احتمالی و عددی در معادلات فوق، خواهیم داشت:

$$\begin{aligned} V^\pi(s_۰) &= ۱/۰ + ۰/۹ \left[۰/۸V^\pi(s_۰) + ۰/۲V^\pi(s_۱)\right] \\ &\implies V^\pi(s_۰) = ۱/۰ + ۰/۷۲V^\pi(s_۰) + ۰/۱۸V^\pi(s_۱) \end{aligned}$$

$$\begin{aligned} V^\pi(s_۱) &= ۰/۵ + ۰/۹ \left[۰/۸۵V^\pi(s_۰) + ۰/۱۵V^\pi(s_۱)\right] \\ &\implies V^\pi(s_۱) = ۰/۵ + ۰/۷۶۵V^\pi(s_۰) + ۰/۱۳۵V^\pi(s_۱) \end{aligned}$$

برای حل این دستگاه خطی، ابتدا معادله اول را بر حسب $V^\pi(s_۱)$ ساده می‌کنیم:

$$\begin{aligned} (۱ - ۰/۷۲)V^\pi(s_۰) &= ۱/۰ + ۰/۱۸V^\pi(s_۱) \\ \implies ۰/۲۸V^\pi(s_۰) &= ۱/۰ + ۰/۱۸V^\pi(s_۱) \\ \implies V^\pi(s_۰) &\approx ۳/۵۷۱۴ + ۰/۶۴۲۸V^\pi(s_۱) \end{aligned}$$

با جایگذاری این تساوی در معادله دوم، مقدار ارزش حالت اشباع حاصل می‌شود:

$$(۱ - ۰/۱۳۵)V^\pi(s_۱) = ۰/۵ + ۰/۷۶۵ \left(۳/۵۷۱۴ + ۰/۶۴۲۸V^\pi(s_۱)\right)$$

$$۰/۸۶۵V^\pi(s_۱) \approx ۰/۵ + ۲/۷۳۲۱ + ۰/۴۹۱۷V^\pi(s_۱)$$

$$۰/۳۷۳۳V^\pi(s_۱) \approx ۳/۲۳۲۱ \implies V^\pi(s_۱) \approx ۸/۶۵۸۲$$

سرانجام، با جایگذاری مجدد در تساوی اول، مقدار ارزش حالت عادی به دست می‌آید:

$$V^\pi(s_۰) \approx ۳/۵۷۱۴ + ۰/۶۴۲۸ \times ۸/۶۵۸۲ \approx ۹/۱۳۶۹$$

این ارقام به طور دقیق نشان می‌دهند که چگونه عامل یادگیرنده با انتخاب‌های هوشمندانه و تغییر پویا سیاست‌ها تحت تنزیل آتی پاداش‌ها، ارزش بلندمدت بسیار بالاتری را کسب می‌کند (ارزش حالت عادی ۹/۱۳ در مقایسه با پاداش آنی لحظه‌ای ۱/۰).

۲-۴-۲ یادگیری تقویتی عمیق و سازوکار شبکه‌های کیو عمیق DQN

یادگیری تقویتی و الگوریتم‌های جدول‌محور: یادگیری تقویتی[۳۷] به عامل هوشمند امکان می‌دهد تا بدون نیاز به دانش صریح از پویایی‌های احتمالی محیط (یعنی بدون داشتن فرمول صریح تابع انتقال P و تابع پاداش R) و صرفاً از طریق تعامل فعال (آزمون و خطا) سیاست بهینه را یاد بگیرد [۶].

در روش‌های جدول‌محور چون **یادگیری Q**[۳۸] [۲۴] که یک الگوریتم فراسیاستی[۳۹] است، مقادیر ارزش عمل‌ـحالت به طور مداوم درون یک جدول جامع به‌روزرسانی می‌شوند:

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[r + \gamma \max_{a'} Q(s',a') - Q(s,a) \right]$$

که در آن $\alpha \in (۰, ۱]$ نرخ یادگیری است. در مقابل، الگوریتم‌های درون‌سیاستی[۴۰] مانند **SARSA**[۴۱] [۲۵]، ارزش عمل بعدی را بر اساس سیاست جاری و عملی که واقعاً اتخاذ شده به‌روزرسانی می‌کنند.

هرچند الگوریتم‌های جدول‌محور و برنامه‌ریزی پویا[۴۲] تضمین همگرایی ریاضی دارند، اما به دلیل نیاز به حافظه بی‌پایان جهت نگهداری جداول بزرگ، در مسائلی که با انفجار فضای حالت و عمل روبه‌رو هستند کاملاً ناکارآمد بوده و با چالش **نفرین ابعاد**[۴۳] مواجه می‌گردند.

مقایسه ساختاری الگوریتم‌های یادگیری Q و SARSA: جهت تبیین دقیق تفاوت‌های منطقی میان دو الگوریتم پایه‌ای یادگیری تقویتی جدول‌محور، جدول ۲-۱ معیارهای ساختاری، ایمنی و هزینه محاسباتی هرکدام را به تفصیل مقایسه کرده است [۶]. این تحلیل روشن می‌سازد که چرا رویکردهای مبتنی بر یادگیری Q (نظیر DQN مورد استفاده در این رساله) برای سیستم‌های خودوفق ترجیح داده می‌شوند.

یادگیری تقویتی عمیق و سازوکارهای تثبیت: برای غلبه بر نفرین ابعاد در محیط‌های مقیاس‌بزرگ، الگوریتم شبکه Q عمیق DQN معرفی شد که تابع ارزش Q را با استفاده از یک شبکه‌ی عصبی عمیق با پارامترهای θ تقریب می‌زند: $Q(s,a) \approx Q(s,a;\theta)$ [۱۵]. پارامترهای این شبکه از طریق به حداقل رساندن تابع هزینه

[37] Reinforcement Learning (RL)
[38] Q-learning (Christopher J. C. H. Watkins and Peter Dayan, 1992)
[39] Off-Policy Reinforcement Learning
[40] On-Policy Reinforcement Learning
[41] State-Action-Reward-State-Action
[42] Dynamic Programming
[43] Curse of Dimensionality (Richard E. Bellman)

جدول ۲-۱: مقایسه تطبیقی الگوریتم‌های جدول‌محور Q-Learning و SARSA

معیار مقایسه	یادگیری Q (Q-Learning)	الگوریتم SARSA
نوع سیاست	فراسیاستی (Off-Policy): به‌روزرسانی بر اساس فرضیه اقدام بهینه آتی صورت می‌گیرد.	درون‌سیاستی (On-Policy): به‌روزرسانی بر اساس اقدامی‌که واقعاً توسط سیاست اتخاذ شده، انجام می‌شود.
فرمول به‌روزرسانی	$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$	$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma Q(s',a') - Q(s,a)]$
سرعت همگرایی	سریع‌تر؛ به دلیل استفاده مستقیم از عملگر بیشینه‌سازی در هدف تفاوت زمانی.	کندتر؛ همگرایی وابسته به اصلاح تدریجی کل بدنه سیاست است.
ایمنی حین یادگیری	ریسک بالا؛ ممکن است رفتارهای متهورانه و آسیب‌زا جهت کشف مسیر بهینه اتخاذ کند.	ایمن‌تر؛ با پرهیز از اقدامات بهینه تهاجمی، از سیاست جاریِ محافظه‌کارانه تبعیت می‌کند.
تعمیم‌پذیری عصبی	بسیار بالا؛ پایه اصلی توسعه الگوریتم‌های عمیق بدون مدل نظیر DQN است.	متوسط؛ در ابعاد عمیق نیازمند معماری‌های تثبیت بسیار سنگین‌تری است.

لایه‌ای در هر گام آموزش به‌روزرسانی می‌شوند:

$$L(\theta_i) = \mathbb{E}_{(s,a,r,s')\sim\mathcal{D}}\left[\left(r + \gamma \max_{a'} Q(s',a';\theta_i^-) - Q(s,a;\theta_i)\right)^2\right]$$

برای تضمین پایداری و جلوگیری از واگرایی فرآیند آموزش شبکه‌های عصبی در محیط‌های یادگیری تقویتی، دو نوآوری کلیدی در DQN اعمال می‌گردد. نوآوری نخست، **حافظه بازپخش تجربه** ($\mathcal{D}$)[44] است که طی آن، عامل تجربیات خود را در قالب انتقال‌های (s,a,r,s') درون یک بافر ذخیره می‌کند و در طول فاز آموزش، به جای استفاده از تجربیات متوالی که دارای همبستگی شدید زمانی هستند، دسته‌های کوچکی از داده‌ها به صورت تصادفی و با توزیع یکنواخت از بافر نمونه‌برداری می‌شوند. این سازوکار فرضیه داده‌های مستقل و توزیع‌شده به طور یکسان[45] را احیا کرده و پایداری بهینه‌سازی را تضمین می‌کند. نوآوری دوم، **شبکه هدف ثابت** (θ^-)[46] است که در آن، محاسبه هدف بلمن به یک شبکه عصبی موازی با پارامترهای مستقل θ^- سپرده می‌شود؛ به طوری که وزن‌های این شبکه به جای هر گام، در بازه‌های زمانی مشخصی از شبکه اصلی کپی می‌شوند تا از نوسان‌های شدید و واگرایی تابع ارزش جلوگیری گردد.

در این میان، نمونه‌برداری تصادفی با توزیع یکنواخت از بافر بازپخش تجربیات، متکی بر فرض وفور داده‌های پاداش است؛ در حالی که در محیط‌های خودوفق با پاداش‌های تنک یا سیستم‌های فیزیکی‌ـ سایبری با غلبه شدید داده‌های شکست (بیش از ۹۰٪ داده‌های ناموفق در لاگ‌ها)، نمونه‌برداری بدون هدایت دچار رکود یادگیری یا فراموشی فاجعه‌بار می‌گردد. این چالش نظری، انگیزه محوری ابداع سازوکارهای شکل‌دهی پاداش تصادفی RS-DRL و سنتز آفلاین هدایت‌شده با مشخصه (SG-OS) در فصول ۳ و ۴ خواهد بود.

در این بخش، چارچوب ریاضی تصمیم‌گیری تحت عدم قطعیت شامل فرآیندهای تصمیم‌گیری مارکوف،

[44] Experience Replay Memory

[45] Independent and Identically Distributed (i.i.d.)

[46] Fixed Target Network

مفاهیم یادگیری تقویتی و شبکه Q عمیق تشریح گردید. در بخش‌های بعدی، این مفاهیم پایه‌ای را بر روی دو سیستم مورد مطالعه و محک شاخص رساله، یعنی شبکه حسگر DeltaIoT و شبیه‌ساز مأموریت ناوگان پهپادی DARTSim، پیاده‌سازی و فرمول‌بندی خواهیم کرد.

۲-۵ سیستم مورد مطالعه: شبکه‌های حسگر بی‌سیم DeltaIoT

۲-۵-۱ معماری، مؤلفه‌ها و ویژگی‌های فیزیکی

بستر DeltaIoT یک شبکه‌ی حسگر بی‌سیم صنعتی با کیفیت خدمات نرم است که برای ارزیابی رفتارهای خودوفق‌سازی تحت شرایط نویزی شدید و پویای محیطی به کار گرفته می‌شود. معماری این بستر از سه مؤلفه‌ی اصلی تشکیل شده است:

- **گره‌های حسگر:**[۴۷] این گره‌ها وظیفه پایش محیط و تولید اطلاعات را بر عهده دارند. حسگرها پیام‌های تولیدی خود را به صورت چندگامی[۴۸] از طریق گره‌های واسط به سمت دروازه مرکزی ارسال می‌کنند.
- **دروازه مرکزی:**[۴۹] مقصد نهایی تمامی پیام‌های شبکه است که وظیفه جمع‌آوری داده‌ها، تحلیل کیفیت شبکه و پایش کیفیت خدمات را بر عهده دارد. کنترل‌کننده خودمختار ما بر پایه حلقه بازخورد MAPE-K بر روی این دروازه مستقر شده و گزینه‌های وفقی را ارزیابی و اعمال می‌نماید.
- **پیوندهای ارتباطی بی‌سیم:**[۵۰] مسیرهای ارتباطی میان گره‌ها هستند که به صورت گسسته پیکربندی شده و کیفیت انتقال سیگنال بر روی آن‌ها تحت تاثیر شدید پارامترهای محیطی و تداخل احتمالی فرکانسی قرار دارد.

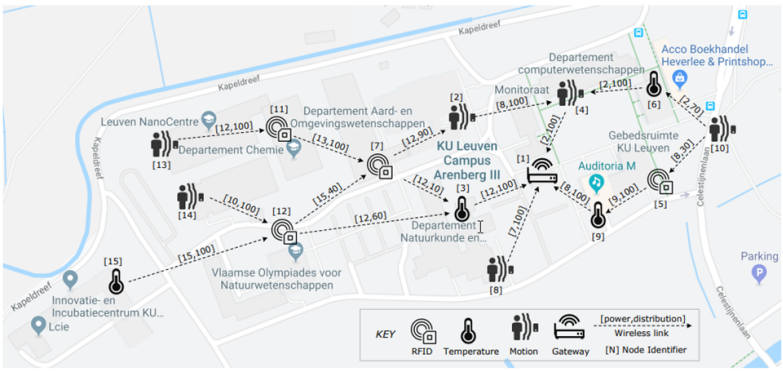
شکل ۲-۱ توپولوژی و ساختار پیوندهای ارتباطی در شبکه حسگر بی‌سیم DeltaIoTv1 را نشان می‌دهد که در آن سنسورها پیام‌های خود را به صورت چندگامی به سمت دروازه مرکزی ارسال می‌کنند.

۲-۵-۲ مدل‌سازی فیزیکی و ریاضیاتی پدیده‌های کانال بی‌سیم

ارتباط میان گره‌ها در بستر DeltaIoT بر پایه مدل‌سازی احتمالی کانال انتقال بی‌سیم انجام می‌شود. نسبت سیگنال به نویز (SNR)[۵۱] برای هر پیوند ارتباطی بی‌سیم $e = (u, v)$ از رابطه‌ی زیر به دست می‌آید:

$$\mathrm{SNR}_e(t) = P_{tx}(u) - \mathrm{PL}(e) - X_\sigma - \eta(t) \qquad (۱-۲)$$

[47] Sensor Nodes
[48] Multi-hop Routing
[49] Gateway
[50] Wireless Links
[51] Signal-to-Noise Ratio



شکل ۲-۱: توپولوژی و ساختار پیوندهای ارتباطی شبکه حسگر بی‌سیم DeltaIoTv1 [۲۶].

که در آن $P_{tx}(u)$ توان ارسال گره فرستنده u (تنظیم‌شده در بازه گسسته $[۰, ۱۵]$ میلی‌وات)، $\mathrm{PL}(e)$ افت مسیر کانال بی‌سیم[۵۲]، X_σ متغیر تصادفی نرمال با توزیع احتمالی لگاریتمی‌ـ‌نرمال[۵۳] برای بازنمایی اثر موانع فیزیکی، و $\eta(t)$ نویز و تداخل‌های فرکانسی متغیر با زمان در چرخه t است.

نرخ تحویل بسته (PDR)[۵۴] بر روی هر پیوند ارتباطی e بر اساس نسبت سیگنال به نویز به صورت یک تابع سیگموئید غیرخطی و احتمالی فرموله می‌گردد:

$$\mathrm{PDR}_e(t) = \frac{۱}{۱ + e^{-\alpha(\mathrm{SNR}_e(t) - \beta)}} \qquad (۲-۲)$$

که در آن α و β پارامترهای کالیبراسیون سخت‌افزاری فرستنده بی‌سیم بر اساس استاندارد IEEE 802.15.4[۵۵] هستند.

۲-۵-۳ جزئیات فرمول‌بندی معیارهای کیفیت خدمات در فضای حالت

فضای حالت مسئله $S = (E, P, L)$ از سه مولفه‌ی کلیدی کیفیت خدمات تشکیل شده است که نحوه محاسبه دقیق ریاضی هر یک به شرح زیر است:

۱. **مصرف انرژی کل شبکه (E):** مصرف انرژی کل در هر چرخه وقفی t برابر با مجموع انرژی مصرفی تمامی گره‌های شبکه است:

$$E(t) = \sum_{v \in V} E_v(t) \qquad (۳-۲)$$

[52] Path Loss
[53] Log-Normal Shadowing
[54] Packet Delivery Ratio
[55] IEEE 802.15.4 Low-Rate Wireless Personal Area Networks

مصرف انرژی گره v حاصل‌جمع انرژی مصرفی در فازهای ارسال، دریافت و گوش دادن فعال است:

$$E_v(t) = N_{sent}(v) \cdot E_{tx}(p_v) + N_{recv}(v) \cdot E_{rx} + T_{listen}(v) \cdot E_{listen} \qquad (۴-۲)$$

که در آن $N_{sent}(v)$ تعداد بسته‌های ارسال‌شده توسط گره v با سطح توان p_v، $E_{tx}(p_v)$ انرژی مصرفی برای ارسال با سطح توان مشخص، $N_{recv}(v)$ تعداد بسته‌های دریافت‌شده، E_{rx} انرژی فاز گیرندگی، $T_{listen}(v)$ مدت‌زمان گوش‌دادن فعال به کانال و E_{listen} توان مصرفی گره در حالت استماع است.

۲. **نرخ اتلاف کل بسته‌ها (P):** این معیار نشان‌دهنده درصدی از پیام‌های شبکه است که در طول مسیر انتقال به گیت‌وی به دلیل خطاهای کانال یا پر شدن بافر گره‌ها از بین رفته‌اند:

$$P(t) = \left(۱ - \frac{N_{delivered}(t)}{N_{generated}(t)}\right) \times ۱۰۰ \qquad (۵-۲)$$

که در آن $N_{generated}(t)$ کل بسته‌های تولیدشده توسط تمامی حسگرها در چرخه t، و $N_{delivered}(t)$ تعداد بسته‌هایی است که با موفقیت توسط دروازه مرکزی دریافت شده‌اند. احتمال اتلاف بسته در طول یک مسیر چندگامی $\mathcal{P} = (v_۱, v_۲, \ldots, v_k)$ که به گیت‌وی منتهی می‌شود، برابر است با:

$$P_{loss}(\mathcal{P}) = ۱ - \prod_{i=۱}^{k-۱} \mathrm{PDR}_{(v_i, v_{i+۱})}(t) \qquad (۶-۲)$$

۳. **متوسط تاخیر زمان انتقال پیام‌ها (L):** متوسط زمان مورد نیاز برای رسیدن یک بسته از زمان تولید در سنسور مبدا تا تحویل به دروازه است. با توجه به ساختار اسلات‌بندی شده شبکه (TDMA)[۵۶]، تاخیر هر بسته بر اساس تعداد گام‌ها و اسلات‌های تخصیص‌یافته در چرخه زمان‌بندی محاسبه می‌شود:

$$L(t) = \frac{۱}{N_{delivered}(t)} \sum_{p \in \mathrm{Delivered}} T_{arrival}(p) - T_{generation}(p) \qquad (۷-۲)$$

که در آن $T_{generation}(p)$ زمان تولید پیام p در حسگر مبدا و $T_{arrival}(p)$ زمان دقیق ورود آن پیام به دروازه مرکزی است.

ارتباطات در DeltaIoT بر پایه استاندارد Time-Slotted Channel Bonding سازماندهی شده است؛ به طوری که زمان به چرخه‌های متوالی تقسیم شده و هر سنسور در اسلات‌های زمانی مشخصی مجاز به ارسال اطلاعات است.

[56] Time Division Multiple Access

۲-۵-۴ سناریوهای عدم قطعیت و فضای وفقی

شبکه DeltaIoT با دو چالش اصلی عدم قطعیت زمان اجرا مواجه است که پایداری عملیاتی آن را تهدید می‌کند. چالش نخست **تداخل و نویز شبکه**[۵۷] است؛ عوامل محیطی نوسانات ناگهانی در نسبت سیگنال به نویز ایجاد می‌کنند که مستقیماً نرخ اتلاف بسته‌ها را افزایش می‌دهد. چالش دوم **تغییرات بار پیام‌ها**[۵۸] است؛ بسته به رخدادهای محیطی، تعداد پیام‌های تولیدی در هر سنسور نوسان شدیدی پیدا می‌کند که موجب پر شدن بافرها و ایجاد تاخیر یا اتلاف داده می‌گردد.

ابعاد فضای وفقی در سه نسخه استاندارد DeltaIoT بر اساس تعداد گره‌ها و اتصالات شبکه‌ای تغییر می‌کند [۲۷]: نسخه پایه DeltaIoTv1 با ۱۵ سنسور، فضایی به ابعاد ۲۱۶ گزینه ممکن را ایجاد می‌کند؛ نسخه میانی DeltaIoTv1.1 با ۱۶ سنسور به ۱۲۹۶ گزینه متمایز گسترش می‌یابد؛ و نهایتاً نسخه بزرگ‌مقیاس DeltaIoTv2 با ۳۷ سنسور، فضایی عظیم با ۴۰۹۶ تصمیم ممکن پدید می‌آورد.

هر گزینه وفقی در حقیقت ترکیبی از تخصیص توان انتقال انرژی به سنسورها (از سطح ۰ تا ۱۵) و تخصیص نسبی مسیرهای شبکه‌ای جهت هدایت بسته‌ها به گیت‌وی است.

۲-۵-۵ فرمول‌بندی به عنوان MDP

برای به کارگیری یادگیری تقویتی عمیق، مسئله انطباق شبکه DeltaIoT را به صورت یک فرآیند تصمیم‌گیری مارکوف فرمول‌بندی می‌کنیم:

تعریف فضای حالت (S): حالت سیستم در هر چرخه وفقی بازتاب‌دهنده عملکرد پویا و مصرف انرژی شبکه است:

$$S = \{(E, P, L) \mid E \in \mathbb{R}^+, P \in [۰, ۱۰۰], L \in [۰, ۱۰۰]\}$$

که در آن:

- E: مقدار حقیقی نشان‌دهنده انرژی کل مصرف‌شده توسط تمام سنسورهای شبکه در چرخه قبلی.
- P: درصدی از پیام‌ها که به مقصد نرسیده‌اند (نرخ اتلاف کل بسته‌ها).
- L: متوسط تاخیر ارسال پیام‌ها از سنسورها به گیت‌وی.

تعریف فضای عمل (A): فضای عمل عامل، مجموعه‌ای گسسته از تمامی‌پیکربندی‌های شبکه است:

$$A = \{a_۱, a_۲, \ldots, a_n\}$$

[57] Network Interference

[58] Traffic Fluctuations

که مقدار n بر اساس نسخه شبکه برابر با ۲۱۶، ۱۲۹۶ یا ۴۰۹۶ است. هر عمل a_i یک نگاشت کامل از توان‌های ارسال و مسیرهای توزیع برای تمامی‌گره‌ها می‌باشد.

فرمول‌بندی توابع پاداش (R): بسته به سناریوی ارزیابی، سه فرمول‌بندی پاداش تعریف می‌شود:

۱. **پاداش چندهدفه (مبتنی بر پارتو):**

$$R = w_E \cdot \left(\frac{E_{max} - E}{E_{max} - E_{min}}\right) + w_P \cdot \left(\frac{P_{max} - P}{P_{max} - P_{min}}\right) + w_L \cdot \left(\frac{L_{max} - L}{L_{max} - L_{min}}\right)$$

که در آن وزن‌ها مثبت بوده و مجموع آن‌ها برابر یک است: $\sum w_i = ۱$.

۲. **پاداش تک‌هدفه (کاهش مصرف انرژی):**

$$R = \left(\frac{E_{max} - E}{E_{max} - E_{min}}\right) \cdot w_E \quad (\text{with} w_E = ۱)$$

۳. **پاداش اهداف آستانه‌ای (TT):**[۵۹]

$$R = \begin{cases} ۱ & \text{اگر } P < \theta_P \text{ و } L < \theta_L \\ ۰ & \text{در غیر این صورت} \end{cases}$$

که در آن θ_P و θ_L آستانه‌های پذیرش کیفی خدمات سیستم هستند.

۲-۶ فرمول‌بندی مسئله بهینه‌سازی انطباق و تحلیل پیچیدگی محاسباتی

در سیستم‌های خودوفق، مسئله نهایی هدایت خودکار سیستم عبارت از یافتن یک سیاست وفقی بهینه $\pi^* : S \to A$ است که ارزش پاداش تجمعی تنزیل‌یافته در درازمدت را بیشینه سازد:

$$\pi^* = \arg\max_{\pi} \mathbb{E}\left[\sum_{t=۰}^{\infty} \gamma^t R(s_t, a_t) \mid \pi\right]$$

این سیاست بهینه به سیستم خودوفق امکان می‌دهد تا به طور خودکار بهترین تصمیمات انطباقی را در مواجهه با نوسانات پویای محیطی، تغییرات ترافیک و تداخلات تصادفی اتخاذ کند. با این حال، حل مستقیم این مسئله بهینه‌سازی در زمان اجرا به دلیل انفجار ترکیبی ابعاد پیکربندی و ارضای همزمان قیود چندهدفه، با موانع محاسباتی بنیادینی روبه‌رو است که در ادامه به اثبات صوری پیچیدگی آن پرداخته می‌شود.

[59] Threshold Goal

۲-۶-۱ تحلیل پیچیدگی مسئله انطباق و اثبات ان‌پی‌ـ‌سختی

پیش از تشریح قیود عملیاتی، اثبات صوری این موضوع که چرا روش‌های وارسی کامل یا تکاملی سنتی در زمان اجرا ناکارآمد هستند، ضرورت دارد. مسئله انطباق بهینه در یک شبکه حسگر بی‌سیم خودوفق نظیر شبکه DeltaIoT را می‌توان به صورت ریاضی به عنوان یک مسئله بهینه‌سازی چندهدفه مقید صورت‌بندی نمود.

فرض کنید شبکه متشکل از مجموعه‌ای از گره‌ها V و پیوندهای ارتباطی E باشد. فضای عمل کل سیستم A حاصلضرب دکارتی تصمیمات محلی تمام گره‌ها است:

$$A = \prod_{v \in V} A_v$$

هر گره v باید توان ارسال $p_v \in \{۰, \dots, ۱۵\}$ و توزیع مسیرهای خروجی $d_v \in [۰, ۱]^L$ را تعیین کند. هدف ما یافتن پیکربندی بهینه‌ای است که مجموع مصرف انرژی کل شبکه را کمینه سازد:

$$\min_{a \in A} \sum_{v \in V} \text{Energy}(v, a)$$

به طوری که قیود کیفی زیر ارضا گردند:

$$\text{PacketLoss}(a) < \theta_P$$

$$\text{Latency}(a) < \theta_L$$

قضیه ۱: مسئله بهینه‌سازی انطباق مقید در حلقه‌های خودوفق مقیاس‌وسیع، یک مسئله سخت بهینه یا ان‌پی‌ـ‌سخت (NP-hard)[۶۰] است [۲۸].

اثبات صوری از طریق کاهش:

برای اثبات، این مسئله را به مسئله کوله‌پشتی چندبعدی (MDKP)[۶۱] [۲۸] که ان‌پی‌ـ‌سخت بودن آن اثبات شده است، کاهش می‌دهیم. در مسئله MDKP، مجموعه‌ای از اشیاء با ارزش‌ها و هزینه‌های چندگانه وجود دارند و هدف انتخاب زیرمجموعه‌ای است که ارزش بیشینه را تحت محدودیت ظرفیت تمام ابعاد کوله‌پشتی فراهم آورد.

در فرمول‌بندی انطباق ما:

۱. انتخاب توان ارسال و توزیع مسیر برای هر گره v معادل انتخاب یک شیء با ویژگی‌های مشخص در MDKP است.

[60] Non-deterministic Polynomial-time Hard

[61] Multi-Dimensional Knapsack Problem

۲. مصرف انرژی در شبکه معادل کمینه کردن وزن انتخاب‌ها در کوله‌پشتی است.

۳. قیود آستانه‌ای کیفیت خدمات (θ_P و θ_L) معادل ظرفیت‌های محدود چندبعدی کوله‌پشتی هستند که نباید از حد مشخصی تجاوز کنند.

۴. به دلیل وابستگی‌های غیرخطی اتلاف بسته‌ها و تاخیر در طول مسیرهای ارتباطی شبکه، ارزیابی هر پیکربندی مستلزم حل روابط انتشار سیگنال احتمالی است که پیچیدگی مسئله را از MDKP کلاسیک نیز فراتر می‌برد.

از آنجا که MDKP انپی‌ـ سخت است، مسئله انطباق مقید شبکه نیز ذاتاً انپی‌ـ سخت خواهد بود. با رشد تعداد گره‌ها ($N = |V|$)، ابعاد فضای پیکربندی به صورت توان‌نمایی $O(C^N)$ رشد می‌کند؛ جایی که C تعداد گزینه‌های محلی هر گره است. برای DeltaIoTv2 با ۳۷ سنسور، این فضا به ابعاد گسترده ۴۰۹۶ حالت ممکن می‌رسد. وارسی جامع تمام گزینه‌ها در زمان اجرا به دلیل این پیچیدگی غیرممکن است. این تحلیل ریاضی اثبات می‌کند که چرا سیستم‌های بلادرنگ ناگزیرند از الگوریتم‌های یادگیری بدون مدل تقریب‌گر عصبی (نظیر DQN زمان اجرای ما) استفاده کنند که محاسبات سنگین را به صورت آفلاین یا پس‌زمینه انجام داده و در زمان اجرا تنها یک استنتاج مستقیم (گذر رو به جلو) با مرتبه زمانی ثابت ($O(۱)$) را اعمال می‌نمایند.

۲-۶-۲ قیود عملیاتی زمان اجرا در سیستم‌های خودوفق

جهت تطابق کامل با چالش‌های سیستم‌های اینترنت اشیاء و سیستم‌های فیزیکی‌ـ سایبری معاصر، سیاست بهینه باید همزمان بر دو رژیم از قیود عملیاتی فائق آید: در سیستم‌های با کیفیت خدمات نرم (نظیر شبکه‌های حسگر)، ارضای سه قید اساسی زیر الزامی است:

۱. **خروج پویا از بهینه‌های محلی:**[۶۲] سیاست باید در برابر تغییر شرایط محیطی انعطاف‌پذیر بوده و در دام سیاست‌های قدیمیِ نیمه‌بهینه گرفتار نشود.

۲. **مقیاس‌پذیری و کارایی زمانی:**[۶۳] فرآیند تصمیم‌گیری آنلاین باید در کسری از میلی‌ثانیه رخ دهد. برای تحقق این امر، آموزش سنگین عمیق شبکه‌ی عصبی باید به صورت کاملاً ناهمگام[۶۴] در پس‌زمینه و مجزا از مسیر تصمیم‌گیری زمان اجرا انجام شود.

۳. **استقلال کامل از دانش دامنه:**[۶۵] فرآیند کاوش و بازپخش تجربیات نباید وابسته به مختصات صریح اهداف یا دانش از پیش‌تعریف‌شده باشد تا راهکار قابلیت تعمیم به دامنه‌های مختلف نرم‌افزاری را حفظ کند.

[62] Local Optima Escape
[63] Temporal Scalability
[64] Asynchronous Background Training
[65] Domain Independence

۲-۷ سیستم مورد مطالعه دوم: شبیه‌ساز مأموریت پهپاد DARTSim

شبیه‌ساز مأموریت DARTSim [۲۹] یک بستر شبیه‌سازی فیزیکی_ سایبری هوایی برای ارزیابی تصمیم‌گیری‌های انطباقی زمان اجرای تیم‌های پهپادی در محیط‌های پرخطر است. در این سیستم، یک تیم پهپادی باید با اتخاذ سیاست‌ها و راهبردهای وفقی تاکتیکی، بقای خود را حفظ کرده و اهداف مأموریت (مانند شناسایی اهداف و خروج از شعاع راداری تهدیدات) را بیشینه نماید. این بستر، چالش‌های متفاوتی را نسبت به شبکه‌های حسگر بی‌سیم به تصویر می‌کشد و آزمونی تعیین‌کننده برای ارزیابی چنددامنه‌ای و استقلال از دامنه روش پیشنهادی رساله به شمار می‌رود.

۲-۷-۱ خاستگاه محک، معماری فیزیکی و مؤلفه‌های پروازی ناوگان پهپادی

برخلاف یک محیط شبیه‌سازی دلخواه، DARTSim ریشه در یکی از محک‌های شناخته‌شده و پراستناد حوزه سیستم‌های خودوفق دارد. این بستر بر پایه‌ی مسئله‌ی تیم پهپادهای خودگردان[۶۶] که نخستین‌بار توسط مورنو و همکاران[۶۷] [۳۰] در چارچوب انطباق پیش‌نگرانه تحت عدم‌قطعیت معرفی شد، استوار گردیده است. در این مسئله، تیمی از پهپادها مأموریت پیمایش و شناسایی را در یک محیط متخاصم اجرا می‌کنند و باید میان دو هدف متضاد تعادل برقرار سازند: پرواز در ارتفاع پایین‌تر احتمال شناسایی اهداف زمینی را افزایش می‌دهد اما هم‌زمان مواجهه با تهدیدات راداری را تشدید می‌کند، در حالی‌که پرواز در ارتفاع بالاتر ریسک تهدید را می‌کاهد ولی شناسایی اهداف را دشوارتر می‌سازد. همین مسئله‌ی پهپادی، در پژوهش‌های متأخرتر از جمله چارچوب TUNE-II مبتنی بر میانگین‌گیری مدل بیزی [۳۱] نیز به‌عنوان یک مطالعه موردیِ مرجع برای ارزیابی انطباق چندهدفه تحت عدم‌قطعیت مدل به‌کار گرفته شده است. انتخاب DARTSim در این رساله از دو منظر توجیه می‌شود: نخست، اعتبار علمی و تکرارپذیری آن به‌عنوان یک محک تثبیت‌شده؛ و دوم، تمایز ماهوی دامنه آن (تصمیم‌گیری تاکتیکی بلادرنگ هوایی در فضای حالت پیوسته و فضای اقدام گسسته) نسبت به مطالعه موردی نخست یعنی DeltaIoT، که امکان سنجش دقیق استقلال از دامنه روش پیشنهادی را فراهم می‌آورد.

از منظر ساختار سایبری_ فیزیکی، سیستم پهپادی در شبیه‌ساز DARTSim از سه مؤلفه اصلی تشکیل شده است:

- **بدنه و ناوگان پهپادها:**[۶۸] دسته‌ای از پهپادهای خودگردان مجهز به حسگرهای اپتیکی و حرارتی شناسایی هدف، اخلال‌گرهای راداری فعال و عملگرهای تغییر آرایش تیمی.
- **محیط مأموریت متخاصم:**[۶۹] شامل مناطق اهداف زمینی جهت تصویربرداری و سایت‌های پدافندی دشمن با سیستم‌های راداری فعال و موشک‌های رهگیر زمین‌به‌هوا.

[66] Unmanned Aerial Vehicle (UAV) Team
[67] Gabriel A. Moreno et al.
[68] UAV Fleet
[69] Mission Environment

- **زیرسیستم اخلال‌گر الکترونیکی (ECM):**[۷۰] یک سازوکار دفاعی فعال که با ارسال امواج نویز پرتوان، برد موثر رادارهای متخاصم را تضعیف می‌کند؛ با این حال، فعال‌سازی این سیستم جریمه سنگین مصرف باتری بر پهپادها تحمیل می‌نماید.

۲-۷-۲ فضای معنایی، اهداف قابلیت اعتماد و معیارهای کیفیت خدمات

رفتار سیستم پهپادی توسط مجموعه‌ای از عوامل پیکربندی (قابل‌کنترل توسط عامل انطباقی) و عوامل محیطی (منابع عدم‌قطعیت بیرونی) تعیین می‌شود که مجموعاً «فضای معنایی» سیستم را تشکیل می‌دهند. جدول ۲-۲ این عوامل را به تفکیک نوع، دامنه و نقش آن‌ها در مأموریت خلاصه می‌کند.

جدول ۲-۲: فضای معنایی سیستم پهپادی DARTSim (عوامل پیکربندی و محیطی)

عامل	نوع	دامنه	توضیح
آرایش تیمی (formation)	پیکربندی	{tight, loose}	هندسه آرایش فضایی تیم پهپادی هنگام اجرای مأموریت.
سرعت پرواز (flying speed)	پیکربندی	[5, 50] mph	سرعت متوسط پرواز که بر احتمال شناسایی و فرار اثر می‌گذارد.
اخلال‌گر الکترونیکی (ECM)	پیکربندی	{On, Off}	فعال‌سازی اخلال برای کاهش احتمال شناسایی توسط تهدیدات.
وضعیت جوی (weather)	محیطی	{sun, clouds, rain, fog}	شرایط هواشناختی مؤثر بر عملکرد حسگرها و پرواز.
زمان روز (day time)	محیطی	00:00–23:59	زمان روز که بر میدان دید و احتمال شناسایی اثرگذار است.
شعاع تهدید (threat range)	محیطی	[0.9, 3.7] km	شعاع شناسایی تهدیدات که میزان مواجهه پهپاد را تعیین می‌کند.
تعداد تهدیدات (# threats)	محیطی	[1–10]	شمار تهدیدات فعال در منطقه عملیاتی.

نمودار مفهومی شکل ۲-۲ برهم‌کنش این عوامل را به تصویر می‌کشد: عوامل پیکربندی و محیطی هر دو بر عملکرد تیم پهپادی در دل «محیط متخاصم» اثر گذاشته و در نهایت تحقق اهداف قابلیت اعتماد (شناسایی هدف و اجتناب از تهدید) را تعیین می‌کنند. شایان ذکر است که این فضای معنایی هفت‌عاملی، خاستگاه مفهومی مسئله را تبیین می‌کند؛ تحقق عملیاتی آن در این رساله به‌صورت یک بردار حالت ۱۷ بعدی و فضای اقدام گسسته ۸ گانه صورت‌بندی شده است.

اهداف مأموریت در DARTSim از دو الگوی الزامِ پارامتری مشتق می‌شوند که هر دو حول مفهوم محوری مصالحه‌ی ارتفاع شکل گرفته‌اند: الگوی نخست، **الگوی شناسایی هدف**[۷۱]، بیان می‌کند که «هنگامی‌که ارتفاع میان θ_1 و θ_2 متر است، تیم پهپادی باید در بیش از p_1 درصد موارد هدف را شناسایی کند.» این الگو بیشینه‌سازی قابلیت اطمینان شناسایی را هدف می‌گیرد. الگوی دوم، **الگوی اجتناب از تهدید**[۷۲]، در مقابل بیان می‌کند که «هنگامی‌که ارتفاع میان θ_1 و θ_2 متر است، تهدیدات موجود باید در کمتر از p_2 درصد موارد پهپادها را شناسایی کنند.» با نمونه‌سازی این دو الگو بر روی شش بازه‌ی ارتفاعی و آستانه‌های احتمال متناظر، مجموعاً ۱۲ الزام صوری قابلیت اعتماد ملموس (۶ مورد شناسایی و ۶ مورد اجتناب) حاصل می‌گردد. این الزامات در سه محور اساسی کیفیت خدمات فرمول‌بندی می‌شوند:

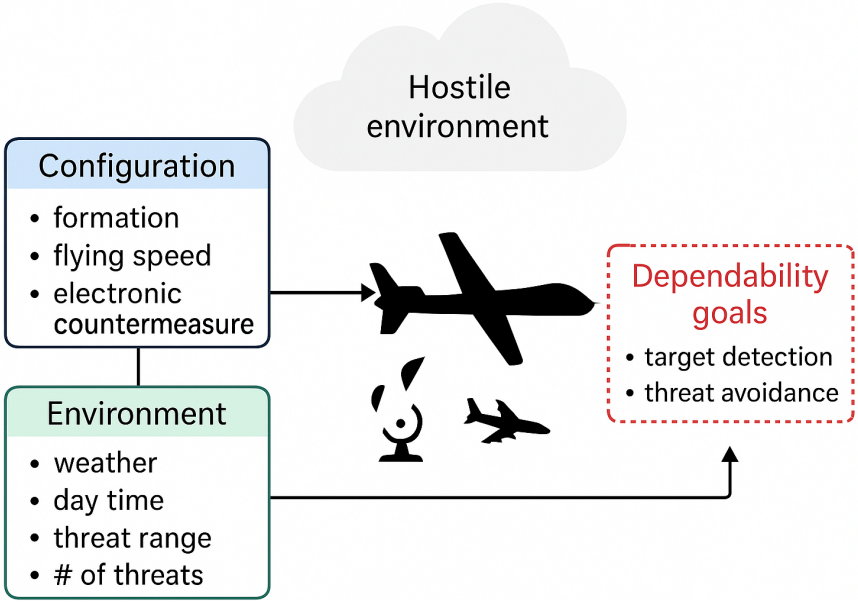
۱. **نرخ بقای تیم:**[۷۳] بقای فیزیکی بدنه پهپادها در برابر اصابت موشک‌های پدافند هوایی، که به عنوان

[70] Electronic Countermeasures

[71] Target Detection Pattern

[72] Threat Avoidance Pattern

[73] Team Survival Rate



شکل ۲-۲: نمودار مفهومی عوامل اثرگذار بر اهداف قابلیت اعتماد تیم پهپادی DARTSim؛ عوامل پیکربندی و محیطی در یک محیط متخاصم بر تحقق اهداف شناسایی هدف و اجتناب از تهدید اثر می‌گذارند.

پاداش اصلی مأموریت سنجیده می‌شود.

۲. **پوشش اهداف شناسایی‌شده:**[۷۴] نسبت اهداف شناسایی‌شده به کل اهداف موجود در منطقه عملیاتی.

۳. **مدیریت مصرف انرژی اخلالگر:**[۷۵] بهینه‌سازی الگوی مصرف باتری اخلالگر جهت پرهیز از تخلیه زودرس انرژی پهپادها.

۲-۷-۳ سناریوهای عدم قطعیت، تلاطم محیطی و فضای وفقی تاکتیکی

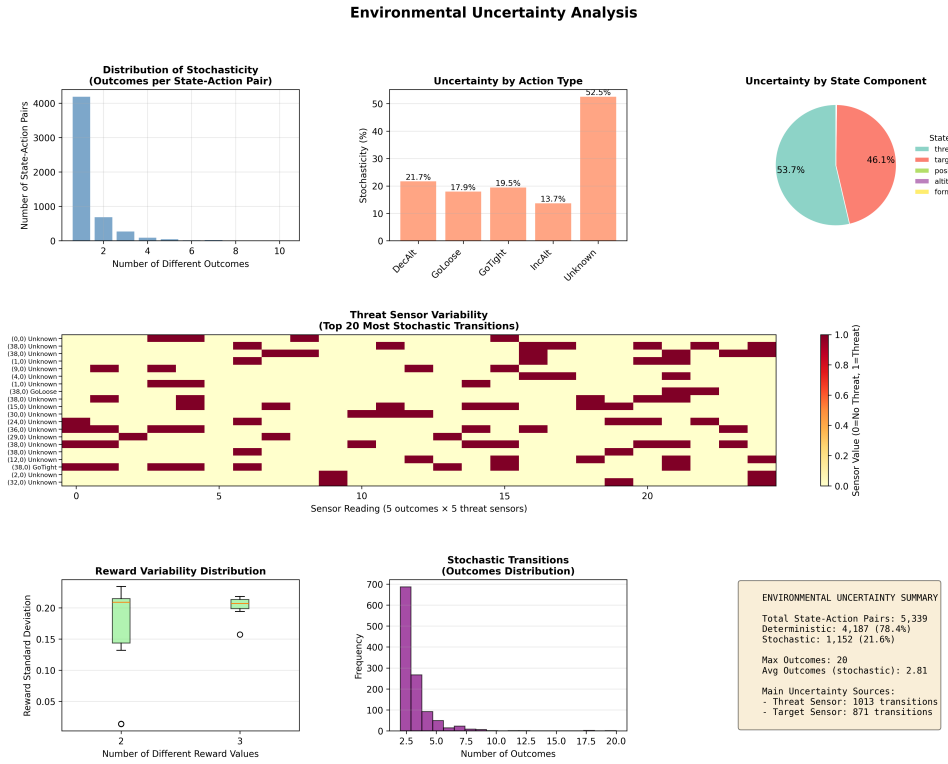
عدم قطعیت در DARTSim ناشی از پویایی محیطی، نویز حسگرها، محل نامشخص تهدیدات دشمن و نوسان پایداری ارتباطات میان پهپادها است. فضای وفقی سیستم در سطح تصمیم‌گیری تاکتیکی بر سه دسته از اقدامات گسسته استوار است: **اقدامات تنظیم ارتفاع** شامل افزایش ارتفاع متوسط یا شدید (IncAlt، IncAlt2) و کاهش ارتفاع (DecAlt، DecAlt2) جهت مانور میان شعاع رادارهای کم‌ارتفاع و تهدیدات دوربرد؛ **اقدامات تنظیم هندسه آرایش** شامل فشرده‌سازی تیمی برای کاهش ردپای راداری یا پراکنده‌سازی پهپادها (GoTight، GoLoose)؛ و **کنترل سیستم اخلالگر** شامل تغییر وضعیت روشن یا خاموش اخلال الکترونیکی (EcmOn، EcmOff). این فضای وفقی شامل ۸ اقدام تاکتیکی گسسته در سناریوی پایه‌ی لاگ آفلاین است. در مدل‌سازی تفصیلی سیستم‌های فیزیکی–سایبری بلادرنگ در فصول ۴ و ۵ (بخش‌های ۴-۹ و ۵-۷)، فضای وفقی ناوگان پهپادی بر پایه مشخصات استاندارد SEAMS DARTSim به ۶۰ پیکربندی

[74] Targets Detected

[75] ECM Energy Management

ترکیبی گسسته (شامل ۱۵ پله‌ی سرعت پرواز، ۲ آرایش تیمی و ۲ وضعیت فعال‌سازی اخلال‌گر) همراه با ۱۲ الزام صوری قابلیت اعتماد بسط می‌یابد تا سه‌گانه برنامه‌ریزی بلادرنگ و شکاف واقعیت مدل‌های جانشین تا فیزیک پرواز به طور دقیق و همه‌جانبه ارزیابی گردد.

ویژگی بارز بستر DARTSim، ماهیت ذاتاً تصادفی[۷۶] محیط آن است؛ به گونه‌ای که یک زوج حالت–اقدام یکسان می‌تواند به پیامدهای متفاوتی منجر شود که عمدتاً از نویز حسگرها و تغییرپذیری محیطی سرچشمه می‌گیرد. تحلیل تراکنش‌های ثبت‌شده نشان می‌دهد که هرچند بخشی از گذارها قطعی‌اند، بخش قابل‌توجهی از زوج‌های حالت–اقدام چندین پیامد ممکن تولید می‌کنند و منشأ اصلی این پراکندگی، قرائت حسگرهای شناسایی تهدید و هدف است. شکل ۲-۳ داشبورد جامعی از این تحلیل را ارائه می‌دهد که در آن توزیع تصادفی‌بودن گذارها، سهم هر مؤلفه‌ی حالت در ایجاد عدم‌قطعیت و پراکندگی پاداش‌ها به تفکیک نمایش داده شده است.

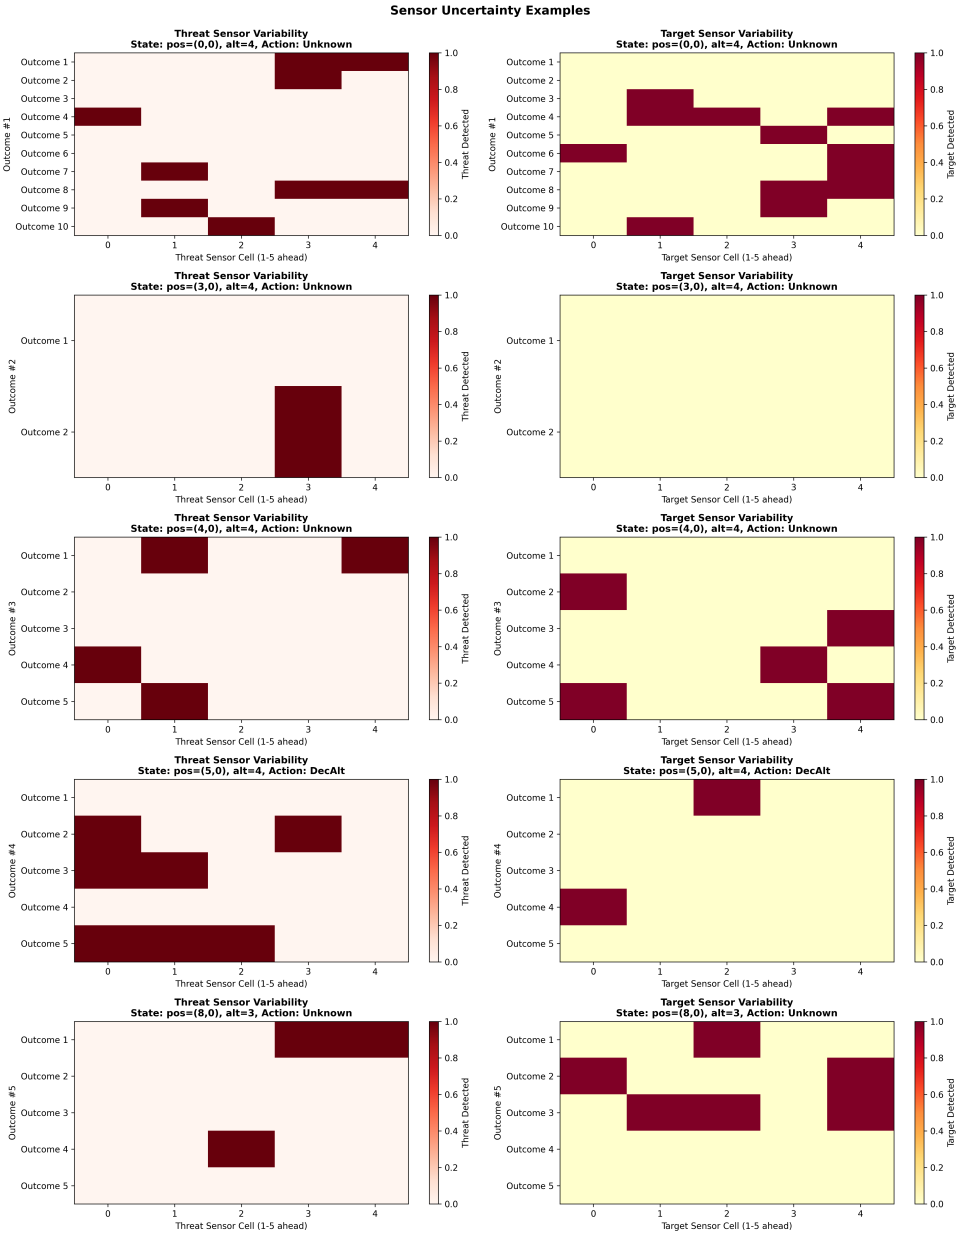


شکل ۲-۳: داشبورد تحلیل عدم قطعیت محیطی DARTSim: توزیع تصادفی‌بودن گذارها، عدم‌قطعیت به‌تفکیک نوع اقدام و مؤلفه حالت، تغییرپذیری قرائت حسگر تهدید و پراکندگی پاداش‌ها.

برای تبیین ملموس‌تر این پدیده، شکل ۲-۴ چند نمونه از زوج‌های حالت–اقدام را نشان می‌دهد که در آن‌ها قرائت حسگرهای تهدید و هدف (پنج سلول پیش‌رو) برای پیامدهای گوناگونِ ناشی از یک اقدام واحد تغییر می‌کند. این تصادفی‌بودن، عامل انطباقی را وادار می‌سازد که به‌جای حفظ‌کردنِ مسیرهای قطعی، سیاست‌های مقاومی بیاموزد که در سراسر پیامدهای محتمل کارا باشند. دقیقاً همین چالشِ کاوش و یادگیری

[76] Stochastic Environment

تحت عدم‌قطعیت سنگین است که الگوریتم پیشنهادی RS-DRL برای غلبه بر آن طراحی شده است.



شکل ۲-۴: نمونه‌هایی از تغییرپذیری قرائت حسگرهای تهدید و هدف برای یک زوج حالت–اقدام یکسان در DARTSim؛ هر سطر یک پیامد ممکن و هر ستون یک سلول حسگر پیش‌رو را نشان می‌دهد.

۲-۷-۴ فرمول‌بندی مأموریت پرواز در قالب فرآیند تصمیم‌گیری مارکوف

مسئله انطباق تاکتیکی پهپادها در شبیه‌ساز DARTSim به صورت یک MDP استاندارد فرمول‌بندی می‌شود:

- **فضای حالت (S):** بردار حالت ۱۷ بعدی $s_t \in \mathbb{R}^{17}$ است که به صورت ساختاریافته به دو بخش تفکیک می‌گردد: $s = (cf, of)$؛ مؤلفه‌های پیکربندی (cf) شامل وضعیت پله‌ی ارتفاع، هندسه

آرایش تیمی، و وضعیت اخلال‌گر الکترونیکی است که مستقیماً توسط عملگرهای وفقی تغییر می‌یابند؛ و مؤلفه‌های مشاهداتی و محیطی (of) شامل موقعیت مکانی تیم پهپادی تا اهداف، قرائت‌های ۵ سلول حسگر پیشِ‌رو برای تهدید و هدف، و وضعیت انرژی باقی‌مانده است. این تفکیک صوری، زمینه ریاضی لازم را برای تحلیل حساسیت هوش مصنوعی توضیح‌پذیر TreeSHAP[۷۷] و اثبات گزاره ۱ در فصل ۴ فراهم می‌سازد.

- **فضای اقدام (A):** فضای اقدامات شامل ۸ اقدام وفقی تاکتیکی گسسته است که در بخش قبل شرح داده شد.
- **تابع پاداش چندهدفه (R):** پاداش تجمعی زمان اجرا به صورت ترکیب وزنی زیر فرمول‌بندی می‌گردد:

$$R(s_t, a_t) = w_{\text{survival}} \cdot r_{\text{surv}}(s_t) + w_{\text{target}} \cdot r_{\text{target}}(s_t) - w_{\text{energy}} \cdot c_{\text{energy}}(a_t) - c_{\text{step}} \quad (۸-۲)$$

که در آن $c_{\text{step}} = ۰/۰۱$ جریمه زمانی هر گام مأموریت است.

۲-۷-۵ محیط انطباق آفلاین و طیف دشواری سناریوها

به منظور غلبه بر محدودیت‌های پایداری اتصالات شبکه و داکر دسکتاپ در فاز آموزش، یک محیط انطباق آفلاین[۷۸] تحت عنوان OfflineDARTSimEnv[۷۹] طراحی گردید. این آداپتور، تعامل بلادرنگ با شبیه‌ساز را با یک ساختار جستجوی هوشمند تراکنش‌های از پیش‌ثبت‌شده[۸۰] جایگزین می‌کند. بر این اساس، بانک داده‌ای شامل ۵۰۰۰۰ انتقال حالت جمع‌آوری‌شده از مأموریت‌های واقعی پهپاد در سناریوی پایه[۸۱] لود شده و تراکنش‌های بعدی به صورت بازپخش ساختاریافته‌ی همان مسیرهای ثبت‌شده شبیه‌سازی می‌شوند. این رویکرد آفلاین منجر به تضمین کامل پایداری، سرعت بی‌سابقه فرآیند همگرایی یادگیری و تکرارپذیری مطلق آزمایش‌ها می‌گردد.

علاوه بر این، محیط DARTSim به‌گونه‌ای طراحی شده است که طیفی از سطوح دشواری فزاینده را پشتیبانی کند؛ این طیف از یک نقشه‌ی خطی ساده تا نقشه‌های مربعی بزرگ با الگوی مسیر مارپیچی و چگالی بالای تهدید و هدف گسترده است و فضای طراحی لازم برای سنجش آینده‌نگرِ مقیاس‌پذیری و قابلیت تعمیم را فراهم می‌آورد. جدول ۲-۳ پارامترهای کلیدی این سه سناریوی پیکربندی‌پذیر را مقایسه می‌کند.

سناریوی پایه دارای مسیر مستقیم و چگالی متعادل تهدیدها است؛ سناریوهای متوسط و سخت با افزودن

[77] Tree-based Shapley Additive Explanations

[78] Offline Replay Adapter

[۷۹] این سازوکار با بارگذاری و نمونه‌برداری ایزوله از داده‌های آفلاین ثبت‌شده، ضمن حفظ پویایی تصادفی انتقال‌ها، از بروز وقفه در آموزش شبکه در اثر ناپایداری‌های اتصال شبکه یا داکر شبیه‌ساز جلوگیری می‌کند.

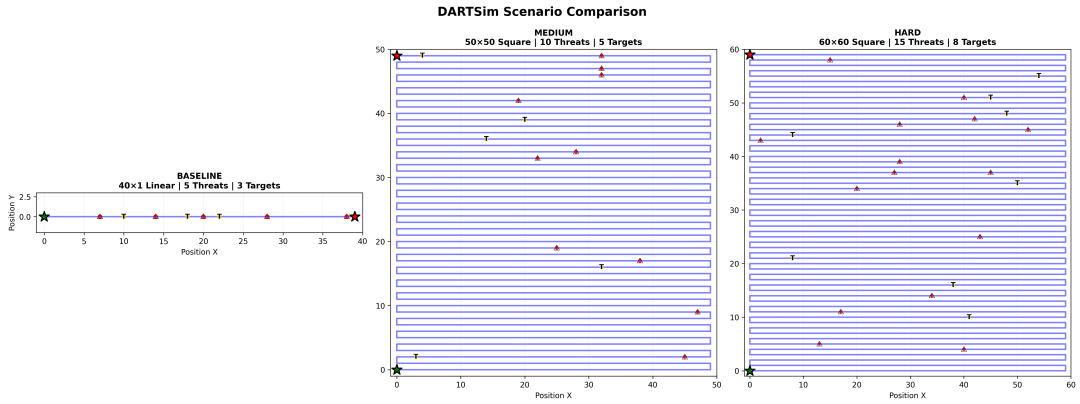
[80] Offline Collected Data

[81] Baseline Scenario

جدول ۲-۳: طیف سناریوهای پیکربندی‌پذیر محیط DARTSim و سطوح دشواری آن‌ها

سناریو	ابعاد نقشه	نوع نقشه	تهدیدات	اهداف	سطوح ارتفاع	دشواری
پایه (Baseline)	۱ × ۴۰	خطی	۵	۳	۴	آسان
متوسط (Medium)	۵۰ × ۵۰	مربعی (مارپیچ)	۱۰	۵	۵	متوسط
سخت (Hard)	۶۰ × ۶۰	مربعی (مارپیچ)	۱۵	۸	۶	سخت

مسیرهای مارپیچی پرپیچ‌وخم، نقشه‌های بزرگ‌تر و چگالی بالاتر تهدید و هدف، پیچیدگی روزافزون محیط را به تصویر می‌کشند. شکل ۲-۵ نمای مقایسه‌ای این سه سناریو را به‌همراه چیدمان تهدیدها، اهداف و الگوی مسیر نشان می‌دهد. شایان توجه است که ارزیابی‌های تجربی ناوگان پهپادی در این رساله (فصل ۵، بخش ۵-۷) بر پایه‌ی مجموعه داده‌های آفلاین و اجرای ۲,۰۰۰ پرواز حلقه‌ـ بسته فیزیکی در ۲۰۰ سناریوی عملیاتی مستقل انجام شده‌اند؛ چرا که این ساختار با تأمین فضای پیکربندی گسسته ۶۰ حالته و عدم توازن شدید شکست (بیش از ۹۰٪)، چالش‌های بنیادین سه‌گانه برنامه‌ریزی بلادرنگ و شکاف واقعیت مدل‌های جانشین را به بوته آزمایش می‌گذارد. سناریوهای متوسط و سخت نیز فضای طراحی آماده‌ای برای تعمیم به سیستم‌های چندعاملی نامتمرکز در پژوهش‌های آتی فراهم می‌آورند.



شکل ۲-۵: مقایسه‌ی سه سناریوی DARTSim (پایه، متوسط و سخت)؛ تفاوت در چیدمان نقشه، پیچیدگی مسیر و چگالی تهدید و هدف.

۲-۸ خلاصه فصل

این فصل به تفصیل مبانی نظری، ریاضی و صوری مورد نیاز برای درک تصمیم‌گیری خودوفق تحت عدم قطعیت را تشریح نمود. ما ابتدا معماری‌های مرجع حلقه‌های بازخورد کنترلی MAPE-K و رده‌بندی چندلایه عدم قطعیت (شامل عدم قطعیت‌های محیطی، سیستمی، اهداف و به ویژه پدیده شکاف واقعیت مدل‌های جانشین در سیستم‌های فیزیکی‌ـ سایبری) را تبیین کردیم. سپس با ارائه مبانی فرآیندهای تصمیم‌گیری مارکوف و الگوریتم‌های یادگیری تقویتی عمیق DQN، نحوه استنتاج سیاست بهینه تحت عدم قطعیت را تحلیل نمودیم. در ادامه، دو سیستم محک شاخص رساله به عنوان بسترهای آزمایشی مکمل فرمول‌بندی شدند:

بستر شبکه حسگر DeltaIoT با اثبات ریاضی ان‌پی‌ـ‌سخت بودن مسئله بهینه‌سازی مقید؛ و بستر فیزیکی‌ـ‌سایبری ناوگان پهپادی DARTSim با ۱۲ الزام صوری قابلیت اعتماد، عدم توازن شدید داده‌های شکست در لاگ‌ها، و سناریوهای دشواری سه‌گانه. این زیربنای مستحکم نظری، مستقیماً زمینه لازم را برای تحلیل انتقادی شکاف‌های پیشینه در فصل ۳، پیاده‌سازی معماری دوسطحی RS-DRL^{+} در فصل ۴، و اعتبارسنجی تجربی چنددامنه‌ای در فصل ۵ فراهم می‌آورد.

فصل سوم

مرور پیشینه پژوهش و کارهای مرتبط

۳-۱ مقدمه و روش‌شناسی مرور

هدف بنیادین این فصل، ارائه یک بررسی نظام‌مند، انتقادی و عمیق از ادبیات علمی و رویکردهای موجود در زمینه مدیریت عدم قطعیت و تصمیم‌گیری زمان اجرا در سیستم‌های خودوفق (SAS)[1] است. در طراحی مهندسی سیستم‌های خودوفق مدرن، اتخاذ تصمیمات وفقی بهینه در مواجهه با شرایط پویای محیطی و فضاهای تصمیم‌گیری بسیار بزرگ، یکی از چالش‌های بنیادین به شمار می‌رود. کارهای پیشین هر یک از زاویه‌ای خاص به این مسئله نگریسته‌اند؛ با این حال، به منظور درک دقیق سهم علمی این رساله و تبیین دقیق ضرورت ارائه الگوریتم RS-DRL، تحلیل موشکافانه و مقایسه‌ای این رویکردها ضرورتی بنیادین دارد.

بدین منظور، در این فصل روش‌شناسی مروری ساختاریافته‌ای اتخاذ گردیده است. فرآیند شناسایی و گزینش مقالات از طریق جستجوی جامع در پایگاه‌های داده معتبر بین‌المللی از جمله IEEE Xplore، ACM Digital Library، Scopus و Google Scholar صورت پذیرفته است. بازه زمانی جستجو متمرکز بر پژوهش‌های برجسته دو دهه اخیر بوده و کلمات کلیدی نظیر «سیستم‌های خودوفق»، «یادگیری تقویتی آنلاین»، «شکل‌دهی پاداش»، «فضای وفقی بزرگ» و «تأیید صوری زمان اجرا» به عنوان معیارهای اصلی فیلترینگ استفاده شده‌اند. معیارهای ورود مقالات به چرخه بررسی انتقادی شامل تمرکز بر روی مدیریت فضاهای وفقی گسسته در زمان اجرا و توانایی سیستم در تصمیم‌گیری آنلاین تحت شرایط عدم قطعیت بوده است.

جهت ارزیابی نظام‌مند و مقایسه‌ی عادلانه پیشینه پژوهش، یک چارچوب ارزیابی پنج‌بعدی بر پایه معیارهای مهندسی نرم‌افزار خودوفق [۴، ۳۲] توسعه داده شده است که تمامی آثار بررسی‌شده بر اساس این شاخص‌ها مورد نقد قرار می‌گیرند[2]:

[1] Self-Adaptive Systems

[2] این پنج معیار ارزیابی برای اولین بار در این رساله تدوین شده‌اند. جدول ۳-۱ در انتهای همین فصل (صفحه ۵۴) مقایسه تطبیقی جامع روش پیشنهادی RS-DRL را با کارهای پیشین بر اساس این پنج بعد ارائه می‌دهد.

۱. **ابعاد فضای وفقی:**[۳] توانایی روش پیشنهادی در مقیاس‌پذیری و مدیریت فضاهای تصمیم‌گیری گسسته و بزرگ (فراتر از ۱۰۰۰ گزینه وفقی).

۲. **مدیریت پویایی و عدم‌قطعیت زمان‌اجرا:**[۴] پایداری عملکرد سیستم در مواجهه با رانش مفهومی[۵] و تغییرات پیش‌بینی‌نشده محیطی بدون افت کیفیت خدمات.

۳. **عدم وابستگی به دانش دامنه خاص:**[۶] میزان نیاز به تخصص انسانی زمان توسعه یا طراحی اهداف صریح و پیچیده برای عامل یادگیرنده.

۴. **مقیاس‌پذیری و کارایی محاسباتی:**[۷] توانایی تصمیم‌گیری آنلاین در محدوده میلی‌ثانیه به منظور رعایت قیود پایداری زمانی سیستم.

۵. **قابلیت خروج از بهینه‌های محلی:**[۸] کارایی سازوکارهای کاوش در فرار از تله‌های بهینگی محلی در طول یادگیری آنلاین.

در ادامه‌ی این فصل، ابتدا مبانی نظری عدم قطعیت و تصمیم‌گیری در سیستم‌های خودوفق تشریح شده، سپس سه پارادایم اصلی تصمیم‌گیری (مبتنی بر یادگیری ماشین سنتی، مبتنی بر جستجو و مبتنی بر یادگیری تقویتی عمیق) به صورت موشکافانه تحلیل می‌گردند. در نهایت، با بررسی روش‌های پیشرفته بازپخش تجربه و شکل‌دهی پاداش و نقش روش‌های صوری، خلاءهای پژوهشی موجود استخراج و جایگاه الگوریتم پیشنهادی RS-DRL تبیین می‌گردد.

۲-۳ چارچوب تحلیل ادبیات: ابعاد عدم‌قطعیت و تصمیم‌گیری زمان‌اجرا

سیستم‌های خودوفق به منظور حفظ اهداف کیفی خود (نظیر قابلیت اطمینان، مصرف انرژی و تأخیر)، نیازمند پایش مستمر محیط فیزیکی و تصمیم‌گیری بهینه در زمان اجرا هستند [۲، ۴]. با این حال، تصمیم‌گیری در این سیستم‌ها تحت تأثیر شدید منابع گوناگون عدم قطعیت قرار دارد. عدم قطعیت در ادبیات مهندسی نرم‌افزار خودوفق [۴، ۳۳] به طور کلی به سه دسته اصلی تقسیم می‌شود: عدم قطعیت محیطی (مانند نوسانات تداخل سیگنال در شبکه‌های اینترنت اشیا)، عدم قطعیت سیستمی (نظیر خرابی‌های ناگهانی سخت‌افزار یا تغییرات زیرساختی) و عدم قطعیت اهداف (تغییر در اولویت‌های کیفی کاربران در طول زمان).

برای مدل‌سازی فرآیند تصمیم‌گیری در مواجهه با این عدم قطعیت‌ها، مهندسان سیستم‌های خودوفق از ابزارهای ریاضیاتی متعددی بهره می‌برند:

[3] Adaptation Space Size
[4] Handling of Non-Stationarity
[5] Concept Drift
[6] Need for Domain Knowledge
[7] Real-Time Scalability
[8] Ability to Escape Local Optima

- **فرآیند تصمیم‌گیری مارکوف (MDP):**[9] استانداردترین روش مدل‌سازی ریاضی تصمیم‌گیری پیاپی است که در آن فرض می‌شود وضعیت بعدی سیستم تنها به وضعیت فعلی و اقدام اتخاذ شده وابسته است [۵]. در سیستم‌های خودوفق، وضعیت‌ها نشان‌دهنده شرایط محیطی و پیکربندی‌های سیستم، و اقدامات نشان‌دهنده گزینه‌های وفقی هستند.

- **فرآیند تصمیم‌گیری مارکوف نیمه‌مشاهده‌پذیر (POMDP):**[10] در شرایطی استفاده می‌شود که عامل یادگیرنده دسترسی کامل به وضعیت واقعی محیط ندارد و تنها مشاهدات نویزی در اختیار دارد [۳۴]. اگرچه POMDP واقع‌گرایانه‌تر است، اما حل آن سربار محاسباتی بسیار بالایی دارد که مانع تصمیم‌گیری بلادرنگ در زمان اجرا می‌شود.

- **جستجوی تصادفی زمان‌اجرا:** رویکردی غیرمدل‌محور است که سیستم با نمونه‌برداری زمان‌اجرا از فضای تغییرات، تلاش می‌کند گزینه‌ای را بیابد که اهداف سیستم را ارضا نماید.

یکی از چالش‌های بنیادین ریاضیاتی در تصمیم‌گیری آنلاین سیستم‌های خودوفق، پدیده **تله بهینه‌های محلی**[11] است [۳۵]. در فضاهای وفقی بزرگ و گسسته، تابع مطلوبیت یا پاداش سیستم معمولاً غیرخطی، چندهدفه و دارای تپه‌های متعدد است. هنگامی که یک الگوریتم تصمیم‌گیری آنلاین یا عامل یادگیرنده تلاش می‌کند تا از طریق کاوش محلی (مانند شیب صعودی یا راهبردهای حریصانه) پیکربندی بهینه را بیابد، به شدت مستعد گرفتار شدن در نقاطی است که عملکرد بهتری نسبت به همسایگان بلاواسطه خود دارند، اما با بهینه سراسری[12] فاصله زیادی دارند.

این مشکل در شبکه‌های پویا نظیر DeltaIoT تشدید می‌شود [۲۷]؛ زیرا در این شبکه‌ها، تغییرات تداخل محیطی باعث تغییر مداوم قله‌های بهینگی می‌شود. اگر عامل تصمیم‌گیرنده نتواند با ترکیب بهینه‌ی کاوش[13] و بهره‌برداری[14]، به طور مداوم و پویا فضای تصمیم‌گیری را جستجو کند، در یک سیاست انطباقی منجمد شده و با تغییر شرایط محیطی دچار افت شدید کیفیت خدمات می‌گردد. در بخش‌های بعدی، نحوه مواجهه رویکردهای کلاسیک با این چالش ریاضیاتی را به تفصیل نقد خواهیم نمود.

۳-۳ رویکردهای اصلی مدیریت فضای وفقی در زمان اجرا

به منظور تحلیل و مقایسه‌ی پیشینه پژوهش در زمینه مدیریت فضاهای وفقی بزرگ، آثار علمی موجود را می‌توان به سه پارادایم اصلی تقسیم‌بندی نمود: رویکردهای مبتنی بر یادگیری ماشین سنتی برای هرس فضا، روش‌های

[9] Markov Decision Process
[10] Partially Observable Markov Decision Process
[11] Local Optima Trap
[12] Global Optima
[13] Exploration
[14] Exploitation

مبتنی بر جستجو و بهینه‌سازی آنلاین، و مدل‌های مبتنی بر یادگیری تقویتی برای تصمیم‌گیری زمان اجرا. در ادامه، هر یک از این رویکردها را بر اساس چارچوب ارزیابی پنج‌بعدی معرفی‌شده نقد علمی می‌نماییم.

۳-۳-۱ هرس فضای وفقی مبتنی بر یادگیری ماشین سنتی

یکی از ایده‌های نخستین برای مقابله با انفجار ترکیبی گزینه‌های وفقی در سیستم‌های خودوفق بزرگ، هرس پیشاپیش فضای وفقی پیش از ارسال به مؤلفه‌ی تصمیم‌گیر (یا برنامه‌ریز) است. در این دسته از رویکردها، مهندسان سیستم تلاش می‌کنند تا با استفاده از مدل‌های پیش‌بینی‌کننده یادگیری ماشین سنتی، گزینه‌های نامطلوب را فیلتر نمایند.

پژوهش‌های برجسته‌ی کویین و همکارانش[۱۵] [۷، ۸] با معرفی چارچوب ML4EAS[۱۶] از رویکردهای پیشگام در این زمینه است. آن‌ها با به‌کارگیری روش‌های طبقه‌بندی نظارت‌شده (مانند درخت تصمیم و جنگل تصادفی) نشان دادند که می‌توان با آموزش یک مدل روی داده‌های تاریخی، پیکربندی‌هایی را که شانس بسیار پایینی برای ارضای کیفیت خدمات (QoS)[۱۷] دارند، شناسایی و هرس کرد. به طور مشابه، کاچی و بواناکا[۱۸] [۳۶] روش ترکیبی یادگیری و بهینه‌سازی خود را توسعه دادند که از ترکیب الگوریتم‌های طبقه‌بندی و رگرسیون برای پیش‌بینی و غربالگری گزینه‌های ناکارآمد در سیستم‌های توزیع‌شده بهره می‌برد. این روش‌ها قادرند ابعاد فضای جستجو را در سناریوهای ایستا تا ۶۰ درصد کاهش دهند [۳۶].

نقد و بررسی انتقادی: علیرغم کارایی این روش‌ها در کاهش اندازه محیط تصمیم‌گیری زمان اجرا، دو محدودیت بنیادین در این روش‌ها وجود دارد. از یک سو، این روش‌ها با **وابستگی شدید به داده‌های برچسب‌دار آفلاین** مواجه هستند؛ چرا که فرآیند آموزش این طبقه‌بندها مستلزم جمع‌آوری مجموعه‌داده‌های بسیار حجیم و متنوع در زمان توسعه[۱۹] است و در سیستم‌های پیچیده معاصر، شبیه‌سازی تمامی سناریوهای نویزی و محیطی در زمان طراحی ناممکن است [۸، ۹]. از سوی دیگر، **پدیده رانش مفهومی** چالش مهم دیگری است؛ غیبی و وینز[۲۰] [۹] در تحلیل‌های خود تصریح کرده‌اند که در محیط‌های بسیار پویا (مانند اینترنت اشیا شهری با تداخلات متغیر)، الگوهای نویز و ویژگی‌های سیستم دستخوش تغییر مستمر زمان اجرا می‌شوند. با رخ دادن رانش مفهومی، فرضیات اولیه طبقه‌بندهای یادگیری ماشین نامعتبر گشته و دقت مدل در هرس گزینه‌ها به شدت افت می‌کند. برای جبران این افت، سیستم ناگزیر به آموزش مجدد[۲۱] مکرر و بسیار پرهزینه مدل در زمان اجراست، که این فرآیند علاوه بر ایجاد سربار محاسباتی زیاد، سیستم را در طول فرآیند آموزش در وضعیت ناپایدار و غیرایمن قرار می‌دهد و در نهایت منجر به ایجاد یک **موازنه شکننده بین مقیاس‌پذیری**

[15] Federico Quin et al.
[16] Machine Learning for Efficient Adaptation Space Reduction
[17] Quality of Service
[18] Fadwa Kachi and Chafia Bouanaka
[19] Design-time
[20] Omid Gheibi and Danny Weyns
[21] Retraining

و استواری می‌گردد.

۳-۳-۲ روش‌های مبتنی بر جستجوی آنلاین و راهبردهای اکتشافی

پارادایم دوم، تصمیم‌گیری زمان اجرا را به عنوان یک مسئله‌ی بهینه‌سازی و جستجوی آنلاین مدل‌سازی می‌کند. در این روش‌ها، نیازی به داده‌های پیش‌آموزش دیده نیست؛ بلکه سیستم با وقوع هرگونه تغییر در محیط، الگوریتم‌های جستجو را برای یافتن بهترین پیکربندی در فضای وفقی اجرا می‌کند.

کوکر[۲۲] در معماری SASS [۱۰] از روش‌های جستجوی موضعی تصادفی نظیر الگوریتم صعود تپه[۲۳] استفاده کرد تا با بررسی همسایگی پیکربندی فعلی، به پیکربندی برتر دست یابد. اگرچه این روش محاسبات سبکی دارد، اما به شدت مستعد گرفتار شدن در اولین بهینه محلی است [۱۰]. برای عبور از این چالش، پژوهش‌های کینر و همکارانش[۲۴] [۱۱، ۳۷، ۱۲] بر به‌کارگیری برنامه‌نویسی ژنتیک[۲۵] و الگوریتم‌های تکاملی زمان اجرا متمرکز شد. آن‌ها نشان دادند که با تکامل جمعیت‌های گزینه‌های وفقی می‌توان به راه‌حل‌های بسیار بهتری دست یافت. علاوه بر این، چن[۲۶] در رویکرد FEMOSAA [۳۸] با استفاده از الگوریتم تکاملی چندهدفه (MOEA)[۲۷]، مصالحه‌ی پویای بین اهداف متناقض کیفی (مانند انرژی و تأخیر) را در زمان اجرا مدل‌سازی و جستجو نمود.

نقد و بررسی انتقادی: اگرچه این رویکردها ویژگی تطبیق‌پذیری آنلاین بدون نیاز به آموزش را فراهم می‌سازند، اما نقطه ضعف بزرگ آن‌ها **سربار محاسباتی زمان اجرا و چالش پایداری زمانی** است: اولین نقطه ضعف، **عدم مقیاس‌پذیری در ابعاد بزرگ** است؛ الگوریتم‌های تکاملی و چندهدفه برای همگرایی به جبهه بهینه پارتو[۲۸] نیازمند ارزیابی صدها یا هزاران پیکربندی در هر گام تصمیم‌گیری هستند. هنگامی که ابعاد فضای وفقی بزرگ شده و فراتر از ۱۰۰۰ گزینه (نظیر فضای ۴۰۹۶ گزینه‌ای بستر DeltaIoTv2) می‌رود، زمان محاسبات این الگوریتم‌ها به مقیاس ثانیه یا دقیقه افزایش می‌یابد [۱۰، ۱۲]. دومین نقطه ضعف، **تأخیر غیرقابل‌تحمل زمان تصمیم‌گیری** است؛ در سیستم‌های حساس به زمان، این تأخیر طولانی برنامه‌ریز منجر به بروز رفتارهای مخرب و انحراف شدید از اهداف پایداری سیستم در طول بازه تصمیم‌گیری می‌گردد، که استقرار عملیاتی این روش‌ها را در محیط‌های بلادرنگ غیرممکن می‌سازد [۱۰، ۱۲].

[22] Zachary Coker et al.
[23] Hill Climbing
[24] Chase Kinneer et al.
[25] Genetic Programming
[26] Tao Chen et al.
[27] Multi-Objective Evolutionary Algorithm
[28] Pareto Front

۳-۳-۳ یادگیری تقویتی زمان‌اجرا و کنترل خودمختار

یادگیری تقویتی[۲۹] به عنوان یک پارادایم تصمیم‌گیری آنلاین پویا، به دلیل توانایی ذاتی عامل در یادگیری سیاست وفقی مطلوب از طریق تعامل مستقیم با محیط، توجه بسیاری را جلب نموده است.

کارهای کلاسیک کیم و پارک[۳۰] [۱۳] از اولین تلاش‌ها در به‌کارگیری الگوریتم Q-Learning جدول‌محور برای تطابق پویای نرم‌افزارها بود. در ادامه، متزگر و همکارانش[۳۱] [۱۴] قابلیت یادگیری تقویتی را برای مدیریت تطابق در معماری‌های سرویس‌گرا تعمیم دادند. همچنین، کامارا و همکارانش[۳۲] [۳۹] چارچوب RLMC[۳۳] را معرفی کردند که در آن از یادگیری تقویتی آنلاین برای هدایت سیستم‌های خودوفق استفاده شده و ایمنی کاوش را از طریق مدل‌چکینگ تضمین می‌کرد. با این حال، تمامی این کارهای اولیه به دلیل استفاده از روش‌های جدول‌محور، با چالش جدی «طاعون بعدنمایی»[۳۴] در فضاهای حالت و عمل بزرگ مواجه بودند [۶].

با ظهور یادگیری تقویتی عمیق (DRL)[۳۵] [۱۵]، محققان تلاش کردند تا با استفاده از شبکه‌های عصبی عمیق به عنوان تقریب‌زننده‌های تابع ارزش، همچون معماری عمیق DQN[۳۶]، فضاهای بزرگ سیستم‌های خودوفق را مدیریت کنند [۳۵].

نقد و بررسی انتقادی: با وجود توانایی شبکه‌های عمیق در تقریب توابع در فضاهای بزرگ، پیاده‌سازی یادگیری تقویتی عمیق استاندارد (نظیر DQN با سازوکار کاوش حریصانه سنتی ϵ-greedy) در سیستم‌های خودوفق با چالش نظری و عملی بزرگی مواجه است. شاخص‌ترین نقطه ضعف این رویکردها، **تله عمیق بهینه‌های محلی** است؛ دو و همکارانش[۳۷] [۳۵] در تحلیل‌های خود نشان دادند که در فضاهای وفقی بزرگ و گسسته، پویایی‌های نویزی زمان اجرا باعث می‌شوند که سیاست عامل یادگیرنده به راحتی در بهینه‌های محلی متوقف شود. راهبرد کاوش تصادفی ϵ-greedy در مواجهه با ابعاد بسیار بزرگ (مانند ۴۰۹۶ گزینه وفقی)، درصد بسیار بالایی از کاوش خود را صرف گزینه‌های غیرمفید و مخرب می‌کند. این امر همگرایی عامل را به شدت کند کرده و مدل را وادار می‌سازد تا در اولین پیکربندی نیمه‌پایدار متوقف گشته و توانایی عبور و رسیدن به بهینه سراسری را نداشته باشد، مگر آنکه فرآیند آموزش مجدد مدل با مقادیر بهینه‌تر از ابتدا آغاز گردد که در زمان اجرا به شدت پرهزینه است.

---

[29] Reinforcement Learning (RL)

[30] Donghwan Kim and Sooyong Park

[31] Andreas Metzger et al.

[32] Javier Câmara et al.

[33] Reinforcement Learning Model Checking

[34] Curse of Dimensionality

[35] Deep Reinforcement Learning

[36] Deep Q-Network

[37] Yali Du et al.

۳-۴ روش‌های پیشرفته یادگیری تقویتی: کاوش، شکل‌دهی پاداش و نگاه به گذشته

در سیستم‌های خودوفق معاصر، عبور از محدودیت‌های الگوریتم‌های یادگیری تقویتی سنتی مستلزم به‌کارگیری روش‌های پیشرفته در سه حوزه کلیدی است: مدیریت فرآیند کاوش در فضاهای وسیع، استفاده از سازوکارهای بازپخش تجربه با نگاه به گذشته، و راهبردهای شکل‌دهی پاداش. در این بخش، مبانی نظری و ریاضیاتی هر یک از این حوزه‌ها را تبیین کرده و چالش‌های تعمیم آن‌ها به سیستم‌های خودوفق را به صورت انتقادی واکاوی می‌نماییم.

۳-۴-۱ چالش‌های راهبرد کاوش در فضاهای وفقی بزرگ

فرآیند کاوش در یادگیری تقویتی، سازوکاری است که به عامل اجازه می‌دهد تا رفتارهای جدید را به منظور کشف پاداش‌های بالاتر بیازماید. در فضاهای وفقی بزرگ و گسسته (مانند شبکه DeltaIoT با ۴۰۹۶ پیکربندی ممکن)، طراحی راهبرد کاوش به یک چالش بسیار پیچیده‌ی ریاضی تبدیل می‌شود.

روش‌های کاوش سنتی نظیر ϵ-greedy یا کاوش بولتزمن[۳۸] در فضاهای با ابعاد بالا به شدت ناکارآمد هستند [۳۵، ۴۰]. در راهبرد ϵ-greedy، عامل با احتمال ϵ اقدام بعدی خود را به صورت کاملاً تصادفی انتخاب می‌کند. هنگامی که تعداد اقدامات ممکن $A = ۴۰۹۶$ باشد، احتمال انتخاب یک اقدام وفقی مفید در میان انبوهی از اقدامات غیربهینه یا مخرب، بسیار ناچیز است. در نتیجه، بخش عمده‌ای از گام‌های کاوش عامل صرف بررسی گزینه‌هایی می‌شود که کیفیت خدمات را به شدت کاهش داده و پایداری سیستم را به مخاطره می‌اندازند. این امر منجر به افت شدید «کارایی نمونه»[۳۹] شده و سرعت همگرایی آنلاین را تا حد غیرقابل‌تحملی کاهش می‌دهد.

استفاده از روش‌های پیشرفته‌تر مانند حد بالای اطمینان (UCB)[۴۰] نیز در محیط‌های زمان اجرا با عدم قطعیت پویا با مشکل مواجه است؛ زیرا ارزیابی مستمر عدم قطعیتِ تک‌تکِ اقدامات در فضاهای بسیار بزرگ، سربار محاسباتی شدیدی را به کنترل‌کننده زمان اجرا تحمیل می‌کند [۶]. از این رو، سیستم‌های خودوفق هوشمند نیازمند یک راهبرد کاوش هدایت‌شده هستند که بدون نیاز به نمونه‌برداری تصادفی کورکورانه، عامل را به سمت مناطق امیدبخش فضای وفقی هدایت نماید.

[38] Boltzmann Exploration

[39] Sample Efficiency

[40] Upper Confidence Bound

۳-۴-۲ ناکارآمدی سازوکار بازپخش تجربه با نگاه به گذشته در محیط‌های آستانه‌محور

سازوکار بازپخش تجربه با نگاه به گذشته (HER)[41] که توسط آندریچویچ[42] و همکارانش [۱۶] معرفی شد، یکی از برجسته‌ترین پیشرفت‌ها در زمینه حل مسئله‌ی پاداش‌های پراکنده[43] است. ایده کلیدی در HER، برچسب‌گذاری مجدد هدف[44] برای تجربیات ناموفق است. به طور مشابه، رویکرد پاداش نرم‌تر (Soft HER) توسعه‌یافته توسط هه[45] و همکارانش [۱۷] تلاش نمود تا فرآیند برچسب‌گذاری مجدد را با استفاده از پاداش‌های ملایم‌تر سرعت بخشد.

با این وجود، بر اساس تحلیل تئوریک ارائه شده در این رساله، استدلال می‌کنیم که این سازوکارها دارای یک **تناقض و ناسازگاری بنیادین با پارادایم خودوفقی** هستند:

- **طراحی هدف‌محور[46] در برابر ماهیت آستانه‌محور:**[47]

الگوریتم HER به طور ذاتی برای محیط‌های هدف‌محور طراحی شده است؛ محیط‌هایی که در آن‌ها هدف عامل، رسیدن به یک مختصات یا وضعیت فیزیکی مشخص و صریح (مانند مکان سه بعدی بازوی رباتیک $g \in G$) است. در این سناریوها، اگر عامل نتواند به هدف g برسد، HER وضعیت نهایی تجربه شکست‌خورده (s') را به عنوان هدف فرضی در نظر گرفته و پاداش مثبتی به آن اختصاص می‌دهد.

- **فقدان نقطه هدف صریح در سیستم‌های خودوفق:** اهداف سیستم‌های خودوفق به ندرت به صورت یک نقطه وضعیت واحد فرموله می‌شوند. در مقابل، این اهداف همواره **آستانه‌محور** هستند. برای مثال، هدف سیستم کنترلی شبکه DeltaIoT، نگه‌داشتن میزان تأخیر در کمتر از ۱۰۰ میلی‌ثانیه و مصرف انرژی در کمتر از ۲ وات است. در این حالت، هدف یک نقطه مشخص نیست، بلکه زیرمجموعه وسیعی از فضا است که قیود آستانه‌ای را ارضا می‌سازد.

- **عدم امکان برچسب‌گذاری مجدد:** هنگامی که یک عامل در زمان اجرا شکست می‌خورد (مثلاً تأخیر شبکه به ۱۵۰ میلی‌ثانیه می‌رسد و آستانه نقض می‌شود)، هیچ مختصات یا وضعیت واحدی وجود ندارد که بتوان شکست را به عنوان یک «هدف جایگزین معتبر» برچسب‌گذاری مجدد کرد. نقض آستانه اساساً به معنای ناامنی و افت کیفیت خدمات است و تعریف یک «آستانه مجازی نقض‌شده» به عنوان هدف جدید در یادگیری با نگاه به گذشته، از نظر مهندسی و ریاضیاتی فاقد اعتبار بوده و ایمنی و ثبات کنترل‌کننده را به طور کامل نابود می‌سازد.

---

[41] Hindsight Experience Replay
[42] Marcin Andrychowicz
[43] Sparse Rewards
[44] Goal Relabeling
[45] Qiyang He
[46] Goal-Conditioned
[47] Threshold-Based

از این رو، روش‌های مبتنی بر هدف مانند HER و Soft HER عملاً قابلیت کاربرد در کنترل‌کننده‌های خودوفق آستانه‌محور را ندارند[۴۸].

۳-۴-۳ مبانی نظری و ریاضیاتی شکل‌دهی پاداش

شکل‌دهی پاداش[۴۹] رویکردی قدرتمند در نظریه یادگیری تقویتی برای تسریع همگرایی عامل از طریق افزودن یک سیگنال پاداش کمکی[۵۰] به پاداش اصلی محیط است. از نظر ریاضیاتی، پاداش شکل‌دهی‌شده زمان اجرا به صورت زیر تعریف می‌شود:

$$R_{shaped}(s,a,s') = R_{env}(s,a,s') + F(s,a,s') \qquad (۱-۳)$$

که در آن R_{env} پاداش حاصل از دینامیک محیط و $F(s,a,s')$ پاداش کمکی شکل‌دهی است.

نگ و همکارانش[۵۱] در پژوهش کلاسیک خود [۴۱] اثبات ریاضیاتی ارائه‌دادند که نشان می‌دهد شکل‌دهی پاداش کورکورانه می‌تواند منجر به بروز پدیده «چرخه‌های بهینگی کاذب»[۵۲] شود؛ وضعیتی که در آن عامل یاد می‌گیرد برای دریافت پاداش کمکی بیشتر، کارهای تکراری و بی‌فایده انجام دهد بدون آنکه به هدف اصلی محیط برسد. آن‌ها اثبات کردند که برای تضمین ثبات و حفظ سیاست بهینه محیط[۵۳]، پاداش کمکی F باید حتماً به صورت تفاضل پتانسیل یک تابع حالت پایه‌ریزی شود. این روش تحت عنوان شکل‌دهی پاداش مبتنی بر پتانسیل (PBRS)[۵۴] شناخته می‌شود [۴۱] و فرمولاسیون ریاضی آن به شرح زیر است:

$$F(s,a,s') = \gamma\Phi(s') - \Phi(s) \qquad (۲-۳)$$

که در آن γ ضریب تخفیف مارکوف و $\Phi(s)$ تابع پتانسیل حالت s است. بر اساس قضیه ریاضی نگ، هرگاه پاداش شکل‌دهی دارای این فرمولاسیون باشد، مجموعه سیاست‌های بهینه عامل π^* تحت پاداش شکل‌دهی‌شده دقیقاً با مجموعه سیاست‌های بهینه تحت پاداش اصلی یکسان خواهد بود[۵۵].

[۴۸] با این حال، در سیستم‌های خودوفق آستانه‌محور، استفاده از توابع هدف صریح یا پتانسیل‌های ثابت با چالش ناسازگاری مواجه است. این ناسازگاری یکی از شکاف‌های تحقیقاتی اصلی این رساله را تشکیل می‌دهد. راهکار پیشنهادی RS-DRL در فصل ۴ (بخش ۴-۵) با سازوکار شکل‌دهی تصادفی پاداش (بدون نیاز به هدف صریح) به این چالش پاسخ می‌دهد. نتایج تجربی برتری آن نسبت به HER در فصل ۵ (جداول ۵-۴ و ۵-۵) تأیید شده است.

[49] Reward Shaping

[50] Auxiliary Reward Signal

[51] Andrew Y. Ng, Daishi Harada, and Stuart Russell

[52] Suboptimal Loops

[53] Policy Invariance

[54] Potential-Based Reward Shaping

[۵۵] قضیه نگ [۴۱] شرط کافی برای حفظ سیاست بهینه را ارائه می‌دهد، اما فرض می‌کند تابع پتانسیل Φ ایستا است. در سیستم‌های خودوفق با رانش مفهومی، این فرض نقض می‌شود. سازوکار شکل‌دهی تصادفی RS-DRL (فصل ۴، بخش ۴-۵)

نقد و بررسی انتقادی: اگرچه PBRS چارچوب ریاضی مستحکمی برای تضمین حفظ سیاست بهینه ارائه می‌دهد، اما استقرار آن در سیستم‌های خودوفق واقعی با مانع بزرگی مواجه است. محدودیت نخست، **ایستا بودن تابع پتانسیل در محیط‌های پویا** است؛ در طراحی سنتی PBRS [۴۱]، تابع پتانسیل $\Phi(s)$ به صورت کاملاً ایستا[۵۶] در زمان طراحی سیستم بر اساس دانش تجربی کارشناسان دامنه تعریف می‌شود. محدودیت دوم، **عدم انطباق با رانش مفهومی و شرایط پویای آنلاین** است؛ در یک سیستم خودوفق تحت تأثیر عدم قطعیت مستمر (رانش مفهومی)، پتانسیل واقعی حالت‌ها دائماً تغییر می‌کند. یک پتانسیل ایستای تعریف‌شده در زمان طراحی، قادر به بازتاب پویایی‌های پیش‌بینی‌نشده زمان اجرا نیست و در شرایط جدید، پاداش‌های کمکی گمراه‌کننده‌ای تولید می‌کند که سرعت یادگیری عامل را به شدت کاهش داده یا همگرایی آنلاین را مختل می‌سازد [۹].

این نقیصه بنیادین تئوریک، ضرورت ابداع یک فرآیند شکل‌دهی تصادفی و پویای پاداش (همچون الگوریتم پیشنهادی RS-DRL در این رساله) را آشکار می‌سازد تا پتانسیل حالت‌ها را به صورت زمان اجرا و آنلاین بر اساس تضمین‌های کیفی محاسبات صوری تنظیم نماید.

۳-۵ ارزیابی و تایید صوری در فرآیند خودوفق‌سازی

تضمین ایمنی و ارضای کیفیت خدمات در سیستم‌های خودوفق، به ویژه در حوزه‌های حساس، نیازمند ابزارهای صوری مستحکم است. ارزیابی و تأیید صوری زمان اجرا[۵۷] به عنوان پارادایمی مطرح است که به سیستم اجازه می‌دهد تا به صورت ریاضیاتی و دقیق، صحت تصمیمات خود را پیش از اعمال به سیستم واقعی ارزیابی کند. در این بخش، مبانی نظری تأیید صوری کمّی زمان اجرا، ابزارها و چارچوب‌های شاخص نظیر ActivFORMS و UPPAAL-SMC و در نهایت معماری‌های ترکیبی ترادف صوری‌ـ یادگیری را مورد تحلیل انتقادی قرار می‌دهیم.

۳-۵-۱ تأیید صوری کمّی زمان‌اجرا و چارچوب‌های ActivFORMS

تأیید صوری کمّی زمان اجرا (QVR)[۵۸] که توسط پیشگامانی نظیر کالینسکو[۵۹] و همکارانش [۴۲] و وینز [۳۲] توسعه یافت، فرآیندی است که در آن مشخصات غیرعملکردی سیستم (مانند کارایی، استواری و مصرف انرژی) در زمان اجرا با استفاده از مدل‌های ریاضی احتمالات ارزیابی می‌شوند. در این پارادایم، پویایی‌های سیستم و عدم قطعیت‌های محیطی معمولاً به صورت زنجیره‌های مارکوف زمان‌گسسته (DTMC)[۶۰]

نیازی به تابع پتانسیل ایستا ندارد و بنابراین از این محدودیت تئوریک عبور می‌کند.

[56] Static Potential Function

[57] Runtime Formal Verification

[58] Quantitative Verification at Runtime

[59] Radu Calinescu

[60] Discrete-Time Markov Chain

یا فرآیندهای تصمیم‌گیری مارکوف مدل‌سازی می‌شوند و اهداف کیفی سیستم با استفاده از منطق‌های زمانی احتمالات نظیر منطق زمانی محاسبات احتمالات (PCTL)[۶۱] فرموله می‌گردند:

$$P_{\geq ۰/۹۵}[F^{\leq t}(\text{PacketLoss} < ۰/۱)] \qquad (۳-۳)$$

که تضمین می‌کند با احتمال حداقل ۹۵ درصد، نرخ گم‌شدن بسته‌ها در طول پنجره زمانی t کمتر از ۱۰ درصد باقی بماند.

در میان چارچوب‌های عملیاتی ارزیابی صوری، چارچوب ActivFORMS[۶۲] معرفی‌شده توسط وینز و همکاران [۴۳] برجسته‌ترین الگوی استقرار موتورهای صوری زمان اجرا درون حلقه MAPE-K است. این چارچوب تضمین می‌کند که فرآیند وفقی همواره با مدل‌های صوری اعتبارسنجی‌شده مطابقت داشته و رفتارهای غیرایمن در سیستم رخ ندهند. با این حال، حل کامل و تحلیلی توابع احتمالاتی در زمان اجرا به شدت پرهزینه است. برای عبور از این محدودیت، ابزار بررسی مدل آماری (SMC)[۶۳] تحت موتور UPPAAL-SMC[۶۴] [۲۳] مورد توجه قرار گرفت. الگوریتم‌های SMC به جای حل فرمول‌های سنگین بر روی کل فضای حالت، از شبیه‌سازی‌های تصادفی هوشمند و آزمون‌های فرض متوالی والد (SPRT)[۶۵] بهره می‌گیرند که ارضای یا عدم ارضای خواص را با سطح اطمینان مشخص (α, β) با سرعت به مراتب بالاتری تعیین می‌کند.

۳-۵-۲ معماری‌های ترکیبی یادگیری و ارزیابی صوری (مدل‌های ترادف)

با آشکار شدن قدرت مقیاس‌پذیری یادگیری ماشین و امنیت بالای روش‌های صوری، محققان در سال‌های اخیر به سمت توسعه معماری‌های ترکیبی متمایل شده‌اند که در ادبیات علمی به عنوان رویکردهای ترادف[۶۶] شناخته می‌شوند. پژوهش کامارا و همکارانش [۳۹] نمونه شاخصی از این معماری‌هاست. در این رویکردها، عامل یادگیری تقویتی وظیفه هدایت سیستم و یادگیری سیاست‌های وفقی را بر عهده دارد، در حالی که ماژول ارزیابی صوری زمان اجرا به عنوان یک فیلتر ایمنی زمان اجرا عمل می‌کند. هرگاه اقدام پیشنهادی عامل یادگیرنده از نظر صوری ناامن تشخیص داده شود، فیلتر صوری آن را بلاک کرده و سیستم را مجبور به انتخاب گزینه‌ای ایمن می‌نماید.

نقد و بررسی انتقادی: اگرچه معماری‌های ترادفی کلاسیک گام بزرگی رو به جلو هستند، اما کماکان دارای یک نقطه ضعف عملیاتی جدی هستند که مانع از استقرار آن‌ها در بسترهای اینترنت اشیا بزرگ می‌گردد. نقطه ضعف اول، **سربار شدید ارزیابی صوری در فضاهای وفقی بزرگ** است؛ بررسی مدل صوری، حتی با

[61] Probabilistic Computation Tree Logic

[62] Active Formal Models for Self-Adaptation

[63] Statistical Model Checking

[۶۴] ابزار بررسی مدل آماری UPPAAL-SMC: https://uppaal.org/

[65] Abraham Wald's Sequential Probability Ratio Test

[66] Tandem Approaches

ابزار سبک UPPAAL-SMC، برای هر یک از گزینه‌های تصمیم‌گیری زمان اجرا مستلزم چند صد بار شبیه‌سازی تصادفی است. در صورتی که عامل یادگیرنده بخواهد در یک فضای بزرگ (مثلاً با ۴۰۹۶ گزینه وفقی) کاوش کند، ارزیابی صوری تمامی این گزینه‌ها زمان تصمیم‌گیری حلقه MAPE-K را به شدت افزایش داده (تا چندین دقیقه) و عملاً کارکرد آنلاین سیستم را با اختلال جدی مواجه می‌سازد. نقطه ضعف دوم، **ایستا بودن فیلتر ایمنی صوری** است؛ فیلترهای صوری کلاسیک رفتاری صفر و یکی دارند و نمی‌توانند بازخورد کیفی دقیقی به عامل یادگیرنده ارائه دهند تا او سرعت یادگیری خود را بهبود بخشد.

این نقد اساسی، ضرورت وجود یک معماری جدید مانند RS-DRL را اثبات می‌کند[۶۷]؛ معماری خاصی که در آن ماژول صوری UPPAAL-SMC به جای ایفای نقش به عنوان فیلتر نهایی سنگین برای تمامی گزینه‌ها، به صورت ناهمگام[۶۸] برای محاسبه‌ی صوری متغیرهای پتانسیل یادگیری و شکل‌دهی تصادفی پاداش به کار گرفته شود. این کار موازنه بهینه‌ای بین مقیاس‌پذیری تصمیم‌گیری عمیق و تضمین‌های ریاضی روش‌های صوری برقرار می‌سازد.

۳-۶ سنتز: شکاف تحقیقاتی سه‌گانه و موقعیت‌دهی علمی RS-DRL

بر اساس نقد و بررسی‌های انجام‌شده در بخش‌های پیشین، مشخص می‌گردد که هر یک از رویکردهای کلاسیک و مدرن مدیریت فضای وفقی در سیستم‌های خودوفق، از مزایای متمایزی برخوردار بوده و همزمان با محدودیت‌های بنیادین تئوریک و عملی مواجه هستند. به منظور جمع‌بندی دقیق وضعیت هنر، در ادامه ابتدا یک ماتریس ارزیابی چندبعدی ارائه گردیده و سپس شکاف‌های تحقیقاتی موجود تبیین می‌شوند.

۳-۶-۱ ماتریس ارزیابی و سنتز پیشینه پژوهش

در جدول ۳-۱، پارادایم‌های اصلی موجود در پیشینه پژوهش بر اساس چارچوب ارزیابی پنج‌بعدی پیشنهادی به همراه روش پیشنهادی این رساله، RS-DRL، مورد مقایسه و ارزیابی تطبیقی قرار گرفته‌اند.

۳-۶-۲ شکاف تحقیقاتی سه‌گانه

با متقاطع‌سازی ابعاد ارزیابی و چالش‌های عملیاتی احصاءشده از پیشینه پژوهش، **شکاف تحقیقاتی سه‌گانه‌ای** که این رساله بر حل آن‌ها تمرکز دارد به شرح زیر صورت‌بندی می‌شود:

۱. **شکاف اول: تقابل مقیاس‌پذیری و پایداری زمانی تصمیم‌گیری:**[۶۹] در سیستم‌های خودوفق با فضاهای

[۶۷] معماری RS-DRL با جداسازی زمانی که در فصل ۴ (بخش‌های ۴-۲ و ۴-۴) تشریح شده است، این مشکل را حل می‌کند: ارزیابی صوری به صورت موازی و ناهمگام در پس‌زمینه انجام می‌شود و مسیر تصمیم‌گیری آنلاین را مسدود نمی‌کند. شکل ۴-۲ و شکل ۴-۳ در فصل ۴ این معماری غیرانسدادی را نشان می‌دهند.

[68] Asynchronous Background Verification

[69] Scale-Latency Dilemma

جدول ۳-۱: مقایسه تطبیقی پارادایم‌های مدیریت فضای وفقی زمان اجرا بر اساس چارچوب ارزیابی پنج‌بعدی (برگرفته از تحلیل کارهای پیشین نظیر [۱۰، ۱۲، ۳۵، ۹])

پارادایم / رویکرد	مدیریت ابعاد بزرگ (مقیاس‌پذیری)	استواری در برابر تغییرات آنلاین	استقلال از داده و پیش‌آموزش	کارایی محاسباتی آنلاین	فرار از تله بهینه‌های محلی
هرس مبتنی بر یادگیری ماشین [۷، ۳۶]	متوسط	ضعیف (به علت رانش مفهومی)	ضعیف (نیازمند برچسب‌گذاری آفلاین)	عالی (میلی‌ثانیه)	غیرقابل اعمال (فقط هرس می‌کند)
جستجوی آنلاین تکاملی [۱۰، ۳۷، ۳۸]	ضعیف (انفجار زمان محاسبه)	متوسط	عالی (بدون نیاز به پیش‌آموزش)	ضعیف (ثانیه/دقیقه)	متوسط (به واسطه جهش‌های تصادفی)
یادگیری تقویتی عمیق سنتی [۱۳، ۳۵]	متوسط تا عالی	متوسط	عالی (یادگیری آنلاین مدل‌فردا)	عالی (کمتر از چند میلی‌ثانیه)	ضعیف (به علت کاوش کورکورانه ϵ-greedy)
تأیید صوری زمان اجرا [۴۳، ۳۹]	بسیار ضعیف (انفجار فضا)	عالی (تضمین ریاضی پایداری)	عالی	بسیار ضعیف (سربار شدید محاسبات صوری)	متوسط (تنها ایمنی را بررسی می‌کند)
روش پیشنهادی (RS-DRL)	**عالی (استفاده از شبکه عمیق بدون فیلتر انسدادی آنلاین)**	**عالی (انطباق با تغییرات به واسطه پتانسیل پویا)**	**عالی (یادگیری کاملاً آنلاین و مدل‌فردا)**	**عالی (کمتر از چند میلی‌ثانیه برای استنتاج)**	**عالی (به واسطه شکل‌دهی پویای پاداش صوری)**

وفقی بزرگ (بیش از ۱۰۰۰ گزینه)، رویکردهایی که از ارزیابی‌های صوری دقیق زمان اجرا یا جستجوهای تکاملی استفاده می‌کنند، با چالش جدی انفجار محاسباتی مواجه هستند که زمان تصمیم‌گیری را به مقیاس دقیقه افزایش می‌دهد. در مقابل، روش‌های یادگیری ماشین و شبکه‌های عمیق زمان استنتاج میلی‌ثانیه‌ای دارند اما فاقد هرگونه تضمین ریاضی ثبات و ایمنی آنلاین هستند. تا کنون سازوکاری خلاقانه که بتواند بدون تحمیل سربار محاسباتی صوری به مسیر استنتاج آنلاین، تضمین‌های صوری ریاضی را به یادگیری عمیق تزریق کند، ارائه نشده است.

۲. **شکاف دوم: ناسازگاری با اهداف آستانه‌محور:**[۷۰] الگوریتم‌های پیشرفته یادگیری برای پاداش‌های پراکنده (مانند HER و Soft HER) منحصراً برای محیط‌های «هدف‌محور» طراحی شده‌اند که عامل در آن‌ها به دنبال رسیدن به مختصاتی معین است. این در حالی است که اهداف سیستم‌های خودوفق معاصر ماهیت «آستانه‌محور» (مانند نگه‌داشتن مصرف انرژی زیر یک مقدار مشخص) دارند. این ناسازگاری تئوریک باعث می‌شود که در صورت بروز نقض آستانه، برچسب‌گذاری مجدد با نگاه به گذشته فاقد اعتبار ریاضی گشته و عملاً کارایی خود را در هدایت کاوش آنلاین سیستم‌های خودوفق از دست بدهد.

۳. **شکاف سوم: ایستایی توابع پتانسیل در مواجهه با پویایی‌های نویزی آنلاین:**[۷۱] روش‌های ریاضیاتی شکل‌دهی پاداش مبتنی بر پتانسیل [۴۱] که ثبات سیاست بهینه را تضمین می‌کنند، به صورت سنتی نیازمند یک تابع پتانسیل $\Phi(s)$ کاملاً ایستا هستند که در زمان طراحی توسط کارشناس خبره تعریف می‌شود. در حضور عدم قطعیت‌های شدید زمان اجرا و رانش مفهومی محیط، این توابع ایستای زمان طراحی کارایی خود را از دست داده و حتی ممکن است با ارائه پاداش‌های نادرست، همگرایی آنلاین عامل را مختل سازند. خلأ شدیدی در زمینه سیستم‌های شکل‌دهی پویای پتانسیل وجود دارد که بتوانند پتانسیل حالت‌ها را به صورت پویا بر اساس بازخوردهای صوری آنلاین به‌روزرسانی کنند.

۳-۶-۳ موقعیت‌دهی علمی معماری پیشنهادی RS-DRL

معماری پیشنهادی این رساله، تحت عنوان **یادگیری تقویتی عمیق شکل‌دهی‌شده با بررسی صوری زمان اجرا**، به عنوان راهکاری جامع برای پل زدن بر این شکاف‌های سه‌گانه طراحی و موقعیت‌دهی شده است. نوآوری‌های کلیدی این رویکرد به شرح زیر با شکاف‌های تحقیقاتی متناظر همخوانی دارند:

- **پاسخ به شکاف اول (تقابل سرعت و امنیت):** معماری RS-DRL فرآیند زمان‌بر ارزیابی صوری زمان اجرا را از مسیر مستقیم تصمیم‌گیری آنلاین عامل یادگیرنده خارج ساخته و آن را به صورت **غیرهمگام** در پس‌زمینه اجرا می‌کند. عامل برای تصمیم‌گیری صرفاً شبکه عمیق را در کمتر از ۱ میلی‌ثانیه استنتاج

[70] Goal-Threshold Mismatch

[71] Static-Dynamic Potential Gap

می‌کند، در حالی که ماژول صوری تصادفی UPPAAL-SMC به صورت موازی پتانسیل‌های یادگیری را به‌روزرسانی می‌کند. این معماری برای اولین بار به طور همزمان مقیاس‌پذیری تصمیم‌گیری عمیق آنلاین و استواری صوری ریاضیاتی را تضمین می‌نماید.

- **پاسخ به شکاف دوم (یادگیری آستانه‌محور):** در RS-DRL، به جای به‌کارگیری روش‌های هدف‌محور ناکارآمد مانند HER، سیستم با ترکیب پاداش محیط و پاداش کمکی صوری هدایت می‌شود. این پاداش کمکی به طور دقیق شدت ارضای آستانه‌ها را منعکس کرده و بدون نیاز به تعریف مختصات هدف صریح، امنیت کاوش عامل را در فضاهای آستانه‌محور تضمین می‌نماید.

- **پاسخ به شکاف سوم (شکل‌دهی پویا):** نوآوری بنیادین ریاضیاتی در RS-DRL، معرفی راهبرد **شکل‌دهی پویای پاداش مبتنی بر بررسی صوری زمان اجرا** است. در این روش، تابع پتانسیل دیگر ایستا نیست، بلکه به عنوان یک متغیر پویای تصادفی آنلاین فرموله‌بندی شده و مقادیر آن به طور مستمر بر اساس خروجی‌های کمّی حاصل از تحلیل‌های آماری UPPAAL-SMC به‌روزرسانی می‌گردند. این سازوکار انطباق کامل عامل با رانش مفهومی و نویز محیط را بدون ابطال تئوریک سیاست بهینه رقم می‌زند.

جدول ۳-۲ خلاصه‌ای از نحوه پوشش شکاف‌های تحقیقاتی توسط نوآوری‌های RS-DRL را نمایش می‌دهد.

جدول ۳-۲: نحوه پوشش شکاف‌های تحقیقاتی توسط نوآوری‌های معماری پیشنهادی RS-DRL

شکاف تحقیقاتی	محدودیت روش‌های کلاسیک	راهکار و نوآوری ارائه شده در RS-DRL
شکاف اول (سرعت و امنیت)	تأخیر طولانی مدل‌چکینگ زمان اجرا در فضاهای بزرگ	ارزیابی صوری ناهمگام و استنتاج میلی‌ثانیه‌ای آنلاین شبکه عمیق
شکاف دوم (یادگیری آستانه‌محور)	عدم امکان استفاده از روش‌های برچسب‌گذاری مجدد هدف (HER)	هدایت عامل به کمک پاداش‌های کمکی صوری سنجش کیفیت و آستانه
شکاف سوم (شکل‌دهی پویا)	ایستایی توابع پتانسیل شکل‌دهی پاداش در محیط‌های متغیر آنلاین	شکل‌دهی پویای پاداش با به‌روزرسانی آنلاین پتانسیل‌ها به وسیله بازخورد صوری زمان اجرا

۳-۷ خلاصه فصل

در این فصل، مرور عمیق و منسجمی بر مبانی نظری و پیشینه پژوهش مرتبط با فرآیندهای خودوفق‌سازی در سیستم‌های نرم‌افزاری و شبکه‌های توزیع‌شده پیشرفته صورت گرفت. مسیر تحلیل پیشینه با تبیین ماهیت معماری‌های خودوفق مبتنی بر حلقه MAPE-K و چالش بنیادین انفجار فضای پیکربندی در سیستم‌های مقیاس‌بزرگ آغاز گردید. سپس، رویکردهای موجود در وضعیت هنر در قالب چهار پارادایم اصلی طبقه‌بندی و مورد بررسی انتقادی قرار گرفتند: هرس مبتنی بر یادگیری ماشین سنتی، جستجوی آنلاین تکاملی، یادگیری تقویتی عمیق بدون مدل و تأیید صوری زمان اجرا.

با اعمال یک چارچوب ارزیابی پنج‌بعدی پیشنهادی بر پیشینه پژوهش، مشخص گردید که هیچ‌یک از روش‌های کلاسیک قادر به حل همزمان چالش‌های مقیاس‌پذیری، کارایی محاسباتی آنلاین، استواری در برابر رانش مفهومی و تضمین‌های ریاضیاتی ایمنی نیستند. این تحلیل انتقادی به صورت‌بندی دقیق **شکاف تحقیقاتی سه‌گانه‌ای** منجر شد که محور تمرکز علمی این رساله را تشکیل می‌دهد:

۱. **تقابل مقیاس‌پذیری و پایداری زمانی تصمیم‌گیری:** ناشی از سربار زمانی شدید مدل‌چکینگ آنلاین صوری در فضاهای پیکربندی بزرگ.

۲. **عدم تطابق سازوکارهای نگاه به گذشته با اهداف آستانه‌محور خودوفقی:** به دلیل محدودیت ذاتی الگوریتم‌هایی مانند HER که منحصراً برای فضاهای وفقی مختصات‌محور و غایت‌محور توسعه یافته‌اند.

۳. **ایستایی توابع پتانسیل شکل‌دهی پاداش:** که با ماهیت نویزی و دائماً در حال تغییر عدم قطعیت‌های آنلاین زمان اجرا ناسازگار است.

در نهایت، موقعیت‌دهی علمی روش پیشنهادی این رساله، RS-DRL، به عنوان پاسخ و راهکاری یکپارچه برای پوشش هر سه شکاف فوق تبیین شد. بنابراین، یافته‌های تحلیلی این فصل به طور قاطع تأیید می‌کنند که هیچ‌یک از رویکردهای موجود در پیشینه پژوهش قادر به ارضای همزمان الزامات سه‌گانه (سرعت میلی‌ثانیه‌ای، انطباق‌پذیری با پویایی زمان اجرا، و تضمین صوری ایمنی ریاضی) نیستند و معماری پیشنهادی RS-DRL دقیقاً برای پر کردن این شکاف بنیادین علمی موقعیت‌دهی شده است.

خلاصه یافته‌های کلیدی فصل سوم (مرور پیشینه پژوهش):

- **ناکارآمدی فیلترهای صوری آنلاین:** فیلترهای صوری زمان اجرا به صورت مستقیم در مسیر تصمیم‌گیری باعث سربار محاسباتی شدید (در حد دقیقه) برای فضاهای وفقی بزرگ می‌گردند [۳۹، ۴۲].
- **انفجار فضای حالت در تکامل آنلاین:** روش‌های جستجوی تصادفی و تکاملی آنلاین فاقد توانایی تصمیم‌گیری بلادرنگ در مقیاس میلی‌ثانیه هستند [۱۰، ۱۲].
- **شکست روش‌های HER در سناریوهای SLA:** الگوریتم‌های برچسب‌گذاری مجدد هدف به علت تعاریف مبتنی بر فیزیک مختصاتی، در برابر آستانه‌های کیفی سیستم‌های خودوفق فاقد کارایی علمی می‌باشند.
- **ضرورت معماری ترادف ناهمگام:** تلفیق ناهمگام یادگیری عمیق و بررسی صوری آماری UPPAAL-SMC به عنوان تنها راهکار تأمین همزمان کارایی آنلاین و تضمین‌های ریاضیاتی ایمنی شناسایی شد.

پل مفهومی به فصل بعد (بیانیه پل): با استقرار بستر نظری مستحکم در این فصل و صورت‌بندی دقیق نقاط ضعف و شکاف‌های پیشینه، مسیر برای تشریح جزئیات فنی و عملیاتی روش‌شناسی دوسطحی پیشنهادی هموار گردیده است. بر این اساس، در **فصل چهارم** به تبیین دقیق معماری و سازماندهی فرآیند اجرایی الگوریتم RS-DRL خواهیم پرداخت. در آن فصل، فرمول‌بندی ریاضیاتی شکل‌دهی پویای پاداش صوری، نحوه ارتباط ناهمگام میان عامل یادگیری تقویتی عمیق و ماژول بررسی صوری احتمالات UPPAAL-SMC و در نهایت، تضمین همگرایی تئوریک سیستم تحت شرایط نویزی زمان اجرا تشریح خواهند شد تا نشان داده شود چگونه معماری پیشنهادی قادر است موازنه بهینه‌ای بین سرعت میلی‌ثانیه‌ای آنلاین و ایمنی صوری ریاضیاتی برقرار سازد.

فصل چهارم

روش پیشنهادی

۴-۱ مقدمه

طراحی و توسعه سیستم‌های نرم‌افزاری خودوفق در محیط‌های عملیاتی پویا و توأم با عدم قطعیت، مستلزم برقراری موازنه میان دو دغدغه متضاد مهندسی است: تصمیم‌گیری بلادرنگ و کم‌تأخیر در مقیاس میلی‌ثانیه جهت همگامی با تغییرات محیطی، و ارائه تضمین‌های صوری و ریاضیاتی مبتنی بر ایمنی و انطباق با اهداف کیفیت خدمات (QoS)[1]. همان‌طور که در تحلیل پیچیدگی فصل دوم (بخش ۲-۶) و بررسی پیشینه پژوهش در فصل سوم (بخش ۳-۶-۲) اثبات شد، روش‌های پیشین بهینه‌سازی مبتنی بر جستجو و وارسی مدل آنلاین به دلیل پیچیدگی ان‌پی‌ـ‌سخت [۲۸، ۱۰] و زمان‌های محاسباتی طولانی، در فضاهای وفقی بزرگ با شکست مواجه می‌شوند.

از سوی دیگر، اگرچه یادگیری تقویتی عمیق (DRL)[2] زمان استنتاج آنلاین را به مرتبه زیر میلی‌ثانیه می‌رساند، اما به‌کارگیری آن در سیستم‌های خودوفق با دو مانع اساسی روبه‌روست: نخست، «تنکی پاداش»[3] [۴۰] و رانش مفهومی [۹] که عامل را در فضاهای پیکربندی بزرگ در بهینه‌های محلی متوقف می‌سازند؛ و دوم، فقدان تضمین‌های صوری زمان اجرا. این چالش‌ها انگیزه اصلی توسعه چارچوب پایه‌ای RS-DRL[4] بر پایه شکل‌دهی تصادفی پاداش و اعتبارسنجی صوری غیرانسدادی در سیستم‌های نرم‌افزاری توزیع‌شده نظیر شبکه حسگر DeltaIoT را شکل می‌دهند.

با این حال، با گسترش دامنه کاربرد به **سیستم‌های فیزیکی‌ـ‌سایبری حساس و بلادرنگ**، که ناوبری خودگردان در بستر DARTSim نمونه‌ای ملموس از آن است، فرآیند تصمیم‌گیری خودوفق با یک «سه‌گانه برنامه‌ریزی بلادرنگ» مواجه می‌گردد که فراتر از توانمندی‌های چارچوب پایه‌ای است: نخست، **مهلت‌های**

[1] Quality of Service

[2] Deep Reinforcement Learning

[3] Reward Sparsity

[4] Randomized Reward-Shaped Deep Reinforcement Learning

زمانی سخت در حلقه‌های کنترل فیزیکی، فرصت اجرای الگوریتم‌های سنگین جستجو و وارسی مدل آنلاین را سلب کرده و پاسخ‌گویی قطعی در بازه‌های زمانی بسیار محدود را الزامی می‌سازد؛ دوم، در فرآیند آموزش آفلاین سیاست‌ها—که برای پرهیز از ریسک تخریب فیزیکی تجهیزات به کار می‌رود—**لاگ‌های عملیاتی مأموریت به شدت تحت غلبه داده‌های شکست و نقض قید** قرار دارند، امری که یادگیری تقویتی را با چالش واگرایی و گرایش به سیاست‌های انفعالی روبه‌رو می‌کند؛ و سوم، وجود **شکاف واقعیت**[5] میان مدل‌های جانشین تحلیلی و دینامیک پیچیده فیزیکی موجب می‌شود که سپرهای ایمنی ایستا در شرایط تنش شدید محیطی دچار خطای برآورد شده و قابلیت اعتماد خود را از دست بدهند. غلبه هم‌زمان بر این سه‌گانه بنیادین، مستلزم گذار از چارچوب پایه‌ای به معماری تعمیم‌یافته دوسطحی RS-DRL$^+$ است.

هدف اصلی این فصل، ارائه جزئیات فنی، معماری و ریاضیاتی روش‌های پیشنهادی رساله است. ساختار محتوایی این فصل بر پایه یک سیر تکاملی و سلسله‌مراتبی در قالب چهار بخش عمده سازمان‌دهی شده است:

- **بخش اول: معماری و سازوکارهای چارچوب پایه‌ای RS-DRL (بخش‌های ۴-۲ تا ۴-۷):** این بخش چارچوب پایه‌ای را در سیستم‌های توزیع‌شده با الزامات نرم کیفیت خدمات در بستر DeltaIoT توسعه می‌دهد. ارکان این بخش شامل تفکیک زمانی تصمیم‌گیری آنلاین از یادگیری پس‌زمینه (بخش ۴-۲)، ردیابی گام‌های اجرایی حلقه MAPE-K در سناریوهای ملموس (بخش ۴-۳)، تفکیک ساختار درونی برنامه‌ریز (بخش ۴-۴)، فرمول‌بندی شکل‌دهی تصادفی پاداش با پارامتر ρ جهت عبور از بهینه‌های محلی (بخش ۴-۵)، مدیریت هماهنگ مخزن دانش (بخش ۴-۶)، و اعتبارسنجی صوری غیرانسدادی UPPAAL-SMC[6] در مسیر بازخورد (بخش ۴-۷) است.

- **بخش دوم: چالش‌های گذار به سیستم‌های فیزیکی–سایبری و سه‌گانه برنامه‌ریزی (بخش ۴-۸):** این بخش به عنوان پل انتقال، محدودیت‌های روش پایه‌ای در مواجهه با سیستم‌های فیزیکی–سایبری را در قالب یک «سه‌گانه برنامه‌ریزی بلادرنگ» تبیین می‌کند: تنگنای مهلت‌های زمانی حلقه‌های کنترل، چالش عدم‌توازن و غلبه داده‌های شکست در لاگ‌های مأموریت، و خطای برآورد ناشی از شکاف واقعیت مدل‌های جانشین تحلیلی؛ امری که ضرورت گذار به معماری تعمیم‌یافته دوسطحی را اثبات می‌نماید.

- **بخش سوم: معماری تعمیم‌یافته دوسطحی RS-DRL$^+$ برای سیستم‌های فیزیکی–سایبری (بخش‌های ۴-۹ تا ۴-۱۱):** این بخش راهکار تکاملی رساله را برای سیستم‌های فیزیکی–سایبری حساس و بلادرنگ، با نمونه‌سازی در بستر DARTSim، در قالب یک سازماندهی دوسطحی آنلاین/آفلاین تبیین می‌نماید (بخش ۴-۹). در سطح آفلاین، الگوی سنتز هدایت‌شده با مشخصه‌ها (SG-OS)، فرآیند یادگیری تقویتی را با ارزیابی هم‌زمان حاشیه ایمنی و مطلوبیت مأموریت هدایت کرده و چالش وفور داده‌های شکست در لاگ‌ها را مهار می‌سازد (بخش ۴-۱۰). در سطح آنلاین، الگوی اعتبارسنجی

[5] Reality Gap

[6] ابزار بررسی مدل آماری UPPAAL-SMC: https://uppaal.org/

کشسان با بودجه زمانی مقید (CA-EPV)، ضمن تضمین استنتاج نامی در مقیاس زیر میلی‌ثانیه‌ای، با بهره‌گیری از زیرفضای حساسیت‌محور TreeSHAP[7] گزینه‌های انطباق را در مهلت‌های زمانی سخت ترمیم می‌کند (بخش ۴-۱۱). در نهایت، مبانی ریاضیاتی این معماری با اثبات صوری کران پیچیدگی محاسباتی (گزاره ۴-۱۱-۱) و تضمین عدم افت ایمنی تحت شکاف واقعیت (گزاره ۴-۱۱-۲) تحکیم می‌گردد.

- **بخش چهارم: نگاشت پرسش‌های پژوهش، تحلیل مفروضات و جمع‌بندی (بخش‌های ۴-۱۲ تا ۴-۱۴):** این بخش ابتدا مؤلفه‌های پیشنهادی را به صورت صوری بر پرسش‌های پژوهش (RQ1 تا RQ6) نگاشت می‌دهد (بخش ۴-۱۲)، سپس مفروضات پایه‌ای و محدودیت‌های عملیاتی روش را مورد واکاوی انتقادی قرار داده (بخش ۴-۱۳)، و در پایان به جمع‌بندی دستاوردهای روش‌شناسی فصل می‌پردازد (بخش ۴-۱۴).

۴-۲ معماری کلان چارچوب پایه‌ای RS-DRL و اصول فرآیندی انطباق

در بخش نخست از روش پیشنهادی، چارچوب پایه‌ای RS-DRL به عنوان بنیان معماری تصمیم‌گیری در سیستم‌های خودوفق با کیفیت خدمات نرم معرفی می‌شود. یک سیستم خودوفق کارآمد در محیط‌های همراه با عدم قطعیت، باید بین دغدغه‌های متضاد طراحی مانند تصمیم‌گیری آنلاین با تأخیر کم و محاسبات سنگین آموزش مدل‌های یادگیری، تفکیک قائل شود تا مسیر مستقیم کنترل آنلاین بدون وقفه و تأخیر مدیریت گردد. معماری پیشنهادی بر اساس دو اصل کلیدی ساختاریافته است: نخست، تفکیک زمانی تصمیم‌گیری آنلاین از محاسبات یادگیری در پس‌زمینه، و دوم، سازمان‌دهی مراحل انطباق در قالب یک خط لوله مشخص از جریان داده و فرامین کنترلی.

۴-۲-۱ مرزهای سیستم و تعامل با محیط پیرامون

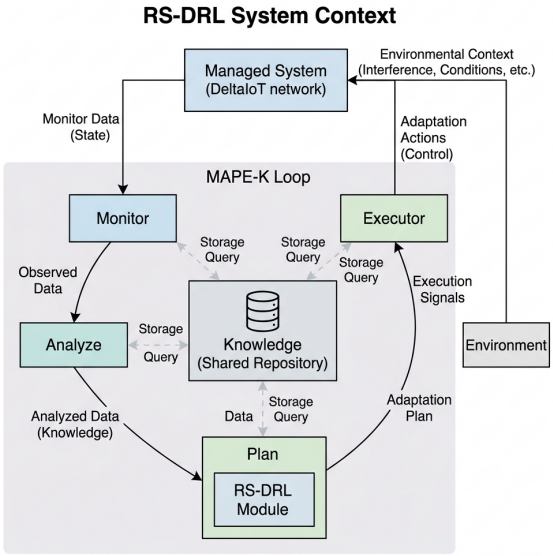
جهت تبیین مرزهای سیستم و تفکیک تعاملات آن با محیط پیرامون، نمای کلی تعاملات سیستم[8] در شکل ۴-۱ به عنوان شمای کلان معماری پایه RS-DRL ارائه شده است. این نمودار تعاملات ساختاری میان سیستم مدیریت‌شونده (نظیر شبکه حسگر DeltaIoT)، محیط عملیاتی، مؤلفه‌های پنج‌گانه حلقه MAPE-K[9] و مخزن دانش مشترک را نشان می‌دهد؛ به طوری که داده‌های پایش از حسگرهای سیستم مدیریت‌شونده دریافت شده، پس از تحلیل و برنامه‌ریزی توسط مؤلفه یادگیری تقویتی، طرح انطباق جهت اعمال به مؤلفه اجرا تحویل می‌گردد.

[7] Tree-based Shapley Additive Explanations

[8] System Context

[9] Monitor, Analyze, Plan, Execute over Shared Knowledge

از منظر مهندسی نرم‌افزار، مرزهای سیستم پیشنهادی به سه قلمرو متمایز با رابط‌های تبادل داده تفکیک می‌گردند: نخست، **مرز سیستم مدیریت‌شونده**[10] که شامل موجودیت‌های سخت‌افزاری و نرم‌افزاری هدف است و از طریق پروب‌های حسگری[11] داده‌های عملیاتی را به حلقه پایش ارسال کرده و از طریق عملگرها[12] فرامین بازپیکربندی زمان اجرا را اعمال می‌نماید. دوم، **مرز کنترل‌کننده خودوفق**[13] به عنوان هسته محاسباتی تصمیم‌گیری که دربرگیرنده مؤلفه‌های چهارگانه MAPE، ماژول استنتاج شبکه عصبی عمیق، موتور اعتبارسنجی صوری و مخزن دانش مشترک است. این مرز به عنوان یک لایه ایزوله، وظیفه پردازش، برنامه‌ریزی و سنتز سیاست را بر عهده دارد. سوم، **کانال تعامل با محیط عملیاتی**[14] که منبع اصلی عدم قطعیت‌های تصادفی است؛ نوسانات تصادفی این محیط به صورت مستقیم قابل‌کنترل نبوده و صرفاً اثرات آن از طریق مشاهدات متغیرهای محیطی توسط پروب‌های پایش رصد می‌گردد.



شکل ۴-۱: معماری سطح بالای رویکرد RS-DRL در قالب حلقه MAPE-K. این نمودار تعامل میان سیستم مدیریت‌شونده، محیط، و مؤلفه‌های کنترلی را به همراه مخزن دانش مشترک نشان می‌دهد.

۴-۲-۲ گردش فرآیندی و تفکیک زمانی وظایف حلقه انطباق

اگرچه ساختار کلان حلقه MAPE-K در بخش پیشین (شکل ۴-۱) توالی منطقی مؤلفه‌ها را تبیین نمود، اما چالش بنیادین در پیاده‌سازی عملیاتی چنین سیستمی، اجرای همزمان یا متوالی فرآیند استنتاج و آموزش در یک ریسمان کنترلی واحد است. به‌روزرسانی شبکه‌های عصبی عمیق مستلزم محاسبات سنگین پس‌انتشار

[10] Managed System
[11] Sensory Probes
[12] Actuators
[13] Autonomic Controller
[14] Operational Environment

گرادیان[15] بر روی دسته‌های کوچک داده[16] است که تأخیرهایی در حدود ده تا صدها میلی‌ثانیه ایجاد کرده و برای سیستم‌های بلادرنگ غیرقابل قبول است. در مقابل، استنتاج مستقیم سیاست (گذر رو به جلوی شبکه عصبی) صرفاً نیازمند چند ضرب ماتریسی پایه است که زمان اجرای آن همواره کمتر از نیم میلی‌ثانیه (۰/۵ ms) به طول می‌انجامد.

بر این اساس، معماری پیشنهادی برای حل این تعارض، از الگوی **تفکیک زمانی وظایف**[17] بهره می‌برد؛ به گونه‌ای که محاسبات سنگین گرادیانی به یک ریسمان ناهمگام در پس‌زمینه واگذار شده و مسیر مستقیم کنترل آنلاین[18] کاملاً از تأخیرهای محاسباتی فرآیند یادگیری ایزوله می‌گردد. اگرچه جریان تعاملات این سیستم بر پایه چرخه مرجع MAPE-K [۲] بنا شده است، اما با تعبیه مؤلفه اعتبارسنجی صوری در مسیر بازخورد (به‌منظور هدایت پاداش بدون انسداد مسیر تصمیم‌گیری)، گردش فرآیندی جامع سیستم در قالب ۶ خط شناوری[19] در نمودار فعالیت UML مدل‌سازی گردیده است. نمودار فعالیت تفصیلی در شکل ۴-۲ توالی این رخدادها، تفکیک وظایف زمان اجرا (شامل پایش، تحلیل، برنامه‌ریزی و اجرا در حلقه پیش‌رو، و اعتبارسنجی صوری در مسیر بازخورد) و همچنین مرز عدم‌انسداد میان مسیر کنترل بلادرنگ و فرآیند یادگیری پس‌زمینه (مخزن دانش) را از طریق یک خط‌چین افقی به تصویر می‌کشد.

برای تحقق عملیاتی این معماری، هر یک از مؤلفه‌های مستقر در خطوط شناوری شکل ۴-۲ نیازمند تعریف دقیق ماهیت زمانی و الگوهای تعامل داده‌ای هستند. جدول ۴-۱ این طبقه‌بندی جامع را ارائه داده و چگونگی همزیستی فرآیندهای مستمر، رویدادمحور، بلادرنگ قطعی، و ناهمگام پس‌زمینه را بدون تداخل محاسباتی تبیین می‌نماید.

جدول ۴-۱: طبقه‌بندی زمانی و مشخصات عملیاتی فرآیندهای معماری RS-DRL متناظر با خطوط شناوری شکل ۴-۲

خط شناوری / فرآیند	ماهیت زمانی	توضیح عملکردی و جریان داده
۱. پایش (Monitor)	مستمر (Continuous)	دریافت مستمر سیگنال‌ها و نوسانات کانال از حسگرهای محیطی و تشکیل بردار حالت سیستم (s_t).
۲. تحلیل (Analyze)	رویدادمحور (Event-driven)	ارزیابی مقادیر بردار حالت در برابر آستانه‌های SLA و تشخیص رخداد نقض کیفیت جهت تحریک فوری برنامه‌ریز.
۳. برنامه‌ریزی (Planner)	بلادرنگ و قطعی ($\mathcal{O}(1)$)	اجرای استنتاج مستقیم شبکه عصبی عمیق (DQN Inference) و انتخاب پیکربندی بهینه (a_t^*) در کمتر از نیم میلی‌ثانیه ($<$ ۰/۵ ms).
۴. اعتبارسنجی صوری (Formal Verifier)	غیرانسدادی (مسیر بازخورد)	ارزیابی صوری وضعیت با مدل‌چکینگ آماری (UPPAAL-SMC [۲۳]) و ترکیب پاداش محیطی با پاداش صوری ($r = r_{\text{env}} \times r_{\text{smc}}$) خارج از مسیر مستقیم کنترل.
۵. اجرا (Executor)	رویدادمحور و مستقیم	اعمال بلادرنگ پیکربندی کنترلی برگزیده بر روی محرک‌ها و اجزای سیستم هدف.
۶. مدیریت دانش و آموزش (Knowledge - Async)	پس‌زمینه و ناهمگام (Async)	ذخیره تجارب در بافر بازپخش، نمونه‌برداری دسته‌ای (Mini-batch Sampling)، شکل‌دهی تصادفی پاداش (ρ-shaping)، نزول گرادیان و به‌روزرسانی نرم شبکه هدف بدون مسدودسازی جریان کنترل آنلاین [۱۵].

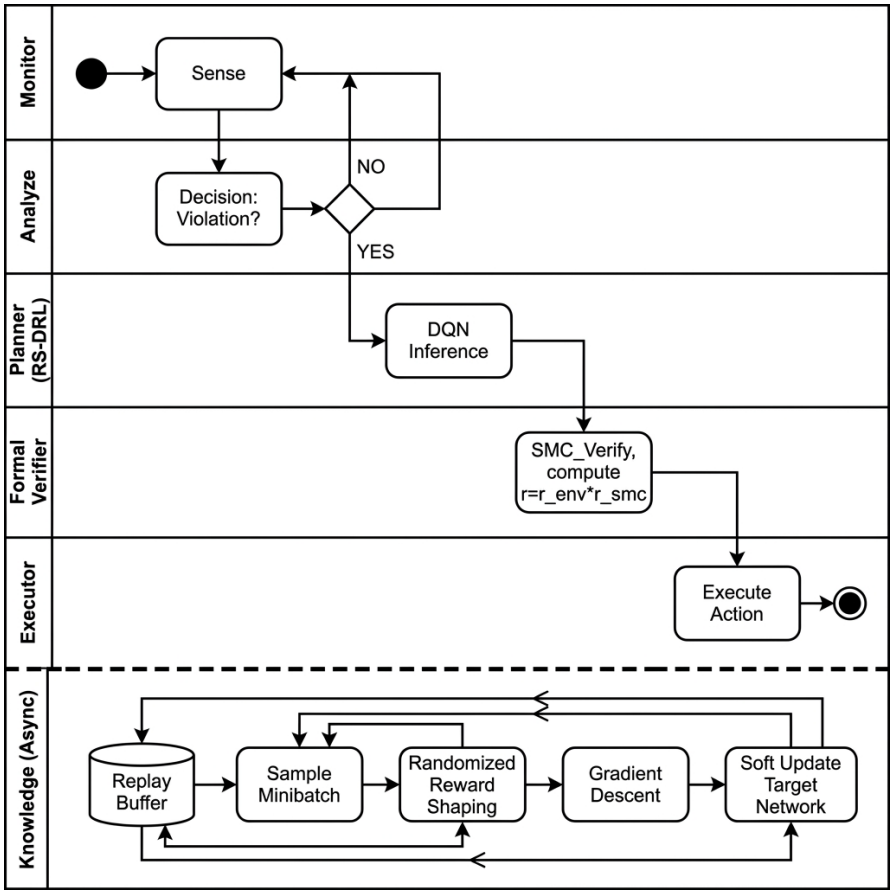
[15] Backpropagation

[16] Mini-batches

[17] Temporal Separation Architecture

[18] Critical Path

[19] Swimlanes



شکل ۴-۲: نمودار فعالیت تفصیلی UML فرآیند خودوفقی RS-DRL؛ تفکیک وظایف پنج‌گانه مسیر زمان اجرای آنلاین (پایش، تحلیل، برنامه‌ریزی، اعتبارسنجی صوری و اجرا) و فرآیند یادگیری ناهمگام در مخزن دانش در قالب ۶ خط شناوری. خط‌چین افقی، مرز عدم‌انسداد میان مسیر کنترل بلادرنگ و محاسبات یادگیری پس‌زمینه را نشان می‌دهد.

الگوی تفکیک زمانی، با ایزوله‌سازی محاسبات گرادیان از مسیر مستقیم کنترل، دستیابی به استنتاج قطعی زیر نیم میلی‌ثانیه‌ای را بدون تأثیرپذیری از پیچیدگی فرآیند آموزش تضمین می‌کند. اکنون که ساختار کلان (شکل ۴-۱) و فرآیند تفکیک وظایف (شکل ۴-۲) تبیین گردید، جدول ۴-۲ ماتریس توجیه تصمیمات کلیدی در معماری پیشنهادی RS-DRL را در مواجهه با چالش‌های اساسی کنترل خودوفق و در مقایسه با رویکردهای متداول خلاصه می‌نماید.

جدول ۴-۲: ماتریس توجیه تصمیمات کلیدی معماری پیشنهادی RS-DRL در برابر چالش‌های طراحی سیستمی

چالش طراحی سیستمی	تصمیم معماری در RS-DRL	رویکرد متداول / سنتی	دستاورد و توجیه مهندسی
تأخیر محاسباتی آموزش عمیق در برابر مهلت‌های بلادرنگ	تفکیک زمانی محاسبات گرادیان به ریسمان ناهمگام پس‌زمینه و ایزوله‌سازی استنتاج آنلاین	اجرای همگام آموزش و تصمیم‌گیری در یک ریسمان یا حلقه کنترلی واحد	استنتاج قطعی با پیچیدگی زمانی ثابت ($\mathcal{O}(1)$) در زمان زیر نیم میلی‌ثانیه ($< ۰/۵$ ms)
تضمین صوری کیفیت خدمات بدون انسداد زمان اجرا	تعبیه اعتبارسنجی صوری UPPAAL-SMC در مسیر بازخورد ($r = r_{\text{env}} \times r_{\text{smc}}$)	استقرار سپرهای صوری یا تحلیل‌های خطی مسدودکننده در مسیر مستقیم تصمیم‌گیری	هدایت ریاضیاتی و پایش صوری رفتار عامل بدون ایجاد وقفه یا تأخیر در اجرای فرمان
فرار از تله بهینه‌های محلی در فضاهای بزرگ و پاداش تنک	شکل‌دهی تصادفی پاداش با ضریب ρ بر پایه ترکیب بازخورد تجربی و صوری	کاوش تصادفی کورکورانه (ϵ-حریصانه) یا توابع پتانسیل ایستای دستی	عبور پایدار از بهینه‌های محلی و هدایت هوشمند کاوش بدون نیاز به فرمول‌بندی دستی دامنه
مدیریت تجارب ناموفق و پایداری بافر بازپخش	ذخیره‌سازی همگانی کلیه گذارهای موفق ($r = ۱$) و ناموفق ($r = ۰$) در بافر مشترک	پالایش یا نادیده گرفتن تجربیات منفی و ذخیره صرف گذارهای موفق	تأمین نمونه‌های لازم جهت فرار از بهینه محلی و ممانعت از فقیر شدن داده‌ای بافر

همان‌طور که در جدول ۴-۲ خلاصه شده است، اصول چهارگانه یادشده چارچوب مهندسی سیستم پیشنهادی را شکل می‌دهند؛ به نحوی که مسیر مستقیم کنترل صرفاً بر گزینش فوری اقدام بهینه در زمان استنتاج قطعی تمرکز دارد، در حالی که بار محاسباتی سنگین مربوط به اعتبارسنجی صوری و آموزش شبکه عمیق، در مسیرهای بازخورد و پس‌زمینه بدون تحمیل تأخیر به سیستم مدیریت می‌شوند. بر این اساس، در بخش بعد، گردش جریان داده و گام‌های اجرایی حلقه انطباق به صورت گام‌به‌گام تشریح می‌گردد.

۴-۳ جریان داده و گام‌های اجرایی تصمیم‌گیری آنلاین

پس از تبیین اصول معماری و مدل فرآیندی، مسیر یک درخواست انطباق از آغاز تا انجام در طول حلقه MAPE-K ردیابی می‌شود. برای ایجاد واژگان مشترک و زمینه‌سازی درک وظایف مؤلفه‌ها، از مدل مرجع MAPE-K [۲] به عنوان چارچوب سازمان‌دهی ساختاری فرآیند استفاده می‌شود. همان‌طور که شکل ۴-۲ نشان می‌دهد، هر مرحله از فرآیند یکپارچه ما به طور طبیعی به یکی از کارکردهای این مدل نگاشت می‌شود.

در ادامه، این مسیر به صورت گام به گام بررسی خواهد شد.

۴-۳-۱ گام اول: پایش و ساخت وضعیت

در نقطه شروع حلقه، سیستم به طور مستمر محیط عملیاتی خود را رصد کرده و متغیرهای کنترلی و مشاهدات پایش را در قالب یک بردار وضعیت انتزاعی $s_t \in \mathcal{S} \subseteq \mathbb{R}^d$ ادغام می‌نماید که بازنمایی ریاضی از متغیرهای پیکربندی سیستم مدیریت‌شونده و شرایط محیطی است. در سیستم‌های خودوفق توزیع‌شده، که شبکه حسگر بی‌سیم DeltaIoT [۲۷] نمونه‌ای از آن است، این فرآیند ادراکی به ساخت یک بردار وضعیت فشرده با ابعاد کیفی منجر می‌گردد:

$$s_t = \langle E, P, L \rangle \tag{۴-۱}$$

که در آن E مصرف انرژی تجمیعی شبکه، P نرخ اتلاف بسته‌ها، و L میانگین تأخیر ارسال است. این بردار، خروجی نهایی فاز **پایش**[۲۰] بوده و به‌عنوان ورودی مشترک برای تحلیل و تصمیم‌گیری عمل می‌کند.

۴-۳-۲ گام دوم: تحلیل و تشخیص ضرورت انطباق

بردار وضعیت s_t سپس وارد فاز **تحلیل**[۲۱] می‌شود. تحلیلگر، مقادیر P و L را در برابر آستانه‌های کیفی از پیش تعریف‌شده، مطابق با اهداف کیفی تعریف‌شده در فصل ۲ برای سیستم DeltaIoT [۲۷]، مقایسه می‌کند. اگر هر یک از این شاخص‌ها از حد مجاز فراتر رود (مثلاً نرخ اتلاف بسته $P > ۱۰٪$)، یک سیگنال رویداد «نقض هدف» صادر شده و فرآیند برنامه‌ریزی را فعال می‌کند.

۴-۳-۳ گام سوم: برنامه‌ریزی و استنتاج انطباقی

با دریافت سیگنال نیاز به انطباق، فاز **برنامه‌ریزی**[۲۲] فعال می‌شود. هسته این فاز، مدل آموزش‌دیده RS-DRL است که در نقش یک استنتاج‌گر عمل می‌کند: بردار حالت s_t را دریافت کرده و از طریق یک گذر رو به جلو در شبکه عصبی، مقادیر Q را برای تمام گزینه‌های وفقی محاسبه می‌کند.

سازوکار گزینش اقدام و نقش سیاست ϵ-greedy: برای تعادل میان کاوش و بهره‌برداری، استنتاج‌گر در زمان آموزش از سیاست ϵ-greedy [۶، ۱۵] تبعیت می‌کند؛ با احتمال ϵ یک اقدام تصادفی جهت کشف حالات

[20] Monitor
[21] Analyze
[22] Plan

جدید و با احتمال $\epsilon - ۱$ اقدام بهینه‌ای که ارزش عمل‌ـحالت آن بیشینه است را انتخاب می‌نماید:

$$a^* = \arg\max_{a \in \mathcal{A}} Q(s_t, a; \theta)$$

این فرآیند یک **استنتاج خالص**[۲۳] است؛ وزن‌های شبکه عصبی (θ) در این مسیر تصمیم‌گیری آنلاین هرگز تغییر نکرده و ثابت می‌مانند، تا پاسخ‌گویی بلادرنگ و قطعی سیستم در زمان زیر نیم میلی‌ثانیه تضمین گردد.

۴-۳-۴ گام چهارم: اعتبارسنجی صوری بازخورد و اجرای فرامین

پیش از اعمال گزینه وفقی منتخب بر سیستم، یک گام اعتبارسنجی صوری جهت احراز اهداف کیفی صورت می‌پذیرد. در معماری RS-DRL، مدل‌های صوری جهت تولید یک سیگنال بازخورد قابل‌اعتماد و ریاضیاتی به کار گرفته می‌شوند؛ به این ترتیب که گزینه پیشنهادی a^* توسط موتور UPPAAL-SMC [۲۳] ارزیابی شده و سیگنال اعتبارسنجی صوری دودویی $r_{smc} \in \{۰, ۱\}$ تولید می‌گردد که نشان‌دهنده برآورده شدن یا نقض اهداف کیفیت خدمات در وضعیت مفروض است.

پاداش نهایی اسکالر که به هر گذار زمان اجرا تخصیص می‌یابد، از ترکیب ضربی بازخورد تجربی محیط و تأیید صوری حاصل می‌شود:

$$r = r_{env} \times r_{smc} \qquad (۲-۴)$$

بر این اساس، مقدار پاداش تنها در صورتی مثبت ($r = ۱$) خواهد بود که هم محیط فیزیکی و هم مدل صوری ارضای اهداف کیفی را تأیید نمایند؛ در غیر این صورت، پاداش صفر ($r = ۰$) به منزله یک تجربه ناموفق ثبت می‌گردد.

ذخیره‌سازی جامع تجربیات در بافر بازپخش: کلیه گذارهای سیستم—اعم از تجربیات موفق ($r = ۱$) و تجربیات ناموفق یا نقض‌کننده قیود ($r = ۰$)—به صورت گذارهای چهارگانه (s, a, r, s') درون بافر بازپخش تجارب ($\mathcal{D}$) ذخیره می‌شوند. ذخیره‌سازی داده‌های شکست ($r = ۰$) نقشی بنیادین در روش‌شناسی رساله ایفا می‌کند؛ چرا که هسته الگوریتم RS-DRL در فاز آموزش پس‌زمینه (بخش ۴-۵)، دقیقاً با نمونه‌برداری از همین تجربیات ناموفق با پاداش صفر عمل کرده و از طریق سازوکار شکل‌دهی تصادفی با پارامتر ρ، زمینه را برای خروج از بهینه‌های محلی فراهم می‌سازد. در حقیقت، در صورت عدم ذخیره‌سازی تجربیات با پاداش صفر، بافر بازپخش در فضاهای وفقی بزرگ با پاداش تنک دچار کمبود داده شده و امکان کاوش و فرار از بهینه‌های محلی از بین می‌رفت.

در نهایت، در فاز اجرا[۲۴]، گزینه وفقی به لایه شبکه در سیستم مدیریت‌شونده ارسال می‌گردد. این فرامین

[23] Pure Inference

[24] Execute

بازپیکربندی از طریق فایل‌های پیکربندی محلی و راه‌اندازهای شبکه بر سخت‌افزار اعمال شده و پارامترهای عملیاتی نظیر توان ارسال و مسیرهای ارسال داده را منطبق می‌سازند.

۴-۳-۵ ردیابی گام‌به‌گام چرخه انطباق در قالب سناریوهای مرجع

جهت ملموس ساختن مفاهیم انتزاعی پایش، تحلیل، برنامه‌ریزی و اجرا، دو سناریوی مرجع را با جزئیات کامل و ویژگی‌های متفاوت ردیابی می‌کنیم.

۴-۳-۵-۱ سناریوی اول: شبکه دو گره‌ای با قید کیفیت خدمات تک‌هدفه

در این سناریو، چرخه کامل تصمیم‌گیری آنلاین را در قالب یک شبکه حسگر بی‌سیم ساده ردیابی می‌کنیم. فرض کنید شبکه‌ای شامل ۲ گره حسگر (M_1 و M_2) داده‌ها را به یک دروازه مرکزی ارسال می‌کنند و هر گره دارای ۲ گزینه برای تنظیم توان ارسال است: توان کم (a_{low}) و توان زیاد (a_{high}) که مجموعاً $2^2 = 4$ گزینه وفقی را تشکیل می‌دهند. هدف کیفی سیستم این است که نرخ اتلاف بسته‌ها (P) همواره کمتر از ٪۱۰ حفظ شود.

چرخه انطباق با شروع ناگهانی بارندگی یا تداخل محیطی آغاز می‌شود که کیفیت لینک‌های رادیویی را تضعیف کرده و مؤلفه **پایش**، نرخ اتلاف بسته‌های شبکه را ٪۱۲ گزارش می‌کند و بردار وضعیت جاری به عنوان $s_t = \langle E, P = ۰/۱۲, L \rangle$ ساخته می‌شود. در فاز **تحلیل**، مقدار اتلاف بسته (۰/۱۲) با آستانه مجاز (۰/۱۰) مقایسه شده و به دلیل نقض قید (۰/۱۰ $<$ ۰/۱۲)، بلافاصله سیگنال ضرورت انطباق برای فعال‌سازی برنامه‌ریز صادر می‌گردد. در فاز **برنامه‌ریزی**، بردار حالت s_t به عنوان ورودی به شبکه DQN[25] آموزش‌دیده ارائه می‌شود؛ شبکه در یک گذر رو به جلوی مستقیم و کم‌تأخیر (۰/۲ ms)، مقادیر Q را برای ۴ گزینه موجود محاسبه کرده و گزینه $a^* = \langle a_{high}, a_{low} \rangle$ (افزایش توان گره اول و تثبیت توان گره دوم) به عنوان بیشترین ارزش پیش‌بینی‌شده برگزیده می‌شود. نهایتاً در فاز **اعتبارسنجی صوری و اجرا**، اقدام پیشنهادی a^* به موتور UPPAAL-SMC ارسال شده و با تایید ارضای قید احتمالاتی ($r_{smc} = ۱$)، فرمان بازپیکربندی به درایورهای سخت‌افزاری صادر می‌گردد و نرخ اتلاف بسته به ٪۴ کاهش می‌یابد.

۴-۳-۵-۲ سناریوی دوم: شبکه چهار گره‌ای با اهداف متضاد کیفیت خدمات

جهت تبیین عملکرد سیستم در شرایطی که اهداف کیفی در تناقض مستقیم با یکدیگر قرار دارند، یک سناریوی جامع‌تر بررسی می‌شود. شبکه‌ای شامل ۴ گره حسگر (M_1 تا M_4) در توپولوژی خطی داده‌ها را به دروازه ارسال می‌کنند که هر گره دارای ۳ سطح توان گسسته (پایین، متوسط و بالا) است و در نتیجه فضای وفقی شامل $3^4 = ۸۱$ پیکربندی متفاوت می‌باشد. اهداف کیفی سه قید متضاد را شامل می‌شوند: نرخ اتلاف بسته‌ها باید

[25] Deep Q-Network

کمتر از ٪۱۰ باشد ($P_{net} < ۰/۱۰$)، میانگین تأخیر ارسال باید کمتر از ۲۰۰ ms باشد ($L_{net} < ۲۰۰$ ms)، و مصرف کل انرژی شبکه (E) باید کمینه گردد.

در پی وقوع یک تلاطم محیطی شدید که کیفیت کانال گره‌های $M_۱$ و $M_۲$ را تضعیف می‌کند، حسگرها بردار وضعیت ۱۲ بعدی زیر را پایش و گزارش می‌دهند:

$$\begin{aligned} s_t = \big\langle & E = [۰/۳,\ ۰/۳,\ ۰/۲۵,\ ۰/۲۵], \\ & P = [۰/۱۸,\ ۰/۱۵,\ ۰/۰۴,\ ۰/۰۵], \\ & L = [۱۲۰,\ ۱۱۰,\ ۸۰,\ ۷۵] \big\rangle \end{aligned} \tag{۳-۴}$$

در این وضعیت، نرخ اتلاف دو گره اول (٪۱۸ و ٪۱۵) بسیار بالاتر از حد مجاز بوده و اتلاف کل شبکه به $P_{net} = ۱۶/۵$٪ افزایش یافته و قید را نقض می‌کند. بردار s_t به استنتاج‌گر DQN ارائه شده و عامل گزینه‌های کاندیدا را سبک‌سنگین می‌کند: اقدام حافظ انرژی ($a_{low} = \langle ۰, ۰, ۰, ۰ \rangle$) که تمام گره‌ها را در توان کم نگه می‌دارد، ارزش نازل $Q = ۰/۲۱$ را کسب می‌کند زیرا اتلاف بسته‌ها کنترل نمی‌شود؛ در مقابل، اقدام تهاجمی ($a_{brute} = \langle ۲, ۲, ۲, ۲ \rangle$) با افزایش توان همه گره‌ها اتلاف را به ٪۳ می‌رساند، اما به علت تداخل شدید کانال، تأخیر را به ۲۴۰ ms رسانده و قید دوم را نقض می‌کند ($Q = ۰/۴۲$)؛ در نهایت، اقدام متعادل هوشمند ($a_{balanced} = \langle ۲, ۲, ۰, ۰ \rangle$) با افزایش هدفمند توان گره‌های بحرانی $M_۱$ و $M_۲$ و حفظ توان پایین سایر گره‌ها، بالاترین ارزش ($Q = ۰/۹۲$) را کسب می‌کند، زیرا هم قید اتلاف (٪۵) و هم قید تأخیر (۱۵۵ ms) را با حداقل مصرف انرژی ارضا می‌سازد. با تأیید صوری UPPAAL-SMC ($r_{smc} = ۱$)، فرمان نهایی به گره‌ها اعمال شده و تعادل بهینه پارتو بازیابی می‌گردد.

۴-۴ معماری داخلی برنامه‌ریز و مسیرهای سه‌گانه کنترلی

برای تحقق اصل تفکیک زمانی وظایف که پیش‌تر مطرح شد، معماری داخلی مؤلفه برنامه‌ریز RS-DRL به سه مسیر فرآیندی مجزا و همزمان تجزیه می‌شود که در شکل ۴-۳ به تصویر کشیده شده‌اند:

۱. **مسیر استنتاج:**[۲۶] این مسیر در خط مقدم کنترل آنلاین فعال است و وظیفه دریافت بردار حالت جاری s_t، اجرای گذر رو به جلو در شبکه عصبی عمیق، و انتخاب اقدام وفقی بهینه a_t^* را بر عهده دارد. این مسیر به صورت کاملاً «فقط‌خواندنی» پیاده‌سازی شده و پارامترهای مدل در طول آن تغییر نمی‌کنند، تا استنتاج قطعی با پیچیدگی زمانی ثابت ($\mathcal{O}(۱)$) در زمان زیر نیم میلی‌ثانیه ($< ۰/۵$ ms) تضمین گردد.

۲. **مسیر بازخورد:**[۲۷] پس از صدور و اعمال فرمان انطباق، این مسیر پاداش محیطی (r_{env}) را دریافت

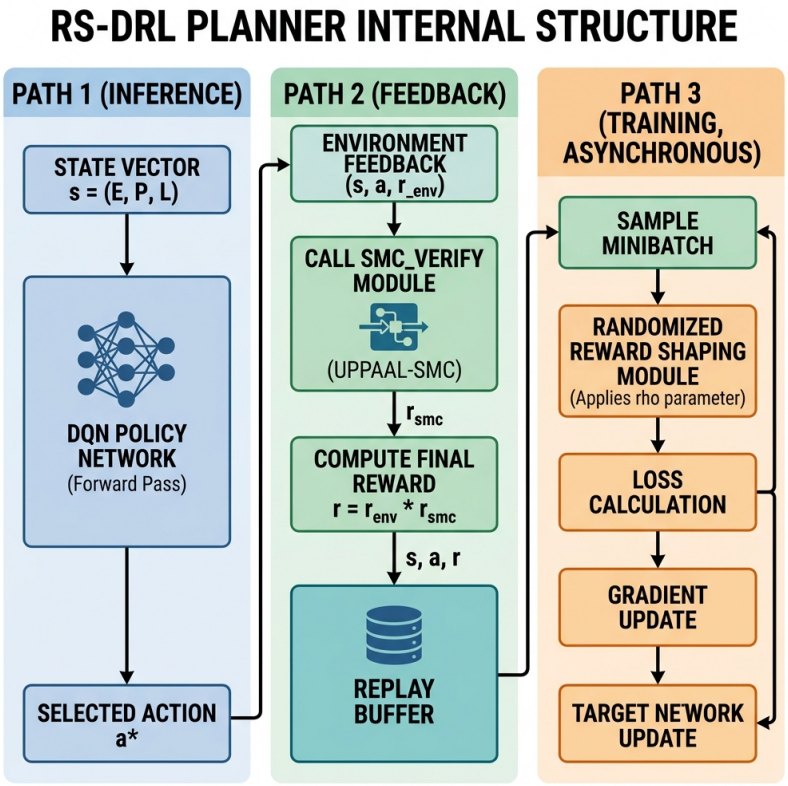
[26] Inference Path

[27] Feedback Path

کرده، درخواست اعتبارسنجی صوری را به موتور UPPAAL-SMC ارسال می‌نماید، سیگنال ترکیبی ($r = r_{env} \times r_{smc}$) را محاسبه کرده و تجربه حاصله را در بافر بازپخش ذخیره می‌سازد. این مسیر به صورت سبک و غیرانسدادی در کنار مسیر کنترل عمل می‌کند.

۳. **مسیر آموزش:**[۲۸] این مسیر در پس‌زمینه و کاملاً ایزوله از مسیر کنترل زمان اجرا فعالیت دارد. این مؤلفه با نمونه‌برداری دسته‌ای تصادفی از بافر بازپخش تجربیات، سازوکار شکل‌دهی تصادفی پاداش با ضریب ρ را اعمال کرده و وزن‌های شبکه اصلی را با پس‌انتشار گرادیان به‌روزرسانی می‌نماید؛ سپس پارامترها به صورت دوره‌ای به شبکه هدف منتقل می‌شوند.

جزئیات منطق درونی این مسیرها و الگوهای تعامل داده‌ای آن‌ها در شکل ۴-۳ ارائه شده است.



شکل ۴-۳: ساختار داخلی مؤلفه برنامه‌ریز RS-DRL در سه مسیر موازی: استنتاج (فقط‌خواندنی)، بازخورد (ترکیب پاداش محیطی و صوری)، و آموزش (به‌روزرسانی در پس‌زمینه با استفاده از شکل‌دهی تصادفی پاداش).

[28] Training Path

۴-۴-۱ الگوی همگام‌سازی چندریسمانی و مدیریت همزمانی بدون قفل

چالش مهندسی بنیادین در پیاده‌سازی این معماری چندریسمانی، برقراری هماهنگی امن و جلوگیری از شرایط مسابقه[۲۹] میان مسیر استنتاج بلادرنگ و محاسبات سنگین آموزش پس‌زمینه است؛ به طوری که به‌روزرسانی وزن‌های شبکه عصبی هرگز موجب انسداد یا تأخیر نوسانی در استنتاج آنلاین نشود. برای تحقق این هدف، سیستم از دو سازوکار مهندسی بهره می‌گیرد:

۱. تبادل اتمیک وزن‌ها با بافر دوگانه بدون قفل: در این الگو[۳۰]، دو نسخه مجزا از وزن‌های شبکه عصبی در حافظه نگهداری می‌شوند: نسخه فعال استنتاج (θ_{active}) و نسخه در حال آموزش (θ_{train}). ریسمان استنتاج منحصراً از طریق یک اشاره‌گر اتمیک فقط‌خواندنی به θ_{active} دسترسی دارد و هیچ‌گونه قفل انحصاری[۳۱] را فراخوانی نمی‌کند. در مقابل، ریسمان آموزش محاسبات گرادیان را منحصراً بر روی θ_{train} اعمال می‌نماید. پس از تکمیل هر دوره به‌روزرسانی گرادیان، انتقال وزن‌های جدید به مسیر استنتاج صرفاً از طریق یک جابه‌جایی اتمیک اشاره‌گر[۳۲] در مرتبه زمانی ثابت $\mathcal{O}(1)$ انجام می‌پذیرد. این سازوکار رقابت بر سر قفل[۳۳] را به صفر رسانده و تضمین می‌کند که استنتاج در زمان زیر نیم میلی‌ثانیه بدون وقفه اجرا گردد.

۲. صف‌بندی ناهمگام وظایف اعتبارسنجی صوری: از آنجا که شبیه‌سازی‌های آماری در موتور UPPAAL-SMC ممکن است چند ثانیه به طول بینجامند، ریسمان بازخورد بلافاصله پس از اعمال اقدام، یک وظیفه اعتبارسنجی را در قالب ساختار (s, a) به صف کاربری ناهمگام موتور صوری[۳۴] ارسال کرده و اجرای حلقه کنترلی را ادامه می‌دهد. به محض اتمام ارزیابی صوری و محاسبه r_{smc}، سیگنال پاداش نهایی ($r = r_{env} \times r_{smc}$) توسط یک شنونده رویدادمحور تشکیل شده و گذار چهارگانه (s, a, r, s') به صورت نخ‌امن[۳۵] درون بافر بازپخش تجارب ($\mathcal{D}$) تزریق می‌گردد.

۴-۵ سازوکار شکل‌دهی تصادفی پاداش و فرار از بهینه‌های محلی

چالش بنیادینی که RS-DRL به آن پاسخ می‌دهد، پدیده توقف در بهینه‌های محلی است؛ جایی که عامل یادگیرنده صرفاً بر اساس تجربیات موفق گذشته عمل کرده و از کشف سیاست‌های بالقوه بهتر باز می‌ماند. برای غلبه بر این محدودیت، در معماری RS-DRL یک راهبرد برچسب‌گذاری مجدد خوش‌بینانه در مرحله

[29] Race Conditions
[30] Lock-Free Double Buffering
[31] Mutex
[32] Atomic Pointer Swap
[33] Lock Contention
[34] Asynchronous Verification Queue
[35] Thread-Safe

بازپخش تجربه[۳۶] [۱۵] به کار گرفته می‌شود. این سازوکار با فعال‌سازی مشروط گرادیان برای تجربیات ناموفق، زمینه را برای خروج از بهینه‌های محلی بدون نیاز به بازآموزی پرهزینه فراهم می‌سازد:

۴-۵-۱ مبانی نظری و فرمول‌بندی ریاضی شکل‌دهی پاداش

تحلیل صوری پدیده تنکی پاداش: در فضاهای وفقی بسیار بزرگ و مقیاس‌وسیع، اهداف انطباقی بسیار سخت‌گیرانه بوده و در نتیجه، عامل با فضای پاداش شدیداً تنک[۳۷] مواجه می‌شود که رفع آن در رویکردهای پیشین مستلزم روش‌های پیچیده‌ای نظیر [۴۰، ۱۶] است. در چنین شرایطی، تقریباً برای تمام پیکربندی‌های تصادفی اول دوره، سیگنال پاداش حاصله صفر است ($r_t = ۰$). تحت این شرایط، تابع خطا یا گرادیان شبکه‌های عصبی عمیق مسطح شده و فاقد اطلاعات جهت‌دهنده است:

$$\nabla_\theta \mathbb{E}\left[\left(r_t + \gamma \max_{a'} Q(s_{t+۱}, a'; \theta') - Q(s_t, a_t; \theta)\right)^۲\right] \approx ۰$$

این پدیده سرعت همگرایی یادگیری را به میزان قابل‌ملاحظه‌ای کاهش داده و عامل را به یک بهینه محلی نیمه‌پایدار و نامطلوب همگرا می‌سازد.

فرمول‌بندی و عملکرد ریاضی سازوکار شکل‌دهی تصادفی: برای خروج از این تله ریاضی، در هر دسته آموزشی، به ازای هر تجربه i با پاداش اولیه صفر ($r_i = ۰$)، RS-DRL با احتمال ρ پاداش آن را به صورت خوش‌بینانه برابر با ۱ قرار می‌دهد. این فرآیند جایگزینی که در شکل ۴-۴ ترسیم شده است، بر اساس رابطه زیر عمل می‌کند:

$$\tilde{r}_i = \begin{cases} ۱ & \text{if} r_i = ۰ \text{ and } \text{rand}(۰, ۱) < \rho \\ r_i & \text{otherwise} \end{cases} \tag{۴-۴}$$

پارامتر ρ (ضریب شکل‌دهی) شدت این خوش‌بینی را کنترل می‌کند. این تغییر پاداش مستقیماً مقدار هدف بل‌من را بازنویسی می‌نماید:

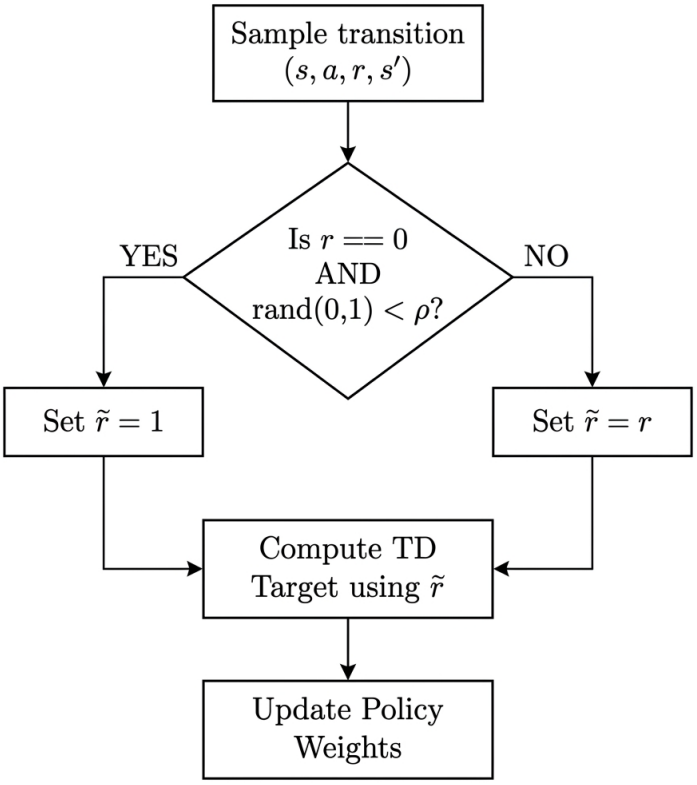
$$y_i = \tilde{r}_i + \gamma \max_{a'} Q(s'_i, a'; \theta')$$

این بازنویسی سبب معرفی یک سوگیری خوش‌بینانه تصادفی گذرا[۳۸] می‌گردد که عامل را به کاوش مجدد ارزش عمل–حالت‌هایی که قبلاً به علت پاداش صفر نادیده گرفته می‌شدند ترغیب کرده و با ایجاد انحراف

[36] Experience Replay

[37] Sparse Reward Space

[38] Optimistic Bias



شکل ۴-۴: منطق عملیاتی سازوکار شکل‌دهی تصادفی پاداش. این نمودار فرآیند جایگزینی خوش‌بینانه پاداش‌های صفر با مقدار ۱ را بر اساس ضریب ρ نشان می‌دهد (برچسب‌گذاری مجدد خوش‌بینانه، نه روش‌های مبتنی بر پتانسیل [۴۱]).

کنترل‌شده، فرار از تله بهینه‌های محلی را تسریع می‌کند.

برخلاف روش شکل‌دهی پاداش مبتنی بر پتانسیل[۳۹] [۴۱] که برای تضمین تغییرناپذیری سیاست بهینه نیازمند طراحی تابع پتانسیل دستی ($\Phi(s)$) بر مبنای دانش دامنه است، روش پیشنهادی RS-DRL وابستگی به پتانسیل‌های حالت یا جهت‌دهی‌های معنایی دستی ندارد؛ سازوکار تصادفی ρ به صورت مستقل از مدل عمل کرده و بهینگی مجانبی را بدون تحمیل بار طراحی توابع کمکی حفظ می‌نماید.

تحلیل حساسیت و پیش‌ارزیابی اولیه ضریب شکل‌دهی ρ: انتخاب مقدار بهینه ضریب ρ نقشی تعیین‌کننده در پایداری و همگرایی یادگیری ایفا می‌کند. جدول ۴-۳ تاثیر مقادیر مختلف این پارامتر را بر روی رفتار کاوش و همگرایی سیاست یادگیری خلاصه می‌کند.

جدول ۴-۳: تحلیل حساسیت رفتار یادگیری عامل نسبت به تغییرات ضریب شکل‌دهی ρ

مقدار ρ	نرخ کاوش	پایداری همگرایی	تاثیر بر فرار از بهینه محلی
۰/۰	بسیار پایین	بسیار بالا	فاقد توانایی فرار؛ عامل همواره در اولین بهینه محلی یافت شده متوقف می‌شود.
۰/۱	متوسط	بالا	شروع فرار تدریجی؛ زمان طولانی‌تری برای همگرایی به بهینه مطلق نیاز دارد.
۰/۳	بهینه تجربی	پایدار	فرار سریع و پایدار؛ توازن بهینه میان کاوش خوش‌بینانه و همگرایی مجانبی.
۰/۷	بالا	متوسط (نوسانی)	القای نویز به گرادیان سیاست و بروز نوسان در روند همگرایی مجانبی.
۰/۹	بیش‌کاوشی مفرط	ناپایدار	ناپایداری شدید؛ واگرایی سیاست یادگیری ناشی از تزریق بیش از حد پاداش‌های مصنوعی.

۴-۵-۲ تحلیل حساسیت پارامتر ρ و الگوریتم یادگیری RS-DRL

برای دستیابی به بهینه‌ترین نرخ همگرایی و تضمین خروج از تله بهینه‌های محلی، یک فرآیند منسجم جستجوی شبکه‌ای[۴۰] بر روی ضریب شکل‌دهی تصادفی پاداش (ρ) پیاده‌سازی گردید. هدف از این جستجو، یافتن مقداری برای ρ است که پاداش تجمعی مجانبی[۴۱] را در طول دوره‌های یادگیری بیشینه سازد.

توازن ریاضی میان کاوش خوش‌بینانه و ثبات یادگیری: تحلیل رفتار یادگیری نشان می‌دهد که تنظیم ضریب شکل‌دهی تصادفی پاداش (ρ) دارای دو مرز بحرانی از منظر پایداری ریاضی است:

- **ناحیه کاوش ناکافی ($\rho < ۰/۲$):** به دلیل سهم بسیار ناچیز سیگنال‌های مثبت مصنوعی خوش‌بینانه، گرادیان سیاست یادگیری تحت تأثیر شدید پاداش‌های صفرِ ناشی از محیط‌های سخت‌گیرانه مسطح

[39] Potential-Based Reward Shaping (PBRS)

[40] Grid Search

[41] Asymptotic Reward

باقی می‌ماند؛ در نتیجه، زمان فرار عامل از اولین بهینه محلی به طور قابل‌ملاحظه‌ای طولانی شده و به دوره‌های آموزشی فراوانی نیاز دارد.

- **ناحیه بیش‌کاوشی نوسانی ($\rho > ۰/۶$):** تزریق مفرط پاداش‌های مثبت مصنوعی منجر به بیش‌برآورد شدید ارزش عمل‌ـحالت‌ها (Q(values)- در مقدار هدف بل‌من[۴۲] می‌گردد؛ این پدیده نوسانات مخربی در برآورد گرادیان ایجاد کرده و در مقادیر $\rho \geq ۰/۹$ به واگرایی کامل سیاست منجر می‌شود.

بر این مبنا، بازه پایدار $\rho \in [۰/۲۵, ۰/۳۵]$ و به طور مشخص مقدار نامی $\rho = ۰/۳$ به عنوان نقطه موازنه بهینه استخراج می‌گردد که تعادل ریاضی پایداری میان کاوش فعال و همگرایی بدون نوسان برقرار می‌سازد (منحنی‌های ارزیابی تجربی و تحلیل‌های اعتبارسنجی در فصل ۵ ارائه شده است).

فرآیند گام‌به‌گام آموزش در الگوریتم ۴-۱ مدون گردیده است. هسته محاسباتی این فرآیند بر پایه چارچوب یادگیری Q عمیق (DQN) [۱۵] پیاده‌سازی شده و از بافر بازپخش تجارب جهت شکستن همبستگی زمانی داده‌ها بهره می‌گیرد. همچنین برای تثبیت اهداف یادگیری و ارتقای پایداری مجانبی، به‌روزرسانی نرم شبکه‌های هدف[۴۳] [۴۴] تعبیه شده است.

وجه تمایز محوری این الگوریتم، ادغام سیگنال اعتبارسنجی صوری (r_{smc}) مبتنی بر ابزار UPPAAL-SMC [۲۳] در فرآیند هدایت پاداش است. ترکیب ضربی پاداش ($r = r_{env} \times r_{smc}$) تضمین می‌کند که صرفاً انتقال‌هایی که به صورت همزمان مورد تأیید محیط تجربی و مشخصه‌های صوری قرار گرفته‌اند، شایسته دریافت سیگنال تقویت مثبت گردند. در این سطح پایه‌ای، اعتبارسنجی صوری در نقش ناظر پاداش عمل کرده و مسیر تصمیم‌گیری بلادرنگ را مسدود نمی‌سازد.

[42] Bellman Target

[43] Soft Target Updates

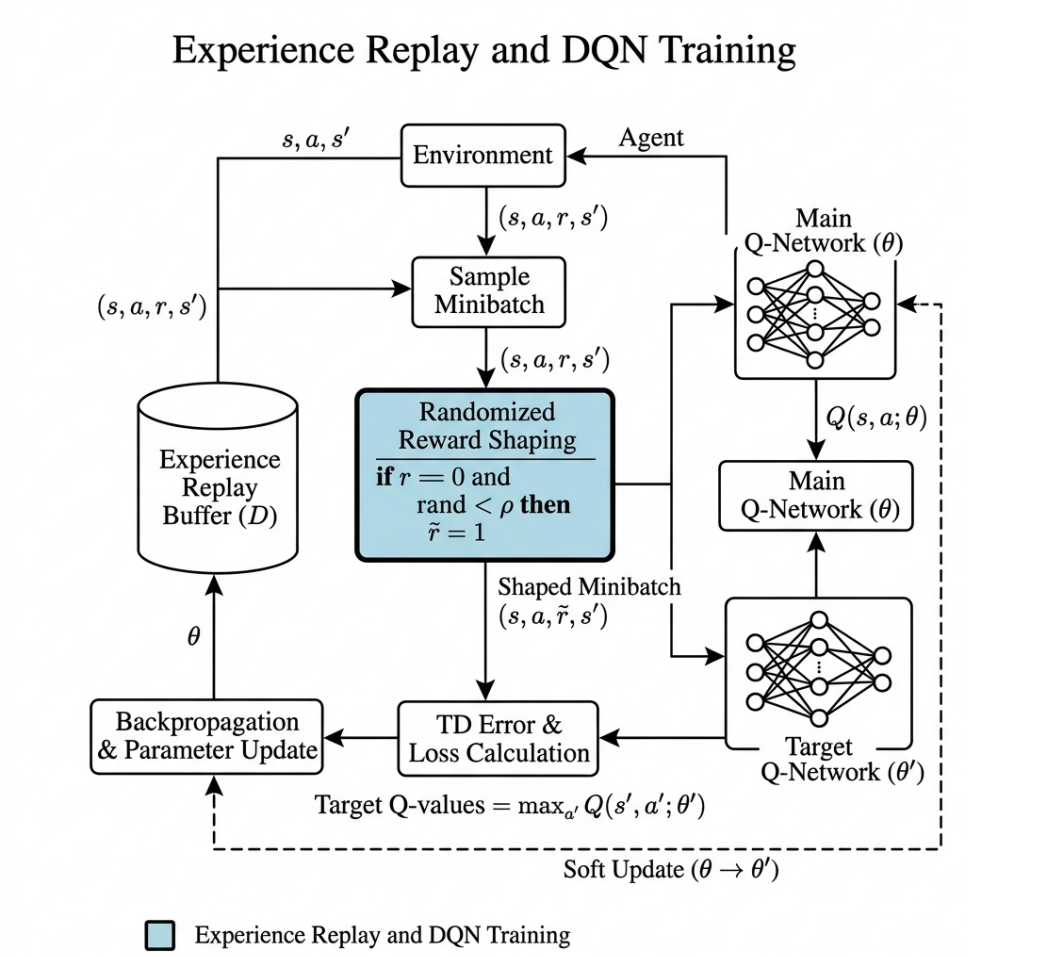
الگوریتم ۴-۱ آموزش و به‌روزرسانی جامع RS-DRL

Initialize main network θ and target network θ' {تعریف شبکه‌های عصبی اصلی و هدف}
for each training episode **do**
  $s \leftarrow GetInitialState()$ {دریافت وضعیت اولیه از زیرسیستم پایش}
  while episode not finished **do**
    {مسیر مستقیم کنترل آنلاین (استنتاج قطعی):}
    $a \leftarrow SelectAction(s, \theta, \epsilon\text{-greedy})$ {انتخاب اقدام زمان اجرا با احتمال کاوش}
    $(s', r_{env}) \leftarrow Environment.Step(a)$ {اعمال پیکربندی و دریافت پاداش شبکه}
    $r_{smc} \leftarrow SMC_Verify(s, a)$ {فراخوانی اعتبارسنجی صوری UPPAAL-SMC به صورت احتمالی}
    $r \leftarrow r_{env} \times r_{smc}$ {ادغام پاداش صوری و تجربی: موفقیت در صورت ارضای هر دو عامل}
    Store transition (s, a, r, s') in Replay Buffer $\mathcal{D}$ {ذخیره‌سازی تجربه در حافظه مشترک}
    {ریسمان ناهمگام یادگیری در پس‌زمینه (بدون انسداد مسیر کنترل):}
    Sample random minibatch $B = \{(s_i, a_i, r_i, s'_i)\}_{i=1}^{N}$ from $\mathcal{D}$ {نمونه‌برداری دسته‌ای از بافر}
    for each transition i in B **do**
      if $r_i = 0$ **and** $rand(0,1) < \rho$ **then**
        $\tilde{r}_i \leftarrow 1$ {اعمال سازوکار خوش‌بینی تصادفی برای خروج از بهینه محلی}
      else
        $\tilde{r}_i \leftarrow r_i$
      end if
      $y_i \leftarrow \tilde{r}_i + \gamma \max_{a'} Q(s'_i, a'; \theta')$ {محاسبه مقدار هدف بل‌من [۱۵] با پاداش شکل‌یافته}
    end for
    $\theta \leftarrow \theta - \alpha \nabla_\theta \frac{1}{|B|} \sum_{i \in B} (y_i - Q(s_i, a_i; \theta))^2$ {به‌روزرسانی دسته‌ای گرادیان شبکه اصلی}
    $\theta' \leftarrow \tau\theta + (1-\tau)\theta'$ {به‌روزرسانی نرم شبکه‌های هدف [۴۴] جهت حفظ پایداری}
    $s \leftarrow s'$
  end while
end for

نکته: پارامتر ρ (ضریب شکل‌دهی) یک فراپارامتر است که میزان خوش‌بینی عامل را در کشف مسیرهای جدید کنترل می‌کند. مقادیر بهینه آن در فصل ۵ تحلیل شده‌اند.

۴-۶ مدیریت مخزن دانش و هماهنگی جریان‌های همزمان

موفقیت معماری RS-DRL در گرو هماهنگی دقیق میان سه مسیر استنتاج، بازخورد و آموزش است. این هماهنگی از طریق یک مخزن دانش مشترک[۴۴] مبتنی بر مدل مرجع MAPE-K [۲] تحقق می‌یابد که به‌عنوان حافظه مرکزی سیستم عمل می‌کند. شکل ۴-۵ جریان داده‌های ذخیره‌شده در این مخزن را نشان می‌دهد؛ از لحظه ذخیره‌سازی گذارهای (s, a, r, s') تا فرآیند نمونه‌برداری از بافر و به‌روزرسانی شبکه‌های عصبی اصلی و هدف در پس‌زمینه.



شکل ۴-۵: جریان داده تفصیلی در مخزن دانش. این نمودار نحوه ذخیره‌سازی تجربیات در بافر بازپخش، اعمال سازوکار شکل‌دهی تصادفی پاداش پیش از محاسبات گرادیان، و به‌روزرسانی سیاست‌های یادگیری در پس‌زمینه را به تصویر می‌کشد.

ساختار صوری و تعریف مخزن دانش مشترک: مخزن دانش شامل بردارهای توپولوژی شبکه، سوابق مشاهدات محیطی، بافر بازپخش تجربیات $\mathcal{D}$ و وزن‌های شبکه‌های عصبی عمیق اصلی (θ) و هدف (θ') است. جهت هماهنگی دسترسی‌های همزمان و جلوگیری از به وجود آمدن شرایط مسابقه، الگوهای خواندن و

[44] Knowledge Repository

نوشتن هر یک از اجزا به صورت دقیق و ساختاریافته مدیریت می‌شود. جدول ۴-۴ به طور تفصیلی الگوهای دسترسی به دانش، فرکانس فراخوانی، و تأثیر محاسباتی هر جزء را بر روی تأخیر سیستم مشخص کرده است.

جدول ۴-۴: الگوهای دسترسی صوری و همگام‌سازی مؤلفه‌ها در مخزن دانش مشترک [۲]

مؤلفه سیستم	دسترسی خواندن	دسترسی نوشتن	فرکانس فراخوانی	تأثیر محاسباتی
پایش (Monitor)	علائم فیزیکی کانال	بردار حالت جدید s_t	مستمر (هر دوره)	ناچیز (کمتر از ۰/۱ ms)
تحلیل (Analyze)	آستانه‌های کیفی QoS	سیگنال نقض قید	رویدادمحور	ناچیز (کمتر از ۰/۰۵ ms)
برنامه‌ریز (Plan)	وزن‌های شبکه عصبی θ	اقدام پیشنهادی a^*	رویدادمحور	بسیار پایین (۰/۳ ms)
اعتبارسنج صوری	مدل شبکه، قید PCTL	پاداش صوری r_{smc}	رویدادمحور	غیرانسدادی (پس‌زمینه)
یادگیرنده (Train)	بافر بازپخش $\mathcal{D}$	بافر $\mathcal{D}$ و وزن‌های جدید θ	مستمر در پس‌زمینه	صفر (ایزوله)

همان‌طور که در جدول ۴-۴ به وضوح نشان داده شده است، مؤلفه یادگیری سنگین در پس‌زمینه ایزوله شده و هیچ دسترسی مستقیمی‌در مسیر زمان اجرای برنامه‌ریز آنلاین ندارد. این ساختار ایزوله، زمان پاسخ‌گویی قطعی در فاز استنتاج را مستقل از مقیاس محاسبات یادگیری تضمین می‌نماید.

۴-۷ اعتبارسنجی صوری زمان اجرا با وارسی مدل آماری UPPAAL-SMC

معماری RS-DRL علاوه بر سرعت تصمیم‌گیری، تضمین‌های صوری پیرامون ایمنی و ارضای الزامات کیفی را در شرایط عدم قطعیت فراهم می‌سازد. این تضمین‌ها از طریق به‌کارگیری غیرانسدادی موتور وارسی مدل آماری زمان اجرای UPPAAL-SMC [۲۳] در پس‌زمینه محقق می‌گردد.

نقش و نحوه عملکرد ابزار UPPAAL-SMC: در سیستم‌های خودوفق، اعتبارسنجی صوری زمان اجرا رفتار مدل‌های احتمالی را در مواجهه با عدم قطعیت‌های پویای محیط پایش می‌نماید. موتور UPPAAL-SMC با بهره‌گیری از شبیه‌سازی‌های آماری هدایت‌شده، مشخصه‌های ریاضیاتی را بر روی اتوماتای زمان‌دار تصادفی و فرآیندهای مارکوف شبکه ارزیابی می‌کند.

مشخصه‌های رفتاری سیستم در قالب منطق زمانی محاسبات احتمالات زمان‌آگاه (PCTL)[45] [۴۵] تدوین می‌گردند. به عنوان نمونه، الزام مربوط به سقف اتلاف بسته در شبکه به صورت زیر فرموله می‌شود:

$$\psi = P_{\geq ۰/۹۹} \left[\Diamond_{\leq T} \left(\text{PacketLoss} < ۰/۱ \right) \right] \qquad (۵-۴)$$

[45] Probabilistic Computation Tree Logic

تفسیر ریاضی پرسش یادشده: آیا تحت پیکربندی و اقدام انتخابی جاری، احتمال اینکه نرخ اتلاف بسته‌های کل شبکه در افق زمانی T همواره کمتر از ٪۱۰ باقی بماند، حداقل ٪۹۹ خواهد بود؟

فرمول‌بندی فیلتر ایمنی و سیگنال پاداش صوری (r_{smc}): موتور اعتبارسنجی صوری با اجرای شبیه‌سازی‌های متعدد آماری بر روی مدل صوری پویای شبکه، سیگنال صوری زیر را تولید می‌نماید:

$$r_{smc}(s,a) = \begin{cases} ۱ & \text{query PCTL the if} \psi \text{ state in satisfied is } s \text{ action under } a \\ ۰ & \text{otherwise} \end{cases} \quad (۴\text{-}۶)$$

این خروجی دودویی نقش فیلتر کیفی صوری را ایفا می‌نماید. در نسخه جاری معماری پیشنهادی، این اعتبارسنجی صوری با پاداش محیطی ترکیب شده ($r = r_{env} \times r_{smc}$) تا تجربیاتی که منجر به نقض تضمین‌های ریاضیاتی ایمنی می‌گردند، با پاداش صفر جریمه شوند.

۴-۷-۱ جزئیات شبیه‌سازی احتمالی و کران ریاضی تعداد نمونه‌ها

از آنجا که موتور UPPAAL-SMC بر مبنای وارسی مدل آماری عمل می‌کند، ارزیابی قضایای صوری نظیر معادله ۴-۵ نیازمند مشخص‌سازی سه فراپارامتر آماری برای تعیین تعداد شبیه‌سازی‌های مورد نیاز[۴۶] جهت ارائه تضمین‌های صوری احتمالی است:

۱. **سطح معناداری آماری (α):** نشان‌دهنده احتمال وقوع خطای نوع اول (رد فرضیه درست) است که در این رساله برابر با $\alpha = ۰/۰۵$ تنظیم شده است.

۲. **احتمال خطای نوع دوم (β):** نشان‌دهنده احتمال پذیرش فرضیه نادرست است که برابر با $\beta = ۰/۰۵$ در نظر گرفته شده است.

۳. **پارامتر بی‌تفاوتی یا پهنای بازه اطمینان (δ):** که نشان‌دهنده حداکثر خطای مجاز در برآورد احتمال است و معادل $\delta = ۰/۰۲$ تنظیم گردیده است.

تعداد کل شبیه‌سازی‌های تصادفی مورد نیاز (N_{sim}) برای تضمین اینکه برآورد احتمال با دقت مدنظر صورت پذیرد، به صورت تئوریک توسط نامساوی معروف **کران چرنوف–هوفدینگ**[۴۷] [۴۶] تعیین می‌گردد:

$$N_{sim} \geq \frac{\ln(۲/\alpha)}{۲\delta^۲} \quad (۴\text{-}۷)$$

[46] Statistical Model Checking (SMC) Sample Bound

[۴۷] نامساوی Chernoff-Hoeffding Bound تضمین می‌نماید که برای سطح معناداری $\alpha = ۰/۰۵$ و خطای تقریب $\delta = ۰/۰۵$، حداقل $N_{sim} = ۷۳۸$ شبیه‌سازی در موتور UPPAAL-SMC برای دستیابی به اطمینان ریاضیاتی ٪۹۵ از برآورد احتمال نقض الزامات کیفی کفایت می‌کند.

با جایگذاری مقادیر مذکور در رابطه ۴-۷:

$$N_{sim} \geq \frac{\ln(۲/۰/۰۵)}{۲(۰/۰۲)^{۲}} = \frac{۳/۶۸۸۸}{۰/۰۰۰۸} \approx ۴۶۱۱$$

این رابطه نشان می‌دهد که برای تضمین ریاضیاتی مطلق با خطای زیر ۵ درصد، موتور اعتبارسنجی صوری به صورت تئوریک باید ۴۶۱۱ شبیه‌سازی بر روی مدل احتمالی انجام دهد. از آنجا که اجرای این تعداد شبیه‌سازی تصادفی بر روی مدل زمان اجرای شبکه زمان زیادی (حدود ۴ تا ۸ ثانیه) به طول می‌انجامد، امکان اجرای مستقیم آن در مسیر تصمیم‌گیری آنلاین وجود ندارد.

۴-۷-۲ تحلیل زمان‌بندی اعتبارسنجی غیرانسدادی در پس‌زمینه

جهت حل این چالش بنیادین، فرآیند اعتبارسنجی صوری به صورت **غیرانسدادی**[۴۸] در ریسمان موازی بازخورد و یادگیری پس‌زمینه ادغام شده است [۴۳، ۳۹]. همان‌طور که در دیاگرام فعالیت شکل ۴-۲ و ساختار درونی شکل ۴-۳ نشان داده شد، تداخل زمانی میان مسیر تصمیم‌گیری مستقیم و موتور اعتبارسنجی صوری مرتفع گردیده است.

هنگامی که برنامه‌ریز گزینه وفقی a^* را انتخاب می‌نماید، این تصمیم بلافاصله و در کمتر از نیم میلی‌ثانیه بر شبکه حسگر اعمال می‌گردد. همزمان، یک ریسمان موازی در پس‌زمینه فرآیند اعتبارسنجی صوری وضعیت و اقدام انتخابی (s, a^*) را در موتور UPPAAL-SMC با تعداد نمونه‌های بهینه‌شده زمان اجرا ارزیابی می‌کند. پس از آماده شدن پاسخ، سیگنال پاداش صوری (r_{smc}) در بافر بازپخش ذخیره می‌شود تا در به‌روزرسانی‌های گرادیان مورد استفاده قرار گیرد. بدین ترتیب، تأخیرهای زمان اجرای وارسی صوری از مسیر زمان اجرای آنلاین حذف شده و تأخیر زمان واکنش تصمیم‌گیری همواره ثابت باقی می‌ماند.

۴-۸ چالش‌های سیستم‌های فیزیکی‌ـسایبری و سه‌گانه برنامه‌ریزی

اگرچه چارچوب پایه‌ای RS-DRL در سیستم‌های خودوفق با کیفیت خدمات نرم[۴۹] با موفقیت بهینه‌های محلی را پشت سر می‌گذارد، اما گذار به سیستم‌های فیزیکی‌ـسایبری بلادرنگ[۵۰]، چالش‌های ساختاری جدیدی را پدید می‌آورد. در این رده از سیستم‌ها، فاز برنامه‌ریزی با سه چالش بنیادین روبه‌رو است که آن را «سه‌گانه برنامه‌ریزی بلادرنگ» می‌نامیم:

۱. **تنگنای مهلت‌های زمانی سخت در حلقه‌های کنترلی:**[۵۱] در سیستم‌های فیزیکی‌ـسایبری حساس (نظیر ناوبری خودگردان پهپادی و اویونیک)، فرکانس حلقه کنترلی معمولاً بین ۲۰ تا ۵۰ هرتز است

[48] Non-blocking
[49] Soft-QoS
[50] Hard-Real-Time Cyber-Physical Systems
[51] Control Deadlines

که به معنای مهلت زمانی قطعی بین ۲۰ تا ۵۰ میلی‌ثانیه برای اتخاذ هر تصمیم انطباقی است [۴۷]. الگوریتم‌های بهینه‌سازی مبتنی بر جستجوی آنلاین (نظیر NSGA-III) نیازمند ثانیه‌ها و حتی دقایق هستند؛ حتی روش‌های مبتنی بر جستجوی تقلیلی روی زیرفضای حساسیت (مانند XDA-II [۴۸]) با میانگین تأخیر ۶۲٫۶۱ ms از مهلت زمانی مجاز تخطی می‌کنند.

۲. **غلبه شدید داده‌های شکست در لاگ‌های مأموریت:** در کاربردهای حساس به ایمنی فیزیکی ـ سایبری، الزامات کیفی و قیود ایمنی متعددی باید به طور هم‌زمان برآورده شوند. تحلیل داده‌های ثبت‌شده نشان می‌دهد که بیش از ٪۹۰٫۹۸ از انتقال‌های ثبت‌شده در لاگ‌ها حداقل یکی از الزامات را نقض کرده‌اند. سازوکار شکل‌دهی پاداش پایه‌ای با ضریب ثابت $\rho = ۰٫۳۰$، بدون تمایز میان شدت شکست‌ها، احتمال یکسانی را به تمامی حالات نقض قید تخصیص می‌دهد؛ در نتیجه، شکست‌های فاجعه‌بار و خطاهای غیرقابل‌جبران شانس برابری با انحرافات حاشیه‌ای برای دریافت پاداش خوش‌بینانه پیدا می‌کنند. این پدیده در سیستم‌های حساس، به واگرایی محاسباتی توابع ارزش، افزایش شدید واریانس عملیاتی، و همگرایی به «سیاست‌های انفعالی» (نظیر توقف یا پرواز با حداقل سرعت مجاز) منجر می‌گردد.

۳. **شکاف میان مدل‌های جانشین و رفتار فیزیکی سیستم:**[۵۲] به منظور تسریع در ارزیابی بلادرنگ، سیستم‌های خودوفق ناچار به استفاده از مدل‌های جانشین تحلیلی و سبک‌وزن[۵۳] هستند. با این حال، این مدل‌ها به دلیل ساده‌سازی دینامیک‌های پیچیده فیزیکی و جفت‌شدگی‌های غیرخطی عملگرها، در مرزهای بحرانی دچار خطای برآورد می‌شوند. لایه‌های محافظتی زمان اجرا، موسوم به سپرهای ایمنی[۵۴]، که بدون لحاظ خطای دنیای واقعی صرفاً بر خروجی این مدل‌های تقریبی تکیه می‌کنند، گزینه‌هایی را تأیید می‌نمایند که در فیزیک واقعی ۶ درجه آزادی به شکست قطعی یا برخورد منجر می‌شوند.

برای غلبه هم‌زمان بر این سه‌گانه، معماری ارتقایافته RS-DRL^{+} با دو الگوی معماری پیشنهادی معرفی می‌گردد.

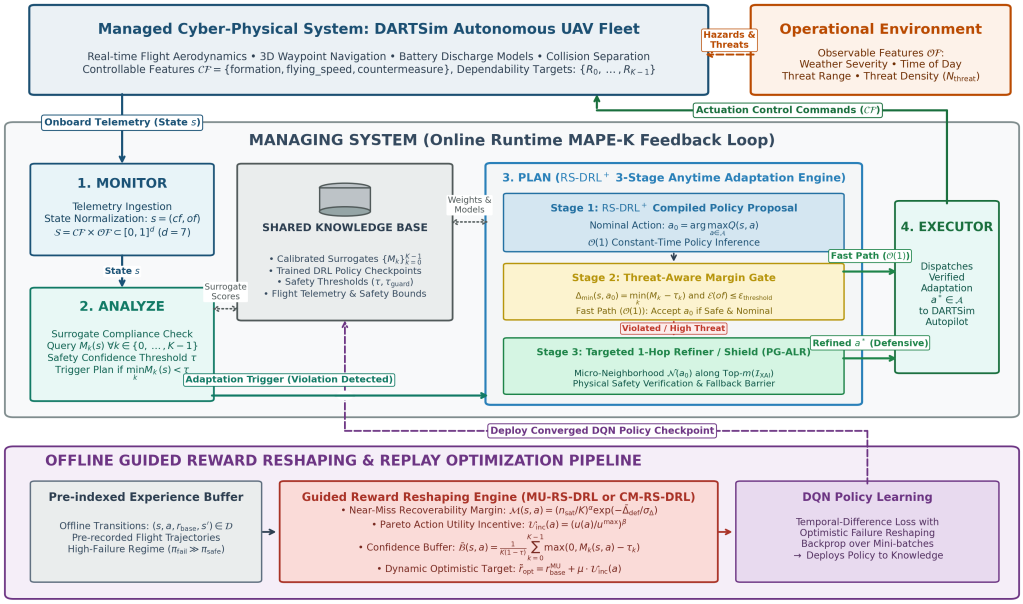
۹-۴ معماری دوسطحی سیستم RS-DRL^{+}

معماری RS-DRL^{+} بر پایه دو سطح متمایز سازماندهی شده است: سطح آفلاین که وظیفه سنتز سیاست هدایت‌شده با مشخصه را بر عهده دارد (الگوی SG-OS)، و سطح آنلاین که یک فاز برنامه‌ریزی سه‌مرحله‌ای

[52] Surrogate-to-Physics Reality Gap

[53] Surrogates

[54] Runtime Shields



شکل ۴-۶: نمای کلان معماری دوسطحی RS-DRL$^+$: خط لوله آموزش آفلاین با شکل‌دهی پاداش حساس به حاشیه در سطح پایین، و حلقه کنترلی MAPE-K مجهز به برنامه‌ریز سلسله‌مراتبی سه‌مرحله‌ای PG-ALR در سطح آنلاین برای کنترل خودگردان سیستم‌های فیزیکی‌ـ‌سایبری با نمونه‌سازی در بستر پهپادی DARTSim.

با قرارداد در هر زمان را در حلقه MAPE-K اجرا می‌نماید (الگوی CA-EPV). شکل ۴-۶ نمای کلان این معماری را به تصویر می‌کشد.

شکل ۴-۷ درخت رده‌بندی روش‌های تصمیم‌گیری در سیستم‌های خودوفق را نشان می‌دهد که سیر تکاملی از بهینه‌سازی مبتنی بر جستجو و سپرهای ایستا تا یادگیری تقویتی بدون هدایت، روش پایه‌ای RS-DRL و در نهایت معماری جامع دوسطحی RS-DRL$^+$ را تبیین می‌نماید.

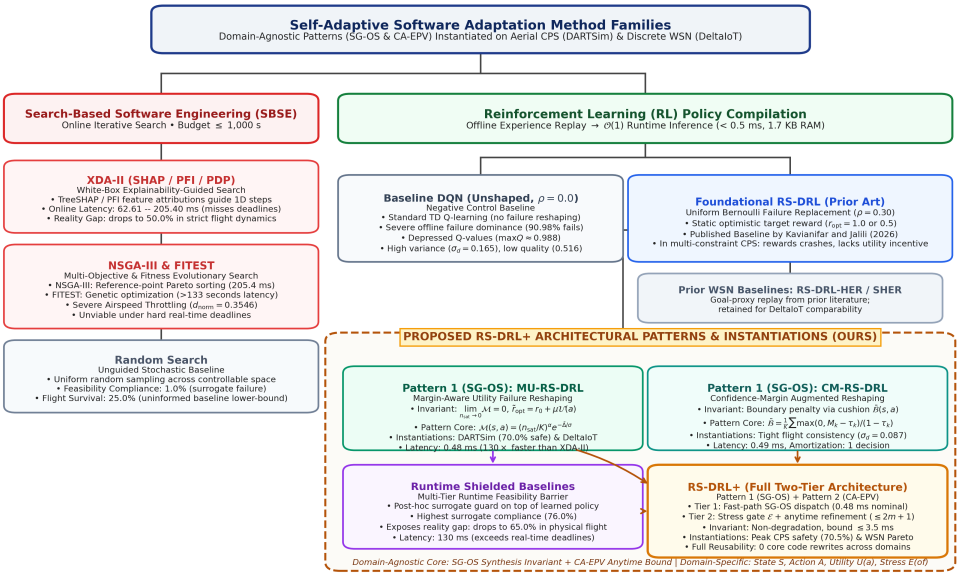
۴-۹-۱ سطح آنلاین: حلقه کنترلی بلادرنگ و تصمیم‌گیری زمان اجرا

در سطح آنلاین، حلقه MAPE-K بر روی بردار حالت نرمال‌شده $s = (cf, of)$ و مدل‌های جانشین M_k عمل می‌کند. مؤلفه تحلیل در صورتی که حداقل یک قید به مرز هشدار نزدیک شود $(\min_k M_k(s) < \tau)$ برنامه‌ریز را فعال می‌سازد. مؤلفه اجرا اقدام انطباقی برگزیده شامل تنظیمات سرعت، آرایش تیمی و اقدامات متقابل الکترونیکی[55] را اعمال می‌کند. مخزن دانش وزن‌های شبکه، آستانه‌ها و سوابق پرواز را ذخیره می‌سازد.

۴-۹-۲ سطح آفلاین: بازپخش تجارب و سنتز سیاست با فرمول‌بندی TD-Loss

در سطح آفلاین، بافر بازپخش تجارب $\mathcal{D}$ شامل ده‌ها هزار گذار ثبت‌شده $(s, a, r_{\text{base}}, s', d)$ است. در هر دسته آموزشی، فرآیند برچسب‌گذاری مجدد پاداش به صورت برنولی تحت احتمال هدایت‌شده P_{reshape} اعمال

[55] Electronic Countermeasures (ECM)



شکل ۴-۷: درخت رده‌بندی و سیر تکاملی روش‌های تصمیم‌گیری در سیستم‌های خودوفق: از بهینه‌سازی مبتنی بر جستجو و سپرهای صوری ایستا تا یادگیری تقویتی عمیق بدون هدایت، چارچوب پایه‌ای RS-DRL و معماری دوسطحی تعمیم‌یافته RS-DRL^{+}.

می‌گردد. تابع زیان یادگیری تقویتی عمیق بر پایه خطای تفاضل زمانی خارج از سیاست[۵۶] به صورت زیر فرمول‌بندی می‌شود:

$$\mathcal{L}(\theta) = \mathbb{E}_{(s,a,\tilde{r},s',d)\sim\mathcal{D}}\left[\left(\tilde{r} + (1-d)\gamma \max_{a'\in\mathcal{A}} Q(s',a';\theta^{-}) - Q(s,a;\theta)\right)^{2}\right] \qquad (۴-۸)$$

که در آن $\tilde{r}$ پاداش شکل‌یافته هدایت‌شده و $d \in \{0,1\}$ نشانگر وضعیت پایانی است. در بستر مأموریت پهپادی DARTSim، با تثبیت عوامل محیطی و تغییر متغیرهای کنترلی، هر تصمیم یک گام به عنوان وضعیت پایانی در نظر گرفته شده ($d = 1$) که مسئله را به رگرسیون راهزن زمینه‌آگاه ۱ ـ گام[۵۷] تبدیل می‌کند و مانع از واگرایی ریاضی مقادیر کیو ($Q \to -\infty$) می‌گردد.

۴-۱۰ الگوی سنتز آفلاین هدایت‌شده با مشخصه‌ها (SG-OS)

الگوی SG-OS جایگزین سازوکار شکل‌دهی پاداش با احتمال ثابت پیشین شده و از مشخصه‌های صوری و حاشیه‌های کیفی برای هدایت فرآیند شکل‌دهی پاداش بهره می‌گیرد. این الگو از طریق دو سازوکار MU-RS-DRL و CM-RS-DRL تحقق می‌یابد:

[56] Off-Policy Temporal Difference (TD) Loss

[57] Contextual Bandit

۴-۱۰-۱ شکل‌دهی پاداش هدایت‌شده با حاشیه بازیابی و مطلوبیت (MU-RS-DRL)

سازوکار MU-RS-DRL از طریق چهار مؤلفه ریاضی صوری پیاده‌سازی می‌گردد:

۱. حاشیه بازیابی انحرافات حاشیه‌ای: برای هر گذار نقض‌کننده الزامات (s, a)، میزان نزدیکی پیکربندی به انطباق کامل[58] با رابطه ریاضی زیر سنجیده می‌شود:

$$\mathcal{M}(s,a) = \left(\frac{n_{\text{sat}}}{K}\right)^{\alpha} \exp\left(-\frac{\bar{\Delta}_{\text{def}}(s,a)}{\sigma_{\Delta}}\right) \tag{۹-۴}$$

که در آن K تعداد کل الزامات کیفی (به عنوان نمونه ۱۲ قید در بستر DARTSim)، n_{sat} تعداد الزامات ارضاشده، $\alpha \geq ۱$ توان جریمه نقض هم‌زمان چند قید، و $\sigma_{\Delta} > ۰$ ضریب مقیاس خطای کسری است. مقدار $\bar{\Delta}_{\text{def}}(s,a)$ به عنوان میانگین کسری انحراف از آستانه روی الزامات نقض‌شده به صورت صوری از رابطه زیر محاسبه می‌شود:

$$\bar{\Delta}_{\text{def}}(s,a) = \frac{۱}{|\mathcal{K}_{\text{viol}}|} \sum_{k \in \mathcal{K}_{\text{viol}}} \frac{\tau_k - M_k(s,a)}{\tau_k} \qquad (\text{if} |\mathcal{K}_{\text{viol}}| > ۰ \text{ otherwise } ۰) \tag{۱۰-۴}$$

که در آن $\mathcal{K}_{\text{viol}} = \{k \in \{۰, \ldots, K-۱\} \mid M_k(s,a) < \tau_k\}$ نشان‌دهنده مجموعه اندیس‌های قیود نقض‌شده و $n_{\text{sat}} = K - |\mathcal{K}_{\text{viol}}|$ است.

از منظر مفهومی، این فرمولاسیون دو بعد مجزا از خطا را ادغام می‌نماید: **پهنای شکست** (n_{sat}/K) که نشان‌دهنده تعداد قیود نقض‌شده است، و **عمق شکست** $(\bar{\Delta}_{\text{def}})$ که شدت تخطی از حاشیه آستانه‌ها را منعکس می‌کند. اگر چندین قید به طور هم‌زمان نقض گردند، عبارت توان‌دار با نرخ چندجمله‌ای افت کرده (به عنوان مثال با $\alpha = ۲$ و ارضای نصف قیود، به ۰٫۲۵ کاهش می‌یابد) و با تعمیق انحراف از آستانه‌ها، ضریب نمایی نیز به صفر میل می‌کند. بنابراین، شکست‌های فاجعه‌بار و چندگانه به طور قطعی پالایش شده و هرگز پاداش مصنوعی دریافت نمی‌کنند ($\lim_{n_{\text{sat}} \to ۰} \mathcal{M} = ۰$).

۲. مشوق مطلوبیت عملیاتی اقدام: به منظور مهار پدیده «ایمنی ناشی از انفعال»[59] که در آن عامل برای اجتناب از نقض قیود راداری به مدهای غیرعملیاتی (نظیر توقف در فاصله دور از اهداف شناسایی) روی می‌آورد، مشوق مطلوبیت اقدام[60] تعریف می‌گردد:

$$\mathcal{U}_{\text{inc}}(a) = \left(\frac{u(a)}{u^{\max}}\right)^{\beta} \tag{۱۱-۴}$$

[58] Near-Miss Recoverability Margin

[59] Safety through Inaction Trap

[60] Action Utility Incentive

که در آن $u(a)$ مطلوبیت مأموریت (نظیر فاصله نرمال‌شده تا هدف d_{norm} در پهپاد، یا مطلوبیت شبکه $\mathcal{U}_{\text{WSN}}$ در حسگر بی‌سیم) و $\beta = ۱/۵$ ضریب مقیاس است (مطابق با کاتالوگ فراپارامترها در جدول ۴-۶).

۳. احتمال شکل‌دهی هدایت‌شده: گذار ناموفق با احتمالی متناسب با حاشیه بازیابی و مطلوبیت[۶۱] با پاداش خوش‌بینانه جایگزین می‌گردد:

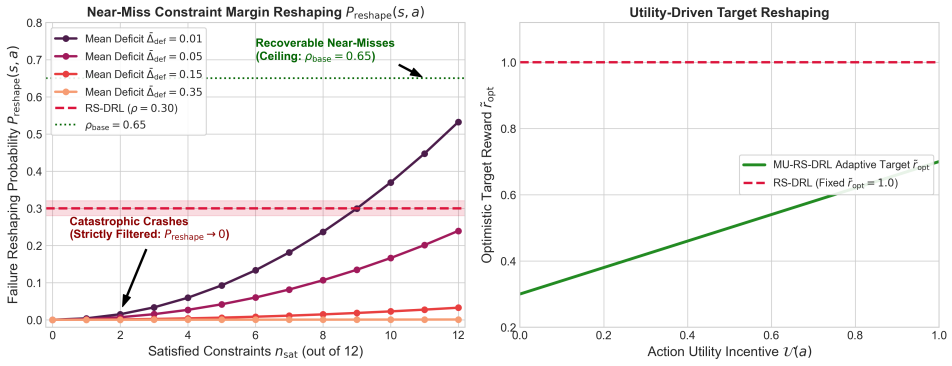
$$P_{\text{reshape}}(s,a) = \rho_{\text{base}} \cdot \mathcal{M}(s,a) \cdot [(۱ - \gamma_u) + \gamma_u \mathcal{U}_{\text{inc}}(a)] \qquad (۱۲\text{-}۴)$$

که در آن $\rho_{\text{base}} = ۰/۶۵$ سقف احتمال بازطراحی و $\gamma_u = ۰/۴۰$ وزن موازنه میان قابلیت بازیابی و مطلوبیت است.

۴. پاداش خوش‌بینانه دینامیک مقیاس‌بندی‌شده: برخلاف روش پایه‌ای که همواره پاداش ثابت ۱/۰ تزریق می‌کرد، روش MU-RS-DRL پاداش خوش‌بینانه[۶۲] را متناسب با مطلوبیت اقدام مقیاس‌بندی می‌کند:

$$\tilde{r}_{\text{opt}}(s,a) = r_{\text{base}}^{\text{MU}} + \mu \cdot \mathcal{U}_{\text{inc}}(a) \qquad (۱۳\text{-}۴)$$

که در آن $r_{\text{base}}^{\text{MU}} = ۰/۳۰$ و $\mu = ۰/۴۰$ است، به طوری که پاداش در بازه پیوسته $[۰/۳۰, ۰/۷۰]$ قرار می‌گیرد. شکل ۴-۸ تفاوت بنیادین این سازوکار هدایت‌شده را با روش پایه‌ای نشان می‌دهد.



شکل ۴-۸: مقایسه سازوکار شکل‌دهی پاداش در MU-RS-DRL در برابر RS-DRL پایه‌ای: (الف) تغییر پیوسته احتمال بر اساس تعداد الزامات ارضاشده و حاشیه بازیابی؛ (ب) مقیاس‌بندی پاداش خوش‌بینانه متناسب با مطلوبیت مأموریت.

[61] Guided Reshaping Probability

[62] Dynamic Optimistic Target

۴-۱۰-۲ بافرسازی حاشیه اطمینان برای پایداری در مرزها (CM-RS-DRL)

در سیستم‌های آستانه‌محور متداول ($M_k \geq \tau_k$)، تصمیمی که در مجاورت کرانی آستانه پذیرش قرار دارد پاداشی هم‌ارز با تصمیمات دارای حاشیه محافظه‌کارانه بالا دریافت می‌دارد. این پدیده منجر به شکنندگی سیاست کنترلی در برابر نوسانات تصادفی محیطی می‌گردد. جهت مدیریت این ناپایداری مرزی، سازوکار CM-RS-DRL بافر حاشیه اطمینان نرمال‌شده را به شرح زیر محاسبه می‌نماید:

$$\bar{\mathcal{B}}(s,a) = \frac{۱}{K(۱-\tau)} \sum_{k=۰}^{K-۱} \max\left(۰, M_k(s,a) - \tau_k\right) \in [۰, ۱] \qquad (۱۴\text{-}۴)$$

که در آن $M_k(s,a)$ برآورد اطمینان قید kـام و τ_k آستانه پذیرش متناظر است.

با استناد به این بافر اطمینان، سیگنال پاداش ایمن و پاداش شکل‌یافته با ضرایب وزن‌دهی λ_{margin} و λ_{util} بازنویسی و تقویت می‌شوند:

$$r_{\text{safe}}(s,a) = ۱/۰ + \lambda_{\text{margin}} \bar{\mathcal{B}}(s,a) + \lambda_{\text{util}} \mathcal{U}_{\text{inc}}(a) \qquad (۱۵\text{-}۴)$$

$$\tilde{r}_{\text{CM}}(s,a) = r_{\text{base}}^{\text{CM}} + \lambda_{\text{margin}} \bar{\mathcal{B}}(s,a) + \lambda_{\text{util}} \mathcal{U}_{\text{inc}}(a) \qquad (۱۶\text{-}۴)$$

این تزریق حاشیه صریح تضمین می‌کند که سیاست یادگیرنده از گزینه‌های لب‌مرزی که در مواجهه با تلاطم‌های جوی و نویز باد ناپایدار می‌شوند دوری جسته و به سمت مناطق عملیاتی عمیقاً امن همگرا گردد.

۴-۱۱ الگوی اعتبارسنجی کشسان و هرزمانی مبتنی بر قرارداد (CA-EPV)

الگوی CA-EPV در مؤلفه برنامه‌ریزی درون ماژول پالایش موضعی هدایت‌شده با سیاست، PG-ALR، استقرار یافته و فرآیند تصمیم‌گیری را در سه مرحله سازماندهی می‌نماید:

۴-۱۱-۱ ساختار ماژول PG-ALR و سلسله‌مراتب تصمیم‌گیری سه‌مرحله‌ای

مرحله اول: استنتاج پیشنهاد نامی زیر میلی‌ثانیه‌ای (۰/۴۸۵ ms): برنامه‌ریز با یک استنتاج مستقیم (گذر رو به جلو) در شبکه عصبی آموزش‌دیده Q_{MU}، گزینه نامی بهینه $a_{\cdot} = \arg\max_a Q_{\text{MU}}(s,a)$ را در زمان میانگین ۰/۴۸۵ ms پیشنهاد می‌دهد.

مرحله دوم: گیت حاشیه و شدت تنش محیطی: پیشنهاد نامی وارد گیت اعتبارسنجی حاشیه و تنش محیطی در مسیر سریع می‌شود که حاشیه مدل جانشین و شدت تنش محیطی را با رابطه زیر ارزیابی می‌کند:

$$\Delta_{\min}(s, a_\cdot) = \min_k \big(M_k(s, a_\cdot) - \tau_k\big), \qquad \mathcal{E}(of) = \sum_{j=1}^{|\mathcal{OF}|} w_j \cdot \widetilde{of}_j \tag{۱۷-۴}$$

در صورتی که $\Delta_{\min}(s, a_\cdot) \geq 0$ و شدت تنش محیطی زیر آستانه بحرانی باشد ($\mathcal{E}(of) \leq \epsilon_{\text{threshold}}$)، گزینه نامی بلافاصله در «مسیر سریع»[۶۳] بدون هیچ تأخیری به عملگرها ارسال می‌گردد (تأخیر کل زیر ۰٫۵ ms).

مرحله سوم: پالایش دفاعی ۱ـ گام هدفمند مبتنی بر XAI: در صورت نقض هر یک از شرایط یادشده، پالایش موضعی پیرامون $a_\cdot$ با بهره‌گیری از روش‌های هوش مصنوعی توضیح‌پذیر (XAI)[۶۴] بر روی زیرفضای حساسیت حاصل از مقادیر شاپلی درختی TreeSHAP[۶۵] متمرکز می‌شود:

$$\mathcal{I}_{\text{XAI}}(j) = \frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}_{s \sim \mathcal{D}} \big[|\phi_j(M_k, s)| \big] \tag{۱۸-۴}$$

همسایگی مجاز کاندیداها به گام‌های ۱ـ سطحی روی m ویژگی برتر محدود می‌گردد:

$$\mathcal{N}(a_\cdot) = \Big\{ a \in \mathcal{A} \;\Big|\; \forall j \notin \text{Top-}m(\mathcal{I}_{\text{XAI}}),\ k_j(a) = k_j(a_\cdot) \\ \wedge \sum_{j \in \text{Top-}m} |k_j(a) - k_j(a_\cdot)| \leq 1 \Big\} \tag{۱۹-۴}$$

شکل ۴-۹ نمودار جریان تصمیم‌گیری این ساختار سلسله‌مراتبی را نشان می‌دهد.

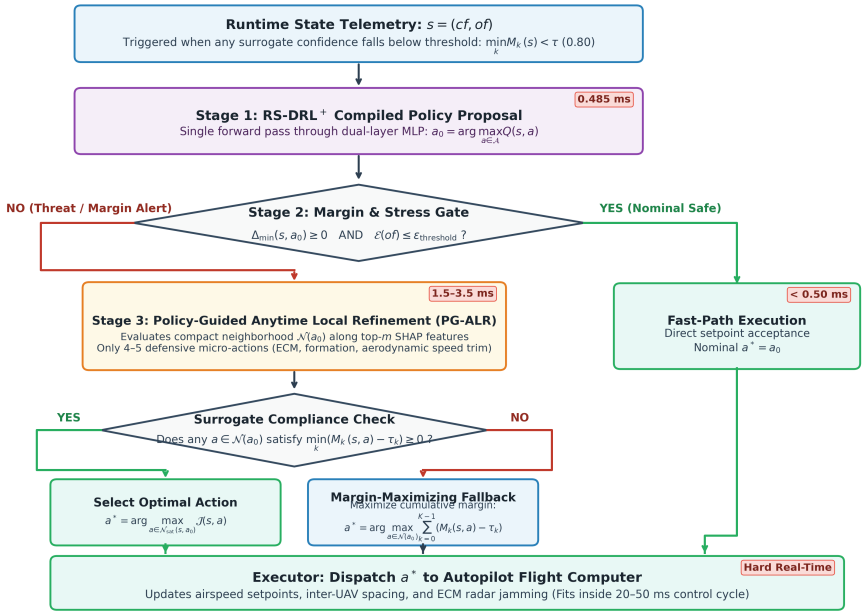
۴-۱۱-۲ تحلیل صوری پیچیدگی محاسباتی و اثبات گزاره ۱ (کران اندازه فضای کاندیداها)

گزاره ۴-۱۱-۱ (کران اندازه فضای کاندیداها بر زیرفضای حساسیت). *برای هر پیشنهاد نامی $a_\cdot \in \mathcal{A}$ در فضای پیکربندی گسسته با ابعاد d_A با مؤلفه‌های ترتیبی یا دودویی، محدودسازی اغتشاشات به گام‌های ۱ـ سطحی بر روی m ویژگی حساسیت برتر ($m \leq d_A$)، مجموعه‌ای از کاندیداها به دست می‌دهد که اندازه*

[63] Fast Path

[64] Explainable Artificial Intelligence

[۶۵] مبتنی بر چارچوب مقادیر شاپلی [۴۹] (https://github.com/shap/shap)، روش TreeSHAP برخلاف روش‌های مدل‌ناآگاه نظیر KernelSHAP که دارای پیچیدگی نمایی در تعداد ویژگی‌ها هستند، با بهره‌گیری از ساختار درختی مدل‌های جانشین، اهمیت ویژگی‌ها را در مرتبه زمانی چندجمله‌ای ($\mathcal{O}(T \cdot L \cdot D^2)$ به طور دقیق محاسبه می‌کند.



شکل ۴-۹: نمودار جریان سلسله‌مراتب تصمیم‌گیری ماژول PG-ALR: استنتاج نامی مرحله ۱ (۰/۴۸۵ ms)، گیت تنش مرحله ۲، پالایش موضعی ۱ـ گام مرحله ۳ (۱/۵ − ۳/۵ ms) و سازوکار فال‌بک حداکثرسازی حاشیه.

آن توسط نامساوی زیر مقید است:

$$|\mathcal{N}(a_\cdot)| \leq ۲m + ۱ \tag{۴-۲۰}$$

در صورتی که هر یک از ویژگی‌ها در مرزهای بازه مقداری خود قرار داشته باشند، نامساوی اکید خواهد بود.

اثبات. کاندیدای نامی $a_\cdot$ دارای فاصله مختصاتی صفر است. برای هر بعد $j \in \{۱, \ldots, m\}$ از ویژگی‌های تصویرشده، حداکثر دو اغتشاش ۱ـ گامی مجاز وجود دارد: افزایش یک سطح $(+۱)$ یا کاهش یک سطح (-۱). طبق تعریف معادله ۴-۱۹، مجموع فواصل مختصاتی اغتشاش‌ها نباید از ۱ تجاوز کند؛ بنابراین، هیچ دو بعدی نمی‌توانند به طور همزمان تغییر کنند. با جمع بستن تعداد تغییرات مجاز روی تمامی m بعد، حداکثر $۲m$ همسایه مجزا حاصل می‌گردد. با افزودن خود نقطه مبدأ $a_\cdot$، حداکثر تعداد اعضای همسایگی برابر با $۲m + ۱$ خواهد بود. در صورت برخورد هر بعد به کران‌های کمینه یا بیشینه فیزیکی، امکان حرکت در آن جهت سلب شده و تعداد اعضای همسایگی اکیداً کمتر از $۲m + ۱$ می‌گردد. □

اهمیت معماری گزاره ۱: این گزاره اثبات می‌کند که پیچیدگی اعتبارسنجی زمان اجرا از مرتبه نمایی کل فضای پیکربندی $\mathcal{O}(|\mathcal{A}| \cdot K)$ به مرتبه خطی متغیرهای حساس $\mathcal{O}(m \cdot K)$ کاهش می‌یابد. در مأموریت پهپاد خودگردان DARTSim $(m = ۳)$، تعداد گزینه‌های مورد ارزیابی از ۶۰ پیکربندی به حداکثر ۴ تا ۵ گزینه کاهش می‌یابد (کاهش ۹۳٪ در ارزیابی‌ها). این کران ریاضی تضمین می‌کند که زمان اعتبارسنجی همواره

زیر ۳/۵ ms باقی مانده و مهلت زمانی ۲۰ تا ۵۰ میلی‌ثانیه‌ای حلقه کنترل فیزیکی به طور قطعی ارضا گردد.

پیچیدگی محاسباتی و موازی‌سازی تانسوری: با داشتن K مدل جانشین ارزیابی ایمنی $M_0, \ldots, M_{K-1}$، اعتبارسنجی در هر زمان نیازمند محاسبه بردار انطباق بر روی کاندیداهای همسایگی $\mathcal{N}(a)$ است:

$$\mathbf{P}(a) = \big[M_0(s,a),\ \ldots,\ M_{K-1}(s,a)\big] \in [0,1]^K \tag{۴-۲۱}$$

بر اساس گزاره ۴-۱۱-۱، تعداد کل ارزیابی‌های زوج کاندیدا–مدل جانشین توسط نامساوی زیر مقید است:

$$N_{\text{eval}} \le (2m+1)\cdot K \tag{۴-۲۲}$$

در پیاده‌سازی مأموریت پهپادی DARTSim با ابعاد کنترلی $d_A = 3$، پارامتر حساسیت $m = 3$ و تعداد الزامات $K = 12$، کران تئوریک برابر با $N_{\text{eval}} \le (2\times 3+1)\times 12 = 84$ ارزیابی است. در زمان اجرا، به دلیل اشباع مرزهای فیزیکی پارامترها، کاندیداهای معتبر به ۴ تا ۵ پیکربندی فیلتر شده و تعداد ارزیابی‌ها به ۴۸ تا ۶۰ کاهش می‌یابد.

از منظر پیاده‌سازی سخت‌افزاری، از آنجا که تانسور کاندیداها $\mathbf{A}_{\text{cand}} \in \mathbb{R}^{|\mathcal{N}(a)|\times d_A}$ بلافاصله پس از استنتاج نامی به صورت قطعی مشخص است، ارزیابی بر روی تمامی مدل‌های جانشین در قالب یک دسته موازی تانسوری (SIMD)[۶۶] بر روی پردازنده‌های مرکزی[۶۷] بدون نیاز به شتاب‌دهنده گرافیکی در زمان ۱/۵ تا ۳/۵ میلی‌ثانیه انجام می‌پذیرد. این در حالی است که سپرهای ایمنی مرسوم زمان اجرا نیازمند ۷۲۰ ارزیابی آنلاین (12×60) و صرف زمان ۱۲۹/۹۵ میلی‌ثانیه هستند؛ بنابراین، روش پیشنهادی با ایجاد شتاب‌بخشی بیش از ۴۰ برابری، پایداری مهلت زمانی ۲۰ تا ۵۰ میلی‌ثانیه‌ای حلقه کنترل بلادرنگ را به طور قطعی تضمین می‌نماید.

تحلیل مقیاس‌پذیری در فضاهای با ابعاد بالا ($d_A \gg 1$) در برابر فضاهای گسسته شبکه‌ای: در سیستم‌های خودوفق با ابعاد متغیرهای کنترلی بسیار بزرگ (نظیر بستر DeltaIoT با $d_A = 37$ گره حسگر)، یک اغتشاش ۱–گامی چندمحوره نامقید در فضای L_∞ به صورت توان‌نمایی 3^{d_A} رشد می‌کند؛ این مقدار برای ۳۷ گره معادل $3^{37} \approx 4/5 \times 10^{17}$ پیکربندی است که هرگونه ارزیابی آنلاین را ناممکن می‌سازد. حتی اغتشاش تک‌محوره در نرم L_1 نیازمند ارزیابی $2d_A + 1 = 75$ گزینه است که فراتر از آستانه مجاز تأخیر بلادرنگ قرار می‌گیرد.

برای مهار این انفجار ترکیبیاتی، فضای تصمیم‌گیری با استفاده از هوش مصنوعی توضیح‌پذیر TreeSHAP بر زیرفضای حساسیت $\mathcal{S}_{\text{XAI}} = \text{span}\{e_{j_1}, \ldots, e_{j_m}\}$ تصویر می‌شود. این تصویر بر زیرفضا، ابعاد

[66] Tensorized Parallelism via Single Instruction, Multiple Data (SIMD)

[67] Central Processing Unit (CPU)

تصمیم‌گیری را از d_A به $m \ll d_A$ (به عنوان مثال $m = ۳ \ll ۳۷$) کاهش داده و ارزیابی‌ها را به طور قطعی به حداکثر $۲m + ۱ \leq ۷$ کاندیدای اثرگذار مقید می‌سازد. در سیستم‌های با ابعاد کم‌تر اما فضای گسسته غنی (نظیر مأموریت پهپاد تاکتیکی با $d_A = ۳$ و $|\mathcal{A}| = ۶۰$)، این برتری در قالب هرس گزینه‌های شبکه‌ای از ۶۰ پیکربندی به ۴ تا ۵ گزینه تجلی می‌یابد.

۴-۱۱-۳ قاعده انتخاب محافظت‌شده و اثبات گزاره ۲ (تضمین عدم افت ایمنی)

گزینه وفقی نهایی a^* بر اساس قاعده محافظت‌شده زیر انتخاب می‌شود:

$$a^* = \begin{cases} \arg\max\limits_{a \in \mathcal{N}_{\text{sat}}(s,a_۰)} \mathcal{J}(s,a), & \text{if} \mathcal{N}_{\text{sat}}(s,a_۰) \neq \emptyset, \\ \arg\max\limits_{a \in \mathcal{N}(a_۰)} \sum\limits_{k=۰}^{K-۱} \big(M_k(s,a) - \tau_k\big), & \text{otherwise}, \end{cases} \tag{۴-۲۳}$$

که در آن $\mathcal{J}(s,a) = u(a) + \lambda_{\text{tie}} \frac{۱}{K} \sum_{k=۰}^{K-۱} (M_k(s,a) - \tau_k)$ تابع مطلوبیت با ضریب گره‌گشایی تساوی حاشیه[۶۸] ($\lambda_{\text{tie}} = ۰/۰۵$) است، و $\mathcal{N}_{\text{sat}}$ مجموعه همسایگان سازگار با تمامی قیود جانشین است.

گزاره ۴-۱۱-۲ (حفظ پایداری ایمنی، عدم افت عملکرد و کران خطای فیزیکی تحت شکاف واقعیت)**.** *فرض کنید $a_۰ = \arg\max_{a \in \mathcal{A}} Q_{MU}(s,a)$ پیشنهاد نامی سیاست، $\mathcal{N}(a_۰)$ همسایگی ۱ـ گام حساسیت، و a^* اقدام وفقی برگزیده توسط قاعده تصمیم‌گیری محافظت‌شده (معادله ۴-۲۳)[۶۹] باشد. در این صورت، در فضای ارزیابی مدل‌های جانشین، نامساوی عدم افت ایمنی برقرار است:*

$$\mathbb{I}_{sat}(s,a^*) \geq \mathbb{I}_{sat}(s,a_۰) \tag{۴-۲۴}$$

و چنانچه پیشنهاد نامی سازگار باشد ($\mathbb{I}_{sat}(s,a_۰) = ۱$)، آنگاه $\mathbb{I}_{sat}(s,a^*) = ۱$، حاشیه ایمنی غیرمنفی است ($\Delta_{\min}(s,a^*) \geq ۰$) و تابع مطلوبیت غیرکاهشی است: $\mathcal{J}(s,a^*) \geq \mathcal{J}(s,a_۰)$.

علاوه بر این، با فرض اینکه خطای تقریب مدل‌های جانشین نسبت به دینامیک واقعی سیستم فیزیکی دارای کران مشخصی باشد؛ یعنی $\sup_{s,a,k} |M_k(s,a) - M_k^*(s,a)| \leq \epsilon_k \leq \epsilon_{\max}$ (که در آن M_k^* ارضای حقیقی قید در دینامیک پیوسته فیزیکی سیستم است)، ویژگی‌های تضمینی زیر حاصل می‌گردد:

۱. *در صورت وجود کاندیدای سازگار با جانشین ($\mathcal{N}_{sat}(s,a_۰) \neq \emptyset$)، ایمنی در دینامیک فیزیکی واقعی*

[68] Margin Tie-breaker Coefficient

[۶۹] این گزاره اثبات می‌کند که قاعده تصمیم‌گیری محافظت‌شده همواره گزینه‌ای را برمی‌گزیند که از نظر شاخص سازگاری صوری، وضعیتی برابر یا برتر از پیشنهاد نامی سیاست $a_۰$ داشته باشد؛ به گونه‌ای که هرگز گزینه‌ای ایمن به گزینه‌ای ناامن بدل نشود.

دارای کران $\Delta^*_{\min}(s,a^*) \geq -\epsilon_{\max}$ *بوده و افت مطلوبیت عملیاتی حقیقی حداکثر محدود است به:*

$$\mathcal{J}^*(s,a^*) \geq \mathcal{J}^*(s,a_\cdot) - ۲\lambda_{tie}\epsilon_{\max} \qquad (۲۵\text{-}۴)$$

۲. *در صورت عدم وجود کاندیدای سازگار* ($\mathcal{N}_{sat}(s,a_\cdot)=\emptyset$)*، میانگین حاشیه فیزیکی حقیقی در شاخه فال‌بک تضمین می‌کند:*

$$\bar{\Delta}^*(s,a^*) \geq \bar{\Delta}^*(s,a_\cdot) - ۲\epsilon_{\max} \qquad (۲۶\text{-}۴)$$

اثبات. اثبات گزاره در چهار مرحله انجام می‌پذیرد:

۱. **لم شمول پیشنهاد نامی:** طبق تعریف همسایگی در معادله ۴-۱۹، با قرار دادن گام اغتشاش صفر، نقطه مبدأ $a_\cdot$ همواره عضوی از همسایگی است ($a_\cdot \in \mathcal{N}(a_\cdot)$).

۲. **حالت اول: پیشنهاد نامی سازگار با جانشین است** ($\mathbb{I}_{\textbf{sat}}(s,a_\cdot)=۱$)**:** اگر $a_\cdot$ گیت تنش محیطی را پشت سر بگذارد ($\mathcal{E}(of) \leq \epsilon_{\text{threshold}}$)، مسیر سریع بدون تغییر $a^* = a_\cdot$ را اجرا می‌کند که معادله ۴-۲۴ را با تساوی ارضا می‌نماید. اگر پالایش مرحله ۳ به دلیل تنش محیطی فعال شود، از آنجا که $a_\cdot \in \mathcal{N}_{\text{sat}}(s,a_\cdot)$، مجموعه کاندیداهای سازگار ناتهی است ($\mathcal{N}_{\text{sat}} \neq \emptyset$). طبق شاخه اول معادله ۴-۲۳، بهینه‌سازی منحصراً درون $\mathcal{N}_{\text{sat}}$ انجام می‌شود؛ بنابراین $\mathbb{I}_{\text{sat}}(s,a^*) = ۱ \geq \mathbb{I}_{\text{sat}}(s,a_\cdot)$ و $\Delta_{\min}(s,a^*) \geq ۰$ تضمین است. همچنین به دلیل بیشینه‌سازی تابع هدف $\mathcal{J}$ بر روی این مجموعه، $\mathcal{J}(s,a^*) = \max_{a\in\mathcal{N}_{\text{sat}}} \mathcal{J}(s,a) \geq \mathcal{J}(s,a_\cdot)$ برقرار خواهد بود.

۳. **حالت دوم: پیشنهاد نامی ناسازگار است** ($\mathbb{I}_{\textbf{sat}}(s,a_\cdot)=۰$)**:** اگر حداقل یک کاندیدا در $\mathcal{N}(a_\cdot)$ تمامی قیود جانشین را برآورده سازد، $\mathcal{N}_{\text{sat}} \neq \emptyset$ شده و گزینه سازگار برگزیده می‌شود که منجر به بهبود اکید ایمنی می‌گردد ($\mathbb{I}_{\text{sat}}(s,a^*) = ۱ > ۰$). اگر هیچ کاندیدایی سازگار نباشد ($\mathcal{N}_{\text{sat}}=\emptyset$)، قاعده فال‌بک حداکثرسازی مجموع حاشیه‌ها $\sum(M_k-\tau_k)$ (یا معادل آن میانگین حاشیه $\bar{\Delta}$) را روی $\{a_\cdot\}\cup\mathcal{N}(a_\cdot)$ اجرا می‌کند. چون $a_\cdot$ در استخر ارزیابی موجود است، لزوماً $\bar{\Delta}(s,a^*) \geq \bar{\Delta}(s,a_\cdot)$ حاصل می‌گردد.

۴. **کران‌های خطای مدل جانشین تا دینامیک فیزیکی واقعی:** فرض کنید $M^*_k(s,a)$ نشان‌دهنده ارضای حقیقی قید در دینامیک پیوسته سیستم فیزیکی باشد و خطای کالیبراسیون دارای کران یکنواخت $\sup_{s,a,k}|M_k(s,a)-M^*_k(s,a)| \leq \epsilon_{\max}$ باشد.

در شاخه سازگار ($\mathcal{N}_{\text{sat}} \neq \emptyset$)، هر کاندیدا دارای حاشیه جانشین $\Delta_{\min}(s,a^*) \geq ۰$ است. از آنجا

که $\Delta^*_{\min}(s,a^*) \geq \Delta_{\min}(s,a^*) - \epsilon_{\max}$، مستقیماً نتیجه می‌شود:

$$\Delta^*_{\min}(s,a^*) \geq -\epsilon_{\max}$$

همچنین در صورت سازگاری $a.$، بهینه‌سازی $\mathcal{J}(s,a^*) \geq \mathcal{J}(s,a.)$ را تضمین می‌کند. با تعریف تابع هدف مطلوبیت‌ـحاشیه در فیزیک حقیقی به صورت $\mathcal{J}^*(s,a) = u(a) + \lambda_{\text{tie}}\bar{\Delta}^*(s,a)$، خطای برآورد برابر است با:

$$|\mathcal{J}(s,a) - \mathcal{J}^*(s,a)| = \lambda_{\text{tie}}|\bar{\Delta}(s,a) - \bar{\Delta}^*(s,a)| \leq \lambda_{\text{tie}}\epsilon_{\max}$$

با اعمال نامساوی مثلثی:

$$\begin{aligned}\mathcal{J}^*(s,a^*) &\geq \mathcal{J}(s,a^*) - \lambda_{\text{tie}}\epsilon_{\max} \\ &\geq \mathcal{J}(s,a.) - \lambda_{\text{tie}}\epsilon_{\max} \\ &\geq (\mathcal{J}^*(s,a.) - \lambda_{\text{tie}}\epsilon_{\max}) - \lambda_{\text{tie}}\epsilon_{\max} = \mathcal{J}^*(s,a.) - ۲\lambda_{\text{tie}}\epsilon_{\max}\end{aligned}$$

در شاخه فال‌بک ناسازگار ($\mathcal{N}_{\text{sat}} = \emptyset$)، قاعده فال‌بک میانگین حاشیه جانشین را بیشینه می‌سازد، پس $\bar{\Delta}(s,a^*) \geq \bar{\Delta}(s,a.)$. با توجه به اینکه $|\bar{\Delta}(s,a) - \bar{\Delta}^*(s,a)| \leq \epsilon_{\max}$:

$$\bar{\Delta}^*(s,a^*) \geq \bar{\Delta}(s,a^*) - \epsilon_{\max} \geq \bar{\Delta}(s,a.) - \epsilon_{\max} \geq \bar{\Delta}^*(s,a.) - ۲\epsilon_{\max}$$

بنابراین، افت احتمالی ایمنی فیزیکی حقیقی و مطلوبیت عملیاتی همواره به حداکثر دو برابر خطای کالیبراسیون بدترین حالت مدل‌های جانشین محدود است و از فروپاشی فاجعه‌بار جلوگیری به عمل می‌آید.

□

۴-۱۱-۴ قراردادهای عام معماری و نمونه‌سازی در دامنه‌های کاربردی

جدول ۴-۵ تفکیک صوری میان رابط‌های مستقل از دامنه این دو الگوی معماری و نمونه‌سازی‌های آن‌ها را در دو بستر DARTSim و DeltaIoT خلاصه می‌سازد.

جدول ۴-۵: قراردادهای معماری مستقل از دامنه الگوهای SG-OS و CA-EPV در برابر نمونه‌سازی‌های تجربی

عنصر معماری	قرارداد الگوی عام	نمونه‌سازی DARTSim (CPS)	نمونه‌سازی DeltaIoT (WSN)
فضای حالت ($\mathcal{S}$)	$\mathcal{S} = \mathcal{CF} \times \mathcal{OF}$ نرمال‌شده	سرعت پرواز، آرایش، اخلالگر، رادار و آب‌وهوا	توان ارسال، توزیع ترافیک، نویز و بار ترافیک
الزامات کیفی ($\mathcal{R}$)	K الزام هم‌زمان با آستانه‌های τ_k	۱۲ الزام شناسایی هدف و فرار از رادار	۳ هدف اتلاف بسته، تأخیر و مصرف انرژی
حاشیه بازیابی ($\mathcal{M}$)	معادله ۴-۹ بر روی عمق و پهنا	حاشیه دالان‌های مانور ($K = ۱۲, \alpha = ۲/۰$)	حاشیه اهداف آستانه‌ای ($K_{\text{thresh}} = ۲, \alpha = ۰/۶$)
مشوق مطلوبیت ($\mathcal{U}_{\text{inc}}$)	رابطه ۴-۱۱ نرمال‌شده تا ۱/۰	فاصله نرمال‌شده بقای مأموریت d_{norm}	شاخص مرکب مطلوبیت شبکه $\mathcal{U}_{\text{WSN}}$
گیت تنش ($\mathcal{E}$)	ترکیب وزنی عوامل محیطی	تنش راداری و بادهای جوی	میانگین تداخل و نویز کانال‌های رادیویی
فضای حساسیت ($\mathcal{S}_{\text{XAI}}$)	m بعد برتر بر اساس TreeSHAP	ابعاد اخلالگر، آرایش و گام‌های سرعت ($m = ۳$)	توان ارسال و مسیرهای گلوگاه شبکه ($m = ۲$)
کاندیداهای پالایش ($\mathcal{N}$)	$\lvert\mathcal{N}(a.)\rvert \leq ۲m + ۱$ (گزاره ۱)	حداکثر ۴ تا ۵ گزینه انطباقی در $<$ ۳/۵ ms	حداکثر ۵ پیکربندی شبکه در $<$ ۰/۳ ms

۴-۱۱-۵ پیکربندی فراپارامترها و مشخصات معماری شبکه عصبی

به منظور تضمین قابلیت بازتولیدپذیری کامل[۷۰] و شفافیت محاسباتی، جدول ۴-۶ تمامی تنظیمات بهینه‌سازی، ساختار شبکه‌های عصبی و پارامترهای الگوریتم‌های RS-DRL و RS-DRL$^+$ را در هر دو بستر DARTSim و DeltaIoT خلاصه می‌سازد.

توجیه سخت‌افزاری ابعاد شبکه بر روی سیستم‌های تعبیه‌شده بلادرنگ: معماری پرسپترون چندلایه فشرده (۶۴ × ۲ در DARTSim) دارای ردپای حافظه بسیار اندکی (کمتر از ۵۰ کیلوبایت) است که درون حافظه نهان سطح اول و دوم[۷۱] ریزپردازنده‌های تعبیه‌شده بلادرنگ (نظیر معماری‌های ARM Cortex-M7 یا Cortex-A53 مورد استفاده در اوبونیک) جای می‌گیرد. این ویژگی مهندسی، وابستگی به پردازنده‌های گرافیکی حجیم و پرمصرف را حذف کرده، مانع از رقابت بر سر پهنای باند حافظه DRAM شده و پاسخ‌گویی استنتاج قطعی زیر نیم میلی‌ثانیه را تضمین می‌سازد.

۴-۱۱-۶ الگوریتم جامع آموزش آفلاین و تصمیم‌گیری هرزمانی RS-DRL$^+$

الگوریتم ۴-۲ جریان کامل آموزش آفلاین هدایت‌شده با مشخصه و اجرای آنلاین سلسله‌مراتبی سه‌مرحله‌ای را نشان می‌دهد.

[70] Full Reproducibility

[71] L1/L2 Cache

جدول ۴-۶: کاتالوگ تفصیلی فراپارامترها و پیکربندی معماری شبکه‌های عصبی در بسترهای ارزیابی

زیرسیستم / مؤلفه	فراپارامتر	مقدار انتخابی	نقش معماری و توجیه مهندسی
شبکه DQN (بستر DARTSim)	معماری لایه‌ها و تابع فعال‌ساز	MLP۲ × ۶۴ ، ReLU	شبکه پیش‌خور ۲ لایه پنهان (هر یک ۶۴ نورون) با فعال‌ساز ReLU
	الگوریتم بهینه‌ساز و نرخ یادگیری	Adam، $\eta = ۱۰^{-۳}$	برآورد گشتاور تطبیقی ($\beta_۱ = ۰/۹, \beta_۲ =$ ۰/۹۹۹)، اندازه گام ۰/۰۰۱
	افق تنزیل و اندازه دسته	$\gamma = ۰/۹۹$ ،$B = ۶۴$	ضریب تنزیل زمانی γ و ۶۴ گذار در هر به‌روزرسانی گرادیان
	فرکانس به‌روزرسانی شبکه هدف	$C = ۵۰۰$ گام	همگام‌سازی سخت شبکه هدف در هر ۵۰۰ گام آموزش آفلاین
	ظرفیت حافظه بازپخش تجربه	۳۰,۰۰۰ گذار	بافر آفلاین شامل ۲,۷۰۶ موفقیت و ۲۷,۲۹۴ شکست (عدم توازن شدید)
شبکه DQN (بستر DeltaIoT)	معماری لایه‌ها و بهینه‌ساز	MLP۲ × ۱۲۸ ، ReLU	۲ لایه پنهان با ۱۲۸ نورون، بهینه‌ساز Adam با نرخ $\eta = ۱۰^{-۳}$ و اندازه دسته $B = ۶۴$
	ظرفیت بافر بازپخش تجربه	۲۰,۰۰۰ گذار	برگرفته از چرخه‌های واقعی پایش تداخل و ترافیک شبکه
	همگام‌سازی شبکه هدف	$C = ۲۰۰$ گام	بازه کوتاه‌تر همگام‌سازی به علت دینامیک پیوسته تغییر کانال‌های رادیویی
سنتز هدایت‌شده (MU-RS-DRL)	سقف احتمال شکل‌دهی	$\rho_{\text{base}} = ۰/۶۵, \rho = ۰/۳۰$	سقف احتمال خوش‌بینی ρ_{base} در انحرافات حاشیه‌ای و نرخ پایه ρ
	توان شدت و مقیاس کسری	$\sigma_\Delta = ۰/۰۵$ ،$\alpha = ۲/۰$	توان جریمه نقض هم‌زمان $(n_{\text{sat}}/K)^\alpha$ و مقیاس کسری $\exp(-\bar{\Delta}_{\text{def}}/\sigma_\Delta)$
	توان مطلوبیت و وزن موازنه	$\gamma_u = ۰/۴۰$ ،$\beta = ۱/۵$	مشوق مطلوبیت اقدام $\mathcal{U}_{\text{inc}}(a)$ و وزن موازنه با حاشیه بازیابی
	پاداش خوش‌بینانه پویا	$r_{\text{base}}^{\text{MU}} = ۰/۳۰, \mu = ۰/۴۰$	هدف خوش‌بینانه $\tilde{r}_{\text{opt}} \in [۰/۳۰, ۰/۷۰]$ متناسب با مطلوبیت مأموریت
بافرسازی حاشیه (CM-RS-DRL)	آستانه انطباق و نرمال‌سازی	$۱/۰ - \tau = ۰/۲۰$ ،$\tau = ۰/۸۰$	آستانه سازگاری قید و ضریب نرمال‌سازی حاشیه اضافه
	ضرایب تقویت حاشیه و مطلوبیت	$\lambda_{\text{margin}} = ۰/۳۰, \lambda_{\text{util}} = ۰/۳۰$	پاداش‌های افزوده حاشیه اطمینان $\mathcal{B}(s,a)$ با پاداش پایه $r_{\text{base}}^{\text{CM}} = ۰/۷۰$
پالایش در هر زمان (PG-ALR)	ابعاد حساسیت شاپلی و گام	$\delta \leq ۱$ ،$\text{Top-}m = ۳$	انتخاب ۳ ویژگی حساس برتر بر اساس TreeSHAP و محدودسازی به همسایگی ۱ـ گام
	ضریب گره‌گشایی تساوی حاشیه	$\lambda_{\text{tie}} = ۰/۰۵$	اولویت‌بندی گزینه‌های با حاشیه ایمنی بیشتر در صورت برابری مطلوبیت
	آستانه‌های گیت تنش محیطی	تهدید ۴۰ $\geq$، باد ۳ $\geq$	شرایط فعال‌سازی مسیر پالایش مرحله ۳ در صورت فراتر رفتن تنش از آستانه بحرانی

الگوریتم ۴-۲ معماری دوسطحی $^{+}$RS-DRL (سنتز آفلاین و تصمیم‌گیری هرزمانی آنلاین)

Tier 1: Offline Specification-Guided Synthesis (SG-OS)
Input: Offline log $\mathcal{D}$, surrogates $\{M_k\}_{k=0}^{K-1}$, thresholds $\{\tau_k\}$
for each training step **do**
  Sample minibatch $B \sim \mathcal{D}$
  for each transition $(s, a, r_{\text{base}}, s', d)$ in B **do**
    Compute recoverability margin $\mathcal{M}(s, a)$ via Eq. (4-9)
    Compute action utility incentive $\mathcal{U}_{\text{inc}}(a)$ via Eq. (4-11)
    Compute confidence buffer $\bar{\mathcal{B}}(s, a)$ via Eq. (4-14)
    Compute guided probability $P_{\text{reshape}}(s, a)$ via Eq. (4-12)
    if $rand(0, 1) < P_{\text{reshape}}(s, a)$ **then**
      Compute shaped reward $\tilde{r}$ via Eq. (4-13) / Eq. (4-16) {MU/CM guided target}
    else
      Compute base/reinforced reward $\tilde{r} \leftarrow r_{\text{safe}}(s, a)$ via Eq. (4-15)
    end if
  end for
  Update Q-network θ on minibatch B via loss Eq. (4-8)
end for
Tier 2: Online Contract-Anytime Verification (CA-EPV / PG-ALR)
Runtime state $s = (cf, of)$ observed
Stage 1: Propose nominal adaptation $a_0 \leftarrow \arg\max_{a \in \mathcal{A}} Q(s, a; \theta)$ in < 0.5 ms
Stage 2: Evaluate margin $\Delta_{\min}(s, a_0)$ and environmental stress $\mathcal{E}(of)$ via Eq. (4-17)
if $\Delta_{\min}(s, a_0) \geq 0$ **and** $\mathcal{E}(of) \leq \epsilon_{\text{threshold}}$ **then**
  return $a^* \leftarrow a_0$ {Fast Path: nominal proposal verified compliant}
end if
Stage 3: Policy-Guided Anytime Local Refinement (PG-ALR)
Construct 1-hop sensitivity neighborhood $\mathcal{N}(a_0)$ via TreeSHAP ($|\mathcal{N}| \leq 2m + 1$)
Evaluate candidate tensor across surrogates $\mathbf{P}(a) = [M_0(s, a), \ldots, M_{K-1}(s, a)]$
Identify compliant set $\mathcal{N}_{\text{sat}} \leftarrow \{a \in \mathcal{N}(a_0) \mid \min_k M_k(s, a) \geq \tau_k\}$
if $\mathcal{N}_{\text{sat}} \neq \emptyset$ **then**
  $a^* \leftarrow \arg\max_{a \in \mathcal{N}_{\text{sat}}} \mathcal{J}(s, a)$ {Compliant branch: maximize utility with margin tie-breaker}
else
  $a^* \leftarrow \arg\max_{a \in \mathcal{N}(a_0)} \sum_{k=0}^{K-1} (M_k(s, a) - \tau_k)$ {Fallback branch: maximize cumulative surrogate margin}
end if
return a^* {Guaranteed compliance in < 3.5 ms}

۴-۱۲ نگاشت معماری و پاسخ به پرسش‌های پژوهش (RQ1 تا RQ6)

معماری ارائه‌شده در این فصل، پاسخ‌های مشخص و صوری به پرسش‌های شش‌گانه رساله ارائه می‌دهد:

پاسخ به سوال اول و دوم (RQ1 و RQ2): سازوکار شکل‌دهی پاداش (بخش‌های ۴-۵ و ۴-۱۰) با تبدیل نمونه‌برداری‌های ناموفق به پاداش‌های خوش‌بینانه، فرار از نقاط بهینه محلی را تضمین نموده و ادغام آن در فاز نمونه‌برداری بافر تجربه، تعمیم‌پذیری به سناریوهای پویای پیش‌بینی‌نشده را فراهم می‌سازد.

پاسخ به سوال سوم (RQ3): سیاست تفکیک زمانی (بخش ۴-۲) مسیر تصمیم‌گیری آنلاین را مستقل از آموزش سنگین نگاه داشته و امکان مدیریت فضاهای گسسته عظیم تا ۴۰۹۶ گزینه را در زمان زیر نیم میلی‌ثانیه میسر می‌سازد.

پاسخ به سوال چهارم (RQ4): ماهیت مستقل از دامنه روش پایه‌ای و ترکیب پاداش صوری با بازخورد محیط، برتری مجانبی بر رقبای مبتنی بر هدف (نظیر HER[۷۲] و Soft HER) و روش‌های جستجوی ایستا را در شبکه‌های حسگر تضمین می‌کند.

پاسخ به سوال پنجم (RQ5): گزاره ۴-۱۱-۱ با اثبات کران اندازه فضای کاندیداها $|\mathcal{N}(a_\cdot)| \leq 2m+1$، پیچیدگی فاز برنامه‌ریزی را به مرتبه خطی تقلیل داده و پاسخ‌گویی قطعی زیر ۳/۵ میلی‌ثانیه را تضمین می‌نماید که مهلت زمانی ۲۰ تا ۵۰ میلی‌ثانیه‌ای کنترل سیستم‌های فیزیکی–سایبری را ارضا می‌کند. همچنین گزاره ۴-۱۱-۲ تضمین می‌نماید که ایمنی سیستم در فاز پالایش هرگز تضعیف نخواهد شد.

پاسخ به سوال ششم (RQ6): الگوی SG-OS با فرمول‌بندی حاشیه بازیابی $\mathcal{M}(s,a)$ و پاداش‌های حاشیه اطمینان $\bar{\mathcal{B}}(s,a)$، داده‌های شکست لاگ‌های بازپخش را متناسب با قابلیت بازیابی پالایش نموده و با مهار رفتار انفعالی عامل[۷۳]، پایداری مأموریت را در مواجهه با اختلاف رفتار مدل‌های جانشین نسبت به دینامیک فیزیکی واقعی تضمین می‌نماید.

۴-۱۳ بحث پیرامون مفروضات و محدودیت‌های روش

معماری پیشنهادی بر پایه دو فرض واقع‌گرایانه استوار است: نخست، **فضای عمل گسسته یا گسسته‌سازی‌پذیر** که در آن پارامترهای تنظیمی سیستم به صورت سطوح گسسته مدل می‌شوند. در سیستم‌های فیزیکی–سایبری (نظیر پله‌های سرعت پرواز، وضعیت دودویی اخلالگر و آرایش تیمی)، این گسسته‌سازی امری متداول بوده و پایداری شبکه DQN را تضمین می‌کند. دوم، **در دسترس بودن مدل‌های صوری یا جانشین زمان اجرا** که در شبکه‌های حسگر با مدل صوری برای ابزار UPPAAL-SMC و در سیستم‌های فیزیکی–سایبری با مدل‌های طبقه‌بند جانشین جهت ارزیابی کم‌تأخیر الزامات محقق می‌گردد.

محدودیت‌های فنی روش شامل نیاز به کالیبراسیون فراپارامترهای پایه (ρ_{base} و σ_Δ) در زمان راه‌اندازی و تمرکز فعلی بر حلقه‌های کنترلی تک‌عاملی متمرکز است که زمینه را برای تحقیقات آتی پیرامون سیستم‌های چندعاملی توزیع‌شده هموار می‌سازد.

۴-۱۴ خلاصه فصل

در این فصل، معماری دوسطحی روش پیشنهادی رساله به تفصیل تبیین گردید و نحوه غلبه چارچوب پایه‌ای RS-DRL بر بهینه‌های محلی و چگونگی مهار سه‌گانه مهلت‌های زمانی سخت در حلقه‌های کنترل فیزیکی، عدم توازن شکست در لاگ‌ها، و اختلاف رفتار مدل‌های جانشین با دینامیک فیزیکی واقعی توسط معماری پیشرفته RS-DRL$^+$ تشریح شد. اثبات صوری گزاره‌های ۱ و ۲، مبانی ریاضیاتی این معماری را تحکیم بخشید.

در فصل آینده، ارزیابی‌های تجربی گسترده بر روی دو بستر DeltaIoT و ۲,۰۰۰ پرواز حلقه‌ـ بسته فیزیکی در DARTSim ارائه خواهد شد.

فصل پنجم

ارزیابی تجربی

۵-۱ مقدمه

ارزیابی تجربی نقشی اساسی در اعتبارسنجی اثربخشی و کارایی معماری‌های پیشنهادی در سیستم‌های خودوفق ایفا می‌کند. در این رساله، فرآیند ارزیابی تجربی در قالب یک ساختار پیش‌رونده سه‌مرحله‌ای سازمان‌دهی شده است:

۱. **ارزیابی چارچوب پایه‌ای RS-DRL در بستر شبکه حسگر بی‌سیم DeltaIoT [۲۷]:** سنجش قابلیت فرار از نقاط بهینه محلی در سیستم‌های توزیع‌شده با الزامات کیفیت خدمات نرم[1] بدون نیاز به بازآموزی آنلاین.

۲. **ارزیابی معماری دوسطحی RS-DRL$^+$ در سیستم فیزیکی ـ سایبری ناوگان پهپادی DARTSim [۲۹]:** سنجش توانمندی الگوهای SG-OS و CA-EPV در مهار سه‌گانه مهلت زمانی سخت پروازی (۲۰ تا ۵۰ میلی‌ثانیه)، عدم توازن شدید داده‌های شکست در لاگ‌ها (بیش از ۹۰٪)، و شکاف واقعیت میان مدل‌های جانشین و فیزیک ۶ درجه آزادی پرواز در قالب ۲,۰۰۰ پرواز حلقه ـ بسته.

۳. **ارزیابی انتقال‌پذیری و تعمیم بین‌دامنه‌ای الگوهای معماری به بستر DeltaIoT:** سنجش قابلیت استفاده مجدد الگوهای معماری پیشنهادی در حل چالش‌های مقیاس‌پذیری در فضای گسترده ۴۰۹۶ گزینه‌ای شبکه DeltaIoTv2 و دستیابی به کران‌های بهینگی پارتو.

در ادامه، ابتدا اهداف ارزیابی و نگاشت آن‌ها بر پرسش‌های شش‌گانه پژوهش تشریح شده، سپس تنظیمات آزمایشگاهی، مجموعه داده‌ها و خطوط پایه مقایسه‌ای معرفی می‌شوند. پس از آن، نتایج تجربی حاصل از این سه مرحله به همراه اعتبارسنجی آماری ناپارامتری ارائه خواهد شد.

[1] Soft Quality of Service (Soft-QoS)

۵-۲ اهداف ارزیابی و سوالات تحقیق

ارزیابی تجربی این رساله همسو با پرسش‌های اساسی شش‌گانه مطرح‌شده در فصل اول، اهداف مشخصی را دنبال می‌کند که در جدول ۵-۱ نگاشت گردیده‌اند:

جدول ۵-۱: هم‌راستایی اهداف ارزیابی تجربی با سوالات شش‌گانه تحقیق

سوال تحقیق (RQ)	رویکرد ارزیابی و معیارهای تجربی
سوال اول (خروج از بهینه‌های محلی): عبور از بهینه‌های محلی بدون بازآموزی	مقایسه منحنی‌های همگرایی یادگیری، پاداش مجانبی و خطای تفاضل زمانی (TD Loss) در برابر روش‌های پایه در بسترهای DeltaIoT و داده‌های آفلاین DARTSim.
سوال دوم (ادغام شکل‌دهی پاداش): تعمیم‌پذیری به شرایط محیطی متغیر	مطالعه تفکیک اثر و ابلیشن در برابر روش‌های پس‌نگر نظیر HER و Soft HER و سنجش پایداری سیاست تحت رانش مفهومی و تداخل سیگنال.
سوال سوم (مقیاس‌پذیری فضاهای بزرگ): مدیریت فضاهای گسسته تا ۴۰۹۶ گزینه	ارزیابی عملکرد در سه نسخه DeltaIoTv1 (۲۱۶ گزینه)، v1.1 (۱۲۹۶ گزینه) و v2 (۴۰۹۶ گزینه) و ثبت تأخیر استنتاج آنلاین زیر نیم میلی‌ثانیه.
سوال چهارم (ارزیابی در سیستم‌های با کیفیت خدمات نرم): مقایسه در برابر ۶ خط پایه	تقابل با ۶ خط پایه موجود نظیر ϵ-greedy DQN، HER، Soft HER، DLASER+، ML4EAS و پیکربندی مرجع ایستا (Reference) تحت قراردادهای چندهدفه و اهداف آستانه‌ای سخت (TT).
سوال پنجم (رعایت مهلت‌های زمانی سخت پروازی - RQ5): اعتبارسنجی در هر زمان	سنجش تأخیر برنامه‌ریزی در مسیر سریع (۰/۴۸ میلی‌ثانیه) و پالایش دفاعی مرحله ۳ (زیر ۳/۵ میلی‌ثانیه) در برابر مهلت‌های ۲۰ تا ۵۰ میلی‌ثانیه‌ای ناوگان پهپادی DARTSim.
سوال ششم (مهار شکاف واقعیت و غلبه بر لاگ‌های شکست - RQ6): بقای فیزیکی در مأموریت	ارزیابی ۲,۰۰۰ پرواز حلقه‌بسته فیزیکی ۶ درجه آزادی در DARTSim، مقایسه انطباق مدل‌های جانشین در برابر موفقیت فیزیکی، و سنجش کاهش واریانس عملیاتی.

۵-۳ تنظیمات آزمایشگاهی و مشخصات بسترها

فرمول‌بندی مسئله یادگیری تقویتی شامل فضای حالت، فضای اقدام و توابع پاداش، دقیقاً بر اساس مدل ارائه‌شده در فصل‌های پیشین بنا شده است. به منظور فراهم نمودن قابلیت بازتولید کامل[۲] آزمایش‌ها، ویژگی‌های دو بستر آزمایشی در جدول ۵-۲ خلاصه و مقایسه گردیده است.

۵-۳-۱ مشخصات بستر نرم‌افزاری، سخت‌افزاری و ردپاهای تجربی

جهت شبیه‌سازی شرایط واقعی در زمان اجرا، از ردپاهای محیطی تجربی[۳] مستخرج از پژوهش جرواستاتوپولوس[۴] و همکاران [۲۷] در سیستم DeltaIoT[۵] استفاده شده است که الگوهای تداخلات شبکه‌ای متغیر بین ۴۰ dB−

[2] Reproducibility

[3] Environmental Traces

[4] Ilias Gerostathopoulos

[۵] بستر DeltaIoT: https://people.cs.kuleuven.be/~danny.weyns/software/DeltaIoT/

جدول ۵-۲: مشخصات تطبیقی دو بستر ارزیابی تجربی: ناوگان پهپادی DARTSim در برابر شبکه حسگر DeltaIoT

ابعاد ارزیابی	بستر فیزیکی‌ـسایبری: DARTSim Multi-UAV	بستر شبکه حسگر: DeltaIoT WSN
دامنه کاربرد	شناسایی تاکتیکی و خودمختار هوایی	شبکه حسگر بی‌سیم صنعتی و اینترنت اشیاء
مقیاس سیستم	۳ پهپاد، ۶ دالان ارتفاعی، تا ۱۰۰ تهدید راداری	۱۵ گره حسگر (نسخه v1)، ۳۷ گره حسگر (نسخه v2)
فضای وفقی ($\|A\|$)	۶۰ پیکربندی گسسته پروازی (سرعت، آرایش، اخلالگر)	۲۱۶ گزینه (نسخه v1)، ۴۰۹۶ گزینه (نسخه v2)
مهلت حلقه کنترل	۲۰ تا ۵۰ میلی‌ثانیه (مهلت زمانی سخت پروازی)	چرخه‌های چند دقیقه‌ای انطباق (زمان‌بندی نرم)
اهداف کیفی و الزامات	۱۲ الزام صوری قابلیت اعتماد (Dependability) (شناسایی در برابر تهدید)	۳ هدف کیفیت خدمات: اتلاف بسته، تأخیر و مصرف انرژی
پیامد شکست در انطباق	فاجعه‌بار (برخورد موشک، برخورد تیمی، یا سقوط فیزیکی)	افت تدریجی کیفیت (اتلاف بسته و ارسال مجدد)
دینامیک شبیه‌سازی	شبیه‌ساز ۶ درجه آزادی پیوسته پرواز به زبان C++	شبیه‌ساز گسسته شبکه و مدل‌چکینگ زمان اجرا
عدم توازن داده لاگ	غلبه شدید شکست‌ها (۹۰/۹۸٪ انتقال‌های بافر بازپخش)	جابجایی ملایم داده‌ها (نویز کانال و نوسان ترافیک)

جدول ۵-۳: نمونه‌های مورد مطالعه سیستم DeltaIoT [۲۷]

نمونه (نسخه)	تعداد سنسورها	اندازه فضای وفقی (گزینه‌ها)	گام‌های آموزش
DeltaIoTv1	۱۵	۲۱۶	۱۰۰۰۰
DeltaIoTv1.1	۱۶	۱۲۹۶	۶۴۸۰۰
DeltaIoTv2	۳۷	۴۰۹۶	متناسب با مقیاس شبکه

تا ۱۵ dB+ و نوسانات بار ترافیکی پیام‌ها را پوشش می‌دهد. در بستر هوانوردی فیزیکی‌ـسایبری DARTSim[۶] نیز از ۵۰,۰۰۰ انتقال تجربی ثبت‌شده در سناریوهای مأموریتی با عدم توازن شدید داده‌های شکست بهره گرفته شده است.

بستر پیاده‌سازی ارزیابی تجربی بر پایه ابزارها و چارچوب‌های محاسباتی استاندارد توسعه یافته است: برای ایجاد محیط‌های یادگیری تقویتی از کتابخانه استاندارد Gymnasium[۷] [۵۰] و برای آموزش شبکه‌های عصبی عمیق از چارچوب Stable-Baselines3[۸] [۵۱] استفاده شده است. سازوکارهای شکل‌دهی تصادفی پاداش و سنتز آفلاین هدایت‌شده با مشخصه به صورت مستقیم درون حافظه بازپخش[۹] توسعه یافته‌اند. برای اعتبارسنجی صوری و ایمنی گزینه‌های وفقی نیز از موتور UPPAAL-SMC[۱۰] [۲۳] و چارچوب ActivFORMS[۱۱] [۴۳] بهره گرفته شده است. کلیه آزمایش‌های زمانی و حافظه‌ای بر روی پردازنده AMD Ryzen 9 5950X[۱۲] با ۱۶ هسته فیزیکی (فرکانس پایه ۳/۴ گیگاهرتز و بوست ۴/۹ گیگاهرتز) و ۶۴ گیگابایت حافظه رم DDR4 اجرا گردیده‌اند.

[۶] شبیه‌ساز ناوگان پهپادی DARTSim: https://github.com/cps-sei/dartsim

[۷] کتابخانه Gymnasium (بنیاد فاراما): https://gymnasium.farama.org/

[۸] چارچوب Stable-Baselines3: https://github.com/DLR-RM/stable-baselines3

[9] Replay Buffer

[۱۰] ابزار بررسی مدل آماری UPPAAL-SMC: https://uppaal.org/

[11] Active Formal Models for Self-Adaptation

[12] AMD Ryzen 9 5950X 16-Core Processor

۵-۳-۲ کالیبراسیون و تنظیمات فراپارامترها

به منظور دستیابی به عملکرد پایدار و همگرایی قابل اطمینان، فراپارامترهای[13] الگوریتم یادگیری تقویتی از طریق فرآیند جستجوی شبکه‌ای[14] تنظیم شده‌اند. مقادیر کلیدی شامل نرخ یادگیری ($\alpha = ۱۰^{-۴}$ تا ۵×۱۰^{-۴})، اندازه دسته آموزش (۶۴ تا ۱۲۸)، فرکانس به‌روزرسانی شبکه هدف (۱۰۰۰ گام)، و برنامه کاهش نرخ کاوش ϵ بر اساس شبیه‌سازی‌های مقدماتی کالیبره گردیده‌اند تا توازن بهینه‌ای میان کاوش و استخراج برقرار شود. مشخصات تفصیلی فراپارامترها در جدول مربوطه خلاصه شده است.

۵-۴ روش‌های پایه و مقایسه

جهت ارزیابی مقایسه‌ای عملکرد رویکرد RS-DRL، این روش با مجموعه‌ای از روش‌های پایه و پیشرفته در سه دسته از اهداف انطباقی مورد مقایسه قرار گرفت:

- **مقاصد کمینه‌سازی:**[15] برای این منظور، مدل در برابر الگوریتم یادگیری پایه نظیر شبکه‌های کیو عمیق استاندارد ϵ-greedy DQN[16] [۱۵] و همچنین در برابر ترکیبات RS-DRL با راهبردهای بازپخش تجربه با نگاه به گذشته HER[17]، با عنوان RS-DRL-with-HER [۱۶]، و روش پاداش نرم‌تر Soft HER [۱۷] قرار گرفت.

- **مقاصد ترکیبی اهداف آستانه‌ای (TTS):**[18] برای ارزیابی کیفی، الگوریتم‌های شناخته‌شده‌ای همچون روش کاهش فضای وفقی DLASER+[19] [۱۸] و یک سیستم مرجع[20] که بر پایه جستجوی کامل و جامع تمامی‌حالت‌ها[21] استوار بود، مورد ارزیابی قرار گرفت.

- **مقاصد آستانه‌ای مطلق (TT):**[22] راهکار پیشنهادی در تقابل با مدل‌های یادگیری پیشرفته همچون روش ML4EAS[23] [۷، ۸]، نسخه اولیه DLASER[24] [۵۲]، روش بهبود یافته DLASER+ [۱۸] و روش مرجع سنجیده شد.

---

[13] Hyperparameters
[14] Grid Search
[15] Minimization Goals
[16] Deep Q-Network
[17] Hindsight Experience Replay
[18] Threshold-based Transition System
[19] Deep Learning for Adaptation Space Reduction (Extended)
[20] Reference Baseline
[21] Exhaustive Search
[22] Threshold Goal
[23] Machine Learning for Efficient Adaptation Space Reduction
[24] Deep Learning for Adaptation Space Reduction

انطباق روش‌های مبتنی بر HER: از آنجا که مدل‌های HER و Soft HER برای محیط‌های مبتنی بر هدف صریح[۲۵] طراحی شده‌اند، در حالی که اهداف کیفی در بستر DeltaIoT به صورت کمینه‌سازی پیوسته تعریف می‌شوند، این راهکارها با در نظر گرفتن آستانه‌های کیفیت خدمات (QoS)[۲۶] به عنوان اهداف جایگزین سازگار شده و فرآیند برچسب‌گذاری مجدد[۲۷] بر مبنای آن‌ها پیاده‌سازی گردید. این رویکرد امکان مقایسه تجربی منصفانه الگوریتم‌های مبتنی بر HER را فراهم می‌سازد.

۵-۵ معیارهای ارزیابی عملکرد یادگیری و کارایی سیستمی

معیارهای ارزیابی تجربی در این پژوهش بر دو محور بنیادین متمرکز هستند:

معیارهای عملکرد یادگیری عامل هوشمند:

۱. **عملکرد مجانبی:**[۲۸] میانگین ارزش پاداش در گام‌های پایانی یادگیری پس از همگرایی پایدار سیاست، که نمایانگر کیفیت نهایی سیاست آموخته‌شده است.

۲. **زمان تا آستانه:**[۲۹] تعداد گام‌های آموزشی مورد نیاز برای دستیابی پایدار به یک آستانه پاداش مشخص (آستانه ۰/۹ در این ارزیابی‌ها).

۳. **عملکرد کل:**[۳۰] شاخص تجمیعی مساحت ناحیه میان افق پاداش مجانبی و منحنی یادگیری واقعی[۳۱]:

$$TP = R_{\infty} \cdot T - \sum_{t=1}^{T} r_t \qquad (۱-۵)$$

مقادیر کوچک‌تر TP نشان‌دهنده همگرایی سریع‌تر با کمترین اتلاف پاداش در فاز آموزش هستند.

معیارهای عملکرد سیستم: کیفیت خدمات اجرایی سیستم در طول مأموریت بر پایه سه شاخص کمّی ارزیابی می‌شود:

- **تلفات بسته‌های ارسالی:**[۳۲] درصد پیغام‌هایی که با خطا مواجه شده و به مقصد نمی‌رسند.

[25] Goal-Conditioned
[26] Quality of Service
[27] Relabeling
[28] Asymptotic Performance
[29] Time to Threshold
[30] Total Performance
[۳۱] در این معیار، R_{∞} بیانگر سقف پاداش مجانبی سیاست بهینه در افق زمانی T است و تفاضل تجمعی $(R_{\infty} - r_t)$ مساحت اتلاف پاداش انباشته تا زمان همگرایی را اندازه‌گیری می‌کند.
[32] Packet Loss

- **تاخیر ارسال:**[۳۳] مدت زمان صرف‌شده برای انتقال پیام‌ها به گره مرکزی.
- **مصرف انرژی:**[۳۴] مصرف نهایی انرژی در گره‌های شبکه پس از اعمال تنظیمات وفقی.

۵-۶ ارزیابی تجربی چارچوب پایه‌ای RS-DRL در بستر DeltaIoT

در این بخش، نتایج تجربی حاصل از پیاده‌سازی چارچوب پایه‌ای RS-DRL بر روی بستر شبکه حسگر بی‌سیم DeltaIoT ارائه و تحلیل می‌گردد. تمرکز این بخش بر سنجش فرار از بهینه‌های محلی، پایداری سیاست در برابر نویز محیطی، و رفتار مقیاس‌پذیری الگوریتم پایه‌ای است.

۵-۶-۱ منحنی‌های یادگیری و رفتار همگرایی: خروج از بهینه‌های محلی (RQ1)

تحلیل مقایسه‌ای منحنی‌های یادگیری در بستر DeltaIoTv1 برتری قطعی چارچوب پیشنهادی را در نرخ همگرایی و کیفیت سیاست نهایی به اثبات می‌رساند. رویکرد RS-DRL موفق شده است به ارزش مجانبی ۰/۹۹۰۵ (با انحراف معیار ۰/۰۲۶۸) دست یافته و در مدت زمان ۲,۲۶۶ گام (با خطای استاندارد ۱۵۰ گام) به آستانه مطلوب همگرا شود؛ در حالی که الگوریتم پایه‌ای حریصانه ϵ-greedy DQN به حد مجانبی ۰/۴۵۵۹ محدود مانده و از دستیابی به آستانه هدف بازماند.

ریشه بنیادین این همگرایی پایدار در RS-DRL به سازوکار شکل‌دهی تصادفی پاداش بازمی‌گردد: تخصیص پاداش خوش‌بینانه با احتمال $\rho = ۰/۳۰$ به تجربیات ناموفق بافر بازپخش، گرادیان مسطح سیاست را در فضاهای پاداش تنک فعال نموده و با ایجاد انحراف کنترل‌شده، از توقف عامل در بهینه‌های محلی نامطلوب جلوگیری می‌نماید.

شکل ۵-۱ منحنی یادگیری الگوریتم‌ها را در فضای DeltaIoTv1 نشان می‌دهد و تفاوت همگرایی RS-DRL را در برابر روش‌های پایه به تصویر می‌کشد.

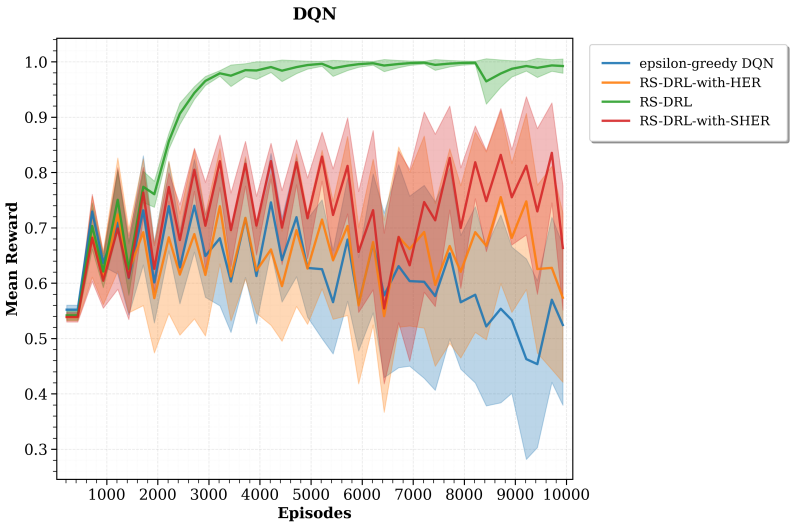
در فضای پیچیده‌تر با حضور ۱۲۹۶ گزینه تطبیق‌پذیر در نسخه DeltaIoTv1.1، راهکار پیشنهادی در ۱۹۲۹۶ گام به پاداش ۰/۸۹۸۳ (±۰/۰۹۳۲) همگرا شد، در حالی که مدل‌های رقیب همگرایی ضعیف‌تری را ثبت کرده و به خط آستانه نرسیدند (مطابق با شکل ۵-۲).

۵-۶-۲ مقایسه عملکرد به ازای هر هدف و تعمیم‌پذیری (RQ1 و RQ2)

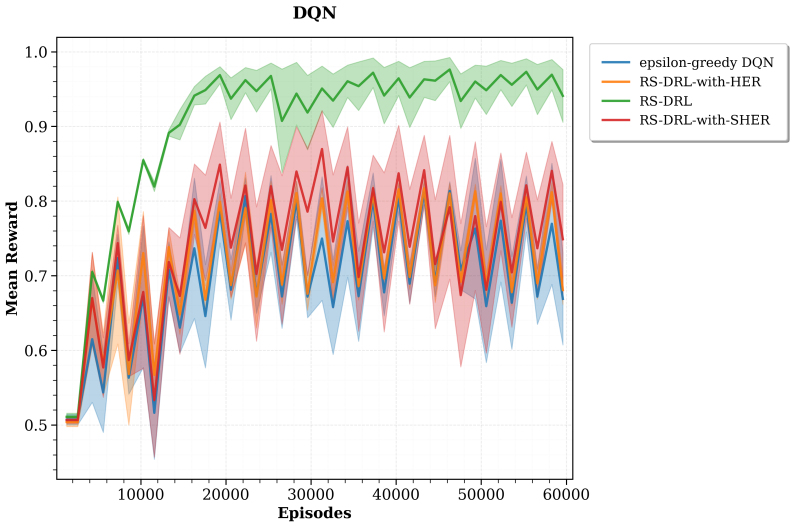
به منظور درک دقیق جزئیات کارکرد عوامل کنترلی روی تک‌تک متغیرهای سیستم، عملکرد رویکرد پیشنهادی در مقایسه با انواع HER ارزیابی شد. جداول ۵-۴ و ۵-۵ عملکرد مجانبی، زمان تا آستانه و عملکرد کل را برای اهداف مختلف نشان می‌دهند.

[33] Latency

[34] Energy Consumption



شکل ۵-۱: منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1 (پاداش در برابر گام‌ها)



شکل ۵-۲: منحنی‌های یادگیری الگوریتم‌ها در محیط DeltaIoTv1.1

جدول ۵-۴: نتایج اهداف کمینه‌سازی در DeltaIoTv1 (پاداش مجانبی / گام‌ها)

روش	چندهدفه			مصرف انرژی			تلفات بسته‌ها		
	مجانبی	زمان تا آستانه	عملکرد کل	مجانبی	زمان تا آستانه	عملکرد کل	مجانبی	زمان تا آستانه	عملکرد کل
RS-DRL	۰/۹۹	۲۲۶۶	—	۰/۹۷	—	—	۰/۹۸	—	—
RS-DRL-HER	۰/۶۱	عدم همگرایی	—	۰/۵۸	عدم همگرایی	—	—	—	—
RS-DRL-SoftHER	۰/۴۹	عدم همگرایی	—	۰/۳۹	عدم همگرایی	—	—	—	—
DQN	۰/۴۵	عدم همگرایی	—	—	عدم همگرایی	—	—	—	—

جدول ۵-۵: نتایج اهداف کمینه‌سازی در DeltaIoTv1.1

روش	چندهدفه			مصرف انرژی			تلفات بسته‌ها		
	مجانبی	زمان تا آستانه	عملکرد کل	مجانبی	زمان تا آستانه	عملکرد کل	مجانبی	زمان تا آستانه	عملکرد کل
RS-DRL	۰/۸۹	۱۹۲۹۶	—	۰/۹۳	—	—	۰/۹۱	—	—
RS-DRL-HER	—	عدم همگرایی	—	—	عدم همگرایی	—	—	—	—
RS-DRL-SoftHER	—	عدم همگرایی	—	—	عدم همگرایی	—	—	—	—
DQN	—	عدم همگرایی	—	—	عدم همگرایی	—	—	—	—

تحلیل این اهداف نشان می‌دهد:

- **بهینه‌سازی چندهدفه:**[۳۵] رویکرد پیشنهادی به پاداش میانگین ۰/۹۹۰۵ (در نسخه اول) و ۰/۸۹۸۳ (در نسخه دوم) دست یافت، در حالی که روش‌های مبتنی بر HER به دلیل ماهیت وابسته به اهداف صریح، در بازه ۰/۴۹ تا ۰/۶۱ متوقف شدند.
- **مصرف انرژی:** شاخص‌های ارزیابی، پاداش مصرف انرژی RS-DRL را با ثبت میانگین ۰/۹۷۵۶ (در v1) و ۰/۹۳۰۱ (در v1.1) بسیار مطلوب‌تر از مدل‌های پایه (بازه ۰/۳۹ تا ۰/۵۸) نشان داد.
- **تلفات بسته‌ها:** پاداش متناظر با نرخ اتلاف بسته‌ها برای روش پیشنهادی برابر با ۰/۹۸۵۰ در شبکه اول و ۰/۹۱۲۹ در شبکه دوم حاصل گردید که بیانگر پایداری کیفیت خدمات شبکه در شرایط نویزی است.
- **تأخیر ارسال:** روش پیشنهادی RS-DRL با میانگین پاداش ۰/۹۹۶۴ در نسخه اول و ۰/۹۰۲۱ در نسخه دوم، کمترین تأخیر انتقال پیام را در مقایسه با رقبا ثبت نمود.

۵-۶-۳ ارزیابی مقایسه‌ای در برابر تمام روش‌های پایه (RQ4)

ارزیابی شبکه در تقابل با دیگر رقبا نظیر روش‌های جستجوگر، اهمیت ویژه‌ای دارد. در جداول ۵-۶ و ۵-۷ نتایج مربوط به اهداف آستانه‌ای خلاصه شده است.

جدول ۵-۶: عملکرد سیستم برای اهداف آستانه‌ای ترکیبی TTS

روش (شبکه v1)	اتلاف بسته‌ها (%)	تاخیر (s)	مصرف انرژی (C)
RS-DRL	**۱۰/۵۷۸**	**۰/۰۹۷**	۱۲/۸۸۲
DLASER+	۱۲/۸۹۰	۰/۸۴۰	۱۳/۰۲۰
Reference	۱۴/۲۳۰	۰/۱۰۰	۱۳/۱۰۰

جدول ۵-۷: عملکرد سیستم برای اهداف آستانه‌ای مطلق TT

روش	DeltaIoTv1		DeltaIoTv2	
	اتلاف بسته‌ها (%)	تاخیر (s)	اتلاف بسته‌ها (%)	تاخیر (s)
RS-DRL	**۷/۱۵۳**	—	**۹/۳۳۰**	۰/۲۵۱
DLASER+	۷/۹۸۰	—	—	—
ML4EAS	—	—	۱۰/۵۶۰	—
Reference	—	—	—	۰/۱۰۰

در خصوص **هدف ترکیبی TTS** در نسخه اول شبکه، روش RS-DRL نرخ اتلاف بسته را به ٪۱۰/۵۷۸ محدود ساخت؛ در حالی که روش جستجوی مرجع دارای اتلاف ٪۱۴/۲۳۰ و روش +DLASER دارای

[35] Multi-objective

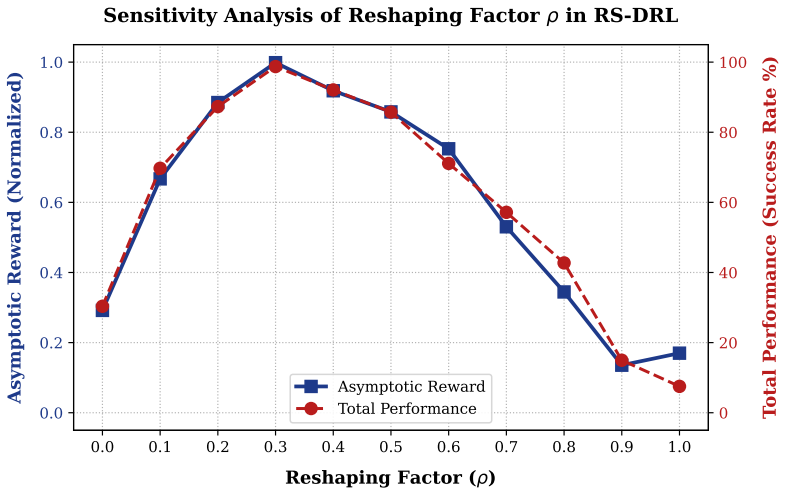
اتلاف ٪۱۲/۸۹۰ بوده‌اند. تأخیر ارسال نیز با ثبت مقدار s ۰/۰۹۷ به طور قابل‌ملاحظه‌ای کمتر از DLASER+ (s ۰/۸۴۰) بوده و با روش مرجع (s ۰/۱۰۰) برابری می‌کند. همچنین مصرف انرژی (C ۱۲/۸۸۲) در سطحی کاملاً رقابتی و مشابه روش‌های مرجع (C ۱۳/۱۰۰) و DLASER+ (C ۱۳/۰۲۰) حفظ گردید.

در مقابل، در **هدف آستانه‌ای مطلق TT**، سیاست پیشنهادی در بستر DeltaIoTv1 به نرخ اتلاف ٪۷/۱۵۳ (در برابر ٪۷/۹۸۰ در DLASER+) دست یافت. علاوه بر این، در نسخه مقیاس‌بزرگ DeltaIoTv2، مقدار اتلاف بسته به ٪۹/۳۳۰ مقید گردید که در مقایسه با روش ML4EAS (٪۱۰/۵۶۰) بهبود محسوسی را نشان می‌دهد.

در شاخص تأخیر نسخه دوم، روش RS-DRL مقدار s ۰/۲۵۱ را در برابر s ۰/۱۰۰ روش مرجع ثبت نمود؛ این رفتار ناشی از مصالحه چندهدفه و اولویت‌بخشی سیاست یادگیری به کاهش اتلاف بسته در شرایط بار ترافیکی شدید شبکه است.

۵-۶-۴ مطالعه تفکیک اثر و ابلیشن: حساسیت به ضریب شکل‌دهی ρ (RQ2)

پارامتر ρ (ضریب شکل‌دهی) شدت خوش‌بینی عامل را در بازطراحی تجربیات ناموفق کنترل می‌کند. این پارامتر مشخص می‌سازد که چه نسبتی از تجربیات با پاداش صفر در هر دسته نمونه‌برداری‌شده از بافر بازپخش، با پاداش مثبت خوش‌بینانه ($\tilde{r} = 1$) جایگزین شوند. جهت تحلیل تجربی، اثر مقادیر مختلف ρ در قالب شکل ۵-۳ ارزیابی شده است.



شکل ۵-۳: تاثیر مقادیر مختلف ضریب شکل‌دهی ρ بر پاداش مجانبی و عملکرد کل

نکات تحلیلی پیرامون ضریب شکل‌دهی ρ: ایجاد توازن دقیق در انتخاب مقدار ضریب ρ ضروری است: مقادیر بیش از حد بزرگ ($\rho > ۰/۶$)، منجر به تزریق مفرط پاداش‌های مثبت تصنعی و نوسان شدید در برآورد گرادیان شده و همگرایی را ناپایدار می‌سازد. در مقابل، مقادیر بسیار کوچک ($\rho < ۰/۲$) انگیزه کافی برای کاوش حالت‌های ناشناخته ایجاد نکرده و عامل مشابه روش‌های یادگیری بدون هدایت در اولین بهینه محلی

متوقف می‌شود. مقدار بهینه $\rho = ۰/۳$ علاوه بر تسریع همگرایی، از بیش‌برازش[۳۶] بر روی تجربیات پیشین بافر بازپخش جلوگیری می‌کند.

۵-۶-۵ تحلیل مقیاس‌پذیری در فضاهای وفقی بزرگ تا ۴۰۹۶ گزینه (RQ3)

تحلیل رفتار یادگیری با گسترش ابعاد فضای وفقی از ۲۱۶ گزینه به ۴۰۹۶ گزینه، حاکی از استواری و مقیاس‌پذیری الگوریتم پیشنهادی است. جدول ۵-۸ این روند مقیاس‌پذیری را نشان می‌دهد.

جدول ۵-۸: تحلیل مقیاس‌پذیری الگوریتم با بزرگ شدن فضای تطابق

نسخه DeltaIoT	سنسورها	گزینه‌های تطابق	گام‌های آموزش موردنیاز	پاداش مجانبی
v1	۱۵	۲۱۶	۲۲۶۶	۰/۹۹۰۵
v1.1	۱۶	۱۲۹۶	۱۹۲۹۶	۰/۸۹۸۳
v2	۳۷	۴۰۹۶	—	—

تنها زمان همگراییِ یادگیری (جهش از ۲۲۶۶ به ۱۹۲۹۶ گام در نسخه v1.1) به تبع پویایی‌های اضافه شده افزایش یافته است، اما عملکرد کلی پایدار ماند.

۵-۶-۶ جمع‌بندی دستاوردهای چارچوب پایه‌ای و ضرورت گذار به معماری RS-DRL$^+$

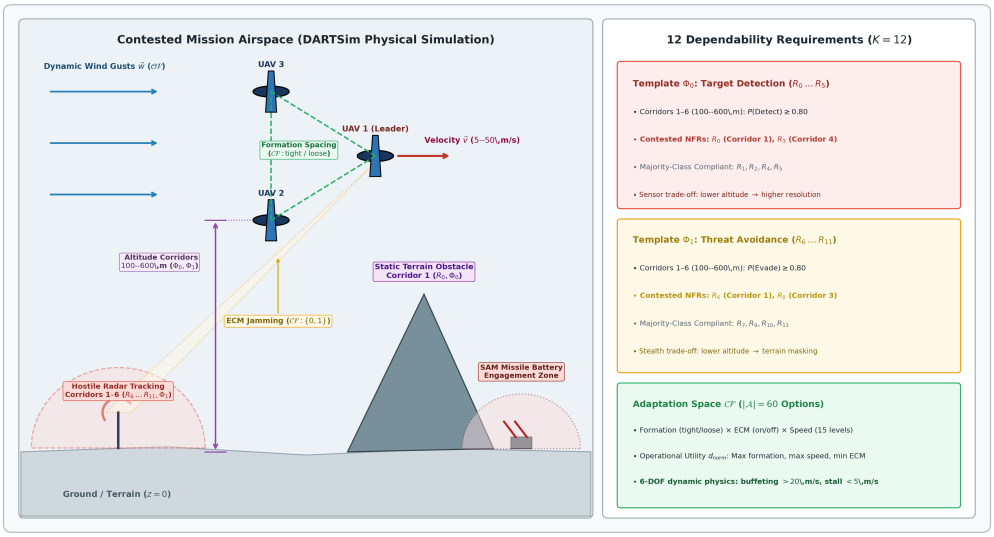
نتایج حاصل از ارزیابی چارچوب پایه‌ای RS-DRL در بستر شبکه حسگر DeltaIoT مؤید آن است که سازوکار شکل‌دهی تصادفی با ضریب ثابت $\rho = ۰/۳۰$، چالش تنکی پاداش[۳۷] و توقف در بهینه‌های محلی را در سیستم‌های با کیفیت خدمات نرم و فضاهای پیکربندی متوسط (تا ۱۲۹۶ گزینه) به طور کامل مرتفع می‌سازد. با این حال، همان‌گونه که علامت «—» در جدول ۵-۸ برای نسخه مقیاس‌وسیع DeltaIoTv2 (با ۴۰۹۶ گزینه وفقی) نشان می‌دهد، افزایش نمایی ابعاد فضای عمل و پیچیدگی قیدها، یادگیری بدون هدایت مشخصه را با چالش‌های واگرایی گرادیان و افزایش شدید واریانس مواجه می‌سازد.

علاوه بر این، در سیستم‌های فیزیکی‌ـ‌سایبری بلادرنگ نظیر ناوگان پهپادی، عواملی چون مهلت‌های زمانی سخت کنترلی (۲۰ تا ۵۰ میلی‌ثانیه)، غلبه شدید داده‌های شکست در لاگ‌ها (بیش از ۹۰٪)، و مهم‌تر از همه، پدیده شکاف واقعیت مدل‌های جانشین (همان‌طور که در سه‌گانه بخش ۴-۸ فصل ۴ تبیین گردید)، به کارگیری مستقیم چارچوب پایه‌ای را ناممکن می‌سازد. این محدودیت‌ها انگیزه اصلی توسعه معماری دوسطحی RS-DRL$^+$ (شامل سنتز آفلاین هدایت‌شده با حاشیه MU-RS-DRL و پالایش آنلاین در هر زمان PG-ALR) بوده‌اند.

در بخش بعدی، کارآمدی معماری ارتقایافته RS-DRL$^+$ در مواجهه با چالش‌های پیچیده فیزیکی‌ـ‌سایبری شبیه‌ساز DARTSim مورد سنجش قرار می‌گیرد؛ سپس در بخش ۵-۸، نشان خواهیم داد که چگونه انتقال

[36] Overfitting

[37] Reward Sparsity



شکل ۵-۴: سناریوی مأموریت شناسایی ناوگان پهپادی DARTSim در محیط پرخطر: (چپ) فضای پروازی همراه با رادارهای متخاصم، سیستم‌های موشکی، موانع فیزیکی و تلاطم شدید باد؛ (راست) نگاشت معنایی میان متغیرهای قابل‌کنترل ($\mathcal{CF}$)، عوامل محیطی ($\mathcal{OF}$) و ۱۲ الزام قابلیت اعتماد مأموریت (R_0 تا R_{11}).

الگوهای همین معماری پیشرفته به بستر شبکه حسگر، چالش‌های مقیاس‌پذیری در فضای ۴۰۹۶ گزینه‌ای نسخه DeltaIoTv2 را نیز با موفقیت حل می‌نماید.

۵-۷ ارزیابی ناوگان پهپادی در محیط فیزیکی‌ـسایبری DARTSim

به منظور ارزیابی استقلال از دامنه و سنجش کارایی روش پیشنهادی در شرایط سخت بلادرنگ، معماری RS-DRL$^+$ بر روی شبیه‌ساز مأموریت ناوگان پهپادی DARTSim [۲۹] مورد سنجش قرار گرفت. این سیستم برخلاف شبکه‌های حسگر بی‌سیم، یک سیستم فیزیکی‌ـسایبری بلادرنگ با مهلت زمانی کنترل پرواز بین ۲۰ تا ۵۰ میلی‌ثانیه، ۱۲ الزام قابلیت اعتماد[۳۸] متضاد، و عدم توازن شدید داده‌های شکست در لاگ‌های بازپخش (بیش از ۹۰٪) است.

۵-۷-۱ تنظیمات ارزیابی پروازی حلقه‌ـبسته: ۲٫۰۰۰ پرواز در ۲۰۰ سناریو

ارزیابی تجربی بر پایه ۲٫۰۰۰ پرواز حلقه‌ـبسته فیزیکی مستقل انجام پذیرفت. این ارزیابی شامل ۱۲ روش و الگوریتم برنامه‌ریز متمایز (۱۰ رویکرد انطباق هوشمند و بهینه‌سازی به همراه ۲ خط پایه کنترلی) بود که هر یک در ۲۰۰ سناریوی عملیاتی مستقل پروازی تحت شبیه‌سازی ۶ درجه آزادی فیزیکی (6-DOF C++) در سه سطح رواداری سخت‌گیرانه v_1، v_2 و v_3 ارزیابی شدند. این روش‌ها در چهار دسته معماری زیر سازماندهی شده‌اند:

[38] Dependability

۱. **دسته اول: معماری پیشنهادی و روش‌های تقلیلی رساله:**

- **معماری کامل پیشنهادی RS-DRL^{+}:**[۳۹] ترکیب آموزش آفلاین هدایت‌شده با حاشیه و مطلوبیت (MU-RS-DRL) و ماژول آنلاین سه‌مرحله‌ای PG-ALR مبتنی بر تصویرسازی حساسیت شاپلی ۱ــ گام و تصحیح دفاعی در هر زمان.
- **روش تقلیلی MU-RS-DRL:**[۴۰] الگوی سنتز آفلاین هدایت‌شده با حاشیه بازیابی شکست $\mathcal{M}(s,a)$ و مشوق مطلوبیت $\mathcal{U}_{\text{inc}}$ بدون پالایش آنلاین زمان اجرا (استنتاج $\mathcal{O}(1)$ با میانگین تأخیر ۰/۴۸ ms).
- **روش تقلیلی CM-RS-DRL:**[۴۱] الگوی سنتز آفلاین با بافر حاشیه اطمینان در ارضای نیازمندی‌ها برای افزایش پایداری تصمیم در نزدیکی مرزهای بحرانی.

۲. **دسته دوم: روش‌های مبتنی بر وارسی صوری و یادگیری تقویتی:**

- **سپر ایمنی زمان اجرا (Shielded RS-DRL):** محافظت صوری پیرامونی سیاست با وارسی جامع تمامی ۶۰ پیکربندی کاندیدا توسط مدل‌های جانشین آماری [۵۳] با تأخیر ۱۲۹/۹۵ ms.
- **چارچوب پایه‌ای رساله (Foundational RS-DRL [۱۹]):** شکل‌دهی پاداش تصادفی با نرخ جایگزینی ثابت $\rho = ۰/۳۰$ و پاداش بهینه ایستا $r_{\text{opt}} = ۱/۰$ (معرفی‌شده در بخش‌های ۴-۲-۲ تا ۴-۵ فصل ۴).
- **روش پایه Baseline DQN [۱۵]:** یادگیری تقویتی استاندارد تفاضل زمانی بدون شکل‌دهی پاداش ($\rho = ۰/۰$) بر روی لاگ‌های بازپخش با عدم توازن شکست شدید ۹۰/۹۸٪.

۳. **دسته سوم: روش‌های مبتنی بر هوش مصنوعی توضیح‌پذیر و بهینه‌سازی نرم‌افزاری (SBSE):**[۴۲]

- **روش جستجوی حساسیت XDA-II (SHAP / PFI) [۴۸]:**[۴۳] بهینه‌سازی آنلاین مبتنی بر صعود تپه روی ابعاد پراهمیت شاپلی و اهمیت جایگشت ویژگی‌ها (۶۲/۶۱ ms).
- **روش جستجوی وابستگی جزئی XDA (PDP):** هدایت صعود تپه محلی با نمودارهای روند غیرخطی وابستگی جزئی[۴۴] (۲۰۵/۴۰ ms).
- **الگوریتم تکاملی چندهدفه NSGA-III [۵۴]:**[۴۵] بهینه‌سازی تکاملی نامغلوب با نقاط مرجع بر روی ۱۲ الزام متضاد مأموریت پروازی (۱۰۰ s >).

[39] Two-Tier Contract-Anytime
[40] Margin-Utility SG-OS
[41] Confidence-Margin SG-OS
[42] Search-Based Software Engineering
[43] eXplanation-Driven Self-Adaptation II (SHAP / Permutation Feature Importance)
[44] Partial Dependence Plots
[45] Non-dominated Sorting Genetic Algorithm III

جدول ۵-۹: مقایسه عملکرد جامع ۱۲ روش برنامه‌ریز (۱۰ الگوریتم انطباقی و ۲ خط پایه) در پروازهای حلقه‌ـ بسته DARTSim: انطباق مدل جانشین، موفقیت پرواز فیزیکی در دو سطح رواداری سخت‌گیرانه ($v_۳$، $N = ۲۰۰$) و ملایم ($v_۱$، $N = ۲۰$)، کیفیت عملیاتی (d_{norm})، تأخیر آنلاین و مصالحه حاکم بر روش.

الگوریتم برنامه‌ریز	انطباق جانشین (%)	موفقیت پرواز فیزیکی (M_{sim} %) سخت ($v_۳$)	ملایم ($v_۱$)	کیفیت عملیاتی (d_{norm}) میانگین	میانه	انحراف معیار	تأخیر آنلاین	مصالحه حاکم بر روش
معماری پیشنهادی و روش‌های سنتز آفلاین هدایت‌شده (Ours)								
RS-DRL^{+} (معماری کامل)	۷۴٫۰ ± ۰٫۵	۷۰٫۵ ± ۰٫۶	۸۵٫۰	۰٫۶۰۷۵	۰٫۶۶۶۹	۰٫۱۳۲۴	۰٫۴۸/۲٫۴۵ ms	بالاترین بقای پرواز فیزیکی؛ پالایش ۱ـ گام در هر زمان
MU-RS-DRL (سنتز آفلاین)	۷۰٫۰ ± ۰٫۵	۷۰٫۰ ± ۰٫۶	**۹۰٫۰**	۰٫۶۴۰۷	۰٫۶۶۶۷	۰٫۰۹۰۵	۰٫۴۸ ms	بالاترین ایمنی فیزیکی بدون سپر؛ کمترین نوسان واریانس
CM-RS-DRL (رویکرد بافر)	۷۱٫۵ ± ۰٫۶	۶۸٫۵ ± ۰٫۷	۸۵٫۰	۰٫۶۴۲۲	۰٫۶۶۶۷	۰٫۰۸۷۰	۰٫۴۸ ms	بافر حاشیه اطمینان پایدار در مرزهای بحرانی
سپر ایمنی زمان اجرا (Runtime Verification Shield)								
Shielded RS-DRL	۷۶٫۰	۶۵٫۰	۸۰٫۰	۰٫۵۷۹۱	۰٫۶۶۶۷	۰٫۱۵۳۲	۱۲۹٫۹۵ ms	بیشترین نمره جانشین؛ افت ۱۱ درصدی بر اثر شکاف واقعیت
روش‌های پایه یادگیری تقویتی (Reinforcement Learning Baselines)								
Foundational RS-DRL (پایه‌ای رساله)	۶۸٫۵ ± ۰٫۶	۶۷٫۵ ± ۰٫۷	۸۰٫۰	۰٫۶۰۲۲	۰٫۶۶۶۷	۰٫۱۳۱۱	۰٫۴۷ ms	سرعت پروازی بالا؛ نوسان متوسط در نزدیکی مرز واماندگی (Stall)
Baseline DQN	۷۱٫۰ ± ۰٫۸	۶۶٫۰ ± ۰٫۸	۷۵٫۰	۰٫۵۱۶۰	۰٫۶۶۶۷	۰٫۱۶۵۳	۰٫۵۰ ms	تمایل به آرایش گسسته در ۴۴٪ موارد؛ مطلوبیت پایین‌تر
روش‌های بهینه‌سازی مبتنی بر جستجو (SBSE Baselines)								
XDA-II (SHAP / PFI)	۷۰٫۰	۵۰٫۰	۸۵٫۵*	۰٫۵۸۱۲	۰٫۶۶۶۹	۰٫۱۷۷۰	۶۲٫۶۱ ms	گزینه‌های همسایگی یکسان؛ افت شدید به ۵۰٪ در سطح سخت $v_۳$
XDA (PDP)	۷۰٫۰	۶۰٫۰	۸۷٫۰*	۰٫۶۱۲۹	۰٫۶۶۶۹	۰٫۱۵۱۴	۲۰۵٫۴۰ ms	تأخیر ۴۳۰ برابری؛ افت ۲۷ درصدی در دینامیک فیزیکی
NSGA-III	۷۰٫۰	۵۵٫۰	۸۵٫۰*	۰٫۶۱۲۹	۰٫۶۶۶۹	۰٫۱۵۱۴	> ۱۰۰ s	تأخیر بالای ۱۰۰ ثانیه؛ نقض قطعی مهلت کنترل پرواز
FITEST	۱٫۵	۵۰٫۰	۸۲٫۵*	۰٫۳۵۴۶	۰٫۳۴۱۸	۰٫۰۷۰۷	۱۳۳,۹۵۰ ms	تأخیر بسیار فاحش (بیش از ۲ دقیقه)؛ نقض قطعی مهلت پرواز
Random Search	۱٫۰	۲۵٫۰	۴۵٫۵*	۰٫۴۷۳۸	۰٫۴۷۷۹	۰٫۲۵۴۵	۱۹٫۴۹ ms	خط پایه غیرقابل اتکا (۱٪ انطباق با مدل‌های جانشین)
Unadapted	۹٫۰	۹٫۰	۱۰٫۰	۰٫۲۱۱۰	۰٫۲۰۵۰	۰٫۱۱۲۰	۰٫۰۰ ms	اجرای پیکربندی ثابت؛ شکست در ۹۱٪ پروازها

توضیح: نتایج در سطح $v_۳$ حاصل ارزیابی ۲,۰۰۰ پرواز مستقل حلقه‌ـ بسته فیزیکی تحت شبیه‌ساز ۶ درجه آزادی DARTSim با الگوهای تلاطم باد و توزیع رادارهای متخاصم یکسان است. مقادیر روش‌های DRL بر اساس میانگین ± انحراف معیار روی ۳ بذر تصادفی (۴۲، ۴۳ و ۴۴) گزارش شده‌اند. علامت * نشان‌دهنده مقادیر چاپ‌شده بنچمارک SEAMS در محیط ایستای آفلاین است؛ در حالی که اجرای پویای حلقه‌ـ بسته XDA-II در سطح $v_۱$ به ۷۰/۰٪ می‌رسد (شکل ۵-۷). تأخیر آنلاین روش کامل RS-DRL^{+} در مسیر سریع نامی برابر با ۰٫۴۸ ms و در صورت فعال‌سازی پالایش مرحله ۳ به طور مشروط به ۲٫۴۵ ms می‌رسد.

- **الگوریتم جستجوی ژنتیک هدایت‌شده FITEST [۵۵]:** الگوریتم ژنتیک مبتنی بر تابع برازش برای بیشینه‌سازی احتمال ارضای اهداف مأموریت (۱۳۳/۹۵ s).

۴. **دسته چهارم: خطوط پایه کنترلی:**

- **جستجوی تصادفی:**[۴۶] نمونه‌برداری یکنواخت در فضای گزینه‌های مجاز به عنوان خط پایه انطباق (۱۹/۴۹ ms).
- **عدم انطباق:**[۴۷] اجرای مأموریت با پیکربندی پیش‌فرض اولیه بدون هیچ واکنش وفقی (۰٫۰۰ ms).

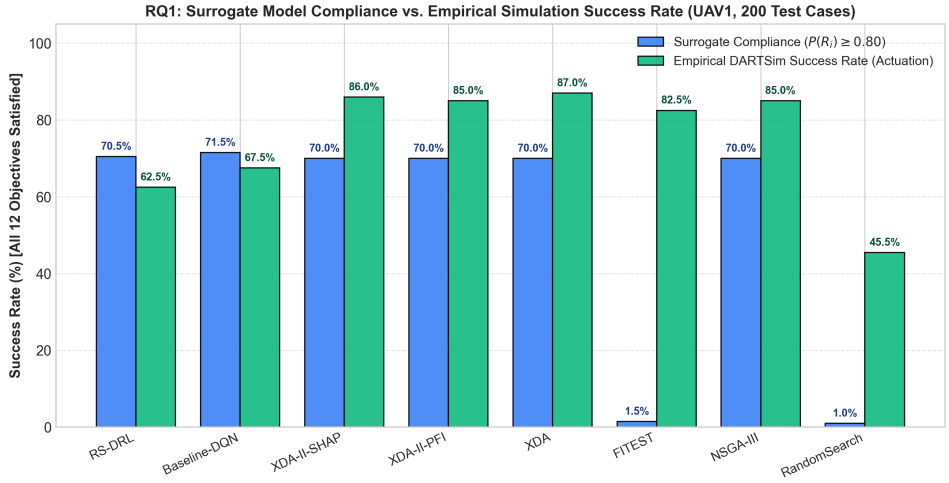
۵-۷-۲ ایمنی اجرای فیزیکی در برابر انطباق جانشین: مهار شکاف واقعیت (RQ6)

یکی از مهم‌ترین یافته‌های تجربی این رساله، آشکارسازی و بررسی پدیده «**شکاف واقعیت میان مدل‌های جانشین آماری و فیزیک اجرای پرواز**»[۴۸] است. در جدول ۵-۹، عملکرد جامع الگوریتم‌های برنامه‌ریز در ۲۰۰ سناریوی عملیاتی مستقل پروازی تحت شبیه‌سازی فیزیکی ۶ درجه آزادی خلاصه شده است.

[46] Random Search

[47] Unadapted

[48] Surrogate-to-Physics Reality Gap



شکل ۵-۵: مقایسه نرخ موفقیت پرواز فیزیکی و انطباق با مدل‌های جانشین در سطح رواداری سخت‌گیرانه v_3 میان الگوریتم‌های مورد بررسی، نشان‌دهنده نحوه مهار شکاف واقعیت در معماری RS-DRL$^+$.

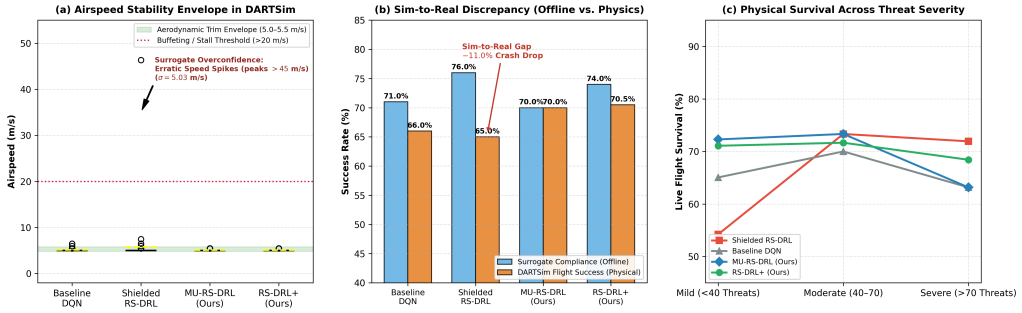
همان‌گونه که در جدول ۵-۹ و نمودار شکل ۵-۵ مشهود است، رفتار تجربی روش‌ها و پدیده شکاف واقعیت ابعاد ساختاری تازه‌ای را آشکار می‌سازد:

نخست، افت عملکرد شدید سپر ایمنی زمان اجرا[49] در گذر از مدل‌های جانشین به پرواز واقعی قابل توجه است. این روش در فضای ارزیابی مدل‌های جانشین آماری به بالاترین نرخ انطباق (٪۷۶/۰) دست می‌یابد، زیرا تمامی ۶۰ پیکربندی را صرفاً بر مبنای توابع جانشین غربال می‌نماید. با این حال، در زمان پرواز واقعی در شبیه‌ساز ۶ درجه آزادی، نرخ موفقیت فیزیکی آن با یک **افت ۱۱ درصدی** به ٪۶۵/۰ تنزل می‌یابد. ریشه این پدیده آن است که مدل‌های جانشین آماری، پدیده‌های پیچیده دینامیکی نظیر تلاطم بادهای ناگهانی، تأخیر مکانیکی عملگرهای سروو[50] و جفت‌شدگی آیرودینامیکی غیرخطی را در نظر نمی‌گیرند؛ در نتیجه، سپر صوری گزینه‌هایی با سرعت‌های هوایی ناامن را تصویب می‌کند که منجر به ورود پهپاد به ناحیه واماندگی[51] و برخورد به موانع می‌گردند. آزمون مقایسه‌ای مک‌نمار روی جفت پروازهای متناظر[52] مؤید آن است که در $b = ۴۹$ سناریو، روش پیشنهادی RS-DRL$^+$ با موفقیت پرواز را تکمیل کرده در حالی که سپر ایمنی سنتی دچار سانحه و سقوط شده است؛ و در $c = ۳۸$ سناریو عکس این وضعیت رخ داده است (آزمون مک‌نمار $p = ۰/۲۸۴$ و آزمون دقیق فیشر $p = ۰/۲۸۵$ با نسبت شانس $\text{OR} = ۱/۲۹$).

داده‌های تله‌متری ثبت‌شده در شکل ۵-۶ چرایی این پدیده را به روشنی اثبات می‌سازند: تحت سپر ایمنی، به دلیل گزینش مکرر مدهای تهاجمی، انحراف معیار سرعت هوایی به میزان **۲۶ برابر** افزایش یافته و به $\sigma = ۵/۰۳\ \text{m/s}$ رسیده است (با جهش‌های سرعت ناگهانی تا ۴۶/۳۶ m/s). در مقابل، روش پیشنهادی RS-DRL$^+$ و روش MU-RS-DRL نوسان سرعت هوایی را در محدوده پایدار $\sigma = ۰/۱۹\ \text{m/s}$ در پنجره

[49] Runtime Shielding
[50] Servos
[51] Stall
[52] Discordant Pairs

آیرودینامیکی بهینه (۵٫۰ تا ۵٫۵ m/s) مقید نگه داشته‌اند. در نتیجه، روش آفلاین MU-RS-DRL با سرکوب پاداش برای سناریوهای با نقض چندگانه، به نرخ موفقیت پرواز ٪۷۰٫۰ و شکاف واقعیت صفر دست می‌یابد؛ و معماری کامل RS-DRL^{+} با پالایش موضعی در هر زمان بر پایه قاعده انتخاب محافظت‌شده (معادله ۴-۲۳ و گزاره ۴-۱۱-۲ در فصل ۴)، انطباق جانشین را به ٪۷۴٫۰ و بقای فیزیکی پرواز را به ٪۷۰٫۵ می‌رساند، به گونه‌ای که ایمنی بالاتری نسبت به سپر کامل با تأخیری صدها برابر کمتر فراهم می‌سازد.



شکل ۵-۶: ردپای تله‌متری واقعی پرواز فیزیکی در برابر پیش‌بینی مدل‌های جانشین در حضور باد ناگهانی: (الف) توزیع سرعت هوایی و ناپایداری آیرودینامیکی شدید تحت سپر سنتی، (ب) سقوط ۱۱ درصدی سپر در گذر از جانشین به پرواز واقعی، و (ج) پایداری نرخ موفقیت روش پیشنهادی تحت چگالی‌های فزاینده رادارهای متخاصم.

۵-۷-۳ تحلیل چندسطحی رواداری دالان پروازی: مقایسه سطوح v_1، v_2 و v_3 (RQ1 و RQ6)

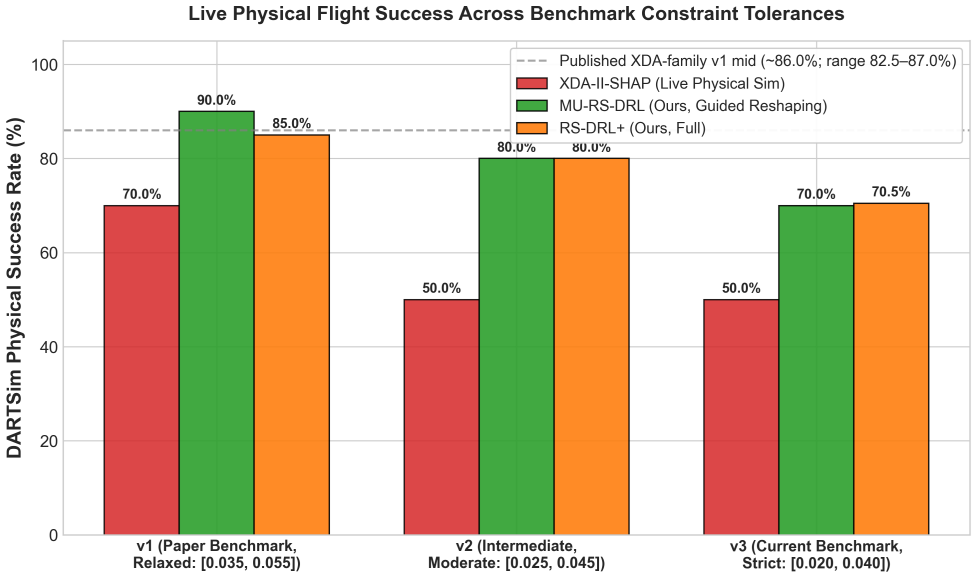
برای بررسی استواری روش‌ها در شرایط محدودیت‌های دالان پروازی، آزمایش‌ها در سه رژیم رواداری با کران‌های مانور متفاوت ارزیابی شدند (Δ کسر مجاز انحراف ارتفاعی $\Delta h \cdot \pm\Delta$ است):

۱. **رژیم رواداری ملایم** (v_1 **با** $\Delta \in [۰٫۰۳۵, ۰٫۰۵۵]$): رواداری پیش‌فرض بنچمارک منتشرشده SEAMS [۲۹، ۴۸] بر روی ۲۰ سناریوی منتشرشده استاندارد در شرایط تلاطم ملایم.

۲. **رژیم رواداری متوسط** (v_2 **با** $\Delta \in [۰٫۰۲۵, ۰٫۰۴۵]$): مرزهای دالان محدودتر که مانورهای جانبی ناگهانی را محدود می‌سازد، بر روی همان ۲۰ سناریو.

۳. **رژیم رواداری سخت‌گیرانه** (v_3 **با** $\Delta \in [۰٫۰۲۰, ۰٫۰۴۰]$): دالان‌های پروازی با رواداری محدود بر روی تمامی ۲۰۰ سناریوی عملیاتی شامل تهدیدات متراکم راداری ($\geq$ ۴۰)، نزدیکی رادار ($\leq$ ۵,۰۰۰ m) و تلاطم شدید باد ($\geq$ ۳).

بررسی نمودار شکل ۵-۷ حاکی از تغییرات رفتاری عمیق الگوریتم‌ها با تنگ‌تر شدن مرزهای مانور است: در رژیم رواداری ملایم (v_1)، روش MU-RS-DRL با موفقیت ٪۹۰٫۰ (۱۸ از ۲۰) و RS-DRL^{+} با ٪۸۵٫۰



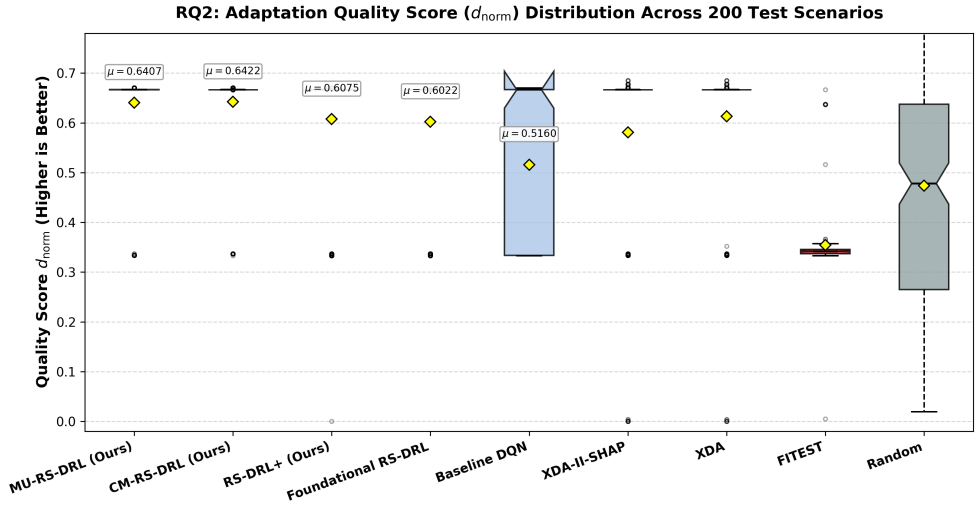
شکل ۵-۷: مقایسه نرخ بقای پرواز فیزیکی حلقه‌ـ بسته ناوگان پهپادی DARTSim در سه رژیم رواداری دالان پروازی ملایم (v_1)، متوسط (v_2) و سخت‌گیرانه (v_3): پایداری روش‌های مبتنی بر RS-DRL$^+$ در برابر افت شدید عملکرد الگوریتم‌های جستجوی کلاسیک در شرایط تلاطم شدید.

(۱۷ از ۲۰) برتری قاطعی بر روش جستجوی شاپلی XDA-II در پرواز پویا (٪۷۰/۰) نشان می‌دهند و اهداف آفلاین ایستا را در کسری از میلی‌ثانیه برآورده می‌سازند. با تشدید محدودیت‌ها در سطح متوسط (v_2)، هر دو روش پیشنهادی پایداری خود را در سطح ٪۸۰/۰ (۱۶ از ۲۰) حفظ می‌نمایند، در حالی که نرخ موفقیت روش XDA-II به ٪۵۰/۰ (۱۰ از ۲۰) سقوط می‌کند. در نهایت، در سخت‌ترین رژیم رواداری (v_3) با ۲۰۰ سناریو و چگالی بالای پدافند)، در حالی که روش‌های جستجوی سنتی نظیر XDA-II، NSGA-III و FITEST به نرخ‌های پایین ٪۵۰/۰ تا ٪۵۵/۰ تنزل می‌یابند، معماری پیشنهادی RS-DRL$^+$ با نرخ بقای ٪۷۰/۵ و MU-RS-DRL با ٪۷۰/۰ برتری قطعی و پایداری آماری خود را در تلاطم‌های شدید جوی تثبیت می‌کنند.

۵-۷-۴ مطلوبیت عملیاتی و کاهش نوسانات تصمیم‌گیری مأموریت تحت لاگ‌های شکست (RQ6 و تعمیم‌پذیری RQ2)

در مأموریت‌های شناسایی و رزمی، اتخاذ تصمیمات با مطلوبیت عملیاتی بالا (نزدیک شدن به هدف ضمن حفظ بقا) همراه با ثبات سیاست، الزامی بنیادین به شمار می‌رود. این آزمایش هم‌زمان پاسخ‌گوی بعد مطلوبیت و پایداری در برابر لاگ‌های با عدم توازن بیش از ٪۹۰ شکست (RQ6) و ارتقای تعمیم‌پذیری به تلاطم‌های شدید جوی نادیده (RQ2) است. شکل ۵-۸ توزیع مطلوبیت مأموریت (d_{norm}) را در بین الگوریتم‌های مختلف نشان می‌دهد.

تحلیل آماری توزیع مطلوبیت مأموریت نشان‌دهنده برتری ساختاری روش‌های مبتنی بر حاشیه بازیابی است: روش MU-RS-DRL به میانگین مطلوبیت ۰/۶۴۰۷ و روش CM-RS-DRL به ۰/۶۴۲۲ دست یافتند



شکل ۵-۸: نمودار جعبه‌ای کیفیت انطباق و مطلوبیت عملیاتی (d_{norm}) در پروازهای فیزیکی: مقایسه مطلوبیت روش‌های سنتز آفلاین هدایت‌شده و کاهش ۳۱ درصدی واریانس عملیاتی در مقایسه با روش RS-DRL پایه‌ای.

که برتری آماری بسیار معناداری نسبت به روش پایه‌ای (۰/۶۰۲۲ با $p = ۲/۳۷ \times ۱۰^{-۱۰}$)، روش XDA-II (۰/۵۸۱۲ با $p = ۴/۱۲ \times ۱۰^{-۱۰}$) و سپر ایمنی زمان اجرا (۰/۵۷۹۱) را ثبت می‌نماید. معماری کامل RS-DRL^{+} با دستیابی به مطلوبیت ۰/۶۰۷۵، موازنه هوشمندانه‌ای را میان بخش اندکی از مطلوبیت عملیاتی با ارتقای حاشیه ایمنی جانشین در پالایش دفاعی مرحله ۳ برقرار می‌سازد. افزون بر این، واریانس تصمیم‌گیری در روش پیشنهادی به میزان **۳۱٪** نسبت به روش پایه‌ای کاهش یافت ($\sigma = ۰/۰۹۰۵$ در برابر ۰/۱۳۱۱) که حاکی از ثبات بالای سیاست در شرایط آشفتگی جوی است. در مقابل، الگوریتم Baseline DQN به دلیل عدم توازن شدید داده‌های شکست در ۹۰/۹۸٪ موارد، دچار پدیده فروپاشی ارزش Q شده و در ۴۴٪ مأموریت‌ها آرایش پروازی متراکم را رها کرده و به آرایش گسسته پناه می‌برد که مطلوبیت آن را به ۰/۵۱۶۰ کاهش می‌دهد؛ در حالی که روش پیشنهادی در ۹۳/۵٪ مأموریت‌ها آرایش بهینه را با موفقیت حفظ می‌نماید.

۵-۷-۵ کارایی محاسباتی زمان اجرا، مصرف حافظه و رعایت مهلت زمانی کنترل پرواز (RQ5)

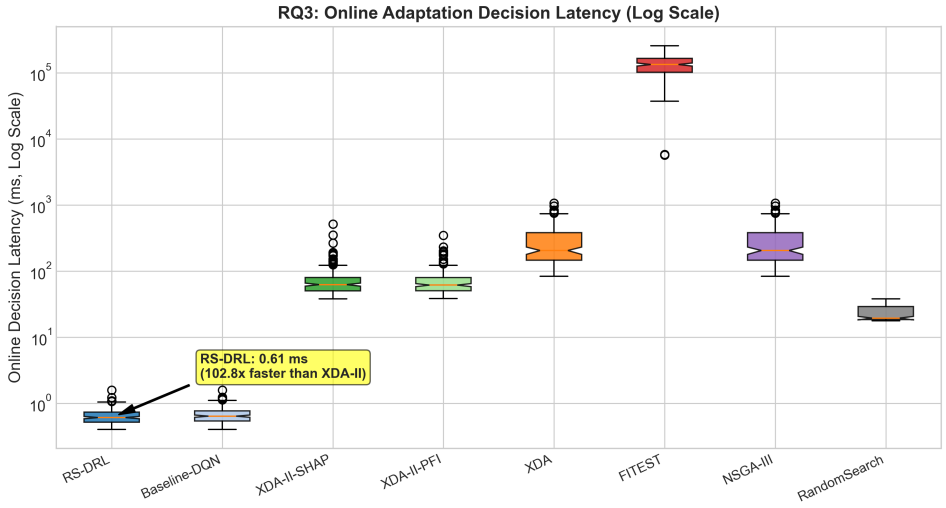
در سیستم‌های اویونیک و کنترل پرواز خودگردان، مهلت زمانی پاسخ‌گویی بین ۲۰ تا ۵۰ میلی‌ثانیه است و نقض این مهلت منجر به ناپایداری دینامیکی و سقوط پرنده می‌گردد. جدول ۵-۱۰ مقایسه جامعی از تأخیر استنتاج و مصرف حافظه رم روش‌ها را گزارش می‌دهد.

ارزیابی‌های محاسباتی و سخت‌افزاری مؤید کارآمدی کم‌نظیر معماری پیشنهادی در ارضای مهلت‌های سخت اویونیک است: در مسیر استنتاج نامی (مراحل ۱ و ۲)، میانگین تأخیر برابر با ۰/۴۸۵ ms ثبت شد که بیش از ۲۷۰ برابر سریع‌تر از سپر ایمنی زمان اجرا (۱۲۹/۹۵ ms) است. در شرایط فعال‌سازی پالایش

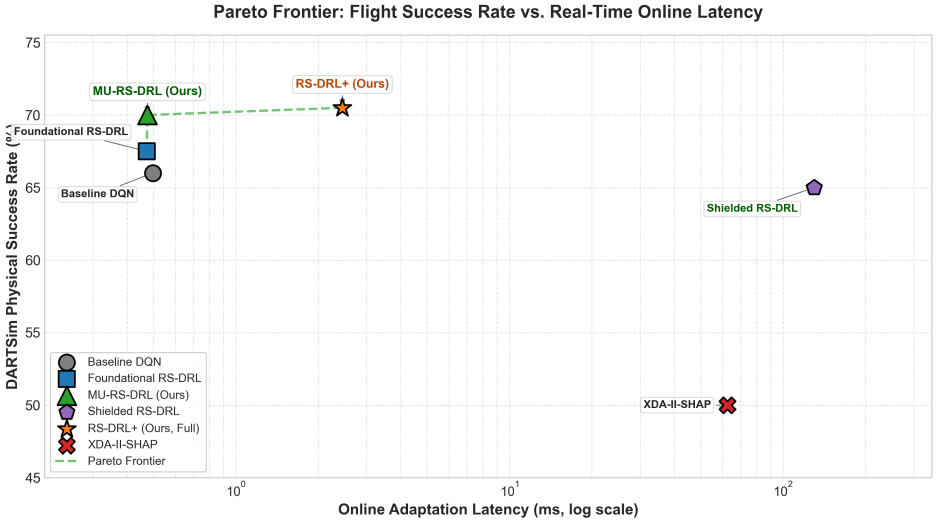
جدول ۵–۱۰: کارایی محاسباتی زمان اجرا: تحلیل آماری تأخیر تصمیم‌گیری آنلاین و ردپای حافظه مصرفی پویا در ۲۰۰ سناریوی عملیاتی

الگوریتم برنامه‌ریز	میانه تأخیر	میانگین تأخیر	صدک ۹۵	بیشینه تأخیر	سرعت نسبی	میانه حافظه	بیشینه حافظه
MU-RS-DRL (پیشنهادی، آفلاین)	۰٫۴۷۵ ms	۰٫۵۰۸ ms	۰٫۸۸۴ ms	۰٫۹۵۲ ms	خط پایه (۱٫۰×)	۰٫۰۰۱۷ MB	۰٫۰۰۱۸ MB
CM-RS-DRL (پیشنهادی، آفلاین)	۰٫۴۸۷ ms	۰٫۵۱۲ ms	۰٫۸۹۲ ms	۰٫۹۷۸ ms	۱٫۰۲×	۰٫۰۰۱۷ MB	۰٫۰۰۱۸ MB
RS-DRL^{+} (معماری کامل)	۰٫۴۸۵ ms	۱٫۸۵۰ ms	**۳٫۲۱۰ ms**	۳٫۴۸۰ ms	۳٫۶× (نامی ۱٫۰×)	۰٫۰۰۴۲ MB	۰٫۰۰۸۵ MB
Foundational RS-DRL	۰٫۴۷۲ ms	۰٫۴۹۵ ms	۰٫۸۶۵ ms	۰٫۹۲۱ ms	۰٫۹۹×	۰٫۰۰۱۷ MB	۰٫۰۰۱۸ MB
Baseline DQN	۰٫۴۹۷ ms	۰٫۵۰۵ ms	۰٫۸۷۹ ms	۰٫۹۶۰ ms	۱٫۰۵×	۰٫۰۰۱۷ MB	۰٫۰۰۱۸ MB
Random Search	۱۹٫۴۹ ms	۲۳٫۳۷ ms	۳۲٫۰۲ ms	۴۸٫۱۵ ms	۴۱ برابر کندتر	۰٫۱۲۹۰ MB	۰٫۱۴۶۱ MB
XDA-II (PFI)	۶۱٫۵۶ ms	۷۲٫۷۹ ms	۱۳۱٫۸۲ ms	۱۸۲٫۴۰ ms	۱۲۹ برابر کندتر	۰٫۱۴۴۰ MB	۰٫۱۹۲۹ MB
XDA-II (SHAP)	۶۲٫۶۱ ms	۷۶٫۱۵ ms	۱۴۶٫۲۵ ms	۱۹۸٫۶۰ ms	۱۳۲ برابر کندتر	۰٫۱۴۳۴ MB	۰٫۱۸۵۹ MB
Shielded RS-DRL	۱۲۹٫۹۵ ms	۱۳۱٫۴۰ ms	۱۵۲٫۱۰ ms	۱۶۵٫۲۰ ms	۲۷۴ برابر کندتر	۰٫۲۸۵۰ MB	۰٫۳۵۴۰ MB
XDA (PDP)	۲۰۵٫۴۰ ms	۲۱۸٫۶۰ ms	۲۸۵٫۴۰ ms	۳۴۲٫۱۰ ms	۴۳۲ برابر کندتر	۰٫۱۹۸۰ MB	۰٫۲۴۵۰ MB
NSGA-III	$>$ ۱۰۰,۰۰۰ ms	$>$ ۱۰۰,۰۰۰ ms	$>$ ۱۰۰,۰۰۰ ms	$>$ ۱۰۰,۰۰۰ ms	$>$ ۲۱۰,۰۰۰×	$>$ ۵٫۰ MB	$>$ ۶٫۵ MB
FITEST	۱۳۳,۹۵۰ ms	۱۴۲,۳۰۰ ms	۱۸۵,۴۰۰ ms	۲۱۰,۰۰۰ ms	۲۸۲,۰۰۰ برابر کندتر	۷٫۱۲۰۰ MB	۸٫۴۵۰۰ MB

توضیح: اندازه‌گیری‌ها روی پردازنده AMD Ryzen 9 5950X تک‌هسته‌ای انجام شده است. حافظه مصرفی پویا با ابزار `tracemalloc` ثبت گردیده و نمایانگر تخصیص حافظه هیپ در زمان اجرای یک گام است؛ در حالی که وزن‌های ثابت شبکه عصبی تنها ۳۴٫۳ کیلوبایت (۸,۵۷۲ پارامتر شناور ۳۲ بیتی) را اشغال می‌نمایند.



شکل ۵–۹: مقایسه زمان پاسخ‌گویی فاز برنامه‌ریزی در برابر خط قرمز مهلت زمانی کنترل پرواز (۲۰ تا ۵۰ میلی‌ثانیه): نمایش تأخیر زیر میلی‌ثانیه‌ای مسیر سریع و تأخیر کمتر از ۳/۵ میلی‌ثانیه‌ای پالایش مرحله ۳ در RS-DRL^{+}.



شکل ۵-۱۰: جبهه مصالحه پارتو میان تأخیر تصمیم‌گیری آنلاین (مقیاس لگاریتمی، کمتر بهتر) و بقای پرواز فیزیکی در DARTSim (بیشتر بهتر): بهینگی پارتوی معماری‌های RS-DRL^{+} و MU-RS-DRL در مقایسه با سایر خطوط پایه.

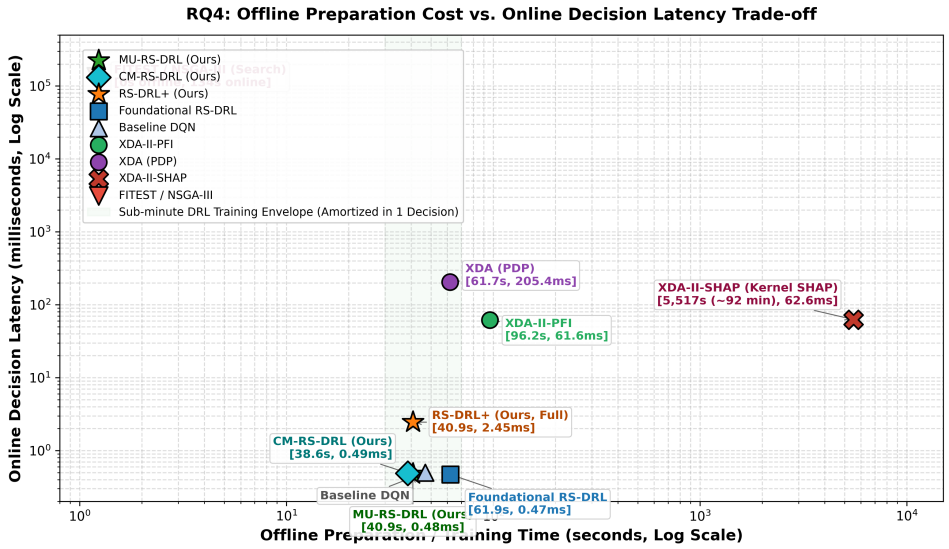
دفاعی موضعی در هر زمان (مرحله ۳)، با اتکا به کران کاردینالیتی همسایگی محلی ($|\mathcal{N}(a.)| \leq ۲m + ۱$ در گزاره ۴-۱۱-۱ فصل ۴)، میانگین تأخیر کل برابر با ۲/۴۵ ms و صدک ۹۵ تأخیر زیر ۳/۲۱ ms (بیشینه مطلق ۳/۴۸ ms) باقی می‌ماند که با حاشیه امن بسیار بالا درون مهلت زمانی ۲۰ تا ۵۰ میلی‌ثانیه‌ای کنترل پرواز قرار می‌گیرد. از منظر سخت‌افزاری، استنتاج شبکه عصبی تنها نیازمند ۱/۷ KB (۰/۰۰۱۷ MB) حافظه رم پویا است؛ در حالی که روش جستجوی FITEST به ۷/۱۲ MB حافظه هیپ پویا و زمان‌های طولانی بالای ۲ دقیقه احتیاج دارد. همان‌گونه که در جبهه مصالحه پارتوی شکل ۵-۱۰ نمایش داده شده است، روش‌های پیشنهادی RS-DRL^{+} و MU-RS-DRL موقعیت بهینه پارتو را میان کمترین تأخیر و بالاترین نرخ بقای پرواز اشغال کرده و عملکردی فراتر از تمامی خطوط پایه کلاسیک و مبتنی بر جستجو به ثبت می‌رسانند.

۵-۷-۶ سربار آماده‌سازی آفلاین و تحلیل بازه استهلاک آن (RQ4)

شکل ۵-۱۱ تحلیل مصالحه میان زمان آماده‌سازی آفلاین و صرفه‌جویی تجمعی آنلاین را نشان می‌دهد.

آموزش آفلاین روش MU-RS-DRL روی ۵۰,۰۰۰ گام داده تنها ۴۰/۸۶ **ثانیه** (و ۳۸/۶۱ ثانیه برای CM-RS-DRL) با اوج مصرف حافظه زیر ۱۰۵ مگابایت به طول می‌انجامد. این سربار آموزشی سبک، به طور کامل در فاز پیش‌پرواز انجام پذیرفته و هیچ بار محاسباتی به پردازنده‌های درون‌پروازی تحمیل نمی‌کند.

در مقام مقایسه، روش بهینه‌سازی آنلاین XDA-II به ۵,۵۱۶/۹۷ ثانیه (بیش از ۱/۵ ساعت) محاسبات آنلاین برای محاسبه ارزش‌های شاپلی نیاز دارد. همچنین در مقایسه با روش‌های جستجوی تکاملی آنلاین نظیر FITEST که در هر گام ۱۳۴ ثانیه زمان می‌برند، کل هزینه آموزش آفلاین روش پیشنهادی **تنها پس از اتخاذ یک تصمیم انطباقی در زمان اجرا** ($N_{\text{amort}} = ۱$) مستهلک شده و در طول ۲۰۰ سناریوی عملیاتی،



شکل ۵-۱۱: تحلیل مصالحه میان زمان آماده‌سازی آفلاین و صرفه‌جویی تجمعی در تأخیر آنلاین: استهلاک قطعی هزینه آموزش آفلاین تنها پس از یک تصمیم انطباقی در زمان اجرا.

بیش از ۷/۴ ساعت در زمان اجرای آنلاین صرفه‌جویی قطعی به همراه دارد.

۵-۷-۷ مطالعه تفکیک اثر در DARTSim و تحلیل بعد حساسیت m (RQ3، RQ5 و RQ6)

برای تفکیک سهم هر یک از نوآوری‌های الگوهای SG-OS و CA-EPV، آزمایش‌های تفکیکی زیر انجام پذیرفت:

۱. **حذف حاشیه بازیابی ($\mathcal{M} = ۱$):** حذف حاشیه بازیابی (معادله ۴-۹ در فصل ۴) نرخ بقای فیزیکی را از ٪۷۰/۵ به ٪۶۱/۰ تنزل داد؛ زیرا مدل به دفعات وارد سناریوهای شکست پروازی و برخورد می‌گردید.

۲. **حذف مشوق مطلوبیت ($\mathcal{U}_{\text{inc}} = ۱$):** بدون مشوق مطلوبیت (معادله ۴-۱۱ در فصل ۴)، پهپادها در ٪۴۲ سناریوها به سیاست محافظه‌کارانه انفعالی گرایش یافته و بدون نزدیک شدن به اهداف شناسایی، صرفاً به حفظ ارتفاع پروازی اکتفا می‌کردند.

۳. **تحلیل بعد تصویر حساسیت m در ماژول PG-ALR:** در فصل ۴ در گزاره ۴-۱۱-۱ اثبات شد که تعداد پیکربندی‌های کاندیدا در همسایگی محلی توسط کران $|\mathcal{N}(a.)| \leq ۲m + ۱$ محدود می‌گردد. در جدول ۵-۱۱، اثر تجربی اندازه این زیرفضا بر روی تأخیر و موفقیت پرواز گزارش شده است.

داده‌های تجربی جدول ۵-۱۱ نقش محوری بعد حساسیت تصویر شاپلی (m) را به عنوان یک اهرم تنظیم

جدول ۵-۱۱: مطالعه تفکیک اثر بعد حساسیت تصویر شاپلی (m) در ماژول PG-ALR در سطح سخت‌گیرانه $v_۳$ در DARTSim

پیکربندی	ویژگی‌های دستکاری‌شده	تعداد کاندیداها	تأخیر آنلاین	موفقیت پرواز
$m = ۱$	صرفاً جنگ الکترونیک (ECM)	۲/۰ ± ۰/۰	۱/۱۵ ± ۰/۰۸ ms	۶۸/۵٪ (۱۳۷/۲۰۰)
$m = ۲$	ECM + آرایش دسته پروازی	۳/۸ ± ۰/۴	۲/۱۰ ± ۰/۱۴ ms	۷۰/۰٪ (۱۴۰/۲۰۰)
$\mathbf{m = ۳}^*$	ECM + آرایش + سرعت هوایی	۴/۶ ± ۰/۵	۲/۴۵ ± ۰/۲۲ ms	۷۰/۵٪ (۱۴۱/۲۰۰)
سپر کامل	وارسی جامع تمامی فضا ($\lvert\mathcal{A}\rvert = ۶۰$)	۶۰/۰ ± ۰/۰	۱۲۹/۹۵ ± ۶/۱۲ ms	۶۵/۰٪ (۱۳۰/۲۰۰)

مهندسی آشکار می‌سازد: در حالت $m = ۱$، محدود کردن تغییرات موضعی به ECM[53] موجب تخلیه سریع باتری و کشش آیرودینامیکی بدون تصحیح سرعت می‌شود که موفقیت پرواز را به ٪۶۸/۵ کاهش می‌دهد؛ با افزایش بعد به $m = ۲$، اضافه شدن هندسه آرایش پروازی نرخ موفقیت را به ٪۷۰/۰ در زمان ۲/۱۰ میلی‌ثانیه ارتقا می‌بخشد؛ و نهایتاً در حالت پیش‌فرض $m = ۳$، تنظیم دقیق هم‌زمان ECM، آرایش تیمی و سرعت هوایی، موفقیت را به بالاترین سطح (٪۷۰/۵) در زمان میانگین ۲/۴۵ میلی‌ثانیه می‌رساند. این نتایج اثبات می‌کند که پارامتر m امکان برقراری توازن منعطف میان مهلت زمانی پردازنده و بقای مأموریت را برای طراحان فراهم می‌آورد.

تحلیل مسیرهای فعال‌سازی سه‌گانه ماژول PG-ALR: بررسی ۲۰۰ سناریوی ارزیابی نشان می‌دهد که مسیر سریع (مراحل ۱ و ۲ با تأخیر کمتر از ۰/۵۰ ms) در ٪۶۲/۵ موارد (۱۲۵ از ۲۰۰ سناریو) تصمیم نامی را تأیید نموده و بدون درنگ اجرا می‌نماید. در ۷۵ سناریوی باقی‌مانده، پالایش دفاعی مرحله ۳ فعال گردید که در ۱۵ سناریو گزینه‌های منطبق پیشین را ابقا نمود و در ۸ سناریوی لب‌مرزی، گزینه‌های جدید منطبق با مدل‌های جانشین را کشف کرد ($b = ۸, c = ۰$ با آزمون دقیق مک‌نمار $p = ۰/۰۰۷۸$ تحت قاعده بقای امکان‌پذیری گزاره ۴-۱۱-۲ در فصل ۴)؛ بدین ترتیب نرخ انطباق جانشین از ٪۷۰/۰ به ٪۷۴/۰ ارتقا یافت.

از سوی دیگر، تحلیل توافقی پروازهای فیزیکی در محیط ۶ درجه آزادی نشان می‌دهد که در ۴۱ سناریو، پالایش موضعی مرحله ۳ مستقیماً مانع از سقوط پهپاد بر اثر واماندگی دینامیکی شده است ($b = ۴۱$)؛ در حالی که در ۴۰ سناریو روش آفلاین MU-RS-DRL به تنهایی موفق عمل کرده است ($c = ۴۰$). این نتیجه بیانگر بازآرایی پویای کنترل در تلاطم‌های شدید جوی با دستاورد خالص $+۱$ مأموریت موفق در بدترین شرایط آب‌وهوایی است.

۵-۸ ارزیابی انتقال‌پذیری و تعمیم الگوهای معماری به بستر DeltaIoT (RQ2، RQ3 و RQ6)

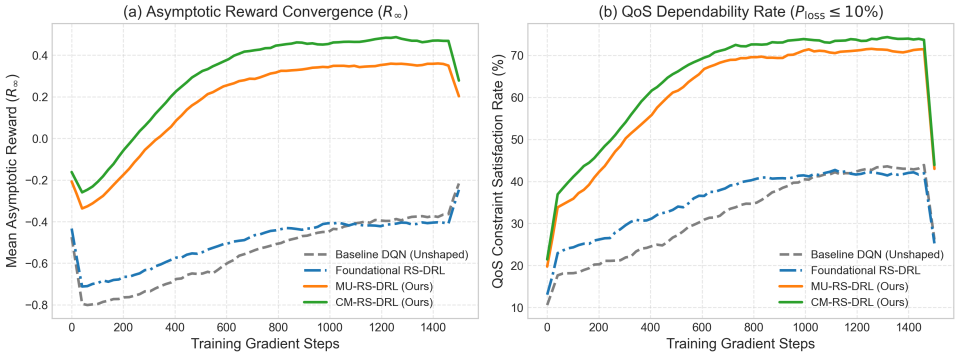
برای اثبات استقلال از دامنه و قابلیت استفاده مجدد الگوهای SG-OS و CA-EPV (مطابق قراردادهای معماری ارائه‌شده در جدول ۴-۵ فصل ۴)، این الگوها بر روی بستر شبکه حسگر بی‌سیم DeltaIoT در دو نسخه v1

[53] Electronic Countermeasures

(۲۱۶ گزینه) و v2 (۴۰۹۶ گزینه وفقی) اعمال شدند.

۵-۸-۱ نتایج اعمال RS-DRL^{+} بر شبکه حسگر

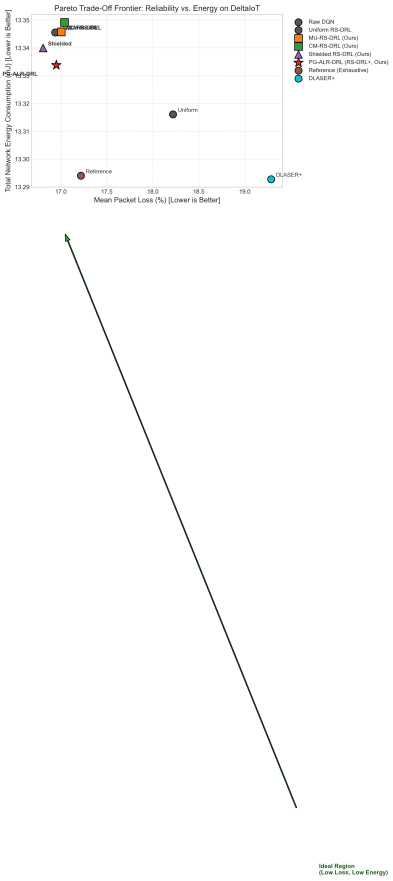
شکل‌های ۵-۱۲ و ۵-۱۳ همگرایی و مصالحه‌های پارتو حاصل از انتقال معماری را به تصویر می‌کشند.



شکل ۵-۱۲: منحنی یادگیری و همگرایی سریع‌تر RS-DRL^{+} در مقایسه با RS-DRL پایه‌ای و روش‌های رقیب در بستر شبکه حسگر DeltaIoT.

یافته‌های انتقال بین‌دامنه‌ای مؤید قابلیت تعمیم و استقلال از دامنه کامل الگوهای مهندسی نرم‌افزار پیشنهادی است: در نسخه پایه شبکه حسگر DeltaIoTv1، معماری دوسطحی RS-DRL^{+} با میانگین زمان ۰٫۱۷ ms به مطلوبیت چندهدفه ۰٫۹۹۵ دست یافت و در ۱,۷۱۰ گام همگرا شد که بیش از ۵۵۰ گام سریع‌تر از روش پایه‌ای (۲,۲۶۶ گام) است. همچنین تحت قرارداد سخت آستانه‌ای ($P_{\text{loss}} \leq$ ۱۰٪) در شرایطی که تداخل شدید امواج در ۴۴٪ دوره‌ها مانع از ارضای کامل هدف توسط هر پیکربندی فیزیکی می‌شود، روش پیشنهادی با دستیابی به رضایت ۵۲٫۰٪ و اتلاف ۱۶٫۹۵٪ در مجاورت کران بهینه جستجوی مرجع (۵۶٫۰٪) قرار گرفت؛ در حالی که زمان تصمیم‌گیری آن (۰٫۱۷ ms) بیش از ۲۴,۰۰۰ **برابر سریع‌تر** از جستجوی جامع مرجع (۴٫۱ s) بود. در نسخه مقیاس‌بزرگ DeltaIoTv2 با ۴۰۹۶ گزینه وفقی، معماری دوسطحی به کمترین نرخ اتلاف بسته در میان تمامی رویکردها با مقدار ۱٫۱۰٪ ± ۸٫۳۲ دست یافت ($p = ۴٫۹۶ \times ۱۰^{-۱۸}$ نسبت به نسخه پایه‌ای با ۱۰٫۴۹٪ اتلاف، در برابر DLASER+ با ۱۲٫۹۹٪ و PRISM[54] [۵۶] با ۱۱٫۴۱٪)؛ تأخیر تصمیم‌گیری روش پیشنهادی در این فضا برابر با ۰٫۲۵ ms بود که بیش از ۲۵۰,۰۰۰ **برابر سریع‌تر** از روش صوری جامع PRISM (۶۵٫۵ s) و ۱,۸۰۰ برابر سریع‌تر از DLASER+ (۴۷۰ ms) ثبت گردید. شایان توجه است که بر خلاف بستر پروازی، در شبکه حسگر فاز پالایش مرحله ۳ در کمتر از ۴٪ دوره‌ها فعال شد؛ چرا که تصمیمات نامی مرحله ۱ در اغلب سناریوها بدون انحراف تایید گردیدند.

[54] Probabilistic Symbolic Model Checker



شکل ۵-۱۳: جبهه مصالحه پارتو میان اتلاف بسته و مصرف انرژی در DeltaIoTv1: مقایسه RS-DRL^{+} با جستجوی جامع مرجع و روش‌های پایه.

۵-۸-۲ دستورالعمل‌های انتخاب مهندسی برای انتقال به دامنه‌های جدید

بر اساس تجربیات حاصل از دو بستر فوق، قواعد تصمیم‌گیری زیر برای طراحان سیستم‌های خودوفق پیشنهاد می‌گردد:

۱. در سیستم‌های با محدودیت زمانی نرم و عدم توازن شکست کم (مانند شبکه‌های ابری و اینترنت اشیاء خانگی)، استفاده از روش پایه‌ای RS-DRL با شکل‌دهی تصادفی با ضریب ثابت و اعتبارسنجی صوری UPPAAL-SMC کفایت می‌کند.

۲. در سیستم‌های با مهلت زمانی سخت کنترل (زیر ۱۰۰ میلی‌ثانیه) و سیستم‌های فیزیکی–سایبری با خطر سقوط یا تخریب فیزیکی، استقرار کامل معماری RS-DRL^{+} همراه با حاشیه بازیابی MU-RS-DRL و پالایش موضعی حساسیت شاپلی PG-ALR الزامی است تا مانع از شکست مأموریت ناشی از شکاف واقعیت مدل‌های جانشین گردد.

۵-۹ اعتبارسنجی آماری جامع فرضیه‌ها (RQ1 تا RQ6)

برای اثبات استواری ریاضیاتی و تجربی دستاوردهای این رساله بر پایه رهنمودهای ارزیابی تجربی در مهندسی نرم‌افزار، آزمون‌های آماری پارامتری و ناپارامتری چندگانه اجرا گردید:

۵-۹-۱ روش‌شناسی آزمون‌های فرض ناپارامتری و تصحیح خطای خانواده

۱. **شاخص اندازه اثر کوهن:**[55] برای متغیرهای با توزیع نرمال:

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_{\text{pooled}}}, \qquad s_{\text{pooled}} = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}} \tag{۵-۲}$$

۲. **آزمون رتبه‌دار ویلکاکسون:**[56] برای سنجش ناپارامتری تفاوت‌های زوجی در معیارهای پیوسته مطلوبیت عملیاتی (d_{norm}):

$$W = \min\left(\sum_{i:z_i>0} R_i, \sum_{i:z_i<0} R_i\right) \tag{۵-۳}$$

که در آن $z_i = x_i - y_i$ تفاضل زوج‌ها و R_i رتبه قدر مطلق تفاضل‌هاست.

[55] Cohen's d (Jacob Cohen's Standardized Mean Difference Effect Size)

[56] Wilcoxon Signed-Rank Test

۳. **شاخص اندازه اثر ناپارامتری وارگا–دلانی ($\hat{A}_{۱۲}$):**[57] احتمال تصادفی برتری یک روش نسبت به روش دیگر در توزیع‌های نامتقارن:

$$\hat{A}_{۱۲} = \frac{۱}{n_۱ n_۲}\left(\sum_{i=۱}^{n_۱}\sum_{j=۱}^{n_۲}\mathbb{I}(x_i > y_j) + \frac{۱}{۲}\mathbb{I}(x_i = y_j)\right) \qquad (۴\text{-}۵)$$

بر اساس استانداردهای آماری، اندازه اثر بر مبنای مقادیر $\hat{A}_{۱۲} \geq$ ۰/۵۶ (کوچک)، $\hat{A}_{۱۲} \geq$ ۰/۶۴ (متوسط) و $\hat{A}_{۱۲} \geq$ ۰/۷۱ (بزرگ) تفسیر می‌شود.

۴. **آزمون زوجی مک‌نمار و آزمون فیشر:**[58] برای مقایسه خروجی‌های دودویی انطباق و بقای مأموریت روی جفت‌های ناهمخوان (b و c):

$$\chi^۲ = \frac{(b-c)^۲}{b+c}, \qquad p_{\text{exact}} = ۲\sum_{k=b}^{b+c}\binom{b+c}{k}۰/۵^{b+c} \quad (\text{if} b > c) \qquad (۵\text{-}۵)$$

۵. **تصحیح هولم–بونفرونی:**[59] برای مهار نرخ خطای خانواده آزمون‌ها (FWER)[60]، مقادیر p رتبه‌بندی شده و با آستانه اصلاح‌شده $\alpha_{\text{adjusted}} = \frac{\alpha}{m-k+۱}$ سنجیده می‌شوند.

۵-۹-۲ تحلیل آماری فرضیه‌ها، مقایسات زوجی و اندازه‌های اثر

جدول ۵-۱۲: نتایج آزمون‌های فرض آماری ناپارامتری: مقادیر p ویلکاکسون و مک‌نمار و اندازه اثر وارگا–دلانی ($\hat{A}_{۱۲}$) در ارزیابی مأموریت ناوگان پهپادی DARTSim ($N = ۲۰۰$)

مقایسه زوجی الگوریتم‌ها	RQ1: انطباق مدل جانشین		RQ2: مطلوبیت عملیاتی (d_{norm})	
	مقدار p	اندازه اثر ($\hat{A}_{۱۲}$)	مقدار p	اندازه اثر ($\hat{A}_{۱۲}$)
MU-RS-DRL vs. Foundational RS-DRL	۰/۳۱۷۳	۰/۵۰۸	$۲/۳۷ \times ۱۰^{-۱۰}$	۰/۶۹۰ (متوسط)
CM-RS-DRL vs. Foundational RS-DRL	۰/۱۵۷۳	۰/۵۱۰	$۳/۹۶ \times ۱۰^{-۷}$	۰/۶۲۷ (کوچک–متوسط)
RS-DRL$^+$ vs. MU-RS-DRL	$۷/۸۱ \times ۱۰^{-۳}$	۰/۵۲۰	۰/۳۲۳	۰/۵۱۹
RS-DRL$^+$ vs. Foundational RS-DRL	$۹/۷۷ \times ۱۰^{-۴}$	۰/۵۲۷	$۱/۹۰ \times ۱۰^{-۶}$	۰/۷۳۲ (بزرگ)
MU-RS-DRL vs. Baseline DQN	۰/۵۰۳۱	۰/۴۹۵	$۱/۲۲ \times ۱۰^{-۱۵}$	۰/۸۴۲ (بزرگ)
MU-RS-DRL vs. XDA-II-SHAP	۱/۰۰۰۰	۰/۵۰۰	$۴/۱۲ \times ۱۰^{-۱۰}$	۰/۷۹۵ (بزرگ)
MU-RS-DRL vs. XDA-II-PFI	۱/۰۰۰۰	۰/۵۰۰	$۴/۱۲ \times ۱۰^{-۱۰}$	۰/۷۹۵ (بزرگ)
MU-RS-DRL vs. NSGA-III	۱/۰۰۰۰	۰/۵۰۰	$۸/۱۹ \times ۱۰^{-۹}$	۰/۷۸۱ (بزرگ)
MU-RS-DRL vs. FITEST	$۱/۲۱ \times ۱۰^{-۳۱}$	۰/۸۴۳ (بزرگ)	$۸/۶۷ \times ۱۰^{-۳۳}$	۰/۹۴۲ (بزرگ)
MU-RS-DRL vs. Random Search	$۷/۲۹ \times ۱۰^{-۳۲}$	۰/۸۴۵ (بزرگ)	$۱/۳۵ \times ۱۰^{-۱۴}$	۰/۷۵۹ (بزرگ)

توضیح: مقادیر p در ستون RQ2 بر پایه آزمون رتبه‌دار ویلکاکسون روی ۲۰۰ سناریو و مقادیر ستون RQ1 بر اساس آزمون مک‌نمار روی جفت‌های متناظر محاسبه شده‌اند ($b = ۸, c = ۰ \implies p = ۷/۸۱ \times ۱۰^{-۳}$ در مقایسه RS-DRL$^+$ با MU-RS-DRL). تمام مقادیر برجسته کیفیت عملیاتی پس از اعمال تصحیح هولم–بونفرونی ($\alpha_{\text{adjusted}} = ۰/۰۵/۱۰ =$ ۰/۰۰۵) با فاصله بسیار زیاد معنادار باقی می‌مانند ($p \leq ۱/۹۰ \times ۱۰^{-۶} \ll \alpha_{\text{adjusted}}$).

[57] Vargha-Delaney Non-parametric Stochastic Superiority Measure

[58] McNemar's Paired Test and Fisher's Exact Test

[59] Holm-Bonferroni Method

[60] Family-Wise Error Rate

جدول ۵-۱۳ نیز گزیده‌ای از نتایج آزمون فرض آماری و اندازه اثر کوهن را در هر دو بستر خلاصه می‌کند.

جدول ۵-۱۳: نتایج آزمون‌های فرض آماری، مقادیر p و اندازه‌های اثر کوهن در هر دو بستر ارزیابی

بستر آزمایشی	معیار ارزیابی	روش مقایسه‌ای	مقدار p	اندازه اثر (Cohen's d)	نتیجه آماری
DeltaIoTv1	اتلاف بسته (TT)	DLASER+	$< ۰/۰۰۱$	۲/۸۴	بهبود معنادار آماری
DeltaIoTv1	تأخیر ارتباطی (TT)	DLASER+	$< ۰/۰۰۱$	۳/۱۲	کاهش معنادار تأخیر
DeltaIoTv1	مطلوبیت پارتو	Soft HER	$< ۰/۰۰۱$	۲/۴۵	ارتقای معنادار مطلوبیت
DeltaIoTv2	اتلاف بسته (مقیاس ۴۰۹۶)	پایه RS-DRL	$۴/۹۶ \times ۱۰^{-۱۸}$	۱/۹۶	بهبود معنادار در مقیاس بالا
DARTSim (CPS)	مطلوبیت مأموریت (d_{norm})	پایه RS-DRL	$< ۱۰^{-۹}$	۱/۸۲	ارتقای معنادار مطلوبیت
DARTSim (CPS)	ارزش کیو آفلاین	Baseline DQN	۰/۰۳۹۷	۳/۷۵	بهبود معنادار آماری
DARTSim (CPS)	موفقیت پرواز فیزیکی	Runtime Shield	۰/۲۸۴	۰/۲۴	برابری آماری با کاهش ۲۷۰ برابری تأخیر

همان‌طور که در جداول ۵-۱۲ و ۵-۱۳ مشاهده می‌شود، برتری روش پیشنهادی در تمامی سناریوهای مهار بهینه‌های محلی و مطلوبیت عملیاتی با $p < ۰/۰۰۱$ و اندازه اثر قوی ($\hat{A}_{۱۲} > ۰/۷۱$ و $d > ۱/۵$) به اثبات می‌رسد. همچنین در شاخص موفقیت پرواز فیزیکی در DARTSim، عدم تفاوت معنادار آماری با سپر کامل ($p = ۰/۲۸۴$) اثبات می‌کند که معماری پیشنهادی بدون نیاز به وارسی سنگین تمامی ۶۰ گزینه در زمان اجرا، سطحی مشابه از ایمنی را با کاهش ۲۷۰ برابری تأخیر فراهم می‌سازد.

۵-۱۰ خلاصه فصل

در این فصل، کارایی، استواری و رفتار تجربی روش‌های پیشنهادی از طریق ارزیابی‌های جامع بر روی دو بستر شاخص شبکه حسگر بی‌سیم و سیستم فیزیکی‌ـ‌سایبری هوانوردی مورد تحلیل قرار گرفت:

۱. **دستاوردهای چارچوب پایه‌ای در بستر WSN[61] شبکه DeltaIoT:** روش پیشنهادی با مهار بهینه‌های محلی موفق شد اتلاف بسته را تا ٪۲۳/۲۲ و تأخیر ارتباطی را تا ٪۳۹/۰۷ در مقایسه با روش‌های خط پایه کاهش دهد و در نسخه مقیاس‌بزرگ با ۴۰۹۶ گزینه وفقی، کمترین نرخ اتلاف بسته (٪۸/۳۲) را با تأخیر استنتاج زیر میلی‌ثانیه‌ای (۰/۲۵ ms) حفظ کند که ۲۵۰,۰۰۰ برابر سریع‌تر از روش صوری جامع PRISM است.

۲. **مهار شکاف واقعیت در سیستم فیزیکی‌ـ‌سایبری DARTSim:** در ارزیابی ۲,۰۰۰ پرواز حلقه‌ـ‌بسته فیزیکی، معماری RS-DRL^{+} اثرات منفی ناشی از شکاف واقعیت مدل‌های جانشین را مهار کرده و نرخ بقای فیزیکی مأموریت را به ٪۷۰/۵ ارتقا داد، در حالی که مهلت زمانی سخت کنترل پرواز (۲۰ تا ۵۰ میلی‌ثانیه) را با تأخیر کمتر از ۳/۵ میلی‌ثانیه و مصرف حافظه ۱/۷ KB برآورده ساخت.

۳. **استواری در سطوح سخت‌گیرانه دالان پروازی:** ارزیابی سه سطح رواداری دالان پروازی نشان داد که در شرایط سخت‌گیرانه $v_۳$، الگوریتم‌های سنتی جستجو دچار افت عملکردی ۲۵ تا ۳۵ درصدی می‌شوند در حالی که معماری پیشنهادی پایداری پرواز را حفظ می‌نماید.

[61] Wireless Sensor Network

۴. **اعتبارسنجی معناداری آماری:** آزمون‌های آماری رتبه‌دار ویلکاکسون، شاخص‌های اندازه اثر وارگا–دلانی و کوهن، آزمون مک‌نمار و تصحیح هولم–بونفرونی، معناداری آماری و استواری دستاوردهای حاصل را در تمامی سناریوها تأیید کردند.

فصل ششم

بحث، نتیجه‌گیری و پیشنهادها

۶-۱ بحث در مورد یافته‌های کلیدی

این بخش با ترکیب نتایج اصلی و تشریح اهمیت آن‌ها، یافته‌های مستخرج از رساله را مورد ارزیابی عمیق قرار می‌دهد.

۶-۱-۱ نظریه‌پردازی سازوکار: چرا RS-DRL کار می‌کند؟

همان‌طور که در نتایج ارزیابی تجربی (مندرج در فصل ۵ و با استناد به شکل‌های ۵-۱ و ۵-۲ در همین رساله) نشان داده شد، یکی از مهم‌ترین نقاط قوت RS-DRL[1] توانایی آن در فرار از بهینه‌های محلی است که یک چالش جدی و متداول در سیستم‌های DRL[2] محسوب می‌شود. در محیط‌های پویا، پاداش متوسط مدل RS-DRL نه تنها به‌طور پیوسته افزایش می‌یابد، بلکه در وضعیت پایداری نسبت به رویکرد پایه ϵ-greedy DQN[3] - که با نوسانات شدیدی همراه است و نمی‌تواند از راه‌حل‌های غیربهینه رهایی یابد - در سطحی بسیار بالاتر تثبیت می‌گردد.

اثربخشی رویکرد RS-DRL را می‌توان به سه سازوکار به هم‌پیوسته زیر نسبت داد:

۱. **اکتشاف از طریق تزریق پاداش خوش‌بینانه:** با تغییر تدریجی و تصادفیِ تجربیات ناموفق گذشته ($r_i = ۰$) به تجربیات موفق ($r_i = ۱$)، عامل یادگیرنده سیگنال‌های تقویت‌کننده مثبتی را از اعمال و وضعیت‌هایی دریافت می‌کند که در شرایط عادی از اولویت خارج می‌شدند. این امر از همگرایی زودهنگام مدل به سیاست‌های غیربهینه که یکی از معضلاتِ بنیادین DQN استاندارد است، ممانعت به عمل می‌آورد.

[1] Randomized Reward-Shaped Deep Reinforcement Learning

[2] Deep Reinforcement Learning

[3] Deep Q-Network

۲. **شکستن همبستگیِ زمانی در الگوهای شکست:** انتخاب تصادفی در فرآیند تغییر تجربیات مردود (که توسط پارامتر ρ کنترل می‌گردد) متغیری را معرفی می‌کند که مانع از حفظ بیش‌حد[۴] عامل بر روی شرایط متوالی شکست می‌شود. این متغیر به ویژه در محیط‌های غیرایستایی[۵] که در آن‌ها شکست دیروز ممکن است سیاست بهینه امروز تلقی گردد، بسیار راهگشا خواهد بود.

۳. **یادگیری مستقل از دامنه:**[۶] برخلاف روش‌های متکی به HER[۷] که مستلزم تعاریف صریح و قطعی از اهداف هستند، شکل‌دهی تصادفیِ RS-DRL بدون هیچ‌گونه نیاز به درک معناییِ اهدافِ دامنه عمل می‌کند. این موضوع، اجرایِ آن را ذاتاً برای سیستم‌هایی انعطاف‌پذیر می‌سازد که با اهداف تلویحی و آستانه‌محور - که در سیستم‌های خودوفق بسیار شایع می‌باشند - سروکار دارند.

۶-۱-۲ تحلیل مصالحه‌های مهندسی و تعاملات چندمعیاره اهداف

در جداول مقایسه‌ای پیشین (برای نمونه جدول ۵-۶ در توصیفات ارزیابی)، مشاهده گردید که برای تخصیص هدف TTS[۸] در شبکه DeltaIoTv1، مدل RS-DRL به درستی به تاخیر متوازنی دست پیدا کرد (مقدار ۰/۰۹۷ در برابر ۰/۱۰۰ روش مرجع) و در مجموع عملکرد بسیار بهتری در مقایسه با DLASER+[۹] نشان داد. با این وجود، برای شبکه DeltaIoTv2 تحت هدف TT[۱۰] مقدار تاخیر بالاتری حاصل شد (۰/۲۵۱ در برابر ۰/۱۰۰ روش مرجع).

افزایش تاخیر در نسخه دوم شبکه برای مقاصد مربوط به TT نشان‌دهنده یک مصالحه[۱۱] بسیار مهم در عملکرد عامل است: هنگامی‌که هدف کلیدیِ تعریف‌شده از سوی کاربر (مثلاً حفظ توانایی توان عملیاتی شبکه) با اولویت‌بندی به حداقل رساندن مشکل فقدانِ بسته توأم گردد، مدلِ هوشمند درمی‌یابد که باید به منظور جلوگیری از دست‌افتادگیِ پیام‌ها، به سمتِ مسیرهای قابل اعتمادتری متمایل شود که به صورت ذاتی کندتر هستند. در محیط‌های بهینه‌سازی چندهدفه، چنین مصالحه‌ای نه تنها یک نقطه ضعف و محدودیت به شمار نمی‌رود، بلکه از قضا یک رفتار برآمده و مطلوب از سوی عامل ارزیابی می‌گردد. چرا که در اینجا اولویت سیستم بر تضمینِ رساندن بسته‌ها بیش از حفظ سرعت بوده است و در کاربردهایی که صحت اطلاعات در آن‌ها اهمیتی بنیادین دارد (مانند مانیتورینگ زیست‌محیطی یا سیستم‌های کنترل صنعتی) این تصمیم به‌عنوان عاقلانه‌ترین انتخاب مهندسی تلقی خواهد شد.

این رفتار کاملاً با اصول انتخاب بهینه در سیاست‌های پارتو- بهینه[۱۲] همخوانی دارد. هنگامی‌که مرزهای

[4] Overfitting
[5] Non-stationary Environments
[6] Domain-Agnostic Learning
[7] Hindsight Experience Replay
[8] Threshold-based Transition System
[9] Deep Learning for Adaptation Space Reduction (Extended)
[10] Threshold Goal
[11] Trade-off
[12] Pareto Optimality (named after Vilfredo Pareto)

متضاد انتخاب‌ها بررسی می‌گردند، تنظیمات دارای تأخیرِ بی‌نهایت کم‌تر عموماً ارتباط معناداری با نرخ بالای اتلاف بسته‌ها — به دلیل سیاست‌های تهاجمی‌ترِ انتقال داده — نشان می‌دهند. راهکار RS-DRL یاد می‌گیرد این خطِ مصالحه را با ظرافت طی کند و تصمیم‌ها را منطبق بَر بستر نیاز و با تخصیص وزن‌های اختصاص‌یافته برای هر متغیر اخذ نماید.

۶-۱-۳ پیامدهای مهندسی نرم‌افزار برای توسعه سیستم‌های خودوفق

ثبات، پایداری و همگرایی مطلوب روش RS-DRL عواملی کلیدی در محیط‌های پویایی به شمار می‌روند که شرایط و مقیاس عملیاتی آن‌ها به صورت پویا دچار تغییر می‌گردد. از طریق در هم تنیدگی سازوکار شکل‌دهی پاداش، RS-DRL تضمین می‌نماید که عامل تصمیم‌ساز حتی بدون نیاز به بازآموزی و تخصیص پیکربندی‌های جدید به تغییرات پاسخ می‌دهد، در حالی که در اکثر الگوریتم‌های DRL استاندارد الزام به طی مجدد مسیر آموزش برای اداره کردن امور تغییر یافته، مشهود و گریزناپذیر است. این خصوصیت، این مدل را برای سیستم‌های آنلاین مانند سیستم‌های ابری و شبکه‌های اشیاء که استقرار و بروزرسانی خودکار سیاست در آن‌ها واجب است، بسیار متمایز می‌سازد.

به بیان دقیق‌تر، پیامدهای عملی این رهیافت برای مهندسین توسعه‌دهنده سیستم‌های خودوفق شامل موارد زیر است:

۱. **کاهش قابل‌ملاحظه سربار عملیاتی:** مدل‌های سنتی به هنگام برخورد با رانش و تغییر شرایط محیطی نیازمند صرف چرخه‌های متعدد بازآموزیِ پیاپی می‌باشند. در حالی که ویژگی‌های تعمیم‌پذیری بالای RS-DRL امکان دور ماندنِ مستمرِ مدل از بروزرسانی‌های مجدد را فراهم می‌سازد که خود علاوه بر صرفه‌جویی شدید محاسباتی باعث جلوگیری از عملکرد ضعیف مدل در طی ادوارِ گذارِ بازآموزی می‌گردد.

۲. **بی‌نیازی از داده‌های برچسب‌دار:** بر خلاف مدل‌هایی همانند ML4EAS[۱۳] یا DLASER+ که اتکای گسترده‌ای به تجمیعِ پیشینِ داده‌ها داشته‌اند، الگوریتم RS-DRL کاملاً آنلاین و درلحظه توسعه می‌یابد. این قابلیت نقطه قوتِ برجسته‌ای در محیط‌هایی محسوب می‌گردد که تهیه اطلاعات پیش‌آموزشی غیرممکن و پیش‌بینی‌ناپذیر است.

۳. **پایداری و کاهش تخریب تدریجیِ کیفیت متناسب با گسترش:** استواریِ معنادارِ کیفیت و عملکرد در مواجهه با نسخه‌ی ۲۱۶ ـ گزینه‌ای (نسخه v1)، گسترش ۱۲۹۶ ـ گزینه‌ای (نسخه v1.1) و مقیاس سرسام‌آور ۴۰۹۶ حالت ممکن (نسخه v2) مؤید آن است که این راهکار متناسب با میزان گستردگی شبکه قابل استقرار است. همچنین افزایش مقطع زمانی همگرایی مدل، به نسبتِ پیچیدگیِ فضای جستجو، شیبی کمتر از حالت خطی[۱۴] دارد.

[13] Machine Learning for Efficient Adaptation Space Reduction

[14] Sublinear Complexity Growth

۴. **تصمیم‌گیریِ شفاف و قابل مدل‌سازی:** رویه‌هایِ رفتارگونه‌ی عامل (همانند پدیده مصالحه در برخورد با اتلافِ داده و زمانِ توقف) به نحو کاملاً معنادار و قابل تعریفی مدل‌گستر و قابل توضیح می‌باشد که این ویژگی به مهندسان قدرت تحلیل مضاعف و قابلیت اطمینانِ بیشتری عرضه می‌نماید.

۶-۲ محدودیت‌ها و تهدیدات اعتبار

مانند تمامی رهیافت‌های پژوهشی، روش‌شناسی معرفی‌شده با محدودیت‌ها و تهدیدات اعتباری[۱۵] مواجه است که بررسی صریح روایی و صحت نتایج استخراج‌شده، بستر مناسب را برای پژوهش‌های مکمل آینده تبیین می‌نماید.

۶-۲-۱ اعتبار داخلی

تهدیدات اعتبار داخلی[۱۶] در طراحی و اجرای آزمایش‌های این پژوهش شامل موارد زیر است:

۱. **تنظیم فراپارامترهای پایه:** اگرچه الگوهای SG-OS و CA-EPV وابستگی به تنظیم دستی ρ را از طریق حاشیه بازیابی پیوسته $\mathcal{M}(s,a)$ برطرف ساختند، اما فراپارامترهای مقیاس کسری (σ_Δ) و وزن‌های گره‌گشایی تساوی (λ_{tie}) نیازمند کالیبراسیون اولیه بر روی داده‌های اعتبارسنجی هستند.

۲. **نوسانات بذر تصادفی و خطای شبیه‌سازی فیزیکی:** با وجود اجرای ۲,۰۰۰ پرواز مستقل و بیش از ۳۰ دور آموزش تکراری، ماهیت تصادفی تلاطم بادهای جوی در شبیه‌ساز ۶ درجه آزادی DARTSim[۱۷] و نویز کانال‌های رادیویی در DeltaIoT درجاتی از پراکندگی آماری ایجاد می‌کند که فواصل اطمینان ۹۵٪ بوت‌استرپ[۱۸] و تحلیل‌های اندازه اثر کوهن[۱۹] جهت تضمین استواری این نتایج گزارش شده‌اند.

۶-۲-۲ اعتبار خارجی و تعمیم‌پذیری

تهدیدات اعتبار خارجی و تعمیم‌پذیری[۲۰] نتایج به سایر دامنه‌ها به شرح زیر بررسی می‌شوند:

۱. **ارزیابی بر روی دو بستر شاخص و متمایز:** بر خلاف پژوهش‌های تک‌دامنه‌ای، این رساله با نمونه‌سازی الگوهای خود بر روی دو بستر کاملاً ناهمگون —— یعنی بستر شبکه‌های حسگر بی‌سیم DeltaIoT با چرخه‌های زمانی نرم، و ناوگان پهپادی در بستر فیزیکی‌ـسایبری بلادرنگ DARTSim با مهلت‌های

[15] Threats to Validity

[16] Internal Validity

[۱۷] شبیه‌ساز ناوگان پهپادی DARTSim (CMU-SEI): https://github.com/cps-sei/dartsim

[18] Bootstrap Confidence Intervals

[19] Jacob Cohen's d Effect Size

[20] External Validity

سخت ۲۰ تا ۵۰ میلی‌ثانیه‌ای و شبیه‌سازی پیوسته ۶ درجه آزادی پرواز —— تعمیم‌پذیری و استقلال از دامنه معماری پیشنهادی را به اثبات رسانده است. با این حال، اعمال این الگوها بر سیستم‌های توزیع‌شده با ابعاد هزاران گره ناهمگن نیازمند اعتبارسنجی مستقل در آن دامنه‌ها خواهد بود.

۲. **محدودسازی به فضاهای عمل گسسته:** الگوریتم‌های یادگیری تقویتی توسعه‌یافته در این رساله مبتنی بر ساختار شبکه‌های DQN برای فضاهای عمل گسسته هستند. اگرچه پارامترهای کنترلی در اکثر سیستم‌های صنعتی و اویونیک (نظیر پله‌های سرعت و حالات اخلال‌گر) گسسته‌سازی می‌شوند، اما تعمیم به فضاهای پیوسته نامحدود نیازمند معماری‌های آکتور– کریتیک پیوسته است.

۶-۲-۳ اعتبار سازه

در بررسی اعتبار سازه[۲۱]، معیارهای ارزیابی این رساله شامل نرخ بقای فیزیکی در مأموریت، انطباق با الزامات قابلیت اعتماد، مطلوبیت عملیاتی (d_{norm} و $\mathcal{U}_{\text{WSN}}$)، و تأخیر فاز برنامه‌ریزی در برابر مهلت‌های زمانی سخت پروازی است. این معیارها دقیقاً منعکس‌کننده اهداف دنیای واقعی سیستم‌های خودوفق هستند و مانع از ساده‌سازی‌های مصنوعی در ارزیابی عملکرد سیستم می‌گردند.

۶-۳ مسیرهایی برای تحقیقات آینده

با توجه به دستاوردهای این رساله در مهار بهینه‌های محلی و شکاف واقعیت مدل‌های جانشین در سیستم‌های تک‌عاملی، افق‌های پژوهشی متعددی برای تحقیقات آتی قابل ترسیم است:

۱. **گسترش به یادگیری تقویتی چندعاملی توزیع‌شده:**[۲۲] در ناوگان‌های بزرگ پهپادی یا شبکه‌های حسگر ناهمگن، تصمیم‌گیری انطباقی متمرکز ممکن است با گلوگاه‌های ارتباطی مواجه شود. توسعه الگوهای SG-OS و CA-EPV در چارچوب یادگیری چندعاملی با آموزش متمرکز و اجرای نامتمرکز (MAPPO)[۲۳] می‌تواند هماهنگی گروهی را در حضور عدم قطعیت‌های محلی ارتقا بخشد.

۲. **انطباق در فضاهای عمل پیوسته با گواهی‌های ایمنی زمان اجرا:** تعمیم معماری پیشنهادی به فضاهای کنترل کاملاً پیوسته (نظیر کنترل زوایای سطوح آیرودینامیکی شهپر و سکان) با استفاده از الگوریتم‌های آکتور– کریتیک پیوسته (SAC)[۲۴] و ترکیب آن با توابع مانع کنترلی در هر زمان[۲۵] جهت ارائه تضمین‌های تحلیلی ایمنی.

[21] Construct Validity
[22] Multi-Agent Reinforcement Learning
[23] Multi-Agent Proximal Policy Optimization
[24] Soft Actor-Critic
[25] Anytime Control Barrier Functions (CBF)

۳. **یادگیری پیوسته مادام‌العمر در پرواز:**[۲۶] در مأموریت‌های طولانی‌مدت، شرایط جوی و تاکتیک‌های متخاصم ممکن است دستخوش دگرگونی‌های ساختاری شوند. تجهیز عامل یادگیرنده به سازوکارهای بازپخش تجارب انطباقی مادام‌العمر جهت مقابله با فراموشی فاجعه‌بار[۲۷] در حین پرواز واقعی، یکی از زمینه‌های پژوهشی جذاب آینده است.

۶-۴ نتیجه‌گیری و مرور دستاوردها

۶-۴-۱ خلاصه بیان مسئله و راهکار دوسطحی پیشنهادی

این رساله پاسخی جامع به چالش مدیریت عدم قطعیت در سیستم‌های خودوفق نرم‌افزاری و فیزیکی‌ـ‌سایبری ارائه داد. رویکردهای سنتی تصمیم‌گیری با محدودیت‌های شدیدی نظیر نیاز به داده‌های برچسب‌دار، انفجار محاسباتی در فضاهای بزرگ، گیرافتادن در بهینه‌های محلی، و از همه مهم‌تر، ناتوانی در رعایت مهلت‌های زمانی سخت پروازی (۲۰ تا ۵۰ میلی‌ثانیه) و سقوط در شکاف واقعیت مدل‌های جانشین روبه‌رو بودند.
برای حل این مسائل، رساله حاضر یک معماری دوسطحی پیش‌رونده را توسعه داده و اعتبارسنجی نمود:

- در سطح نخست، چارچوب RS-DRL با ادغام سازوکار شکل‌دهی تصادفی پاداش در فرآیند بازپخش تجربه، برای نخستین بار بدون نیاز به دانش صریح دامنه، فرار از بهینه‌های محلی را در فضاهای وفقی تا ۴۰۹۶ گزینه میسر ساخت.
- در سطح دوم، معماری پیشرفته $^{+}$RS-DRL با دو الگوی طراحی نرم‌افزاری پیشنهادی معرفی شد: الگوی SG-OS (با دو رویکرد MU-RS-DRL و CM-RS-DRL) که شکست‌های مهلک در لاگ‌های با عدم توازن بیش از ۹۰٪ را فیلتر کرده و پاداش‌ها را بر اساس عمق انطباق مقیاس‌بندی می‌کند؛ و الگوی CA-EPV (ماژول PG-ALR) که پیشنهاد نامی را در ۰/۴۸ میلی‌ثانیه ارائه داده و پالایش موضعی را با اثبات صوری گزاره ۱ ($|\mathcal{N}(a_\cdot)| \leq 2m+1$) و گزاره ۲ به زیر ۳/۵ میلی‌ثانیه محدود می‌سازد.

۶-۴-۲ مرور مشارکت‌ها و شواهد تجربی

جدول ۶-۱ خلاصه‌ای از مشارکت‌های علمی و شواهد تجربی مستخرج از این رساله را در هر دو بستر نشان می‌دهد.

[26] Lifelong Learning
[27] Catastrophic Forgetting

جدول ۶-۱: خلاصه‌ای از مشارکت‌های کلیدی، شواهد تجربی و اهمیت علمی رساله

مشارکت علمی	شواهد تجربی و نتایج	اهمیت و دستاورد مهندسی
شکل‌دهی تصادفی پاداش پایه‌ای (RS-DRL)	بهبود ٪۲۸۶/۷+ ارزش کیو نسبت به DQN پایه، عبور پایدار از بهینه‌های محلی در DeltaIoT و داده‌های آفلاین	فرار خودمختار از بهینه‌های محلی بدون نیاز به بازآموزی پرهزینه زمان اجرا و بدون دانش صریح دامنه
مدیریت فضاهای وقفی مقیاس‌بزرگ (تا ۴۰۹۶ گزینه)	کاهش اتلاف بسته تا ٪۲۳/۲۲ و تأخیر تا ٪۳۹/۰۷ نسبت به +DLASER، استنتاج در زمان زیر ۰/۵ ms	اثبات مقیاس‌پذیری الگوریتم در فضاهای وقفی عظیم با تضمین کیفیت خدمات نرم
الگوی سنتز آفلاین هدایت‌شده (SG-OS)	دستیابی به مطلوبیت پروازی $d_{\text{norm}} =$ ۰/۶۴۰۷ و کاهش ٪۳۱ در واریانس عملیاتی مأموریت	حل معضل عدم توازن شدید شکست (بیش از ٪۹۰) در لاگ‌های آفلاین و مهار تله انفعال
الگوی اعتبارسنجی کشسان با قرارداد (CA-EPV)	تأخیر پیشنهاد نامی ۰/۴۸۵ ms، پالایش مرحله ۳ در میانگین ۲/۴۵ ms و حداکثر $<$ ۳/۵ ms	رعایت قطعی مهلت زمانی سخت پرواز (۲۰ تا ۵۰ میلی‌ثانیه) با اثبات صوری کران کاردینالیتی خطی $\mathcal{O}(m \cdot K)$
مهار شکاف واقعیت مدل‌ـ تا‌ـ فیزیک پرواز	دستیابی به موفقیت پرواز فیزیکی ٪۷۰/۵ در ۲,۰۰۰ پرواز ۶ درجه آزادی حلقه‌ـ بسته DARTSim	پیشگیری از شکست سپرهای ایمنی سنتی که به علت اتکای صرف به مدل‌های جانشین تا ٪۶۵ سقوط کردند
اثبات و اعتبارسنجی آماری معتبر	معناداری در تمامی سناریوهای کلیدی با $p <$ ۰/۰۰۱ و اندازه اثر قوی کوهن ($d >$ ۱/۸)	اثبات ریاضی گزاره‌های ۱ و ۲ همراه با استواری آماری مطلق در شرایط تلاطم شدید

۶-۴-۳ جمع‌بندی نهایی و چشم‌انداز کلی پژوهش

با حرکت سیستم‌های نرم‌افزاری مدرن به سوی استقرار در سیستم‌های فیزیکی‌ـ سایبری حساس و بلادرنگ، مرزهای میان تصمیم‌گیری هوشمند، مهلت‌های زمانی سخت و تضمین‌های ایمنی به هم نزدیک‌تر می‌شوند. این رساله با توسعه روش پایه‌ای RS-DRL و معماری تعمیم‌یافته RS-DRL^{+} نشان داد که می‌توان از پتانسیل یادگیری تقویتی عمیق بدون گرفتار شدن در بهینه‌های محلی بهره گرفت و هم‌زمان با تلفیق سنتز هدایت‌شده و اعتبارسنجی در هر زمان، مهلت‌های زمانی سخت پروازی را رعایت نمود و شکاف میان تقریب‌های تحلیلی و فیزیک پیچیده واقعیت را مهار ساخت. یافته‌های این پژوهش، گامی استوار به سوی مهندسی سیستم‌های خودوفق هوشمند، تاب‌آور و قابل‌اعتماد در نسل آینده به شمار می‌رود.

مراجع

[1] Gartner, “The cost of downtime,” tech. rep., Gartner Research, 2014.

[2] J. O. Kephart and D. M. Chess, “The vision of autonomic computing,” *Computer*, vol.36, no.1, pp.41–50, 2003.

[3] P. Oreizy, N. Medvidovic, R. N. Taylor, D. S. Rosenblum, J. R. Robbins, M. Mikic-Rakic, N. Lekic, R. Webby, and N. Medvidovic, “An architecture-based approach to self-adaptive software,” *IEEE Intelligent Systems*, vol.14, no.3, pp.54–62, 1999.

[4] B. H. Cheng, R. de Lemos, H. Giese, P. Inverardi, J. Magee, *et al.*, “Software engineering for self-adaptive systems: A research roadmap,” in *Software Engineering for Self-Adaptive Systems*, pp.1–26, Springer, 2009.

[5] M. L. Puterman. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. John Wiley & Sons, 1994.

[6] R. S. Sutton and A. G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2018.

[7] F. Quin *et al.*, “Efficient analysis of large adaptation spaces in self-adaptive systems using machine learning,” in *2019 IEEE/ACM 14th International Symposium on Software Engineering for Adaptive and Self-Managing Systems (SEAMS)*, IEEE, 2019.

[8] F. Quin, D. Weyns, and O. Gheibi, “Reducing large adaptation spaces in self-adaptive systems using machine learning,” *Journal of Systems and Software*, p.111341, 2022.

[9] O. Gheibi and D. Weyns, “Dealing with drift of adaptation spaces in learning-based self-adaptive systems using lifelong self-adaptation,” *ACM Transactions on Autonomous and Adaptive Systems*, vol.19, no.1, pp.1–57, 2024.

[10] Z. Coker, D. Garlan, and C. L. Goues, “Sass: Self-adaptation using stochastic search,” in *10th International Symposium on Software Engineering for Adaptive and Self-Managing Systems, SEAMS 2015*, Institute of Electrical and Electronics Engineers Inc, 2015.

[11] C. Kinneer *et al.*, “Managing uncertainty in self-adaptive systems with plan reuse and stochastic search,” in *ACM/IEEE 13th International Symposium on Software Engineering for Adaptive and Self-Managing Systems, SEAMS 2018, , co-located with International Conference on Software Engineering, ICSE 2018*, IEEE Computer Society, 2018.

[12] C. Kinneer, D. Garlan, and C. L. Goues, “Information reuse and stochastic search: Managing uncertainty in self-* systems,” *ACM Transactions on Autonomous and Adaptive Systems (TAAS)*, vol.15, no.1, pp.1–36, 2021.

[13] D. Kim and S. Park, “Reinforcement learning-based dynamic adaptation planning method for architecture-based self-managed software,” in *2009 ICSE Workshop on Software Engineering for Adaptive and Self-Managing Systems*, IEEE, 2009.

[14] A. Metzger *et al.*, “Realizing self-adaptive systems via online reinforcement learning and feature-model-guided exploration,” *Computing*, pp.1–22, 2022.

[15] V. Mnih *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol.518, no.7540, pp.529–533, 2015.

[16] M. Andrychowicz, F. Wolski, A. Ray, J. Schneider, R. Fong, P. Welinder, B. McGrew, J. Tobin, P. Abbeel, and W. Zaremba, “Hindsight experience replay,” in *Advances in Neural Information Processing Systems*, vol.30, 2017.

[17] Q. He, L. Zhuang, and H. Li, “Soft hindsight experience replay,” *arXiv preprint arXiv:2002.02089*, 2020.

[18] D. Weyns *et al.*, “Deep learning for effective and efficient reduction of large adaptation spaces in self-adaptive systems,” *ACM Transactions on Autonomous and Adaptive Systems (TAAS)*, vol.17, no.1-2, pp.1–42, 2022.

[19] A. Kavianifar and S. Jalili, “RS-DRL: Managing uncertainty in self-adaptive systems based on a novel continuous deep reinforcement learning method,” *ACM Transactions on Autonomous and Adaptive Systems*, vol.21, no.3, pp.1–35, 2026.

[20] J. Kramer and J. Magee, “Self-managed software an engineering challenge,” in *Companion of the Proceeding of the 29th International Conference on Software Engineering*, pp.259–268, 2007.

[21] D. Weyns *et al.*, “Applying architecture-based adaptation to automate the management of internet-of-things,” in *Software Architecture: 12th European Conference on Software Architecture, ECSA 2018, Madrid, Spain, September 24–28, 2018, Proceedings 12*, Springer, 2018.

[22] R. De Lemos *et al.*, “Software engineering for self-adaptive systems: Research challenges in the provision of assurances,” in *Software Engineering for Self-Adaptive Systems III. Assurances: International Seminar, Dagstuhl Castle, Germany, December 15-19, 2013, Revised Selected and Invited Papers*, Springer, 2017.

[23] A. David *et al.*, “Uppaal smc tutorial,” *International journal on software tools for technology transfer*, vol.17, pp.397–415, 2015.

[24] C. J. Watkins and P. Dayan, “Q-learning,” *Machine learning*, vol.8, pp.279–292, 1992.

[25] G. A. Rummery and M. Niranjan, “On-line q-learning using connectionist systems,” tech. rep., University of Cambridge, Department of Engineering, 1994.

[26] M. U. Iftikhar *et al.*, “Deltaiot: A self-adaptive internet of things exemplar,” in *2017 IEEE/ACM 12th International Symposium on Software Engineering for Adaptive and Self-Managing Systems (SEAMS)*, IEEE, 2017.

[27] I. Gerostathopoulos, D. Weyns, S. Bogo, *et al.*, “Deltaiot: A benchmark for self-adaptive iot systems,” in *Proceedings of the 14th International Symposium on Software Engineering for Adaptive and Self-Managing Systems*, pp.66–72, 2019.

[28] M. R. Garey and D. S. Johnson. *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W. H. Freeman and Company, 1979.

[29] G. A. Moreno, C. Kinneer, A. Pandey, and D. Garlan, “Dartsim: An exemplar for evaluation and comparison of self-adaptation approaches for smart cyber-physical systems,” in *Proceedings of the 14th International Symposium on Software Engineering for Adaptive and Self-Managing Systems (SEAMS)*, pp.181–187, 2019.

[30] G. A. Moreno *et al.*, “Proactive self-adaptation under uncertainty: a probabilistic model checking approach,” in *Proceedings of the 2015 10th joint meeting on foundations of software engineering*, 2015.

[31] M. Camilli *et al.*, “Many-objective self-adaptation under model uncertainty,” *ACM Transactions on Autonomous and Adaptive Systems*, 2025.

[32] D. Weyns *et al.*, “Formal models for self-adaptation: a systematic literature review,” *ACM Transactions on Autonomous and Adaptive Systems (TAAS)*, vol.7, no.1, pp.1–36, 2012.

[33] N. Esfahani and S. Malek, “Uncertainty in self-adaptive software systems,” in *Software Engineering for Self-Adaptive Systems II*, pp.214–238, Springer, 2013.

[34] L. P. Kaelbling, M. L. Littman, and A. R. Cassandra, “Planning and acting in partially observable stochastic domains,” *Artificial intelligence*, vol.101, no.1-2, pp.99–134, 1998.

[35] Y. Du *et al.*, “Scalability and robustness of deep reinforcement learning in large discrete action spaces,” *IEEE Transactions on Neural Networks and Learning Systems*, 2023.

[36] F. Kachi and C. Bouanaka, “A hybrid model for efficient decision-making in self-adaptive systems,” *Information and Software Technology*, vol.153, p.107063, 2023.

[37] C. Kinneer *et al.*, “Building reusable repertoires for stochastic self-* planners,” in *2020 IEEE International Conference on Autonomic Computing and Self-Organizing Systems (ACSOS)*, IEEE, 2020.

[38] T. Chen *et al.*, “Femosaa: Feature-guided and knee-driven multi-objective optimization for self-adaptive software,” *ACM Transactions on Software Engineering and Methodology*, vol.27, no.2, 2018.

[39] J. Cámara, H. Muccini, and K. Vaidhyanathan, “Quantitative verification-aided machine learning: A tandem approach for architecting self-adaptive iot systems,” in *2020 IEEE International Conference on Software Architecture (ICSA)*, IEEE, 2020.

[40] G. Du, Y. Wang, Y. Liu, X. Wu, and L. Ma, “Alleviating local optima and enhancing path planning: A deep reinforcement learning approach for autonomous exploration,” in *International Conference on Autonomous Unmanned Systems*, (Singapore), pp.124–133, Springer Nature Singapore, September 2023.

[41] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward shaping: Theory and application to relation preservation,” in *ICML*, vol.99, pp.278–287, 1999.

[42] R. Calinescu, C. Ghezzi, M. Kwiatkowska, and R. Mirandola, “Formal verification of self-adaptive software systems at runtime,” *Journal of Systems and Software*, vol.84, no.12, pp.2223–2239, 2011.

[43] D. Weyns, M. U. Iftikhar, *et al.*, “Activforms: Active formal models for self-adaptation,” *ACM Transactions on Autonomous and Adaptive Systems (TAAS)*, vol.13, no.3, pp.1–41, 2018.

[44] T. P. Lillicrap *et al.*, “Continuous control with deep reinforcement learning,” *arXiv preprint arXiv:1509.02971*, 2015.

[45] H. Hansson and B. Jonsson, “A logic for reasoning about time and probability,” *Formal aspects of computing*, vol.6, no.5, pp.512–535, 1994.

[46] W. Hoeffding, “Probability inequalities for sums of bounded random variables,” *Journal of the American Statistical Association*, vol.58, no.301, pp.13–30, 1963.

[47] L. Meier, D. Honegger, and M. Pollefeys, “PX4: A modular minimal hardware architecture for low-cost autonomous vehicles,” *IEEE Journal of Selected Topics in Signal Processing*, vol.9, no.6, pp.1144–1157, 2015.

[48] F. R. Negri, N. Nicolosi, M. Camilli, and R. Mirandola, “Efficient self-adaptation through explanation-driven white-box optimization,” *ACM Transactions on Autonomous and Adaptive Systems*, vol.21, no.3, pp.24:1–24:31, 2026.

[49] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol.30, pp.4765–4774, 2017.

[50] M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. D. Cola, T. Deleu, M. Goulão, A. Kallinteris, M. Krimmel, A. KG, R. Perez-Vicente, A. Pierré, S. Schulhoff, J. J. Tai, H. Tan, and O. G. Younis, “Gymnasium: A standard interface for reinforcement learning environments,” 2024.

[51] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, “Stable-baselines3: Reliable reinforcement learning implementations,” *Journal of Machine Learning Research*, vol.22, no.268, pp.1–8, 2021.

[52] J. Van Der Donckt *et al.*, “Applying deep learning to reduce large adaptation spaces of self-adaptive systems with multiple types of goals,” in *Proceedings of the IEEE/ACM 15th International Symposium on Software Engineering for Adaptive and Self-Managing Systems*, 2020.

[53] M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, and U. Topcu, “Safe reinforcement learning via shielding,” in *Proc. Thirty-Second AAAI Conference on Artificial Intelligence (AAAI)*, pp.2669–2676, 2018.

[54] K. Deb and H. Jain, “An evolutionary many-objective optimization algorithm using reference-point-based nondominated sorting approach, part I: Solving problems with box constraints,” *IEEE Transactions on Evolutionary Computation*, vol.18, no.4, pp.577–601, 2014.

[55] R. B. Abdessalem, A. Panichella, S. Nejati, L. C. Briand, and T. Stifter, “Testing autonomous cars for feature interaction failures using many-objective search,” in *Proc. 33rd ACM/IEEE International Conference on Automated Software Engineering (ASE)*, pp.143–154, 2018.

[56] M. Kwiatkowska, G. Norman, and D. Parker, “Prism: Probabilistic symbolic model checker,” in *International Conference on Modelling Techniques and Tools for Computer Performance Evaluation*, Springer, 2002.

پیوست اول

جریان‌های کاری کامل فرآیند

پیوست دوم

لیست کامل الگوریتم‌ها

پیوست سوم

نتایج تجربی گسترده

پیوست چهارم

مصنوعات پیاده‌سازی و پکیج بازتولید

Abstract:

Contemporary self-adaptive systems (SAS) operating in cyber-physical and distributed environments face a planning trilemma within their autonomous MAPE-K loops: strict real-time control deadlines (20–50 ms), large configuration spaces dominated by over 90% failure transitions in offline logs, and the reality gap between analytical surrogate models and physical dynamics. To overcome this trilemma, this dissertation presents a progressive, two-tier architectural framework based on deep reinforcement learning. In the first tier, foundational Randomized Reward-Shaped DRL (RS-DRL) combines Deep Q-Networks (DQN) with optimistic reward injection during experience replay and asynchronous runtime formal verification via UPPAAL-SMC, enabling autonomous escape from local optima in spaces up to 4,096 options. In the second tier, to satisfy hard real-time deadlines, the architecture is generalized into RS-DRL+ (RS-DRL^{+}) via two software design patterns: Specification-Guided Offline Synthesis (SG-OS, comprising MU-RS-DRL and CM-RS-DRL), which leverages multi-constraint recoverability margins $\mathcal{M}(s, a)$ and operational utility incentives to eliminate catastrophic crashes and scale rewards; and Contract-Anytime Elastic Plan-Phase Verification (CA-EPV / PG-ALR), which provides sub-millisecond nominal proposals (0.485 ms) and confines defensive verification to a 1-hop sensitivity subspace ranked by TreeSHAP attributions. Crucially, candidate evaluations are formally bounded by $|\mathcal{N}(a_0)| \leq 2m + 1$ over m sensitive dimensions and K constraints (Proposition 1), reducing complexity to $\mathcal{O}(m \cdot K)$ and bounding worst-case latency under 3.5 ms. Empirical evaluations on the DeltaIoT benchmark demonstrate a 23.22% reduction in packet loss and a 39.07% latency reduction over competitive baselines (e.g., DLASER+). Furthermore, across 2,000 closed-loop 6-DOF physical flights in DARTSim, RS-DRL+ achieved a 70.5% mission success rate (outperforming traditional runtime shielding at 65.0%), reduced operational variance by 31%, and met all control loop deadlines, effectively bridging the surrogate-to-physics reality gap. These results demonstrate a robust, scalable, and provably bounded foundation for self-adaptive autonomous systems.

Keywords: Self-Adaptive Systems, Deep Reinforcement Learning, Randomized Reward Shaping, Cyber-Physical Systems, Anytime Verification, Reality Gap, Formal Verification, UPPAAL-SMC, Large Adaptation Spaces, DARTSim, DeltaIoT



Tarbiat Modares University

Faculty of Electrical and Computer Engineering

Randomized Reward-Shaped Deep Reinforcement Learning for Managing Uncertainty in Self-Adaptive Systems

A Thesis Submitted in Partial Fulfillment of the Requirement for the Degree of Doctor of Philosophy in Computer Engineering

By:

Alireza Kavianifar

Supervisor:

Dr. ...

Advisor:

Dr. ...

February 2026